Geometria i topologia różniczkowa

Tom II

Geometria globalna i metody topologii różniczkowej

Mapa tomów. Tom I zaczyna się w Rozdziale 1 (podstawy geometrii, algebry i topologii). Tom II zaczyna się w Rozdziale 11 (geometria globalna i metody topologii różniczkowej). Tom III zaczyna się w Rozdziale 23 (kobordyzmy i chirurgia). Tom IV zaczyna się w Rozdziale 31 (potok Ricciego oraz topologia wymiarów trzy i cztery). Odsyłacze do pozostałych tomów prowadzą do odpowiednich plików PDF.

Spis treści

11 Tensor metryczny, długość i miara **3**
11.1 Metryka w przestrzeniach stycznych . . . 3
11.2 Geometrie modelowe . . . 6
11.3 Metryki lorentzowskie: Schwarzschild, Kerr i FLRW . . . 10
11.4 Długość, energia i odległość . . . 13
11.5 Objętość wyznaczona przez metrykę . . . 16
11.6 Metryka indukowana i całki po podrozmaitości . . . 17
11.7 Miara Hausdorffa: pomiar bez map i pochodnych . . . 21
11.8 Dywergencja i twierdzenie Gaussa . . . 25

12 Koneksje i transport równoległy **28**
12.1 Dlaczego zwykła pochodna współrzędnych nie wystarcza? . . . 28
12.2 Koneksja Leviego-Civity i wzór Koszula . . . 30
12.3 Symbole Christoffela w geometriach modelowych . . . 32
12.4 Pochodna kowariantna i transport wzdłuż krzywej . . . 36
12.5 Przykłady w metrykach Schwarzschilda i Kerra . . . 39
12.6 Dlaczego koneksja pojawia się w równaniu ruchu? . . . 41

13 Geodezyjne, odwzorowanie wykładnicze i zupełność **43**
13.1 Geodezyjna i pierwsza wariacja . . . 43
13.2 Odwzorowanie wykładnicze i współrzędne normalne . . . 44
13.3 Lemat Gaussa i lokalna minimalność . . . 46
13.4 Geodezyjne w geometriach modelowych . . . 48
13.5 Twierdzenie Hopfa–Rinowa . . . 55
13.6 Miejsce cięcia i promień injektywności . . . 57
13.7 Schwarzschild i Kerr: geodezyjne czasoprzestrzeni . . . 60
13.8 Geodezyjne modelu FLRW . . . 64

14 Krzywizna: od transportu równoległego do tensorów **66**
14.1 Co mierzy krzywizna? Tensor Riemanna . . . 66
14.2 Symetrie tensora i krzywizna sekcyjna . . . 69
14.3 Krzywizna Gaussa i Theorema Egregium . . . 70
14.4 Ricci, krzywizna skalarna i przykłady modelowe . . . 71
14.5 Krzywizna Minkowskiego i modelu FLRW . . . 76
14.6 Schwarzschild i Kerr: próżnia nie oznacza płaskości . . . 77
14.7 Równania Friedmanna i osobliwość modelu FLRW . . . 80
14.8 Kiedy metryka jest naprawdę płaska? . . . 84
14.9 Holonomia: transport po wszystkich pętlach . . . 86
14.10 Niezmienniki holonomii i rozkład de Rhama . . . 88
14.11 Druga wariacja energii i pola Jacobiego . . . 90
14.12 Twierdzenia porównawcze . . . 96
14.13 Twierdzenie Gaussa–Bonneta . . . 104

II Grupy Liego i geometria globalna **112**

15 Grupy Liego i ich algebry **113**
15.1 Grupa z gładką strukturą . . . 113
15.2 Od wektora przy jedności do algebry Liego . . . 114
15.3 Podgrupy jednoparametrowe i eksponenta . . . 116
15.4 Sprzężenie i działanie adjungowane . . . 120
15.5 Od SU(2) do obrotów przestrzeni . . . 122

16 Geometria Kleina: przestrzeń i jej symetrie **126**
16.1 Działanie, orbita i stabilizator . . . 126
16.2 Metryka a wybór grupy . . . 128
16.3 Zwarte stabilizatory, właściwe działania i ilorazy . . . 129

16.4 Struktury lokalnie modelowane na przestrzeni jednorodnej . . . 133
16.5 Przestrzeń euklidesowa i afiniczna . . . 135
16.6 Przestrzeń rzutowa i sfera . . . 136
16.7 Torus: iloraz, grupa i geometria płaska . . . 137
16.8 Dysk Poincarégo jako iloraz grupy Liego . . . 137
16.9 Jak przechodzi się między geometriami . . . 138

17 Teoria Cherna–Weila i dowód wzoru Cherna–Gaussa–Bonneta 140
17.1 Wielomiany niezmiennicze i transgresja . . . 140
17.2 Znormalizowana forma kątowa . . . 141
17.3 Dowód i poprawka brzegowa . . . 142

18 Teoria Hodge'a i metoda Bochnera 144
18.1 Gwiazda Hodge'a i sprzężenie różniczki zewnętrznej . . . 144
18.2 Eliptyczność i rozkład Hodge'a . . . 146
18.3 Wzór Weitzenböcka dla form stopnia pierwszego . . . 147
18.4 Cztery wymiary: formy samodualne i sygnatura . . . 148
18.5 Trzy wzory indeksowe potrzebne dalej . . . 149

III Topologia różniczkowa, kobordyzmy i chirurgia 154

19 Twierdzenie Sarda i transwersalność 155
19.1 Wartości krytyczne i twierdzenie Sarda . . . 155
19.2 Transwersalność: precyzyjny sens przecięcia . . . 157
19.3 Brzeg i kontrola miejsca przecięcia . . . 159
19.4 Transwersalność z parametrem . . . 160
19.5 Zera przekrojów i punkty krytyczne funkcji . . . 162
19.6 Dlaczego transwersalność pojawi się u Smale'a? . . . 164

20 Zanurzenia i otoczenia podrozmaitości 166
20.1 Zanurzenia właściwe i twierdzenie Whitneya . . . 166
20.2 Wiązka normalna: kierunki poprzeczne . . . 172
20.3 Otoczenie tubularne . . . 173
20.4 Obramowanie i dane potrzebne do chirurgii . . . 174
20.5 Kołnierz brzegu i podwojenie . . . 175
20.6 Izotopie i zgodność otoczeń . . . 176
20.7 Funkcje wyczerpujące i regularne poziomice . . . 177

21 Przecięcia, dualność i klasy charakterystyczne 181
21.1 Kochainy symplicjalne i iloczyn kubkowy . . . 181
21.2 Orientacja jako klasa homologii . . . 183
21.3 Dualność Poincarégo przez komórki dualne . . . 184
21.4 Liczba przecięcia: znak i niezmienniczość . . . 186
21.5 Lokalne współczynniki i brak orientacji . . . 187
21.6 Wiązki nad sferami i funkcje sklejające . . . 188
21.7 Klasy charakterystyczne: przeszkody w kohomologii . . . 190
21.8 Klasa Eulera, zera pól i samoprzecięcie . . . 192
21.9 Twierdzenie Poincarégo–Hopfa . . . 194
21.10Forma przecięcia i przygotowanie do chirurgii . . . 196

22 Teoria Morse'a: punkty krytyczne, uchwyty i przepływ 199
22.1 Lemat Morse'a: dokładny opis w pobliżu punktu . . . 199
22.2 Przekroczenie wartości krytycznej: uchwyt . . . 200
22.3 Komórki, nierówności Morse'a i twierdzenie Reeba . . . 203
22.4 Gradient i rozmaitości trajektorii . . . 205
22.5 Warunek Morse'a–Smale'a i przestrzenie trajektorii . . . 207
22.6 Kompleks Morse'a: homologia z trajektorii . . . 209
22.7 Jak to prowadzi do Smale'a i chirurgii? . . . 214

Indeks pojęć 215

Rozdział 11

Tensor metryczny, długość i miara

Topologia mówi, które punkty są blisko w sensie otoczeń, ale sama nie podaje długości odcinka ani pola powierzchni. Na gładkiej rozmaitości możemy w każdym punkcie mierzyć wektory styczne iloczynem skalarnym. Jeżeli taki pomiar zmienia się gładko od punktu do punktu, otrzymujemy *tensor metryczny*. Z niego wyprowadzimy długość krzywej, odległość punktów, pole podrozmaitości i objętość. Na końcu połączymy te pojęcia z miarą Hausdorffa i twierdzeniem Gaussa o dywergencji.

11.1 Metryka w przestrzeniach stycznych

Definicja 11.1.1 (Metryka riemannowska)**.** Na gładkiej rozmaitości M^n *metryka riemannowska* g jest gładkim polem symetrycznych tensorów typu $(0,2)$ takim, że dla każdego $p \in M$ i $v \in T_pM \setminus \{0\}$ zachodzi $g_p(v,v) > 0$. Piszemy

$$\langle v, w\rangle_{g,p} := g_p(v,w), \qquad |v|_g := \sqrt{g_p(v,v)}.$$

Dla niezerowych v, w kąt α wyznacza $\cos\alpha = g_p(v,w)/(|v|_g|w|_g)$.

Intuicja: g_p jest linijką i kątomierzem przyłożonym do *wektorów stycznych w punkcie* p. Nie porównuje jeszcze bezpośrednio dwóch odległych punktów. Żeby to zrobić, zsumujemy później długości maleńkich wektorów prędkości wzdłuż krzywej. Współrzędne mogą deformować rysunek: okrąg jednostkowych wektorów $g_p(v,v) = 1$ bywa na kartce elipsą. To zmiana opisu, nie zmiana pomiaru geometrycznego.

W mapie $x = (x^1, \dots, x^n)$ zapisujemy

$$g = \sum_{i,j=1}^{n} g_{ij}(x)\,\mathrm{d}x^i \otimes \mathrm{d}x^j, \qquad g_{ij} = g\Big(\frac{\partial}{\partial x^i}, \frac{\partial}{\partial x^j}\Big). \tag{11.1.1}$$

Macierz $G = (g_{ij})$ jest symetryczna i dodatnio określona. Zapis $g = g_{ij}\mathrm{d}x^i\mathrm{d}x^j$ jest skrótem dla (11.1.1): nie chodzi tu o iloczyn zewnętrzny form.

Definicja 11.1.2 (Izomorfizmy muzyczne: $\flat$ i $\sharp$)**.** Niech g będzie metryką riemannowską na M. Jej niezdegenerowanie pozwala w każdym punkcie utożsamić wektory styczne z kowektorami, definiując

$$\flat_g \colon TM \longrightarrow T^*M, \qquad v \longmapsto v^\flat := g(v,\cdot), \qquad \sharp_g := \flat_g^{-1} \colon T^*M \longrightarrow TM, \quad \alpha \longmapsto \alpha^\sharp. \tag{11.1.2}$$

Wektor $\alpha^\sharp$ jest więc jednoznacznie określony warunkiem $g(\alpha^\sharp, w) = \alpha(w)$ dla każdego w. Nazwy *obniżanie* i *podnoszenie indeksu* odnoszą się do współrzędnych tych odwzorowań. Jeżeli $g =$

$g_{ij}\mathrm{d}x^i\mathrm{d}x^j$ oraz $(g^{ij}) = (g_{ij})^{-1}$, to dla $X = X^i\partial_i$ i $\alpha = \alpha_i\mathrm{d}x^i$ mamy

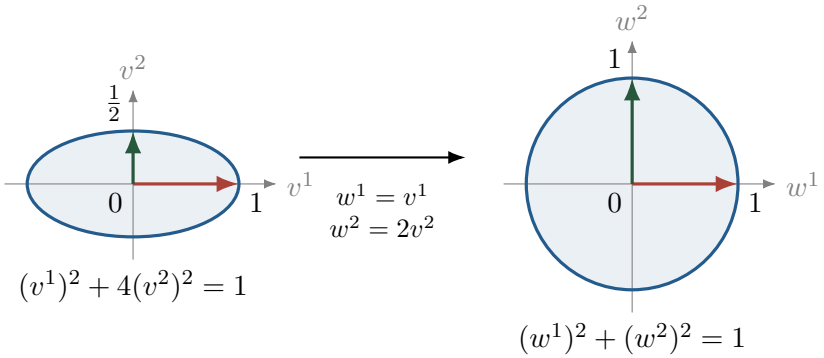
$$X^\flat = g_{ij}X^j\mathrm{d}x^i, \qquad \alpha^\sharp = g^{ij}\alpha_j\partial_i, \qquad (X^\flat)^\sharp = X, \quad (\alpha^\sharp)^\flat = \alpha. \tag{11.1.3}$$

Pierwszy wzór wynika z obliczenia współczynników kowektora: $(X^\flat)_i = X^\flat(\partial_i) = g(X^j\partial_j, \partial_i) = g_{ij}X^j$. Jeżeli $Y = \alpha^\sharp$, to warunek $g(Y, \partial_i) = \alpha_i$ daje układ $g_{ij}Y^j = \alpha_i$. Mnożąc go przez g^{ki} i używając $g^{ki}g_{ij} = \delta^k_j$, otrzymujemy $Y^k = g^{ki}\alpha_i$. Ta sama tożsamość macierzy odwrotnych dowodzi dwóch ostatnich równości w (11.1.3). Tak samo podnosimy i obniżamy wybrane indeksy tensorów. Dla tensora $S = S_{ij}\mathrm{d}x^i \otimes \mathrm{d}x^j$ otrzymujemy $(S^{\sharp_1})^i{}_j = g^{ik}S_{kj}$ i $(S^{\sharp_1\sharp_2})^{ij} = g^{ik}g^{j\ell}S_{k\ell}$; należy wskazać, który indeks podnosimy. W szczególności $(g^{\sharp_1})^i{}_j = \delta^i_j$. Definicja pozostaje poprawna dla każdej niezdegenerowanej metryki pseudoriemannowskiej, także lorentzowskiej; dodatnia określoność nie jest tu potrzebna.

Uzasadnijmy użyte w definicji słowo „izomorfizm". Jeżeli $v^\flat = 0$, to $g(v, w) = 0$ dla każdego w, a więc niezdegenerowanie daje $v = 0$. Wymiary T_pM i T_p^*M są równe, zatem liniowa iniekcja $\flat_g$ jest bijekcją na każdym włóknie. Gładkość jej odwrotności wynika z gładkości $G^{-1} = (\det G)^{-1}\operatorname{adj} G$, bo $\det G \neq 0$. Otrzymujemy więc izomorfizmy gładkich wiązek, a nie tylko pojedynczych przestrzeni wektorowych.

Przykład 11.1.3 (obniżanie i podnoszenie indeksów)**.** Na $\mathbb{R}^2$ rozważmy $g = \mathrm{d}x^2 + 4\mathrm{d}y^2$. Dla $X = \partial_x + 3\partial_y$ oraz $\alpha = 2\mathrm{d}x + 8\mathrm{d}y$ zachodzi $X^\flat = \mathrm{d}x + 12\mathrm{d}y$ i $\alpha^\sharp = 2\partial_x + 2\partial_y$. Istotnie, macierz metryki to $G = \operatorname{diag}(1, 4)$, a jej odwrotność wynosi $G^{-1} = \operatorname{diag}(1, 1/4)$. Widać, że $X^\flat$ nie jest jedynie zmianą sposobu zapisania tych samych współczynników: zależy od metryki.

Dla metryki Minkowskiego $g_M = -c^2\mathrm{d}t^2 + \mathrm{d}x^2 + \mathrm{d}y^2 + \mathrm{d}z^2$ mamy natomiast $(\partial_t)^\flat = -c^2\mathrm{d}t$ oraz $(\mathrm{d}t)^\sharp = -c^{-2}\partial_t$. Znak minus wynika z sygnatury lorentzowskiej. W szczególności, jeżeli $U = \partial_t$ i $c = 1$, to $U^\flat = -\mathrm{d}t$; tego zapisu użyjemy później w tensorze energii i pędu płynu doskonałego.



Rysunek 11.1: Te same wektory jednostkowe dla $g = \mathrm{d}x^2 + 4\mathrm{d}y^2$ w dwóch bazach przestrzeni stycznej. W bazie (∂_x, ∂_y) tworzą elipsę; w bazie ortonormalnej $(\partial_x, \frac{1}{2}\partial_y)$ tworzą okrąg. Oba zaznaczone wektory mają długość 1.

Stwierdzenie 11.1.4 (Zmiana współrzędnych)**.** *Jeżeli $x = x(y)$ na przecięciu dwóch map i $J = (\partial x^i/\partial y^a)$, to*

$$G_y = J^\mathsf{T}G_xJ, \qquad \det G_y = (\det J)^2 \det G_x.$$

Dowód. Reguła łańcuchowa daje $\partial/\partial y^a = \sum_i (\partial x^i/\partial y^a)\partial/\partial x^i$. Wstawmy tę równość dwa razy do $g(\partial/\partial y^a, \partial/\partial y^b)$. Otrzymamy $(G_y)_{ab} = \sum_{i,j} J_{ia}(G_x)_{ij}J_{jb}$, czyli pierwszy wzór. Wyznacznik iloczynu macierzy i $\det J^\mathsf{T} = \det J$ dają drugi. W szczególności dodatnia określoność nie zależy od wyboru współrzędnych: $w^\mathsf{T}G_yw = (Jw)^\mathsf{T}G_x(Jw) > 0$ dla $w \neq 0$. □

Cofnięcie i przeniesienie metryki

Zapis f^*h jest szczególnym przypadkiem cofnięcia tensora z Definicji 3.9.1. Warto tu rozdzielić dwie czynności: *cofnięcie* metryki z przestrzeni docelowej na dziedzinę oraz *przeniesienie* metryki z dziedziny na cel przez dyfeomorfizm. Nazwy angielskie to odpowiednio *pullback* i *pushforward*.

Definicja 11.1.5 (Pullback i pushforward metryki)**.** Niech $f : M \to N$ będzie gładkim odwzorowaniem, a h metryką riemannowską na N. *Cofnięty tensor* f^*h na M jest określony przez

$$(f^*h)_p(v,w) = h_{f(p)}(\mathrm{d}f_p v, \mathrm{d}f_p w), \qquad v, w \in T_pM. \tag{11.1.4}$$

Jeśli f jest immersją, f^*h jest metryką riemannowską, zwaną metryką indukowaną.

Jeżeli f jest dyfeomorfizmem i g jest metryką na M, definiujemy *przeniesioną metrykę* na N wzorem

$$(f_*g)_q(u,w) := g_{f^{-1}(q)}(\mathrm{d}(f^{-1})_q u, \mathrm{d}(f^{-1})_q w), \qquad f_*g = (f^{-1})^* g. \tag{11.1.5}$$

W (11.1.4) dwa wektory z T_pM przenosimy różniczką do $T_{f(p)}N$ i mierzymy tam za pomocą h. Dlatego do cofnięcia tensora typu $(0,2)$ *nie* jest potrzebna odwrotność f. Jeżeli $\mathrm{d}f_p$ ma jądro, wektor $v \neq 0$ z tego jądra ma $(f^*h)_p(v,v) = 0$; wtedy cofnięty tensor nie jest metryką riemannowską. Na przykład dla $f : \mathbb{R}^2 \to \mathbb{R}$, $f(x,y) = x$, cofnięcie $\mathrm{d}t^2$ to $\mathrm{d}x^2$, które nie mierzy wektora ∂_y. Przy pushforwardzie trzeba zaś umieć odtworzyć jednoznacznie wektor w punkcie $f^{-1}(q)$; dyfeomorfizm to gwarantuje.

Stwierdzenie 11.1.6 (Co daje dyfeomorfizm?)**.** *Niech $f : M \to N$ będzie dyfeomorfizmem. Wtedy f^*h i f_*g są metrykami riemannowskimi, a operacje są wzajemnie odwrotne:*

$$f^*(f_*g) = g, \qquad f_*(f^*h) = h.$$

Dyfeomorfizm $f : (M,g) \to (N,h)$ jest izometrią wtedy i tylko wtedy, gdy $f^*h = g$, równoważnie $f_*g = h$. W tym przypadku zachowuje długości krzywych, odległość punktów, kąty, geodezyjne i tensor krzywizny.

Dowód. Jeśli $v \neq 0$, to $\mathrm{d}f_p v \neq 0$, bo różniczka dyfeomorfizmu jest odwracalna. Zatem $(f^*h)_p(v,v) = h_{f(p)}(\mathrm{d}f_p v, \mathrm{d}f_p v) > 0$; gładkość i symetria wynikają ze wzoru. Analogicznie jest dla f_*g. Równość $\mathrm{d}(f^{-1})_{f(p)} \circ \mathrm{d}f_p = \mathrm{Id}$ daje

$$\big(f^*(f_*g)\big)_p(v,w) = (f_*g)_{f(p)}(\mathrm{d}f_p v, \mathrm{d}f_p w) = g_p(v,w).$$

Po zamianie f z f^{-1} otrzymujemy drugą tożsamość. Warunek $f^*h = g$ mówi dokładnie, że $\mathrm{d}f_p$ zachowuje iloczyn skalarny wszystkich wektorów stycznych; jest to definicja izometrii. Dla każdej odcinkami gładkiej krzywej $\gamma : [a,b] \to M$ reguła łańcuchowa daje

$$L_h(f \circ \gamma) = \int_a^b \sqrt{h_{f(\gamma(t))}(\mathrm{d}f\,\dot\gamma, \mathrm{d}f\,\dot\gamma)}\,\mathrm{d}t = \int_a^b \sqrt{g_{\gamma(t)}(\dot\gamma,\dot\gamma)}\,\mathrm{d}t = L_g(\gamma).$$

Ponieważ f i f^{-1} przenoszą wszystkie drogi między odpowiednimi punktami, branie kresu dolnego ich długości daje $d_h(f(p),f(q)) = d_g(p,q)$. Twierdzenia o zachowaniu geodezyjnych i krzywizny są zapowiedzią pojęć z dwóch następnych rozdziałów. Poniższy akapit można przeczytać po poznaniu koneksji Leviego-Civity i definicji krzywizny; pozostała część obecnego rozdziału nie korzysta z tych dwóch własności. Sprawdźmy je, używając wskazanych tam definicji. Dla pól na M połóżmy

$$\widetilde{\nabla}_X Y := (f^{-1})_*(\nabla^h_{f_*X}(f_*Y)).$$

Ponieważ $f_*[X,Y] = [f_*X, f_*Y]$, torsja tej koneksji jest zerowa. Zgodność ∇^h z h oraz $g(Y,Z) = h(f_*Y, f_*Z) \circ f$ daje

$$Xg(Y,Z) = g(\widetilde{\nabla}_X Y, Z) + g(Y, \widetilde{\nabla}_X Z).$$

Z jednoznaczności w Twierdzeniu 12.2.1 wynika $\widetilde{\nabla} = \nabla^g$. Stąd $f_*(\nabla^g_{\dot\gamma}\dot\gamma) = \nabla^h_{(f\circ\gamma)'}(f\circ\gamma)'$, więc obrazy geodezyjnych są geodezyjnymi. Podstawienie tej równości do definicji (14.1.1) pokazuje, że $\mathrm{d}f_p$ przenosi też operator krzywizny. □

W mapach, jeśli J_f jest macierzą różniczki f, to (11.1.4) przyjmuje postać

$$G_{f^*h}(x) = J_f(x)^{\mathsf{T}} H(f(x)) J_f(x).$$

W szczególności wzór $G_y = J^{\mathsf{T}} G_x J$ ze Stwierdzenia 11.1.4 jest cofnięciem *tej samej* metryki przy zmianie współrzędnych. Współczynniki się zmieniają, lecz odległości mierzone na rozmaitości pozostają te same.

Przykład 11.1.7 (Dwa kierunki przekształcenia)**.** Dyfeomorfizm $f : \mathbb{R}^2_{u,v} \to \mathbb{R}^2_{x,y}$, $f(u,v) = (u, v+u^2)$, ma odwrotność $f^{-1}(x,y) = (x, y-x^2)$. Cofając metrykę euklidesową przestrzeni docelowej, znajdujemy

$$f^*(\mathrm{d}x^2 + \mathrm{d}y^2) = \mathrm{d}u^2 + (\mathrm{d}v + 2u\,\mathrm{d}u)^2.$$

Przenosząc w przeciwną stronę metrykę euklidesową dziedziny, dostajemy

$$f_*(\mathrm{d}u^2 + \mathrm{d}v^2) = \mathrm{d}x^2 + (\mathrm{d}y - 2x\,\mathrm{d}x)^2.$$

To *dwie różne* metryki zapisane na dwóch różnych dziedzinach. Pierwsza sprawia, że $f : (\mathbb{R}^2, f^*h_{\mathrm{E}}) \to (\mathbb{R}^2, h_{\mathrm{E}})$ jest izometrią; druga sprawia, że $f : (\mathbb{R}^2, g_{\mathrm{E}}) \to (\mathbb{R}^2, f_*g_{\mathrm{E}})$ jest izometrią. Choć współczynniki zależą od punktu, obie są płaskie, bo powstały przez przeniesienie metryki euklidesowej.

Twierdzenie 11.1.8 (Istnienie metryki riemannowskiej)**.** *Każda gładka rozmaitość Hausdorffa o przeliczalnej bazie, również z brzegiem, ma metrykę riemannowską.*

Dowód. Wybierzmy pokrycie mapami (U_α, x_α). W każdej mapie przenieśmy standardowy iloczyn skalarny z $\mathbb{R}^n$ na wektory styczne:

$$(g_\alpha)_p(v,w) = \sum_{i=1}^{n} \mathrm{d}x^i_{\alpha p}(v)\,\mathrm{d}x^i_{\alpha p}(w).$$

To dodatnio określony, gładki tensor na U_α, bo $\mathrm{d}x_{\alpha,p} : T_pM \to \mathbb{R}^n$ jest izomorfizmem. Twierdzenie 10.4.1 daje gładki podział jedności (ρ_j) z $\operatorname{supp}\rho_j \subset U_{\alpha(j)}$. Każdy tensor $\rho_j g_{\alpha(j)}$ przedłużamy przez zero poza odpowiadającą mu mapę i kładziemy $g = \sum_j \rho_j g_{\alpha(j)}$. To przedłużenie jest gładkie: jeśli punkt nie należy do $U_{\alpha(j)}$, to nie należy też do domkniętego zbioru $\operatorname{supp}\rho_j$, więc w pewnym jego otoczeniu przedłużony tensor jest identycznie zerowy. Suma jest lokalnie skończona, zatem gładka. Jeżeli $v \neq 0$ w punkcie p, to dla wszystkich j składniki $\rho_j(p)(g_{\alpha(j)})_p(v,v)$ są nieujemne, a przynajmniej jeden jest dodatni: $\sum_j \rho_j(p) = 1$, więc istnieje j z $\rho_j(p) > 0$. Stąd $g_p(v,v) > 0$. Ta sama konstrukcja działa w mapach przybrzegowych. □

Twierdzenie zapewnia *istnienie*, nie wskazuje jednego wyróżnionego wyboru. Na przykład na $\mathbb{R}^n$, $n \geq 1$, metryki $\sum_i (\mathrm{d}x^i)^2$ i $e^{2f(x)}\sum_i (\mathrm{d}x^i)^2$ są różne dla niezerowej funkcji gładkiej f. Druga mnoży długości wektorów w x przez $e^{f(x)}$, a objętości n-wymiarowe przez $e^{nf(x)}$.

11.2 Geometrie modelowe

Przykład 11.2.1 (Przestrzeń euklidesowa)**.** Na $\mathbb{R}^n$ bierzemy $g_{\mathrm{E}} = \sum_i (\mathrm{d}x^i)^2$. Wtedy $G = I_n$ i $|v|_g = \sqrt{\sum_i (v^i)^2}$. To punkt odniesienia dla kolejnych modeli.

Przykład 11.2.2 (Sfera)**.** Dla $R > 0$ sfera $S^2_R = \{x \in \mathbb{R}^3 : |x| = R\}$ otrzymuje metrykę przez ograniczenie euklidesowego iloczynu skalarnego do $T_p S^2_R$. Parametryzacja

$$F(\theta, \phi) = R(\sin\theta\cos\phi, \sin\theta\sin\phi, \cos\theta)$$

ma wektory pochodne

$$F_\theta = R(\cos\theta\cos\phi, \cos\theta\sin\phi, -\sin\theta), \quad F_\phi = R(-\sin\theta\sin\phi, \sin\theta\cos\phi, 0).$$

Ich iloczyny skalarne wynoszą kolejno R^2, 0 i $R^2\sin^2\theta$. Zatem

$$g_{S^2_R} = R^2 \mathrm{d}\theta^2 + R^2\sin^2\theta\,\mathrm{d}\phi^2. \tag{11.2.1}$$

Długość przy zmianie samego kąta biegunowego θ jest inna niż przy zmianie ϕ blisko bieguna: równoleżniki stają się tam krótkie. Zanik $\sin\theta$ na biegunie nie oznacza degeneracji metryki; współrzędna ϕ nie jest tam poprawną współrzędną lokalną.

Dla S^n_R współrzędne stereograficzne $u \in \mathbb{R}^n$ z mapą odwrotną

$$s(u) = \left(\frac{2R^2 u}{R^2 + |u|^2}, R\frac{|u|^2 - R^2}{R^2 + |u|^2}\right)$$

dają

$$s^* g_{S^n_R} = \left(\frac{2R^2}{R^2 + |u|^2}\right)^2 \sum_i (\mathrm{d}u^i)^2. \tag{11.2.2}$$

Rzeczywiście, dla $q = R^2 + |u|^2$ i wektora h różniczka dwóch składowych s ma postać

$$\mathrm{d}s_u(h) = \left(\frac{2R^2 h}{q} - \frac{4R^2 u(u\cdot h)}{q^2}, \frac{4R^3(u\cdot h)}{q^2}\right).$$

W kwadracie normy współczynnik przy $(u\cdot h)^2$ wynosi

$$-\frac{16R^4}{q^3} + \frac{16R^4|u|^2 + 16R^6}{q^4} = 0,$$

bo $|u|^2 + R^2 = q$. Zostaje $4R^4|h|^2/q^2$. Wzór polaryzacyjny $2g(h,k) = g(h+k, h+k) - g(h,h) - g(k,k)$ odtwarza iloczyny mieszane i daje (11.2.2).

Przykład 11.2.3 (Trzy modele przestrzeni hiperbolicznej)**.** Niech $n \geq 2$. W *modelu półprzestrzeni* punkty mają współrzędne $(x, y) \in \mathbb{R}^{n-1} \times (0, \infty)$, a metryka jest

$$g_{\mathbb{H}} = \frac{|\,\mathrm{d}x\,|^2 + \mathrm{d}y^2}{y^2}. \tag{11.2.3}$$

Przy małej wysokości y ten sam ruch euklidesowy staje się długi hiperbolicznie.

W *modelu kuli Poincarégo* $B^n = \{|u| < 1\}$,

$$g_B = \frac{4\sum_i (\mathrm{d}u^i)^2}{(1 - |u|^2)^2}. \tag{11.2.4}$$

Brzeg kuli nie należy do przestrzeni. Wreszcie *model hiperboloidy* jest górnym płatem

$$\mathcal{H}^n = \{(t, z) \in \mathbb{R}\times\mathbb{R}^n : t^2 - |z|^2 = 1,\ t > 0\}$$

z ograniczeniem formy $-\mathrm{d}t^2 + \sum_i (\mathrm{d}z^i)^2$ do wektorów stycznych. Choć forma w otoczeniu ma znak minus, jej ograniczenie do $T\mathcal{H}^n$ jest dodatnio określone. Jeśli (a, w) jest styczny, to $ta = z\cdot w$ i

$$|w|^2 - a^2 = |w|^2 - \frac{(z\cdot w)^2}{t^2} \geq \frac{|w|^2}{t^2} > 0 \quad \text{dla } (a,w) \neq 0.$$

Możemy także opisać hiperboloidę *samymi współrzędnymi przestrzennymi* $z \in \mathbb{R}^n$:

$$Q(z) = (\sqrt{1+|z|^2}, z), \qquad (g_{\mathcal{H}})_{ij} = \delta_{ij} - \frac{z_i z_j}{1+|z|^2}. \tag{11.2.5}$$

Istotnie, dla $t(z) = \sqrt{1+|z|^2}$ mamy $\partial_i t = z_i/t$, toteż ograniczenie $-\mathrm{d}t^2 + |\mathrm{d}z|^2$ do wykresu Q daje (11.2.5). Na wektorach prostopadłych do z macierz G ma wartość własną 1, a w kierunku z wartość $1/(1+|z|^2)$. Stąd, również przy $z=0$ przez ciągłość,

$$G^{-1} = I + zz^{\mathsf{T}}, \qquad \det G = \frac{1}{1+|z|^2}. \tag{11.2.6}$$

Równość dla macierzy odwrotnej można sprawdzić mnożąc $(I - zz^{\mathsf{T}}/t^2)(I+zz^{\mathsf{T}})$ i używając $t^2 = 1+|z|^2$.

Dlaczego to ta sama geometria? Odwzorowanie

$$P : B^n \longrightarrow \mathcal{H}^n, \qquad P(u) = \left(\frac{1+|u|^2}{1-|u|^2}, \frac{2u}{1-|u|^2}\right)$$

ma odwrotność $u = z/(t+1)$. Dla $q = 1-|u|^2$ różniczkujemy:

$$\mathrm{d}t = \frac{4(u\cdot \mathrm{d}u)}{q^2}, \qquad \mathrm{d}z = \frac{2\,\mathrm{d}u}{q} + \frac{4u(u\cdot \mathrm{d}u)}{q^2}.$$

Po podniesieniu do kwadratu w $|\,\mathrm{d}z\,|^2 - \mathrm{d}t^2$ współczynnik przy $(u\cdot \mathrm{d}u)^2$ jest $16(q+|u|^2-1)/q^4 = 0$. Pozostaje dokładnie $4|\,\mathrm{d}u\,|^2/q^2$, czyli $P^* g_{\mathcal{H}} = g_B$.

Kula przechodzi na półprzestrzeń przez

$$F(u) = \left(\frac{2v}{D}, \frac{1-|u|^2}{D}\right), \quad u = (v,s), \quad D = |v|^2 + (s-1)^2.$$

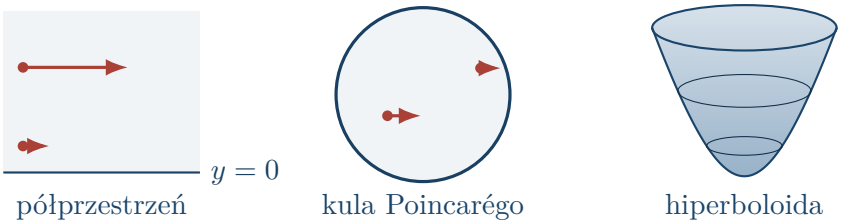
Jest to dyfeomorfizm: dla (x,y) z $y>0$ odwrotność ma postać

$$F^{-1}(x,y) = \left(\frac{2x}{E}, \frac{|x|^2+y^2-1}{E}\right), \quad E = |x|^2 + (y+1)^2.$$

Mianownik D nie znika w kuli, gdyż punkt $(0,1)$ leży na jej brzegu. Odwrotność przyjmuje wartości w kuli, bo $1-|F^{-1}(x,y)|^2 = 4y/E > 0$; podstawienie w obu kierunkach daje odwzorowania tożsamościowe. Aby sprawdzić metrykę bez długiego rozwijania, połóżmy $w = u - e_n$. Wówczas $F(u) = (2w'/|w|^2, -1 - 2w_n/|w|^2)$. Widać więc przesunięcia, inwersję $w \mapsto w/|w|^2$, jednokładność o skali 2 i odbicie ostatniej współrzędnej. Różniczka inwersji to $|w|^{-2}(I - 2ww^{\mathsf{T}}/|w|^2)$; macierz w nawiasie jest ortogonalna: dla rzutu $\Pi = ww^{\mathsf{T}}/|w|^2$ mamy $\Pi^{\mathsf{T}} = \Pi$, $\Pi^2 = \Pi$, a więc $(I-2\Pi)^{\mathsf{T}}(I-2\Pi) = I$. Zatem $|\,\mathrm{d}F_u(h)\,| = 2|h|/D$. Współrzędna wysokości wynosi $y = (1-|u|^2)/D$, więc

$$F^* g_{\mathbb{H}}(h,h) = \frac{4|h|^2/D^2}{(1-|u|^2)^2/D^2} = g_B(h,h).$$

Oba odwzorowania zachowują więc długości wektorów i krzywych. Sfera i przestrzeń hiperboliczna są zakrzywione inaczej; formalny opis ich krzywizny odłożymy do rozdziału o tensorze krzywizny.



Rysunek 11.2: Trzy zapisy tej samej geometrii hiperbolicznej. Czerwone strzałki przedstawiają wektory o długości hiperbolicznej 1: taki wektor ma różną długość na euklidesowym rysunku półprzestrzeni i kuli. Linia $y = 0$ oraz okrąg brzegowy nie należą do rozmaitości. Rysunek hiperboloidy przedstawia fragment górnego płata; jego profil jest gładki także w najniższym punkcie.

Przykład 11.2.4 (Objętość i anizotropia w geometriach Nil i Sol)**.** W rozdziale o geometryzacji przedstawimy dwie jednorodne metryki trójwymiarowe, które nie mają stałej krzywizny sekcyjnej: $g_N = (\mathrm{d}x)^2 + (\mathrm{d}y)^2 + (\mathrm{d}z - x\,\mathrm{d}y)^2$ oraz $g_S = e^{-2t}(\mathrm{d}x)^2 + e^{2t}(\mathrm{d}y)^2 + (\mathrm{d}t)^2$. Obie są dodatnio określone: w pierwszej trzy formy podnoszone do kwadratu tworzą bazę kowektorów, a w drugiej wszystkie współczynniki diagonalne są dodatnie. Zbadamy teraz ich macierze i elementy objętości. Korzystamy ze wzoru $\mathrm{vol}_g = \sqrt{\det G}\,\mathrm{d}x^1 \wedge \cdots \wedge \mathrm{d}x^n$, który uzasadnimy w Sekcji 11.5.

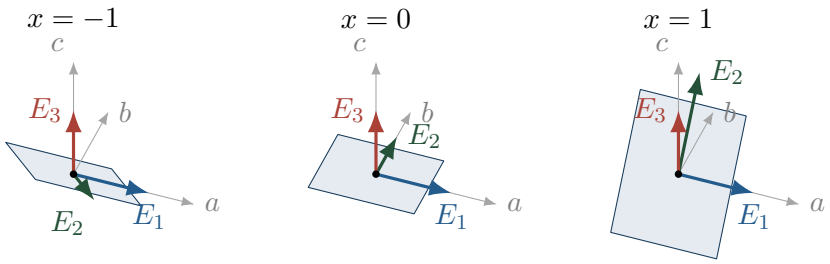
Dla g_N macierz w mapie (x, y, z) ma postać

$$G_N = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 + x^2 & -x \\ 0 & -x & 1 \end{pmatrix}, \qquad \det G_N = 1.$$

Zatem riemannowska forma objętości przy orientacji (x, y, z) to $\mathrm{d}x \wedge \mathrm{d}y \wedge \mathrm{d}z$, mimo że współczynniki metryki zależą od x. W modelu Sol macierz jest diagonalna, $G_S = \mathrm{diag}(e^{-2t}, e^{2t}, 1)$, więc także $\det G_S = 1$ i $\mathrm{vol}_{g_S} = \mathrm{d}x \wedge \mathrm{d}y \wedge \mathrm{d}t$. Dla poziomego wektora $v = a\partial_x + b\partial_y$ w Sol mamy $|v|^2_{g_S} = e^{-2t}a^2 + e^{2t}b^2$: odcinki równoległe do dwóch osi podlegają przeciwnym zmianom skali, chociaż element objętości jest niezmienny. W Nil z kolei forma $\theta = \mathrm{d}z - x\,\mathrm{d}y$ mierzy składową wektora w wyróżnionym kierunku pionowym. Wzór na objętość nie rozstrzyga zatem ani o płaskości, ani o izotropii metryki; dokładny rachunek krzywizn przeprowadzimy w Rozdziale 14.

Nil: nachylenie płaszczyzn poziomych. Dla wektora $v = a\partial_x + b\partial_y + c\partial_z$ metryka z poprzedniego przykładu daje $|v|^2_{g_N} = a^2 + b^2 + (c - xb)^2$. W każdym punkcie pola $E_1 = \partial_x$, $E_2 = \partial_y + x\partial_z$ i $E_3 = \partial_z$ tworzą więc bazę ortonormalną: trójki wartości form $(\mathrm{d}x, \mathrm{d}y, \mathrm{d}z - x\,\mathrm{d}y)$ na tych wektorach to kolejno $(1, 0, 0)$, $(0, 1, 0)$ i $(0, 0, 1)$.

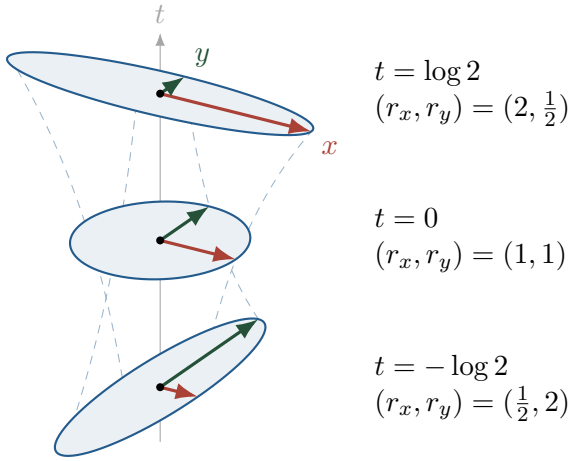
Płaszczyzna $\mathcal{H}_p = \ker(\mathrm{d}z - x\,\mathrm{d}y)_p$ jest rozpięta przez E_1, E_2; nazywamy ją tutaj poziomą. Jej równanie $c = xb$ pokazuje, jak nachylenie względem płaszczyzny $c = 0$ zależy od x (Rysunek 11.3). Znaczenie tych płaszczyzn dla podnoszenia krzywych rozwiniemy w Przykładzie 33.2.2.



Rysunek 11.3: Nil w przestrzeniach stycznych przy $p_x = (x, 0, 0)$. Płatki przedstawiają płaszczyzny $c = xb$ we współczynnikach (a, b, c) wektora. Strzałki E_1, E_2, E_3 mają długość 1 i są wzajemnie prostopadłe w g_N; ich kąty na rysunku wynikają z opisu współrzędnymi i z perspektywy.

Sol: przeciwne zmiany skali. Przy $p_t = (0, 0, t)$ poziomy wektor $v = a\partial_x + b\partial_y$ ma długość jednostkową wtedy, gdy $e^{-2t}a^2 + e^{2t}b^2 = 1$. W płaszczyźnie współczynników (a, b) jest to elipsa o półosiach $r_x = e^t$, $r_y = e^{-t}$. Jej końce na osiach odpowiadają jednostkowym wektorom $e^t\partial_x$ i $e^{-t}\partial_y$. Zarazem wektory współrzędnych ∂_x, ∂_y mają długości odwrotne: odpowiednio e^{-t}, e^t.

Na Rysunku 11.4 przenosimy te elipsy z przestrzeni stycznych do ich punktów bazowych. Iloczyn półosi stale wynosi $r_x r_y = 1$: wzrost jednej dokładnie równoważy zmniejszenie drugiej. Jest to widoczny na rysunku odpowiednik równości $\det G_S = 1$, bo także pionowy wektor ∂_t ma długość 1.



Rysunek 11.4: Sol: poziome jednostkowe elipsy w $T_{(0,0,t)}M$, przedstawione w perspektywie we współrzędnych. Czerwone strzałki są równoległe do ∂_x, zielone do ∂_y; każda ma długość 1. Linie przerywane łączą końce odpowiednich półosi. Elipsy obrazują normę wektorów stycznych, nie kule odległości d_{g_S} w rozmaitości.

11.3 Metryki lorentzowskie: Schwarzschild, Kerr i FLRW

Definicja 11.3.1 (Metryka lorentzowska)**.** Metryka pseudoriemannowska jest gładkim, symetrycznym, *niezdegenerowanym* tensorem typu $(0, 2)$; dopuszczamy ujemne wartości $g(v, v)$. W czterech wymiarach metryka o jednym kierunku ujemnym i trzech dodatnich ma sygnaturę $(-, +, +, +)$ i nazywa się *lorentzowską*.

Tu słowo „metryka” oznacza tensor, a nie funkcję odległości na parach punktów. Dla wektora czasopodobnego v może być $g(v, v) < 0$, a dla niezerowego wektora światłopodobnego $g(v, v) = 0$.

Wzory na riemannowską długość i odległość z następnej sekcji nie stosują się do całej takiej czasoprzestrzeni.

Przykład 11.3.2 (urojona współrzędna czasowa Poincarégo)**.** W pracy *Sur la dynamique de l'électron*, przedłożonej w 1905 roku i opublikowanej w tomie z 1906 roku, Henri Poincaré interpretował transformacje Lorentza jako obroty w czterowymiarowej przestrzeni z urojoną współrzędną czasową. Nie jest to jeszcze ogólna teoria względności: rozważana geometria jest płaska.

Na $M = \mathbb{R}^4$, we współrzędnych (t, x, y, z), rozważmy metrykę Minkowskiego

$$g_M = -c^2 \mathrm{d}t^2 + \mathrm{d}x^2 + \mathrm{d}y^2 + \mathrm{d}z^2. \tag{11.3.1}$$

Ma ona sygnaturę $(-,+,+,+)$. W dalszych przykładach 13.4.4 i 14.5.1 obliczymy jej koneksję, geodezyjne i pełny tensor krzywizny, a następnie sprawdzimy regularność hiperpowierzchni $t = 0$.

Wprowadźmy $\zeta = \mathrm{i}ct$, gdzie $\mathrm{i}^2 = -1$. Wtedy $\mathrm{d}\zeta = \mathrm{i}c\,\mathrm{d}t$ i formalnie

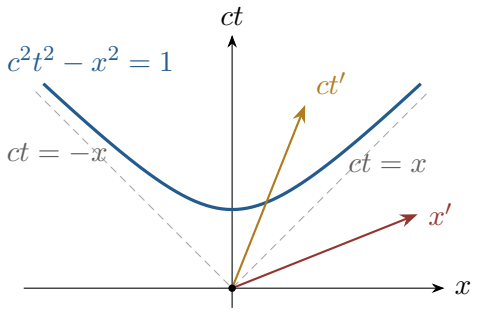
$$g_M = \mathrm{d}x^2 + \mathrm{d}y^2 + \mathrm{d}z^2 + \mathrm{d}\zeta^2. \tag{11.3.2}$$

Nie jest to dodatnio określona metryka na rzeczywistej czasoprzestrzeni: $\zeta \in \mathrm{i}\mathbb{R}$, nie zaś $\mathbb{R}$. Ściślej, na $\mathbb{C}^4$ rozważmy *zespoloną symetryczną formę dwuliniową* (nie hermitowską) $h = \sum_{j=1}^{4} \mathrm{d}z_j^2$ i odwzorowanie $F\colon \mathbb{R}^4 \to \mathbb{C}^4$ dane przez $F(t,x,y,z) = (x, y, z, \mathrm{i}ct)$. Wówczas $F^*h = g_M$. Jest to algebraiczne przedstawienie tej samej rzeczywistej metryki lorentzowskiej za pomocą formy zespolonej.

Dla prędkości $|v| < c$ połóżmy $\beta = v/c$ oraz $\gamma = (1-\beta^2)^{-1/2}$. Transformacja Lorentza w kierunku osi x jest dana wzorami $x' = \gamma(x - vt)$, $t' = \gamma(t - vx/c^2)$, $y' = y$, $z' = z$. Ponieważ $t = -\mathrm{i}\zeta/c$, podstawienie daje $x' = \gamma(x + \mathrm{i}\beta\zeta)$ oraz $\zeta' = \mathrm{i}ct' = \gamma(\zeta - \mathrm{i}\beta x)$. Zatem w zmiennych (x, ζ) transformacja przyjmuje postać

$$\begin{pmatrix} x' \\ \zeta' \end{pmatrix} = \gamma \begin{pmatrix} 1 & \mathrm{i}\beta \\ -\mathrm{i}\beta & 1 \end{pmatrix} \begin{pmatrix} x \\ \zeta \end{pmatrix}. \tag{11.3.3}$$

Macierz A tego przekształcenia spełnia $A^{\mathsf{T}} A = \gamma^2(1-\beta^2) I = I$ oraz $\det A = \gamma^2(1-\beta^2) = 1$, czyli $A \in SO(2,\mathbb{C})$. Jeśli $\beta = \tanh\varphi$, to $\gamma = \cosh\varphi$ i $\gamma\beta = \sinh\varphi$: uzyskujemy obrotową macierz o *zespolonym* kącie $-\mathrm{i}\varphi$. W rzeczywistych współrzędnych jest to obrót hiperboliczny, zachowujący $x^2 + y^2 + z^2 - c^2t^2$ oraz stożek świetlny, a nie zwykły obrót euklidesowy.



Rysunek 11.5: Przekrój czasoprzestrzeni Minkowskiego (x, ct). Transformacja Lorentza zachowuje proste zerowe $ct = \pm x$ i hiperbole stałego interwału. Osie (x', ct') układu poruszającego się ($\beta = 0{,}4$) nie powstają przez obrót euklidesowy.

Podstawienie $\zeta = \mathrm{i}ct$ nie jest zatem rzeczywistą zmianą współrzędnych ani procedurą usuwania osobliwości. Prawo bezwładności Sylvestera wyklucza zamianę sygnatury lorentzowskiej na riemannowską przez rzeczywistą zmianę bazy.

W poniższych dwóch przykładach używamy jednostek geometrycznych $G = c = 1$. W jednostkach fizycznych parametr masy ma wymiar długości: $M = GM_{\text{fiz}}/c^2$, gdzie M_{fiz} jest masą ciała, G stałą grawitacji, a c prędkością światła. Współrzędna t ma wtedy wymiar długości ($t = c\,t_{\text{fiz}}$). Kąty $\theta \in (0,\pi)$ i $\phi \pmod{2\pi}$ oznaczają odpowiednio kąt od osi obrotu oraz azymut. Symbole $\mathrm{d}t^2$, $\mathrm{d}r^2$ itd. oznaczają kwadraty różniczek współrzędnych w zapisie symetrycznego tensora g.

Przykład 11.3.3 (Schwarzschild)**.** W jednostkach geometrycznych $G = c = 1$, dla $M > 0$ i na obszarze zewnętrznym $r > 2M$, metryka ma postać

$$g_{\text{Sch}} = -\left(1 - \frac{2M}{r}\right)\mathrm{d}t^2 + \left(1 - \frac{2M}{r}\right)^{-1}\mathrm{d}r^2 + r^2(\mathrm{d}\theta^2 + \sin^2\theta\,\mathrm{d}\phi^2). \tag{11.3.4}$$

Parametr M opisuje masę źródła, natomiast r jest *promieniem powierzchniowym*: sfera określona przez $t, r = \text{const}$ ma pole $4\pi r^2$. Nie jest to ogólnie odległość zmierzona wzdłuż promienia; z metryki na $t = \text{const}$ odczytujemy element takiej odległości $\mathrm{d}\ell = \mathrm{d}r/\sqrt{1 - 2M/r}$. Współrzędna t jest unormowana tak, aby asymptotycznie, gdy $r \to \infty$, zgadzać się z czasem własnym obserwatorów statycznych po przeliczeniu jednostek. Dla obserwatora o stałych r, θ, ϕ odczytujemy z metryki $\mathrm{d}\tau = \sqrt{1 - 2M/r}\,\mathrm{d}t$; przy skończonym r czas własny τ różni się więc od t. Przy $r > 2M$ współczynnik $\mathrm{d}t^2$ jest ujemny, a trzy przestrzenne są dodatnie, więc sygnatura wynosi $(-,+,+,+)$. Dla ustalonego t otrzymujemy *riemannowską* metrykę przestrzennego przekroju

$$h_{\text{Sch}} = \left(1 - \frac{2M}{r}\right)^{-1}\mathrm{d}r^2 + r^2(\mathrm{d}\theta^2 + \sin^2\theta\,\mathrm{d}\phi^2).$$

Na sferze $t, r = \text{const}$ metryka indukowana to (11.2.1) z $R = r$, więc jej pole wynosi $4\pi r^2$. Współrzędne sferyczne nie działają na biegunach, a postać (11.3.4) nie obejmuje $r = 2M$; odpowiednie przedłużenie opisuje się innymi współrzędnymi.

Przykład 11.3.4 (Kerr)**.** Przy $M > 0$, $|a| \le M$ i $r > r_+ := M + \sqrt{M^2 - a^2}$ połóżmy $\Sigma = r^2 + a^2\cos^2\theta$ i $\Delta = r^2 - 2Mr + a^2$. W zewnętrznej dziedzinie współrzędnych Boyera–Lindquista metrykę zapisuje się zwięźle jako

$$\begin{aligned} g_{\text{K}} = &-\frac{\Delta}{\Sigma}(\mathrm{d}t - a\sin^2\theta\,\mathrm{d}\phi)^2 + \frac{\sin^2\theta}{\Sigma}\big((r^2 + a^2)\mathrm{d}\phi - a\,\mathrm{d}t\big)^2 \\ &+ \frac{\Sigma}{\Delta}\mathrm{d}r^2 + \Sigma\,\mathrm{d}\theta^2. \end{aligned} \tag{11.3.5}$$

Tutaj M ponownie jest parametrem masy, J oznacza moment pędu źródła, a $a = J/M$ w jednostkach $G = c = 1$ jest parametrem *obrotu* o wymiarze długości (w zwykłych jednostkach $a = J_{\text{fiz}}/(M_{\text{fiz}}c)$). Znak a ustala zwrot obrotu względem rosnącego ϕ; $a = 0$ daje przypadek bez obrotu. Założenie $|a| \le M$ zapewnia rzeczywiste pierwiastki $\Delta = 0$; r_+ jest większym z nich, czyli współrzędną zewnętrznego horyzontu. Wielkości Σ i Δ są skrótami zależnymi od współrzędnych, nie dodatkowymi parametrami. Współrzędna r nie mierzy tu odległości przestrzennej i przy $a \neq 0$ nie jest także promieniem sfery o polu $4\pi r^2$; t, θ, ϕ są współrzędnymi Boyera–Lindquista. Wzór opisuje zewnętrze horyzontu, a nie całą czasoprzestrzeń. Kwadrat nawiasu jest kwadratem symetrycznym 1-formy. Ponieważ $\Delta > 0$ dla $r > r_+$ i $0 < \theta < \pi$, cztery wyświetlone kwadraty mają odpowiednio znaki $-,+,+,+$ (po liniowo niezależnej zamianie pary $\mathrm{d}t, \mathrm{d}\phi$). Istotnie, macierz tej zamiany to $\left(\begin{smallmatrix} 1 & -a\sin^2\theta \\ -a & r^2+a^2 \end{smallmatrix}\right)$, a jej wyznacznik wynosi $r^2 + a^2\cos^2\theta = \Sigma > 0$. W szczególności nie jest to metryka riemannowska.

Sprawdźmy związek ze Schwarzschildem: dla $a = 0$ mamy $\Sigma = r^2$ oraz $\Delta = r^2(1 - 2M/r)$; cztery składniki (11.3.5) stają się dokładnie składnikami (11.3.4). Dla $a \neq 0$ wyraz mieszany w pierwszym kwadracie ma współczynnik $2a\Delta\sin^2\theta/\Sigma$, a w drugim $-2a(r^2 + a^2)\sin^2\theta/\Sigma$. Ich suma wynosi $2a\sin^2\theta(\Delta - r^2 - a^2)/\Sigma$. Podstawiając $\Delta - r^2 - a^2 = -2Mr$, otrzymujemy wyraz

$$-\frac{4Mar\sin^2\theta}{\Sigma}\,\mathrm{d}t\,\mathrm{d}\phi.$$

W macierzy tensora oznacza to $g_{t\phi} = -2Mar\sin^2\theta/\Sigma$: oba wyrazy $g_{t\phi}\mathrm{d}t\otimes\mathrm{d}\phi$ i $g_{\phi t}\mathrm{d}\phi\otimes\mathrm{d}t$ składają się na współczynnik podwojony. Ten wyraz wiąże czas z kierunkiem obrotu. Przekrój $t=\text{const}$ ma dodatnio określoną metrykę w podanej dziedzinie. Współczynniki przy $\mathrm{d}r^2$ i $\mathrm{d}\theta^2$ są dodatnie, a współczynnik przy $\mathrm{d}\phi^2$ wynosi

$$\frac{\sin^2\theta}{\Sigma}\bigl((r^2+a^2)^2 - a^2\Delta\sin^2\theta\bigr) > 0,$$

ponieważ wyrażenie w nawiasie równa się $(r^2+a^2)\Sigma + 2Mra^2\sin^2\theta$. Pomiary przestrzenne zależą jednak od wybranego przekroju czasoprzestrzeni.

W obu przykładach zapisaliśmy konkretne tensory i sprawdziliśmy ich znaki oraz prostą zależność między nimi. Ich wyprowadzenie z równań Einsteina wymaga aparatu krzywizny, którego jeszcze nie wprowadziliśmy.

Przykład 11.3.5 (metryka FLRW i geometria rozszerzającego się Wszechświata)**.** Przyjmujemy jednostki $c=1$. Rozważmy czasoprzestrzeń $M = I\times\mathbb{R}^3$, gdzie $I\subset(0,\infty)$ jest przedziałem, z metryką lorentzowską

$$g = -\mathrm{d}t^2 + a(t)^2(\mathrm{d}x^2+\mathrm{d}y^2+\mathrm{d}z^2), \qquad a\in C^\infty(I),\quad a(t)>0. \tag{11.3.6}$$

Jest to przestrzennie płaski model Friedmanna–Lemaître'a–Robertsona–Walkera (FLRW). Funkcja a nazywa się *czynnikiem skali*, a $H = \dot a/a$ parametrem Hubble'a; kropka oznacza pochodną po t. Symbol a w Przykładzie 11.3.4 oznaczał stały parametr obrotu. Współrzędne (x,y,z) są *współporuszające się*. Na przekroju $\{t\}\times\mathbb{R}^3$ metryka indukowana wynosi $h_t = a(t)^2(\mathrm{d}x^2+\mathrm{d}y^2+\mathrm{d}z^2)$, a więc jego krzywizna wewnętrzna jest zerowa: na ustalonym przekroju zamiana współrzędnych $\mathbf{X} = a(t)\mathbf{x}$ daje metrykę euklidesową. Wyprowadźmy też odległość przestrzenną dwóch punktów o stałych współrzędnych $\mathbf{x},\mathbf{y}$. Korzystamy z definicji długości i odległości (11.4.1)–(11.4.2) z następnej sekcji. Dla drogi $\sigma:[0,1]\to\mathbb{R}^3$ łączącej te punkty, przy ustalonym t, mamy

$$L_{h_t}(\sigma) = a(t)\int_0^1 |\dot\sigma(s)|\,\mathrm{d}s \geq a(t)\left|\int_0^1 \dot\sigma(s)\,\mathrm{d}s\right| = a(t)|\mathbf{y}-\mathbf{x}|.$$

Odcinek $\sigma(s) = (1-s)\mathbf{x}+s\mathbf{y}$ osiąga równość, więc $D(t) = a(t)|\mathbf{x}-\mathbf{y}|$. Różniczkujemy przy stałych $\mathbf{x},\mathbf{y}$: $\dot D = \dot a|\mathbf{x}-\mathbf{y}| = (\dot a/a)D = HD$. Płaskość każdego przekroju przestrzennego nie oznacza jednak płaskości czterowymiarowej czasoprzestrzeni.

Dla $x^0 = t$ i indeksów przestrzennych $i,j\in\{1,2,3\}$ mamy $g_{00}=-1$, $g_{0i}=0$, $g_{ij}=a^2\delta_{ij}$ oraz $g^{00}=-1$, $g^{ij}=a^{-2}\delta^{ij}$. W szczególności $\det(g_{\mu\nu}) = -a^6$; warunek $a>0$ zapewnia niezdegenerowanie metryki na M.

11.4 Długość, energia i odległość

Definicja 11.4.1 (Długość i energia krzywej)**.** Niech $a<b$, a $\gamma:[a,b]\to(M,g)$ będzie ciągła i odcinkami klasy C^1 (na skończonym podziale przedziału). Wektor prędkości to $\dot\gamma(t)$, a jego długość, nazywana także szybkością, wynosi $|\dot\gamma(t)|_g$. Jej *długość* i *energia* to odpowiednio

$$L_g(\gamma) = \int_a^b |\dot\gamma(t)|_g\,\mathrm{d}t, \qquad E_g(\gamma) = \frac12\int_a^b |\dot\gamma(t)|_g^2\,\mathrm{d}t. \tag{11.4.1}$$

Dla krzywych łączących p z q definiujemy

$$d_g(p,q) = \inf_{\gamma(a)=p,\ \gamma(b)=q} L_g(\gamma). \tag{11.4.2}$$

Infimum bierzemy po krzywych odcinkami C^1. Jeśli nie ma takiej krzywej, przyjmujemy $\inf\varnothing = +\infty$. Zatem dla rozmaitości niespójnej wzór daje metrykę skończoną osobno na każdej składowej; między różnymi składowymi ma wartość $+\infty$.

Metryka g mierzy wektor prędkości w każdym punkcie, długość sumuje te pomiary wzdłuż *jednej* drogi, a d_g szuka najkrótszej możliwej długości. Infimum nie zakłada jeszcze, że istnieje krzywa, która je osiąga.

Stwierdzenie 11.4.2 (Zmiana parametru i energia)**.** *Jeśli $h : [c,d] \to [a,b]$ jest rosnącym dyfeomorfizmem klasy C^1, to $L_g(\gamma \circ h) = L_g(\gamma)$. Ponadto*

$$L_g(\gamma)^2 \le 2(b-a)E_g(\gamma), \tag{11.4.3}$$

z równością wtedy i tylko wtedy, gdy prędkość $|\dot\gamma|_g$ jest stała prawie wszędzie. Dla regularnej krzywej klasy C^1, czyli takiej, że $\dot\gamma(t) \neq 0$, istnieje przeparametryzowanie klasy C^1 ze stałą szybkością. Osiąga ono najmniejszą energię wśród wszystkich regularnych przeparametryzowań na ustalonym $[a,b]$. Dla krzywej odcinkami regularnej odpowiednie przeparametryzowanie jest odcinkami klasy C^1.

Dowód. Reguła łańcuchowa daje $(\gamma \circ h)'(s) = \dot\gamma(h(s))h'(s)$. Ponieważ $h' > 0$, jednorodność normy i podstawienie $t = h(s)$ dają

$$L_g(\gamma \circ h) = \int_c^d |\dot\gamma(h(s))|_g h'(s)\,\mathrm{d}s = \int_a^b |\dot\gamma(t)|_g\,\mathrm{d}t.$$

Dla malejącego dyfeomorfizmu ten sam rachunek używa $|h'| = -h'$ i odwróconych granic całkowania, więc długość także się nie zmienia. Dla energii w pierwszej całce występuje $(h')^2$, a więc podstawienie nie usuwa całego czynnika: energia na ogół się zmienia. Nierówność Cauchy'ego–Schwarza dla funkcji 1 i $|\dot\gamma|_g$ na $[a,b]$ daje

$$\left(\int_a^b |\dot\gamma|_g\,\mathrm{d}t\right)^2 \le \left(\int_a^b 1\,\mathrm{d}t\right)\left(\int_a^b |\dot\gamma|_g^2\,\mathrm{d}t\right).$$

To (11.4.3). Warunek równości w Cauchym–Schwarzu oznacza, że obie funkcje są proporcjonalne prawie wszędzie, czyli $|\dot\gamma|_g$ jest stała prawie wszędzie. Dla regularnej krzywej $|\dot\gamma|_g > 0$; funkcja $s(t) = a + \frac{b-a}{L_g(\gamma)}\int_a^t |\dot\gamma(\tau)|_g\,\mathrm{d}\tau$ ma pochodną $s'(t) = (b-a)|\dot\gamma(t)|_g / L_g(\gamma) > 0$ i przenosi końce przedziału na siebie. Ma zatem odwrotność klasy C^1, a dla $u = s(t)$ reguła łańcuchowa daje

$$\left|(\gamma \circ s^{-1})'(u)\right|_g = \frac{|\dot\gamma(t)|_g}{s'(t)} = \frac{L_g(\gamma)}{b-a}.$$

Krzywa o tej stałej prędkości osiąga dolną granicę energii $L_g(\gamma)^2/[2(b-a)]$. □

Na przykład na $[0,1]$ z metryką euklidesową krzywa $\gamma(t) = t$ ma długość 1 i energię $1/2$. Dla $h(s) = (s+s^2)/2$ pochodna $h'(s) = 1/2 + s$ jest dodatnia, więc jest to dopuszczalne przeparametryzowanie. Nadal $L(\gamma \circ h) = 1$, lecz $E(\gamma \circ h) = \frac{1}{2}\int_0^1 (1/2+s)^2\,\mathrm{d}s = 13/24 > 1/2$. Nierównomierny ruch po tej samej drodze zwiększył energię.

Twierdzenie 11.4.3 (Odległość riemannowska jest metryką)**.** *Jeżeli M jest spójna, to* (11.4.2) *przyjmuje skończone wartości, spełnia aksjomaty metryki przestrzeni metrycznej (M, d_g) i wyznacza pierwotną topologię rozmaitości.*

Dowód. W wymiarze 0 spójna rozmaitość składa się z jednego punktu i teza jest natychmiastowa. Załóżmy $n \ge 1$. Relacja „można połączyć krzywą odcinkami C^1" jest relacją równoważności. Każda jej klasa jest otwarta: w małej kuli współrzędnych, a przy brzegu w półkuli, można połączyć dwa punkty odcinkiem prostym w mapie. Dopełnienie klasy także jest otwarte, jako suma innych klas. Ze spójności wynika, że jest tylko jedna klasa. Na każdym ze skończenie wielu kawałków takiej krzywej prędkość i współczynniki metryki są ciągłe na zwartym przedziale, więc długość jest skończona. Zatem $d_g(p,q) < \infty$.

Długości są nieujemne, stała krzywa ma długość zero, odwrócenie kierunku zachowuje długość, a długości sklejonych krzywych dodają się. Biorąc infima (i drogi o długości dowolnie bliskiej obu infimom), otrzymujemy $d_g(p,p)=0$, symetrię i nierówność trójkąta.

Zostało najważniejsze: $d_g(p,q)>0$ dla $p\neq q$. Wybierzmy mapę x z $x(p)=0$ i domkniętą kulę współrzędnych $\overline{B}_{2r}$ leżącą w obrazie tej mapy. Jeśli $p\in\partial M$, wybieramy mapę przybrzegową z $x(p)=0$ i w całym poniższym rachunku zastępujemy B_ρ przez $B_\rho\cap\{x^n\geq 0\}$. Te półkule są wypukłe, więc odcinki używane w dowodzie pozostają w M. „Wyjście z kuli" oznacza wtedy przekroczenie jej sferycznej części brzegu wewnątrz półprzestrzeni. Na zwartym zbiorze $x^{-1}(\overline{B}_{2r})$ dodatnia określoność i ciągłość macierzy G dają stałe $c,C>0$, takie że

$$c|w|\leq\sqrt{w^{\mathsf{T}}G(x)w}\leq C|w|\quad(x\in\overline{B}_{2r}).$$

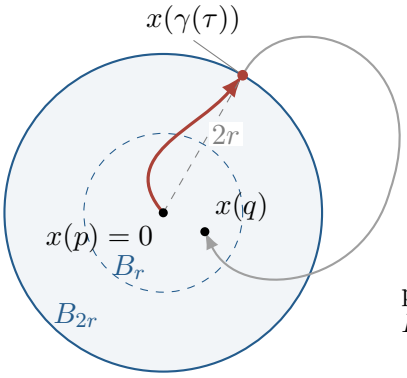
Istnienie wspólnego c można zobaczyć, minimalizując $w^{\mathsf{T}}G(x)w$ po zwartym iloczynie $\overline{B}_{2r}\times S^{n-1}$.

Jeśli q leży w $x^{-1}(B_r)$, droga z p do q pozostająca w B_{2r} ma długość co najmniej $c|x(q)|$, bo długość euklidesowa drogi jest nie mniejsza niż przemieszczenie końców. Dla drogi $\gamma:[a,b]\to M$ wychodzącej z $x^{-1}(B_{2r})$ niech τ będzie pierwszym momentem osiągnięcia sfery współrzędnych $|x|=2r$. Ciągłość drogi i zawieranie domkniętej kuli w mapie zapewniają istnienie takiego momentu, zanim droga opuści mapę. Do chwili τ możemy stosować oszacowanie metryki, więc

$$L_g(\gamma)\geq L_g(\gamma|_{[a,\tau]})\geq c\int_a^\tau|(x\circ\gamma)'(t)|\,\mathrm{d}t\geq c|x(\gamma(\tau))-x(p)|=2cr.$$

Jest to również co najmniej $c|x(q)|$. Jeśli q leży poza $x^{-1}(B_r)$, każda droga do q musi najpierw opuścić B_r, zatem ma długość co najmniej cr. Oba przypadki dają dodatnią odległość od p.

Te same oszacowania porównują topologie. Dla q w B_r odcinek prosty od 0 do $x(q)$ daje $d_g(p,q)\leq C|x(q)|$. Z drugiej strony kula metryczna $B_{d_g}(p,cr)$ leży w $x^{-1}(B_r)$, a na niej $d_g(p,q)\geq c|x(q)|$. Zbieżność w mapie i zbieżność dla d_g są więc lokalnie równoważne. □



Rysunek 11.6: Oszacowanie przed pierwszym wyjściem z kuli. Czerwony fragment pozostaje w obszarze, gdzie $|v|_g\geq c|v|$, i ma przemieszczenie współrzędnych $2r$. Dalszy przebieg drogi nie może zmniejszyć już przebytej długości.

Przykład 11.4.4 (Niezupełność i brzeg modelu hiperbolicznego)**.** Przedział $(0,1)$ z $g=\mathrm{d}x^2$ ma zwykłą odległość $|p-q|$, ale ciąg $1/j$, $j\geq 2$, jest Cauchy'ego i nie zbiega w tym przedziale. Samo istnienie g nie zapewnia zupełności.

W półprzestrzeni hiperbolicznej rozważmy dowolną odcinkami gładką drogę $\gamma:[0,1]\to\mathbb{H}^n$ od (x,y_0) do (x,y_1), zapisaną jako $\gamma(t)=(x(t),y(t))$, gdzie $y(t)>0$. Z metryki półprzestrzeni i nierówności $\sqrt{|\dot{x}|^2+\dot{y}^2}\geq|\dot{y}|$ wynika

$$L_g(\gamma)=\int_0^1\frac{\sqrt{|\dot{x}(t)|^2+\dot{y}(t)^2}}{y(t)}\,\mathrm{d}t\geq\int_0^1\frac{|\dot{y}(t)|}{y(t)}\,\mathrm{d}t\geq\left|\int_0^1\frac{\dot{y}(t)}{y(t)}\,\mathrm{d}t\right|=|\log(y_1/y_0)|.$$

Ostatnia równość używa $(\log y(t))' = \dot{y}(t)/y(t)$ i twierdzenia podstawowego rachunku całkowego. Dla pionowego odcinka $\eta(t) = (x, (1-t)y_0 + ty_1)$ współrzędna x jest stała, a $\dot{y} = y_1 - y_0$ ma stały znak. Obie nierówności stają się równościami; dotyczy to także drogi stałej, gdy $y_0 = y_1$. Zatem $d_g((x,y_0),(x,y_1)) = |\log(y_1/y_0)|$. Dolne oszacowanie przez zmianę $\log y$ działa również przy różnych współrzędnych poziomych, więc dążenie do brzegu $y = 0$ wymaga nieograniczonej długości.

Podobnie w kuli Poincarégo weźmy drogę $\gamma : [0,1] \to B^n$ od 0 do u. Funkcja $\rho(t) = |\gamma(t)|$ jest absolutnie ciągła i $|\rho'| \le |\dot{\gamma}|$ prawie wszędzie. Potrzebną funkcję pierwotną wyznaczamy z rozkładu $2/(1-s^2) = 1/(1+s) + 1/(1-s)$: $F(s) = \log((1+s)/(1-s))$ spełnia $F'(s) = 2/(1-s^2)$ oraz $F(0) = 0$. Stąd

$$\begin{aligned} L_g(\gamma) &= \int_0^1 \frac{2|\dot{\gamma}(t)|}{1-\rho(t)^2}\,\mathrm{d}t \ge \int_0^1 \frac{2|\rho'(t)|}{1-\rho(t)^2}\,\mathrm{d}t \\ &\ge \left|\int_0^1 F'(\rho(t))\rho'(t)\,\mathrm{d}t\right| = |F(\rho(1)) - F(\rho(0))| = \log\frac{1+|u|}{1-|u|}. \end{aligned}$$

Regułę łańcuchową można zastosować do absolutnie ciągłej ρ, ponieważ zwarty obraz drogi leży w mniejszej kuli o promieniu mniejszym niż 1, gdzie F' jest ograniczona. Droga promieniowa $\eta(t) = tu$ ma $|\dot{\eta}| = |u| = \rho'$ i osiąga wszystkie równości. Otrzymujemy więc $d_g(0,u) = \log((1+|u|)/(1-|u|))$.

11.5 Objętość wyznaczona przez metrykę

Jeden wektor ma długość; n niezależnych wektorów stycznych rozpinających maleńki równoległościan ma objętość. W bazie ortogonalnej jest to iloczyn długości. W dowolnej bazie odpowiednią liczbę zawiera wyznacznik macierzy Grama.

Definicja 11.5.1 (Element objętości i miara riemannowska)**.** W mapie x na (M^n, g) *element objętości* jest dodatnią gęstością

$$\mathrm{d}\mu_g = \sqrt{\det(g_{ij}(x))}\,|\,\mathrm{d}x^1 \cdots \mathrm{d}x^n\,|. \tag{11.5.1}$$

Przez całkowanie tej gęstości w mapach otrzymujemy miarę borelowską μ_g. Dla funkcji borelowskiej $f \ge 0$ lub funkcji całkowalnej, o nośniku zawartym w jednej mapie,

$$\int_M f\,\mathrm{d}\mu_g = \int_{x(U)} f(x^{-1}(u))\sqrt{\det G(u)}\,\mathrm{d}u^1 \cdots \mathrm{d}u^n.$$

Ogólną całkę definiujemy z podziałem jedności: dla funkcji nieujemnej dopuszczamy wartość $+\infty$, a dla funkcji ze znakiem wymagamy $\int_M |f|\,\mathrm{d}\mu_g < \infty$. Sam zwarty nośnik funkcji mierzalnej nie zapewnia całkowalności. W wymiarze 0 przyjmujemy wyznacznik macierzy pustej równy 1; μ_g jest wtedy miarą liczącą punkty. Na rozmaitości zorientowanej *forma objętościowa* ma w dodatniej mapie postać $\mathrm{vol}_g = \sqrt{\det G}\,\mathrm{d}x^1 \wedge \cdots \wedge \mathrm{d}x^n$. Dla $n = 0$ forma objętościowa ma w punkcie wartość $\varepsilon_p \in \{1, -1\}$ zadaną jego orientacją; całkowanie z tą samą orientacją daje dodatnią masę 1.

Kreski pionowe w (11.5.1) oznaczają gęstość: zmiana orientacji nie zmienia miary. Forma vol_g ma natomiast znak zależny od orientacji. Dlatego pole powierzchni możemy obliczyć również na rozmaitości nieorientowalnej, choć nie ma na niej globalnej formy objętościowej.

Twierdzenie 11.5.2 (Niezależność elementu objętości od mapy)**.** *Wzór* (11.5.1) *daje jednoznaczną miarę borelowską na M, niezależną od atlasu i podziału jedności. Jeżeli $F : (M,g) \to (N,h)$ jest izometrią, czyli dyfeomorfizmem z $F^*h = g$, to $\mu_g(F^{-1}A) = \mu_h(A)$ dla zbiorów borelowskich $A \subset N$.*

Dowód. Na przecięciu map niech $x = x(y)$ i $J = \partial x/\partial y$. Ze Stwierdzenia 11.1.4 wynika

$$\sqrt{\det G_y} = |\det J|\sqrt{\det G_x}.$$

To dokładnie czynnik w twierdzeniu o zmianie zmiennych w całce Lebesgue'a, więc obliczenia tego samego zbioru w obu mapach są zgodne. W mapach przybrzegowych dla $n \geq 1$ stosujemy zmianę zmiennych we wnętrzu półprzestrzeni; jej płaski brzeg ma zerową miarę Lebesgue'a, więc nie dodaje wkładu do całki n-wymiarowej. Dla $n = 0$ miara jest po prostu miarą liczącą. Wybierzmy przeliczalne pokrycie mapami (U_j), a borelowski zbiór A rozbijmy na rozłączne fragmenty $A \cap U_1$, $A \cap (U_2 \setminus U_1)$ itd. Oznaczmy te części przez A_j i sumujmy ich lokalne miary. Jeżeli (B_k) jest drugim takim rozbiciem A, to przecięcia $A_j \cap B_k$ rozbijają każdą część obu rodzin. Zgodność lokalnych miar oraz możliwość zamiany kolejności sum o nieujemnych wyrazach dają ten sam wynik $\sum_j \sum_k \mu_g(A_j \cap B_k)$. To dowodzi niezależności od pokrycia i kolejności map. Dla rozłącznych borelowskich E_ℓ rozcinamy każdy z nich tym samym pokryciem; lokalna przeliczalna addytywność i zamiana sum po j, ℓ dają addytywność globalną. Przy definicji przez podział jedności wspólnym rozdrobnieniem dwóch podziałów (ρ_j) i (σ_k) są iloczyny $\rho_j\sigma_k$; sumowanie po dowolnym indeksie odtwarza wyjściowy podział.

Dla izometrii macierz jej różniczki spełnia w lokalnych bazach $G_M = (DF)^{\mathsf{T}} G_N (DF)$. Poprzedni rachunek wyznaczników i podstawienie w całce pokazują $\int_M (f \circ F)\mathrm{d}\mu_g = \int_N f \mathrm{d}\mu_h$ dla nieujemnych funkcji mierzalnych f. Wstawiając funkcję charakterystyczną A, otrzymujemy tezę o miarach. □

Przykład 11.5.3 (Gęstości w modelach)**.** Ze (11.2.1) otrzymujemy $\mathrm{d}\mu_{S^2_R} = R^2 \sin\theta \,\mathrm{d}\theta\,\mathrm{d}\phi$ dla $0 < \theta < \pi$, a stąd $\mathrm{Pole}(S^2_R) = \int_0^{2\pi}\int_0^{\pi} R^2 \sin\theta \,\mathrm{d}\theta\,\mathrm{d}\phi = 4\pi R^2$. Parametry $0 < \theta < \pi$, $0 < \phi < 2\pi$ pomijają bieguny i jeden południk. Zbiory te mają zerową miarę powierzchniową: w regularnych mapach są punktami lub wykresami jednowymiarowymi, zerowymi dla dwuwymiarowej miary Lebesgue'a z twierdzenia Fubiniego. Gładka gęstość nie zmienia tej zerowości. Nie całkujemy więc przez osobliwość mapy; dodajemy jedynie zbiór miary zero. W półprzestrzeni hiperbolicznej macierz metryki jest $y^{-2} I_n$, więc $\mathrm{d}\mu_{\mathbb{H}} = y^{-n}\mathrm{d}x^1 \cdots \mathrm{d}x^{n-1}\mathrm{d}y$. W kuli Poincarégo gęstość wynosi $(2/(1-|u|^2))^n \mathrm{d}u^1 \cdots \mathrm{d}u^n$. W przestrzennych współrzędnych z hiperboloidy z (11.2.5) wyznacznik obliczony w (11.2.6) daje

$$\mathrm{d}\mu_{\mathcal{H}} = \frac{\mathrm{d}z^1 \cdots \mathrm{d}z^n}{\sqrt{1+|z|^2}}.$$

Podana formuła dotyczy *metryki indukowanej na hiperboloidzie*, nie miary otaczającej przestrzeni Minkowskiego. Izometrie P i F z Przykładu 11.2.3 przekształcają te trzy gęstości w siebie.

Dla przestrzennego przekroju Schwarzschilda z Przykładu 11.3.3 macierz h_{Sch} jest diagonalna:

$$\det h_{\mathrm{Sch}} = \frac{r^4 \sin^2\theta}{1-2M/r}, \qquad \mathrm{d}\mu_{h_{\mathrm{Sch}}} = \frac{r^2 \sin\theta}{\sqrt{1-2M/r}}\,\mathrm{d}r\,\mathrm{d}\theta\,\mathrm{d}\phi.$$

Jest to *trójwymiarowa* miara wybranego przekroju, a nie miara całej metryki lorentzowskiej.

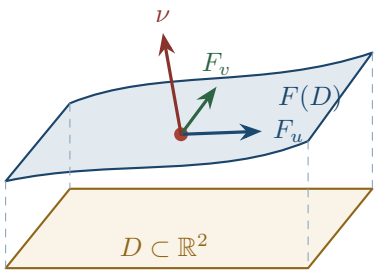
11.6 Metryka indukowana i całki po podrozmaitości

Definicja 11.6.1 (Metryka indukowana)**.** Niech $i : S^k \hookrightarrow (M^n, g)$ będzie gładką podrozmaitością, $k \leq n$. Na S definiujemy $h = i^* g$:

$$h_p(v,w) = g_{i(p)}(\mathrm{d}i_p v, \mathrm{d}i_p w) \quad (v, w \in T_p S).$$

Ponieważ $\mathrm{d}i_p$ jest iniektywna, h jest metryką riemannowską. Miara μ_h na S pozwala całkować funkcję $f : S \to \mathbb{R}$; oznaczenie $\int_S f \,\mathrm{d}A_g$ stosujemy, gdy $k = n-1$.

Parametryzacja $F : U \subset \mathbb{R}^k \to S$ wybiera wektory $F_1, \dots, F_k$ styczne do powierzchni. Macierz Grama tych wektorów wyznacza rzeczywisty rozmiar obrazu małego prostokąta współrzędnych.



Rysunek 11.7: Parametryzacja unosi obszar parametrów D na powierzchnię. Wektory F_u, F_v wyznaczają element pola $\sqrt{\det(g(F_a, F_b))}\,\mathrm{d}u\,\mathrm{d}v$; normalna ν pozwala dodatkowo mierzyć strumień.

Uwaga 11.6.2 (Interpretacja ortogonalna wiązki normalnej). Niech $S \subset M$ będzie podrozmaitością zanurzoną i niech g będzie metryką riemannowską na M. Dla każdego $p \in S$ definiujemy *przestrzeń normalną* jako dopełnienie ortogonalne przestrzeni stycznej:

$$\nu_p^\perp S := (T_pS)^\perp = \{v \in T_pM : \ g_p(v, w) = 0 \text{ dla każdego } w \in T_pS\}.$$

Dodatnia określoność metryki daje rozkład ortogonalny

$$T_pM = T_pS \oplus \nu_p^\perp S.$$

Przestrzenie te tworzą *ortogonalną wiązkę normalną*

$$\nu^\perp S := \bigsqcup_{p \in S} \nu_p^\perp S \subset TM|_S,$$

a na poziomie wiązek otrzymujemy

$$TM|_S = TS \oplus \nu^\perp S.$$

Uzasadnijmy, że $\nu^\perp S$ jest gładką podwiązką. Niech $(X_1, \dots, X_k)$ będzie lokalną bazą gładkich sekcji TS. Macierz Grama

$$G(p) = \big(g_p(X_a(p), X_b(p))\big)_{a,b=1}^{k}$$

jest gładka i odwracalna. Aby wyznaczyć rzut, piszemy $P_p(v) = \sum_b c^b X_b(p)$ i żądamy, by $v - P_p(v)$ był prostopadły do każdego $X_a(p)$. Oznaczając $d_a = g_p(v, X_a(p))$, dostajemy układ $d_a = \sum_b G_{ab}(p) c^b$, czyli $c = G(p)^{-1} d$. Symetria G^{-1} pozwala zapisać wynik jako

$$P_p(v) = \sum_{a,b=1}^{k} g_p(v, X_a(p))(G(p)^{-1})^{ab} X_b(p).$$

Układ zapewnia prostopadłość różnicy $v - P_p(v)$. Dla $v \in T_pS$ jego jednoznaczne rozwiązanie daje $P_p(v) = v$, zatem $P_p^2 = P_p$: jest to rzeczywiście rzut ortogonalny. Zależy on gładko od p, więc również $\mathrm{id} - P$ jest gładkim rzutowaniem wiązek o stałym rzędzie $n - k$, gdzie $n = \dim M$. Jego obrazem jest $\nu^\perp S$. Aby otrzymać lokalną bazę tego obrazu, wybieramy spośród obrazów lokalnej bazy $TM|_S$ dokładnie $n - k$ wektorów niezależnych w p. Odpowiedni minor nie znika też w pewnym otoczeniu p, więc te gładkie sekcje pozostają niezależne. Ponieważ wymiar obrazu jest stale równy $n - k$, stanowią tam jego bazę. To dowodzi gładkości podwiązki.

Rozkład ortogonalny pozwala ponadto utożsamić kanoniczną wiązkę normalną ilorazową $\nu S = TM|_S / TS$ z $\nu^\perp S$. Istotnie, odwzorowanie

$$\nu^\perp S \longrightarrow \nu S, \qquad v \longmapsto [v],$$

jest izomorfizmem wiązek wektorowych: na każdym włóknie jest liniowe i różnowartościowe, ponieważ $T_pS \cap \nu_p^\perp S = \{0\}$, oraz surjektywne na mocy rozkładu ortogonalnego. Odwrotność ma postać $[v] \mapsto (\mathrm{id} - P)v$: zmiana reprezentanta o wektor styczny nie zmienia wyniku, gdyż $P|_{TS} = \mathrm{id}$. Ten wzór w lokalnych trywializacjach dowodzi także gładkości odwrotności.

W przeciwieństwie do konstrukcji ilorazowej, wybór podwiązki $\nu^\perp S \subset TM|_S$ zależy od metryki g. W ten sposób metryka pozwala reprezentować klasy wektorów normalnych przez jednoznacznie wyznaczone wektory prostopadłe do T_pS.

Twierdzenie 11.6.3 (Wzór parametryczny na całkę)**.** *Jeżeli F jest parametryzacją kawałka podrozmaitości, jeden raz pokrywającą rozważany fragment, i f jest całkowalna o nośniku w tym fragmencie, to*

$$\int_{F(U)} f \,\mathrm{d}\mu_h = \int_U f(F(u)) \sqrt{\det\bigl(g(F_a, F_b)\bigr)_{a,b=1}^{k}} \,\mathrm{d}u^1 \cdots \mathrm{d}u^k. \tag{11.6.1}$$

Dla $M = \mathbb{R}^3$ z metryką euklidesową i $k = 2$ czynnik pod pierwiastkiem jest $|F_u \times F_v|^2$.

Dowód. Z definicji cofnięcia tensora $h_{ab}(u) = g_{F(u)}(\partial_a F, \partial_b F)$. Podstawmy tę macierz do (11.5.1) w wymiarze k: dostajemy dokładnie prawą stronę (11.6.1). Dlaczego jest to pole, a nie sztuczny czynnik? Wybierzmy ortonormalną bazę w $T_{F(u)}M$ i zapiszmy kolumny F_a w macierzy J. Wówczas $(h_{ab}) = J^\mathsf{T} J$. Ortogonalizując kolumny metodą Grama–Schmidta, otrzymujemy prostopadłe wektory o długościach $\ell_1, \ldots, \ell_k$. Ortogonalna zmiana kierunków i dodawanie wcześniejszych kolumn do późniejszych nie zmieniają objętości rozpiętego równoległościanu. Zatem jego k-wymiarowa objętość wynosi $\ell_1 \cdots \ell_k$ i jednocześnie $\det(J^\mathsf{T} J) = \ell_1^2 \cdots \ell_k^2$. Zmiana parametrów $u = u(v)$ mnoży ten czynnik przez $|\det(\partial u/\partial v)|$, jak w Stwierdzeniu 11.1.4; twierdzenie o podstawieniu pokazuje niezależność wyniku od parametryzacji. W $\mathbb{R}^3$ tożsamość $|F_u \times F_v|^2 = |F_u|^2|F_v|^2 - (F_u \cdot F_v)^2$ jest wyznacznikiem macierzy Grama 2×2. □

Jeśli parametryzacja pokrywa fragment kilka razy, prawa strona liczy go z krotnością. Dla całej podrozmaitości używamy map i podziału jedności, żeby każdy punkt został policzony tylko raz. Dla $k = 1$ i regularnej parametryzacji $\gamma : [a, b] \to S$ rozważanego łuku wzór jest całką po łuku $\int_a^b f(\gamma(t))|\dot\gamma(t)|_g \,\mathrm{d}t$; dla $k = n$ jest zwykłą całką objętościową.

Przykład 11.6.4 (Wykres funkcji i paraboloida)**.** Dla $F(x, y) = (x, y, f(x, y))$ w euklidesowej $\mathbb{R}^3$ wektory styczne to $(1, 0, f_x)$ i $(0, 1, f_y)$, a ich macierz Grama to

$$\begin{pmatrix} 1 + f_x^2 & f_x f_y \\ f_x f_y & 1 + f_y^2 \end{pmatrix}.$$

Jej wyznacznik jest $1 + f_x^2 + f_y^2$, więc

$$\int_{\mathrm{graf}(f|_D)} \psi \,\mathrm{d}A = \int_D \psi(x, y, f(x, y)) \sqrt{1 + f_x^2 + f_y^2} \,\mathrm{d}x \,\mathrm{d}y. \tag{11.6.2}$$

Pierwiastek wyraża nachylenie: skośny fragment ma większe pole niż jego rzut na płaszczyznę.

Weźmy $f = x^2 + y^2$ nad dyskiem $x^2 + y^2 \le a^2$. Współrzędne biegunowe dają pole wykresu

$$\int_0^{2\pi} \int_0^a \sqrt{1 + 4r^2}\, r \,\mathrm{d}r \,\mathrm{d}\phi = \frac{\pi}{6}\bigl((1 + 4a^2)^{3/2} - 1\bigr).$$

W ostatnim kroku użyliśmy podstawienia $s = 1 + 4r^2$, $\mathrm{d}s = 8r \,\mathrm{d}r$.

Przykład 11.6.5 (Całka skalarna po sferze)**.** Na S_R^2 obliczmy całkę z funkcji z^2. Ponieważ $z = R\cos\theta$, mamy

$$\int_{S_R^2} z^2 \,\mathrm{d}A = R^4 \int_0^{2\pi} \int_0^{\pi} \cos^2\theta \sin\theta \,\mathrm{d}\theta \,\mathrm{d}\phi = \frac{4\pi R^4}{3}.$$

Wewnętrzna całka wynosi $2/3$ po podstawieniu $s = \cos\theta$. Jest to całka *skalarna*; nie potrzebujemy wybrać orientacji sfery.

Całki skierowane: dlaczego pojawia się znak?

Pole powierzchni i strumień odpowiadają na dwa różne pytania. W całce skalarnej $\int_S f\,\mathrm{d}A$ liczymy wielkość fragmentów powierzchni: wzór (11.6.1) zawiera dodatni pierwiastek z wyznacznika Grama. Odwrócenie parametrów nie zmienia wyniku. W *całce skierowanej* pytamy, ile pola wektorowego przechodzi przez powierzchnię w *wybranym kierunku*. Musimy ustalić, która strona jest dodatnia; odwrócenie normalnej zmienia znak strumienia.

Przykład 11.6.6 (Całka skierowana po krzywej)**.** Niech $\gamma:[a,b]\to\mathbb{R}^3$ ma wybrany kierunek przebiegu, a $X=(P,Q,R)$ będzie polem wektorowym. Całka skierowana wzdłuż krzywej (często zwana *całką krzywoliniową drugiego rodzaju*) ma wzór

$$\int_\gamma X\cdot\mathrm{d}\mathbf{r}=\int_a^b X(\gamma(t))\cdot\dot\gamma(t)\,\mathrm{d}t=\int_\gamma (P\,\mathrm{d}x+Q\,\mathrm{d}y+R\,\mathrm{d}z). \tag{11.6.3}$$

Jeżeli $\bar\gamma(t)=\gamma(a+b-t)$, to $\dot{\bar\gamma}(t)=-\dot\gamma(a+b-t)$. Podstawienie $s=a+b-t$ w całce daje $\int_{\bar\gamma}X\cdot\mathrm{d}\mathbf{r}=-\int_\gamma X\cdot\mathrm{d}\mathbf{r}$. Natomiast $\int_\gamma f\,\mathrm{d}s=\int_a^b f(\gamma(t))|\dot\gamma(t)|\,\mathrm{d}t$ nie zmienia się przy odwróceniu przebiegu: norma usuwa znak prędkości.

Przykład 11.6.7 (Całka skierowana po powierzchni)**.** Niech $\Phi:D\subset\mathbb{R}^2\to S\subset\mathbb{R}^3$ będzie regularną parametryzacją pokrywającą rozważany fragment jednokrotnie, a orientację S wybierzmy przez normalną $\nu=(\Phi_u\times\Phi_v)/|\Phi_u\times\Phi_v|$. Dla pola X *strumień* przez S wynosi

$$\int_S X\cdot\mathrm{d}\mathbf{S}:=\int_S X\cdot\nu\,\mathrm{d}A=\int_D X(\Phi(u,v))\cdot(\Phi_u\times\Phi_v)\,\mathrm{d}u\,\mathrm{d}v. \tag{11.6.4}$$

To ten sam element pola co na Rysunku 11.7, ale z kierunkiem normalnej. Zamiana u z v zmienia $\Phi_u\times\Phi_v$ na jego przeciwieństwo; czynnik $|\Phi_u\times\Phi_v|$ w całce skalarnej nie zmieniłby się.

Dla wykresu $\Phi(u,v)=(u,v,f(u,v))$ i stałego pola pionowego $X=(0,0,1)$ mamy $\Phi_u\times\Phi_v=(-f_u,-f_v,1)$. Przy normalnej ku górze $\int_S X\cdot\mathrm{d}\mathbf{S}=\int_D 1\,\mathrm{d}u\,\mathrm{d}v=\mathrm{Pole}(D)$; przy normalnej ku dołowi wynik ma znak minus. Natomiast $\int_S 1\,\mathrm{d}A=\int_D\sqrt{1+f_u^2+f_v^2}\,\mathrm{d}u\,\mathrm{d}v$ jest dodatnie przy obu orientacjach.

Stwierdzenie 11.6.8 (Związek z całką z formy)**.** *W zorientowanej $\mathbb{R}^3$ ze standardową formą objętości $\mathrm{vol}=\mathrm{d}x\wedge\mathrm{d}y\wedge\mathrm{d}z$ polu $X=(P,Q,R)$ odpowiada 2-forma*

$$\beta=\iota_X\mathrm{vol}=P\,\mathrm{d}y\wedge\mathrm{d}z+Q\,\mathrm{d}z\wedge\mathrm{d}x+R\,\mathrm{d}x\wedge\mathrm{d}y.$$

Wówczas $\int_{(S,o)}\beta=\int_S X\cdot\nu_o\,\mathrm{d}A$. Na zorientowanej (M^n,g) $\mathrm{d}\mu_g=|\mathrm{vol}_{g,o}|$ w sensie gęstości, a więc

$$\int_M f\,\mathrm{d}\mu_g=\int_{(M,o)} f\,\mathrm{vol}_{g,o}.$$

Jeśli ta sama *forma najwyższego stopnia ω jest całkowana po M z orientacją przeciwną $-o$, to $\int_{(M,-o)}\omega=-\int_{(M,o)}\omega$.*

Dowód. Z definicji cofnięcia form z Rozdziału 10,

$$(\Phi^*\beta)(\partial_u,\partial_v)=\mathrm{vol}\big(X\circ\Phi,\Phi_u,\Phi_v\big)=(X\circ\Phi)\cdot(\Phi_u\times\Phi_v).$$

Całkowanie po D daje (11.6.4). Dla krzywej analogicznie $\gamma^*(P\,\mathrm{d}x+Q\,\mathrm{d}y+R\,\mathrm{d}z)=(X\circ\gamma)\cdot\dot\gamma\,\mathrm{d}t$. W dodatniej mapie $\mathrm{vol}_{g,o}=\sqrt{\det G}\,\mathrm{d}x^1\wedge\cdots\wedge\mathrm{d}x^n$, podczas gdy wzór (11.5.1) na $\mathrm{d}\mu_g$ zawiera wartość bezwzględną wyznacznika zmiany współrzędnych. Stąd równość całek dla *zgodnie* wybranych orientacji i formy. Przy odwróceniu samej orientacji dodatnie mapy stają się ujemne, więc całka z ustalonej formy zmienia znak. Gdybyśmy jednocześnie zastąpili $\mathrm{vol}_{g,o}$ nową dodatnią formą $\mathrm{vol}_{g,-o}=-\mathrm{vol}_{g,o}$, oba znaki by się zniosły; całka z gęstości pozostałaby ta sama. Właśnie dlatego przy strumieniu trzeba podać *stronę* powierzchni, a przy samym polu powierzchni nie. □

11.7 Miara Hausdorffa: pomiar bez map i pochodnych

Miara riemannowska wykorzystuje gładkie mapy i wyznacznik macierzy metryki. Miara Hausdorffa wychodzi tylko od *odległości*: pokrywamy zbiór coraz mniejszymi częściami i sumujemy odpowiednie potęgi ich średnic. Dzięki temu ma sens również na zbiorach, które nie są rozmaitościami.

Definicja 11.7.1 (Miara Hausdorffa)**.** Niech (X,d) będzie przestrzenią metryczną, $s \ge 0$, a $A \subset X$. Przez $\operatorname{diam}_d U$ oznaczmy $\sup\{d(x,y) : x,y \in U\}$. Kładziemy

$$\mathcal{H}^s_{d,\delta}(A) = c_s \inf\left\{ \sum_{j=1}^{\infty} (\operatorname{diam}_d U_j)^s : A \subset \bigcup_j U_j,\ \operatorname{diam}_d U_j < \delta \right\}, \tag{11.7.1}$$

$$\mathcal{H}^s_d(A) = \lim_{\delta \downarrow 0} \mathcal{H}^s_{d,\delta}(A).$$

Pokrycia mogą być skończone lub przeliczalne; puste składniki pomijamy, a puste pokrycie zbioru pustego ma koszt 0. Przy braku dopuszczalnego pokrycia infimum wynosi $+\infty$. Dla $s = k$ całkowitego stosujemy normalizację $c_k = \omega_k / 2^k$, gdzie ω_k jest objętością euklidesowej kuli jednostkowej w $\mathbb{R}^k$ ($\omega_0 = 1$). Dla innych s można wziąć dowolne dodatnie c_s; wartość *wymiaru Hausdorffa* $\dim_{\mathrm{H}} A = \inf\{s : \mathcal{H}^s_d(A) = 0\}$ nie zależy od tego wyboru.

Gdy δ maleje, pokryć dopuszczalnych jest mniej, więc infimum nie maleje: granica w (11.7.1) istnieje, choć może być nieskończona. Dla $s = 0$ przyjmujemy $0^0 = 1$ dla niepustego zbioru w pokryciu; $\mathcal{H}^0$ liczy punkty: zbiór N różnych punktów wymaga co najmniej N składników dla δ mniejszego niż ich minimalna wzajemna odległość, a pokrycie singletonami ma koszt N. Dla zbioru nieskończonego stosujemy dolne oszacowanie do dowolnie dużych skończonych podzbiorów i dostajemy $+\infty$. Na prostym odcinku z odległością euklidesową $\mathcal{H}^1$ jest jego długością, a na gładkiej powierzchni euklidesowej $\mathcal{H}^2$ jest polem. Pierwszą równość sprawdzimy teraz bezpośrednio, a drugą uzasadni Twierdzenie 11.7.4.

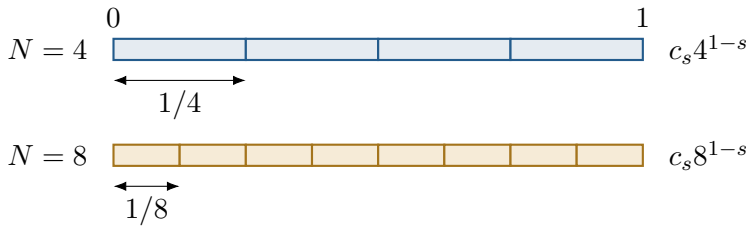
Przykład: jak pokrycia wykrywają wymiar odcinka

Rozważmy $I = [0,1]$ ze zwykłą odległością. W dowolnym pokryciu (U_j) można przeciąć składniki z I. Każdy niepusty składnik zawiera się w przedziale o długości $\operatorname{diam} U_j$. Z podaddytywności zewnętrznej miary Lebesgue'a wynika $1 \le \sum_j \operatorname{diam} U_j$. Ponieważ $c_1 = \omega_1/2 = 1$, każde dopuszczalne pokrycie ma koszt co najmniej 1. Z drugiej strony podział I na N domkniętych odcinków długości $1/N < \delta$ daje koszt 1. Stąd $\mathcal{H}^1_\delta(I) = 1$ dla każdego $\delta > 0$ i $\mathcal{H}^1(I) = 1$.

Dla $s > 1$ to samo pokrycie ma koszt $c_s N (1/N)^s = c_s N^{1-s}$, który dąży do zera przy $N \to \infty$, nawet dla ustalonego δ. Zatem $\mathcal{H}^s(I) = 0$. Dla $0 < s < 1$ i $0 < d_j = \operatorname{diam} U_j < \delta$ mamy natomiast $d_j^s \ge \delta^{s-1} d_j$. Ta nierówność jest prawdziwa także dla $d_j = 0$, gdy $s > 0$. Każde pokrycie kosztuje więc co najmniej $c_s \delta^{s-1} \sum_j d_j \ge c_s \delta^{s-1}$. Gdy $\delta \downarrow 0$, dolna granica rośnie do nieskończoności. Łącznie

$$\mathcal{H}^s(I) = \begin{cases} +\infty, & 0 \le s < 1, \\ 1, & s = 1, \\ 0, & s > 1, \end{cases} \qquad \dim_{\mathrm{H}} I = 1.$$

Przypadek $s = 0$ wynika z liczenia punktów. Wykładnik 1 jest więc wartością, przy której koszt pokrycia nie zanika ani nie rośnie bez ograniczeń.



Rysunek 11.8: Dwa pokrycia odcinka $[0,1]$. Prostokąty jedynie rozdzielają wizualnie składniki; pokryciami są odcinki na prostej, każdy o średnicy $1/N$. Koszt $c_s N^{1-s}$ przy dalszym podziale maleje dla $s > 1$, pozostaje stały dla $s = 1$ i rośnie dla $s < 1$.

Stwierdzenie 11.7.2 (Dlaczego otrzymujemy miarę borelowską)**.** *Funkcja $\mathcal{H}^s_d$ jest miarą zewnętrzną. Jeśli $d(A,B) := \inf\{d(a,b) : a \in A, b \in B\} > 0$, to*

$$\mathcal{H}^s_d(A \cup B) = \mathcal{H}^s_d(A) + \mathcal{H}^s_d(B).$$

Wszystkie zbiory borelowskie są dla niej mierzalne, a na nich $\mathcal{H}^s_d$ jest przeliczalnie addytywna.

Dowód. Dla ustalonego δ monotoniczność i wartość zero na zbiorze pustym wynikają z definicji. Pokrywając każdy A_i z kosztem co najwyżej $\mathcal{H}^s_{d,\delta}(A_i) + \eta 2^{-i}$ i łącząc pokrycia, otrzymujemy przeliczalną podaddytywność. Jeśli suma po prawej jest nieskończona, nierówność jest automatyczna. W przeciwnym razie puszczamy $\eta \downarrow 0$. Ponadto

$$\mathcal{H}^s_{d,\delta}\Big(\bigcup_i A_i\Big) \le \sum_i \mathcal{H}^s_{d,\delta}(A_i) \le \sum_i \mathcal{H}^s_d(A_i).$$

Granica przy $\delta \downarrow 0$ dowodzi podaddytywności $\mathcal{H}^s_d$. Dla $\delta < d(A,B)$ żaden składnik pokrycia nie spotyka obu zbiorów; rozdzielenie składników daje odwrotną nierówność dla ich sumy i następnie równość w granicy.

Wykażmy mierzalność zbioru domkniętego F. Oznaczmy $\mu = \mathcal{H}^s_d$. Kryterium Carathéodory'ego wymaga dla każdego $T \subset X$ równości $\mu(T) = \mu(T \cap F) + \mu(T \setminus F)$. Jedna nierówność jest podaddytywnością. Możemy założyć $\mu(T) < \infty$, bo dla $\mu(T) = \infty$ ta nierówność wymusza nieskończoność prawej strony. Niech $T_i = \{x \in T : d(x,F) \ge 1/i\}$. Addytywność dla zbiorów oddalonych daje $\mu(T) \ge \mu(T \cap F) + \mu(T_i)$. Żeby przejść do $T \setminus F$, rozważmy warstwy

$$E_j = \{x \in T : 1/(j+1) \le d(x,F) < 1/j\}.$$

Każda skończona rodzina warstw o indeksach tej samej parzystości składa się ze zbiorów oddalonych dodatnio: funkcja $d(\,\cdot\,, F)$ jest 1-lipschitzowska. Na przykład między warstwami E_j i E_{j+2} różnica wartości tej funkcji jest co najmniej $1/(j+1) - 1/(j+2) > 0$, więc odległość punktów jest co najmniej tak duża. Suma ich miar nie przekracza $\mu(T)$. Zatem $\sum_j \mu(E_j) < \infty$ i jej ogony dążą do zera. Ponieważ F jest domknięty, $T \setminus F \subset T_i \cup \bigcup_{j \ge i} E_j$, skąd $\mu(T \setminus F) \le \mu(T_i) + \sum_{j \ge i} \mu(E_j)$. Łącząc oba oszacowania, mamy

$$\mu(T \cap F) + \mu(T \setminus F) \le \mu(T) + \sum_{j \ge i} \mu(E_j).$$

Puszczając $i \to \infty$, otrzymujemy żądane kryterium bez zakładania ciągłości miary zewnętrznej na rosnących zbiorach. Przypadki $F = \varnothing, X$ są natychmiastowe. Z twierdzenia Carathéodory'ego zbiory spełniające to kryterium tworzą σ-algebrę, na której miara zewnętrzna jest miarą. Zawiera ona zbiory domknięte, a więc wszystkie zbiory borelowskie. □

Lemat 11.7.3 (Zmiana skali odległości)**.** *Jeśli $F : (X, d_X) \to (Y, d_Y)$ jest L-lipschitzowskie z $L > 0$, to dla każdego $A \subset X$ i $s \geq 0$*

$$\mathcal{H}^s_{d_Y}(F(A)) \leq L^s \, \mathcal{H}^s_{d_X}(A).$$

Jeśli na A i $F(A)$ odwzorowanie ma odwrotność L'-lipschitzowską z $L' > 0$, otrzymujemy również $(L')^{-s}\mathcal{H}^s_{d_X}(A) \leq \mathcal{H}^s_{d_Y}(F(A))$.

Dowód. Obraz pokrycia (U_j) zbioru A pokrywa $F(A)$, a średnica $F(U_j)$ jest co najwyżej $L \operatorname{diam} U_j$. Zatem pokrycia o średnicach poniżej δ dają pokrycia obrazu o średnicach poniżej $L\delta$, a sumy potęg średnic są co najwyżej L^s razy większe. Bierzemy infimum i następnie granicę $\delta \downarrow 0$. Drugą nierówność otrzymujemy przez to samo rozumowanie zastosowane do F^{-1}. Można przy tym pracować z pokryciami wewnątrz A: przecięcie każdego składnika pokrycia z A nie zwiększa jego średnicy. Miara Hausdorffa podzbioru z odległością ograniczoną jest więc taka sama jak jego miara liczona w przestrzeni otaczającej. Założenie $L > 0$ nie wyklucza odwzorowań stałych, które są lipschitzowskie z dowolną dodatnią stałą. □

Twierdzenie 11.7.4 (Zgodność z miarą riemannowską)**.** *Dla spójnej rozmaitości riemannowskiej M^n, również z brzegiem, na (M^n, d_g) z normalizacją (11.7.1) mamy $\mathcal{H}^n_{d_g} = \mu_g$ na zbiorach borelowskich. Jeśli $S^k \subset M$ jest gładką podrozmaitością zanurzoną, z metryką $h = i^*g$, to $\mathcal{H}^k_{d_{g|_S}} = \mu_{i^*g}$ na S. Tę samą miarę na S daje odległość wewnętrzna d_{i^*g}, liczona na każdej składowej S osobno. Dla niespójnego M pierwszą równość również rozumiemy składowa po składowej i sumujemy otrzymane miary. W wymiarze 0 wszystkie te miary są miarami liczącymi punkty.*

Dowód. Przypadek wymiaru 0 wynika z ustalonych konwencji. W pozostałej części dowodu wymiary są dodatnie. Zacznijmy od użytego faktu euklidesowego: przy normalizacji $c_k = \omega_k/2^k$ miara $\mathcal{H}^k$ na $\mathbb{R}^k$ jest miarą Lebesgue'a. Wyjaśnijmy rolę stałej. Nierówność izodiametryczna mówi, że zbiór o średnicy D ma k-wymiarową miarę zewnętrzną najwyżej $\omega_k(D/2)^k$. Sumując tę nierówność po dowolnym pokryciu, otrzymujemy $\mathcal{L}^k(A) \leq \mathcal{H}^k(A)$. W drugą stronę dla otwartego zbioru o skończonej objętości wybieramy drobne kule leżące w nim; twierdzenie Vitalego o pokryciach wybiera rozłączne kule pokrywające go z dokładnością do zbioru miary zero. Ich suma objętości nie przekracza objętości zbioru. Tu potrzebne jest osobne uzasadnienie, że reszta zerowej miary Lebesgue'a ma też zerową miarę Hausdorffa. Dla ustalonych $\delta, \eta > 0$ pokrywamy taki zbiór sześcianami o bokach $\ell_j < \delta/\sqrt{k}$ i $\sum_j \ell_j^k < \eta$; pozwala na to definicja miary zewnętrznej Lebesgue'a, z ewentualnym podziałem sześcianów. Ich koszt Hausdorffa nie przekracza $c_k k^{k/2}\eta$. Puszczając $\eta \downarrow 0$, a następnie $\delta \downarrow 0$, dostajemy zerowość bez zakładania dowodzonej równości miar. Kule z twierdzenia Vitalego wybieramy o średnicach mniejszych niż δ. Ich koszt Hausdorffa jest dokładnie sumą objętości, ponieważ $c_k(2r)^k = \omega_k r^k$. Dodanie pokrycia reszty daje $\mathcal{H}^k_\delta(O) \leq \mathcal{L}^k(O)$ dla otwartego O. Granica po δ i zewnętrzna regularność miary Lebesgue'a dają $\mathcal{H}^k(A) \leq \mathcal{L}^k(A)$ dla borelowskich A o skończonej mierze. Dla nieskończonej miary równość wynika już z przeciwnej nierówności. Użytymi wynikami zewnętrznymi są tu nierówność izodiametryczna dla ograniczonych podzbiorów $\mathbb{R}^k$ oraz następująca wersja pokrycia Vitalego: dla otwartego $O \subset \mathbb{R}^k$ i dowolnego $\delta > 0$ istnieje przeliczalna rodzina rozłącznych kul zawartych w O, o średnicach mniejszych niż δ, których suma pomija jedynie zbiór zerowej miary Lebesgue'a. Ich źródłem są odpowiednio twierdzenie A.8 i lemat A.6 w dodatku A do notatek Iyera wskazanych na końcu rozdziału. Powyżej wyprowadziliśmy z tych wyników równość miar euklidesowych, odpowiadającą twierdzeniu A.4 tych notatek.

Przejdźmy do M. Ustalmy $0 < \varepsilon < 1$. W punkcie p dobierzmy liniowo współrzędne x tak, by $x(p) = 0$ i $G(0) = I_n$. Przy brzegu można to zrobić, wybierając najpierw ortonormalną bazę przestrzeni stycznej do brzegu i dopełniając ją normalną do wnętrza; zmiana liniowa zachowuje

model półprzestrzeni. Na dostatecznie małej domkniętej kuli współrzędnych $\overline{B}_{3r}$ (przy brzegu przeciętej z półprzestrzenią) ciągłość daje

$$(1-\varepsilon)|v|^2 \le g_x(v,v) \le (1+\varepsilon)|v|^2.$$

Niech q, q' leżą w mniejszej kuli B_r. Odcinek prosty daje oszacowanie górne. Krzywa pozostająca w B_{3r} ma długość co najmniej $\sqrt{1-\varepsilon}|x(q)-x(q')|$. Krzywa wychodząca z B_{3r} musi przed pierwszym wyjściem przebyć we współrzędnych co najmniej $2r$, podczas gdy $|x(q)-x(q')| \le 2r$. Dlatego dla *wszystkich* krzywych, także opuszczających mapę, otrzymujemy

$$\sqrt{1-\varepsilon}|x(q)-x(q')| \le d_g(q,q') \le \sqrt{1+\varepsilon}|x(q)-x(q')|. \tag{11.7.2}$$

Dla borelowskiego A zawartego w tej mniejszej mapie Lemat 11.7.3 porównuje $\mathcal{H}^n_{d_g}(A)$ z $\mathcal{L}^n(x(A))$ z czynnikami $(1\pm\varepsilon)^{n/2}$. Te same granice dotyczą $\sqrt{\det G}$, ponieważ wszystkie wartości własne G leżą w $[1-\varepsilon, 1+\varepsilon]$. Eliminując miarę Lebesgue'a między oboma porównaniami, dostajemy

$$\left(\frac{1-\varepsilon}{1+\varepsilon}\right)^{n/2} \mu_g(A) \le \mathcal{H}^n_{d_g}(A) \le \left(\frac{1+\varepsilon}{1-\varepsilon}\right)^{n/2} \mu_g(A).$$

Dla ustalonego ε wybieramy przeliczalne pokrycie takimi mapami (przeliczalna baza gwarantuje istnienie przeliczalnego podpokrycia). Dowolny zbiór borelowski rozcinamy na rozłączne części: najpierw część w pierwszej mapie, następnie w drugiej bez pierwszej itd. Przeliczalna addytywność obu miar daje te same nierówności globalnie. Dopiero teraz puszczamy $\varepsilon \downarrow 0$. Otrzymujemy równość także dla miary nieskończonej, gdyż już dowolna dodatnia dolna stała wymusza nieskończoność drugiej miary.

Pozostaje istotna różnica między odległością otoczenia a odległością wewnętrzną na S. W mapie otoczenia unormowanej jak wyżej wybierzmy lokalną parametryzację $F : V \subset \mathbb{R}^k \to S$, a przy brzegu S – z półprzestrzeni, tak aby $F(0) = p$ i macierz $J = D(x\circ F)_0$ spełniała $J^{\mathsf{T}}J = I_k$. Istnienie takiego wyboru wynika z iniektywności różniczki i ortonormalizacji bazy T_pS. Zmniejszamy V do wypukłej kuli lub półkuli i dla $0<\eta<1$ zapewniamy $\|D(x\circ F)_u - J\| \le \eta$ na V. Parametryzujemy odcinek jako $v + t(u-v)$, $0 \le t \le 1$. Reguła łańcuchowa i twierdzenie podstawowe dają

$$x(F(u)) - x(F(v)) - J(u-v) = \int_0^1 \big(D(x\circ F)_{v+t(u-v)} - J\big)(u-v)\,\mathrm{d}t.$$

Wypukłość V gwarantuje, że cały odcinek leży w V. Norma całki jest więc co najwyżej $\int_0^1 \eta|u-v|\,\mathrm{d}t = \eta|u-v|$, czyli

$$|x(F(u)) - x(F(v)) - J(u-v)| \le \eta|u-v|.$$

W szczególności różnica obrazów ma normę co najmniej $(1-\eta)|u-v|$. Dobieramy V tak małe, żeby jego obraz leżał w kuli B_r z (11.7.2). Każda droga na S jest także drogą na M, a obraz odcinka parametrów jest drogą na S. Zatem

$$\sqrt{1-\varepsilon}(1-\eta)|u-v| \le d_g(F(u),F(v)) \le d_h(F(u),F(v)) \le \sqrt{1+\varepsilon}(1+\eta)|u-v|.$$

Tak samo normy $|DF_u(w)|_g$ są ograniczone przez te dwie stałe razy $|w|$. Wyznacznik Grama daje więc dla gęstości μ_h granice będące k-tymi potęgami tych stałych. Oznaczmy je przez $a = \sqrt{1-\varepsilon}(1-\eta)$ i $b = \sqrt{1+\varepsilon}(1+\eta)$. Dla borelowskiego $A \subset F(V)$ oraz każdej z dwóch odległości $d = d_g|_S, d_h$ mamy więc

$$a^k\mathcal{L}^k(F^{-1}(A)) \le \mathcal{H}^k_d(A) \le b^k\mathcal{L}^k(F^{-1}(A)),$$
$$a^k\mathcal{L}^k(F^{-1}(A)) \le \mu_h(A) \le b^k\mathcal{L}^k(F^{-1}(A)).$$

Pierwsze porównanie wynika z lematu o odwzorowaniach lipschitzowskich, a drugie z całkowania gęstości Grama. Eliminując $\mathcal{L}^k$, dostajemy $(a/b)^k\mu_h(A) \le \mathcal{H}^k_d(A) \le (b/a)^k\mu_h(A)$. Przeliczalne rozcinanie na mapy S daje te nierówności globalnie. Ponieważ $a/b \to 1$ przy $\varepsilon, \eta \downarrow 0$, obie odległości dają μ_h, choć globalnie na ogół nie są równe. Zanurzenie zapewnia, że mapy S opisują jego własną topologię jako podzbioru M; nie liczymy wielokrotności różnych punktów dziedziny immersji. $\square$

Na przykład dla dwóch punktów okręgu $S^1_R \subset \mathbb{R}^2$ o mniejszym kącie środkowym $0 \le \theta \le \pi$ odległość otoczenia jest długością cięciwy $2R\sin(\theta/2)$, a odległość wewnętrzna jest długością krótszego łuku $R\theta$. Mimo tej różnicy obie miary $\mathcal{H}^1$ okręgu są równe jego długości $2\pi R$. Lokalnie iloraz tych odległości dąży do 1, bo $\sin(\theta/2)/(\theta/2) \to 1$; właśnie taką lokalną zgodność wykorzystuje dowód.

Rozróżnijmy dwa użycia twierdzenia: $\mathcal{H}^n(M)$ jest objętością całego n-wymiarowego M, a $\mathcal{H}^{n-1}(\partial M)$ mierzy pole brzegu. Gdy krzywa sama się przecina, jej parametr może liczyć fragment wielokrotnie, podczas gdy miara Hausdorffa jej *obrazu* liczy każdy punkt raz. Miara Hausdorffa nie wymaga gładkości; znaczenie to ma przy zbiorach osobliwych i granicach rozmaitości.

11.8 Dywergencja i twierdzenie Gaussa

Dywergencja pola wektorowego opisuje lokalne źródło lub ujście przepływu. Jeżeli przez mały obszar wypływa więcej niż wpływa, dywergencja jest dodatnia. Metryka określa zarówno objętość obszaru, jak i jednostkową normalną potrzebną do zmierzenia strumienia przez brzeg.

Definicja 11.8.1 (Gradient i dywergencja metryczna)**.** Dla $f \in C^\infty(M)$ *gradient* $\nabla_g f$ jest jedynym polem spełniającym $g(\nabla_g f, Y) = \mathrm{d}f(Y)$ dla każdego pola Y. Na zorientowanej (M^n, g) *dywergencję* pola X określa równość

$$\mathrm{d}(\iota_X \mathrm{vol}_g) = (\mathrm{div}_g X)\,\mathrm{vol}_g. \tag{11.8.1}$$

Definicja jest niezależna od orientacji: jej odwrócenie zmienia znak obu form po obu stronach. Dlatego $\mathrm{div}_g X$ jest zdefiniowana także na rozmaitości nieorientowalnej: wybieramy orientacje lokalnie, a na przecięciach ich znaki różnią się o funkcję lokalnie stałą o wartościach ± 1, której różniczka jest zerowa.

Gradient to $(\mathrm{d}f)^\sharp$ z Definicji 11.1.2; izomorfizm $\sharp_g$ uzasadnia jego istnienie, jednoznaczność i gładkość. W mapie, przy macierzy odwrotnej $(g^{ij}) = G^{-1}$, otrzymujemy $(\nabla_g f)^i = \sum_j g^{ij}\partial_j f$. Na przykład dla $g = \mathrm{d}x^2 + 4\mathrm{d}y^2$ i $f = y$ mamy $\nabla_g f = \frac{1}{4}\partial_y$. Sprawdzenie definicji daje $g(\frac{1}{4}\partial_y, Y) = b = \mathrm{d}y(Y)$ dla $Y = a\partial_x + b\partial_y$. Gradient zależy więc od metryki, chociaż forma $\mathrm{d}f$ od niej nie zależy.

Stwierdzenie 11.8.2 (Wzór lokalny i reguła iloczynu)**.** *Jeżeli* $X = \sum_i X^i\partial_i$ *oraz* $G = (g_{ij})$*, to*

$$\mathrm{div}_g X = \frac{1}{\sqrt{\det G}} \sum_i \partial_i\Big(\sqrt{\det G}\, X^i\Big). \tag{11.8.2}$$

Dla funkcji f *zachodzi* $\mathrm{div}_g(fX) = \mathrm{d}f(X) + f\,\mathrm{div}_g X$*.*

Dowód. W dodatniej mapie połóżmy $w = \sqrt{\det G}$ i $\mathrm{vol}_g = w\,\mathrm{d}x^1\wedge\cdots\wedge\mathrm{d}x^n$. Z definicji kontrakcji

$$\iota_X \mathrm{vol}_g = w\sum_{i=1}^{n}(-1)^{i-1}X^i\,\mathrm{d}x^1\wedge\cdots\wedge\widehat{\mathrm{d}x^i}\wedge\cdots\wedge\mathrm{d}x^n.$$

Po zastosowaniu d do i-tego składnika tylko pochodna względem x^i daje niezerową formę najwyższego stopnia: każda inna różniczka $\mathrm{d}x^j$ powtarzałaby już obecny czynnik. Przeniesienie $\mathrm{d}x^i$ na i-te miejsce daje kolejny znak $(-1)^{i-1}$, który kasuje znak kontrakcji. Otrzymujemy $\mathrm{d}(\iota_X \mathrm{vol}_g) = \sum_i \partial_i(wX^i)\,\mathrm{d}x^1 \wedge \cdots \wedge \mathrm{d}x^n$. Porównanie z (11.8.1) daje (11.8.2). Następnie rozwijamy $\partial_i(wfX^i) = wX^i\partial_i f + f\partial_i(wX^i)$ i sumujemy. □

Jednostkowa normalna zewnętrzna istnieje niezależnie od orientowalności M. W mapie przybrzegowej z $s \geq 0$ połóżmy $\nu = -\nabla_g s/|\nabla_g s|_g$ na $s = 0$. Różniczka $\mathrm{d}s$ jest niezerowa i znika na wektorach stycznych do brzegu, więc wzór daje jednostkowy wektor prostopadły. Ponadto $\mathrm{d}s(-\nabla_g s) = -|\nabla_g s|_g^2 < 0$, zatem wskazuje on stronę malejącego s, czyli na zewnątrz M. Inna funkcja definiująca brzeg ma tam różniczkę $a\,\mathrm{d}s$, $a > 0$; normalizacja usuwa ten czynnik. Lokalne wzory sklejają się więc w jedno gładkie pole ν na ∂M.

Twierdzenie 11.8.3 (Twierdzenie Gaussa o dywergencji)**.** *Niech (M^n, g) będzie zwartą, zorientowaną gładką rozmaitością z gładkim brzegiem, $n \geq 1$, a X gładkim polem wektorowym. Niech ν będzie na ∂M jednostkową normalną skierowaną na zewnątrz, $h = i^*g$ metryką brzegu, a $i : \partial M \hookrightarrow M$ inkluzją. Wówczas*

$$\boxed{\int_M \mathrm{div}_g X \,\mathrm{d}\mu_g = \int_{\partial M} g(X,\nu)\,\mathrm{d}\mu_h.} \tag{11.8.3}$$

Ta sama równość zachodzi dla M niezwartych, jeśli X ma zwarty nośnik. Obowiązuje również bez założenia orientowalności, z całkami względem podanych dodatnich miar.

Dowód. Najpierw przyjmijmy orientację. Wstawmy do Twierdzenia Stokesa 10.7.1 formę $\omega = \iota_X \mathrm{vol}_g$. Definicja dywergencji daje

$$\int_M \mathrm{div}_g X \,\mathrm{vol}_g = \int_M \mathrm{d}\omega = \int_{\partial M} i^*\omega.$$

Dla $n \geq 2$ ustalmy punkt brzegu i dodatnią ortonormalną bazę $(e_1, \ldots, e_{n-1})$ jego przestrzeni stycznej. Z reguły orientowania brzegu w Definicji 10.5.4 baza $(\nu, e_1, \ldots, e_{n-1})$ jest dodatnia w T_pM; stąd $\mathrm{vol}_g(\nu, e_1, \ldots, e_{n-1}) = 1$. Rozłóżmy $X = g(X,\nu)\nu + X^\top$ na część normalną i styczną. Forma naprzemienna zeruje składnik $\mathrm{vol}_g(X^\top, e_1, \ldots, e_{n-1})$, bo jest to n wektorów w $(n-1)$-wymiarowej przestrzeni $T_p\partial M$. Zatem

$$(i^*(\iota_X \mathrm{vol}_g))(e_1, \ldots, e_{n-1}) = \mathrm{vol}_g(X, e_1, \ldots, e_{n-1}) = g(X,\nu).$$

Forma objętościowa brzegu przyjmuje na $(e_1, \ldots, e_{n-1})$ wartość 1, więc $i^*\omega = g(X,\nu)\mathrm{vol}_h$. Dla $n = 1$ używamy konwencji orientacji punktu: $\mathrm{vol}_h(p) = \mathrm{vol}_g(\nu_p) = \varepsilon_p$. Ponieważ $X_p = g(X_p, \nu_p)\nu_p$, ta sama tożsamość $i^*\omega = g(X,\nu)\mathrm{vol}_h$ zachodzi bez wybierania „dodatniej bazy” przestrzeni zerowej. To dowodzi (11.8.3) po uwzględnieniu, że dodatnie formy odpowiadają miarom μ_g i μ_h.

Dla nieorientowalnego M bierzemy podział jedności (ρ_j) o zwartych nośnikach zawartych w mapach, jak w Twierdzeniu 10.4.1. Wybieramy w każdej mapie orientację i stosujemy powyższy dowód do pól $\rho_j X$ w tych mapach. Ich nośniki nie dotykają sztucznych brzegów map. Suma lewych stron jest całką z $\sum_j \mathrm{div}_g(\rho_j X)$, a reguła iloczynu daje

$$\sum_j \mathrm{div}_g(\rho_j X) = \left(\sum_j \rho_j\right) \mathrm{div}_g X + \mathrm{d}\left(\sum_j \rho_j\right)(X) = \mathrm{div}_g X.$$

Na rzeczywistym brzegu $\sum_j g(\rho_j X, \nu) = g(X,\nu)$. Lokalne wybory orientacji nie wpływają na całki z dodatnich gęstości. Ten sam argument z lokalnie skończonym podziałem działa dla pola o zwartym nośniku na niezwartym M; po pomnożeniu przez X pozostaje tylko skończenie wiele składników. □

Wniosek 11.8.4 (Całkowanie przez części)**.** *Przy założeniach Twierdzenia 11.8.3, dla gładkiej funkcji f i pola X,*

$$\int_M g(\nabla_g f, X)\,\mathrm{d}\mu_g = -\int_M f\,\mathrm{div}_g X\,\mathrm{d}\mu_g + \int_{\partial M} f\,g(X,\nu)\,\mathrm{d}\mu_h.$$

Jeśli $\partial M = \varnothing$, to $\int_M \mathrm{div}_g X\,\mathrm{d}\mu_g = 0$.

Dowód. Z definicji gradientu $\mathrm{d}f(X) = g(\nabla_g f, X)$. Zastosujmy (11.8.3) do fX i podstawmy regułę iloczynu ze Stwierdzenia 11.8.2. Przenieśmy składnik z $f\,\mathrm{div}\,X$ na prawą stronę. Dla drugiej tezy podstawmy $f = 1$ i pusty brzeg. □

Przykład 11.8.5 (Kula euklidesowa i strumień)**.** Dla $M = \overline{B}_R(0) \subset \mathbb{R}^3$ i $X(x) = x$ wzór (11.8.2) daje $\mathrm{div}\,X = 3$. Na sferze $\nu = x/R$, więc $X \cdot \nu = R$. Obie strony twierdzenia Gaussa są równe $3(4\pi R^3/3) = R(4\pi R^2) = 4\pi R^3$. Odzyskujemy klasyczne Twierdzenie Gaussa–Ostrogradskiego z Wniosku 10.7.6.
W modelu półprzestrzeni hiperbolicznej $g = y^{-2}(\sum_{a=1}^{n-1}(\mathrm{d}x^a)^2 + \mathrm{d}y^2)$ pole $X = y\partial_y$ ma długość 1, lecz dla $n \geq 2$ ma ujemną dywergencję:

$$\mathrm{div}_g X = y^n \partial_y(y^{-n} y) = y^n(1-n)y^{-n} = 1 - n.$$

Użyliśmy gęstości $w = y^{-n}$ z przykładu modeli. Stała długość pola nie oznacza zerowej dywergencji: przy wzroście y metryka zmienia objętość poprzecznych przekrojów przepływu. Wzór euklidesowy $\partial_y X^y = 1$ pominąłby ten wpływ gęstości.

Dalsza lektura: Trzy modele hiperboliczne i ich izometrie omawiają notatki Danny'ego Calegariego o geometrii hiperbolicznej. Postacie lorentzowskich metryk Schwarzschilda i Kerra opisuje kurs *Geometry of General Relativity* Uniwersytetu Stanowego Oregonu. Równość miary Hausdorffa i objętości riemannowskiej wraz z formułą pola rozwija Isaac Chavel, *Riemannian Geometry: A Modern Introduction*, część III. Fakty o miarze Hausdorffa w przestrzeni euklidesowej, w tym nierówność izodiametryczną i pokrycia Vitalego, omawia dodatek A do *Lecture Notes on Measure Theory* Gautama Iyera.

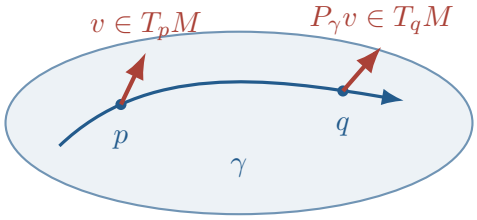
Rozdział 12

Koneksje i transport równoległy

Wektor styczny w punkcie p należy do T_pM, a wektor w punkcie q do innej przestrzeni T_qM. Samo odejmowanie tych wektorów nie ma więc znaczenia. Koneksja mówi, jak różniczkować pole wektorowe, gdy przemieszczamy się po rozmaitości. W metryce riemannowskiej szczególna koneksja pozwala przenosić wektory bez zmiany ich iloczynów skalarnych. Będziemy używać definicji pochodnej pola z Rozdziału 3 oraz metryk z Rozdziału 11.

12.1 Dlaczego zwykła pochodna współrzędnych nie wystarcza?

Na płaszczyźnie euklidesowej wektor można przesuwać równolegle, bo wszystkie przestrzenie styczne mają kanoniczny opis przez $\mathbb{R}^2$. Nawet tu pochodne *współczynników* zależą od bazy: wektor stale wskazujący na wschód ma stałe współczynniki w bazie kartezjańskiej, lecz zmienne w obracającej się bazie biegunowej. Na sferze potrzebny jest ponadto przepis, jak porównać wektory styczne w jej różnych punktach.



Koneksja określa transport wzdłuż γ; wynik może zależeć od drogi.

Rysunek 12.1: Schemat transportu wzdłuż drogi. Strzałki reprezentują wektory w różnych przestrzeniach stycznych; ich położenie na kartce nie wyznacza metryki ani wielkości obrotu.

Definicja 12.1.1 (Koneksja afiniczna)**.** Koneksją afiniczną na TM nazywamy przyporządkowanie $(X, Y) \mapsto \nabla_X Y$ pól wektorowych, liniowe nad $\mathbb{R}$ w obu argumentach, takie że dla $f \in C^\infty(M)$

$$\nabla_{fX} Y = f \nabla_X Y, \qquad \nabla_X (fY) = X(f) Y + f \nabla_X Y. \tag{12.1.1}$$

Pierwszy wzór pozwoli wykazać, że $\nabla_X Y$ w p zależy tylko od wektora X_p. Drugi jest regułą iloczynu: zmienia się zarówno wielkość współczynnika f, jak i samo pole Y.

Lemat 12.1.2 (Lokalność koneksji)**.** *Wartość $(\nabla_X Y)_p$ zależy tylko od ograniczeń X, Y do dowolnego otoczenia p. Można więc stosować koneksję do pól określonych jedynie na otwartym podzbiorze M. W pierwszym argumencie wystarcza sama wartość X_p.*

Dowód. Jeśli pole Z znika na otoczeniu U punktu p, wybieramy gładką funkcję χ o nośniku zawartym w U, równą 1 w pobliżu p. Takie funkcje daje konstrukcja z Sekcji 10.4. Ponieważ $\chi Z = 0$, aksjomaty koneksji dają

$$0 = \nabla_{\chi Z} Y = \chi \nabla_Z Y, \qquad 0 = \nabla_X(\chi Z) = X(\chi)Z + \chi \nabla_X Z.$$

Po obliczeniu w p otrzymujemy $(\nabla_Z Y)_p = 0$ i $(\nabla_X Z)_p = 0$. Odejmowanie pól dowodzi lokalności. Pole określone na U mnożymy przez taką funkcję χ i przedłużamy zerem poza U; wynik obliczenia w p nie zależy od przedłużenia. Te lokalne definicje sklejają się. W lokalnej ramce $X = X^i \partial_i$ pierwsza reguła daje $(\nabla_X Y)_p = X^i(p)(\nabla_{\partial_i} Y)_p$, co dowodzi ostatniego zdania. Drugi argument wymaga także pierwszych pochodnych współczynników pola Y. □

Stwierdzenie 12.1.3 (Współczynniki lokalne)**.** *W mapie $(x^1, \dots, x^n)$ koneksję wyznaczają funkcje Γ^k_{ij}, zwane symbolami Christoffela, określone przez*

$$\nabla_{\partial_i} \partial_j = \sum_k \Gamma^k_{ij} \partial_k. \tag{12.1.2}$$

Dla $X = X^i \partial_i$ i $Y = Y^j \partial_j$ mamy

$$(\nabla_X Y)^k = X^i (\partial_i Y^k + \Gamma^k_{ij} Y^j). \tag{12.1.3}$$

W powtarzających się indeksach stosujemy sumowanie.

Dowód. Z pierwszego aksjomatu $\nabla_X Y = X^i \nabla_{\partial_i}(Y^j \partial_j)$. Z drugiego $\nabla_{\partial_i}(Y^j \partial_j) = (\partial_i Y^j)\partial_j + Y^j \Gamma^k_{ij} \partial_k$. Zbierając współczynniki przy ∂_k, otrzymujemy podany wzór. I odwrotnie: gładkie funkcje Γ^k_{ij} w mapie definiują tam koneksję przez ten wzór. □

Uwaga 12.1.4 (Symbole nie są tensorem). Przy zamianie współrzędnych $x = x(y)$ stosujemy $\partial_{y^a} = (\partial x^i / \partial y^a)\partial_{x^i}$ oraz regułę iloczynu. Jeśli $B^i_a = \partial x^i / \partial y^a$, to przed zmianą bazy w wyniku mamy

$$\nabla_{\partial_{y^a}} \partial_{y^b} = (B^i_a \partial_{x^i} B^k_b + B^i_a B^j_b \Gamma^k_{ij}) \partial_{x^k}.$$

Pierwszy składnik to $\partial^2 x^k / \partial y^a \partial y^b$. Po zapisaniu $\partial_{x^k} = (\partial y^c / \partial x^k)\partial_{y^c}$ otrzymujemy

$$\widetilde{\Gamma}^c_{ab} = \frac{\partial y^c}{\partial x^k} \left(\frac{\partial x^i}{\partial y^a} \frac{\partial x^j}{\partial y^b} \Gamma^k_{ij} + \frac{\partial^2 x^k}{\partial y^a \partial y^b} \right). \tag{12.1.4}$$

Druga pochodna jest dodatkowym składnikiem; same Γ^k_{ij} nie tworzą tensora. To pozwala mieć zerowe symbole w kartezjańskim opisie płaszczyzny i niezerowe w biegunowym, choć geometrycznie jest to ta sama płaszczyzna.

Definicja 12.1.5 (Torsja i zgodność z metryką)**.** Torsją koneksji jest pole tensorowe

$$T(X, Y) = \nabla_X Y - \nabla_Y X - [X, Y].$$

Koneksja jest *bez torsji*, gdy $T = 0$. Jeżeli g jest metryką, koneksja jest z nią *zgodna*, gdy dla dowolnych pól

$$X\big(g(Y, Z)\big) = g(\nabla_X Y, Z) + g(Y, \nabla_X Z). \tag{12.1.5}$$

Stwierdzenie 12.1.6 (Co zależy tylko od wartości w punkcie?)**.** *Torsja jest tensorem typu $(1,2)$. Jeżeli ∇ i $\widehat{\nabla}$ są koneksjami, to $A(X, Y) = \widehat{\nabla}_X Y - \nabla_X Y$ również jest tensorem typu $(1,2)$.*

Dowód. W pierwszym argumencie dla torsji używamy $[fX,Y] = f[X,Y] - Y(f)X$. Po rozwinięciu

$$T(fX,Y) = f\nabla_X Y - Y(f)X - f\nabla_Y X - f[X,Y] + Y(f)X = fT(X,Y).$$

Analogicznie $[X,fY] = f[X,Y] + X(f)Y$, więc wyrazy $X(f)Y$ w $T(X,fY)$ się skracają. Ponieważ ∇ i $\widehat{\nabla}$ mają tę samą regułę iloczynu, również w ich różnicy kasują się składniki $X(f)Y$. Dokładniej, $A(fX,Y) = fA(X,Y)$ i $A(X,fY) = fA(X,Y)$. W lokalnej bazie każda z tych dwuliniowych operacji $B = T, A$ ma więc postać $B(X,Y)^k = B^k_{ij}X^iY^j$, gdzie $B(\partial_i,\partial_j) = B^k_{ij}\partial_k$. Współczynniki B^k_{ij} są gładkie, a wartość wyniku w p zależy tylko od X_p, Y_p. To uzasadnia stwierdzenie, że otrzymaliśmy pola tensorowe. To wyjaśnia, czemu przestrzeń wszystkich koneksji jest afiniczna: do jednej koneksji można dodać dowolny tensor takiego typu. W mapie $T^k_{ij} = \Gamma^k_{ij} - \Gamma^k_{ji}$, bo $[\partial_i,\partial_j] = 0$. □

Najprostszy przykład dowolności daje prosta z metryką $\mathrm{d}x^2$. Dla stałej $c \in \mathbb{R}$ wzór $\nabla^c_{a\partial_x}(b\partial_x) = a(b' + cb)\partial_x$ spełnia oba aksjomaty koneksji. Każda z tych koneksji ma zerową torsję, ponieważ w wymiarze 1 tensor antysymetryczny w dwóch argumentach jest zerowy. Zgodność z metryką dla $X = Y = Z = \partial_x$ wymaga jednak $0 = \partial_x g(\partial_x,\partial_x) = 2c$. Tylko $c = 0$ jest zatem zgodne z tą metryką.

12.2 Koneksja Leviego-Civity i wzór Koszula

Metryka dostarcza iloczynu skalarnego w każdym punkcie. Wybieramy koneksję, która zachowuje ten iloczyn podczas przemieszczania się, i żądamy zerowej torsji. Te dwa warunki usuwają dowolność.

Twierdzenie 12.2.1 (Istnienie i jednoznaczność koneksji Leviego-Civity)**.** *Każda metryka riemannowska g na M wyznacza dokładnie jedną koneksję ∇ zgodną z g i bez torsji. Ta sama teza zachodzi dla metryki pseudoriemannowskiej, w szczególności Schwarzschilda i Kerra.*

Dowód. Krok 1: wyprowadzenie wzoru i jednoznaczność. Załóżmy, że taka koneksja istnieje. Zapiszmy (12.1.5) kolejno dla (X,Y,Z), (Y,Z,X) oraz (Z,X,Y):

$$\begin{aligned} Xg(Y,Z) &= g(\nabla_X Y, Z) + g(Y, \nabla_X Z),\\ Yg(Z,X) &= g(\nabla_Y Z, X) + g(Z, \nabla_Y X),\\ Zg(X,Y) &= g(\nabla_Z X, Y) + g(X, \nabla_Z Y). \end{aligned}$$

Dodajemy dwa pierwsze równania i odejmujemy trzecie. Brak torsji daje $\nabla_Y X = \nabla_X Y - [X,Y]$, $\nabla_Z X = \nabla_X Z - [X,Z]$ oraz $\nabla_Z Y = \nabla_Y Z - [Y,Z]$. Po podstawieniu pary z $\nabla_X Z$ i pary z $\nabla_Y Z$ się skracają. Zostaje

$$\begin{aligned} 2g(\nabla_X Y, Z) = {} & Xg(Y,Z) + Yg(Z,X) - Zg(X,Y)\\ & + g([X,Y],Z) - g([X,Z],Y) - g([Y,Z],X). \end{aligned} \tag{12.2.1}$$

Jest to *wzór Koszula*. Jego prawa strona zależy wyłącznie od g, X, Y, Z. Niezdegenerowanie g_p sprawia, że wartości $g_p(W, Z_p)$ dla wszystkich Z_p wyznaczają jedyny wektor W. Stąd co najwyżej jedna taka koneksja.

Krok 2: konstrukcja. Oznaczmy prawą stronę (12.2.1) przez $K(X,Y,Z)$ i zdefiniujmy $\nabla_X Y$ przez $2g(\nabla_X Y, Z) = K(X,Y,Z)$. Najpierw trzeba sprawdzić, że prawa strona jest C^∞-liniowa względem Z. Po zastąpieniu Z przez fZ składniki z $X(f)g(Y,Z)$ pochodzące od $Xg(Y,fZ)$ i $-g([X,fZ],Y)$ mają przeciwne znaki; tak samo znoszą się $Y(f)g(X,Z)$ z $Yg(fZ,X)$ i

$-g([Y,fZ],X)$. Reszta jest pomnożona przez f. Zatem $K(X,Y,\cdot)$ jest gładką 1-formą, której współczynniki w mapie to $K(X,Y,\partial_i)$. Jawnie

$$(\nabla_X Y)^j = \tfrac{1}{2} g^{ji} K(X,Y,\partial_i).$$

Macierz G^{-1} jest gładka, więc otrzymujemy gładkie pole. Definicje w różnych mapach są zgodne, ponieważ wszystkie spełniają tę samą równość z g, a niezdegenerowanie metryki zapewnia punktową jednoznaczność.

Sprawdźmy aksjomaty koneksji. W $K(fX,Y,Z)$ dodatkowe $Y(f)g(X,Z)$ z $Yg(Z,fX)$ znosi $-Y(f)g(X,Z)$ z $g([fX,Y],Z)$. Dodatkowe $-Z(f)g(X,Y)$ z $-Zg(fX,Y)$ znosi $+Z(f)g(X,Y)$ z $-g([fX,Z],Y)$. Wobec tego $K(fX,Y,Z) = fK(X,Y,Z)$. W $K(X,fY,Z)$ dwukrotnie pojawia się $X(f)g(Y,Z)$: z $Xg(fY,Z)$ oraz $g([X,fY],Z)$. Wyrazy $Z(f)g(X,Y)$ z $-Zg(X,fY)$ i $-g([fY,Z],X)$ znoszą się. Dostajemy

$$K(X,fY,Z) = fK(X,Y,Z) + 2X(f)g(Y,Z).$$

Po podzieleniu przez 2 i użyciu niezdegenerowania g są to dokładnie aksjomaty (12.1.1). Addytywność i liniowość nad $\mathbb{R}$ w obu argumentach wynikają wprost z tych własności pochodnych i nawiasu w definicji K.

Krok 3: sprawdzenie warunków. Różnica $K(X,Y,Z) - K(Y,X,Z)$ jest równa $2g([X,Y],Z)$: pochodne metryki się kasują, a antysymetria nawiasu daje wyraz podwojony. Stąd $\nabla_X Y - \nabla_Y X = [X,Y]$. Dodając $K(X,Y,Z)$ i $K(X,Z,Y)$, otrzymujemy $2Xg(Y,Z)$: pozostałe pochodne i wyrazy z nawiasami redukują się parami. To jest (12.1.5). Użyliśmy jedynie niezdegenerowania macierzy G, nie jej dodatniej określoności; dowód dotyczy również metryk lorentzowskich. □

W szczególności istnienie metryki riemannowskiej z Twierdzenia 11.1.8 zapewnia istnienie *jakiejś* koneksji afinicznej na każdej rozmaitości z naszych założeń. Koneksji jest zwykle wiele, ale dla ustalonego g warunki z twierdzenia wybierają jedną.

Stwierdzenie 12.2.2 (Podrozmaitość w przestrzeni euklidesowej)**.** *Jeżeli $M \subset \mathbb{R}^N$ ma metrykę indukowaną, to jej koneksja Leviego-Civity jest równa*

$$\nabla_X Y = \mathrm{pr}_{TM}(D_X Y),$$

gdzie $D_X Y$ oznacza zwykłą pochodną pola Y traktowanego jako odwzorowanie do $\mathbb{R}^N$.

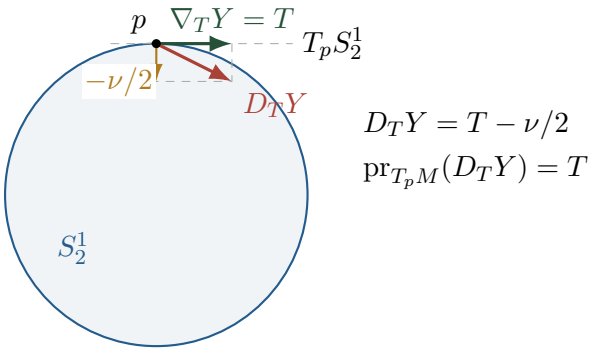
Dowód. Rzut ortogonalny jest liniowy w punkcie, a pochodna euklidesowa spełnia regułę iloczynu, więc wzór spełnia aksjomaty koneksji. Jego gładkość wynika z gładkości rzutu na TM, uzasadnionej przy wiązce normalnej w Sekcji 11.6. Pochodna iloczynu skalarnego w $\mathbb{R}^N$ daje $X\langle Y,Z\rangle = \langle D_X Y, Z\rangle + \langle Y, D_X Z\rangle$. Składowe normalne obu pochodnych są prostopadłe do Y lub Z i znikają z tej równości; koneksja jest zgodna z metryką indukowaną. Aby sprawdzić torsję, weźmy lokalną parametryzację F. Zapisując $X = X^i F_i$, $Y = Y^j F_j$, gdzie $F_i = \partial_i F$, otrzymujemy

$$D_X Y = X^i(\partial_i Y^j) F_j + X^i Y^j F_{ij}, \qquad D_Y X = Y^i(\partial_i X^j) F_j + Y^i X^j F_{ij}.$$

W różnicy wyrazy z F_{ij} znoszą się: po zamianie i,j mają te same współczynniki, bo $F_{ij} = F_{ji}$. Zostaje $(X^i\partial_i Y^j - Y^i\partial_i X^j)F_j = [X,Y]$. Ten wektor jest styczny, więc rzut go nie zmienia. Stąd $\nabla_X Y - \nabla_Y X = [X,Y]$. Stosujemy Twierdzenie 12.2.1. □

Różnicę między pochodnymi można zobaczyć już na okręgu $S^1_2 \subset \mathbb{R}^2$ o promieniu 2. Krzywa $\gamma(s) = (2\sin(s/2), 2\cos(s/2))$ ma jednostkową prędkość $T = \dot\gamma$. W punkcie $p = \gamma(0) = (0,2)$ zewnętrzna normalna to $\nu = (0,1)$, a $D_T T = \ddot\gamma(0) = -\nu/2$. Dla pola $Y(\gamma(s)) = (1+s)T(s)$,

określonego na małym łuku, reguła iloczynu daje więc $D_T Y = T - \nu/2$ w p. Rzut usuwa składnik normalny: $\nabla_T Y = T$.



Rysunek 12.2: Pochodna pola stycznego w przestrzeni otaczającej może mieć składową normalną. Na okręgu z metryką indukowaną pochodna kowariantna jest jej częścią styczną. Rysunek przedstawia rozkład w punkcie p dla pola $Y = (1+s)T$ opisanego powyżej.

12.3 Symbole Christoffela w geometriach modelowych

W mapie pola bazowe komutują, więc wzór Koszula z $X = \partial_i$, $Y = \partial_j$, $Z = \partial_\ell$ przyjmuje postać

$$2g_{k\ell}\Gamma^k_{ij} = \partial_i g_{j\ell} + \partial_j g_{i\ell} - \partial_\ell g_{ij}.$$

Mnożymy przez $g^{m\ell}$, gdzie $(g^{m\ell}) = G^{-1}$. Ponieważ $g^{m\ell}g_{k\ell} = \delta^m_k$, otrzymujemy

$$\boxed{\Gamma^m_{ij} = \frac{1}{2} g^{m\ell}(\partial_i g_{j\ell} + \partial_j g_{i\ell} - \partial_\ell g_{ij}).} \tag{12.3.1}$$

Algorytm jest prosty: zapisać G, odwrócić ją, obliczyć pochodne współczynników, podstawić. Duże metryki nie wymagają zapamiętania wielkiej listy symboli; zwykle liczymy tylko te, które potrzebne są w danym równaniu.

Przykład 12.3.1 (symbole Christoffela metryki FLRW)**.** Dla metryki (11.3.6) przyjmijmy $x^0 = t$ oraz $i, j \in \{1,2,3\}$. Jedynymi pochodnymi współczynników, które mogą być niezerowe, są $\partial_0 g_{ij} = 2a\dot{a}\,\delta_{ij}$. Ze wzoru (12.3.1) dostajemy

$$\Gamma^0_{ij} = a\dot{a}\,\delta_{ij}, \qquad \Gamma^i_{0j} = \Gamma^i_{j0} = H\delta^i_j, \tag{12.3.2}$$

przy czym wszystkie niewypisane symbole znikają. Istotnie, $\Gamma^0_{ij} = \frac{1}{2}g^{00}(-\partial_0 g_{ij}) = a\dot{a}\,\delta_{ij}$ oraz $\Gamma^i_{0j} = \frac{1}{2}g^{ik}\partial_0 g_{kj} = (\dot{a}/a)\delta^i_j$. Równoważnie, dla $\partial_0 = \partial_t$,

$$\nabla_{\partial_0}\partial_0 = 0, \qquad \nabla_{\partial_0}\partial_i = \nabla_{\partial_i}\partial_0 = H\partial_i, \qquad \nabla_{\partial_i}\partial_j = a\dot{a}\,\delta_{ij}\partial_0.$$

Przykład 12.3.2 (Płaszczyzna euklidesowa w dwóch mapach)**.** W kartezjańskiej mapie $g = \mathrm{d}x^2 + \mathrm{d}y^2$, wszystkie g_{ij} są stałe, zatem $\Gamma^k_{ij} = 0$. W biegunowej mapie $x = r\cos\phi$, $y = r\sin\phi$ (dla $r > 0$ i ϕ w otwartym przedziale długości co najwyżej 2π) ta sama metryka jest $g = \mathrm{d}r^2 + r^2\mathrm{d}\phi^2$. Macierze $G = \mathrm{diag}(1, r^2)$ i $G^{-1} = \mathrm{diag}(1, r^{-2})$ oraz $\partial_r g_{\phi\phi} = 2r$ dają

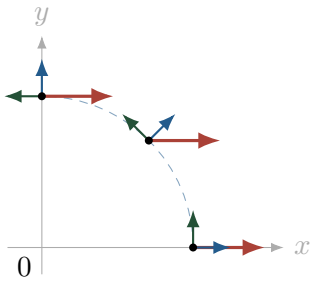
$$\Gamma^r_{\phi\phi} = -r, \qquad \Gamma^\phi_{r\phi} = \Gamma^\phi_{\phi r} = \frac{1}{r}, \tag{12.3.3}$$

a wszystkie pozostałe symbole są zerowe. Dokładniej, jedyna pochodna metryki daje dwa rodzaje składników: $\Gamma^r_{\phi\phi} = -\frac{1}{2}g^{rr}\partial_r g_{\phi\phi} = -\frac{1}{2}(2r) = -r$ oraz $\Gamma^\phi_{r\phi} = \frac{1}{2}g^{\phi\phi}\partial_r g_{\phi\phi} = \frac{1}{2}r^{-2}(2r) = 1/r$.

Symetria dolnych indeksów daje $\Gamma^{\phi}_{\phi r}$; w każdej innej kombinacji indeksów wszystkie pochodne we wzorze (12.3.1) są zerowe. Na przykład $\nabla_{\partial_\phi}\partial_\phi = -r\partial_r$: wektor ∂_ϕ w miarę obrotu układu zmienia kierunek nawet wtedy, gdy płaszczyzna pozostaje płaska. Wzór $\nabla_X Y$ uwzględnia ten obrót bazy. Sprawdźmy, że poprawka rzeczywiście usuwa zmianę współrzędnych stałego pola kartezjańskiego $U = \partial_x = \cos\phi\,\partial_r - (\sin\phi/r)\partial_\phi$. Z (12.1.3) otrzymujemy

$$(\nabla_{\partial_\phi} U)^r = -\sin\phi + (-r)\frac{-\sin\phi}{r} = 0, \qquad (\nabla_{\partial_\phi} U)^\phi = -\frac{\cos\phi}{r} + \frac{\cos\phi}{r} = 0.$$

Zmiana współczynników U nie oznacza więc zmiany samego wektora w przestrzeni euklidesowej.



$U = \partial_x = \cos\phi\, e_r - \sin\phi\, e_\phi$

$e_r = \partial_r$
$e_\phi = r^{-1}\partial_\phi$
U: stale ten sam wektor

Rysunek 12.3: Na płaskiej przestrzeni baza biegunowa obraca się wraz z położeniem punktu. Czerwone strzałki przedstawiają to samo pole ∂_x przy kątach $0, \pi/4, \pi/2$; niebieskie i zielone wskazują lokalne kierunki bazy ortonormalnej. Długości strzałek bazowych skrócono dla czytelności. Koneksja uwzględnia obrót bazy przy różniczkowaniu współczynników.

Przykład 12.3.3 (Sfera o promieniu R)**.** Z (11.2.1) odczytujemy $G = \mathrm{diag}(R^2, R^2\sin^2\theta)$. Jedyna niezerowa pochodna współczynników to $\partial_\theta g_{\phi\phi} = 2R^2\sin\theta\cos\theta$. Stąd

$$\Gamma^{\theta}_{\phi\phi} = -\sin\theta\cos\theta, \qquad \Gamma^{\phi}_{\theta\phi} = \Gamma^{\phi}_{\phi\theta} = \cot\theta. \tag{12.3.4}$$

Podstawienia są tu analogiczne do biegunowych, ale zapiszmy czynniki zależne od R: $\Gamma^{\theta}_{\phi\phi} = -\frac{1}{2}R^{-2}(2R^2\sin\theta\cos\theta) = -\sin\theta\cos\theta$ oraz $\Gamma^{\phi}_{\theta\phi} = \frac{1}{2}(R^2\sin^2\theta)^{-1}(2R^2\sin\theta\cos\theta) = \cot\theta$. Inne pochodne metryki znikają, więc nie powstają dalsze symbole poza wymianą dolnych indeksów. Brak R w tych symbolach jest zgodny z tym, że stałe przemnożenie metryki nie zmienia jej koneksji: dla $g \mapsto cg$, $c > 0$, macierz odwrotna dostaje czynnik c^{-1}, a każda pochodna współczynnika czynnik c. We wzorze (12.3.1) czynniki te się skracają. Bieguny wymagają innej mapy; $\cot\theta$ nie opisuje tam osobliwości sfery.

Przykład 12.3.4 (Górna półprzestrzeń hiperboliczna)**.** Dla dwuwymiarowego modelu $g = y^{-2}(\mathrm{d}x^2 + \mathrm{d}y^2)$, $y > 0$, macierze $G = y^{-2}I$, $G^{-1} = y^2 I$. Ponieważ $\partial_y(y^{-2}) = -2y^{-3}$, (12.3.1) daje

$$\Gamma^{y}_{xx} = \frac{1}{y}, \quad \Gamma^{y}_{yy} = -\frac{1}{y}, \quad \Gamma^{x}_{xy} = \Gamma^{x}_{yx} = -\frac{1}{y}. \tag{12.3.5}$$

Istotnie, $\Gamma^{y}_{xx} = -\frac{1}{2}y^2\partial_y(y^{-2}) = 1/y$, $\Gamma^{y}_{yy} = \frac{1}{2}y^2\partial_y(y^{-2}) = -1/y$ i $\Gamma^{x}_{xy} = \frac{1}{2}y^2\partial_y(y^{-2}) = -1/y$. Każdy inny składnik zawiera pochodną po x albo pochodną zerowego współczynnika mieszanego. W wyższych wymiarach, dla $g = y^{-2}(\sum_a \mathrm{d}x_a^2 + \mathrm{d}y^2)$, podobnie $\Gamma^{y}_{x_a x_b} = \delta_{ab}/y$, $\Gamma^{x_a}_{x_b y} = \Gamma^{x_a}_{y x_b} = -\delta^a_b/y$ oraz $\Gamma^{y}_{yy} = -1/y$; pozostałe symbole są zerowe. Na przykład pole w kierunku x przenoszone pionowo musi mieć odpowiednio zmienne współrzędne: $\nabla_{\partial_y}(y\partial_x) = 0$. Rzeczywiście $\partial_y(y) = 1$ oraz $\Gamma^{x}_{yx}y = -1$; jego długość w metryce hiperbolicznej stale wynosi 1.

Przykład 12.3.5 (Kula Poincarégo: jawne symbole)**.** Metryka (11.2.4) ma postać $g = \lambda(u)^2\sum_i(\mathrm{d}u^i)^2$, $\lambda = 2/(1-|u|^2) > 0$. Indeksy $u_i = u^i$ w tym przykładzie odnoszą się do współrzędnych euklidesowych; nie oznaczają obniżenia indeksu metryką hiperboliczną. Po

wstawieniu $g_{ij} = \lambda^2\delta_{ij}$ i $g^{ij} = \lambda^{-2}\delta^{ij}$ do (12.3.1) otrzymujemy dla dowolnej metryki takiej postaci

$$\Gamma^k_{ij} = \delta^k_i\partial_j \log\lambda + \delta^k_j\partial_i\log\lambda - \delta_{ij}\partial_k\log\lambda. \tag{12.3.6}$$

Rzeczywiście $\partial_i g_{j\ell} = 2\lambda(\partial_i\lambda)\delta_{j\ell}$; kontrakcja z $\lambda^{-2}\delta^{k\ell}/2$ daje trzy pokazane wyrazy. Ponieważ $\partial_k\log\lambda = 2u_k/(1-|u|^2)$, otrzymujemy *jawnie*

$$\boxed{\Gamma^k_{ij} = \frac{2}{1-|u|^2}(\delta^k_i u_j + \delta^k_j u_i - \delta_{ij}u_k).} \tag{12.3.7}$$

Na przykład w dysku o współrzędnych (u,v), przy $D = 1-u^2-v^2$, niezależne składowe to

$$\begin{aligned} \Gamma^u_{uu} &= 2u/D, & \Gamma^u_{uv} &= 2v/D, & \Gamma^u_{vv} &= -2u/D,\\ \Gamma^v_{uu} &= -2v/D, & \Gamma^v_{uv} &= 2u/D, & \Gamma^v_{vv} &= 2v/D. \end{aligned}$$

Wszystkie symbole znikają *w środku* dysku, ale to nie czyni metryki płaską: pochodne symboli w (14.1.2) z Rozdziału 14 mogą być niezerowe. Jako kontrolę wzoru weźmy średnicę $u = r$, $v = 0$. Pole $V = \frac{1-r^2}{2}\partial_v$ wzdłuż niej ma długość 1 i jest równoległe, gdyż

$$\nabla_{\partial_r}V = \left(-r + \Gamma^v_{uv}\frac{1-r^2}{2}\right)\partial_v = \left(-r + \frac{2r}{1-r^2}\frac{1-r^2}{2}\right)\partial_v = 0.$$

Przykład 12.3.6 (Hiperboloida: symbole w mapie przestrzennej)**.** Użyjmy współrzędnych z z (11.2.5), oznaczając $t^2 = 1+|z|^2$. Także tutaj $z_i = z^i$ oznacza współrzędne w euklidesowej przestrzeni parametrów. Mamy $g_{ij} = \delta_{ij} - z_iz_j/t^2$ oraz $g^{ij} = \delta^{ij} + z_iz_j$ z (11.2.6). Po zróżniczkowaniu

$$\partial_i g_{j\ell} = -\frac{\delta_{ij}z_\ell + \delta_{i\ell}z_j}{t^2} + \frac{2z_iz_jz_\ell}{t^4},$$

więc trzy pochodne ze wzoru (12.3.1) łączą się w

$$\partial_i g_{j\ell} + \partial_j g_{i\ell} - \partial_\ell g_{ij} = -\frac{2z_\ell}{t^2}\left(\delta_{ij} - \frac{z_iz_j}{t^2}\right) = -\frac{2z_\ell}{t^2}g_{ij}.$$

Ponieważ $g^{k\ell}z_\ell = t^2z^k$, otrzymujemy

$$\boxed{\Gamma^k_{ij} = -z^k g_{ij} = -z^k\left(\delta_{ij} - \frac{z_iz_j}{1+|z|^2}\right).} \tag{12.3.8}$$

Na przykład dla $z(\tau) = (\sinh\tau, 0, \ldots, 0)$ mamy $g_{11} = 1/\cosh^2\tau$ oraz $\Gamma^1_{11} = -\sinh\tau/\cosh^2\tau$. Równanie geodezyjnej w pierwszej współrzędnej przyjmuje zatem postać $\ddot z^1 + \Gamma^1_{11}(\dot z^1)^2 = \sinh\tau - \sinh\tau = 0$, zgodnie ze wzorem (13.4.2) w rozdziale o geodezyjnych.

Izometrie między modelami z Przykładu 11.2.3 przenoszą te koneksje: wynika to z jednoznaczności koneksji Leviego-Civity przy zachowaniu zgodności z metryką i braku torsji. Dokładniej, dla izometrii $F : (M,g) \to (N,h)$ definiujemy na M

$$\widehat\nabla_X Y = (F^{-1})_*(\nabla^h_{F_*X}(F_*Y)).$$

Reguła łańcuchowa daje aksjomaty koneksji. Równości $F_*[X,Y] = [F_*X, F_*Y]$ i $F^*h = g$ zapewniają zerową torsję oraz zgodność z g. Jednoznaczność daje $\widehat\nabla = \nabla^g$, czyli $F_*(\nabla^g_X Y) = \nabla^h_{F_*X}(F_*Y)$. Symboli Christoffela *nie porównujemy bezpośrednio* między różnymi mapami: transformują się wraz z pochodnymi zmiany współrzędnych, podczas gdy sama koneksja jest tym samym obiektem geometrycznym.

Stwierdzenie 12.3.7 (Dywergencja zapisana przez koneksję)**.** *Dla koneksji Leviego-Civity i pola X na rozmaitości riemannowskiej tensor ∇X przyporządkowuje wektorowi Y_p wektor $(\nabla_Y X)_p$. Jego ślad jest dywergencją:*

$$\operatorname{div}_g X = \nabla_i X^i = \partial_i X^i + \Gamma^i_{ij} X^j = \frac{1}{\sqrt{\det G}} \partial_i (\sqrt{\det G}\, X^i). \tag{12.3.9}$$

Jest to ten sam operator, który wystąpił w Twierdzeniu Gaussa w Rozdziale 11.

Dowód. Podstawiamy (12.3.1) i korzystamy z symetrii macierzy. Przy sumowaniu po i składniki $g^{i\ell}\partial_i g_{j\ell}$ i $-g^{i\ell}\partial_\ell g_{ij}$ są przeciwne po zamianie nazw indeksów i, ℓ. Pozostaje

$$\Gamma^i_{ij} = \tfrac{1}{2} g^{i\ell} \partial_j g_{i\ell} = \partial_j \log \sqrt{\det G}.$$

Ostatnia równość jest wzorem na pochodną wyznacznika: $\partial_j \det G = (\det G)\operatorname{tr}(G^{-1}\partial_j G)$. Można go otrzymać z $G(x + he_j) = G(x)(I + hG^{-1}\partial_j G + o(h))$: w rozwinięciu $\det(I + hB)$ wyrazy liniowe pochodzą tylko z wyboru jednego diagonalnego składnika hB_{ii}, więc $\det(I + hB) = 1 + h \operatorname{tr} B + o(h)$. Reguła iloczynu daje ostatnie wyrażenie w (12.3.9), zgodne z wcześniejszym (11.8.2). □

Wzór Koszula w ramie nieholonomicznej: geometria Nil

We współrzędnej ramie ∂_i zachodzi $[\partial_i, \partial_j] = 0$. W geometrycznych modelach grup Liego znacznie wygodniejsze bywają jednak ramy ortonormalne, których pola nie komutują. Nie wolno wtedy stosować wzorów na symbole Christoffela tak, jakby były ramą współrzędną.

Stwierdzenie 12.3.8 (Koneksja w ramie ortonormalnej)**.** *Niech $E_1, \dots, E_n$ będzie lokalną ramą ortonormalną, a $c^k_{ij} = g([E_i, E_j], E_k)$. Wtedy dla koneksji Leviego-Civity*

$$2g(\nabla_{E_i} E_j, E_k) = c^k_{ij} - c^i_{jk} + c^j_{ki}. \tag{12.3.10}$$

Dowód. Wstawiamy E_i, E_j, E_k do wzoru Koszula (12.2.1). Wszystkie pochodne $E_i(g(E_j, E_k))$ znikają, ponieważ $g(E_j, E_k) = \delta_{jk}$ jest stałe. Pozostają trzy wyrazy zawierające nawiasy pól, co daje powyższą formułę. Równość ta nie wymaga, aby rama pochodziła od mapy współrzędnych. □

Przykład 12.3.9 (Koneksja Leviego-Civity w grupie Heisenberga)**.** Dla metryki g_N z Przykładu 11.2.4 weźmy ramę $E_1 = \partial_x$, $E_2 = \partial_y + x\partial_z$, $E_3 = \partial_z$. Jest ona ortonormalna, a jedynym niezerowym nawiasem bazowym (z dokładnością do antysymetrii) jest $[E_1, E_2] = E_3$. Stąd (12.3.10) daje

$$\begin{aligned} \nabla_{E_1} E_2 &= \tfrac{1}{2} E_3, & \nabla_{E_2} E_1 &= -\tfrac{1}{2} E_3, \\ \nabla_{E_1} E_3 &= -\tfrac{1}{2} E_2, & \nabla_{E_3} E_1 &= -\tfrac{1}{2} E_2, \\ \nabla_{E_2} E_3 &= \tfrac{1}{2} E_1, & \nabla_{E_3} E_2 &= \tfrac{1}{2} E_1. \end{aligned}$$

Ponadto $\nabla_{E_i} E_i = 0$ dla każdego i. Przykładowo $2g(\nabla_{E_1} E_2, E_3) = g([E_1, E_2], E_3) = 1$. Natomiast $2g(\nabla_{E_1} E_3, E_2) = g([E_2, E_1], E_3) = -1$: ten wyraz pochodzi z ostatniego nawiasu we wzorze Koszula. Trzecia niezależna wartość wynika z $2g(\nabla_{E_2} E_3, E_1) = c^1_{23} - c^2_{31} + c^3_{12} = 0 - 0 + 1 = 1$. Brak torsji daje następnie $\nabla_{E_2} E_1 = \nabla_{E_1} E_2 - E_3$, $\nabla_{E_3} E_1 = \nabla_{E_1} E_3$ i $\nabla_{E_3} E_2 = \nabla_{E_2} E_3$. Dla pochodnych diagonalnych wzór ma postać $2g(\nabla_{E_i} E_i, E_k) = -2c^i_{ik} = 0$, bo jedyny niezerowy współczynnik nawiasu ma trzy różne indeksy. Pozostałe składowe każdej z tych pochodnych są zerowe, bo odpowiednie współczynniki c^k_{ij} znikają. Różnica $\nabla_{E_1} E_2 - \nabla_{E_2} E_1 = E_3$ równa się $[E_1, E_2]$, a dla par (E_1, E_3) i (E_2, E_3) obie różnice są zerowe, tak samo jak nawiasy. Koneksja nie ma więc torsji, mimo że współczynniki w tej ramie nie są symetryczne. Ten sam rachunek posłuży do wyznaczenia tensora krzywizny w Przykładzie 14.4.8.

12.4 Pochodna kowariantna i transport wzdłuż krzywej

Pochodna $\nabla_X Y$ odpowiada na pytanie: jak szybko zmienia się Y, gdy ruszamy z punktu w kierunku X, *z uwzględnieniem zmiany lokalnej bazy*? Wzór (12.1.3) dodaje do pochodnej współrzędnych dokładnie poprawkę $\Gamma^k_{ij} X^i Y^j$.

Definicja 12.4.1 (Pochodna wzdłuż krzywej)**.** Niech $\gamma : I \to M$ będzie gładką krzywą. Gładkie pole wzdłuż niej to gładkie odwzorowanie $V : I \to TM$ z $V(t) \in T_{\gamma(t)}M$, czyli gładki przekrój wiązki $\gamma^* TM$. Jego pochodną kowariantną oznaczamy $DV/\mathrm{d}t$ lub $\nabla_{\dot\gamma} V$. W mapie, przy $\gamma(t) = (x^i(t))$ oraz $V(t) = V^k(t)\partial_k|_{\gamma(t)}$, jest to

$$\frac{DV}{\mathrm{d}t} = \left(\frac{\mathrm{d}V^k}{\mathrm{d}t} + \Gamma^k_{ij}(\gamma(t)) \dot x^i V^j \right) \partial_k|_{\gamma(t)}. \tag{12.4.1}$$

Pole jest *równoległe* wzdłuż γ, gdy $DV/\mathrm{d}t = 0$. Rozwiązanie z wartością $V(a) = v$ oznaczymy przez $V(t) = P_{\gamma, a\to t} v$.

Uzasadnijmy niezależność od mapy bez zakładania, że V ma przedłużenie do pola na M. Niech $J(t)$ będzie macierzą $\partial y/\partial x$ w $\gamma(t)$ i niech $A^k{}_j = \Gamma^k_{ij}(\gamma(t))\dot x^i$. Współczynniki pola w nowych współrzędnych to $\widetilde V = JV$. Oznaczmy $B = J^{-1} = \partial x/\partial y$. Po pomnożeniu (12.1.4) przez $\dot y^a$ pierwszy składnik daje JAB, bo $B^i_a \dot y^a = \dot x^i$. Druga pochodna zmiany mapy daje $J\dot B$, ponieważ $\dot B^k_b = (\partial B^k_b/\partial y^a)\dot y^a$. Zatem $\widetilde A = JAB + J\dot B$. Różniczkując $JB = I$, otrzymujemy $J\dot B = -\dot J B$. W konsekwencji

$$\begin{aligned} \widetilde A &= JAJ^{-1} - \dot J J^{-1}, \\ \dot{\widetilde V} + \widetilde A \widetilde V &= \dot J V + J\dot V + JAV - \dot J V = J(\dot V + AV). \end{aligned}$$

Jest to dokładnie prawo transformacji wektora, więc definicja jest poprawna również przy samoprzecięciach i punktach z $\dot\gamma = 0$. Potrzeba tego argumentu: dla krzywej stałej $\gamma(t) = p$ pole $V(t) = tv$, $v \neq 0$, nie jest nawet lokalnie ograniczeniem jednego pola na M.

Jeżeli $V = Y \circ \gamma$ pochodzi od pola z otoczenia, reguła łańcuchowa daje $DV/\mathrm{d}t = \nabla_{\dot\gamma} Y$. Dla dowolnego pola wzdłuż krzywej mamy też $D(fV)/\mathrm{d}t = f'V + f\, DV/\mathrm{d}t$. Przy zmianie parametru $t = h(s)$ bezpośrednie podstawienie do wzoru daje

$$\frac{D(V\circ h)}{\mathrm{d}s} = h'(s) \frac{DV}{\mathrm{d}t}\bigg|_{t=h(s)}. \tag{12.4.2}$$

W szczególności zachowująca orientację gładka zmiana parametru nie zmienia transportu między końcami.

Twierdzenie 12.4.2 (Istnienie i własności transportu)**.** *Dla gładkiej krzywej $\gamma : [a,b] \to M$ i $v \in T_{\gamma(a)}M$ istnieje dokładnie jedno równoległe pole V wzdłuż γ spełniające $V(a) = v$. Transport $P_{\gamma,a\to b} : T_{\gamma(a)}M \to T_{\gamma(b)}M$ jest liniowym izomorfizmem. Na kolejnych odcinkach drogi transporty składają się; po odwróceniu drogi otrzymujemy odwrotność. Jeżeli koneksja jest zgodna z metryką g, to*

$$g_{\gamma(t)}(P_{a\to t} v, P_{a\to t} w) = g_{\gamma(a)}(v, w). \tag{12.4.3}$$

Dotyczy to również metryk lorentzowskich, gdzie zachowywana forma nie jest dodatnio określona.

Dowód. W jednej mapie warunek $DV/\mathrm{d}t = 0$ jest liniowym układem zwyczajnych równań różniczkowych

$$\dot V^k(t) = -A^k{}_j(t) V^j(t), \qquad A^k{}_j(t) = \Gamma^k_{ij}(\gamma(t))\dot x^i(t). \tag{12.4.4}$$

Współczynniki są ciągłe. Twierdzenie o liniowym układzie ODE daje jednoznaczne rozwiązanie na każdym zwartym odcinku, na którym krzywa pozostaje w mapie: rozwiązanie nie może uciec do nieskończoności w skończonym czasie przy ciągłej, ograniczonej macierzy $A(t)$. Istotnie, równanie całkowe wynika z całkowania $\dot V = -AV$ między t_0 i t:

$$V(t) = V(t_0) - \int_{t_0}^{t} A(u)V(u)\,\mathrm{d}u, \qquad |V(t)| \le |V(t_0)| + \int_{t_0}^{t} \|A(u)\|\,|V(u)|\,\mathrm{d}u \quad (t \ge t_0).$$

Stosujemy teraz następującą elementarną postać nierówności Grönwalla: jeśli $v(t) \le C + \int_{t_0}^{t} a(u)v(u)\,\mathrm{d}u$ dla $a, v \ge 0$, to $v(t) \le C\exp(\int_{t_0}^{t} a(u)\,\mathrm{d}u)$. Dla $C > 0$ wystarczy bowiem zdefiniować $w(t) = C + \int_{t_0}^{t} a(u)v(u)\,\mathrm{d}u$; wtedy $v \le w$, $w' \le aw$ i całkowanie $(\log w)' \le a$ daje tezę. Przypadek $C = 0$ wynika przez zastąpienie go dowolnym $C > 0$ i przejście do granicy. Otrzymujemy więc

$$|V(t)| \le |V(t_0)| \exp\!\left(\int_{t_0}^{t} \|A(u)\|\,\mathrm{d}u\right).$$

Ograniczoność A i V ogranicza też $\dot V = -AV$, więc na skończonym końcu przedziału istnieje granica V; lokalne twierdzenie o istnieniu przedłuża rozwiązanie. Ten sam argument działa wstecz w czasie. Zwartość $[a, b]$ pozwala podzielić go na skończenie wiele odcinków, z których każdy mieści się w jednej mapie: przeciwobrazy dziedzin map tworzą otwarte pokrycie $[a, b]$, a jego liczba Lebesgue'a pozwala wybrać dostatecznie drobny skończony podział. Rozwiązania sklejamy zgodnie z ich jednoznacznością na przecięciach.

Liniowość układu w V daje liniowość transportu. Rozwiązując równanie od b ku a, dostajemy odwrotność; jednoznaczność daje też prawo składania po przecięciu drogi. Wreszcie zgodność metryczna w lokalnej bazie ma postać $\partial_i g_{jk} = \Gamma^{\ell}_{ij} g_{\ell k} + \Gamma^{\ell}_{ik} g_{j\ell}$. Różniczkując $g_{jk}(\gamma(t))V^j(t)W^k(t)$, dostajemy

$$\partial_i g_{jk}\,\dot x^i V^j W^k + g_{jk}\dot V^j W^k + g_{jk} V^j \dot W^k.$$

Wstawiając wzór na $\partial_i g_{jk}$, łączymy jego pierwszy składnik z pochodną V, a drugi z pochodną W. Są to dokładnie poprawki z symbolami Christoffela w $DV/\mathrm{d}t$ i $DW/\mathrm{d}t$. Zatem, bez przedłużania V, W poza krzywą,

$$\frac{\mathrm{d}}{\mathrm{d}t} g(V, W) = g(DV/\mathrm{d}t, W) + g(V, DW/\mathrm{d}t).$$

Gdy V, W są równoległe, prawa strona jest zerem, więc iloczyn pozostaje stały. □

Dla ciągłej krzywej kawałkami gładkiej, z podziałem na skończenie wiele gładkich odcinków, definiujemy transport jako złożenie transportów na tych odcinkach. Jednoznaczność zapewnia niezależność od zagęszczenia podziału. W ten sposób prawo składania obejmuje również sklejenia z narożnikiem. Jawnie, dla $a < c < b$, $P_{\gamma, a\to b} = P_{\gamma, c\to b} \circ P_{\gamma, a\to c}$. Dla drogi odwróconej $\bar\gamma(t) = \gamma(a + b - t)$ mamy $P_{\bar\gamma, a\to b} = P^{-1}_{\gamma, a\to b}$.

Transport zależy zwykle od *drogi*, a nie tylko od jej końców. Jeśli koneksja jest zgodna z metryką i krzywa jest zamknięta, jej transport jest izometrią $T_pM \to T_pM$; poniższy przykład pokaże niezerowy obrót wektora po pełnym okrążeniu.

Przykład 12.4.3 (Obrót po równoleżniku sfery)**.** Na sferze S^2_R, $R > 0$, użyjmy lokalnie współrzędnych (θ, ϕ) i ramki ortonormalnej

$$e_\theta = R^{-1}\partial_\theta, \qquad e_\phi = (R\sin\theta)^{-1}\partial_\phi.$$

Idźmy po równoleżniku $\theta = \theta_0$, ϕ od 0 do 2π, z $0 < \theta_0 < \pi$. Cały równoleżnik nie mieści się w jednej mapie kątowej, ale pola e_θ, e_ϕ sklejają się do gładkiej ramki na sferze bez biegunów i są 2π-okresowe w ϕ. Możemy zatem rozwiązać równanie na całym przedziale. Wstawiając (12.3.4) do reguły iloczynu, otrzymujemy

$$\nabla_{\partial_\phi} e_\theta = \cos\theta_0\, e_\phi, \qquad \nabla_{\partial_\phi} e_\phi = -\cos\theta_0\, e_\theta.$$

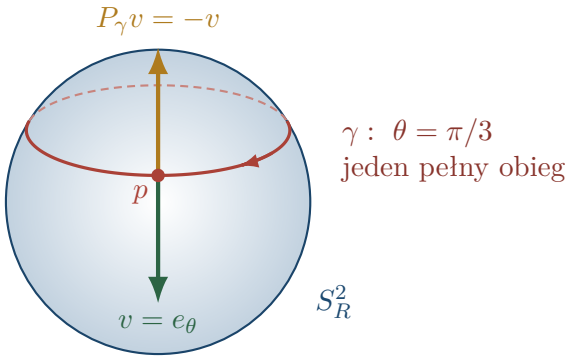
Na przykład $\nabla_{\partial_\phi} e_\theta = R^{-1}\Gamma^{\phi}_{\phi\theta}\partial_\phi = R^{-1}\cot\theta_0 (R\sin\theta_0) e_\phi$. W drugiej pochodnej współczynnik $(R\sin\theta)^{-1}$ ma zerową pochodną po ϕ, więc $\nabla_{\partial_\phi} e_\phi = (R\sin\theta_0)^{-1}(-\sin\theta_0\cos\theta_0)\partial_\theta = -\cos\theta_0 e_\theta$. Jeśli $V = A(\phi)e_\theta + B(\phi)e_\phi$, to równanie $DV/\mathrm{d}\phi = 0$ ma postać

$$A' = B\cos\theta_0, \qquad B' = -A\cos\theta_0, \quad \Longrightarrow \quad A + iB = (A(0) + iB(0))e^{-i\phi\cos\theta_0}.$$

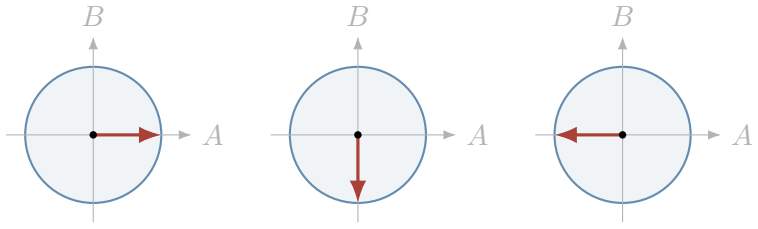
Wyjaśnijmy rozwiązanie układu: dla $c = \cos\theta_0$ i $Z = A + iB$ mamy $Z' = cB - icA = -icZ$. Zatem $(e^{ic\phi}Z)' = 0$; obliczenie tej stałej w $\phi = 0$ daje podany wzór, a rozdzielenie części rzeczywistej i urojonej daje następną macierz. W zapisie rzeczywistym, dla $c = \cos\theta_0$, jest to

$$\begin{pmatrix} A(\phi) \\ B(\phi) \end{pmatrix} = \begin{pmatrix} \cos(c\phi) & \sin(c\phi) \\ -\sin(c\phi) & \cos(c\phi) \end{pmatrix} \begin{pmatrix} A(0) \\ B(0) \end{pmatrix}.$$

Macierz jest obrotem o $-c\phi$, a jej ortogonalność od razu daje stałość długości $A^2 + B^2$. Po powrocie do punktu początkowego ramka jest znowu ta sama, a wektor obrócił się o kąt $-2\pi\cos\theta_0$ modulo 2π, mierzony od e_θ ku e_ϕ. Na równiku kąt jest zerowy. Dla $\theta_0 = \pi/3$ wynosi $-\pi$: wektor wraca przeciwnie skierowany. Obliczenie pokazuje różnicę między przenoszeniem *równoległym na sferze* a utrzymywaniem strzałki nieruchomej na kartce.



Rysunek 12.4: Transport po równoleżniku $\theta = \pi/3$ obraca wektor o $-\pi$. Dla czytelności początek pętli wybrano w punkcie p o $\phi = \pi/2$ (zakres parametru przesuwa się wtedy o $\pi/2$). Strzałki są rzutami przeciwnych wektorów w tej samej płaszczyźnie $T_pS^2_R$, narysowanymi w tej samej skali. Przerywana część równoleżnika leży z tyłu sfery.



Rysunek 12.5: Kolejne etapy transportu po równoleżniku $\theta = \pi/3$, dla $V(0) = e_\theta$. Każdy panel pokazuje współczynniki we własnej ruchomej bazie (e_θ, e_ϕ) przy odpowiednim punkcie krzywej. Kąt maleje od 0 przez $-\pi/2$ do $-\pi$. Po pełnym obiegu wracamy do tej samej przestrzeni stycznej i tej samej bazy, lecz z przeciwnie skierowanym wektorem.

Pochodna kowariantna innych pól tensorowych

Pochodna funkcji to $\nabla_X f = X(f)$. Dla 1-formy α definiujemy $\nabla_X \alpha$ przez wymóg różniczkowania parowania:

$$(\nabla_X \alpha)(Y) = X\big(\alpha(Y)\big) - \alpha(\nabla_X Y). \tag{12.4.5}$$

Prawa strona jest $C^\infty(M)$-liniowa w Y: po zastąpieniu Y przez fY dwa składniki $X(f)\alpha(Y)$ znoszą się. Określa więc 1-formę. W argumencie X jest liniowa nad funkcjami, a w α spełnia regułę Leibniza. We współrzędnych $(\nabla_i \alpha)_j = \partial_i \alpha_j - \Gamma^k_{ij}\alpha_k$: wystarczy w definicji wziąć $X = \partial_i$, $Y = \partial_j$ i użyć $\alpha(\partial_j) = \alpha_j$. W szczególności $(\nabla_{\partial_i} \mathrm{d}x^k)(\partial_j) = -\mathrm{d}x^k(\Gamma^\ell_{ij}\partial_\ell) = -\Gamma^k_{ij}$, czyli $\nabla_{\partial_i}\mathrm{d}x^k = -\Gamma^k_{ij}\mathrm{d}x^j$. To wyjaśnia znak minus przy każdym dolnym indeksie. Na tensorach definiujemy ∇_X przez regułę Leibniza względem iloczynu tensorowego i zgodność z kontrakcją (ściąganiem indeksów). Ściślej, dla tensora S typu (r,s), 1-form $\alpha_1,\dots,\alpha_r$ i pól $Y_1,\dots,Y_s$ wymagamy

$$\begin{aligned}(\nabla_X S)(\alpha_1,\dots,\alpha_r,Y_1,\dots,Y_s) = {}& X\big(S(\alpha_1,\dots,\alpha_r,Y_1,\dots,Y_s)\big)\\ &- \sum_{a=1}^{r} S(\alpha_1,\dots,\nabla_X\alpha_a,\dots,\alpha_r,Y_1,\dots,Y_s)\\ &- \sum_{b=1}^{s} S(\alpha_1,\dots,\alpha_r,Y_1,\dots,\nabla_X Y_b,\dots,Y_s).\end{aligned}$$

Reguły Leibniza sprawiają, że pochodne mnożników w każdym argumencie się znoszą. Wynik jest więc tensorem typu (r,s), określonym bez wyboru bazy. Rozwinięcie w lokalnych iloczynach tensorowych wektorów bazowych i form dualnych dowodzi istnienia i jednoznaczności rozszerzenia: każdy górny indeks wnosi składnik z $+\Gamma$, a każdy dolny z $-\Gamma$. Na przykład

$$(\nabla_i S)_{jk} = \partial_i S_{jk} - \Gamma^\ell_{ij} S_{\ell k} - \Gamma^\ell_{ik} S_{j\ell}.$$

Dla tensora mieszanego $S = S^j{}_k \partial_j \otimes \mathrm{d}x^k$ otrzymujemy analogicznie $(\nabla_i S)^j{}_k = \partial_i S^j{}_k + \Gamma^j_{i\ell} S^\ell{}_k - \Gamma^\ell_{ik} S^j{}_\ell$. Ściągając indeksy $j = k$, widzimy po zamianie nazw j,ℓ, że oba wyrazy z Γ się znoszą: $\nabla_i(S^j{}_j) = \partial_i(S^j{}_j)$. To bezpośrednie sprawdzenie zgodności pochodnej z kontrakcją. Dla koneksji zgodnej z metryką dodatkowo $\nabla_i g_{jk} = 0$; jest to właśnie warunek (12.1.5). Dowolna koneksja afiniczna nie musi go spełniać. W przypadku koneksji bez torsji pochodna Liego z Rozdziału 2 i pochodna kowariantna mają związek

$$\mathcal{L}_X Y = [X,Y] = \nabla_X Y - \nabla_Y X. \tag{12.4.6}$$

Pochodna Liego porównuje pola przez przepływ X, a pochodna kowariantna wykorzystuje wybraną koneksję. Równość jest konsekwencją zerowej torsji, nie definicją którejś z pochodnych.

12.5 Przykłady w metrykach Schwarzschilda i Kerra

W obu czasoprzestrzeniach z Rozdziału 11 macierz metryki jest nieosobliwa w podanej tam dziedzinie. Wzór Koszula daje zatem jednoznaczną koneksję także tutaj. Transport zachowuje *lorentzowski iloczyn* wektorów; nie interpretujemy $g(v,v)$ jako kwadratu euklidesowej długości dla wszystkich wektorów.

Przykład 12.5.1 (Wybrane symbole Schwarzschilda)**.** Niech $f(r) = 1 - 2M/r$, zatem $f'(r) = 2M/r^2$. Pozostajemy w dziedzinie $r > 2M$, $0 < \theta < \pi$, przy $M > 0$, zgodnie z przykładem metryki w rozdziale 11. Dla metryki (11.3.4) macierz jest diagonalna:

$$(g_{\mu\nu}) = \operatorname{diag}(-f, f^{-1}, r^2, r^2\sin^2\theta), \qquad g^{rr} = f, \quad g^{tt} = -f^{-1}.$$

Liczymy kilka przydatnych składników za pomocą (12.3.1):

$$\Gamma^t_{tr}=\Gamma^t_{rt}=\frac{f'}{2f}=\frac{M}{r^2 f},\qquad \Gamma^r_{tt}=\frac{ff'}{2}=\frac{Mf}{r^2},$$
$$\Gamma^r_{rr}=-\frac{f'}{2f},\qquad \Gamma^r_{\theta\theta}=-rf,\qquad \Gamma^r_{\phi\phi}=-rf\sin^2\theta, \tag{12.5.1}$$
$$\Gamma^\theta_{r\theta}=\Gamma^\theta_{\theta r}=\frac{1}{r},\qquad \Gamma^\phi_{r\phi}=\Gamma^\phi_{\phi r}=\frac{1}{r}.$$

Na przykład $\Gamma^r_{tt}=-\frac12 g^{rr}\partial_r g_{tt}=-\frac12 f(-f')=ff'/2$, a $\Gamma^r_{\theta\theta}=-\frac12 f\partial_r(r^2)=-rf$. Pozostałe wypisane wartości otrzymujemy z tych samych pochodnych diagonalnej macierzy:

$$\Gamma^t_{tr}=\tfrac12(-f^{-1})(-f')=\frac{f'}{2f},\qquad \Gamma^r_{rr}=\tfrac12 f(-f'/f^2)=-\frac{f'}{2f},$$
$$\Gamma^r_{\phi\phi}=-\tfrac12 f(2r\sin^2\theta)=-rf\sin^2\theta,\quad \Gamma^\theta_{r\theta}=\tfrac12 r^{-2}(2r)=\frac{1}{r},$$
$$\Gamma^\phi_{r\phi}=\tfrac12(r^2\sin^2\theta)^{-1}(2r\sin^2\theta)=\frac{1}{r}.$$

Pozostałe symbole kątowe są identyczne jak w (12.3.4); pełny spis nie jest potrzebny do użycia metody.

Dla drogi radialnej $\gamma(s)=(t_0,r(s),\theta_0,\phi_0)$ wektor $V(s)=V^\theta(s)\partial_\theta$ jest równoległy wtedy i tylko wtedy, gdy

$$\frac{\mathrm{d}V^\theta}{\mathrm{d}s}+\frac{\dot r}{r}V^\theta=0,\qquad\Longleftrightarrow\qquad r(s)V^\theta(s)=\text{stała}.$$

Rzeczywiście lewa strona równania, pomnożona przez $r>0$, to $(rV^\theta)'=\dot r V^\theta+r(V^\theta)'$. W pozostałych równaniach nie powstają składowe pola, gdyż $\Gamma^\mu_{r\theta}=0$ dla $\mu\neq\theta$. Sprawdziliśmy więc cały układ transportu, nie tylko jego składową θ. To łatwy test wzoru: $g_{\theta\theta}=r^2$, więc $g(V,V)=r^2(V^\theta)^2$ jest zachowane. Chodzi o transport w pełnej czasoprzestrzeni wzdłuż tej wybranej drogi, nie o wyznaczenie trajektorii fizycznej.

Przykład 12.5.2 (Wybrane symbole Kerra)**.** Stosujemy $\Sigma=r^2+a^2\cos^2\theta$, $\Delta=r^2-2Mr+a^2$ oraz współrzędne Boyera–Lindquista z (11.3.5). W bloku (r,θ) metryka i jej odwrotność są diagonalne:

$$g_{rr}=\frac{\Sigma}{\Delta},\quad g_{\theta\theta}=\Sigma,\quad g^{rr}=\frac{\Delta}{\Sigma},\quad g^{\theta\theta}=\frac{1}{\Sigma}.$$

Ponieważ $\partial_r\Sigma=2r$ oraz $\partial_r\Delta=2(r-M)$, otrzymujemy

$$\Gamma^r_{rr}=\tfrac12 g^{rr}\partial_r g_{rr}=\frac{r}{\Sigma}-\frac{r-M}{\Delta},\qquad \Gamma^r_{\theta\theta}=-\tfrac12 g^{rr}\partial_r g_{\theta\theta}=-\frac{r\Delta}{\Sigma},$$
$$\Gamma^\theta_{r\theta}=\Gamma^\theta_{\theta r}=\frac{r}{\Sigma},\qquad \Gamma^r_{r\theta}=\Gamma^r_{\theta r}=-\frac{a^2\sin\theta\cos\theta}{\Sigma}. \tag{12.5.2}$$

Ostatni wzór pochodzi z $\frac12 g^{rr}\partial_\theta g_{rr}=\frac{\partial_\theta\Sigma}{2\Sigma}$. Pokazuje, że współczynnik radialny może zmieniać się także przy zmianie kąta θ. W pierwszym wzorze użyto reguły ilorazu: $\partial_r(\Sigma/\Delta)=2r/\Delta-2(r-M)\Sigma/\Delta^2$; mnożenie przez $\Delta/(2\Sigma)$ daje dwa składniki wypisanej odpowiedzi. Trzeci wzór to $\Gamma^\theta_{r\theta}=\frac12\Sigma^{-1}\partial_r\Sigma=r/\Sigma$, a w ostatnim $\partial_\theta\Sigma=-2a^2\sin\theta\cos\theta$.

Parametr obrotu a wprowadza sprzężenie między czasem a kierunkiem ϕ. Z (11.3.5) mamy $g_{t\phi}=-2Mar\sin^2\theta/\Sigma$. Metryka nie zależy od t,ϕ i nie ma wyrazów $\mathrm{d}r\,\mathrm{d}t$ ani $\mathrm{d}r\,\mathrm{d}\phi$, zatem (12.3.1) daje

$$\Gamma^r_{t\phi}=\Gamma^r_{\phi t}=-\frac12\frac{\Delta}{\Sigma}\partial_r g_{t\phi}=-\frac{Ma\Delta\sin^2\theta(r^2-a^2\cos^2\theta)}{\Sigma^3},$$
$$\partial_r g_{t\phi}=\frac{2Ma\sin^2\theta(r^2-a^2\cos^2\theta)}{\Sigma^2}. \tag{12.5.3}$$

W drugim wierszu różniczkujemy r/Σ: $\partial_r(r/\Sigma) = (\Sigma - 2r^2)/\Sigma^2 = (a^2\cos^2\theta - r^2)/\Sigma^2$. Mnożenie przez $-2Ma\sin^2\theta$ daje ten wiersz, a następnie przez $-\Delta/(2\Sigma)$ daje pierwszy. Przy $a = 0$ składnik mieszany znika, $\Sigma = r^2$, $\Delta = r^2 f$; (12.5.2) redukuje się do radialnych i kątowych wzorów Schwarzschilda. Na przykład $\Gamma^r_{rr} = 1/r - (r-M)/(r^2 f) = -M/(r^2 f) = -f'/(2f)$; wyrazy zależne od $\partial_\theta\Sigma$ znikają. To sprawdzian rachunku oraz zależności obu metryk.

Nie należy odczytywać pojedynczego symbolu Christoffela jako niezależnej od współrzędnych „siły". Wzór (12.1.4) zmienia jego wartość po zmianie mapy. Geometryczny sens mają całe równania transportu i pochodne kowariantne.

12.6 Dlaczego koneksja pojawia się w równaniu ruchu?

Funkcjonał energii z (11.4.1) pozwala rozpoznać krzywe stacjonarne. W tej sekcji zakładamy $a < b$ i gładkość γ. Rozpatrujemy rozmaitość bez brzegu albo krzywą zawartą w jej wnętrzu, aby dopuszczalne były dowolne małe wariacje. Dla ustalonych końców i lokalnego zapisu $\gamma(t) = (x^i(t))$ mamy

$$E(\gamma) = \frac{1}{2}\int_a^b g_{ij}(x(t))\dot{x}^i(t)\dot{x}^j(t)\,\mathrm{d}t. \tag{12.6.1}$$

Niech $x(t,s)$ będzie wariacją z końcami niezależnymi od s i $\eta^k(t) = \partial_s x^k(t,s)|_{s=0}$. Różniczkując pod całką i uwzględniając symetrię g_{ij}, otrzymujemy

$$\left.\frac{\mathrm{d}E}{\mathrm{d}s}\right|_{s=0} = \int_a^b \left(\tfrac{1}{2}\partial_k g_{ij}\,\eta^k\dot{x}^i\dot{x}^j + g_{kj}\dot{\eta}^k\dot{x}^j\right)\mathrm{d}t.$$

Całkując drugi składnik przez części, wyraz brzegowy $[g_{kj}\eta^k\dot{x}^j]_a^b$ jest zerowy. Dostajemy

$$\delta E = \int_a^b \eta^k\left(\tfrac{1}{2}\partial_k g_{ij}\dot{x}^i\dot{x}^j - \frac{\mathrm{d}}{\mathrm{d}t}(g_{kj}\dot{x}^j)\right)\mathrm{d}t.$$

Jeśli $\delta E = 0$ dla wszystkich η o zwartym nośniku we wnętrzu przedziału, lemat podstawowy rachunku wariacyjnego daje dla każdego k

$$g_{kj}\ddot{x}^j + \partial_i g_{kj}\dot{x}^i\dot{x}^j - \tfrac{1}{2}\partial_k g_{ij}\dot{x}^i\dot{x}^j = 0.$$

Wyjaśnijmy dwa użyte tu kroki. Każde gładkie η o zwartym nośniku wewnątrz odcinka zawartego w mapie realizuje wariacja $x(t,s) = x(t,0) + s\eta(t)$ dla małego $|s|$, sklejona z niezmienioną krzywą poza tym odcinkiem. Zwartość nośnika zapewnia, że pozostajemy w dziedzinie mapy. Jeśli zaś ciągły współczynnik przy pewnym η^k w całce byłby dodatni (lub ujemny) w jednym punkcie, miałby ten sam znak w małym otoczeniu. Nieujemna, niezerowa funkcja gładka o nośniku w tym otoczeniu dawałaby niezerową całkę. To dowód potrzebnej wersji lematu podstawowego.

Iloczyn $\dot{x}^i\dot{x}^j$ jest symetryczny; zastępujemy więc $\partial_i g_{kj}$ przez $\frac{1}{2}(\partial_i g_{kj} + \partial_j g_{ki})$. Po pomnożeniu przez $g^{\ell k}$ wzór (12.3.1) daje

$$\ddot{x}^\ell + \Gamma^\ell_{ij}\dot{x}^i\dot{x}^j = 0, \qquad \text{czyli} \qquad \frac{D\dot{\gamma}}{\mathrm{d}t} = 0. \tag{12.6.2}$$

Rachunek jest lokalny: wystarczy stosować takie wariacje w kolejnych mapach pokrywających krzywą. Odwrotnie, jeśli $D\dot{\gamma}/\mathrm{d}t = 0$, to dla dowolnej gładkiej wariacji o ustalonych końcach całkowanie przez części na odcinkach zawartych w mapach daje $\delta E = 0$. Wyrazy brzegowe w punktach podziału znoszą się, ponieważ każdy jest wartością tego samego iloczynu $g(\partial_s\gamma, \dot{\gamma})$ z

przeciwnymi znakami. Stacjonarność jest więc równoważna temu równaniu. Współczynnik przy η^k w δE jest równy $-g_{k\ell}(D\dot\gamma/\mathrm{d}t)^\ell$. Ten sam rachunek daje zatem niezależną od mapy tożsamość

$$\delta E = -\int_a^b g\Big(\eta, \frac{D\dot\gamma}{\mathrm{d}t}\Big)\,\mathrm{d}t, \qquad \eta = \partial_s \gamma_s|_{s=0}\,, \tag{12.6.3}$$

dla wariacji o ustalonych końcach.

Krzywa stacjonarna energii przenosi więc swój wektor prędkości równolegle. Takie krzywe nazywamy *geodezyjnymi* z parametrem afinicznym. Zgodność z metryką daje $\frac{\mathrm{d}}{\mathrm{d}t} g(\dot\gamma,\dot\gamma) = 2g(D\dot\gamma/\mathrm{d}t,\dot\gamma) = 0$; w przypadku riemannowskim prędkość ma zatem stałą normę. Określenie parametru jest istotne: dla $\widetilde\gamma(s) = \gamma(h(s))$ reguła (12.4.2) daje

$$\frac{D\dot{\widetilde\gamma}}{\mathrm{d}s} = h''(s)\dot\gamma(h(s)) + (h'(s))^2 \frac{D\dot\gamma}{\mathrm{d}t}\Big|_{t=h(s)}.$$

Dla niestałej geodezyjnej $\dot\gamma$ nigdzie nie znika (jest transportem niezerowego wektora), więc gładka zmiana parametru zachowuje równanie dokładnie wtedy, gdy $h(s) = cs+d$ z $c \neq 0$. Na przykład $\gamma(t) = t$ na prostej euklidesowej jest geodezyjną, lecz po przeparametryzowaniu $h(s) = (s+s^2)/2$ na $[0,1]$ ma $D\dot{\widetilde\gamma}/\mathrm{d}s = h''(s) = 1$. Obraz drogi jest ten sam; nowy parametr nie jest afiniczny. Dalsze własności geodezyjnych i odwzorowanie wykładnicze omówimy w następnym rozdziale, a krzywiznę w dalszej części skryptu. Dla metryki lorentzowskiej to samo równanie ma sens jako równanie stacjonarności odpowiedniego działania; nie twierdzimy, że definiuje odległość riemannowską na czasoprzestrzeni.

Dalsza lektura: Eckhard Meinrenken, *Riemannian Geometry*, §15 (koneksja, wzór Koszula i transport), MIT (symbole Schwarzschilda), Oregon (metryka Kerra).

Rozdział 13

Geodezyjne, odwzorowanie wykładnicze i zupełność

W Rozdziale 12 otrzymaliśmy równanie $D\dot\gamma/\mathrm{d}t = 0$ jako warunek stacjonarności energii. Teraz wyjaśnimy, kiedy taka krzywa rzeczywiście jest najkrótsza, jak opisuje otoczenie punktu i co gwarantuje jej istnienie przez dowolnie długi czas. Ostatnia część rozdziału odróżnia te riemannowskie twierdzenia od geodezyjnych czasoprzestrzeni Schwarzschilda i Kerra.

W całym rozdziale rozmaitości są gładkie i *bez brzegu*. Jeśli nie zaznaczono inaczej, metryka jest riemannowska; odległości rozpatrujemy w jednej składowej spójnej. Brak brzegu jest istotny: domknięty przedział z metryką euklidesową jest zwarty, ale prosta dochodząca do jego końca nie ma geodezyjnego przedłużenia w tym przedziale.

13.1 Geodezyjna i pierwsza wariacja

Definicja 13.1.1 (Geodezyjna)**.** Geodezyjną koneksji ∇ nazywamy krzywą $\gamma : I \to M$ spełniającą

$$\nabla_{\dot\gamma}\dot\gamma = 0, \qquad \ddot x^k + \Gamma^k_{ij}(x)\dot x^i \dot x^j = 0. \tag{13.1.1}$$

Użyty parametr jest *afiniczny*. Gdy g jest metryką, mamy na myśli jej koneksję Leviego-Civity.

Zgodność koneksji z metryką daje $\frac{\mathrm{d}}{\mathrm{d}t} g(\dot\gamma,\dot\gamma) = 2g(D\dot\gamma/\mathrm{d}t,\dot\gamma) = 0$. Wektor prędkości geodezyjnej riemannowskiej ma więc stałą normę. Parametr $s = at + b$, $a \neq 0$, zachowuje równanie (13.1.1); dowolna nieliniowa zmiana parametru na ogół go nie zachowuje. Dla przykładu prosta $\gamma(t) = p + tv$ w $\mathbb{R}^n$ jest geodezyjną, ale dla $v \neq 0$ krzywa $p + t^2 v$ nie spełnia równania geodezyjnej w parametrze t.

Stwierdzenie 13.1.2 (Dane początkowe)**.** *Dla każdego $p \in M$ i $v \in T_pM$ istnieje jedyna maksymalna geodezyjna $\gamma_{p,v}$ o $\gamma_{p,v}(0) = p$, $\dot\gamma_{p,v}(0) = v$. Jest określona co najmniej dla $|t| < \varepsilon$ zależnego od (p, v) i zależy gładko od danych tam, gdzie jest określona.*

Dowód. W mapie wprowadzamy $u^k = \dot x^k$. Równanie drugiego rzędu staje się gładkim układem pierwszego rzędu na otwartym podzbiorze $\mathbb{R}^{2n}$:

$$\dot x^k = u^k, \qquad \dot u^k = -\Gamma^k_{ij}(x)u^i u^j.$$

Twierdzenie Picarda–Lindelöfa o lokalnym istnieniu, jednoznaczności i gładkiej zależności od danych dla gładkiego pola na TM daje rozwiązanie. Jednoznaczność pozwala skleić rozwiązania z różnych map i przedłużać je do maksymalnego przedziału. Nie zakładamy jeszcze, że tym przedziałem jest cała $\mathbb{R}$. □

Pierwsza wariacja jest dobrym miejscem na rozróżnienie dwóch zdań: *geodezyjna jest punktem stacjonarnym długości* oraz *krótki jej fragment minimalizuje długość*. Drugie wymaga osobnego dowodu poniżej.

Twierdzenie 13.1.3 (Wzór na pierwszą wariację długości)**.** *Niech $F(s,t)$ będzie gładką wariacją regularnej krzywej $\gamma(t) = F(0,t)$, $t \in [a,b]$, $a < b$, na rozmaitości riemannowskiej. Oznaczmy $V = \partial_s F|_{s=0}$ i $T = \dot\gamma/|\dot\gamma|_g$. Wtedy*

$$\frac{\mathrm{d}}{\mathrm{d}s} L(F_s)\Big|_{s=0} = \big[g(V,T)\big]_a^b - \int_a^b g\Big(V, \frac{DT}{\mathrm{d}t}\Big)\,\mathrm{d}t. \tag{13.1.2}$$

Jeżeli γ ma prędkość 1, to $T = \dot\gamma$ i $DT/\mathrm{d}t = D\dot\gamma/\mathrm{d}t$. Przy ustalonych końcach składnik brzegowy znika.

Dowód. Połóżmy $W = \partial_t F$. Regularność γ i zwartość $[a,b]$ dają dodatnie dolne ograniczenie $|W(0,t)|_g$. Po zmniejszeniu zakresu s także $|W(s,t)|_g$ jest jednostajnie dodatnia, więc możemy różniczkować pierwiastek. Różniczkujemy pod całką $L(F_s) = \int_a^b \sqrt{g(W,W)}\,\mathrm{d}t$. Zgodność koneksji z metryką daje

$$\partial_s |W|_g = \frac{g(D_s W, W)}{|W|_g} = g(D_s W, T).$$

Pochodne D_s, D_t bierzemy wzdłuż odpowiednich krzywych w rodzinie F. Nie trzeba zakładać, że F jest immersją. Współrzędne dają bezpośrednio

$$(D_s \partial_t F)^k - (D_t \partial_s F)^k = (\Gamma^k_{ij} - \Gamma^k_{ji}) \partial_s F^i \partial_t F^j = 0,$$

ponieważ pochodne mieszane komutują, a koneksja nie ma torsji. W $s = 0$ otrzymujemy $D_s W = D_t V$. Z reguły iloczynu

$$g(D_t V, T) = \frac{\mathrm{d}}{\mathrm{d}t} g(V,T) - g(V, D_t T).$$

Całkujemy tę równość i podstawiamy do pochodnej długości. To daje dokładnie (13.1.2). W ciągłej wariacji kawałkami gładkiej, z ustalonym skończonym podziałem i regularnymi kawałkami, stosujemy wzór na każdym kawałku. W punkcie sklejenia t_0 pozostaje dodatkowo $g(V(t_0), T(t_0^-) - T(t_0^+))$: wyjaśnimy poniżej, jak ten wyraz pozwala skrócić narożnik. □

Wniosek 13.1.4 (Dlaczego krzywa minimalna musi być geodezyjną)**.** *Regularna, gładka krzywa lokalnie minimalizująca długość między swoimi końcami jest geodezyjną po parametryzacji długością łuku.*

Dowód. Parametryzujmy ją ze stałą prędkością 1. Dla wariacji o ustalonych końcach pochodna długości jest zerowa. W mapie możemy wybrać pole wariacyjne V o zwartym nośniku w dowolnie małym odcinku i dowolnych składowych: realizuje je na przykład $F(s,t) = x^{-1}(x(\gamma(t)) + sV^i(t)e_i)$ dla małego s. Wzór (13.1.2) i lemat podstawowy rachunku wariacyjnego dają $DT/\mathrm{d}t = 0$ w każdym punkcie. □

13.2 Odwzorowanie wykładnicze i współrzędne normalne

Zaczynamy w jednym punkcie p i wystrzeliwujemy geodezyjne we wszystkich kierunkach $v \in T_pM$. Wektor zawiera *kierunek i skalę*: geodezyjna startująca z v przebywa w czasie 1 drogę o długości $|v|_g$, o ile jest określona.

Definicja 13.2.1 (Odwzorowanie wykładnicze)**.** Niech $D_p \subset T_pM$ będzie zbiorem wektorów v, dla których $\gamma_{p,v}$ jest określona na całym $[0,1]$. Kładziemy

$$\exp_p : D_p \longrightarrow M, \qquad \exp_p(v) = \gamma_{p,v}(1). \tag{13.2.1}$$

To odwzorowanie nie jest na ogół globalnie określone ani różnowartościowe. Zbiór D_p jest otwarty, zawiera 0 i jest gwiaździsty względem 0. Istotnie, maksymalny przepływ gładkiego pola geodezyjnego na TM ma otwartą dziedzinę w $\mathbb{R} \times TM$; warunek istnienia w chwili 1 jest zatem otwarty w danych początkowych. Istnienie od 0 do 1 wynika z tego, że przedział maksymalnego rozwiązania jest przedziałem zawierającym 0. Krzywa stała daje $0 \in D_p$.

Jednoznaczność i podstawienie do równania dają prawo $\gamma_{p,cv}(t) = \gamma_{p,v}(ct)$ dla dowolnej stałej c na odpowiadających sobie przedziałach istnienia. Dla $v \in D_p$ i $0 \le t \le 1$ wynika stąd gwiaździstość oraz

$$\exp_p(tv) = \gamma_{p,v}(t). \tag{13.2.2}$$

Gładkość przepływu daje gładkość $\exp_p$ na całym D_p, a także gładką zależność od p na otwartym podzbiorze TM.

Twierdzenie 13.2.2 (Lokalne istnienie współrzędnych normalnych)**.** *Dla każdego $p \in (M,g)$ istnieje $\rho > 0$ takie, że $B_\rho(0) \subset T_pM$ leży w D_p i $\exp_p$ ograniczone do tego zbioru jest dyfeomorfizmem na otoczenie U punktu p. Po wybraniu ortonormalnej bazy T_pM odwrotność $\exp_p^{-1} : U \to \mathbb{R}^n$ jest* mapą we współrzędnych normalnych*. W jej środku*

$$g_{ij}(p) = \delta_{ij}, \qquad \Gamma^k_{ij}(p) = 0, \qquad \partial_\ell g_{ij}(p) = 0. \tag{13.2.3}$$

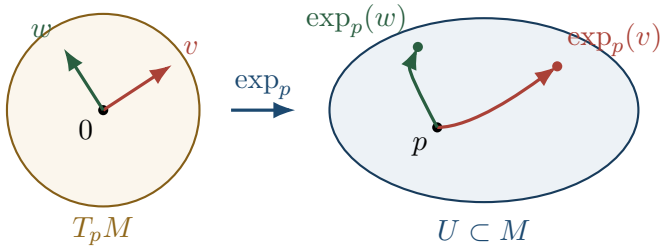
Stwierdzenie lokalnego dyfeomorfizmu działa również dla metryki pseudoriemannowskiej; w bazie pseudoortonormalnej $g_{ij}(p)$ zastępuje wtedy macierz diagonalna o odpowiedniej sygnaturze. Kulę w przestrzeni stycznej wybieramy za pomocą pomocniczej normy euklidesowej, ponieważ metryka nieokreślona nie jest normą.

Dowód. Gładka zależność geodezyjnych od danych początkowych w Stwierdzeniu 13.1.2 gwarantuje, że dla v bliskich 0 wszystkie rozwiązania istnieją aż do czasu 1. Istotnie stała krzywa $\gamma_{p,0}(t) = p$ istnieje dla każdego t; na zwartym odcinku $[0,1]$ można wybrać wspólne małe otoczenie jej danych, w którym działa twierdzenie o gładkiej zależności ODE. Wtedy $\exp_p$ jest gładkie.

Niech $w \in T_pM$. Z (13.2.2) wynika $\exp_p(sw) = \gamma_{p,w}(s)$ dla małego s. Różniczkując w $s = 0$, dostajemy $\mathrm{d}(\exp_p)_0(w) = \dot\gamma_{p,w}(0) = w$. Zatem $\mathrm{d}(\exp_p)_0$ jest identycznością $T_0(T_pM) \simeq T_pM$. Twierdzenie o funkcji odwrotnej daje mniejszą kulę, na której $\exp_p$ jest dyfeomorfizmem.

W ortonormalnej bazie jej różniczka w 0 identyfikuje bazę współrzędnych z wybraną bazą T_pM, więc $g_{ij}(p) = \delta_{ij}$. Krzywe $x(t) = tv$ są geodezyjnymi w tej mapie. Wstawiając je do (13.1.1) w $t = 0$, dostajemy $\Gamma^k_{ij}(p) v^i v^j = 0$ dla każdego v. Ponieważ koneksja Leviego-Civity nie ma torsji, $\Gamma^k_{ij} = \Gamma^k_{ji}$; z polaryzacji tej równości wynika $\Gamma^k_{ij}(p) = 0$. Jawnie, wybór $v = e_i$ zeruje $\Gamma^k_{ii}(p)$, a wybór $v = e_i + e_j$ dla $i \neq j$ daje $\Gamma^k_{ij}(p) + \Gamma^k_{ji}(p) = 0$. Symetria obu składników zeruje także wyrazy mieszane. Wreszcie zgodność z metryką mówi $\partial_\ell g_{ij} = g_{mj}\Gamma^m_{\ell i} + g_{im}\Gamma^m_{\ell j}$, zatem pochodne metryki znikają w p. □

Słowo „normalne” dotyczy tutaj współrzędnych, nie wektora normalnego do powierzchni. Równość $\Gamma(p) = 0$ zachodzi w *jednym* punkcie. Nie daje podstaw do wyzerowania wszystkich symboli na całej zakrzywionej rozmaitości.



Rysunek 13.1: Wektory w T_pM opisują krótkie geodezyjne wychodzące z p. Odwzorowanie $\exp_p$ zamienia małą kulę wektorów na otoczenie punktu.

13.3 Lemat Gaussa i lokalna minimalność

Współrzędne normalne pozwalają rozdzielić ruch *od* p od ruchu *w poprzek*. Lemat Gaussa mówi, że te kierunki są ortogonalne w metryce, a nie tylko na rysunku.

Lemat 13.3.1 (Gaussa)**.** *Jeżeli v leży w otwartej dziedzinie D_p odwzorowania $\exp_p$ i $w \in T_pM$, to*

$$g_{\exp_p(v)}\Big(\mathrm{d}(\exp_p)_v(v), \mathrm{d}(\exp_p)_v(w)\Big) = g_p(v,w). \tag{13.3.1}$$

W szczególności pochodna w kierunku radialnym jest prostopadła do obrazów kierunków stycznych do sfery $|v|_g = \text{const}$.

Dowód. Rozpatrzmy dwuwymiarową rodzinę geodezyjnych $F(s,t) = \exp_p(t(v+sw))$, $0 \le t \le 1$, przy małym s. Otwartość D_p zapewnia $v + sw \in D_p$, a gwiaździstość zapewnia istnienie całej rodziny dla $0 \le t \le 1$. Połóżmy $T = \partial_t F$, $V = \partial_s F$. Każda krzywa $t \mapsto F(s,t)$ jest geodezyjną, więc $D_t T = 0$, a jej kwadrat prędkości jest stały i równy $g_p(v+sw, v+sw)$. Z braku torsji $D_t V = D_s T$. Zatem

$$\partial_t g(V,T) = g(D_s T, T) + g(V, D_t T) = \tfrac{1}{2}\partial_s g(T,T).$$

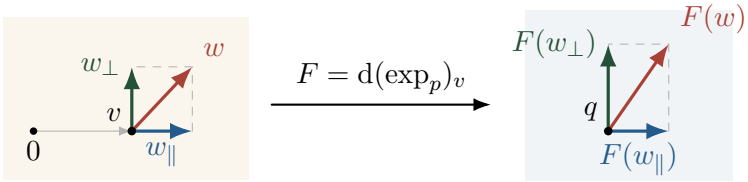
W $s = 0$ prawa strona jest stałą $g_p(v,w)$. Ponadto $V(0) = 0$, gdyż $F(s,0) = p$. Całkując po t od 0 do 1, dostajemy $g(V(1),T(1)) = g_p(v,w)$. Reguła łańcuchowa daje $V(1) = \mathrm{d}(\exp_p)_v(w)$ i $T(1) = \mathrm{d}(\exp_p)_v(v)$, czyli tezę. □

W normalnym otoczeniu zapiszmy niezerowe $v = r\theta$, gdzie $r = |v|_g$ i $|\theta|_g = 1$. Lemat daje lokalnie postać

$$g = \mathrm{d}r^2 + h_{ab}(r,\theta)\mathrm{d}\theta^a \mathrm{d}\theta^b. \tag{13.3.2}$$

Rzeczywiście $\partial_r = \mathrm{d}\exp_{r\theta}(\theta)$ ma długość 1 (stała prędkość radialnej geodezyjnej), a kierunki kątowe są do niego prostopadłe. Macierz (h_{ab}) jest dodatnio określona dla $r > 0$ w tym otoczeniu.

Dla $v \neq 0$ rozkładamy dowolny w na $w_\parallel = g_p(v,w)v/|v|_g^2$ i $w_\perp = w - w_\parallel$. Liniowość różniczki i lemat Gaussa pokazują, że ich obrazy pozostają wzajemnie prostopadłe, a składowa radialna zachowuje długość. Długość składowej poprzecznej może się zmienić.



Rysunek 13.2: Lemat Gaussa rozdziela składową radialną i poprzeczną. Oba panele pokazują wektory w bazach ortonormalnych odpowiednich przestrzeni stycznych. Różniczka $\exp_p$ zachowuje długość składowej radialnej i jej prostopadłość do poprzecznej; długości poprzecznej nie musi zachowywać.

Twierdzenie 13.3.2 (Krótka geodezyjna minimalizuje)**.** *Istnieje $\rho > 0$ takie, że dla każdego $q = \exp_p(v)$ z $|v|_g < \rho$ radialna geodezyjna $\gamma(t) = \exp_p(tv)$, $0 \le t \le 1$, spełnia*

$$d_g(p, q) = L_g(\gamma) = |v|_g. \tag{13.3.3}$$

Dla $v \neq 0$ każda odcinkami C^1 droga osiągająca tę długość ma ten sam ślad radialny i przebiega go bez cofania; może przy tym zatrzymywać się na pewnych odcinkach parametru. Dla $v = 0$ jedyną drogą o długości zero jest droga stała. W szczególności każdy *dostatecznie krótki fragment dowolnej geodezyjnej riemannowskiej minimalizuje odległość między swoimi końcami.*

Dowód. Wybierzmy ρ tak małe, by $\exp_p$ było dyfeomorfizmem na kuli $B_{3\rho}(0)$. W szczególności domknięcie $\overline{B}_{2\rho}(0)$ leży w tej dziedzinie, a jego obraz jest zwarty. W normalnych współrzędnych dowolną odcinkami C^1 krzywą $\alpha : [a, b] \to M$ biegnącą od p do q i pozostającą w obrazie tej kuli piszemy dla $r > 0$ przez $r(t), \theta(t)$. Z (13.3.2) wynika

$$|\dot\alpha|_g^2 = (\dot r)^2 + h_{ab}\dot\theta^a\dot\theta^b \ge (\dot r)^2, \qquad L_g(\alpha) \ge \int_a^b |\dot r(t)|\,\mathrm{d}t \ge \left|\int_a^b \dot r(t)\,\mathrm{d}t\right| = r(b) - r(a) = r(q) = |v|_g.$$

W punkcie p funkcja r nie musi być gładka. Jednak $u(t) = \exp_p^{-1}(\alpha(t))$ jest odcinkami C^1, a $r(t) = |u(t)|_g$ jest lipschitzowska na zwartym przedziale, więc absolutnie ciągła. Pochodna $\dot r$ istnieje prawie wszędzie i jest równa zero prawie wszędzie na zbiorze $\{t : r(t) = 0\}$: w każdym wewnętrznym punkcie tego zbioru, w którym pochodna istnieje, r ma minimum. Nierówność $|\dot\alpha|_g \ge |\dot r|$ zachodzi zatem prawie wszędzie, co uzasadnia całkowanie również przy wielokrotnych powrotach do p. Radialna geodezyjna ma $\dot\theta = 0$, $\dot r \ge 0$ i długość $|v|_g$, więc osiąga dolne ograniczenie. Równość w drugiej nierówności całkowej wymaga $\dot r \ge 0$ prawie wszędzie, czyli r jest niemalejąca. Zbiór $\{r > 0\}$ jest wtedy jednym końcowym przedziałem. Na nim równość w pierwszej nierówności i dodatnia określoność h dają $\dot\theta = 0$ prawie wszędzie. Na każdym zwartym podprzedziale θ jest odcinkami C^1, a więc stała. To dowodzi jednoznaczności śladu; chwile postoju odpowiadają stałym odcinkom funkcji r.

Jeśli α opuści obraz $B_{2\rho}(0)$, jej pierwszy punkt wyjścia ma promień 2ρ. Poprzednia nierówność na początkowym kawałku daje $L_g(\alpha) \ge 2\rho > |v|_g$. Porównaliśmy więc także drogi wychodzące z otoczenia, co jest potrzebne dla odległości d_g zdefiniowanej przez *wszystkie* dopuszczalne krzywe. Dla dowolnej geodezyjnej powtarzamy argument, biorąc za p jej punkt początkowy i skracając przedział parametru. □

Z dowodu wynika również identyfikacja małych kul. Dla $0 < a < \rho$ mamy

$$B_a^g(p) = \exp_p(B_a(0)), \qquad \overline{B}_a^g(p) = \exp_p(\overline{B}_a(0)). \tag{13.3.4}$$

Tutaj $\overline{B}_a^g(p) = \{q : d_g(p, q) \le a\}$. Każdy punkt spoza $\exp_p(B_{2\rho}(0))$ ma odległość co najmniej 2ρ od p, na mocy argumentu z pierwszym wyjściem. Wewnątrz tego otoczenia ten sam rachunek

radialny daje $d_g(p, \exp_p(v)) = |v|_g$. Stąd obie równości i zwartość małych kul domkniętych oraz sfer metrycznych, bez założenia zupełności M.

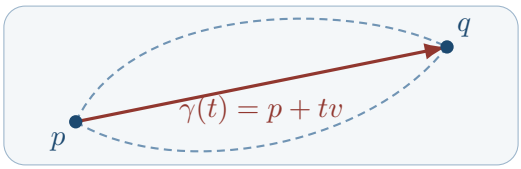
Pierwsza wariacja dowodziła, że krzywa minimalna *musi* być geodezyjną; lemat Gaussa dowiódł, że krótka geodezyjna *jest* krzywą minimalną. Na długich odcinkach drugie zdanie może przestać być prawdziwe. Druga wariacja i pola Jacobiego w Sekcji 14.11 opiszą, jak krzywizna wpływa na utratę tej własności.

13.4 Geodezyjne w geometriach modelowych

Przykład 13.4.1 (Przestrzeń euklidesowa)**.** Dla $g = \sum_i (\mathrm{d}x^i)^2$ symbole Christoffela znikają. Równanie $\ddot{x} = 0$ ma rozwiązanie $\gamma_{p,v}(t) = p + tv$, a $\exp_p(v) = p + v$ na całym $T_p\mathbb{R}^n$. Dla dowolnej krzywej $\alpha : [a,b] \to \mathbb{R}^n$ od p do q nierówność trójkąta dla całki daje

$$L(\alpha) = \int_a^b |\dot\alpha|\,\mathrm{d}t \geq \left| \int_a^b \dot\alpha \,\mathrm{d}t \right| = |q - p|.$$

Odcinek prosty osiąga tę wartość i jest globalnie minimalny.



Rysunek 13.3: Euklidesowa geodezyjna między p i q jest prostym odcinkiem. Przykładowe drogi przerywane mają większą długość.

Przykład 13.4.2 (Sfera: wielkie koła i antypody)**.** Niech $R > 0$, $p \in S^2_R \subset \mathbb{R}^3$ i $v \perp p$, $s = |v|$. Wyprowadźmy wzór z równania geodezyjnej. Stwierdzenie 12.2.2 mówi, że $\ddot\gamma$ ma być normalne do sfery, czyli $\ddot\gamma = \lambda(t)\gamma$. Różniczkowanie $\langle \gamma, \gamma\rangle = R^2$ daje $\langle \dot\gamma, \gamma\rangle = 0$, a następnie $\langle \ddot\gamma, \gamma\rangle = -|\dot\gamma|^2 = -s^2$. Zatem $\lambda R^2 = -s^2$. Równanie $\ddot\gamma = -(s^2/R^2)\gamma$ z danymi $\gamma(0) = p$, $\dot\gamma(0) = v$ jest układem niezależnych równań oscylatora w $\mathbb{R}^3$. Dla $v \neq 0$ jego rozwiązanie daje

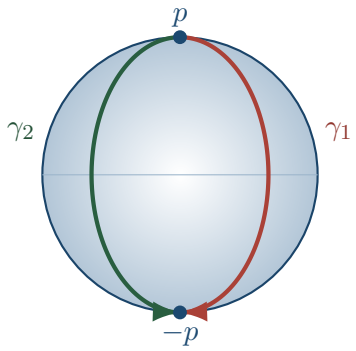
$$\gamma_{p,v}(t) = \cos\!\left(\frac{st}{R}\right) p + \frac{R}{s}\sin\!\left(\frac{st}{R}\right) v, \qquad \exp_p(v) = \gamma_{p,v}(1). \tag{13.4.1}$$

Dla $v = 0$ rozumiemy granicę, czyli $\exp_p(0) = p$. Różniczkując dwa razy, dostajemy $\ddot\gamma = -(s^2/R^2)\gamma$. Wektor γ jest normalny do sfery, więc jego rzut na przestrzeń styczną jest zerowy. Ze Stwierdzenia 12.2.2 wynika $D\dot\gamma/\mathrm{d}t = 0$. Są to łuki wielkich kół.

Dla bieguna p i $r = R\theta$ metryka (11.2.1) przyjmuje postać

$$g = \mathrm{d}r^2 + R^2 \sin^2(r/R)\,\mathrm{d}\phi^2, \qquad 0 < r < \pi R.$$

Jest to konkretny przypadek (13.3.2). Łuk od p do punktu w odległości kątowej $\theta < \pi$ ma długość $R\theta$ i jest minimalny. Funkcja $r(x) = R\arccos(\langle p, x\rangle / R^2)$ jest określona na całej sferze i gładka poza biegunami $p, -p$. Lokalny wzór na metrykę działa po zmianie kąta ϕ także przy przekroczeniu szwu mapy. Dla drogi $\alpha : [a,b] \to S^2_R$ od p do rozważanego punktu, omijającej antypodę, nadal mamy $L(\alpha) \geq \int_a^b |\dot r(t)|\,\mathrm{d}t \geq |r(b) - r(a)| = R\theta$. Dla drogi przechodzącej przez antypodę najpierw stosujemy to oszacowanie do pierwszego osiągnięcia poziomu $r = \pi R - \varepsilon$. Przejście $\varepsilon \downarrow 0$ daje długość co najmniej $\pi R > R\theta$. Przy przejściach przez p argument absolutnej ciągłości z dowodu Twierdzenia 13.3.2 uzasadnia całkowanie mimo niegładkości r. Przy $r = \pi R$



Rysunek 13.4: Dwa różne półokręgi wielkich kół łączą p z antypodą. Każdy ma długość πR. Rysunek jest rzutem ortogonalnym: półokręgi widać jako połówki elips, a równik jako odcinek. Przedłużenie łuku za antypodę nie minimalizuje już długości od p.

wszystkie kierunki jednostkowe trafiają do antypody $-p$: istnieje wiele minimalnych półokręgów o długości πR. Za antypodą przedłużony łuk nadal jest geodezyjną, lecz nie minimalizuje długości. Sfera pozostaje geodezyjnie zupełna: wzór (13.4.1) działa dla każdego $t \in \mathbb{R}$.

Przykład 13.4.3 (Przestrzeń hiperboliczna)**.** W modelu górnej półprzestrzeni z (11.2.3) pionowa krzywa

$$\gamma(s) = (x_0, y_0 e^s), \qquad s \in \mathbb{R},$$

ma prędkość hiperboliczną 1. W dwuwymiarowym przypadku wzory (12.3.5) dają $\ddot{y} - (\dot{y})^2/y = 0$ i równanie poziome jest spełnione, więc to geodezyjna. Dla krzywej $\alpha : [a,b] \to \mathbb{H}^n$ łączącej (x_0, y_0) z (x_0, y_1) mamy

$$L = \int_a^b \frac{\sqrt{|\dot{x}|^2 + \dot{y}^2}}{y}\,\mathrm{d}t \geq \int_a^b \left|\frac{\dot{y}}{y}\right|\mathrm{d}t \geq \left|\log\frac{y_1}{y_0}\right|.$$

Ostatnie przejście używa nierówności $\int_a^b |\dot{y}/y|\,\mathrm{d}t \geq |\int_a^b \dot{y}/y\,\mathrm{d}t|$ i pochodnej $\log y$; pełne wyprowadzenie podano w przykładzie „Niezupełność i brzeg modelu hiperbolicznego” w Sekcji 11.4. Pionowa geodezyjna osiąga tę wartość. Zatem granica $y = 0$ jest w nieskończonej odległości wzdłuż pionu, choć na rysunku euklidesowym wydaje się bliska.

To nie są wszystkie geodezyjne półprzestrzeni. W wymiarze dwa równania geodezyjnej z (12.3.5) mają postać

$$\ddot{x} - \frac{2\dot{x}\dot{y}}{y} = 0, \qquad \ddot{y} + \frac{\dot{x}^2 - \dot{y}^2}{y} = 0.$$

Rozpatrzmy niestałą geodezyjną i parametryzujmy ją długością łuku: $(\dot{x}^2+\dot{y}^2)/y^2 = 1$. Pierwsze równanie po przekształceniu daje $\frac{\mathrm{d}}{\mathrm{d}s}(\dot{x}/y^2) = 0$. Jeżeli stała $c = \dot{x}/y^2$ jest zerowa, otrzymujemy pionową prostą. Jeśli $c \neq 0$, to $\dot{x} = cy^2$ oraz $\dot{y}^2 = y^2(1 - c^2y^2)$. Eliminując parametr,

$$\frac{\mathrm{d}x}{\mathrm{d}y} = \pm\frac{cy}{\sqrt{1-c^2y^2}} \quad\Longrightarrow\quad x - x_c = \mp\frac{1}{c}\sqrt{1-c^2y^2} \quad\Longrightarrow\quad (x-x_c)^2 + y^2 = c^{-2}$$

po scałkowaniu na odcinkach monotoniczności y. Stała x_c jest stałą całkowania. Użytą funkcję pierwotną sprawdzamy regułą łańcuchową:

$$\frac{\mathrm{d}}{\mathrm{d}y}\left(-\frac{1}{c}\sqrt{1-c^2y^2}\right) = -\frac{1}{c}\,\frac{-2c^2y}{2\sqrt{1-c^2y^2}} = \frac{cy}{\sqrt{1-c^2y^2}}.$$

Jest to półokrąg o środku $(x_c, 0)$, przecinający brzeg $y = 0$ prostopadle. Punkt zwrotny wysokości nie jest końcem geodezyjnej. Dla $R_0 = 1/|c|$ jawne rozwiązanie jednostkowe to

$$x(s) = x_c + \operatorname{sgn}(c) R_0 \tanh(s - s_0), \qquad y(s) = \frac{R_0}{\cosh(s - s_0)}, \qquad s \in \mathbb{R}.$$

Podstawienie sprawdza oba równania i stałą $\dot{x}/y^2 = c$; rozwiązanie przechodzi gładko przez maksimum y w $s = s_0$. W wymiarze $n > 2$ każda geodezyjna mieści się w pewnej pionowej dwupłaszczyźnie: odbicie w niej jest izometrią, zachowuje punkt i wektor początkowy, a jednoznaczność rozwiązania równania geodezyjnej wymusza niezmienniczość krzywej. Tam stosujemy powyższy rachunek. W wymiarze 1 model jest półprostą z metryką $\mathrm{d}y^2/y^2$ i pozostają wyłącznie geodezyjne pionowe oraz krzywe stałe.

W modelu hiperboloidy z Przykładu 11.2.3 piszemy $\langle (t,z),(t',z')\rangle_L = -tt' + z\cdot z'$ i $\langle p,p\rangle_L = -1$. Dla $v \in T_p\mathcal{H}^n$, $s = |v|_g$, mamy

$$\exp_p(v) = \cosh(s)p + \frac{\sinh(s)}{s}v, \tag{13.4.2}$$

z wartością graniczną p przy $s = 0$. Dokładniej, dla jednostkowego $w \in T_p\mathcal{H}^n$ cała geodezyjna ma wzór $\gamma_{p,w}(\tau) = \cosh\tau\, p + \sinh\tau\, w$. Leży w przecięciu hiperboloidy z dwuwymiarową płaszczyzną liniową $\operatorname{span}(p,w)$ przechodzącą przez początek przestrzeni Minkowskiego. Rzeczywiście $\langle p,v\rangle_L = 0$; podstawienie daje normę lorentzowską -1, a znak współrzędnej czasowej pozostaje dodatni przez ciągłość. Rzutowanie pochodnej płaskiej działa tu także dla iloczynu lorentzowskiego: przestrzeń styczna jest niezdegenerowana, a jej dopełnieniem ortogonalnym jest prosta rozpięta przez wektor położenia x, o $\langle x,x\rangle_L = -1$. Ten sam dowód zgodności i braku torsji co w Stwierdzeniu 12.2.2 daje

$$\nabla_X Y = D_X Y + \langle D_X Y, x\rangle_L x = D_X Y - g(X,Y)x.$$

Pierwszy znak plus usuwa składową normalną: iloczyn wyniku z x wynosi $\langle D_XY,x\rangle_L(1 + \langle x,x\rangle_L) = 0$. Drugą równość otrzymujemy, różniczkując $\langle Y,x\rangle_L = 0$ w kierunku X: $\langle D_XY,x\rangle_L + \langle Y,X\rangle_L = 0$. Równanie geodezyjnej i stałość kwadratu prędkości dają zatem zwykły układ $\ddot{\gamma} = s^2\gamma$. Jego rozwiązanie z danymi (p,v) jest kombinacją $\cosh(st)p + \sinh(st)v/s$, co wyprowadza (13.4.2). Dla $\gamma(t) = \cosh(st)p + \sinh(st)v/s$ mamy $\ddot{\gamma} = s^2\gamma$ i $g(\dot\gamma,\dot\gamma) = s^2$, więc rzeczywiście $D\dot\gamma/\mathrm{d}t = 0$. Wzór działa dla każdego t, co dowodzi zupełności geodezyjnej.

Uzasadnijmy dziedzinę odwrotnej funkcji hiperbolicznej. Jeśli $p = (\sqrt{1+|z|^2}, z)$ i $q = (\sqrt{1+|w|^2}, w)$, to nierówność Cauchy'ego–Schwarza daje

$$-\langle p,q\rangle_L \geq \sqrt{1+|z|^2}\sqrt{1+|w|^2} - |z|\,|w| \geq 1.$$

Druga nierówność po podniesieniu do kwadratu sprowadza się do $(|z| - |w|)^2 \geq 0$; równość w obu zachodzi dokładnie dla $z = w$. Dla dowolnego $q \in \mathcal{H}^n$ połóżmy $s = \operatorname{arcosh}(-\langle p,q\rangle_L)$. Gdy $q \neq p$, wektor $v = \frac{s}{\sinh s}(q - \cosh(s)p)$ jest styczny w p, ma normę s i spełnia $\exp_p(v) = q$. Zatem $\exp_p$ jest także surjekcją na $\mathcal{H}^n$. Istotnie, dla $C = \cosh s = -\langle p,q\rangle_L$ mamy $\langle p, q - Cp\rangle_L = -C + C = 0$ oraz $\langle q - Cp, q - Cp\rangle_L = -1 + 2C^2 - C^2 = \sinh^2 s$. Mnożnik $s/\sinh s$ nadaje normę s, a podstawienie do (13.4.2) daje q. Późniejszy Wniosek 13.5.4 zapewni istnienie globalnej geodezyjnej minimalnej. Jeśli $q = \exp_p(v)$, iloczyn z p daje $-\langle p,q\rangle_L = \cosh|v|_g$; jednoznaczność dodatniego $|v|_g$ i wyrażenia (13.4.2) pokazuje, że $\exp_p$ jest różnowartościowe. Dlatego

$$d_{\mathcal{H}}(p,q) = \operatorname{arcosh}(-\langle p,q\rangle_L). \tag{13.4.3}$$

W *modelu kuli Poincarégo* z (11.2.4) skorzystajmy z izometrii $P : B^n \to \mathcal{H}^n$ zapisanej w Przykładzie 11.2.3. Ponieważ $P(0) = (1,0)$ i $P^{-1}(t,z) = z/(t+1)$, obraz geodezyjnej $\tau \mapsto (\cosh\tau, \sinh\tau\, e)$, $|e| = 1$, jest równy

$$\gamma_e(\tau) = \tanh(\tau/2)e. \tag{13.4.4}$$

W tym podstawieniu współczynnik przy e jest równy

$$\frac{\sinh\tau}{\cosh\tau + 1} = \frac{2\sinh(\tau/2)\cosh(\tau/2)}{2\cosh^2(\tau/2)} = \tanh(\tau/2).$$

Wszystkie średnice dysku są więc geodezyjnymi *jako zbiory punktów*; parametr euklidesowy na średnicy nie jest parametrem długości hiperbolicznej.

Pozostałe geodezyjne w dwuwymiarowym dysku są łukami okręgów prostopadłych do brzegu $|u| = 1$. Oto rachunek wyjaśniający ten obraz. Geodezyjna hiperboloidy leży w płaszczyźnie liniowej, którą w $\mathbb{R}^{1,2}$ można zapisać jako $\alpha t + b \cdot z = 0$. Po podstawieniu $P(u) = ((1+|u|^2)/(1-|u|^2), 2u/(1-|u|^2))$ jej obraz odwrotny spełnia

$$\alpha(1 + |u|^2) + 2b \cdot u = 0.$$

Jeśli $\alpha = 0$, to średnica $b \cdot u = 0$. Jeśli $\alpha \neq 0$, po oznaczeniu $c = -b/\alpha$ dostajemy

$$|u - c|^2 = |c|^2 - 1. \tag{13.4.5}$$

Środek c leży poza dyskiem: płaszczyzna geodezyjnej przecina hiperboloidę, więc równanie ma rozwiązanie $0 < |u| < 1$; stąd $|b| \geq |\alpha|(1 + |u|^2)/(2|u|) > |\alpha|$. Kwadrat promienia okręgu wynosi $|c|^2 - 1$. Warunek ten oznacza prostopadłe przecięcie z okręgiem jednostkowym: w punkcie przecięcia u równanie okręgu daje $u \cdot (u - c) = 0$, więc promienie obu okręgów są prostopadłe. W wymiarze $n > 2$ geodezyjna leży w odpowiednim dwuwymiarowym przekroju kuli i ten sam opis działa w tym przekroju.

Izometria $F : B^n \to \mathbb{H}^n$ z Przykładu 11.2.3 przenosi opis dyskowy na pionowe proste i półokręgi w półprzestrzeni. Izometrie zachowują pochodną kowariantną, więc obrazy geodezyjnych są geodezyjnymi. Zachowują też długości, skąd z (13.4.3) otrzymujemy użyteczne wzory odległości:

$$\begin{aligned} \cosh d_B(u, v) &= 1 + \frac{2|u - v|^2}{(1 - |u|^2)(1 - |v|^2)}, \\ \cosh d_{\mathbb{H}}((x, y), (x', y')) &= 1 + \frac{|x - x'|^2 + (y - y')^2}{2yy'}. \end{aligned} \tag{13.4.6}$$

Rozpiszmy oba podstawienia. Dla $U = |u|^2$ i $V = |v|^2$ iloczyn Minkowskiego daje

$$-\langle P(u), P(v)\rangle_L = \frac{(1 + U)(1 + V) - 4u \cdot v}{(1 - U)(1 - V)} = 1 + \frac{2(U + V - 2u \cdot v)}{(1 - U)(1 - V)}.$$

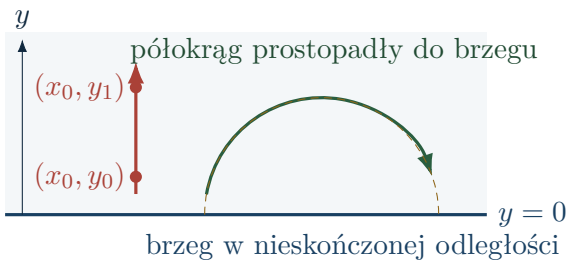
W ostatnim kroku od licznika odjęliśmy mianownik; pozostaje $2|u - v|^2$, co daje pierwszy wzór. Dla półprzestrzeni wygodnie złożyć obie wcześniejsze izometrie. Podstawienie F^{-1} do P, z użyciem $1 - |F^{-1}(x, y)|^2 = 4y/(|x|^2 + (y + 1)^2)$ z Przykładu 11.2.3, daje

$$Q(x, y) := (P \circ F^{-1})(x, y) = \left(\frac{|x|^2 + y^2 + 1}{2y},\ \frac{x}{y},\ \frac{|x|^2 + y^2 - 1}{2y} \right).$$

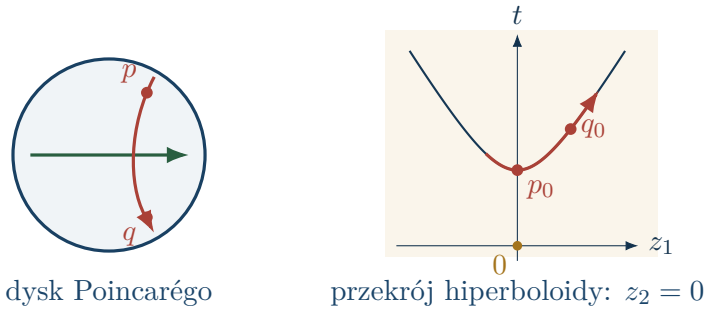
Oznaczmy $A = |x|^2 + y^2$, $A' = |x'|^2 + y'^2$. Wtedy

$$\begin{aligned} -\langle Q(x, y), Q(x', y')\rangle_L &= \frac{(A + 1)(A' + 1) - 4x \cdot x' - (A - 1)(A' - 1)}{4yy'} \\ &= \frac{|x - x'|^2 + y^2 + y'^2}{2yy'} = 1 + \frac{|x - x'|^2 + (y - y')^2}{2yy'}. \end{aligned}$$

To wyprowadza drugi wzór z tej samej tożsamości (13.4.3). W szczególności $d_B(0, u) = 2 \operatorname{artanh} |u| \to \infty$ przy $|u| \uparrow 1$: widoczny brzeg dysku, podobnie jak prosta $y = 0$, nie leży w przestrzeni hiperbolicznej.



Rysunek 13.5: Geodezyjne w modelu górnej półpłaszczyzny: pionowa półprosta i półokrąg przecinający brzeg $y = 0$ pod kątem prostym. Brzeg nie należy do przestrzeni hiperbolicznej.



Rysunek 13.6: Po lewej geodezyjne dysku: średnica i łuk okręgu prostopadłego do brzegu (końce na brzegu nie należą do geodezyjnej). Po prawej dokładny przekrój hiperboloidy $t^2 - z_1^2 - z_2^2 = 1$, $t > 0$, płaszczyzną liniową $z_2 = 0$. Czerwona geodezyjna ma postać $(\cosh u, \sinh u, 0)$; zaznaczono p_0 dla $u = 0$ i q_0 dla $u = 1$. Płaszczyzna przekroju zawiera początek 0.

Przykład 13.4.4 (geodezyjne i symbole Christoffela u Poincarégo)**.** Wróćmy do metryki Minkowskiego (11.3.1). Przyjmijmy $x^0 = t$ oraz $(x^1, x^2, x^3) = (x, y, z)$. Macierz metryki i macierz odwrotna są stałe:

$$(g_{\mu\nu}) = \operatorname{diag}(-c^2, 1, 1, 1), \qquad (g^{\mu\nu}) = \operatorname{diag}(-c^{-2}, 1, 1, 1).$$

Dla dowolnych μ, ν, ρ mamy $\partial_\rho g_{\mu\nu} = 0$, a więc wzór na koneksję Leviego-Civity daje

$$\Gamma^\lambda_{\mu\nu} = \frac{1}{2} g^{\lambda\rho}(\partial_\mu g_{\rho\nu} + \partial_\nu g_{\rho\mu} - \partial_\rho g_{\mu\nu}) = 0. \tag{13.4.7}$$

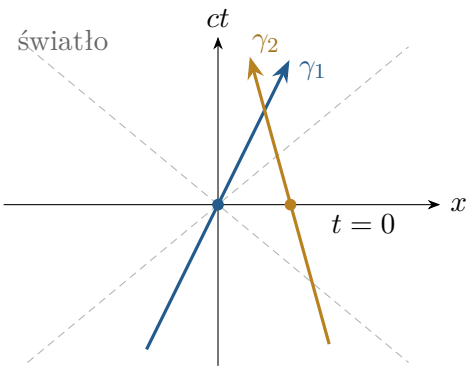
Równanie geodezyjnej przyjmuje zatem postać $(x^\mu)'' = 0$. Jest to układ czterech niezależnych liniowych równań różniczkowych zwyczajnych drugiego rzędu, którego wszystkie rozwiązania mają postać

$$\gamma(s) = (t_0 + u^0 s,\ x_0 + u^1 s,\ y_0 + u^2 s,\ z_0 + u^3 s), \qquad s \in \mathbb{R}. \tag{13.4.8}$$

Wektor styczny $u = \gamma'$ jest stały i $g_M(u, u) = -c^2(u^0)^2 + (u^1)^2 + (u^2)^2 + (u^3)^2$. W przypadku $u \neq 0$ krzywe są odpowiednio czasowe, zerowe lub przestrzenne, gdy to wyrażenie jest ujemne, zerowe lub dodatnie. Dla $u = 0$ krzywa jest stała. Dla $u^0 \neq 0$ geodezyjna przecina hiperpowierzchnię $t = 0$ przy $s_0 = -t_0/u^0$ i przedłuża się na obie strony tego punktu bez zmiany wzoru. Każda geodezyjna ma dziedzinę całe $\mathbb{R}$, więc $(\mathbb{R}^4, g_M)$ jest geodezyjnie zupełna.

Podstawienie Poincarégo $\zeta = ict$ przenosi te proste na $F \circ \gamma$, gdzie $\zeta(s) = ic(t_0 + u^0 s)$ i $\zeta''(s) = 0$. Ograniczenie $\zeta \in i\mathbb{R}$ jest istotne: nie pojawia się dodatkowy rzeczywisty kierunek czasowy.

Przykład 13.4.5 (Geodezyjne geometrii Sol i potencjał efektywny)**.** Przyjmijmy metrykę g_S z Przykładu 11.2.4 i niech $s \mapsto (x(s), y(s), t(s))$ będzie geodezyjną w parametryzacji afinicznej. Jej lagranżjan kinetyczny jest równy $L = \frac{1}{2}(e^{-2t}\dot{x}^2 + e^{2t}\dot{y}^2 + \dot{t}^2)$. Współrzędne x, y nie występują



Rysunek 13.7: Dwie geodezyjne czasowe przechodzące przez hiperpowierzchnię $t = 0$ w czasoprzestrzeni Minkowskiego. Nie występuje tu brzeg rozmaitości ani osobliwość metryki; linie przerywane przedstawiają kierunki świetlne.

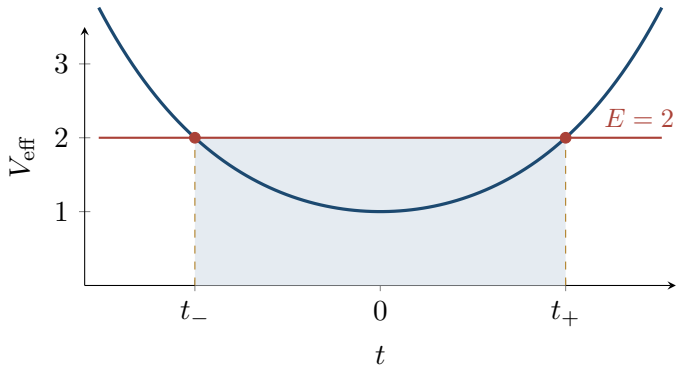
w L, więc równania Eulera–Lagrange'a mają postać $\frac{\mathrm{d}}{\mathrm{d}s}(\partial L/\partial \dot{x}) = 0$ i $\frac{\mathrm{d}}{\mathrm{d}s}(\partial L/\partial \dot{y}) = 0$. Dają dwie całki pierwsze

$$p_x = e^{-2t}\dot{x}, \qquad p_y = e^{2t}\dot{y}. \tag{13.4.9}$$

Dzięki $\dot{x} = p_x e^{2t}$, $\dot{y} = p_y e^{-2t}$ stałość energii $E = L$ przyjmuje postać

$$\tfrac{1}{2}\dot{t}^2 + V_{\mathrm{eff}}(t) = E, \qquad V_{\mathrm{eff}}(t) = \tfrac{1}{2}(p_x^2 e^{2t} + p_y^2 e^{-2t}). \tag{13.4.10}$$

Równanie dla t daje najpierw $\ddot{t} = \partial L/\partial t = -e^{-2t}\dot{x}^2 + e^{2t}\dot{y}^2$. Po podstawieniu momentów jest równoważne $\ddot{t} = -V'_{\mathrm{eff}}(t) = -p_x^2 e^{2t} + p_y^2 e^{-2t}$. W ten sposób trójwymiarowy układ redukuje się do ruchu w jednowymiarowym potencjale i dwóch kwadratur dla x, y. Jeżeli $p_x p_y \neq 0$, potencjał dąży do nieskończoności przy $t \to \pm\infty$ i ma jedno minimum przy $e^{4t} = p_y^2/p_x^2$. Geodezyjna o skończonej energii nie może wówczas uciec do nieskończoności w kierunku t. Zupełność geodezyjną całego modelu można uzasadnić także w przypadkach zerowania się któregoś momentu. Z energii zawsze $|\dot{t}| \le \sqrt{2E}$, więc na skończonym przedziale parametru t pozostaje ograniczone. Wzory na $\dot{x}, \dot{y}$ ograniczają wtedy obie prędkości, a całkowanie ogranicza również x, y. Wszystkie współrzędne położenia i prędkości pozostają zatem w zwartym pudełku w $T\mathbb{R}^3 \simeq \mathbb{R}^6$. Gładki układ geodezyjny nie może mieć w takich warunkach skończonego końca maksymalnego przedziału: ograniczone pole układu daje granicę danych, od której lokalne twierdzenie ODE przedłuża rozwiązanie. Ten argument działa w obu kierunkach parametru.



Rysunek 13.8: Dla $p_x = p_y = 1$ potencjał Sol ma postać $V_{\mathrm{eff}}(t) = \cosh(2t)$. Przy energii $E = 2$ możliwe są tylko wartości $t \in [t_-, t_+]$, gdzie $t_\pm = \pm\frac{1}{2}\operatorname{arcosh} 2$. W punktach zwrotnych $\dot{t} = 0$; ruch w kierunkach x, y nadal trwa.

Przykład 13.4.6 (Rzuty geodezyjnych Nil na płaszczyznę)**.** Dla g_N lagranżjan wynosi $L = \frac{1}{2}(\dot{x}^2 + \dot{y}^2 + (\dot{z} - x\dot{y})^2)$. Współrzędna z jest cykliczna, zatem $w := \partial L/\partial \dot{z} = \dot{z} - x\dot{y}$ jest stałe. Pozostałe potrzebne pochodne to $\partial L/\partial \dot{x} = \dot{x}$, $\partial L/\partial \dot{y} = \dot{y} - xw$, $\partial L/\partial x = -w\dot{y}$ oraz $\partial L/\partial y = 0$. Równania Eulera–Lagrange'a dla x, y sprowadzają się do

$$\ddot{x} = -w\dot{y}, \qquad \ddot{y} = w\dot{x}, \qquad \dot{z} = w + x\dot{y}. \tag{13.4.11}$$

Rzeczywiście, równanie dla y stwierdza stałość $\dot{y} - xw$, a dla x daje $\ddot{x} = -w\dot{y}$. Ponieważ w jest stałe, różniczkowanie pierwszej z tych wielkości daje $\ddot{y} - w\dot{x} = 0$. Ponadto $\frac{\mathrm{d}}{\mathrm{d}s}(\dot{x}^2 + \dot{y}^2) = 2\dot{x}(-w\dot{y}) + 2\dot{y}(w\dot{x}) = 0$. Wektor $(\dot{x}, \dot{y})$ obraca się na płaszczyźnie ze stałą prędkością kątową w i ma stałą długość. Przy $w \neq 0$ całki pierwsze $x - \dot{y}/w$ oraz $y + \dot{x}/w$ wyznaczają stały środek rzutu, a jego promień wynosi $\sqrt{\dot{x}^2 + \dot{y}^2}/|w|$. Jeśli $w = 0$, rzut geodezyjnej jest prostą; przy $w \neq 0$ i niezerowej prędkości poziomej jest łukiem okręgu. Ostatnie równanie wyznacza współrzędną pionową przez całkowanie. Nie należy utożsamiać geodezyjnych Nil z krzywymi poziomymi: warunek poziomości to $w = 0$ i jest dodatkowym ograniczeniem.

Na przykład dla danych $(x, y, z)(0) = (0, 0, 0)$, $\dot{x}(0) = 1$, $\dot{y}(0) = 0$ i $w = 1$ połóżmy $U = \dot{x} + i\dot{y}$. Układ daje $U' = iU$, $U(0) = 1$, czyli $(e^{-is}U)' = 0$ i $U = e^{is}$. Stąd $\dot{x} = \cos s$, $\dot{y} = \sin s$, a całkowanie od 0 do s daje dwie pierwsze współrzędne:

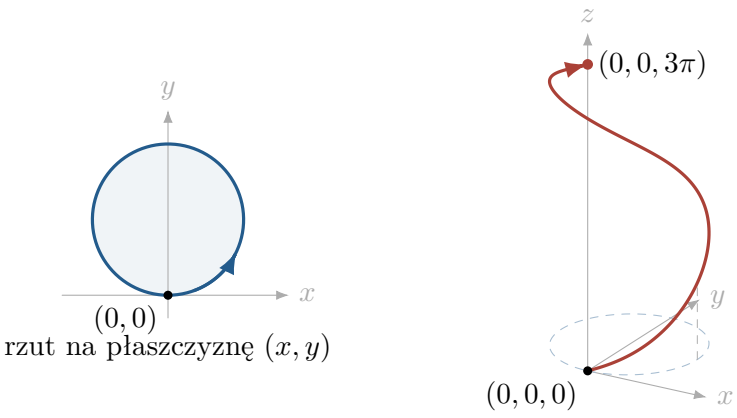
$$x(s) = \sin s, \qquad y(s) = 1 - \cos s, \qquad z(s) = \frac{3}{2}s - \frac{1}{4}\sin(2s).$$

Trzecią otrzymujemy już bez rozwiązywania układu:

$$z(s) = \int_0^s (1 + x(\sigma)\dot{y}(\sigma))\,\mathrm{d}\sigma = \int_0^s \left(\frac{3}{2} - \frac{1}{2}\cos(2\sigma)\right)\mathrm{d}\sigma = \frac{3}{2}s - \frac{1}{4}\sin(2s),$$

gdzie użyliśmy $\sin^2\sigma = (1 - \cos(2\sigma))/2$. Istotnie, $\ddot{x} = -\dot{y}$, $\ddot{y} = \dot{x}$ oraz $\dot{z} = 1 + \sin^2 s = 1 + x\dot{y}$. Rzut jest okręgiem $x^2 + (y-1)^2 = 1$, lecz po jednym obiegu $s = 2\pi$ wysokość wynosi 3π. Prędkość metryczna jest stała i równa $\sqrt{2}$.

Te całki dają też zupełność geodezyjną Nil. Stałość $\dot{x}^2 + \dot{y}^2$ ogranicza prędkości poziome, więc na skończonym przedziale x, y są ograniczone. Równość $\dot{z} = w + x\dot{y}$ ogranicza następnie $\dot{z}$ i z. Jak w Sol, położenie i prędkość pozostają w zwartym podzbiorze $\mathbb{R}^6$, a gładkie ODE przedłuża geodezyjną przez każdy skończony koniec.



Rysunek 13.9: Geodezyjna Nil dla $w = 1$ z przykładu. Po lewej jej kołowy rzut, po prawej przebieg współrzędnych przestrzennych dla $0 \le s \le 2\pi$. Powrót do tego samego punktu w rzucie nie oznacza powrotu w Nil: współrzędna z wzrasta o 3π. Kształt narysowano we współrzędnych, a długość jest mierzona metryką g_N.

13.5 Twierdzenie Hopfa–Rinowa

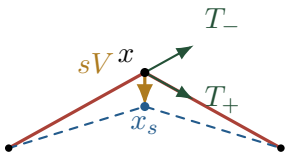
W lokalnym twierdzeniu minimalnym odcinek był krótki. Żeby mieć geodezyjną minimalną między *dowolnymi* punktami, potrzebujemy warunku, który zabrania geodezyjnej uciec z rozmaitości w skończonym czasie. Dla spójnej rozmaitości riemannowskiej równoważne są dwa pozornie różne rodzaje zupełności.

Definicja 13.5.1 (Dwa znaczenia zupełności)**.** (M, g) jest *metrycznie zupełna*, gdy każdy ciąg Cauchy'ego dla d_g ma granicę w M. Jest *geodezyjnie zupełna*, gdy każdą geodezyjną można przedłużyć do parametru z całej $\mathbb{R}$.

Do dowodu potrzebne jest spostrzeżenie o narożniku. Jeżeli dwie jednostkowe geodezyjne składają się w drogę minimalną, ich wektory styczne w punkcie sklejenia x muszą być równe. Oznaczmy je przez T_-, T_+, a chwilę sklejenia przez t_0. W mapie wokół x wybieramy ciągłe, kawałkami gładkie pole wariacyjne o małym nośniku wokół chwili sklejenia, takie że $V(t_0) = T_+ - T_-$. Mnożenie jego współrzędnych przez funkcję odcinającą realizuje taką wariację przez dodanie sV we współrzędnych, przy nieruchomych końcach. Dla małego s oba kawałki pozostają regularne. Wzór pierwszej wariacji na obu geodezyjnych ma zerowe składniki całkowe, a wyraz narożnikowy wynosi

$$g(T_+ - T_-, T_- - T_+) = -|T_+ - T_-|_g^2.$$

Jeśli styczne są różne, długość maleje dla małego $s > 0$, co przeczy minimalności. Przy jednakowych niezerowych prędkościach ten argument stosujemy po wspólnym skalowaniu.



$$V = T_+ - T_-$$
$$L'(0) = -|T_+ - T_-|_g^2 < 0$$

Rysunek 13.10: Skracanie narożnika. Przesuwamy punkt sklejenia w kierunku $T_+ - T_-$ przy nieruchomych końcach drogi. Linia przerywana schematycznie pokazuje wariację w małej mapie; znak zmiany długości wynika z pierwszej wariacji, niezależnie od wyglądu łuków w tej mapie.

Lemat 13.5.2 (Jeden punkt z pełnym odwzorowaniem wykładniczym)**.** *Niech M będzie spójną rozmaitością riemannowską bez brzegu. Jeżeli dla pewnego $p \in M$ odwzorowanie* $\exp_p$ *jest określone na całym T_pM, to każdy $q \in M$ można połączyć z p geodezyjną o długości $d_g(p, q)$.*

Dowód. Jeśli $q = p$, bierzemy stałą geodezyjną. Niech $r = d_g(p, q) > 0$. Wybierzmy małą kulę $B_\varepsilon^g(p)$ spełniającą (13.3.4) i $0 < \delta < \min(\varepsilon, r)$. Sfera $S_\delta(p) = \exp_p\{v : |v| = \delta\}$ jest zwarta jako obraz zwykłej zwartej sfery. Funkcja $z \mapsto d_g(z, q)$ jest ciągła, więc osiąga na niej minimum w punkcie m. Każda droga z p do q przecina tę sferę. Jej część do pierwszego przecięcia ma długość co najmniej δ, pozostała zaś co najmniej $d_g(z, q) \geq d_g(m, q)$. Z drugiej strony biorąc infimum po wszystkich drogach, mamy $r \geq \delta + d_g(m, q)$. Nierówność trójkąta i $d_g(p, m) = \delta$ dają odwrotnie $r \leq \delta + d_g(m, q)$, a więc

$$r = \delta + d_g(m, q). \tag{13.5.1}$$

Niech $\gamma : [0, \infty) \to M$ będzie jednostkową geodezyjną od p przez m. Istnieje dla wszystkich $t \geq 0$: dla danego t punkt $\gamma(t) = \exp_p(t\dot\gamma(0))$ jest określony, a jednoznaczność skleja te odcinki. Rozważmy zamknięty zbiór

$$A = \{t \in [0, r] : t + d_g(\gamma(t), q) = r\}.$$

Z (13.5.1) wiemy, że $\delta \in A$. Zbiór A jest więc niepustym domkniętym podzbiorem zwartego $[0,r]$ i ma największy punkt. Jeśli ten największy punkt t_* zbioru A byłby mniejszy od r, połóżmy $x = \gamma(t_*)$ i wybierzmy małą normalną sferę $S_\eta(x)$ o promieniu $0 < \eta < d_g(x,q)$, tak by η mieściło się również w normalnym otoczeniu x. Niech m' minimalizuje $z \mapsto d_g(z,q)$ na $S_\eta(x)$. To samo rozumowanie z pierwszym wyjściem z kuli daje

$$d_g(x,q) = \eta + d_g(m',q), \qquad r = t_* + \eta + d_g(m',q). \tag{13.5.2}$$

Nierówność trójkąta i droga przez x, m' dają

$$r \le d_g(p,m') + d_g(m',q) \le t_* + \eta + d_g(m',q) = r.$$

Zachodzi więc równość: sklejenie $\gamma|_{[0,t_*]}$ z krótką radialną geodezyjną z x do m' minimalizuje długość od p do m'. Obie części są jednostkowe, zatem spostrzeżenie o narożniku wymusza zgodność ich stycznych w x. Jednoznaczność równania geodezyjnej daje $m' = \gamma(t_* + \eta)$. Wtedy (13.5.2) mówi, że $t_* + \eta \in A$; przy tym $t_* + \eta < r$, bo $\eta < d_g(x,q) = r - t_*$. To sprzeczność z maksymalnością t_*. Musi więc być $r \in A$, czyli $d_g(\gamma(r),q) = 0$ i $\gamma(r) = q$. Ponieważ γ ma prędkość 1, jej długość na $[0,r]$ wynosi $r = d_g(p,q)$. □

Twierdzenie 13.5.3 (Hopfa–Rinowa)**.** *Niech (M,g) będzie niepustą, spójną rozmaitością riemannowską bez brzegu. Równoważne są warunki:*

(i) (M,d_g) jest zupełną przestrzenią metryczną;

(ii) każda maksymalna geodezyjna jest określona na całej $\mathbb{R}$;

(iii) dla pewnego $p \in M$ mamy $D_p = T_pM$, czyli $\exp_p$ jest określone wszędzie;

(iv) każdy domknięty i ograniczony w metryce d_g podzbiór M jest zwarty.

Gdy warunki zachodzą, w (iii) można napisać dla każdego $p \in M$.

Dowód. Pokażemy kolejno (i)⇒(ii) ⇒(iii)⇒(iv)⇒(i).

(i)⇒(ii). Jeśli jednostkowa geodezyjna $\gamma : [0,b) \to M$ miałaby maksymalny skończony prawy koniec b, to $d_g(\gamma(s),\gamma(t)) \le |s-t|$. Dla dowolnego ciągu $t_j \uparrow b$ ciąg $\gamma(t_j)$ jest Cauchy'ego, więc zbiega do pewnego $z \in M$. Oszacowanie odległości przez $|s-t|$ daje wtedy $\gamma(t) \to z$ dla wszystkich $t \uparrow b$. W mapie wokół z macierz G jest dodatnio określona i na mniejszym zwartym otoczeniu jednostajnie porównywalna z macierzą euklidesową. Stałość prędkości geodezyjnej ogranicza więc jej współczynniki $\dot{x}^i$. Symbole Γ^k_{ij} są tam ograniczone; równanie (13.1.1) ogranicza również $\ddot{x}^k$. Stąd $x(t)$ i $\dot{x}(t)$ mają granice przy $t \uparrow b$. Dokładniej, ze wspólnego ograniczenia $|\ddot{x}| \le K$ wynika $|\dot{x}(t) - \dot{x}(s)| \le K|t-s|$. Prędkości tworzą więc ciąg Cauchy'ego, gdy parametr zbliża się do skończonego b; otrzymujemy konkretne dane końcowe $(z, \lim \dot{x})$ w TM. Lokalne twierdzenie ODE, uruchomione od tych danych w chwili b, przedłuża geodezyjną za b – sprzeczność. Analogicznie na lewym końcu. Dla dowolnej stałej prędkości przeskalowujemy parametr; geodezyjne o zerowej prędkości są stałe i istnieją przez cały czas.

(ii)⇒(iii). Każda $\gamma_{p,v}$ istnieje w chwili 1, więc $D_p = T_pM$ dla każdego p.

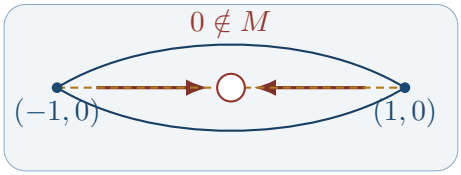
(iii)⇒(iv). Lemat 13.5.2 daje dla każdego q geodezyjną od p o długości $d_g(p,q)$. Jeśli C jest domknięte i ograniczone, wybierzmy R z $d_g(p,q) \le R$ dla wszystkich $q \in C$. Każdy $q \in C$ ma postać $\exp_p(v_q)$ z $|v_q| \le R$. Zatem $C \subset \exp_p(\overline{B}_R(0))$. Domknięta kula w skończenie wymiarowej przestrzeni T_pM jest zwarta, jej obraz też jest zwarty, a domknięty podzbiór tego obrazu jest zwarty. To dowodzi (iv).

(iv)⇒(i). Ciąg Cauchy'ego jest ograniczony; domknięcie zbioru jego wyrazów jest domknięte i ograniczone, więc zwarte. Istnieje zbieżny podciąg, a własność Cauchy'ego zmusza cały ciąg do tej samej granicy. □

Wniosek 13.5.4 (Globalna geodezyjna minimalna)**.** *Jeżeli (M, g) jest spójna i zupełna, to dowolne $p, q \in M$ łączy geodezyjna o długości $d_g(p, q)$. W szczególności każda zwarta rozmaitość riemannowska jest geodezyjnie zupełna.*

Dowód. Pierwszą tezę daje (ii)⇒(iii) oraz Lemat 13.5.2. Dla zwartej M argument stosujemy w każdej składowej spójnej, która jest domknięta i zwarta. Każdy ciąg w niej ma zbieżny podciąg; ciąg Cauchy'ego zbiega do granicy tego podciągu. Zatem (i) zachodzi i stosujemy Twierdzenie 13.5.3. □

Przykład 13.5.5 (Dlaczego potrzebujemy zupełności)**.** W $M = \mathbb{R}^2 \setminus \{0\}$ z metryką euklidesową geodezyjna $\gamma(t) = (1 - t, 0)$ dociera do usuniętego punktu w skończonym czasie $t = 1$. Nie można jej przedłużyć jako krzywej w M. Punkty $(1/n, 0)$ tworzą ciąg Cauchy'ego bez granicy w M. Między $(-1, 0)$ i $(1, 0)$ infimum długości wynosi 2, ale żadna krzywa w M go nie osiąga. Dolne ograniczenie 2 daje nierówność euklidesowa. Dwa odcinki osi, od -1 do $-\varepsilon$ i od ε do 1, połączone półokręgiem promienia ε, mają łączną długość $2 - 2\varepsilon + \pi\varepsilon \to 2$. Równość w nierówności euklidesowej wymagałaby przebiegania odcinka od $(-1, 0)$ do $(1, 0)$ bez cofania, a taki odcinek przechodzi przez usunięty punkt.



Rysunek 13.11: Na przebitej płaszczyźnie prosta geodezyjna może dotrzeć do usuniętego punktu w skończonym czasie. Drogi łączące punkty po przeciwnych stronach otworu omijają go; ich długości mogą zbliżać się do 2, lecz żadna nie osiąga tej wartości.

13.6 Miejsce cięcia i promień injektywności

Krótki łuk geodezyjnej minimalizuje długość, ale na sferze przestaje to robić po przejściu przez antypodę. Na płaskim torusie ten sam kłopot pojawia się bez krzywizny: różne proste w nakryciu mogą dojść do tego samego punktu. Ustalimy dokładną granicę minimalności w każdym kierunku. W tej sekcji (M, g) jest spójną, zupełną rozmaitością riemannowską bez brzegu, więc z Twierdzenia 13.5.3 odwzorowanie $\exp_p$ jest określone na całym T_pM.

Definicja 13.6.1 (Czas i miejsce cięcia)**.** Niech $p \in M$ i $u \in T_pM$ będzie jednostkowy. Dla $\gamma_u(t) = \exp_p(tu)$ określamy *czas cięcia*

$$c_p(u) = \sup\{t \geq 0 : \ d_g(p, \gamma_u(t)) = t\} \in (0, \infty]. \tag{13.6.1}$$

Jeżeli $c_p(u) < \infty$, punkt $\gamma_u(c_p(u))$ jest *miejscem cięcia geodezyjnej* w kierunku u. *Zbiór cięcia* punktu p to

$$\mathrm{Cut}(p) = \{\exp_p(c_p(u)u) : \ |u|_g = 1, \ c_p(u) < \infty\}.$$

Gdy wszystkie czasy cięcia są nieskończone, zbiór ten jest pusty. Czas zależy od wybranego kierunku, a jeden punkt zbioru może mieć kilka kierunków dochodzących.

Definicja mówi o *odległości od p*, nie tylko o tym, czy krzywa spełnia równanie geodezyjnej. Jeśli odcinek $\gamma_u|_{[0,t]}$ jest minimalny, to każdy jego początkowy pododcinek też jest minimalny: krótsza droga do punktu pośredniego, połączona z resztą odcinka, skróciłaby całość. Funkcja $t \mapsto d_g(p, \gamma_u(t)) - t$ jest ciągła. Zbiór czasów z (13.6.1) jest zatem przedziałem $[0, c_p(u)]$ przy

skończonym $c_p(u)$, a przy $c_p(u) = \infty$ jest całym $[0, \infty)$. W szczególności skończony punkt cięcia *jeszcze* łączy z p minimalny odcinek; każdy dłuższy fragment tej samej geodezyjnej już nie minimalizuje. Lokalna minimalność z (13.3.4) daje $c_p(u) > 0$ dla wszystkich u oraz wspólne dodatnie dolne ograniczenie przy ustalonym p.

Definicja 13.6.2 (Promień injektywności)**.** *Promieniem injektywności w punkcie p* nazywamy

$$\operatorname{inj}(p) = \sup\{r > 0 : \ \exp_p|_{B_r(0)} \text{ jest dyfeomorfizmem na swój obraz}\}.$$

Tu $B_r(0) \subset T_pM$ jest otwartą kulą dla g_p; dopuszczamy wartość ∞. Promień całej rozmaitości to $\operatorname{inj}(M) = \inf_{p\in M} \operatorname{inj}(p)$. Lokalne współrzędne normalne zapewniają $\operatorname{inj}(p) > 0$.

Twierdzenie 13.6.3 (Cięcie wyznacza promień injektywności)**.** *Dla spójnej, zupełnej rozmaitości riemannowskiej bez brzegu i każdego $p \in M$ zachodzi*

$$\operatorname{inj}(p) = \inf_{|u|_g=1} c_p(u) = d_g(p, \operatorname{Cut}(p)), \tag{13.6.2}$$

gdzie $d_g(p, \varnothing) = \infty$ oraz $\inf \varnothing = \infty$ dla rozmaitości wymiaru zero. Jeżeli $0 < r < \operatorname{inj}(p)$, to każdy $v \in B_r(0)$ wyznacza jedyną minimalną geodezyjną od p do $\exp_p(v)$, a jej długość wynosi $|v|_g$.

Dowód. Oznaczmy $C = \inf_{|u|=1} c_p(u)$. Najpierw wybierzmy $0 < r < C$. Dla $v = tu \in B_r(0)$, $t > 0$, mamy $t < c_p(u)$, więc $\gamma_u|_{[0,t]}$ minimalizuje. Co więcej, można wybrać ℓ z $t < \ell < c_p(u)$ (gdy $c_p(u) = \infty$, dowolne $\ell > t$). Odcinek do ℓ również minimalizuje. Twierdzenie 14.11.9 z następnego rozdziału mówi, z pełnym dowodem przez drugą wariację, że w jego wnętrzu nie ma punktu sprzężonego z p. Na mocy Stwierdzenia 14.11.6 różniczka $\mathrm{d}(\exp_p)_v$ jest więc odwracalna. Przy $v = 0$ wynika to z dowodu Twierdzenia 13.2.2.

Pokażmy także injektywność $\exp_p$ na $B_r(0)$. Jeśli $\exp_p(v) = \exp_p(w) = q$, to oba promienie są minimalne, więc $|v| = |w| = d_g(p, q) = t$. Dla $t = 0$ mamy $v = w = 0$. Dla $t > 0$ załóżmy, że $v \neq w$. Przedłużmy promień w kierunku v/t do wybranego $\ell > t$ z $\ell < c_p(v/t)$. Droga złożona z minimalnego promienia w kierunku w/t do q i dalszej części promienia w kierunku v/t ma długość $\ell = d_g(p, \exp_p(\ell v/t))$. Jest zatem minimalna, lecz w q ma narożnik: gdyby styczne się zgadzały, jednoznaczność równania geodezyjnej dałaby $v = w$. Argument pierwszej wariacji o narożniku przed Lematem 13.5.2 wyklucza taki narożnik. Zatem $\exp_p$ jest injektywne. Jako lokalny dyfeomorfizm i odwzorowanie injektywne jest dyfeomorfizmem na swój obraz. Otrzymaliśmy $\operatorname{inj}(p) \geq C$.

W drugą stronę załóżmy, że $r > C$. Z definicji infimum istnieje kierunek jednostkowy u z $c_p(u) < r$; wybierzmy $c_p(u) < t < r$ i połóżmy $q = \exp_p(tu)$. Po czasie cięcia ten promień nie minimalizuje, więc $d_g(p, q) < t$. Wniosek 13.5.4 daje inną geodezyjną minimalną do q, z wektorem początkowym w o normie $|w| = d_g(p, q) < t$. Oba różne wektory $w, tu \in B_r(0)$ mają ten sam obraz przez $\exp_p$. Na $B_r(0)$ nie może więc być ona injektywna, tym bardziej nie jest dyfeomorfizmem. To dowodzi $\operatorname{inj}(p) \leq C$.

Jeśli $c_p(u) < \infty$, ciągłość odległości daje $d_g(p, \exp_p(c_p(u)u)) = c_p(u)$. Odległość od p do zbioru cięcia jest zatem infimum wszystkich skończonych $c_p(u)$. Gdy takich nie ma, oba infima w (13.6.2) są równe ∞. Dowiedliśmy równości. Unikalność minimalnej geodezyjnej dla $|v| < r$ wynika z już dowiedzionej injektywności: każda minimalna geodezyjna od p do $\exp_p(v)$ ma wektor początkowy tej samej długości $|v| < r$. □

W dowodzie potrzebowaliśmy informacji o punktach sprzężonych, a więc o drugiej wariacji; jej pełne wyprowadzenie jest w Sekcji 14.11. To, że cięcie może wynikać z dwóch różnych mechanizmów, pokazuje następujący wniosek.

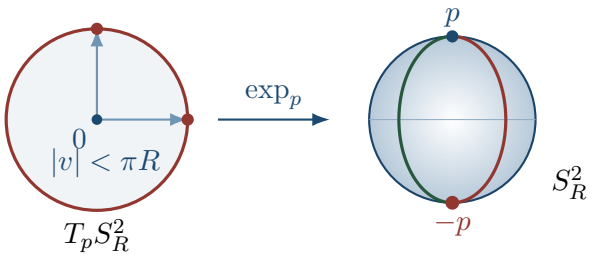
Wniosek 13.6.4 (Co może się zdarzyć w miejscu cięcia)**.** *Jeśli $c_p(u) < \infty$ i $q = \exp_p(c_p(u)u)$, to albo istnieją co najmniej dwie różne minimalne geodezyjne od p do q, albo różniczka $\mathrm{d}(\exp_p)_{c_p(u)u}$ jest osobliwa. Drugi przypadek oznacza sprzężenie wzdłuż wybranego promienia zgodnie ze Stwierdzeniem 14.11.6.*

Dowód. Połóżmy $c = c_p(u)$ i $q_j = \exp_p((c + 1/j)u)$. Z Wniosku 13.5.4 wybierzmy minimalne geodezyjne od p do q_j o wektorach początkowych w_j. Ponieważ $|w_j| = d_g(p, q_j) \le c + 1/j$, po przejściu do podciągu $w_j \to w$. Ciągłość $\exp_p$ i odległości daje $\exp_p(w) = q$ i $|w| = c$. Istnienie podciągu wynika ze zwartości kuli $\overline{B}_{c+1}(0)$ w skończenie wymiarowej przestrzeni T_pM, w której leżą wszystkie w_j. Jeśli $w \neq cu$, mamy dwa różne minimalne promienie do q. Jeśli $w = cu$, a różniczka $\mathrm{d}(\exp_p)_{cu}$ byłaby odwracalna, twierdzenie o funkcji odwrotnej dawałoby injektywność $\exp_p$ na otoczeniu cu. Dla dużych j należałyby do niego zarówno w_j, jak i $(c+1/j)u$, chociaż ich obrazy są równe. To niemożliwe, bo $|w_j| = d_g(p, q_j) < c+1/j$ na mocy definicji czasu cięcia. □

Przykład 13.6.5 (Okrągła sfera)**.** Na S^2_R wzór (13.4.1) daje dla jednostkowego $u \in T_pS^2_R$ punkt $\gamma_u(t) = \cos(t/R)p + R\sin(t/R)u$. Przykład 13.4.2 wykazał, że łuk jest minimalny dla $0 \le t \le \pi R$. Dla $\pi R < t < 2\pi R$ drugi łuk tego samego wielkiego koła, biegnący przeciwnie, ma długość $2\pi R - t < t$. Stąd $c_p(u) = \pi R$ dla każdego u. Wszystkie kierunki trafiają przy $t = \pi R$ do $-p$, więc

$$\mathrm{Cut}(p) = \{-p\}, \qquad \mathrm{inj}(p) = \mathrm{inj}(S^2_R) = \pi R.$$

Na otwartej kuli $B_{\pi R}(0)$ odwzorowanie $\exp_p$ daje jednoznaczne współrzędne; cały okrąg brzegowy $|v| = \pi R$ zapada się do antypody. W tym punkcie występują zarazem wielokrotne geodezyjne minimalne i sprzężenie.



Rysunek 13.12: Na sferze okrąg $|v| = \pi R$ w przestrzeni stycznej przechodzi przez $\exp_p$ w jeden punkt $-p$. Wnętrze koła jest obszarem jednoznacznych geodezyjnych minimalnych; dwa półokręgi na sferze pokazują różne drogi do antypody.

Przykład 13.6.6 (Prostokątny płaski torus)**.** Niech $a, b > 0$ i $T^2_{a,b} = \mathbb{R}^2/(a\mathbb{Z} \times b\mathbb{Z})$ z metryką odziedziczoną z płaszczyzny. Pisząc $[x, y]$ na klasę punktu (x, y), przyjmijmy $p = [0, 0]$. Geodezyjne są rzutami prostych, więc $\exp_p(v_1, v_2) = [v_1, v_2]$. Każda krzywa z p do $[x, y]$ podnosi się do krzywej z $(0, 0)$ do pewnego $(x + ma, y + nb)$, $m, n \in \mathbb{Z}$, o tej samej długości. Euklidesowa nierówność z Przykładu 13.4.1 i rzut odpowiedniego odcinka dają dokładnie

$$d_g(p, [x, y]) = \min_{m,n\in\mathbb{Z}} \sqrt{(x + ma)^2 + (y + nb)^2}. \tag{13.6.3}$$

Minimum istnieje, bo długości wektorów kratowych rosną do nieskończoności.

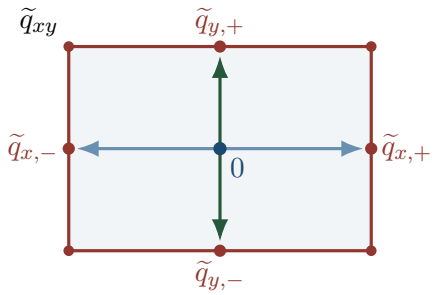
Wśród wszystkich reprezentantów klasy najbliższy zera leży w prostokącie $V = [-a/2, a/2] \times [-b/2, b/2]$. We wnętrzu jest jedyny: każdą współrzędną osobno wybieramy najbliższą zeru modulo a lub modulo b. Na boku są dwa równoodległe reprezentanty, a w narożniku cztery. Dlatego promień w kierunku jednostkowym $u = (u_1, u_2)$ jest minimalny dokładnie do pierwszego spotkania z brzegiem V:

$$c_p(u) = \min\left\{\frac{a}{2|u_1|}, \frac{b}{2|u_2|}\right\}, \qquad \frac{1}{0} := \infty.$$

Zbiór cięcia to obraz brzegu prostokąta:

$$\mathrm{Cut}(p) = \{[a/2, y] : y \in \mathbb{R}\} \cup \{[x, b/2] : x \in \mathbb{R}\}, \qquad \mathrm{inj}(p) = \mathrm{inj}(T^2_{a,b}) = \frac{1}{2}\min(a, b).$$

Każda z obu krzywych tworzących zbiór cięcia jest okręgiem; przecinają się w jednej klasie $[a/2, b/2]$. W punkcie ogólnym każdego z nich są dwie minimalne geodezyjne od p, a w ich przecięciu cztery. Różniczka $\mathrm{d}(\exp_p)_v$ jest wszędzie odwracalna, bo rzut $\mathbb{R}^2 \to T^2_{a,b}$ jest lokalną izometrią. Torus nie ma więc punktów sprzężonych: tutaj cięcie wynika wyłącznie z wielości minimalnych geodezyjnych.



Rysunek 13.13: Komórka najbliższych reprezentantów w nakryciu płaskiego torusa: ma szerokość a i wysokość b. Przeciwległe boki są utożsamione: pary $\widetilde{q}_{x,\pm}$ i $\widetilde{q}_{y,\pm}$ mają po jednym obrazie na torusie, a cztery narożniki także jeden wspólny obraz. Czerwony brzeg rzutuje się na dwa okręgi zbioru cięcia.

Porównanie jest pouczające: na sferze granica jednoznaczności i pierwszy punkt sprzężony wypadają w odległości πR, a na płaskim torusie sama topologia ogranicza promień injektywności do połowy krótszego okresu kratowego. Więcej o zbiorze cięcia i jego związku z promieniem injektywności podaje P. Petersen, *Riemannian Geometry*, §§5.7.3–5.7.4.

13.7 Schwarzschild i Kerr: geodezyjne czasoprzestrzeni

Obie metryki z (11.3.4) i (11.3.5) są *lorentzowskie*. Równanie (13.1.1) i $\exp_p$ nadal mają sens lokalnie, podobnie jak ich dowody z ODE. Nie ma jednak dodatniej normy $\sqrt{g(v,v)}$ dla wszystkich wektorów, więc odległość d_g z Rozdziału 11, lemat o minimalności długości i twierdzenie Hopfa–Rinowa nie stosują się do *całej* czasoprzestrzeni.

Dla czasopodobnej krzywej $\gamma : [a, b] \to M$, $a < b$, z parametrem λ jej *czas własny* jest równy

$$\tau(\gamma) = \int_a^b \sqrt{-g(\dot\gamma, \dot\gamma)}\,\mathrm{d}\lambda. \tag{13.7.1}$$

Przy sygnaturze $(-,+,+,+)$ czasopodobna geodezyjna między dostatecznie bliskimi punktami *maksymalizuje* czas własny wśród przyszłościowych krzywych czasopodobnych o tych samych końcach, zawartych w odpowiednio małym otoczeniu normalnym. W płaskim modelu $g = -\mathrm{d}t^2 + |\mathrm{d}x|^2$, po przejściu do układu spoczynkowego końców, dla $x(a) = x(b)$ mamy wprost

$$\tau(\alpha) = \int_a^b \sqrt{\dot t^2 - |\dot x|^2}\,\mathrm{d}\lambda \le \int_a^b \dot t\,\mathrm{d}\lambda = t(b) - t(a),$$

z równością dla prostej o stałym x. Taki układ spoczynkowy końców istnieje, ponieważ dla przyszłościowej krzywej czasopodobnej $\Delta t = \int_a^b \dot t\,\mathrm{d}\lambda > \int_a^b |\dot x|\,\mathrm{d}\lambda \ge |\Delta x|$. Wektor łączący końce jest więc czasopodobny. W zakrzywionej czasoprzestrzeni ten argument ma lokalną wersję. Dowód

lematu Gaussa 13.3.1 używa jedynie zgodności z metryką i braku torsji, więc działa również dla metryki lorentzowskiej. Wybieramy orientację czasu w małym otoczeniu normalnym U punktu p. Możemy je zmniejszyć tak, aby istniała współrzędna x^0 z $\mathrm{d}x^0$ dodatnią na wszystkich niezerowych przyszłościowych wektorach przyczynowych. Wystarczy wybrać taką współrzędną w p i zachować czasopodobność jej gradientu przez ciągłość.

Dlaczego przyszłościowa krzywa czasopodobna wychodząca z p i pozostająca w U leży w obrazie przyszłego stożka? Niech $Q(\exp_p v) = g_p(v,v)$ i $R_{\exp_p v} = \mathrm{d}(\exp_p)_v(v)$. Lemat Gaussa daje $\mathrm{d}Q(W) = 2g(R,W)$. Początkowo krzywa leży w przyszłym stożku, gdyż $\mathrm{d}(\exp_p)_0 = \mathrm{id}$ i jej początkowa prędkość jest czasopodobna. Gdyby po raz pierwszy doszła do niezerowego punktu jego świetlnego brzegu, mielibyśmy tam $Q = 0$ i $Q' \geq 0$. Jednak R jest wtedy niezerowym przyszłościowym wektorem światłopodobnym, zatem $Q' = 2g(R,\dot\alpha) < 0$. Ostatnia nierówność wynika w bazie lorentzowskiej z $R = (r,\xi)$, $r = |\xi| > 0$, i $\dot\alpha = (a,\eta)$, $a > |\eta|$: $-ra + \xi\cdot\eta < 0$. Powrót do wierzchołka p wyklucza ścisły wzrost x^0. Krzywa pozostaje więc w przyszłym stożku.

We wnętrzu tego stożka piszemy $v = \tau u$, gdzie $g_p(u,u) = -1$, $\tau > 0$. Ortogonalne do czasopodobnego kierunku u wektory mają dodatni kwadrat normy. Lemat Gaussa daje więc w tych współrzędnych schemat metryki $g = -\mathrm{d}\tau^2 + h_{ab}(\tau,u)\mathrm{d}u^a\mathrm{d}u^b$ z dodatnio określonym h_{ab}. Radialne pole ∂_τ jest przyszłościowe, jednostkowe i czasopodobne. Dla przyszłościowej krzywej czasopodobnej mamy więc $\dot\tau = -g(\partial_\tau,\dot\alpha) > 0$ i

$$\sqrt{-g(\dot\alpha,\dot\alpha)} = \sqrt{(\dot\tau)^2 - h_{ab}\dot u^a\dot u^b} \leq \dot\tau.$$

Całkujemy od dodatniego parametru i przechodzimy do początku krzywej, gdzie $\tau \to 0$. Dostajemy $\tau(\alpha) \leq \tau(q)$; radialna geodezyjna osiąga równość. Tym samym lokalna maksymalność dotyczy dróg mieszczących się w takim otoczeniu przy ustalonych końcach. Nie jest to twierdzenie o *minimalizowaniu* riemannowskiej odległości. Dla geodezyjnych światłopodobnych czas własny wynosi zero.

Przykład 13.7.1 (Ruch w metryce Schwarzschilda)**.** Pracujemy w obszarze $r > 2M$, $M > 0$. Z uwagi na symetrię sferyczną możemy wybrać płaszczyznę ruchu $\theta = \pi/2$: obracamy początkowe dane przestrzenne do jednej płaszczyzny przez środek. Odbicie względem niej jest izometrią zachowującą te dane, więc jednoznaczność geodezyjnej utrzymuje ruch w tej płaszczyźnie. Na geodezyjnej z parametrem afinicznym Lagrangian $\mathcal{L} = \frac12 g_{\mu\nu}\dot x^\mu\dot x^\nu$ nie zależy od t,ϕ. Równania Eulera–Lagrange'a dają więc stałe wielkości

$$E = f(r)\dot t, \qquad L = r^2\dot\phi, \qquad f(r) = 1 - \frac{2M}{r}. \tag{13.7.2}$$

Niech $g(\dot\gamma,\dot\gamma) = -\kappa$: $\kappa = 1$ dla czasopodobnej geodezyjnej parametryzowanej czasem własnym i $\kappa = 0$ dla światłopodobnej. Podstawienie $\dot t = E/f$, $\dot\phi = L/r^2$ do metryki daje

$$-\kappa = -\frac{E^2}{f} + \frac{\dot r^2}{f} + \frac{L^2}{r^2} \quad\Longleftrightarrow\quad \dot r^2 + f\left(\kappa + \frac{L^2}{r^2}\right) = E^2. \tag{13.7.3}$$

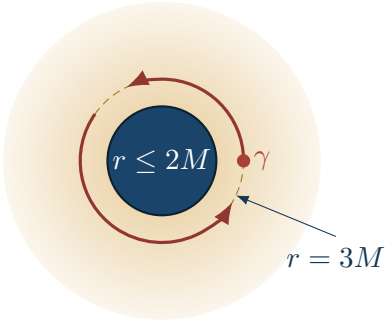
To całka pierwsza równania radialnego. W punktach zwrotnych nie wolno dzielić jej pochodnej przez $\dot r = 0$. Pełne równanie geodezyjnej, po wstawieniu symboli z (12.5.1), ma postać

$$\ddot r + \frac{ff'}{2}\dot t^2 - \frac{f'}{2f}\dot r^2 - rf\dot\phi^2 = 0.$$

Podstawiamy stałe ruchu: $\ddot r = -\frac{f'}{2f}(E^2 - \dot r^2) + fL^2/r^3$. Całka pierwsza daje $E^2 - \dot r^2 = f(\kappa + L^2/r^2)$, więc

$$\ddot r = -\tfrac12 f'\left(\kappa + \frac{L^2}{r^2}\right) + \frac{fL^2}{r^3} = -\tfrac12\frac{\mathrm{d}}{\mathrm{d}r}\left[f\left(\kappa + \frac{L^2}{r^2}\right)\right].$$

Ten wzór obowiązuje także przy $\dot r = 0$. Przy $\kappa = 0$, $L \neq 0$ stały promień orbity światłopodobnej wymaga $\dot r = 0$ i pochodnej potencjału $V(r) = L^2(1-2M/r)/r^2$ równej zeru. Ponieważ $V'(r) = 2L^2(3M-r)/r^4$, dostajemy $r = 3M$ i z (13.7.3) $E^2 = L^2/(27M^2)$. To przykład geodezyjnej, która może krążyć po sferze fotonowej; nie jest to okrąg minimalizujący długość w sensie riemannowskim.



Rysunek 13.14: Schemat rzutu na współrzędne (r,ϕ) równikowej geodezyjnej światłopodobnej Schwarzschilda o stałym $r = 3M$. Ciemny dysk oznacza $r \le 2M$ w tym rysunku współrzędnych; okrąg $r = 3M$ nie przedstawia geodezyjnej metryki indukowanej na przekroju przestrzennym.

Przykład 13.7.2 (Ruch równikowy w metryce Kerra)**.** Przyjmujemy $M > 0$, $|a| \le M$ i $r > r_+ = M + \sqrt{M^2 - a^2}$. Płaszczyzna $\theta = \pi/2$ jest niezmiennicza przez symetrię odbicia $\theta \mapsto \pi - \theta$: geodezyjna startująca na niej ze $\dot\theta = 0$ na niej pozostaje. Niech $E = -p_t$, $L = p_\phi$, gdzie $p_\mu = g_{\mu\nu}\dot x^\nu$; są to stałe, bo metryka nie zależy od t, ϕ. W tej płaszczyźnie $\Sigma = r^2$. Oznaczmy

$$A = \dot t - a\dot\phi, \qquad B = (r^2 + a^2)\dot\phi - a\dot t.$$

Z postaci (11.3.5) przez różniczkowanie Lagrangianu $\mathcal{L} = (-\Delta A^2 + B^2 + r^4\dot r^2/\Delta)/(2r^2)$ względem $\dot t, \dot\phi$ otrzymujemy

$$E = \frac{\Delta A + aB}{r^2}, \qquad L = \frac{a\Delta A + (r^2+a^2)B}{r^2}.$$

Dokładniej, $\partial_{\dot t} A = 1$, $\partial_{\dot t} B = -a$, więc $p_t = (-\Delta A - aB)/r^2$. Podobnie $\partial_{\dot\phi} A = -a$, $\partial_{\dot\phi} B = r^2 + a^2$ dają wypisane $p_\phi = L$. Odejmujemy aE od L: dostajemy $B = L - aE$, a stąd $\Delta A = P(r)$, gdzie $P(r) = E(r^2+a^2) - aL$. Warunek $g(\dot\gamma,\dot\gamma) = -\kappa$ po podstawieniu $A = P/\Delta$, $B = L - aE$ ma postać $-\kappa r^2 = -P^2/\Delta + (L-aE)^2 + r^4\dot r^2/\Delta$. Mnożymy przez $\Delta > 0$ i przenosimy składniki:

$$r^4\dot r^2 = P(r)^2 - \Delta\big(\kappa r^2 + (L-aE)^2\big), \qquad \kappa \in \{0,1\}. \tag{13.7.4}$$

Pozostałe pochodne odzyskujemy z definicji A, B. Dodanie aA do B daje $r^2\dot\phi$, a dodanie aB do $(r^2+a^2)A$ daje $r^2\dot t$. Podstawienie $A = P/\Delta$ i $B = L - aE$ daje zatem

$$r^2\dot t = \frac{r^2+a^2}{\Delta}P + a(L-aE), \qquad r^2\dot\phi = \frac{a}{\Delta}P + (L-aE). \tag{13.7.5}$$

Wzory dotyczą geodezyjnych równikowych; poza tą płaszczyzną ruch wymaga jeszcze jednej stałej związanej z kątem θ. Przy $a = 0$ równanie (13.7.4) redukuje się do (13.7.3). Także tutaj pierwsza całka radialna nie zastępuje pełnego równania geodezyjnej przy poszukiwaniu rozwiązań stałych lub przedłużaniu przez punkty zwrotne.

Dla kołowej geodezyjnej równikowej o $\Omega = \dot\phi/\dot t$ i $\dot r = 0$ radialne równanie geodezyjnej daje

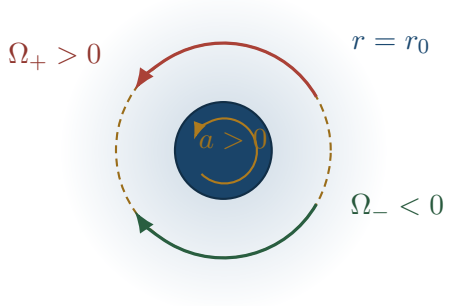
$$\partial_r g_{tt} + 2\Omega\partial_r g_{t\phi} + \Omega^2\partial_r g_{\phi\phi} = 0.$$

Istotnie, przy stałych r, θ pozostają w nim tylko $\Gamma^r_{tt}\dot t^2 + 2\Gamma^r_{t\phi}\dot t\dot\phi + \Gamma^r_{\phi\phi}\dot\phi^2 = 0$. Ponieważ metryka nie zależy od t, ϕ i nie ma składników mieszających r z tymi współrzędnymi, $\Gamma^r_{\mu\nu} = -\frac12 g^{rr}\partial_r g_{\mu\nu}$

dla $\mu,\nu\in\{t,\phi\}$. Dzielimy przez niezerowe $-\tfrac12 g^{rr}\dot r^2$ i otrzymujemy podany warunek. Na równiku $g_{tt}=-1+2M/r$, $g_{t\phi}=-2Ma/r$, $g_{\phi\phi}=r^2+a^2+2Ma^2/r$; po pomnożeniu równania przez $r^2/2$ otrzymujemy

$$-M+2Ma\Omega+(r^3-Ma^2)\Omega^2=0,\qquad \Omega_\pm=\frac{\pm\sqrt{M}}{r^{3/2}\pm a\sqrt{M}}.$$

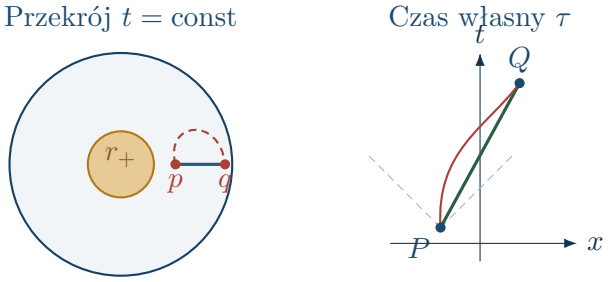
Pochodne użyte w podstawieniu to $-2M/r^2$, $2Ma/r^2$ i $2r-2Ma^2/r^2$. Wzór kwadratowy daje najpierw $\Omega_\pm=(-Ma\pm\sqrt{Mr^3})/(r^3-Ma^2)$, gdyż jedna czwarta wyróżnika wynosi $M^2a^2+M(r^3-Ma^2)=Mr^3$. Rozkład $r^3-Ma^2=(r^{3/2}-a\sqrt{M})(r^{3/2}+a\sqrt{M})$ pozwala skrócić odpowiedni czynnik w każdym z dwóch rozwiązań. W dziedzinie $r>r_+$ oba czynniki są niezerowe. To *kandydaci* na orbity kołowe: dla czasopodobnej trzeba ponadto sprawdzić $g(\partial_t+\Omega_\pm\partial_\phi,\partial_t+\Omega_\pm\partial_\phi)<0$ w rozważanym promieniu. Przy $a=0$ dostajemy $\Omega_\pm=\pm\sqrt{M/r^3}$.



Rysunek 13.15: Schemat rzutu na płaszczyznę równikową dwóch kierunków kołowej geodezyjnej Kerra przy dodatnim a i odpowiednio dużym r_0. Strzałki Ω_+ i Ω_- oznaczają ruch zgodny z obrotem i przeciwny. Ciemny obszar schematycznie zaznacza wnętrze r_+, a okrąg przerywany jest stałym r_0 we współrzędnych Boyera–Lindquista; nie jest to zanurzenie zakrzywionej czasoprzestrzeni.

Riemannowskie przekroje przestrzenne: co w nich minimalizuje?

Można osobno wybrać przekrój $t=\text{const}$ i jego *indukowaną metrykę riemannowską* h. To inny problem geometryczny niż geodezyjne pełnej czasoprzestrzeni. Rysunek 13.16 zestawia przestrzenną długość z czasem własnym; prawe okno pokazuje płaską czasoprzestrzeń, aby oddzielić te dwa rodzaje pomiaru przed obliczeniami metryk Schwarzschilda i Kerra.



Rysunek 13.16: Po lewej odcinek radialny minimalizuje długość w riemannowskim przekroju przestrzennym. Po prawej prosta czasopodobna maksymalizuje czas własny między ustalonymi zdarzeniami w płaskiej czasoprzestrzeni. Schemat nie przedstawia zanurzenia metryki Kerra.

W zewnętrznym obszarze Schwarzschilda

$$h_{\mathrm{Sch}}=f^{-1}\mathrm{d}r^2+r^2(\mathrm{d}\theta^2+\sin^2\theta\,\mathrm{d}\phi^2).$$

Na równiku krzywa o stałych $\theta = \pi/2$ i ϕ oraz zmiennym r ma długość

$$\ell_{\mathrm{Sch}}(r_0, r_1) = \left| \int_{r_0}^{r_1} \frac{\mathrm{d}r}{\sqrt{1 - 2M/r}} \right|. \tag{13.7.6}$$

Dowolna droga $\alpha : [a, b] \to \{t = \text{const}\}$ w tym przekroju między punktami o promieniach r_0, r_1 i tych samych kątach spełnia

$$L_h(\alpha) \geq \int_a^b \frac{|\dot r(s)|}{\sqrt{f(r(s))}}\,\mathrm{d}s \geq \left| \int_a^b \frac{\dot r(s)}{\sqrt{f(r(s))}}\,\mathrm{d}s \right| = \left| \int_{r_0}^{r_1} \frac{\mathrm{d}u}{\sqrt{f(u)}} \right| = \ell_{\mathrm{Sch}}(r_0, r_1).$$

Ostatnia zmiana granic nie zakłada monotoniczności $r(s)$: funkcja $S(r) = \int_{r_0}^{r} \mathrm{d}u/\sqrt{f(u)}$ spełnia $(S \circ r)' = \dot r/\sqrt{f(r)}$, więc całka po s jest różnicą $S(r_1) - S(r_0)$. Monotoniczna krzywa radialna osiąga wszystkie równości.

Dla Kerra na $t = \text{const}$ i $\theta = \pi/2$ składowe metryki indukowanej wynoszą

$$h_{rr} = \frac{r^2}{\Delta}, \qquad h_{\phi\phi} = r^2 + a^2 + \frac{2Ma^2}{r}.$$

Stąd radialna długość ma wzór

$$\ell_{\mathrm{K}}(r_0, r_1) = \left| \int_{r_0}^{r_1} \frac{r}{\sqrt{\Delta}}\,\mathrm{d}r \right|. \tag{13.7.7}$$

Ta droga też jest najkrótsza w *tym przekroju* między równikowymi punktami o tych samych kątach: dla dowolnej drogi $\Sigma \geq r^2$ i $h_{rr} = \Sigma/\Delta$, zatem $|\dot\alpha|_h \geq r|\dot r|/\sqrt{\Delta}$. Po scałkowaniu dostajemy dolne ograniczenie (13.7.7), osiągane przez krzywą radialną na równiku. Wobec Wniosku 13.1.4 obie radialne krzywe, po parametryzacji długością łuku, są geodezyjnymi swoich *przestrzennych* metryk h.

Te zewnętrzne przekroje $r > r_+$ nie są automatycznie zupełne. Dla Schwarzschilda całka (13.7.6) do pominiętego brzegu $r = 2M$ jest skończona. Dla Kerra o $|a| < M$ mamy $\Delta = (r - r_+)(r - r_-)$, $r_- < r_+$, więc całka (13.7.7) do r_+ również jest skończona. W przypadku Schwarzschilda $f^{-1/2} = \sqrt{r}/\sqrt{r - 2M}$; w przypadku Kerra $r/\sqrt{\Delta} = (r/\sqrt{r - r_-})/\sqrt{r - r_+}$. W obu przypadkach czynnik w liczniku ostatniego ilorazu jest ograniczony przez pewne C na dostatecznie małym przedziale $r_+ < r < r_+ + \delta$. Całkę do horyzontu ogranicza więc $C \int_{r_+}^{r_+ + \delta} (r - r_+)^{-1/2}\,\mathrm{d}r = 2C\sqrt{\delta} < \infty$ (jest to całka niewłaściwa). Horyzont nie należy do opisywanego przekroju; ciąg punktów na ustalonym promieniu równikowym, z $r \downarrow r_+$, jest w nim ciągiem Cauchy'ego bez granicy. Nie przeczy to Hopfowi–Rinowowi, ponieważ jego hipoteza zupełności tutaj nie zachodzi. Przypadek ekstremalny $|a| = M$ ma inne zachowanie: wtedy $\Delta = (r - M)^2$, a całka radialna zawiera $r/(r - M) = 1 + M/(r - M)$. Istotnie, przy ustalonym $R > M$ mamy

$$\int_r^R \frac{u}{u - M}\,\mathrm{d}u = R - r + M \log \frac{R - M}{r - M} \longrightarrow \infty \quad (r \downarrow M).$$

To wynika z całkowania $1 + M/(u - M)$. Poprzedni argument o skończonej odległości do pominiętego horyzontu nie obejmuje tego przypadku.

13.8 Geodezyjne modelu FLRW

Przykład 13.8.1 (geodezyjne czasowe i świetlne w modelu FLRW)**.** Niech $\gamma(s) = (t(s), \mathbf{x}(s))$ będzie afinicznie sparametryzowaną geodezyjną metryki (11.3.6); apostrof oznacza pochodną po s. Podstawiając (12.3.2) do równania geodezyjnej otrzymujemy układ równań różniczkowych zwyczajnych

$$t'' + a\dot a \sum_{i=1}^{3} (x^{i\prime})^2 = 0, \qquad x^{i\prime\prime} + 2H(t) t' x^{i\prime} = 0 \quad (i = 1, 2, 3). \tag{13.8.1}$$

Drugie równanie mnożymy przez $a(t)^2$. Reguła iloczynu daje $\frac{\mathrm{d}}{\mathrm{d}s}(a(t)^2 x^{i\prime}) = 2a\dot{a}\,t' x^{i\prime} + a^2 x^{i\prime\prime} = a^2(x^{i\prime\prime} + 2Ht' x^{i\prime}) = 0$. Zatem mamy całkę pierwszą

$$\frac{\mathrm{d}}{\mathrm{d}s}(a(t)^2 x^{i\prime}) = 0, \qquad a(t)^2 x^{i\prime} = P^i, \tag{13.8.2}$$

gdzie P^i są stałymi. Zatem problem geodezyjny redukuje się do jednego równania dla t i kwadratur dla x^i. Dla geodezyjnej przyszłościowo skierowanej, spełniającej $g(\gamma',\gamma') = -\varepsilon$, gdzie $\varepsilon = 1$ w przypadku czasowym (parametr s jest czasem własnym) i $\varepsilon = 0$ w przypadku zerowym, otrzymujemy poniższe wzory. W przypadku świetlnym wymagamy $P \neq 0$, co zapewnia $t' > 0$. Podstawienie $x^{i\prime} = P^i/a^2$ do warunku normalizacji daje $-\varepsilon = -(t')^2 + a^2\sum_i (P^i/a^2)^2 = -(t')^2 + |P|^2/a^2$. Wybieramy dodatni pierwiastek, bo geodezyjna jest przyszłościowa, a następnie dzielimy $x^{i\prime}$ przez t':

$$t' = \sqrt{\varepsilon + \frac{|P|^2}{a(t)^2}}, \qquad \frac{\mathrm{d}x^i}{\mathrm{d}t} = \frac{P^i}{a(t)^2\sqrt{\varepsilon + |P|^2/a(t)^2}}, \qquad |P|^2 = \sum_i (P^i)^2. \tag{13.8.3}$$

Dla $P = 0$ i $\varepsilon = 1$ otrzymujemy $\gamma(t) = (t, \mathbf{x}_0)$: obserwatorzy o stałych współrzędnych przestrzennych poruszają się po geodezyjnych czasowych, a t jest ich czasem własnym.

Dla geodezyjnej świetlnej $P \neq 0$ wzór upraszcza się do $\mathrm{d}\mathbf{x}/\mathrm{d}t = \mathbf{n}/a(t)$, gdzie $\mathbf{n} = P/|P|$ jest jednostkowym kierunkiem. Przy $a(t) = (t/t_*)^{2/3}$, $t_* > 0$, dla chwil t_e, t w dziedzinie modelu mamy $\int_{t_e}^{t} \mathrm{d}u/a(u) = t_*^{2/3}\int_{t_e}^{t} u^{-2/3}\,\mathrm{d}u = 3t_*^{2/3}(t^{1/3} - t_e^{1/3})$. Całkowanie równania przestrzennego daje zatem

$$\mathbf{x}(t) = \mathbf{x}(t_e) + 3t_*^{2/3}(t^{1/3} - t_e^{1/3})\mathbf{n}. \tag{13.8.4}$$

Parametr afiniczny odzyskujemy z $t' = |P|/a(t)$: stąd $\mathrm{d}s/\mathrm{d}t = a(t)/|P|$ i

$$s(t) - s(t_e) = \frac{1}{|P|t_*^{2/3}}\int_{t_e}^{t} u^{2/3}\,\mathrm{d}u = \frac{3}{5|P|t_*^{2/3}}(t^{5/3} - t_e^{5/3}).$$

Wzór (13.8.4) opisuje więc tor promienia w przestrzennych współrzędnych współporuszających się. Czas t nie jest dla tego zmiennego $a(t)$ parametrem afinicznym.

Przykład 13.8.2 (odchylenie geodezyjnych i rozszerzanie się przestrzeni)**.** Dla obserwatorów współporuszających się pole prędkości wynosi $U = \partial_t$. Dwie bliskie geodezyjne rozdziela pole Jacobiego $J = \sum_i v^i\partial_i$ o stałych współczynnikach v^i: otrzymujemy je, różniczkując po u rodzinę $\gamma_u(t) = (t, \mathbf{x}_0 + u\mathbf{v})$ przy $u = 0$. Ogólną definicję pola Jacobiego podamy w Sekcji 14.11. Z (12.3.2) mamy $\nabla_U J = HJ$ i $\nabla_U\nabla_U J = (\dot{H} + H^2)J = (\ddot{a}/a)J$. Pierwsza równość używa stałości v^i oraz $\nabla_{\partial_t}\partial_i = H\partial_i$. Następna wynika z reguły iloczynu $\nabla_U(HJ) = \dot{H}J + H\nabla_U J$ i tożsamości $\dot{H} = (a\ddot{a} - \dot{a}^2)/a^2$. Ponieważ $\nabla_U U = 0$, $\nabla_J U = HJ$ i $[J,U] = 0$, definicja (14.1.1) daje również $R(J,U)U = -\nabla_U(HJ) = -(\dot{H} + H^2)J = -(\ddot{a}/a)J$. Zatem $\nabla_U\nabla_U J + R(J,U)U = 0$, zgodnie z równaniem Jacobiego. Długość pola wynosi $|J|_g = a(t)|v|$ i spełnia

$$\frac{\mathrm{d}^2}{\mathrm{d}t^2}|J|_g = \frac{\ddot{a}}{a}|J|_g.$$

Dla $\ddot{a} < 0$ odległość nadal może rosnąć, ale tempo jej wzrostu maleje. Równanie to wyraża wpływ krzywizny czasoprzestrzeni na względny ruch swobodnych obserwatorów.

Dalsza lektura: D. Spiegel, *The Hopf–Rinow Theorem*, §4.3, E. Meinrenken, *Riemannian Geometry*, §16, geodezyjne w modelach hiperbolicznych, orbity Schwarzschilda w notatkach MIT, metryka Kerra.

Rozdział 14

Krzywizna: od transportu równoległego do tensorów

Co właściwie znaczy, że przestrzeń jest zakrzywiona? Możemy wykonać pomiary *wewnątrz* niej: poprowadzić geodezyjne (odpowiedniki prostych), zmierzyć obwód małego okręgu albo przenieść wektor wzdłuż zamkniętej drogi. Na płaszczyźnie mały okrąg o promieniu r ma obwód $2\pi r$, a wektor po obejściu pętli wraca bez obrotu. Na sferze obwód jest mniejszy, a na płaszczyźnie hiperbolicznej większy; transport po pętli może obrócić wektor. *Krzywizna* opisuje właśnie te odchylenia od geometrii euklidesowej. Bardzo małe otoczenie każdego punktu wygląda w pierwszym przybliżeniu płasko; krzywizna ujawnia się w kolejnych wyrazach rachunku dla małych odległości.

Nie chodzi o samo wygięcie w większej przestrzeni. Mały fragment walca w $\mathbb{R}^3$ można rozwinąć na płaszczyznę bez rozciągania, więc jego wewnętrzna krzywizna jest zerowa. Definicja przez metrykę i koneksję ma sens także wtedy, gdy nie przedstawiamy rozmaitości jako powierzchni zanurzonej w $\mathbb{R}^3$.

W rozdziale o koneksjach porównywaliśmy wektory w różnych punktach za pomocą transportu równoległego. Pytanie, czy wynik zależy od drogi, prowadzi do tensora Riemanna: pełnego opisu krzywizny w punkcie. Krzywizna sekcyjna bada jedną wybraną płaszczyznę styczną; na powierzchni jest to krzywizna Gaussa. Tensor Ricciego sumuje krzywizny płaszczyzn zawierających wybrany kierunek, a krzywizna skalarna zbiera informację ze wszystkich kierunków. Poniżej pokażemy, co te sumy mówią o objętości małych obszarów.

Przez większość rozdziału (M, g) jest rozmaitością *riemannowską*, a ∇ jej koneksją Leviego-Civity z Twierdzenia 12.2.1. Domyślnie rozmaitości nie mają brzegu; powierzchnie z brzegiem i narożnikami wprowadzimy osobno przy twierdzeniu Gaussa–Bonneta. W przykładach Minkowskiego, FLRW, Schwarzschilda i Kerra g ma sygnaturę lorentzowską. Te same wzory tensorowe nadal obowiązują, lecz wtedy nie każda płaszczyzna ma określoną krzywiznę sekcyjną, a ślad z metryką zawiera znaki ujemne.

14.1 Co mierzy krzywizna? Tensor Riemanna

Definicja 14.1.1 (konwencja znaku)**.** Niech X, Y, Z będą polami wektorowymi. Definiujemy

$$R(X,Y)Z = \nabla_X \nabla_Y Z - \nabla_Y \nabla_X Z - \nabla_{[X,Y]} Z, \qquad \mathcal{R}(X,Y,Z,W) = g(R(X,Y)Z, W). \tag{14.1.1}$$

Symbol R nazywamy *operatorem krzywizny*, a $\mathcal{R}$ *tensorem Riemanna* o wszystkich indeksach opuszczonych. Ta konwencja daje dodatnią krzywiznę sekcyjną zwykłej sfery. W literaturze spotyka się także przeciwny znak R; przy porównywaniu wzorów trzeba zawsze sprawdzić definicję.

Pierwsze dwa składniki mierzą różnicę między różniczkowaniem najpierw w kierunku Y, a potem X, oraz w przeciwnej kolejności. Człon $\nabla_{[X,Y]}Z$ usuwa różnicę pochodzącą tylko z tego, że same pola X, Y nie muszą komutować. W efekcie $R(X,Y)Z$ zależy *wyłącznie* od wartości X, Y, Z w danym punkcie.

Stwierdzenie 14.1.2 (tensorowość i współrzędne)**.** *Wyrażenie R jest liniowe nad $C^\infty(M)$ w każdym z trzech argumentów. Jeżeli $\nabla_{\partial_i}\partial_j = \Gamma^a_{ij}\partial_a$, to przy umowie $R(\partial_i,\partial_j)\partial_b = R^a{}_{bij}\partial_a$ mamy*

$$R^a{}_{bij} = \partial_i\Gamma^a_{jb} - \partial_j\Gamma^a_{ib} + \Gamma^a_{ic}\Gamma^c_{jb} - \Gamma^a_{jc}\Gamma^c_{ib}. \tag{14.1.2}$$

W szczególności tensor krzywizny zawiera pochodne współczynników koneksji, a więc drugie pochodne metryki.

Dowód. Dla dowolnej funkcji f reguły koneksji i nawiasu dają $\nabla_{fX}Y = f\nabla_X Y$ oraz $[fX,Y] = f[X,Y] - Y(f)X$. Zatem

$$\begin{aligned} R(fX,Y)Z &= f\nabla_X\nabla_Y Z - \nabla_Y(f\nabla_X Z) - \nabla_{f[X,Y]-Y(f)X}Z \\ &= fR(X,Y)Z - Y(f)\nabla_X Z + Y(f)\nabla_X Z = fR(X,Y)Z. \end{aligned}$$

Antysymetria $R(X,Y) = -R(Y,X)$ daje to samo w drugim argumencie. W trzecim argumencie rozwińmy $\nabla_Y(fZ) = Y(f)Z + f\nabla_Y Z$ i odpowiedni wyraz z zamienionymi X, Y. Składniki zawierające pochodne samego Z znoszą się parami, natomiast pozostały współczynnik przy Z wynosi $X(Yf) - Y(Xf) - [X,Y]f = 0$. Dlatego $R(X,Y)(fZ) = fR(X,Y)Z$.

Ponieważ $[\partial_i,\partial_j] = 0$, wstawiamy pola współrzędnych do (14.1.1):

$$\nabla_{\partial_i}(\Gamma^c_{jb}\partial_c) = (\partial_i\Gamma^a_{jb} + \Gamma^c_{jb}\Gamma^a_{ic})\partial_a.$$

Po odjęciu wyrażenia z i, j zamienionymi miejscami otrzymujemy (14.1.2). □

Uwaga 14.1.3 (mały obwód i transport). Wybierzmy współrzędne normalne x z $x(p) = 0$ i niezależne $X_p, Y_p \in T_pM$. W rachunku piszemy krótko $X = X_p$, $Y = Y_p$, a T_pM utożsamiamy z $\mathbb{R}^n$ przez bazę tych współrzędnych. Dla małego $\varepsilon > 0$ niech $\xi_\varepsilon : [0,4] \to T_pM$ przebiega kolejno odcinki łączące $0, \varepsilon X, \varepsilon(X+Y), \varepsilon Y, 0$. Na każdy bok przeznaczamy jedną jednostkę parametru i poruszamy się po nim liniowo. Określamy zamkniętą pętlę $\gamma_\varepsilon = \exp_p \circ \xi_\varepsilon$; właśnie $\xi_\varepsilon = x \circ \gamma_\varepsilon$ jest jej zapisem we współrzędnych normalnych. Początek i koniec pętli to p. Transport w podanej kolejności oznaczamy przez $P_\varepsilon : T_pM \to T_pM$. Wykażemy, że dla ustalonego $v \in T_pM$

$$P_\varepsilon v = v - \varepsilon^2 R(X_p, Y_p)v + O(\varepsilon^3).$$

Krok 1: skąd bierze się całka. Niech $V(s)$ będzie kolumną współczynników wektora transportowanego równolegle wzdłuż γ_ε, w bazie współrzędnych przy $\gamma_\varepsilon(s)$. W szczególności $V(0) = v$ i $V(4) = P_\varepsilon v$, przy zapisie obu wektorów w tej samej bazie w p. Jeśli $\Gamma_i = (\Gamma^a_{ib})_{a,b}$, to równanie transportu (12.4.4) daje na każdym boku

$$\frac{\mathrm{d}V}{\mathrm{d}s} = -\sum_{i=1}^{n} \Gamma_i(\xi_\varepsilon(s))\,\dot\xi^i_\varepsilon(s) V(s).$$

Całkujemy to równanie po każdym z przedziałów $[0,1]$, $[1,2]$, $[2,3]$, $[3,4]$ i dodajemy wyniki. Wartości $V(1), V(2), V(3)$ znoszą się, a twierdzenie podstawowe rachunku całkowego daje dokładną równość

$$P_\varepsilon v - v = -\int_0^4 \sum_{i=1}^{n} \Gamma_i(\xi_\varepsilon(s))\,\dot\xi^i_\varepsilon(s) V(s)\,\mathrm{d}s.$$

Całka sumuje więc zmiany współczynników wektora w trakcie całego obiegu pętli.

Skrócony zapis tej samej dziedziny całkowania otrzymujemy przez macierzową 1-formę $\mathsf{A} = \sum_{i=1}^{n} \Gamma_i(x)\,\mathrm{d}x^i$ w ustalonej ramie współrzędnych. Z definicji całki po krzywej

$$\oint_{\gamma_\varepsilon} \mathsf{A} := \int_0^4 \sum_{i=1}^{n} \Gamma_i(\xi_\varepsilon(s))\,\dot{\xi}^i_\varepsilon(s)\,\mathrm{d}s.$$

Każdy wyraz macierzy całkujemy osobno. Indeks γ_ε wskazuje całą zorientowaną pętlę, a prawa strona podaje jej parametr i granice.

Krok 2: dlaczego w głównym wyrazie wolno zastąpić $V(s)$ przez v. Współrzędne normalne dają $\Gamma_i(0) = 0$. Na każdym boku mamy $\xi_\varepsilon = O(\varepsilon)$ i $\dot{\xi}_\varepsilon = O(\varepsilon)$, zatem $\sum_i \Gamma_i(\xi_\varepsilon)\dot{\xi}^i_\varepsilon = O(\varepsilon^2)$. Transport zachowuje normę metryczną, a metryka w tym małym otoczeniu jest jednostajnie porównywalna z euklidesową. Współczynniki $V(s)$ są więc ograniczone niezależnie od ε. Całkując równanie transportu od 0 do dowolnego $s \in [0,4]$, otrzymujemy $V(s) - v = O(\varepsilon^2)$ jednostajnie w s. Zastąpienie $V(s)$ przez v zmienia zatem całkę o $O(\varepsilon^2)O(\varepsilon^2) = O(\varepsilon^4)$, bo przedział parametru ma stałą długość 4:

$$P_\varepsilon v - v = -\left(\oint_{\gamma_\varepsilon} \mathsf{A}\right) v + O(\varepsilon^4).$$

Krok 3: obliczenie całki po czterech bokach. Dla $B \in \{X, Y\}$ oznaczmy $\Gamma_B(x) = \sum_i B^i \Gamma_i(x)$, a dla $A, B \in \{X, Y\}$ połóżmy $C_{AB} = (\partial_A \Gamma_B)(0)$, gdzie $\partial_A = \sum_j A^j \partial_j$. Rozwinięcie Taylora w zerze daje $\Gamma_B(\varepsilon(aX + bY)) = \varepsilon(aC_{XB} + bC_{YB}) + O(\varepsilon^2)$. Niech $\gamma_{\varepsilon,k}$ oznacza obcięcie γ_ε do $[k, k+1]$. Dla $0 \le u \le 1$ dostajemy następujące cztery wkłady:

k	$\xi_\varepsilon(k+u)$	$\displaystyle\int_{\gamma_{\varepsilon,k}} \mathsf{A}$
0	$\varepsilon u X$	$\dfrac{\varepsilon^2}{2} C_{XX} + O(\varepsilon^3)$
1	$\varepsilon(X + uY)$	$\varepsilon^2(C_{XY} + \frac{1}{2}C_{YY}) + O(\varepsilon^3)$
2	$\varepsilon((1-u)X + Y)$	$-\varepsilon^2(\frac{1}{2}C_{XX} + C_{YX}) + O(\varepsilon^3)$
3	$\varepsilon(1-u)Y$	$-\dfrac{\varepsilon^2}{2} C_{YY} + O(\varepsilon^3)$

Na przykład na drugim boku prędkość współrzędna wynosi εY, więc

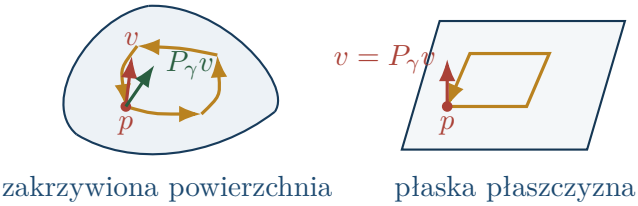
$$\begin{aligned}\int_{\gamma_{\varepsilon,1}} \mathsf{A} &= \varepsilon \int_0^1 \Gamma_Y(\varepsilon(X + uY))\,\mathrm{d}u \\ &= \varepsilon^2 \int_0^1 (C_{XY} + uC_{YY})\,\mathrm{d}u + O(\varepsilon^3) \\ &= \varepsilon^2(C_{XY} + \tfrac{1}{2}C_{YY}) + O(\varepsilon^3).\end{aligned}$$

Reszta Taylora jest rzędu ε^2, a czynnik prędkości wnosi jeszcze ε; stąd błąd $O(\varepsilon^3)$ w każdym wierszu tabeli. Po dodaniu wkładów pierwszego i trzeciego boku znoszą się wyrazy z C_{XX}, a z drugiego i czwartego wyrazy z C_{YY}. Zostaje

$$\oint_{\gamma_\varepsilon} \mathsf{A} = \varepsilon^2(C_{XY} - C_{YX}) + O(\varepsilon^3) = \varepsilon^2(\partial_X \Gamma_Y - \partial_Y \Gamma_X)_p + O(\varepsilon^3).$$

Ze wzoru (14.1.2) macierz $R_p(X, Y)$ to $(\partial_X \Gamma_Y - \partial_Y \Gamma_X + \Gamma_X \Gamma_Y - \Gamma_Y \Gamma_X)_p$. W p obie macierze Γ_X, Γ_Y są zerowe, więc jest to dokładnie $C_{XY} - C_{YX}$. Podstawienie do wyniku Kroku 2 dowodzi podanego wzoru na $P_\varepsilon v - v$, wraz ze znakiem minus. Odwrócenie obiegu pętli zmienia znak całki i głównego wyrazu.

Równoległobok w T_pM ma pole $\varepsilon^2 |X_p \wedge Y_p|$; jego obraz w M ma takie samo pole w głównym rzędzie. Aby mówić o zmianie *na jednostkę pola*, dzielimy więc $P_\varepsilon v - v$ przez $\varepsilon^2 |X_p \wedge Y_p|$ i przechodzimy z ε do zera. Dla pary ortonormalnej $|X_p \wedge Y_p| = 1$. Samo $\Gamma^a_{ij} \neq 0$ nie świadczy o krzywiźnie: we współrzędnych biegunowych płaskiej płaszczyzny symbole Christoffela są niezerowe, ale wszystkie składniki R znikają.



Rysunek 14.1: Transport wektora wzdłuż małej pętli. Na zakrzywionej powierzchni wektor może wrócić obrócony; na płaszczyźnie euklidesowej wraca w tej samej postaci. Strzałki i pętla są schematyczne.

14.2 Symetrie tensora i krzywizna sekcyjna

Twierdzenie 14.2.1 (symetrie i pierwsza tożsamość Bianchiego)**.** *Dla koneksji Leviego-Civity zachodzą*

$$\begin{aligned} \mathcal{R}(X,Y,Z,W) &= -\mathcal{R}(Y,X,Z,W) = -\mathcal{R}(X,Y,W,Z), \\ \mathcal{R}(X,Y,Z,W) &= \mathcal{R}(Z,W,X,Y), \\ R(X,Y)Z + R(Y,Z)X + R(Z,X)Y &= 0. \end{aligned} \tag{14.2.1}$$

Ostatnia równość to pierwsza tożsamość Bianchiego.

Dowód. Antysymetria w X, Y wynika wprost z definicji. Pozostałe tożsamości są punktowe, więc wolno obliczyć je w wygodnych współrzędnych. Wybierzmy współrzędne normalne w punkcie p: $\Gamma^a_{ij}(p) = 0$ i $\partial_k g_{ij}(p) = 0$. Znikanie pierwszych pochodnych metryki wynika tu ze zgodności $\nabla g = 0$ i $\Gamma(p) = 0$. Korzystając ze wzoru na symbole Christoffela (12.3.1) oraz (14.1.2), dostajemy w p

$$\begin{aligned} \mathcal{R}_{ijkl} := \mathcal{R}(\partial_i,\partial_j,\partial_k,\partial_l) = \frac{1}{2}(&\partial_i\partial_k g_{jl} - \partial_i\partial_l g_{jk} \\ &- \partial_j\partial_k g_{il} + \partial_j\partial_l g_{ik})(p). \end{aligned} \tag{14.2.2}$$

Wyrazy kwadratowe w Γ znikają w p. Pierwszą i ostatnią parę indeksów można zamienić miejscami, bo pochodne mieszane komutują i $g_{ij} = g_{ji}$. Zamiana indeksów wewnątrz którejkolwiek pary zmienia znak. Wreszcie po dodaniu wzoru (14.2.2) dla trójek (i,j,k), (j,k,i) i (k,i,j) każdy składnik drugich pochodnych znosi się z innym. To daje tożsamość Bianchiego po sparowaniu z dowolnym W. Tensorowość pozwala przenieść wynik z bazy współrzędnych na dowolne wektory i dowolny punkt. □

Definicja 14.2.2 (krzywizna sekcyjna)**.** Niech $\sigma \subset T_pM$ będzie dwuwymiarową płaszczyzną z bazą u, v. W przypadku riemannowskim

$$K_p(\sigma) = \frac{g(R(u,v)v,u)}{|u|^2|v|^2 - g(u,v)^2} = \frac{\mathcal{R}(u,v,v,u)}{|u\wedge v|^2}. \tag{14.2.3}$$

Mianownik jest kwadratem pola równoległoboku rozpiętego przez u, v. Dla ortonormalnej bazy u, v po prostu $K_p(\sigma) = g(R(u,v)v,u)$. W sygnaturze lorentzowskiej ten sam iloraz określamy tylko dla płaszczyzn *niezdegenerowanych*, czyli gdy wyznacznik macierzy Grama w mianowniku jest różny od zera.

Dlaczego wzór nie zależy od wybranej bazy. Przy zmianie bazy płaszczyzny macierzą A licznik zmienia się przez czynnik $(\det A)^2$. Wynika to z dwuliniowości i antysymetrii tensora $\mathcal{R}$ osobno w dwóch parach argumentów: każda para działa jak pole zorientowanego równoległoboku. Mianownik jest wyznacznikiem macierzy Grama, która przechodzi w $A^{\mathsf{T}}GA$, więc także mnoży się przez $(\det A)^2$. Iloraz jest zatem własnością samej płaszczyzny. □

Uwaga 14.2.3 (intuicja). Krzywizna sekcyjna bada, jak geometria zachowuje się w wybranych *dwóch* kierunkach stycznych. Na sferze geodezyjne wychodzące z punktu zwykle zbliżają się względem modelu płaskiego; w przestrzeni hiperbolicznej rozchodzą się szybciej. W przestrzeni o wymiarze $n \geq 3$ różne płaszczyzny przez ten sam punkt mogą mieć różne krzywizny. Krzywizna powierzchni ma tylko jedną taką płaszczyznę, czyli całe T_pM.

14.3 Krzywizna Gaussa i Theorema Egregium

Dla powierzchni $M^2 \subset \mathbb{R}^3$ można najpierw pomyśleć o tym, jak wygina się ona w przestrzeni. Nie jest to jednak to samo co krzywizna wynikająca z pomiarów długości *na samej powierzchni*. Walec wygina się w $\mathbb{R}^3$, ale można go rozwinąć na płaszczyźnie bez rozciągania.

Wyobraźmy sobie okrąg złożony z punktów odległych o tę samą małą *długość geodezyjną* r od p. W trzech modelach jego obwód jest odpowiednio

$K = R^{-2}$ na S^2_R	$K = 0$ na $\mathbb{R}^2$	$K = -1$ na $\mathbb{H}^2$
$2\pi R \sin(r/R)$	$2\pi r$	$2\pi \sinh r$

(na sferze bierzemy $r < \pi R$). Pierwszy obwód jest mniejszy od $2\pi r$, trzeci większy. Dla dowolnej gładkiej powierzchni zachodzi przy $r \downarrow 0$

$$L_p(r) = 2\pi r \left(1 - \frac{K(p)}{6} r^2 + O(r^3)\right). \tag{14.3.1}$$

Tak można *zmierzyć* znak i wartość $K(p)$ bez oglądania powierzchni z zewnątrz. Wzór wynika z równania pól Jacobiego wzdłuż promieni; wyprowadzimy jego odpowiednik dla objętości w Sekcji 14.4 i uzasadnimy równanie Jacobiego w Sekcji 14.11. Wymiar K to odwrotność kwadratu długości: po powiększeniu promienia dwa razy poprawka względna w (14.3.1) rośnie w przybliżeniu czterokrotnie.

Definicja 14.3.1 (druga forma podstawowa)**.** Niech $F : U \subset \mathbb{R}^2 \to \mathbb{R}^3$ będzie regularną parametryzacją powierzchni, n lokalnie wybranym jednostkowym wektorem normalnym, a D zwykłą pochodną w $\mathbb{R}^3$. Dla pól stycznych X, Y definiujemy

$$\mathrm{II}(X, Y) = \langle D_X Y, n \rangle, \qquad D_X n = -SX.$$

Operator S jest operatorem kształtu. Z równości $X\langle n, Y\rangle = 0$ wynika $\mathrm{II}(X,Y) = g(SX, Y)$; z braku torsji D wynika symetria II. Wartości własne S to krzywizny główne k_1, k_2, a ich iloczyn $K_{\mathrm{G}} = \det S = k_1 k_2$ to *krzywizna Gaussa*. Zmiana n na $-n$ zmienia znaki obu k_i, ale nie zmienia ich iloczynu.

Twierdzenie 14.3.2 (Gauss; Theorema Egregium)**.** *Dla powierzchni z metryką indukowaną z* $\mathbb{R}^3$ *krzywizna Gaussa równa się krzywiźnie sekcyjnej:*

$$K_{\mathrm{G}}(p) = K_p(T_pM) = \frac{\mathrm{II}_{11}\mathrm{II}_{22} - \mathrm{II}_{12}^2}{g_{11}g_{22} - g_{12}^2}. \tag{14.3.2}$$

W szczególności K_{G} *można wyznaczyć* wyłącznie z metryki g*: lokalna izometria powierzchni zachowuje krzywiznę Gaussa.*

Dowód. Rozłóżmy pochodną otaczającą na część styczną i normalną. Zgodnie ze Stwierdzeniem 12.2.2 część styczna jest koneksją Leviego-Civity metryki indukowanej, więc

$$D_X Y = \nabla_X Y + \mathrm{II}(X, Y) n, \qquad D_X n = -SX. \tag{14.3.3}$$

Pochodna D w $\mathbb{R}^3$ ma zerową krzywiznę. Policzmy część styczną równości $D_X D_Y Z - D_Y D_X Z - D_{[X,Y]}Z = 0$. Pierwszy składnik na podstawie (14.3.3) daje

$$(D_X D_Y Z)^\top = \nabla_X \nabla_Y Z - \mathrm{II}(Y,Z)SX.$$

Występuje tu minus: różniczkując składnik normalny $\mathrm{II}(Y,Z)n$, bierzemy jego część styczną $\mathrm{II}(Y,Z)D_X n$. Po odjęciu analogicznego wyrazu z X, Y zamienionymi otrzymujemy *równanie Gaussa*

$$R(X,Y)Z = \mathrm{II}(Y,Z)SX - \mathrm{II}(X,Z)SY. \tag{14.3.4}$$

Wybierzmy ortonormalną bazę e_1, e_2 płaszczyzny stycznej. Podstawiając $X = e_1$, $Y = Z = e_2$ i biorąc iloczyn skalarny z e_1, znajdujemy

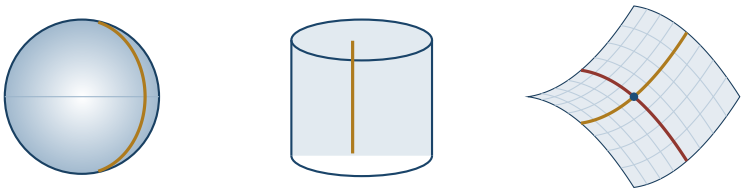
$$g(R(e_1,e_2)e_2, e_1) = \mathrm{II}_{22}\mathrm{II}_{11} - \mathrm{II}_{12}\mathrm{II}_{21} = \det S.$$

To jest pierwszy wzór (14.3.2). Dla bazy współrzędnych F_1, F_2 licznik zamienia się w wyznacznik macierzy II, a mianownik jest wyznacznikiem macierzy g; otrzymujemy drugi wzór. Wreszcie lewa strona (14.3.2) jest ilorazem z definicji 14.2.2, a tensor R oblicza się z samej metryki przez (12.3.1) i (14.1.2). Jeśli F jest lokalną izometrią dwóch powierzchni, przenosi metrykę, jej koneksję Leviego-Civity (jednoznaczność) i R; przenosi zatem również K. To właśnie niezwykły, *wewnętrzny* charakter krzywizny Gaussa stwierdza Theorema Egregium. □

Przykład 14.3.3 (płaszczyzna, walec, sfera i siodło)**.** Na płaszczyźnie euklidesowej $K = 0$. Walec o promieniu $a > 0$ ma lokalną parametryzację

$$F(u,v) = (a\cos(u/a), a\sin(u/a), v), \qquad F^* g_{\mathbb{R}^3} = \mathrm{d}u^2 + \mathrm{d}v^2.$$

Wobec twierdzenia $K = 0$, choć walec jest zgięty w przestrzeni otaczającej. Jego krzywizny główne to $\pm 1/a$ (zależnie od wyboru normalnej) i 0. Sfera o promieniu a ma $S = \pm a^{-1}\mathrm{Id}$, stąd $K = a^{-2} > 0$. Dla wykresu $z = (x^2 - y^2)/2$ w punkcie $(0,0,0)$ pierwsza forma podstawowa jest jednostkowa, a druga ma, zależnie od normalnej, macierz $\mathrm{diag}(1,-1)$. Dlatego $K(0) = -1$. Znaki dodatni, zerowy i ujemny opisują więc różne zachowanie *metryki*, nie sam fakt widocznego zgięcia w $\mathbb{R}^3$.



$K > 0$ sfera $K = 0$ walec $K < 0$ siodło

Rysunek 14.2: Sfera ma dodatnią, walec zerową, a siodło ujemną krzywiznę Gaussa. Złoty łuk na sferze jest rzutem łuku wielkiego okręgu. Na siodle $z = (x^2 - y^2)/2$ wyróżniono przekroje $y = 0$ i $x = 0$; spotykają się w zaznaczonym punkcie, w którym $K = -1$. Wartości K wynikają z metryk tych powierzchni.

14.4 Ricci, krzywizna skalarna i przykłady modelowe

Definicja 14.4.1 (dwa ślady krzywizny)**.** *Tensor Ricciego* jest śladem odwzorowania $W \mapsto R(W,U)V$:

$$\mathrm{Ric}(U,V) = \mathrm{tr}(W \longmapsto R(W,U)V), \qquad \mathrm{Ric}_{ij} = R^a{}_{jai}. \tag{14.4.1}$$

Krzywizna skalarna to jeszcze jeden ślad, tym razem względem metryki:

$$\mathrm{Scal} = \mathrm{tr}_g \,\mathrm{Ric} = g^{ij}\mathrm{Ric}_{ij}. \tag{14.4.2}$$

Nie mylmy Scal z operatorem R ani z wartością $K(\sigma)$ przypisaną płaszczyźnie.

Tensor Ricciego jest symetryczny. Istotnie, z pierwszej tożsamości Bianchiego $R(e_i,U)V - R(e_i,V)U = -R(U,V)e_i$. Bierzemy iloczyn z e_i i sumujemy po bazie ortonormalnej:

$$\mathrm{Ric}(U,V) - \mathrm{Ric}(V,U) = -\sum_i g(R(U,V)e_i, e_i) = 0.$$

Ostatnie składniki znikają przez antysymetrię w dwóch ostatnich argumentach $\mathcal{R}$. W sygnaturze pseudoriemannowskiej ta sama suma ma wagi $\varepsilon_i = g(e_i,e_i) = \pm 1$ i również znika.

Można to zobaczyć bez indeksów. Z punktu p wysyłamy geodezyjne w kierunku jednostkowego wektora v i w sąsiednich kierunkach. $\mathrm{Ric}(v,v)$ opisuje *łączny* wpływ krzywizn płaszczyzn rozpiętych przez v i każdy kierunek prostopadły na to, jak rozszerza się wąska wiązka tych geodezyjnych. Krzywizna skalarna zbiera te wyniki po wszystkich kierunkach v. Ścisłe znaczenie słów „łącznie" i „po wszystkich" podają poniższe sumy.

Stwierdzenie 14.4.2 (sumowanie krzywizn sekcyjnych)**.** *Jeżeli $e_1,\dots,e_n$ jest ortonormalną bazą riemannowskiego T_pM, to*

$$\mathrm{Ric}(v,v) = \sum_{i=1}^{n} g(R(e_i,v)v, e_i). \tag{14.4.3}$$

Dla jednostkowego $v = e_1$ jest to suma $\sum_{i=2}^{n} K(\mathrm{span}\{e_1,e_i\})$. Ponadto

$$\mathrm{Scal} = 2\sum_{1\le i<j\le n} K(\mathrm{span}\{e_i,e_j\}). \tag{14.4.4}$$

W wymiarze dwa: $\mathrm{Ric} = Kg$ *oraz* $\mathrm{Scal} = 2K$*.*

Dowód. Ślad endomorfizmu w bazie ortonormalnej to suma iloczynów skalarnych jego wartości na e_i z e_i. Stosując to do definicji (14.4.1), dostajemy (14.4.3). Składnik z $e_i = v$ znika przez antysymetrię $R(v,v) = 0$; pozostałe są wartościami (14.2.3). Ponowny ślad daje sumę po wszystkich parach uporządkowanych $i \neq j$. Symetria par z Twierdzenia 14.2.1 sprawia, że pary (i,j) i (j,i) mają tę samą krzywiznę; stąd czynnik 2. W wymiarze dwa dla jednostkowego v z pierwszej równości mamy $\mathrm{Ric}(v,v) = K(p)$; jednorodność i polaryzacja dają $\mathrm{Ric} = Kg$. □

Co mierzy Ricci, a co mierzy skalar?

Załóżmy $n \ge 2$. Ustalmy jednostkowy $v \in T_pM$ i patrzmy na geodezyjną $\gamma_v(t) = \exp_p(tv)$. Sąsiednie promienie odchylone w kierunkach prostopadłych do v opisuje macierz pól Jacobiego $A(t)$ z warunkami $A(0) = 0$, $A'(0) = \mathrm{Id}$; szczegóły konstrukcji podamy w Sekcji 14.11. Macierz zapisujemy w ortonormalnej ramie prostopadłej do $\dot\gamma_v$, przenoszonej równolegle wzdłuż promienia. Jej i-ta kolumna jest polem z początkową pochodną e_i. W tej ramie pochodna kowariantna współczynników jest zwykłą pochodną, a $\mathsf{K}_v(t)$ jest symetryczną macierzą operatora $w \mapsto R(w,\dot\gamma_v)\dot\gamma_v$. Ich równanie ma postać $A'' + \mathsf{K}_v(t)A = 0$, gdzie $\mathsf{K}_v(0)w = R(w,v)v$. Wstawiając warunki początkowe i różniczkując równanie w zerze, otrzymujemy

$$A(t) = t\,\mathrm{Id} - \frac{t^3}{6}\mathsf{K}_v(0) + O(t^4).$$

Dlaczego wyraz przy t^2 znika? Z równania $A''(0) = -\mathsf{K}_v(0)A(0) = 0$; trzecia pochodna wynosi $A'''(0) = -\mathsf{K}_v(0)A'(0) = -\mathsf{K}_v(0)$. Ślad $\mathsf{K}_v(0)$ to $\mathrm{Ric}(v,v)$, zatem wyznacznik, czyli gęstość objętości w kierunku v, spełnia

$$j(t,v) = t^{n-1}\left(1 - \frac{\mathrm{Ric}_p(v,v)}{6}t^2 + O(t^3)\right). \tag{14.4.5}$$

Użyliśmy tu elementarnego rozwinięcia $\det(\mathrm{Id} + \varepsilon B) = 1 + \varepsilon \operatorname{tr} B + O(\varepsilon^2)$. Przy dodatnim $\mathrm{Ric}(v,v)$ mała porcja objętości wzdłuż tego promienia jest mniejsza niż w $\mathbb{R}^n$; przy ujemnym jest większa. Mówimy o *sumie* odkształceń prostopadłych, nie o zachowaniu każdej pojedynczej geodezyjnej.

Reszty są jednostajne względem $v \in S_pM$: zależność rozwiązań od kierunku jest gładka, a sfera kierunków jest zwarta. Dla dostatecznie małego r kula metryczna jest obrazem kuli stycznej przez $\exp_p$, zgodnie z (13.3.4). Można zatem całkować w tych współrzędnych bez wielokrotnego liczenia punktów. Zsumujmy (14.4.5) po wszystkich jednostkowych kierunkach. Symetria sfery jednostkowej daje średnią $\int_{S_pM} \mathrm{Ric}(v,v)\,\mathrm{d}\theta/\operatorname{area}(S^{n-1}) = \mathrm{Scal}(p)/n$: średnia v_iv_j wynosi δ_{ij}/n, a ślad macierzy Ricciego to właśnie Scal. Całkując jeszcze promień t od 0 do r, przy $b_n = \mathrm{vol}_{\mathbb{R}^n}(B_1(0))$ dostajemy

$$\mathrm{vol}_g(B_g(p,r)) = b_n r^n\left(1 - \frac{\mathrm{Scal}(p)}{6(n+2)}r^2 + O(r^3)\right). \tag{14.4.6}$$

Faktycznie $\operatorname{area}(S^{n-1}) = nb_n$, a iloraz całek $\int_0^r t^{n+1}\mathrm{d}t$ i $\int_0^r t^{n-1}\mathrm{d}t$ to $nr^2/(n+2)$. Dodatnia krzywizna skalarna oznacza więc mniejszą objętość bardzo małych kul niż w geometrii euklidesowej. W wymiarze dwa $\mathrm{Scal} = 2K$ i (14.4.6) daje $\operatorname{Area}(B(p,r)) = \pi r^2(1 - K(p)r^2/12 + O(r^3))$, zgodnie z obwodem (14.3.1) po scałkowaniu. Sam wzór na obwód otrzymujemy bez różniczkowania symbolu O: dla $n = 2$ całka gęstości $j(r,v)$ po S_pM jest długością okręgu geodezyjnego, więc $C(r) = 2\pi r(1 - K(p)r^2/6 + O(r^3))$.

Ślady tracą część danych: dodatnie i ujemne krzywizny sekcyjne mogą się w nich znosić. W szczególności zerowy Ric nie wymusza $R = 0$ w wymiarze cztery. W metrykach lorentzowskich przy śladzie występują też znaki $\varepsilon_i = g(e_i,e_i) = \pm 1$; powyższa interpretacja objętości małych *kul metrycznych* dotyczy metryki riemannowskiej.

Twierdzenie 14.4.3 (przestrzenie o stałej krzywiźnie)**.** *Jeżeli wszystkie płaszczyzny styczne w rozmaitości riemannowskiej wymiaru $n \geq 2$ mają tę samą stałą krzywiznę κ, to*

$$R(X,Y)Z = \kappa\big(g(Y,Z)X - g(X,Z)Y\big), \quad \mathrm{Ric} = (n-1)\kappa g, \quad \mathrm{Scal} = n(n-1)\kappa. \tag{14.4.7}$$

Dowód. Prawa strona wzoru na R ma symetrie tensora Riemanna i daje $K(\sigma) = \kappa$ dla każdej płaszczyzny. Wykażmy, że te wartości wyznaczają cały tensor. Niech A będzie różnicą obu tensorów z opuszczonym ostatnim indeksem. Ma ona symetrie z Twierdzenia 14.2.1 i $A(u,v,v,u) = 0$ dla wszystkich u, v. Po podstawieniu $u + w$ w miejsce u i użyciu antysymetrii oraz symetrii zamiany par dostajemy $A(u,v,v,w) = 0$. Następnie podstawiamy $v+x$ w miejsce v: po odrzuceniu dwóch zerowych wyrazów zostaje

$$A(u,v,x,w) + A(u,x,v,w) = 0.$$

Z antysymetrii w pierwszej parze wynika $A(u,v,x,w) = A(x,u,v,w)$, a po cyklicznej zamianie argumentów także $A(u,v,x,w) = A(v,x,u,w)$. Pierwsza tożsamość Bianchiego mówi, że suma tych trzech równych wartości wynosi zero. Zatem $A = 0$. Ślad $W \mapsto R(W,U)V$ wzoru na R jest $\kappa(ng(U,V) - g(U,V))$, co daje Ric. Jeszcze jeden ślad daje Scal. □

Przykład 14.4.4 (trzy geometrie modelowe)**.** W $\mathbb{R}^n$ standardowe symbole Christoffela znikają: $R = \mathrm{Ric} = \mathrm{Scal} = 0$. Na sferze S^n_a o promieniu a w $\mathbb{R}^{n+1}$ operator kształtu jest $S = \pm a^{-1}\mathrm{Id}$.

Równanie Gaussa (14.3.4), ważne także dla hiperpowierzchni, daje $R(X,Y)Z = a^{-2}(g(Y,Z)X - g(X,Z)Y)$. Zatem $K = a^{-2}$, $\mathrm{Ric} = (n-1)a^{-2}g$ i $\mathrm{Scal} = n(n-1)a^{-2}$.

Model hiperboloidy $\mathbb{H}^n = \{p : \langle p,p\rangle_L = -1, p_0 > 0\}$ leży w płaskiej przestrzeni Minkowskiego. Jej normalna p ma kwadrat długości -1. Z $Y\langle Z,p\rangle_L = 0$ wynika $\langle D_Y Z, p\rangle_L = -g(Y,Z)$, a więc $D_Y Z = \nabla_Y Z + g(Y,Z)p$. Ponadto $D_X p = X$. Biorąc część styczną komutatora płaskiej pochodnej D tak jak w dowodzie 14.3.2, uzyskujemy

$$R(X,Y)Z = -(g(Y,Z)X - g(X,Z)Y).$$

Stąd $K = -1$, $\mathrm{Ric} = -(n-1)g$ i $\mathrm{Scal} = -n(n-1)$. Po zmianie skali metryki na $g_{\text{nowe}} = a^2 g$, $a > 0$, otrzymujemy $K = -a^{-2}$, $\mathrm{Ric}_{\text{nowe}} = -(n-1)a^{-2}g_{\text{nowe}} = \mathrm{Ric}$ i $\mathrm{Scal}_{\text{nowe}} = -n(n-1)a^{-2}$. Izometrie modeli z Przykładu 11.2.3 przenoszą te wartości na model półprzestrzeni i model kuli.

Stwierdzenie 14.4.5 (krzywizna w każdym z trzech modeli)**.** *Metryki hiperboloidy, kuli Poincarégo* (11.2.4) *i półprzestrzeni* (11.2.3) *mają tę samą krzywiznę sekcyjną $K = -1$ w każdej płaszczyźnie. W wymiarze n w każdym modelu* $\mathrm{Ric} = -(n-1)g$ *i* $\mathrm{Scal} = -n(n-1)$. *Po pomnożeniu metryki przez a^2 wartości te przyjmują odpowiednio postać $K = -a^{-2}$,* $\mathrm{Ric} = -(n-1)a^{-2}g_{\text{nowe}}$ *oraz* $\mathrm{Scal} = -n(n-1)a^{-2}$.

Dowód. Dla hiperboloidy wynik otrzymaliśmy z płaskiej pochodnej otaczającej w Przykładzie 14.4.4. Odwzorowania P i F z Przykładu 11.2.3 spełniają $P^* g_{\mathcal{H}} = g_B$ oraz $F^* g_{\mathbb{H}} = g_B$. Są zatem izometriami. Jednoznaczność koneksji Leviego-Civity daje dla izometrii I równość $\mathrm{d}I(\nabla_X Y) = \nabla_{\mathrm{d}IX}(\mathrm{d}IY)$ (po odpowiednim przeniesieniu pól); wstawienie jej do (14.1.1) przenosi tensor R, a więc i (14.2.3). To dowodzi tezy we wszystkich wymiarach.

Współrzędne z pozwalają również sprawdzić krzywiznę hiperboloidy *bezpośrednio z symboli.* Pisząc $t^2 = 1 + |z|^2$, z (12.3.8) mamy

$$\partial_i \Gamma^k_{j\ell} = -\delta^k_i g_{j\ell} - z^k \partial_i g_{j\ell}, \qquad \Gamma^k_{ic}\Gamma^c_{j\ell} = \frac{z^k z_i}{t^2} g_{j\ell},$$

ponieważ $z^c g_{ic} = z_i/t^2$. Z obliczonej w rozdziale o koneksji pochodnej $g_{j\ell}$ wynika

$$\partial_i g_{j\ell} - \partial_j g_{i\ell} = \frac{\delta_{j\ell} z_i - \delta_{i\ell} z_j}{t^2}.$$

Po podstawieniu do (14.1.2) wyrazy zawierające z^k znoszą się. Zostaje

$$R^k{}_{\ell ij} = -(\delta^k_i g_{j\ell} - \delta^k_j g_{i\ell}), \tag{14.4.8}$$

co ponownie daje $K = -1$ dla każdej płaszczyzny stycznej.

Policzmy dodatkowo krzywiznę *wprost* w wymiarze dwa. Dla metryki konforemnej $g = e^{2\varphi}(\mathrm{d}x^2 + \mathrm{d}y^2)$ wzór (12.3.1) daje

$$\Gamma^k_{ij} = \delta^k_i \varphi_j + \delta^k_j \varphi_i - \delta_{ij}\varphi_k, \qquad \varphi_j = \partial_j \varphi.$$

Przykładowo $\Gamma^1_{11} = \varphi_x$, $\Gamma^1_{12} = \varphi_y$, $\Gamma^1_{22} = -\varphi_x$, $\Gamma^2_{12} = \varphi_x$ i $\Gamma^2_{22} = \varphi_y$. W składniku $R^1{}_{212}$ wzoru (14.1.2) pochodne dają $-\varphi_{xx} - \varphi_{yy}$, zaś dwa wyrazy kwadratowe w symbolach Christoffela są $(-\varphi_x^2 + \varphi_y^2)$ i $-(\varphi_y^2 - \varphi_x^2)$, więc się znoszą. Mianownik w (14.2.3) wynosi $e^{4\varphi}$, a licznik $e^{2\varphi}R^1{}_{212}$; stąd

$$K = -e^{-2\varphi}(\varphi_{xx} + \varphi_{yy}). \tag{14.4.9}$$

Dla półpłaszczyzny $\varphi = -\log y$: $\Delta_{\mathrm{E}}\varphi = 1/y^2$ i $e^{-2\varphi} = y^2$, co daje $K = -1$. Dla dysku $r^2 = x^2 + y^2$ i $\varphi = \log 2 - \log(1 - r^2)$; obliczenie pochodnych

$$\varphi_x = \frac{2x}{1-r^2}, \qquad \varphi_{xx} = \frac{2}{1-r^2} + \frac{4x^2}{(1-r^2)^2}$$

oraz analogiczne dla y daje $\Delta_{\mathrm{E}}\varphi = 4/(1-r^2)^2$. Ponieważ $e^{-2\varphi} = (1-r^2)^2/4$, ponownie $K=-1$. Wzory na Ricciego i skalar wynikają ze śladów w (14.4.7).

Przy skalowaniu $g \mapsto a^2 g$ symbole Christoffela pozostają takie same, więc operator $R(X,Y)Z$ się nie zmienia. Licznik i mianownik w (14.2.3) mnożą się odpowiednio przez a^2 i a^4; dlatego $K \mapsto a^{-2}K$. Tensor Ricciego typu $(0,2)$ pozostaje niezmieniony: jego definicja bierze ślad niezmienionego operatora $W \mapsto R(W,U)V$. Dopiero ślad z nową odwrotnością metryki daje $\mathrm{Scal}_{\mathrm{nowe}} = a^{-2}\mathrm{Scal}$. Nie należy mylić niezmienionego tensora Ricciego z jego wartościami na wektorach jednostkowych dla nowej metryki. □

Przykład 14.4.6 (różne płaszczyzny w jednym punkcie)**.** Na produkcie $S^2_a \times \mathbb{R}$ z metryką produktową płaszczyzna styczna do sfery ma krzywiznę a^{-2}, a płaszczyzna rozpięta przez kierunek sferyczny i kierunek prostej ma krzywiznę 0. W bazie ortonormalnej złożonej z dwóch kierunków sfery i jednego kierunku prostej tensor Ricciego ma wartości diagonalne $(a^{-2}, a^{-2}, 0)$, zaś $\mathrm{Scal} = 2a^{-2}$. Jedna liczba skalarna nie mówi, która z płaszczyzn jest zakrzywiona.

Przykład 14.4.7 (pomiar krzywizny obwodem koła)**.** Niech ρ będzie *odległością geodezyjną* od ustalonego punktu na dwuwymiarowej przestrzeni o stałej krzywiźnie. Współrzędne biegunowe na sferze promienia a dają $g = \mathrm{d}\rho^2 + a^2\sin^2(\rho/a)\mathrm{d}\phi^2$. Na hiperboloidzie można zapisać punkt jako $(a\cosh(\rho/a), a\sinh(\rho/a)\cos\phi, a\sinh(\rho/a)\sin\phi)$; różniczkując tę parametryzację w metryce Minkowskiego, dostajemy $g = \mathrm{d}\rho^2 + a^2\sinh^2(\rho/a)\mathrm{d}\phi^2$. Na płaszczyźnie jest $g = \mathrm{d}\rho^2 + \rho^2\mathrm{d}\phi^2$. Okrąg $\rho = \text{const}$ ma zatem obwód $\int_0^{2\pi}\sqrt{g_{\phi\phi}}\,\mathrm{d}\phi$, czyli

powierzchnia	K	obwód $C(\rho)$
S^2_a	$+a^{-2}$	$2\pi a\sin(\rho/a), \quad 0<\rho<\pi a$
$\mathbb{R}^2$	0	$2\pi\rho$
$\mathbb{H}^2_a$	$-a^{-2}$	$2\pi a\sinh(\rho/a)$

(14.4.10)

Ponieważ $\sin x = x - x^3/6 + O(x^5)$ oraz $\sinh x = x + x^3/6 + O(x^5)$, mały okrąg na sferze ma obwód *mniejszy* od $2\pi\rho$, a w przestrzeni hiperbolicznej *większy*. W każdym przypadku $C(\rho) = 2\pi\rho(1 - K\rho^2/6 + O(\rho^4))$. To sposób odczytania znaku krzywizny z pomiarów wykonanych na samej powierzchni.

Krzywizna metryk jednorodnych Nil i Sol

Poniższe obliczenia stosują konwencję tensora R z Definicji 14.1.1, tę samą co we wcześniejszych przykładach, lecz w ramie nieholonomicznej. Wyznaczanie wszystkich symboli Christoffela w zwykłych współrzędnych nie jest potrzebne.

Przykład 14.4.8 (Krzywizna grupy Heisenberga)**.** Dla ramy E_1, E_2, E_3 z Przykładu 12.3.9 korzystamy z wyznaczonej tam koneksji i z $[E_1, E_2] = E_3$. Na przykład

$$\begin{aligned} R(E_1,E_2)E_2 &= \nabla_{E_1}(\nabla_{E_2}E_2) - \nabla_{E_2}(\nabla_{E_1}E_2) - \nabla_{[E_1,E_2]}E_2 \\ &= 0 - \tfrac{1}{2}\nabla_{E_2}E_3 - \nabla_{E_3}E_2 = -\tfrac{3}{4}E_1. \end{aligned}$$

Ponieważ $[E_1,E_3] = [E_2,E_3] = 0$, dwa dalsze rachunki to

$$\begin{aligned} R(E_1,E_3)E_3 &= -\nabla_{E_3}(-\tfrac{1}{2}E_2) = \tfrac{1}{4}E_1, \\ R(E_2,E_3)E_3 &= -\nabla_{E_3}(\tfrac{1}{2}E_1) = \tfrac{1}{4}E_2. \end{aligned}$$

Otrzymujemy

$$K_{12} = -\tfrac{3}{4}, \qquad K_{13} = K_{23} = \tfrac{1}{4}, \qquad \mathrm{Ric} = \mathrm{diag}(-\tfrac{1}{2}, -\tfrac{1}{2}, \tfrac{1}{2}), \quad \mathrm{Scal} = -\tfrac{1}{2}.$$

Przy obliczeniu tensora Ricciego użyliśmy symetrii krzywizny i faktu, że $R(E_i,E_j)E_k = 0$, gdy wszystkie trzy indeksy są różne. Na przykład $R(E_1,E_2)E_3 = 0$, bo trzy pochodne w jego definicji

są wielokrotnościami $\nabla_{E_1}E_1, \nabla_{E_2}E_2, \nabla_{E_3}E_3$. Pozostałe dwie takie składowe zerują się tak samo. Stąd mieszane składowe Ricciego znikają, a na przekątnej $\mathrm{Ric}_{ii} = \sum_{j\neq i} K_{ij}$. Geometria Nil ma oba znaki krzywizny sekcyjnej. Dodatnia wartość Ricciego w kierunku pionowym jest sumą dwóch dodatnich krzywizn sekcyjnych płaszczyzn zawierających ten kierunek; w kierunkach poziomych przeważa krzywizna ujemna.

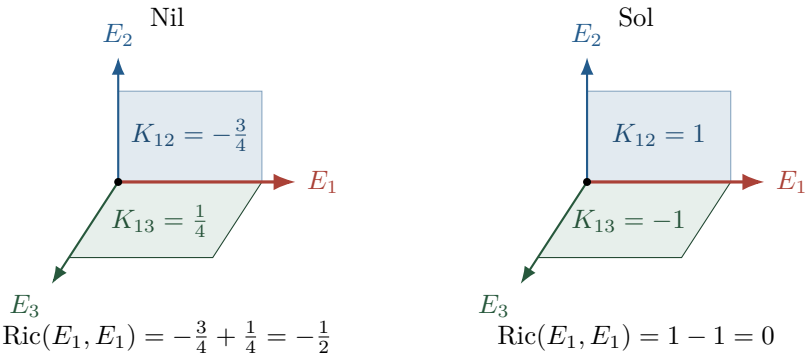
Przykład 14.4.9 (Krzywizna Sol)**.** Dla metryki g_S bierzemy ortonormalną ramę $E_1 = e^t\partial_x$, $E_2 = e^{-t}\partial_y$, $E_3 = \partial_t$. Nawiasy mają postać $[E_3, E_1] = E_1$, $[E_3, E_2] = -E_2$, $[E_1, E_2] = 0$. Wzór (12.3.10) daje niezerowe pochodne

$$\nabla_{E_1}E_1 = E_3, \quad \nabla_{E_1}E_3 = -E_1, \qquad \nabla_{E_2}E_2 = -E_3, \quad \nabla_{E_2}E_3 = E_2;$$

wszystkie pozostałe $\nabla_{E_i}E_j$ są zerowe. Dla przykładu $R(E_1, E_2)E_2 = \nabla_{E_1}(-E_3) = E_1$, a $R(E_1, E_3)E_3 = \nabla_{E_1}E_3 = -E_1$ (po uwzględnieniu wyrazu z nawiasem $[E_1, E_3] = -E_1$). Analogicznie otrzymujemy

$$K_{12} = 1, \qquad K_{13} = K_{23} = -1, \qquad \mathrm{Ric} = \mathrm{diag}(0, 0, -2), \quad \mathrm{Scal} = -2.$$

W szczególności $\mathrm{Ric}(E_1, E_1) = 0$, choć krzywizny płaszczyzn zawierających E_1 są odpowiednio 1 oraz -1. To konkretny przykład, dlaczego zerowanie pewnej wartości kwadratowej Ricciego nie jest równoznaczne z płaskością.



Rysunek 14.3: Dwie płaszczyzny zawierające ten sam jednostkowy kierunek E_1. Ricci w tym kierunku sumuje ich krzywizny. W Sol wkłady znoszą się, choć żadna z tych płaszczyzn nie ma zerowej krzywizny. Rysunek przedstawia przestrzeń styczną w umownej perspektywie; baza E_1, E_2, E_3 jest ortonormalna w odpowiedniej metryce Nil lub Sol.

14.5 Krzywizna Minkowskiego i modelu FLRW

Przykład 14.5.1 (krzywizna Poincarégo i regularność przy $t = 0$)**.** Dla metryki (11.3.1) obliczyliśmy w (13.4.7), że $\Gamma^\lambda_{\mu\nu} = 0$ w całej dziedzinie. W szczególności wszystkie pochodne tych symboli również znikają. Ze wzoru na tensor Riemanna, zgodnie z przyjętą konwencją znaku, otrzymujemy

$$R^\lambda{}_{\rho\mu\nu} = \partial_\mu\Gamma^\lambda_{\nu\rho} - \partial_\nu\Gamma^\lambda_{\mu\rho} + \Gamma^\lambda_{\mu\sigma}\Gamma^\sigma_{\nu\rho} - \Gamma^\lambda_{\nu\sigma}\Gamma^\sigma_{\mu\rho} = 0. \tag{14.5.1}$$

Przez kontrakcję indeksów dostajemy $\mathrm{Ric}_{\rho\nu} = R^\mu{}_{\rho\mu\nu} = 0$, a następnie $\mathrm{Scal} = g^{\rho\nu}\mathrm{Ric}_{\rho\nu} = 0$. Także tensor Einsteina $E = \mathrm{Ric} - \frac{1}{2}\mathrm{Scal}\, g_M$ oraz niezmiennik Kretschmanna $\mathcal{K} = \mathcal{R}_{\alpha\beta\gamma\delta}\mathcal{R}^{\alpha\beta\gamma\delta}$ znikają identycznie. Są to równości tensorowe, niezależne od współrzędnych.

Co dzieje się dokładnie przy $t = 0$? Macierz metryki nadal wynosi $\mathrm{diag}(-c^2, 1, 1, 1)$, a jej wyznacznik $\det(g_{\mu\nu}) = -c^2 \neq 0$. Hiperpowierzchnia $\Sigma_0 = \{t = 0\}$ jest gładka; metryka indukowana na Σ_0 ma postać $g_M|_{T\Sigma_0} = \mathrm{d}x^2 + \mathrm{d}y^2 + \mathrm{d}z^2$. Jej jednostkowy, przyszłościowo

skierowany normalny $U = c^{-1}\partial_t$ spełnia $g_M(U,U) = -1$. Stosując definicję 11.1.2, mamy $U^\flat = -c\,\mathrm{d}t$. Ponieważ $\nabla_X U = 0$ dla każdego pola X stycznego do Σ_0, druga forma fundamentalna $\mathrm{II}(X,Y) = g_M(\nabla_X U, Y)$ także znika. W połączeniu z geodezyjną zupełnością z Przykładu 13.4.4 otrzymujemy, że $t = 0$ jest regularnym przekrojem płaskiej czasoprzestrzeni, a nie osobliwością.

Podstawienie $\zeta = \mathrm{i}ct$ nie zmienia tych wniosków: na rzeczywistym obrazie $F(M) = \mathbb{R}^3 \times \mathrm{i}\mathbb{R}$ mamy $F^*h = g_M$ i identycznie zerowe niezmienniki. Jest to zasadniczo inny przypadek niż pyłowa metryka FLRW z (14.7.7), dla której $\mathcal{K} = 80/(27t^4)$ rozbiega się przy $t \to 0^+$. Różnica wynika z geometrii, nie z użycia liczby urojonej w symbolu współrzędnej czasowej.

Przykład 14.5.2 (tensor Riemanna i jego ślady dla metryki FLRW)**.** Stosujemy konwencję znaku z (14.1.1). Ze wzorów (12.3.2) i (14.1.2) wynikają działania operatora krzywizny:

$$R(\partial_0,\partial_i)\partial_0 = \frac{\ddot a}{a}\partial_i, \qquad R(\partial_0,\partial_i)\partial_j = a\ddot a\,\delta_{ij}\partial_0,$$
$$R(\partial_i,\partial_j)\partial_k = \dot a^2(\delta_{jk}\partial_i - \delta_{ik}\partial_j).$$

Na przykład, $R^0{}_{i0j} = \partial_0\Gamma^0_{ji} - \Gamma^0_{jk}\Gamma^k_{0i} = \partial_t(a\dot a)\delta_{ij} - \dot a^2\delta_{ij} = a\ddot a\,\delta_{ij}$. Biorąc ślad $\mathrm{Ric}_{\mu\nu} = R^\alpha{}_{\mu\alpha\nu}$, dostajemy

$$\mathrm{Ric}_{00} = -3\frac{\ddot a}{a}, \qquad \mathrm{Ric}_{0i} = 0, \qquad \mathrm{Ric}_{ij} = (a\ddot a + 2\dot a^2)\delta_{ij}. \tag{14.5.2}$$

Ponieważ $g^{00} = -1$ i $g^{ij} = a^{-2}\delta^{ij}$, krzywizna skalarna oraz tensor Einsteina $E = \mathrm{Ric} - \frac12 \mathrm{Scal}\, g$ przyjmują postać

$$\mathrm{Scal} = 6\left(\frac{\ddot a}{a} + H^2\right),$$
$$E_{00} = 3H^2, \qquad E_{0i} = 0, \qquad E_{ij} = -a^2\left(2\frac{\ddot a}{a} + H^2\right)\delta_{ij}. \tag{14.5.3}$$

Aby odróżnić osobliwość rzeczywistą od współrzędnościowej, wygodnie obliczyć także skalar Kretschmanna $\mathcal{K} = \mathcal{R}_{\alpha\beta\gamma\delta}\mathcal{R}^{\alpha\beta\gamma\delta}$. W ramie ortonormalnej $e_0 = \partial_t$, $e_i = a^{-1}\partial_i$ niezależne współczynniki krzywizny wyznaczają liczby $\ddot a/a$ (kierunki czasoprzestrzenne) i H^2 (kierunki czysto przestrzenne). Są trzy płaszczyzny typu (e_0,e_i) i trzy typu (e_i,e_j); każda daje cztery składniki w pełnej kontrakcji. Dwa indeksy czasowe w każdym kwadracie znoszą znaki metryki lorentzowskiej. Stąd

$$\mathcal{K} = 12\left[\left(\frac{\ddot a}{a}\right)^2 + H^4\right]. \tag{14.5.4}$$

W szczególności przekroje $t = \mathrm{const}$ są płaskie, choć zwykle $\mathcal{K} \neq 0$.

14.6 Schwarzschild i Kerr: próżnia nie oznacza płaskości

W tej sekcji przyjmujemy jednostki $G = c = 1$ i tę samą konwencję znaku co w (14.1.1). Metryki (11.3.4) i (11.3.5) są lorentzowskie. Ich Ric oraz Scal dotyczą *pełnej czterowymiarowej czasoprzestrzeni*; metryki indukowane na przekrojach $t = \mathrm{const}$ mają własną, inną krzywiznę.

Przykład 14.6.1 (krzywizna metryki Schwarzschilda)**.** Dla $M > 0$, w obszarze $r > 2M$ i $0 < \theta < \pi$, zapiszmy metrykę z (11.3.4) jako

$$g = -f(r)\mathrm{d}t^2 + f(r)^{-1}\mathrm{d}r^2 + r^2\mathrm{d}\theta^2 + r^2\sin^2\theta\,\mathrm{d}\phi^2, \qquad f(r) = 1 - \frac{2M}{r}.$$

Aby zobaczyć, skąd biorą się wartości krzywizny, podajmy obliczenie najpierw dla dowolnej gładkiej funkcji $f > 0$. Niezerowe symbole Christoffela, poza zamianą dolnych indeksów, są następujące:

$$\Gamma^t_{tr} = \frac{f'}{2f}, \qquad \Gamma^r_{tt} = \frac{ff'}{2}, \qquad \Gamma^r_{rr} = -\frac{f'}{2f},$$
$$\Gamma^r_{\theta\theta} = -rf, \qquad \Gamma^r_{\phi\phi} = -rf\sin^2\theta, \qquad \Gamma^\theta_{r\theta} = \Gamma^\phi_{r\phi} = \frac{1}{r},$$
$$\Gamma^\theta_{\phi\phi} = -\sin\theta\cos\theta, \qquad \Gamma^\phi_{\theta\phi} = \cot\theta.$$

Wstawienie ich do (14.1.2), a następnie wykonanie śladu $\mathrm{Ric}_{ij} = R^a{}_{jai}$ daje

$$\mathrm{Ric}_{tt} = f\left(\frac{f''}{2} + \frac{f'}{r}\right), \qquad \mathrm{Ric}_{rr} = -\frac{1}{f}\left(\frac{f''}{2} + \frac{f'}{r}\right),$$
$$\mathrm{Ric}_{\theta\theta} = 1 - f - rf', \qquad \mathrm{Ric}_{\phi\phi} = (1 - f - rf')\sin^2\theta, \tag{14.6.1}$$

zaś pozostałe składowe są zerowe. Dla kontroli prześledźmy składową kątową. W ogólnym wzorze

$$\mathrm{Ric}_{ij} = \partial_a\Gamma^a_{ij} - \partial_j\Gamma^a_{ia} + \Gamma^a_{ac}\Gamma^c_{ij} - \Gamma^a_{jc}\Gamma^c_{ia}$$

dla $i = j = \theta$ kolejne cztery grupy składników wynoszą odpowiednio

$$-f - rf', \qquad \csc^2\theta, \qquad -2f, \qquad 2f - \cot^2\theta.$$

Ich suma to $1 - f - rf'$. Teraz $f' = 2M/r^2$ i $f'' = -4M/r^3$: zarówno $f''/2 + f'/r$, jak i $1 - f - rf'$ znikają. Otrzymujemy

$$\mathrm{Ric} = 0, \qquad \mathrm{Scal} = 0, \qquad \mathcal{K} := \mathcal{R}_{abcd}\mathcal{R}^{abcd} = \frac{48M^2}{r^6}. \tag{14.6.2}$$

Sprawdźmy również ostatnią równość, a przy okazji wskażmy jawną składową niezerowego R. Z (14.1.2) i podanych symboli Christoffela znajdujemy między innymi

$$R^t{}_{rtr} = -\frac{f''}{2f}, \qquad R^t{}_{\theta t\theta} = -\frac{rf'}{2}, \qquad R^r{}_{\theta r\theta} = -\frac{rf'}{2},$$

oraz, rozpisując składową kątową,

$$R^\theta{}_{\phi\theta\phi} = \partial_\theta\Gamma^\theta_{\phi\phi} + \Gamma^\theta_{\theta r}\Gamma^r_{\phi\phi} - \Gamma^\theta_{\phi\phi}\Gamma^\phi_{\theta\phi} = (1 - f)\sin^2\theta.$$

Składowe z ϕ w miejsce θ w parach czasowo-kątowych i radialno-kątowych otrzymujemy przez mnożenie przez $\sin^2\theta$. Weźmy pseudoortonormalną ramkę o sygnaturze $(-,+,+,+)$

$$e_0 = f^{-1/2}\partial_t, \quad e_1 = f^{1/2}\partial_r, \quad e_2 = r^{-1}\partial_\theta, \quad e_3 = (r\sin\theta)^{-1}\partial_\phi$$

i połóżmy $\mu = M/r^3$. Po obniżeniu indeksów metryką i uwzględnieniu czynników w ramie jedynymi niezależnymi niezerowymi wartościami są

(i,j)	$(0,1)$	$(0,2)$	$(0,3)$	$(1,2)$	$(1,3)$	$(2,3)$
$\mathcal{R}(e_i,e_j,e_j,e_i)$	-2μ	μ	μ	$-\mu$	$-\mu$	2μ

Na przykład pierwsza wartość to $f''/2 = -2\mu$, druga to $f'/(2r) = \mu$, a ostatnia to $(1-f)/r^2 = 2\mu$. Symetrie z Twierdzenia 14.2.1 dają wszystkie pozostałe składowe; każda z sześciu wartości występuje cztery razy przy pełnej kontrakcji. Ponieważ w tych wyrazach indeks czasowy występuje dwukrotnie,

$$\mathcal{K} = 4\big((2\mu)^2 + \mu^2 + \mu^2 + \mu^2 + \mu^2 + (2\mu)^2\big) = 48\mu^2 = \frac{48M^2}{r^6}.$$

Płaszczyzna $\operatorname{span}(\partial_\theta, \partial_\phi)$ jest przestrzenna. W *pełnej czasoprzestrzeni* jej krzywizna sekcyjna wynosi

$$K(\partial_\theta \wedge \partial_\phi) = \frac{r^2(1-f)\sin^2\theta}{r^4 \sin^2\theta} = \frac{2M}{r^3}. \tag{14.6.3}$$

Natomiast dwuwymiarowa sfera $t, r = \text{const}$ z *metryką indukowaną* ma krzywiznę Gaussa $1/r^2$. Są to różne obiekty geometryczne; nie wolno utożsamiać ich krzywizn. Niezmiennik $\mathcal{K}$ z (14.6.2) jest skończony przy $r = 2M$, ale rośnie bez ograniczenia, gdy $r \to 0$ w przedłużeniu czasoprzestrzeni. Zerowanie się Ricciego wynika tu ze znoszenia się składowych śladu, a nie z zaniku tensora Riemanna.

Przykład 14.6.2 (krzywizna metryki Kerra)**.** Niech $M > 0$, $\Sigma = r^2 + a^2\cos^2\theta$ i $\Delta = r^2 - 2Mr + a^2$, jak we wzorze (11.3.5). Rachunek wykonamy dla $\Delta > 0$, $\Sigma > 0$ i $0 < \theta < \pi$. Wprowadźmy pseudoortonormalną ramkę

$$e_0 = \frac{(r^2+a^2)\partial_t + a\partial_\phi}{\sqrt{\Sigma\Delta}}, \quad e_1 = \sqrt{\frac{\Delta}{\Sigma}}\,\partial_r,$$
$$e_2 = \frac{\partial_\theta}{\sqrt{\Sigma}}, \qquad\qquad e_3 = \frac{a\sin\theta\,\partial_t + (\sin\theta)^{-1}\partial_\phi}{\sqrt{\Sigma}}.$$

Podstawienie do metryki daje $g(e_i, e_j) = \operatorname{diag}(-1,1,1,1)_{ij}$. Poniższa tabela pozwala sprawdzić oba ślady i pełną kontrakcję bez pomijania składników mieszanych. Oznaczmy

$$A = \frac{Mr(r^2 - 3a^2\cos^2\theta)}{\Sigma^3}, \qquad B = \frac{Ma\cos\theta(3r^2 - a^2\cos^2\theta)}{\Sigma^3}.$$

W kolejności par $01, 02, 03, 12, 13, 23$ macierz $C_{ij,kl} = \mathcal{R}(e_i, e_j, e_k, e_l)$ wynosi

$$C = \begin{pmatrix} 2A & 0 & 0 & 0 & 0 & -2B \\ 0 & -A & 0 & 0 & -B & 0 \\ 0 & 0 & -A & B & 0 & 0 \\ 0 & 0 & B & A & 0 & 0 \\ 0 & -B & 0 & 0 & A & 0 \\ -2B & 0 & 0 & 0 & 0 & -2A \end{pmatrix}. \tag{14.6.4}$$

Wszystkie inne składowe wyznaczają antysymetrie par. Aby odtworzyć tabelę ze wzoru współrzędnego, wygodnie położyć $x = \cos\theta$, $q = 1 - x^2$ i $\Sigma = r^2 + a^2x^2$. W kolejności (t, r, x, ϕ) niezerowe składowe odwrotnej metryki są

$$g^{tt} = -\frac{(r^2+a^2)^2 - a^2\Delta q}{\Sigma\Delta}, \quad g^{t\phi} = -\frac{2Mar}{\Sigma\Delta},$$
$$g^{\phi\phi} = \frac{\Delta - a^2 q}{\Sigma\Delta q}, \qquad\qquad g^{rr} = \frac{\Delta}{\Sigma}, \qquad g^{xx} = \frac{q}{\Sigma}.$$

Współczynniki są wymierne w r, x; pochodne po t, ϕ znikają. Wstawiamy je do (12.3.1) i (14.1.2), opuszczamy indeks metryką i przechodzimy do powyższej ramki. Na przykład dla $F_0 = (r^2 + a^2)\partial_t + a\partial_\phi$, $F_1 = \partial_r$, $F_2 = -\partial_x$, $F_3 = aq\partial_t + \partial_\phi$ otrzymujemy

$$\mathcal{R}(F_0, F_1, F_0, F_1) = \frac{2Mr(r^2 - 3a^2x^2)}{\Sigma},$$
$$\mathcal{R}(F_0, F_1, F_2, F_3) = -\frac{2Max(3r^2 - a^2x^2)}{\Sigma}.$$

Iloczyny czynników normalizujących w obu tych składowych wynoszą Σ^{-2}, co daje $2A$ i $-2B$. Pozostałe pary oblicza się tą samą skończoną procedurą.

Teraz $\mathrm{Ric}_{00} = -2A + A + A = 0$, $\mathrm{Ric}_{11} = 2A - A - A = 0$, a $\mathrm{Ric}_{22} = \mathrm{Ric}_{33} = -A - A + 2A = 0$. Składowe B mają cztery różne indeksy, więc nie wnoszą nic do śladu; pozadiagonalne składowe Ricciego też znikają. Stąd $\mathrm{Ric} = 0$ i $\mathrm{Scal} = 0$. Przy pełnej kontrakcji każda pozycja diagonalna tabeli występuje cztery razy, a każda niezależna pozycja pozadiagonalna osiem razy. Wyrazy B mają jeden indeks czasowy i wnoszą znak ujemny. Zatem

$$\mathcal{K} = 4(4+1+1+1+1+4)A^2 - 8(4+1+1)B^2 = 48(A^2 - B^2).$$

Rozwinięcie $r^2(r^2-3y^2)^2 - y^2(3r^2-y^2)^2 = r^6 - 15r^4y^2 + 15r^2y^4 - y^6$, dla $y = a\cos\theta$, daje

$$\mathcal{K} = \frac{48M^2}{\Sigma^6}(r^6 - 15a^2r^4\cos^2\theta + 15a^4r^2\cos^4\theta - a^6\cos^6\theta). \tag{14.6.5}$$

Można sprawdzić dwa ważne przypadki bez ponawiania całego rachunku: dla $a = 0$ odzyskujemy $48M^2/r^6$ z (14.6.2), a na równiku $\theta = \pi/2$ mamy tę samą wartość nawet przy $a \neq 0$. Poza równikiem pojawia się zależność kątowa związana z obrotem. W sygnaturze lorentzowskiej pełna kontrakcja $\mathcal{K}$ nie jest kwadratem dodatniej normy: może mieć różne znaki. Współrzędny rachunek krzywizny jest wymierny w r, x; otrzymane tożsamości po sprowadzeniu do wspólnego mianownika są tożsamościami wielomianowymi. Obowiązują więc również na pozostałych obszarach $\Delta \neq 0$, $\Sigma > 0$, choć użyta ramka z pierwiastkiem Δ nie jest tam rzeczywista. Równanie $\Sigma = 0$ dla $a \neq 0$ odpowiada $r = 0, \theta = \pi/2$ i wskazuje osobliwość pierścieniową: wzdłuż równika $\mathcal{K} = 48M^2/r^6$ rośnie bez ograniczenia. Usuwalność osobliwości współrzędnych przy $\Delta = 0$, $\Sigma > 0$, uzasadnia inny rachunek, nie sama skończoność $\mathcal{K}$. Wprowadzamy lokalnie

$$\mathrm{d}v = \mathrm{d}t + \frac{r^2+a^2}{\Delta}\mathrm{d}r, \qquad \mathrm{d}\psi = \mathrm{d}\phi + \frac{a}{\Delta}\mathrm{d}r.$$

Po podstawieniu do metryki wszystkie mianowniki Δ znoszą się i otrzymujemy

$$\begin{aligned} g = &-\left(1 - \frac{2Mr}{\Sigma}\right)\mathrm{d}v^2 + 2\mathrm{d}v\mathrm{d}r - \frac{4Mar\sin^2\theta}{\Sigma}\mathrm{d}v\mathrm{d}\psi - 2a\sin^2\theta\,\mathrm{d}r\mathrm{d}\psi \\ &+ \Sigma\mathrm{d}\theta^2 + \sin^2\theta\left(r^2 + a^2 + \frac{2Mra^2\sin^2\theta}{\Sigma}\right)\mathrm{d}\psi^2. \end{aligned}$$

Jej wyznacznik wynosi $-\Sigma^2\sin^2\theta$. Zatem dla $0 < \theta < \pi$ i $\Sigma > 0$ nowy wzór jest gładki i niezdegenerowany także przy $\Delta = 0$. Definiuje lokalne przedłużenie przez tę powierzchnię. Te stwierdzenia dotyczą pełnej metryki lorentzowskiej. Przekrój $t = \text{const}$ może mieć niezerowy tensor Ricciego własnej metryki trójwymiarowej.

Uwaga 14.6.3 (interpretacja porównawcza). Na sferze już Ricci i skalar rejestrują dodatnią krzywiznę. W próżniowych przykładach Schwarzschilda i Kerra oba te ślady znikają, choć transport po pętlach i zachowanie sąsiednich geodezyjnych ujawniają niezerowy tensor R. W czterowymiarowej geometrii lorentzowskiej pozostaje wtedy część krzywizny, która nie jest opisana przez Ricciego (tensor Weyla). Pełny rozkład na część bezśladową i składniki wyznaczone przez Ricciego wykracza poza ten rozdział.

14.7 Równania Friedmanna i osobliwość modelu FLRW

Przykład 14.7.1 (równania Einsteina i wyprowadzenie równań Friedmanna)**.** Przyjmujemy $c = 1$, oznaczamy stałą Newtona przez G_N i rozważamy równania Einsteina z członem kosmologicznym

$$\mathrm{Ric}_{\mu\nu} - \frac{1}{2}\mathrm{Scal}\, g_{\mu\nu} + \Lambda g_{\mu\nu} = 8\pi G_N T_{\mu\nu}. \tag{14.7.1}$$

Zakładamy, że materia jest płynem doskonałym o gęstości energii $\rho(t)$, ciśnieniu $p(t)$ i czteroprędkości $U = \partial_t$: $T = (\rho + p)U^\flat \otimes U^\flat + pg$. W rozważanych współrzędnych $T_{00} = \rho$, $T_{0i} = 0$, $T_{ij} = pa^2\delta_{ij}$. Składowa $(0,0)$ równania (14.7.1) oraz składowe przestrzenne, po użyciu (14.5.3), dają odpowiednio

$$H^2 = \frac{8\pi G_N}{3}\rho + \frac{\Lambda}{3}, \qquad \frac{\ddot{a}}{a} = -\frac{4\pi G_N}{3}(\rho + 3p) + \frac{\Lambda}{3}. \tag{14.7.2}$$

Są to *równania Friedmanna* dla przestrzennie płaskiego modelu FLRW. Równoważnie drugie z nich, razem z pierwszym, można zapisać jako $2\ddot{a}/a + H^2 = \Lambda - 8\pi G_N p$. Równanie ciągłości można tutaj wyprowadzić bez odwołania do ogólnej różniczkowej tożsamości Bianchiego. Z $\dot{H} = \ddot{a}/a - H^2$ i obu równań (14.7.2) mamy $\dot{H} = -4\pi G_N(\rho + p)$. Pochodna pierwszego równania daje $2H\dot{H} = (8\pi G_N/3)\dot{\rho}$; podstawienie $\dot{H}$ i skrócenie stałych, bez dzielenia przez H, prowadzi do równania ciągłości

$$\dot{\rho} + 3H(\rho + p) = 0. \tag{14.7.3}$$

Jest to zarazem składowa $\nabla_\mu T^{\mu 0} = 0$ prawa zachowania energii i pędu. Istotnie, $T^{00} = \rho$, $T^{ij} = pa^{-2}\delta^{ij}$, $\Gamma^\mu_{\mu 0} = 3H$ i $\Gamma^0_{ij}T^{ij} = 3Hp$. Zatem $\nabla_\mu T^{\mu 0} = \dot{\rho} + 3H\rho + 3Hp$. Do wyznaczenia $a(t)$ potrzeba jeszcze *równania stanu* łączącego p i ρ: same równania Einsteina nie określają składu materii.

Przykład 14.7.2 (rozwiązanie równań Friedmanna: pył i promieniowanie)**.** Niech $\Lambda = 0$, $\rho > 0$, a równanie stanu ma postać $p = w\rho$ ze stałą $w > -1$. Równanie (14.7.3) daje po rozdzieleniu zmiennych

$$\frac{\mathrm{d}\rho}{\rho} = -3(1+w)\frac{\mathrm{d}a}{a}, \qquad \rho = \rho_0\left(\frac{a_0}{a}\right)^{3(1+w)}.$$

Podstawiając do pierwszego równania (14.7.2) i wybierając gałąź rozszerzającą się ($\dot{a} > 0$), otrzymujemy

$$\dot{a} = Ca^{-(1+3w)/2}, \qquad C = \sqrt{\frac{8\pi G_N}{3}\rho_0 a_0^{3(1+w)}}.$$

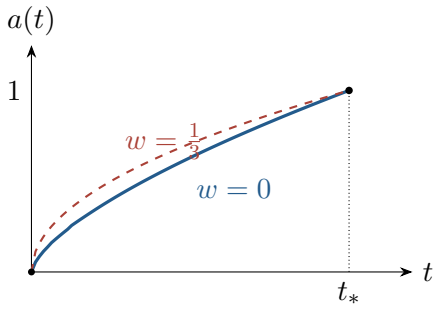
To równanie różniczkowe zwyczajne jest rozdzielne. Całkowanie daje $\frac{2}{3(1+w)}a^{3(1+w)/2} = C(t - t_B)$, a zatem

$$a(t) = A(t - t_B)^{\frac{2}{3(1+w)}}, \qquad \rho(t) = \frac{1}{6\pi G_N(1+w)^2(t-t_B)^2}, \quad t > t_B, \tag{14.7.4}$$

gdzie $A > 0$ i t_B są stałymi. Dla *pyłu* ($p = 0$, $w = 0$), po wyborze początku czasu $t_B = 0$ i normalizacji $a(t_*) = 1$, mamy

$$a(t) = \left(\frac{t}{t_*}\right)^{2/3}, \qquad H(t) = \frac{2}{3t}, \qquad \rho(t) = \frac{1}{6\pi G_N t^2}. \tag{14.7.5}$$

Dla *promieniowania* ($p = \rho/3$, $w = 1/3$) otrzymujemy $a(t) = (t/t_*)^{1/2}$ oraz $\rho(t) = 3/(32\pi G_N t^2)$. Natomiast przy $w = -1$ gęstość jest stała, a równanie $\dot{a} = Ha$ daje $a(t) = a_0 e^{H(t-t_0)}$, $H^2 = 8\pi G_N\rho/3$; w tym przypadku nie występuje osobliwość krzywizny przy skończonym t.

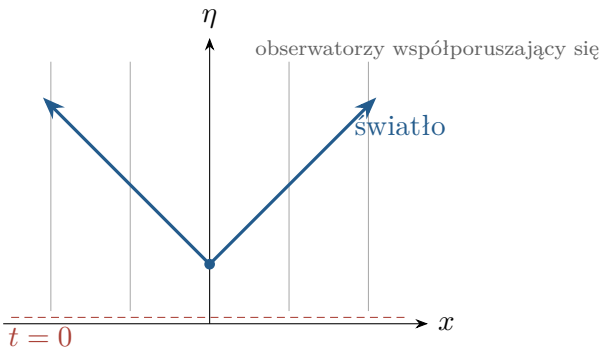


Rysunek 14.4: Czynnik skali dla pyłu (linia ciągła) i promieniowania (linia przerywana), przy $a(t_*) = 1$. Punkt $t = 0$ jest granicą wykresów, a nie punktem rozważanej czasoprzestrzeni.

Przykład 14.7.3 (czas konforemny i geodezyjne świetlne)**.** Dla modelu pyłowego (14.7.5) wprowadźmy *czas konforemny* η przez $\mathrm{d}\eta = \mathrm{d}t/a(t)$. Wybierając $\eta \to 0$ dla $t \to 0^+$, otrzymujemy $\eta = 3t_*^{2/3} t^{1/3}$ oraz

$$g = a(\eta)^2(-\mathrm{d}\eta^2 + \mathrm{d}x^2 + \mathrm{d}y^2 + \mathrm{d}z^2). \tag{14.7.6}$$

Ponieważ metryka jest konforemna do płaskiej metryki Minkowskiego, jej tensor Weyla znika identycznie. Postać promieni świetlnych otrzymujemy bezpośrednio z (13.8.3): dla $\varepsilon = 0$ i $P \neq 0$ mamy $\mathrm{d}\mathbf{x}/\mathrm{d}t = \mathbf{n}/a(t)$. Ponieważ $\mathrm{d}t/\mathrm{d}\eta = a(t)$, reguła łańcuchowa daje $\mathrm{d}\mathbf{x}/\mathrm{d}\eta = \mathbf{n}$. Promienie, rozumiane jako *niesparametryzowane* geodezyjne zerowe, są więc prostymi $\mathbf{x}(\eta) = \mathbf{x}_e + \mathbf{n}(\eta - \eta_e)$, $|\mathbf{n}| = 1$. To nie znaczy, że η jest ich parametrem afinicznym: dla niezerowego pędu P z (13.8.2) mamy $\mathrm{d}\lambda/\mathrm{d}t = a(t)/|P|$.



Rysunek 14.5: Przekrój diagramu konforemnego FLRW. Geodezyjne współporuszające się są pionowe, a promienie świetlne mają nachylenie 45°. Linia $t = 0$ jest brzegiem wybranej czasoprzestrzeni, nie jej przekrojem.

Przykład 14.7.4 (osobliwość Wielkiego Wybuchu: krzywizna i niezupełność)**.** W modelu pyłowym (14.7.5) mamy $\dot{a}/a = 2/(3t)$ i $\ddot{a}/a = -2/(9t^2)$. Wstawienie do (14.5.2)–(14.5.4) daje

$$\begin{aligned} \mathrm{Ric}_{00} &= \frac{2}{3t^2}, & \mathrm{Ric}_{ij} &= \frac{2a(t)^2}{3t^2}\delta_{ij}, \\ \mathrm{Scal} &= \frac{4}{3t^2}, & \mathcal{K} &= \frac{80}{27t^4}. \end{aligned} \tag{14.7.7}$$

Zatem $\mathcal{K} \to +\infty$ przy $t \to 0^+$. Nie jest to osobliwość wynikająca wyłącznie ze złego wyboru współrzędnych: $\mathcal{K}$ jest niezmiennikiem skalarnym, więc żadna zmiana współrzędnych nie może usunąć jego rozbieżności. W szczególności nie istnieje przedłużenie tego rozwiązania przez $t = 0$ jako regularnej metryki lorentzowskiej klasy C^2, przez którą przechodzą te krzywe.

Ten sam problem widać na geodezyjnych. Obserwator współporuszający się ma $\mathrm{d}\tau = \mathrm{d}t$, więc od $t = t_0$ do granicy $t = 0$ upływa skończony czas własny $\Delta\tau = t_0$. Dla geodezyjnej świetlnej z

$P \neq 0$ wzory (13.8.2)–(13.8.3) dają

$$\Delta\lambda = \frac{1}{|P|}\int_0^{t_0} a(t)\,\mathrm{d}t = \frac{3t_0^{5/3}}{5|P|t_*^{2/3}} < \infty.$$

Geodezyjne są więc *niezupełne ku przeszłości*: kończą się po skończonym parametrze afinicznym, choć $M = (0,\infty)\times\mathbb{R}^3$ nie zawiera punktów o $t = 0$.

Warto odróżnić brak wartości wzorów w $t = 0$ od dokładnego wniosku geometrycznego. Dla rozważanego *klasycznego rozwiązania* równań Einsteina z pyłem nie ma regularnego przedłużenia przez tę granicę; nie wynika stąd, że *każde* rozwiązanie równań Einsteina ma osobliwość w $t = 0$ albo że teoria nie opisuje czasów $t > 0$.

Przykład 14.7.5 (czas zespolony a osobliwość w modelu FLRW)**.** Sprawdźmy, czy przedstawienie Poincarégo z Przykładu 11.3.2 pomaga zrozumieć granicę $t \to 0^+$ modelu pyłowego. Dla metryki (11.3.6) z (14.7.5),

$$g = -\mathrm{d}t^2 + \left(\frac{t}{t_*}\right)^{4/3}(\mathrm{d}x^2+\mathrm{d}y^2+\mathrm{d}z^2), \qquad t>0.$$

Po formalnym podstawieniu $\zeta = \mathrm{i}t$, czyli $t = -\mathrm{i}\zeta$, otrzymujemy

$$g = \mathrm{d}\zeta^2 + \left(\frac{-\mathrm{i}\zeta}{t_*}\right)^{4/3}(\mathrm{d}x^2+\mathrm{d}y^2+\mathrm{d}z^2). \tag{14.7.8}$$

Na obrazie rzeczywistej półprostej $t > 0$ mamy $\zeta \in \mathrm{i}(0,\infty)$; zapis ten nadal reprezentuje tę samą metrykę lorentzowską. Aby wyjść poza tę półprostą w płaszczyźnie zespolonej, trzeba wybrać gałąź funkcji $z^{4/3}$; punkt $z = 0$ jest punktem rozgałęzienia.

Nie jest to automatycznie *obrót Wicka*. W tym drugim zabiegu próbuje się analitycznie kontynuować rozwiązanie do $t = -\mathrm{i}\tau$, $\tau \in \mathbb{R}$, a następnie otrzymać rzeczywistą metrykę riemannowską. W naszym przypadku dla $\tau > 0$ na gałęzi głównej dostajemy jedynie zespoloną formę

$$g_{\mathrm{E}}^{\mathrm{formal}} = \mathrm{d}\tau^2 + e^{-2\pi\mathrm{i}/3}\left(\frac{\tau}{t_*}\right)^{4/3}(\mathrm{d}x^2+\mathrm{d}y^2+\mathrm{d}z^2),$$

która nie jest rzeczywistą metryką riemannowską.

Co ważniejsze, kontynuowanie samego niezmiennika Kretschmanna z (14.7.7) daje

$$\mathcal{K}(-\mathrm{i}\zeta) = \frac{80}{27\zeta^4}, \qquad \mathcal{K}(-\mathrm{i}\tau) = \frac{80}{27\tau^4}.$$

W pierwszym wzorze $\zeta = \mathrm{i}t$ i stosujemy $\mathcal{K}(t) = 80/(27t^4)$, a w drugim kontynuujemy bezpośrednio $t \mapsto -\mathrm{i}\tau$. W obu zapisach biegun czwartego rzędu pozostaje w początku. Kontynuacja formalnego wzoru na niezmiennik nie zapewnia wprawdzie istnienia rzeczywistej metryki, ale wyklucza usunięcie tej rozbieżności przez samo przemianowanie czasu.

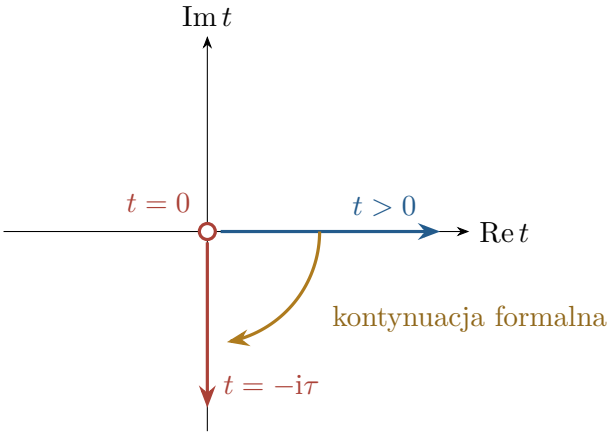
Nie twierdzimy, że każde rozwiązanie równań Einsteina jest osobliwe. Wniosek dotyczy tej konkretnej metryki pyłowej oraz jej rozbieżnych niezmienników krzywizny. W innych geometriach można uzyskać regularne kontynuacje euklidesowe, ale wymaga to osobnej konstrukcji.

Przykład 14.7.6 (dlaczego zanik czynnika skali nie wystarcza)**.** Dla porównania rozważmy na $t > 0$ metrykę

$$g = -\mathrm{d}t^2 + t^2\bigl(\mathrm{d}\chi^2 + \sinh^2\chi\,(\mathrm{d}\theta^2 + \sin^2\theta\,\mathrm{d}\phi^2)\bigr).$$

Ma ona czynnik skali $a(t) = t$ i ujemną krzywiznę przekrojów przestrzennych (model Milne'a). Podstawienie $T = t\cosh\chi$, $R = t\sinh\chi$ daje

$$g = -\mathrm{d}T^2 + \mathrm{d}R^2 + R^2(\mathrm{d}\theta^2 + \sin^2\theta\,\mathrm{d}\phi^2),$$



Rysunek 14.6: Schemat płaszczyzny czasu zespolonego. Dodatnia półprosta rzeczywista odpowiada fizycznemu czasowi modelu FLRW, a półprosta ujemnie urojona ilustruje próbę obrotu Wicka. Punkt $t = 0$ pozostaje osobliwy; łuk przedstawia kontynuację formalną, nie izometrię rzeczywistych czasoprzestrzeni.

czyli metrykę Minkowskiego we wnętrzu przyszłego stożka świetlnego. Tensor Riemanna znika identycznie; pozorny problem przy $a(0) = 0$ wynika tutaj z niepełnego pokrycia współrzędnymi, a nie z rozbieżności krzywizny. Wzór (14.5.4) dotyczył wyłącznie przestrzennie płaskiego modelu FLRW i nie wolno go stosować do tej metryki.

Jeszcze inny kontrast stanowi płaski przestrzennie model z promieniowaniem: $a(t) \sim t^{1/2}$, dla którego $\mathrm{Scal} = 0$, ale $\mathcal{K} = 3/(2t^4) \to \infty$. Sam brak rozbieżności krzywizny skalarnej nie świadczy zatem o regularności czasoprzestrzeni.

14.8 Kiedy metryka jest naprawdę płaska?

Twierdzenie 14.8.1 (lokalna charakteryzacja płaskości)**.** *Niech (M, g) będzie rozmaitością riemannowską i $p \in M$. Następujące warunki są równoważne w odpowiednio małym otoczeniu p:*

(i) *tensor Riemanna znika: $R \equiv 0$;*

(ii) *transport równoległy jest lokalnie niezależny od drogi o ustalonych końcach;*

(iii) *istnieje ortonormalna rama pól równoległych $E_1, \dots, E_n$;*

(iv) *istnieją współrzędne $(x^1, \dots, x^n)$, w których $g = \sum_i (\mathrm{d}x^i)^2$;*

(v) *otoczenie p jest izometryczne z otwartym podzbiorem $\mathbb{R}^n$.*

Ponadto $R = 0$ wtedy i tylko wtedy, gdy $K_p(\sigma) = 0$ dla każdej płaszczyzny stycznej we wszystkich punktach tego otoczenia. W przypadku pseudoriemannowskim równoważność warunków (i)–(iii) *i wersji* (iv) *z metryką stałą właściwej sygnatury jest taka sama.*

Dowód. Wybierzmy małą, ściągalną kulę współrzędnych U wokół p. Załóżmy (i). Pokażemy dokładnie, dlaczego transport po różnych drogach daje to samo. Niech $H(s,t)$ będzie gładką homotopią dróg od p do ustalonego $q \in U$, z nieruchomymi końcami, $0 \le s,t \le 1$. Przenieśmy $v \in T_pM$ równolegle wzdłuż każdej drogi $t \mapsto H(s,t)$; oznaczmy otrzymane pole wzdłuż H przez $V(s,t)$. Mamy $\nabla_t V = 0$. Także gdy H nie jest immersją, pochodne pól wzdłuż H spełniają regułę komutacji. Współrzędnie mają postać $D_\alpha = \partial_\alpha + A_\alpha$, gdzie $A_\alpha = \Gamma_i(H)\partial_\alpha H^i$.

Rozwinięcie komutatora daje $[D_t, D_s] = \partial_t A_s - \partial_s A_t + [A_t, A_s] = R(\partial_t H, \partial_s H)$: mieszane drugie pochodne H znoszą się, a pozostałe składniki są dokładnie wzorem (14.1.2). Stąd

$$\nabla_t(\nabla_s V) = \nabla_s(\nabla_t V) + R(\partial_t H, \partial_s H)V = 0.$$

Na początku $V(s,0) = v$, stąd $\nabla_s V(s,0) = 0$. Jednoznaczność równania transportu równoległego wzdłuż t daje $\nabla_s V(s,t) = 0$ dla każdego t, zwłaszcza przy $t = 1$. Transport jest więc niezależny od homotopii z ustalonymi końcami. W wypukłym obrazie kuli współrzędnych dwie drogi łączymy homotopią liniową $H(s,t) = x^{-1}((1-s)x(\gamma_0(t)) + sx(\gamma_1(t)))$. Zachowuje ona końce. Dla dróg odcinkami gładkich wybieramy wspólny skończony podział parametru t; powyższy rachunek stosujemy kolejno na jego przedziałach. Na łączeniach wartości V i $\nabla_s V$ są zgodne, więc argument przechodzi przez cały podział. Dowodzi to (ii).

Wybierzmy ortonormalną bazę $e_1, \dots, e_n$ w T_pM i przenieśmy każdy e_i do $q \in U$. Niezależność od drogi definiuje pole $E_i(q)$; transport po radialnych drogach zależy gładko od końca, więc E_i są gładkie. Idąc najpierw do q, a potem po dowolnej krótkiej krzywej przez q, widzimy $\nabla_X E_i = 0$ dla wszystkich X. Zgodność koneksji z metryką zachowuje iloczyny skalarne: $g(E_i, E_j) = \delta_{ij}$ na U. Otrzymaliśmy (iii).

Koneksja Leviego-Civity nie ma torsji, więc

$$[E_i, E_j] = \nabla_{E_i} E_j - \nabla_{E_j} E_i = 0.$$

Przepływy komutujących pól komutują lokalnie. Odwzorowanie otrzymane przez wykonanie po kolei ich przepływów z czasami $x^1, \dots, x^n$, zaczynając od p, jest lokalnym dyfeomorfizmem (jego różniczka w zerze wysyła bazę standardową na $E_i(p)$). Komutowanie przepływów sprawia, że w powstałych współrzędnych $E_i = \partial_i$. Stąd $g_{ij} = g(E_i, E_j) = \delta_{ij}$, czyli (iv). Odwzorowanie współrzędnych jest wtedy izometrią na otwarty podzbiór $\mathbb{R}^n$, więc (iv) daje (v). Izometria zachowuje koneksję i R, a w $\mathbb{R}^n$ standardowa koneksja ma $R = 0$: (v) daje (i). Implikacje (iii)⇒(ii) można też sprawdzić bezpośrednio: współczynniki wektora w ramie równoległej nie zmieniają się podczas transportu.

Jeśli $R = 0$, wzór (14.2.3) daje $K = 0$. Odwrotność jest dokładnie krokiem polaryzacji w dowodzie Twierdzenia 14.4.3 dla $\kappa = 0$. W sygnaturze pseudoriemannowskiej wybieramy bazę ortonormalną z $g(e_i, e_i) = \pm 1$; reszta dowodu pozostaje bez zmian, a metryka w współrzędnych ma stałe współczynniki ± 1. □

Wniosek 14.8.2 (niski wymiar a płaskość)**.** *Na powierzchni riemannowskiej* Scal $= 0$ *w otoczeniu wtedy i tylko wtedy, gdy metryka jest tam lokalnie płaska. W wymiarze trzy wystarcza* Ric $= 0$ *w otoczeniu. W wymiarze cztery dla metryk lorentzowskich* Ric $= 0$ *nie wymusza już płaskości.*

Dowód. W wymiarze dwa Scal $= 2K$ na mocy Stwierdzenia 14.4.2; stosujemy Twierdzenie 14.8.1. W wymiarze trzy i przy Ric $= 0$ wybierzmy *dowolną* bazę ortonormalną e_1, e_2, e_3. Oznaczając $K_{ij} = K(e_i \wedge e_j)$, dostajemy z (14.4.3)

$$K_{12} + K_{13} = 0, \qquad K_{12} + K_{23} = 0, \qquad K_{13} + K_{23} = 0.$$

Po odjęciu dwóch pierwszych równań mamy $K_{13} = K_{23}$; trzecie wymusza $K_{13} = K_{23} = 0$, a pierwsze daje $K_{12} = 0$. Każda płaszczyzna w T_pM może być pierwszą płaszczyzną pewnej bazy ortonormalnej; skoro baza była dowolna, wszystkie krzywizny sekcyjne znikają. Twierdzenie 14.8.1 daje płaskość. Odwrotne implikacje są oczywiste, bo $R = 0$ pociąga oba zerowe ślady. Kontrprzykłady w wymiarze cztery dają (14.6.2) i (14.6.5): są lorentzowskie i mają Ric $= 0$ przy $R \neq 0$. □

Uwaga 14.8.3 (lokalnie a globalnie). Twierdzenie jest lokalne. Płaski torus $\mathbb{R}^2/\mathbb{Z}^2$ ma $R = 0$ i lokalnie wygląda jak płaszczyzna, lecz globalnie ma inną topologię i nie jest izometryczny z całą $\mathbb{R}^2$. Walec z Przykładu 14.3.3 również jest lokalnie płaski. Sama równość $\mathrm{Scal} = 0$ jest znacznie słabsza od $R = 0$, co pokazują przykłady Schwarzschilda i Kerra.

14.9 Holonomia: transport po wszystkich pętlach

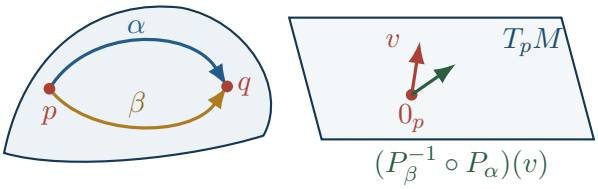
W Uwadze 14.1.3 jedna mała pętla wykrywała krzywiznę w punkcie. Teraz ustalimy punkt p i zbierzemy transporty po *wszystkich* pętlach zaczynających się w p. W ten sposób lokalny pomiar krzywizny łączy się z globalną budową metryki. W całej sekcji (M, g) jest spójną rozmaitością riemannowską bez brzegu, a P_γ oznacza transport Leviego-Civity z Twierdzenia 12.4.2.

Definicja 14.9.1 (Pełna i ograniczona grupa holonomii)**.** *Grupą holonomii* w p nazywamy

$$\mathrm{Hol}_p(M, g) = \{P_\gamma : T_pM \longrightarrow T_pM : \ \gamma \text{ jest pętlą odcinkami gładką z bazą } p\}.$$

Jej podzbiór otrzymany tylko z pętli ściągalnych z zachowaniem punktu bazowego oznaczamy przez $\mathrm{Hol}_p^0(M, g)$ i nazywamy *holonomią ograniczoną*. Transport po pętli jest izometrią T_pM, więc obie grupy działają na tej samej euklidesowej przestrzeni stycznej. Nazwa "ograniczona" dotyczy rodzaju pętli, a nie ograniczenia długości pętli.

Intuicja jest następująca: dwa sposoby przeniesienia wektora z p do q mogą dać różne wyniki. Po powrocie z q do p ich różnica staje się elementem holonomii. Na płaszczyźnie euklidesowej nie ma takiej różnicy; na sferze może ona być obrotem, jak na Rysunku 14.1.



Rysunek 14.7: Dwie drogi z p do q. Po przejściu α i powrocie wzdłuż β wynik w T_pM wynosi $(P_\beta^{-1} \circ P_\alpha)(v)$; rysunek nie wyznacza wielkości obrotu ani kąta między drogami.

Stwierdzenie 14.9.2 (Działanie pętli i zmiana punktu bazowego)**.** *Zbiory z Definicji 14.9.1 są podgrupami $O(T_pM)$, a Hol_p^0 jest podgrupą normalną Hol_p. Jeśli α prowadzi z p do q, to*

$$\mathrm{Hol}_q = \{P_\alpha \circ A \circ P_\alpha^{-1} : A \in \mathrm{Hol}_p\}. \tag{14.9.1}$$

Gdy M jest jednospójna, $\mathrm{Hol}_p^0 = \mathrm{Hol}_p$.

Dowód. Stała pętla daje identyczność. Jeśli najpierw idziemy po γ, a potem po δ, jednoznaczność równania transportu daje $P_{\gamma \text{ potem } \delta} = P_\delta \circ P_\gamma$. Przejście pętli w przeciwnym kierunku rozwiązuje to samo równanie od końca, więc $P_{\gamma^{-1}} = P_\gamma^{-1}$. Pokazuje to domknięcie na iloczyny i odwrotności. Zgodność koneksji z metryką daje $g_p(P_\gamma v, P_\gamma w) = g_p(v, w)$, a więc $P_\gamma \in O(T_pM)$.

Sklejenie pętli ściągalnych i odwrócenie jednej z nich zachowuje ściągalność. Sprzężenie pętli ściągalnej dowolną pętlą także jest ściągalne: najpierw wykonujemy drogę sprzęgającą, następnie skurcz środkowej pętli, a na końcu wracamy po drodze odwrotnej. To dowodzi normalności. Każda pętla przy q po dodaniu na początku α i na końcu α^{-1} staje się pętlą przy p. Rozpisanie transportów i odwrócenie tej operacji daje (14.9.1). Na rozmaitości jednospójnej każda pętla jest ściągalna. □

Sama homotopijność dwóch pętli *nie* oznacza, że mają identyczny transport: na sferze nawet pętle ściągalne mogą obracać wektor. W płaskiej geometrii ograniczona holonomia znika i wtedy topologia może pozostać jedynym źródłem niezerowej holonomii.

Stwierdzenie 14.9.3 (Płaskość a holonomia ograniczona)**.** *Dla spójnej rozmaitości riemannowskiej*

$$R \equiv 0 \quad \Longleftrightarrow \quad \mathrm{Hol}_p^0 = \{\mathrm{id}_{T_pM}\}.$$

Dowód. Jeżeli $R = 0$, weźmy homotopię $H(s,t)$ pętli γ do pętli stałej, z nieruchomym punktem bazowym. Przenieśmy v równolegle wzdłuż każdej krzywej $t \mapsto H(s,t)$, otrzymując $V(s,t)$. Rachunek komutatora pochodnych kowariantnych z dowodu Twierdzenia 14.8.1 daje $\nabla_t \nabla_s V = R(\partial_t H, \partial_s H)V = 0$. Na początku $\nabla_s V(s,0) = 0$, więc przez jednoznaczność transportu $\nabla_s V(s,1) = 0$. Wynik transportu nie zmienia się podczas homotopii i przy pętli stałej wynosi v. Rachunek stosuje się na skończonym podziale parametrów, gdy homotopia jest tylko odcinkami gładka.

Odwrotnie każda mała pętla z Uwagi 14.1.3 jest ściągalna. Przy trywialnej holonomii ograniczonej jej transport jest identycznością. Dla dowolnych $X, Y, v \in T_qM$ wzór tamże daje $0 = -\varepsilon^2 R_q(X,Y)v + O(\varepsilon^3)$. Po podzieleniu przez ε^2 i przejściu do granicy mamy $R_q(X,Y)v = 0$. Punkt q był dowolny: trywialność w p przenosi się na q przez sprzężenie (14.9.1), także dla pętli ściągalnych. Zatem $R \equiv 0$. □

Przykład 14.9.4 (Płaski torus i płaska butelka Kleina)**.** Na $T^2 = \mathbb{R}^2/\mathbb{Z}^2$ standardowe pola ∂_x, ∂_y schodzą do globalnej ramy równoległej. Transport zachowuje ich współczynniki, więc $\mathrm{Hol}_p(T^2) = \{1\}$, choć torus nie jest jednospójny.

Inaczej jest dla płaskiej butelki Kleina

$$K = \mathbb{R}^2/\langle a, b\rangle, \qquad a(x,y) = (x+1, y), \qquad b(x,y) = (-x, y+1).$$

Te izometrie generują swobodne, dyskretne działanie; prostokąt podstawowy po sklejeniu boków daje zwartą rozmaitość. Pętla w K podnosi się do drogi w $\mathbb{R}^2$ od $\widetilde{p}$ do $h\widetilde{p}$ dla pewnego przekształcenia h z tej grupy. W $\mathbb{R}^2$ transport zachowuje współrzędne wektora, a identyfikacja przestrzeni stycznych na końcu używa Dh^{-1}. Ponieważ $Da = I$ i $Db = \mathrm{diag}(-1,1)$, dostajemy

$$\mathrm{Hol}_p(K) = \{I, \mathrm{diag}(-1,1)\}, \qquad \mathrm{Hol}_p^0(K) = \{I\}.$$

Obie metryki są lokalnie płaskie. Butelka pokazuje, że $R = 0$ nie wymusza trywialności *pełnej* holonomii.

Przykład 14.9.5 (Holonomia okrągłej sfery)**.** Na zorientowanej S^2_R transport zachowuje orientację: jego wyznacznik zmienia się ciągle wzdłuż drogi, a na początku wynosi 1. Zatem $\mathrm{Hol}_p(S^2_R) \subset SO(T_pS^2_R)$. W Przykładzie 12.4.3 obliczyliśmy, że obieg równoleżnika o kącie biegunowym θ daje obrót o $-2\pi\cos\theta$ modulo 2π. Aby przenieść tę pętlę do ustalonego punktu p, dochodzimy z p do równoleżnika, wykonujemy obieg i wracamy tą samą drogą. Otrzymany obrót jest sprzężony z poprzednim przez izometrię zachowującą orientację. W $SO(2)$ takie sprzężenie nie zmienia kąta. Gdy $0 < \theta < \pi$, wartości $-2\pi\cos\theta$ modulo 2π obejmują wszystkie kąty. Stąd $\mathrm{Hol}_p(S^2_R) = SO(T_pS^2_R)$. Sfera jest jednospójna, więc jest to także jej holonomia ograniczona. Nie ma na niej niezerowego globalnego pola równoległego.

Uwaga 14.9.6 (Krzywizna wytwarza holonomię). Wzór z Uwagi 14.1.3 pokazuje, że $R_p(X,Y)$ jest kierunkiem nieskończenie małych transportów po pętlach ściągalnych. Dokładną wersją jest *twierdzenie Ambrose'a–Singera*: algebra Liego grupy Hol_p^0 jest rozpięta nad $\mathbb{R}$ przez operatory

$$P_\gamma^{-1} \circ R_q(u,v) \circ P_\gamma, \qquad \gamma : p \longrightarrow q, \quad u, v \in T_qM.$$

Algebra Liego, wprowadzona w Sekcji 15.2, to tutaj przestrzeń kierunków stycznych do grupy w identyczności; fakt, że holonomia ograniczona ma strukturę grupy Liego, także należy do cytowanego wyniku o holonomii. Jedno zawieranie sugeruje rachunek małej pętli; odwrotne jest głęboką częścią twierdzenia, której nie dowodzimy. Źródłem jest W. Ambrose i I. M. Singer, *A theorem on holonomy*, Trans. Amer. Math. Soc. 75 (1953), 428–443.

14.10 Niezmienniki holonomii i rozkład de Rhama

Twierdzenie de Rhama z Rozdziału 10 porównuje kohomologię form z kohomologią singularną. *Twierdzenie o rozkładzie de Rhama* jest innym wynikiem: rozpoznaje w metryce iloczyn czynników na podstawie transportu równoległego. Najpierw udowodnimy część lokalną i zobaczymy dokładnie, gdzie zaczyna się krok globalny.

Stwierdzenie 14.10.1 (Zasada holonomii dla pól równoległych)**.** *Niech E będzie wiązką tensorową nad spójną M, z koneksją indukowaną przez ∇. Wartość w p zadaje bijekcję*

$$\{s \in \Gamma(E) : \nabla s = 0\} \longleftrightarrow (E_p)^{\mathrm{Hol}_p},$$

gdzie po prawej stoją elementy zachowywane przez transport po wszystkich pętlach w p.

Dowód. Jeśli s jest równoległy, ograniczenie s do każdej krzywej rozwiązuje równanie transportu. Dla pętli γ przy p mamy więc $P_\gamma s(p) = s(p)$.

Odwrotnie wybierzmy $a \in E_p$ stały pod całą holonomią i połóżmy $s(q) = P_\alpha a$, gdzie α prowadzi z p do q. Jeśli β jest drugą taką drogą, to $P_\beta^{-1} \circ P_\alpha$ jest transportem po pętli przy p. Z niezmienniczości a wynika $P_\alpha a = P_\beta a$; definicja jest niezależna od drogi. W małym otoczeniu q_0 możemy dołączyć do ustalonej drogi $p \to q_0$ krótkie odcinki promieniowe zależne gładko od końca. Gładka zależność rozwiązań równania transportu od parametrów dowodzi, że s jest gładki. Dla każdej krzywej $c : q \to r$ dołączamy c do drogi $p \to q$ i dostajemy $P_c s(q) = s(r)$. Zatem s jest równoległy. Obie konstrukcje są wzajemnie odwrotne. □

W szczególności podprzestrzeń niezmienniczą przez holonomię $W \subset T_pM$ można przenosić do innych punktów: $\mathcal{E}_q = P_\alpha W$. Gdy W jest właściwy i niezerowy, działanie holonomii na T_pM nazywamy *redukowalnym*. Ponieważ transport jest izometrią, dopełnienie ortogonalne $W^\perp$ też jest niezmiennicze. Na przykład w iloczynie $S^2_R \times \mathbb{R}$ kierunek czynnika $\mathbb{R}$ jest niezmienniczy; sprawdzimy to niżej.

Twierdzenie 14.10.2 (Lokalny rozkład metryki)**.** *Niech (M, g) będzie spójną rozmaitością riemannowską, a $W \subset T_pM$ niezerową właściwą podprzestrzenią niezmienniczą względem* pełnej *grupy* Hol_p*. Istnieją wtedy gładkie, prostopadłe i równoległe rozkłady $TM = \mathcal{E} \oplus \mathcal{F}$, przy czym $\mathcal{E}_p = W$ i $\mathcal{F}_p = W^\perp$. W otoczeniu każdego punktu istnieją współrzędne $(x^1, \dots, x^k, y^1, \dots, y^{n-k})$, w których*

$$\mathcal{E} = \operatorname{span}(\partial_{x^i}), \quad \mathcal{F} = \operatorname{span}(\partial_{y^a}), \quad g = \sum_{i,j} g_{ij}(x)\,\mathrm{d}x^i \mathrm{d}x^j + \sum_{a,b} h_{ab}(y)\,\mathrm{d}y^a \mathrm{d}y^b. \tag{14.10.1}$$

Liście obu rozkładów są całkowicie geodezyjne. Jeśli M jest zupełna, liście są również zupełne w swoich metrykach indukowanych.

Dowód. Krok 1: przeniesienie podprzestrzeni. Dla $q \in M$ wybieramy drogę $\alpha : p \to q$ i definiujemy $\mathcal{E}_q = P_\alpha W$, $\mathcal{F}_q = P_\alpha W^\perp$. Gdy wybierzemy inną drogę β, operator $P_\beta^{-1} \circ P_\alpha$ należy do Hol_p i zachowuje obie podprzestrzenie. Otrzymane przestrzenie w T_qM nie zależą więc od drogi. Na małej kuli używamy dróg promieniowych; gładka zależność transportu od końca pokazuje,

że $\mathcal{E}, \mathcal{F}$ są gładkimi podwiązkami. Ich włókna są prostopadłe i dopełniające się, bo transport zachowuje g. Jeśli c jest krzywą z q do r, dołączenie jej do drogi z p do q daje $P_c\mathcal{E}_q = \mathcal{E}_r$ i analogicznie dla $\mathcal{F}$. Różniczkując wzdłuż krótkiej krzywej, otrzymujemy $\nabla_X Y \in \Gamma(\mathcal{E})$ dla $Y \in \Gamma(\mathcal{E})$ i dowolnego X; to samo zachodzi dla $\mathcal{F}$.

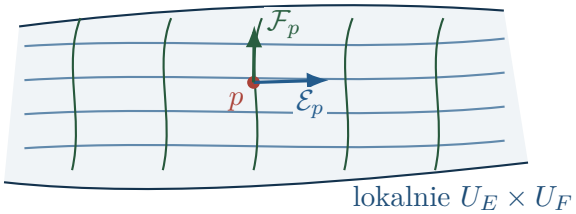
Krok 2: lokalne współrzędne produktu. Ponieważ koneksja Leviego-Civity nie ma torsji, dla $X, Y \in \Gamma(\mathcal{E})$ zachodzi $[X,Y] = \nabla_X Y - \nabla_Y X \in \Gamma(\mathcal{E})$. To samo dotyczy $\mathcal{F}$. Z lokalnego twierdzenia Frobeniusa 2.5.5 oba rozkłady mają liście. Z lokalnej postaci Frobeniusa dla $\mathcal{E}$ dostajemy submersję $f : U \to \mathbb{R}^{n-k}$ z $\ker Df = \mathcal{E}$. Analogicznie dla $\mathcal{F}$ dostajemy $h : U \to \mathbb{R}^k$ z $\ker Dh = \mathcal{F}$. Jądro różniczki $(h,f) : U \to \mathbb{R}^k \times \mathbb{R}^{n-k}$ jest równe $\mathcal{F} \cap \mathcal{E} = \{0\}$. Dziedzina i przeciwdziedzina mają ten sam wymiar, więc twierdzenie o funkcji odwrotnej mówi, że (h,f) jest lokalnym dyfeomorfizmem. W jego współrzędnych $(x,y) = (h,f)$ rozkład $\mathcal{E}$ rozpinają ∂_{x^i}, a $\mathcal{F}$ pola ∂_{y^a}.

Prostopadłość daje $g_{ia} = 0$. Równoległość rozkładów daje $\nabla_{\partial_{x^i}} \partial_{y^a} \in \mathcal{F}$ oraz $\nabla_{\partial_{y^a}} \partial_{x^i} \in \mathcal{E}$. Pola współrzędnych komutują, a torsja jest zerowa, więc obie te pochodne kowariantne są sobie równe. Należą jednocześnie do prostopadłych przestrzeni o przecięciu $\{0\}$; obie muszą zatem znikać. Z $\nabla g = 0$ wynika

$$\partial_{y^a} g_{ij} = g(\nabla_{\partial_{y^a}} \partial_{x^i}, \partial_{x^j}) + g(\partial_{x^i}, \nabla_{\partial_{y^a}} \partial_{x^j}) = 0.$$

Analogicznie $\partial_{x^i} h_{ab} = 0$. To dowodzi dokładnie postaci (14.10.1).

Krok 3: liście. Jeśli γ jest geodezyjną liścia $\mathcal{E}$, jej przyspieszenie w M też jest zerowe, gdyż $\nabla_X Y$ dla stycznych pól pozostaje w $\mathcal{E}$. Liść jest więc całkowicie geodezyjny; podobnie dla $\mathcal{F}$. Przy zupełności M geodezyjna γ ma przedłużenie dla wszystkich czasów na mocy Twierdzenia 13.5.3. Jej prędkość pozostaje w $\mathcal{E}$, bo jest równoległa i rozkład jest równoległy. Przedłużenie pozostaje w tym samym liści. Każda geodezyjna liścia przedłuża się więc bez końca, co dowodzi jego zupełności. □



Rysunek 14.8: Schematyczny dwuwymiarowy przekrój układu liści dwóch prostopadłych rozkładów równoległych. Niebieskie krzywe przedstawiają kierunki $\mathcal{E}$, zielone kierunki $\mathcal{F}$. Siatka ilustruje lokalny iloczyn; warunki potrzebne do iloczynu globalnego podaje Twierdzenie 14.10.3.

Twierdzenie 14.10.3 (Globalny rozkład de Rhama — wynik zewnętrzny)**.** *Niech (M,g) będzie* spójną, zupełną i jednospójną *rozmaitością riemannowską bez brzegu. Jeśli pełna holonomia zachowuje właściwą niezerową podprzestrzeń $W \subset T_pM$, to M jest izometryczna z iloczynem riemannowskim liści przez p dwóch równoległych rozkładów odpowiadających W i $W^\perp$. Powtarzając rozkład, otrzymujemy*

$$(M,g) \cong (\mathbb{R}^k, g_{\text{eukl}}) \times (M_1, g_1) \times \cdots \times (M_r, g_r), \tag{14.10.2}$$

gdzie czynniki M_i są zupełne, jednospójne i mają nieredukowalną nietrywialną holonomię. Czynnik euklidesowy oraz czynniki nieredukowalne są jednoznaczne z dokładnością do izometrii i przestawienia tych drugich.

W Twierdzeniu 14.10.2 udowodniliśmy konstrukcję rozkładów, lokalną postać metryki i zupełność liści. Pozostaje głęboki krok: wykazanie, że lokalne prostokąty liści sklejają się jednoznacznie w *globalny* iloczyn tych liści. Tu zupełność pozwala przedłużać geodezyjne, a jednospójność

usuwa zależność sklejenia od obiegu pętli. Nie utożsamiamy tego wyjaśnienia z dowodem kroku globalnego. Dokładne twierdzenie i jego dowód podaje G. de Rham, *Sur la réductibilité d'un espace de Riemann*, Comment. Math. Helv. 26 (1952), 328–344; inny szczegółowy dowód daje H. Wu, *On the de Rham decomposition theorem*, Illinois J. Math. 8 (1964), 291–311. Twierdzenie 14.10.3 dotyczy metryk *riemannowskich*; przy sygnaturze nieokreślonej nie wolno bez dodatkowych warunków przenosić tej wersji.

W szczególności maksymalna przestrzeń nieruchomych wektorów $(T_pM)^{\mathrm{Hol}_p}$ ma wymiar k czynnika $\mathbb{R}^k$ w (14.10.2). To wynika z Zasady 14.10.1: baza wektorów nieruchomych przedłuża się do równoległych pól, które są kierunkami euklidesowymi. Na czynniku o nietrywialnej niereducowalnej holonomii nie ma niezerowego wektora nieruchomego, bo jego prosta byłaby niezmienniczą podprzestrzenią; w wymiarze jeden jednospójny zupełny czynnik jest prostą i należy do części euklidesowej.

Przykład 14.10.4 (Produkt sfery i prostej)**.** Weźmy $S^2_R \times \mathbb{R}$ z metryką $g_{S^2_R} + \mathrm{d}t^2$. Jest to rozmaitość zupełna i jednospójna. Dla pól pochodzących z obu czynników wzór Koszula (12.2.1) daje $\nabla_{(X,0)}(Y,0) = (\nabla^S_X Y, 0)$, $\nabla_{(0,\partial_t)}(0,\partial_t) = 0$ oraz zerowe pochodne mieszane. Równanie transportu rozpada się więc na dwa niezależne równania:

$$P_\gamma(v, a\partial_t) = (P^S_{\gamma_S} v, a\partial_t), \qquad \mathrm{Hol}_{(q,t)}(S^2_R \times \mathbb{R}) = SO(T_q S^2_R) \times \{1\}.$$

Ostatnia równość korzysta z Przykładu 14.9.5; każdą pętlę na sferze można wykonać przy stałym t. Pole ∂_t jest równoległe. Z (14.4.7) albo z rozszczepienia koneksji wynika, że płaszczyzny styczne do sfery mają $K = R^{-2}$, a płaszczyzny mieszane, zawierające ∂_t, mają $K = 0$. To jawny obraz redukowalnej holonomii i dwóch czynników rozkładu de Rhama.

Przykład 14.10.5 (Po co potrzebne są założenia globalne?)**.** Płaski torus i płaska butelka Kleina z Przykładu 14.9.4 są zupełne, ale niejednospójne. Ich lokalne metryki mają postać $\mathrm{d}x^2 + \mathrm{d}y^2$, natomiast nie są globalnie izometryczne z $\mathbb{R}^2$: są zwarte. Butelka ma nawet dwie równoległe proste w każdej przestrzeni stycznej, lecz nie jest iloczynem dwóch jednowymiarowych rozmaitości: zwarty iloczyn takich czynników byłby torusem, a butelka Kleina jest nieorientowalna.

Zupełność też ma znaczenie. Dysk otwarty $D = \{(x,y) : x^2 + y^2 < 1\} \subset \mathbb{R}^2$ z metryką euklidesową jest jednospójny, płaski i ma dwa stałe ortogonalne rozkłady. Nie jest jednak globalnym iloczynem liści poziomego i pionowego przez 0: oba liście są przedziałami $(-1,1)$, a ich iloczyn jest kwadratem, nie dyskiem z metryką produktu. Geodezyjna radialna kończy się na brzegu w skończonym czasie, więc D nie jest zupełny.

Uwaga 14.10.6 (Most do teorii Hodge'a). Na zwartej, spójnej, zorientowanej rozmaitości riemannowskiej bez brzegu z $\mathrm{Ric} \geq 0$ Wniosek 18.3.3 mówi, że każda harmoniczna 1-forma jest równoległa. Odwrotnie forma równoległa ma $\mathrm{d}\alpha = 0$ i $\delta\alpha = 0$, więc jest harmoniczna. Twierdzenie Hodge'a z Wniosku 18.2.4 oraz Zasada 14.10.1 dają zatem

$$b_1(M) = \dim H^1_{\mathrm{dR}}(M) = \dim (T_pM)^{\mathrm{Hol}_p}.$$

Pierwsza liczba jest topologiczna, ostatnia odczytuje równoległe kierunki z holonomii. Nie jest to ponowny dowód kohomologicznego twierdzenia de Rhama.

14.11 Druga wariacja energii i pola Jacobiego

Pierwsza wariacja z Twierdzenia 13.1.3 mówi, *gdzie* długość może mieć minimum: krzywa minimalna, po parametryzacji długością łuku, jest geodezyjną. Drugie różniczkowanie mówi, *czy w pobliżu geodezyjnej istnieje kierunek*, w którym energia maleje. Krzywizna pojawia się tu dlatego, że zamiana kolejności dwóch pochodnych *kowariantnych* wzdłuż wariacji nie jest na ogół dozwolona bez poprawki R.

W całej sekcji (M,g) jest rozmaitością *riemannowską*, ∇ jej koneksją Leviego-Civity, a znak R jest ustalony w (14.1.1). Nie przenosimy wniosków o minimizowaniu odległości na całe czasoprzestrzenie lorentzowskie.

Drugie różniczkowanie energii

Niech $\gamma:[0,\ell]\to M$ będzie geodezyjną o prędkości 1, gdzie $\ell>0$, więc $\ell=L_g(\gamma)$. Rozważmy gładką rodzinę $F(s,t)$ krzywych o stałych końcach $F(s,0)=p$, $F(s,\ell)=q$, $F(0,t)=\gamma(t)$, i jej pole wariacyjne $V(t)=\partial_s F(0,t)$. W szczególności $V(0)=V(\ell)=0$. Piszemy D_t oraz D_s na pochodne kowariantne pól wzdłuż powierzchni parametrów F.

Twierdzenie 14.11.1 (Druga wariacja energii)**.** *Dla powyższej wariacji, przy energii z* (11.4.1)*, zachodzi*

$$\frac{\mathrm{d}^2}{\mathrm{d}s^2}E_g(F_s)\bigg|_{s=0}=\int_0^\ell\Big(|D_tV|_g^2-g(R(V,T)T,V)\Big)\,\mathrm{d}t,\qquad T=\dot\gamma. \tag{14.11.1}$$

Prawą stronę oznaczamy przez $I(V,V)$. Jej postać dwuliniowa, zwana formą indeksową*, to*

$$I(V,W)=\int_0^\ell\big(g(D_tV,D_tW)-g(R(V,T)T,W)\big)\,\mathrm{d}t \tag{14.11.2}$$

dla pól V,W zerujących się na końcach.

Dowód. Oznaczmy na całej powierzchni wariacji $S=\partial_sF$ i $U=\partial_tF$. Zgodność koneksji z metryką daje, dla każdego s,

$$\frac{\mathrm{d}}{\mathrm{d}s}E_g(F_s)=\int_0^\ell g(D_sU,U)\,\mathrm{d}t.$$

Ponieważ $[\partial_s,\partial_t]=0$ i koneksja nie ma torsji, $D_sU=D_tS$. Po całkowaniu przez części otrzymujemy *dla całej rodziny*

$$\frac{\mathrm{d}}{\mathrm{d}s}E_g(F_s)=\big[g(S,U)\big]_0^\ell-\int_0^\ell g(S,D_tU)\,\mathrm{d}t. \tag{14.11.3}$$

Końce są nieruchome, więc $S(s,0)=S(s,\ell)=0$; składnik brzegowy oraz jego pochodna po s znikają. Różniczkujemy pozostałą całkę. Przy $s=0$ mamy $D_tU=D_tT=0$, gdyż γ jest geodezyjną. Człon zawierający D_sS znika, bez względu na *przyspieszenie* wybranej wariacji. Zostaje

$$E_g''(0)=-\int_0^\ell g(V,D_sD_tU|_{s=0})\,\mathrm{d}t.$$

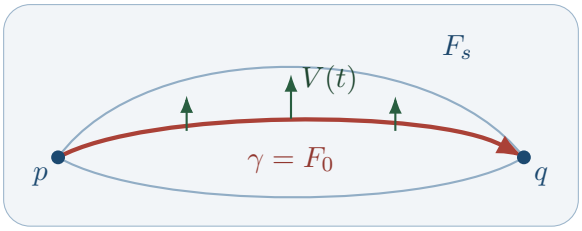
Definicja (14.1.1) na polach wzdłuż F ma tutaj postać $D_sD_tU-D_tD_sU=R(S,U)U$. Ponieważ $D_sU=D_tS$, dostajemy krok po kroku

$$D_sD_tU=D_t(D_sU)+R(S,U)U=D_t^2S+R(S,U)U.$$

Po podstawieniu $s=0$ jest to $D_t^2V+R(V,T)T$. Wreszcie reguła iloczynu i $V(0)=V(\ell)=0$ dają

$$-\int_0^\ell g(V,D_t^2V)\,\mathrm{d}t=-\big[g(V,D_tV)\big]_0^\ell+\int_0^\ell|D_tV|_g^2\,\mathrm{d}t=\int_0^\ell|D_tV|_g^2\,\mathrm{d}t.$$

To dowodzi (14.11.1). Polaryzacja daje (14.11.2); symetria $I(V,W)=I(W,V)$ wynika również z symetrii tensora krzywizny, bo $g(R(V,T)T,W)=g(R(W,T)T,V)$. □



Rysunek 14.9: Wariacja o nieruchomych końcach: pole V opisuje pierwsze przemieszczenie punktów krzywej γ. Druga wariacja mierzy zmianę energii przy takim wychyleniu. Rysunek schematyczny; otaczające krzywe nie muszą być geodezyjnymi.

W przeciwieństwie do pierwszej wariacji, w (14.11.1) pojawia się zarówno koszt zmieniania kierunku pola V, czyli $|D_t V|^2$, jak i wkład krzywizny. Na sferze dodatnia krzywizna odejmuje od pierwszego składnika; przy ujemnej krzywiźnie poprzeczne wychylenie kosztuje dodatkową energię.

Stwierdzenie 14.11.2 (Druga wariacja długości)**.** *Przy tych samych założeniach, dla wariacji regularnych krzywych, zachodzi*

$$\frac{\mathrm{d}^2}{\mathrm{d}s^2} L_g(F_s)\Big|_{s=0} = I(V,V) - \int_0^\ell g(D_t V, T)^2 \,\mathrm{d}t. \tag{14.11.4}$$

Jeśli V jest prostopadłe do T w każdym punkcie, obie drugie wariacje są równe.

Dowód. Przy $s=0$ mamy $|U| = |T| = 1$. Zwykłe różniczkowanie funkcji $\sqrt{h}$ dla $h(s,t) = g(U,U)$ pokazuje punktowo, że

$$\partial_s^2 |U|\Big|_{s=0} = \partial_s^2 \frac{|U|^2}{2}\Big|_{s=0} - \left(\partial_s |U||_{s=0}\right)^2.$$

Pierwszy składnik po scałkowaniu daje $E''(0)$. Ponadto $\partial_s |U||_0 = g(D_s U, T)|_0 = g(D_t V, T)$. To daje wzór. Jeżeli $g(V,T) = 0$ na całym $[0,\ell]$, to $g(D_t V, T) = \frac{\mathrm{d}}{\mathrm{d}t} g(V,T) = 0$, bo $D_t T = 0$. □

To rozróżnienie jest potrzebne: dla pola $V = fT$ z $f(0) = f(\ell) = 0$ wzór na energię daje $I(fT, fT) = \int_0^\ell (f')^2 \mathrm{d}t$, natomiast druga wariacja długości wynosi zero. Przesuwanie punktów *wzdłuż* tej samej krzywej zmienia jej parametryzację, a długość nie zależy od parametryzacji.

Pola Jacobiego: sąsiednie geodezyjne

Definicja 14.11.3 (Pole Jacobiego)**.** Pole wektorowe J wzdłuż geodezyjnej γ, z $T = \dot\gamma$, nazywamy *polem Jacobiego*, jeśli

$$D_t^2 J + R(J,T)T = 0. \tag{14.11.5}$$

Równanie jest liniowe. Przy naszej konwencji na sferze $R(J,T)T$ ma zwrot prostopadłego pola J, a więc $D_t^2 J = -R(J,T)T$ jest skierowane z powrotem ku geodezyjnej.

Twierdzenie 14.11.4 (Pola Jacobiego powstają z geodezyjnych)**.** *Jeżeli $F(s,t)$ jest wariacją, dla której każda krzywa $t \mapsto F(s,t)$ jest geodezyjną z parametrem afinicznym, to $J = \partial_s F|_{s=0}$ spełnia (14.11.5). Odwrotnie: każde pole Jacobiego wzdłuż γ na zwartym przedziale jest polem wariacyjnym pewnej rodziny geodezyjnych.*

Dowód. Niech znów $S = \partial_s F$ i $U = \partial_t F$. Teraz $D_t U = 0$ dla *każdego* s, więc $D_s D_t U = 0$. Obliczenie wykonane w dowodzie Twierdzenia 14.11.1 daje

$$0 = D_t^2 S + R(S,U)U.$$

Przy $s = 0$ jest to równanie Jacobiego.

Dla odwrotności wybierzmy $A = J(0)$ i $B = D_tJ(0)$. Weźmy krzywą p_s z $p_0 = \gamma(0)$, $\dot{p}_0 = A$. Niech $P_s : T_{p_0}M \to T_{p_s}M$ będzie transportem równoległym wzdłuż p_s i połóżmy $v_s = P_s(T(0) + sB)$. Dla małych s rodzina geodezyjnych $F(s,t) = \gamma_{p_s,v_s}(t)$ istnieje na całym zadanym zwartym przedziale: rozwiązania ODE zależą gładko od danych bliskich danym γ, a skończona liczba lokalnych przedłużeń pokrywa przedział. Jej pole $\widetilde{J} = \partial_s F|_0$ ma $\widetilde{J}(0) = A$ oraz, z $D_t\widetilde{J} = D_sU$, $D_t\widetilde{J}(0) = D_sv_s|_0 = B$. W równoległej ramie wzdłuż γ równanie (14.11.5) staje się układem liniowych ODE drugiego rzędu $y'' + A(t)y = 0$. Jednoznaczność rozwiązania przy ustalonych $J(0), D_tJ(0)$ daje $\widetilde{J} = J$ na całym przedziale. □

Pole Jacobiego mierzy więc, jak zmienia się położenie punktu na geodezyjnej, gdy nieznacznie zmieniamy jej *punkt startowy lub prędkość*. Nie zakładamy tu, że końce są nieruchome; wariacje geodezyjnych o ustalonych obu końcach mogą nie istnieć poza szczególnymi sytuacjami.

Definicja 14.11.5 (Punkty sprzężone)**.** Parametry 0 i $c > 0$, a także odpowiadające im punkty $p = \gamma(0)$ i $\gamma(c)$ *wzdłuż wybranej geodezyjnej*, nazywamy *sprzężonymi*, jeśli istnieje niezerowe pole Jacobiego J spełniające $J(0) = J(c) = 0$. Gdy geodezyjna sama się przecina, sformułowanie przez parametry usuwa niejednoznaczność.

Stwierdzenie 14.11.6 (Punkty sprzężone i odwzorowanie wykładnicze)**.** *Jeżeli $\gamma(t) = \exp_p(tv)$ oraz $v = T(0)$, to dla $w \in T_pM$ pole powstające przez zmianę prędkości początkowej $v + sw$ ma postać*

$$J_w(t) = \partial_s \exp_p(t(v + sw))\Big|_{s=0} = \mathrm{d}(\exp_p)_{tv}(tw), \qquad J_w(0) = 0, \quad D_tJ_w(0) = w. \tag{14.11.6}$$

W konsekwencji $\gamma(c)$ jest sprzężony z p wzdłuż γ wtedy i tylko wtedy, gdy $\mathrm{d}(\exp_p)_{cv}$ ma niezerowe jądro.

Dowód. Różniczkujemy rodzinę geodezyjnych $t \mapsto \exp_p(t(v + sw))$ po s i stosujemy regułę łańcuchową; daje to pierwsze dwie równości. Wszystkie krzywe startują z p, więc $J_w(0) = 0$. Ich prędkości początkowe są równe $v + sw$, stąd $D_tJ_w(0) = w$. Każde pole Jacobiego zerujące się w 0 jest jednym z J_w, ponieważ jego początkowa pochodna w wyznacza je jednoznacznie. Dla $c > 0$ warunek $J_w(c) = 0$ jest równoważny $\mathrm{d}(\exp_p)_{cv}(cw) = 0$. Ponieważ $w \neq 0$ dokładnie wtedy, gdy $cw \neq 0$, otrzymujemy tezę. □

Różniczka $\mathrm{d}\exp_p$ pokazuje zatem, kiedy geodezyjne startujące z p zaczynają się *ogniskować*: początkowo różne kierunki mogą w pierwszym przybliżeniu prowadzić do tego samego punktu. W punkcie sprzężonym normalne współrzędne z centrum p tracą lokalną odwracalność wzdłuż tego promienia.

Trzy znaki krzywizny i przykłady

Na przestrzeni o stałej krzywiźnie sekcyjnej κ, z (14.4.7) wynika, że dla jednostkowego T i prostopadłego równoległego pola E mamy $R(E,T)T = \kappa E$. Jeżeli $J(t) = f(t)E(t)$, równanie Jacobiego redukuje się do zwykłego równania

$$f'' + \kappa f = 0, \qquad f(0) = 0, \quad f'(0) = 1. \tag{14.11.7}$$

Jego rozwiązania dla trzech znaków krzywizny to

$$f_\kappa(t) = \begin{cases} \dfrac{\sin(\sqrt{\kappa}\,t)}{\sqrt{\kappa}}, & \kappa > 0, \\ t, & \kappa = 0, \\ \dfrac{\sinh(\sqrt{-\kappa}\,t)}{\sqrt{-\kappa}}, & \kappa < 0. \end{cases} \tag{14.11.8}$$

Sprawdzamy to bez skrótu: dla $\kappa > 0$ dwie pochodne sinusa dają $f'' = -\kappa f$; analogicznie sinh daje $f'' = (-\kappa)f$, więc $f'' + \kappa f = 0$; wszystkie trzy wzory mają $f(0) = 0$, $f'(0) = 1$. Składowa styczna pola Jacobiego ma natomiast postać $(a + bt)T$, bo $R(T, T)T = 0$. Niezerowa taka składowa nie może znikać w dwóch różnych chwilach. O punktach sprzężonych decydują więc składowe poprzeczne.

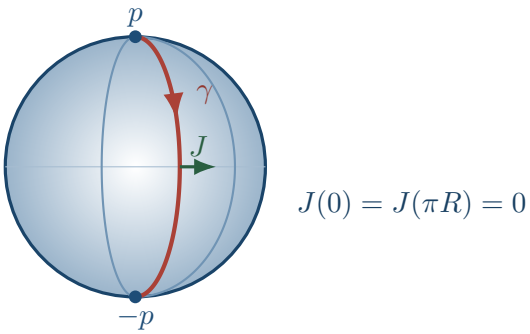
Przykład 14.11.7 (Sfera o promieniu R)**.** Na S^n_R, $n \geq 2$ i $R > 0$, mamy $\kappa = 1/R^2$. Dla $0 \neq w \perp v$, po równoległym przesunięciu w wzdłuż jednostkowej geodezyjnej, dostajemy

$$J_w(t) = R \sin(t/R)\, P_t w.$$

Pole startuje od zera, rośnie, a następnie znika ponownie przy $t = \pi R$, czyli w antypodzie. Istnieje $n - 1$ niezależnych kierunków w, więc jest to punkt sprzężony krotności $n - 1$. Geometrycznie: różne wielkie półokręgi wychodzą z p i spotykają się w $-p$. Na łuku dłuższym niż πR można zobaczyć utratę minimalności bez żadnego ogólnego twierdzenia. Dla $\ell > \pi R$ weźmy równoległe jednostkowe pole normalne E i $V(t) = \sin(\pi t/\ell)E(t)$. Wtedy $V(0) = V(\ell) = 0$ i, z formy indeksowej,

$$I(V, V) = \int_0^\ell \left[\frac{\pi^2}{\ell^2} \cos^2\!\left(\frac{\pi t}{\ell}\right) - \frac{1}{R^2} \sin^2\!\left(\frac{\pi t}{\ell}\right) \right] \mathrm{d}t = \frac{\ell}{2} \left(\frac{\pi^2}{\ell^2} - \frac{1}{R^2} \right) < 0. \tag{14.11.9}$$

Taki łuk nie może być minimalny. Przy $\ell = \pi R$ wybrane pole daje $I = 0$, a mimo to półokrąg *jest* minimalny: zero drugiej wariacji samo nie rozstrzyga sprawy.



Rysunek 14.10: Rzut wielkich półokręgów na sferze oglądanej prostopadle do osi biegunowej. Półokręgi spotykają się w antypodzie. Pole Jacobiego, otrzymane przez zmianę długości geograficznej, znika przy p i $-p$. Zielona strzałka pokazuje jego rzut w punkcie równika, w umownej skali.

Przykład 14.11.8 (Płaszczyzna i trzy modele hiperboliczne)**.** W $\mathbb{R}^n$ pole poprzeczne z $J(0) = 0$ i $D_t J(0) = w$ ma postać $J(t) = tw$, przy identyfikacji przestrzeni stycznych przez transport równoległy. Dla $w \neq 0$ nie znika już przy $t > 0$. W przestrzeni o $K = -1$ analogicznie $J(t) = \sinh(t) P_t w$, więc sąsiednie geodezyjne rozchodzą się szybciej. Ponadto dla $V = V^{\parallel} + V^{\perp}$ z zerowymi końcami

$$I(V, V) = \int_0^\ell (|D_t V|^2 + |V^{\perp}|^2)\mathrm{d}t > 0 \quad \text{dla } V \neq 0.$$

Nie ma punktów sprzężonych. Dotyczy to *tej samej* przestrzeni hiperbolicznej zapisanej jako półprzestrzeń, kula Poincarégo lub hiperboloida; metryki i izometrie między nimi podano w 11.2.3, a $K = -1$ obliczono w Stwierdzeniu 14.4.5. Wzór dodatniej formy mówi o *lokalnej* stabilności. Globalną minimalność i jedyność geodezyjnych w tych trzech modelach potwierdzają odległości (13.4.6).

Co naprawdę wynika dla krzywej minimalnej?

Twierdzenie 14.11.9 (Warunki konieczne i punkty sprzężone)**.** *Jeżeli ciągła, odcinkami C^1 krzywa $\gamma : [0,\ell] \to M$, $\ell > 0$, minimalizuje długość między p i q i jest parametryzowana długością łuku, to:*

(i) *γ jest geodezyjną;*

(ii) *$I(V,V) \geq 0$ dla każdego gładkiego pola V wzdłuż γ z $V(0) = V(\ell) = 0$;*

(iii) *żaden punkt $\gamma(c)$ dla $0 < c < \ell$ nie jest sprzężony z p wzdłuż γ.*

Punkt końcowy q może *być sprzężony z p.*

Dowód. Każdy podłuk γ również minimalizuje długość: jego skrócenie skróciłoby całą drogę. Ustalmy punkt $\gamma(t_0)$ i jego małe otoczenie normalne. Dla t bliskich t_0 krzywa pozostaje w tym otoczeniu. Warunek równości w dowodzie lokalnej minimalności promieni (Twierdzenie 13.3.2) wymusza, aby każdy z dwóch podłuków wychodzących z $\gamma(t_0)$ był radialny. Parametr długości łuku nadaje im prędkość 1. Są więc gładkimi geodezyjnymi po obu stronach t_0, a argument o braku narożników z dowodu Twierdzenia 13.1.3 zrównuje ich prędkości w t_0. Jednoznaczność ODE skleja je w jedną gładką geodezyjną. Na końcach stosujemy argument jednostronny. To dowodzi (i), bez zakładania gładkości minimalnej krzywej z góry. Sama druga wariacja nie zastępuje tego kroku: stosujemy jej wzór dopiero *na geodezyjnej*.

Niech F_s będzie dowolną wariacją z nieruchomymi końcami. Dla krzywych określonych na $[0,\ell]$ nierówność (11.4.3) oraz minimalność γ dają

$$E_g(F_s) \geq \frac{L_g(F_s)^2}{2\ell} \geq \frac{\ell^2}{2\ell} = E_g(\gamma).$$

Energia ma więc minimum przy $s = 0$, skąd $E_g''(0) \geq 0$. Każde gładkie pole V zerujące się na końcach można zrealizować przez $F(s,t) = \exp_{\gamma(t)}(sV(t))$ przy dostatecznie małym s; zwartość przedziału zapewnia wspólną dziedzinę. Wzór (14.11.1) daje (ii).

Dowiedźmy (iii) przez sprzeczność, pokazując konkretny kierunek ujemnej drugiej wariacji. Załóżmy, że $0 < c < \ell$ i istnieje niezerowe pole Jacobiego J z $J(0) = J(c) = 0$. Przedłużmy je przez zero na $[c,\ell]$; powstałe ciągłe pole oznaczmy $\widehat{J}$. Jest gładkie oddzielnie po obu stronach c. Z jednoznaczności równania Jacobiego wynika $D_tJ(c) \neq 0$, gdyż w przeciwnym razie oba dane $J(c), D_tJ(c)$ byłyby zerowe.

Całkując przez części na $[0,c]$ i używając równania Jacobiego, dla każdego pola W o zerowych końcach otrzymujemy

$$I(\widehat{J},W) = \big[g(D_tJ,W)\big]_0^c = g(D_tJ(c),W(c)), \qquad I(\widehat{J},\widehat{J}) = 0. \tag{14.11.10}$$

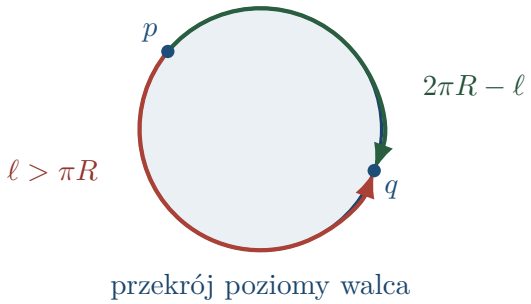
Wybierzmy gładkie W z $W(0) = W(\ell) = 0$ i $W(c) = -D_tJ(c)$, na przykład przez pomnożenie pola z lokalnej równoległej ramy przez funkcję z nośnikiem blisko c. Wtedy $I(\widehat{J},W) = -|D_tJ(c)|^2 < 0$. Dla dostatecznie małego $\varepsilon > 0$

$$I(\widehat{J}+\varepsilon W, \widehat{J}+\varepsilon W) = -2\varepsilon|D_tJ(c)|^2 + \varepsilon^2 I(W,W) < 0.$$

Wygładzamy $\widehat{J}$ w małym otoczeniu c w równoległej ramie. Ponieważ jest ciągłe, odcinkami gładkie i ma ograniczoną pochodną, można to zrobić tak, by pole i jego pierwsza pochodna zbliżały się w całce z kwadratu, zachowując zerowe końce. Na zwartym przedziale współczynniki krzywizny są ograniczone, więc całka (14.11.2) zmienia się wtedy dowolnie mało. Otrzymujemy *gładkie* pole z $I < 0$, sprzeczne z (ii). Zatem punkt sprzężony nie może leżeć we wnętrzu odcinka minimalnego. Wreszcie przy $c = \ell$ wyraz $W(c)$ w (14.11.10) musi być zerowy, więc ten argument nie daje ujemnego kierunku. Przykład sfery powyżej pokazuje, że końcowy punkt sprzężony jest możliwy. □

Brak punktów sprzężonych jest *konieczny* dla minimalności na otwartym odcinku, ale sam nie zapewnia globalnie najkrótszej drogi. Widać to nawet przy zerowej krzywiźnie.

Przykład 14.11.10 (Płaski walec: brak sprzężenia nie wystarcza)**.** Na walcu $S^1_R \times \mathbb{R}$ z metryką $g = R^2 \mathrm{d}\theta^2 + \mathrm{d}z^2$ poziomy łuk $\gamma(t) = (t/R, 0)$, $0 \le t \le \ell$, jest jednostkową geodezyjną. W lokalnych współrzędnych metryka ma stałe współczynniki, więc $R(X,Y)Z = 0$; pola Jacobiego o zerowym początku mają postać $tP_t w$ i dla $w \neq 0$ nie znikają ponownie. Gdy $\pi R < \ell < 2\pi R$, drugi łuk tego samego okręgu łączy te same końce i ma długość $2\pi R - \ell < \ell$. Geodezyjna przestaje zatem być globalnie minimalna *bez punktu sprzężonego*. Przeszkodą jest tu globalne zawinięcie walca, którego lokalne równanie Jacobiego nie widzi.



Rysunek 14.11: Ten sam okrąg oglądany jako poziomy przekrój płaskiego walca. Między p i q dłuższy łuk (czerwony) jest geodezyjną bez punktów sprzężonych, lecz krótszy łuk (zielony) wygrywa globalnie.

Podsumowując logiczną kolejność: *minimalność długości* wymusza równanie geodezyjnej przez pierwszą wariację, a następnie nieujemność formy indeksowej przez drugą. Pola Jacobiego opisują sąsiednie geodezyjne i wskazują pierwszą przeszkodę w utrzymaniu minimalności na coraz dłuższych odcinkach. Na sferze przeszkodą jest ogniskowanie; na walcu może nią być topologia, choć ogniskowania w ogóle nie ma.

Z tym rozróżnieniem łączy się Sekcja 13.6. Jeżeli $u \in T_pM$ jest jednostkowy, to dla każdego $0 < t < c_p(u)$ odcinek geodezyjnej można przedłużyć do odcinka minimalnego. Twierdzenie 14.11.9 wyklucza więc sprzężenie przed czasem cięcia, a Stwierdzenie 14.11.6 daje w tych punktach odwracalność $\mathrm{d}\exp_p$. W samym miejscu cięcia występuje sprzężenie wzdłuż wybranej geodezyjnej lub spotykają się co najmniej dwie geodezyjne minimalne; możliwości te mogą zachodzić jednocześnie (Wniosek 13.6.4). Kres dolny czasów cięcia spośród kierunków to $\mathrm{inj}(p)$ na mocy Twierdzenia 13.6.3. Na sferze oba mechanizmy występują w antypodzie (Przykład 13.6.5), a na płaskim torusie cięcie wynika ze spotkania dróg minimalnych bez sprzężenia (Przykład 13.6.6).

14.12 Twierdzenia porównawcze

Znamy już dokładne rozwiązania równania Jacobiego przy stałej krzywiźnie. Co można powiedzieć, gdy krzywizna zmienia się z punktu na punkt, ale znamy jej górną albo dolną granicę? *Porównanie* z modelem o stałej krzywiźnie zamienia nierówność dotyczącą R w informację o geodezyjnych, odległościach, objętości lub topologii.

Przez tę sekcję zakładamy $n = \dim M \ge 2$ i metrykę riemannowską. Dla $\kappa \in \mathbb{R}$ oznaczmy

$$s_\kappa(r) = \begin{cases} \sin(\sqrt{\kappa}\, r)/\sqrt{\kappa}, & \kappa > 0, \\ r, & \kappa = 0, \\ \sinh(\sqrt{-\kappa}\, r)/\sqrt{-\kappa}, & \kappa < 0, \end{cases} \qquad c_\kappa(r) = \frac{s_\kappa'(r)}{s_\kappa(r)}. \tag{14.12.1}$$

To funkcja z (14.11.8): $s_\kappa'' + \kappa s_\kappa = 0$, $s_\kappa(0) = 0$, $s_\kappa'(0) = 1$. Ilorazu c_κ używamy tylko tam, gdzie $s_\kappa > 0$; dla $\kappa > 0$ oznacza to $0 < r < \pi/\sqrt{\kappa}$. Dla $\kappa = 0$ mamy $c_0 = 1/r$, a dla $\kappa = -1$ mamy $c_{-1} = \coth r$.

Lemat indeksowy i porównanie Raucha

Kluczowy krok jest wariacyjną własnością pola Jacobiego. Piszemy $\mathsf{K}_t(X) = R(X,T)T$ na podprzestrzeni prostopadłej do $T = \dot\gamma$. Ten operator jest symetryczny; jego forma kwadratowa jest krzywizną sekcyjną płaszczyzny rozpiętej przez X, T razy $|X|^2$.

Lemat 14.12.1 (Indeksowy)**.** *Niech $\gamma : [0,b] \to M$ będzie jednostkową geodezyjną bez punktu sprzężonego z $\gamma(0)$ na $(0,b]$. Niech J będzie prostopadłym polem Jacobiego z $J(0) = 0$. Spośród wszystkich ciągłych, odcinkami gładkich pól normalnych X z $X(0) = 0$ i $X(b) = J(b)$ pole J minimalizuje formę indeksową na $[0,b]$:*

$$I_b(X,X) \geq I_b(J,J) = g(D_tJ(b), J(b)). \tag{14.12.2}$$

Dowód. Wybierzmy równoległą bazę ortonormalną normalną do T i zapisujmy pola przez kolumny w $\mathbb{R}^{n-1}$. Niech $A(t)$ będzie macierzą pól Jacobiego spełniających $A(0) = 0$ i $A'(0) = \mathrm{Id}$. Każda kolumna spełnia $A'' + \mathsf{K}A = 0$, gdzie K jest symetryczną macierzą. Brak punktów sprzężonych oznacza, że $A(t)$ jest odwracalna dla $0 < t \leq b$: wektor z jądra $A(t)$ wyznaczałby niezerowe pole Jacobiego zerujące się także w t.

Połóżmy $H = A'A^{-1}$. Najpierw sprawdźmy, że H jest symetryczna. Macierz Wrońskiego $A^{\mathsf{T}}A' - A'^{\mathsf{T}}A$ ma pochodną $A^{\mathsf{T}}A'' - A''^{\mathsf{T}}A = 0$, bo $A'' = -\mathsf{K}A$ i $\mathsf{K}^{\mathsf{T}} = \mathsf{K}$. W zerze Wroński znika, więc znika wszędzie. Mnożenie przez $(A^{-1})^{\mathsf{T}}$ z lewej i A^{-1} z prawej daje $H = H^{\mathsf{T}}$. Różniczkując H i korzystając z równania Jacobiego, otrzymujemy *równanie Riccatiego*

$$H' = A''A^{-1} - A'A^{-1}A'A^{-1} = -\mathsf{K} - H^2. \tag{14.12.3}$$

Napiszmy $X = J + Z$; pole Z znika na obu końcach. Całkowanie przez części i równanie Jacobiego dają $I_b(J,Z) = 0$ oraz $I_b(J,J) = [g(D_tJ, J)]_0^b$. Z (14.12.3) i symetrii H wynika z kolei, dla $0 < \varepsilon < b$,

$$\int_\varepsilon^b |Z' - HZ|^2 \,\mathrm{d}t = I_{[\varepsilon,b]}(Z,Z) - [\langle HZ, Z\rangle]_\varepsilon^b.$$

Istotnie rozwijamy kwadrat i zastępujemy $2\langle HZ, Z'\rangle$ wyrażeniem $\frac{\mathrm{d}}{\mathrm{d}t}\langle HZ, Z\rangle - \langle H'Z, Z\rangle$; pozostałe $H' + H^2$ to $-\mathsf{K}$. Ponieważ $A(t) = t\mathrm{Id} + O(t^3)$, to $H(t) = t^{-1}\mathrm{Id} + O(t)$. Dla odcinkami gładkiego Z z $Z(0) = 0$ mamy $Z(t) = O(t)$, zatem wyraz brzegowy przy $\varepsilon \downarrow 0$ dąży do zera. W rezultacie

$$I_b(Z,Z) = \int_0^b |Z' - HZ|^2 \,\mathrm{d}t \geq 0.$$

Razem z $I_b(X,X) = I_b(J,J) + I_b(Z,Z)$ daje to obie części (14.12.2). □

Najpierw podajemy wygodną wersję Raucha: porównujemy wszystkie płaszczyzny poprzeczne obu geodezyjnych. Ta wersja wystarcza do poniższych zastosowań; dowód używa właśnie podanego porównania dla każdej pary kierunków poprzecznych.

Twierdzenie 14.12.2 (Porównanie Raucha)**.** *Niech $\gamma_i : [0,b) \to M_i$, $i = 1,2$, będą jednostkowymi geodezyjnymi w rozmaitościach tego samego wymiaru. Załóżmy, że dla każdej chwili t i dowolnych jednostkowych wektorów $X_i \perp \dot\gamma_i(t)$ zachodzi*

$$K_1(\dot\gamma_1 \wedge X_1) \leq K_2(\dot\gamma_2 \wedge X_2).$$

Niech normalne pola Jacobiego J_i spełniają $J_i(0)=0$ i $|D_tJ_1(0)|=|D_tJ_2(0)|>0$. Jeśli wzdłuż γ_2 nie ma punktu sprzężonego z początkiem w $(0,b)$, to

$$|J_1(t)|\geq|J_2(t)|,\qquad 0<t<b. \tag{14.12.4}$$

W szczególności niższa krzywizna sekcyjna pozwala geodezyjnym rozchodzić się co najmniej tak szybko, jak w przestrzeni bardziej zakrzywionej.

Dowód. Przy ustalonym t przed ewentualnym pierwszym zerem J_1 połóżmy $Y_i(s)=J_i(s)/|J_i(t)|$ dla $0\leq s\leq t$. Wybierzmy izometrię między przestrzeniami normalnymi obu geodezyjnych, przenoszoną równolegle wzdłuż s, która przy $s=t$ odwzorowuje $Y_1(t)$ na $Y_2(t)$. Niech $\widetilde{Y}_1$ będzie obrazem całego pola Y_1 wzdłuż γ_2. Przenoszenie zachowuje normy pól i ich pochodnych. Założona nierówność krzywizn daje więc, po odjęciu członów krzywizny w (14.11.2),

$$I_{1,t}(Y_1,Y_1)\geq I_{2,t}(\widetilde{Y}_1,\widetilde{Y}_1).$$

Pola $\widetilde{Y}_1$ oraz Y_2 mają te same wartości: zero w 0 i ten sam wektor jednostkowy w t. Lemat 14.12.1 dla γ_2 daje $I_{2,t}(\widetilde{Y}_1,\widetilde{Y}_1)\geq I_{2,t}(Y_2,Y_2)$. Ponieważ Y_i jest polem Jacobiego, (14.12.2) przekształca ten łańcuch nierówności w

$$\frac{\mathrm{d}}{\mathrm{d}t}\log|J_1(t)|=\frac{g(D_tJ_1,J_1)}{|J_1|^2}\geq\frac{g(D_tJ_2,J_2)}{|J_2|^2}=\frac{\mathrm{d}}{\mathrm{d}t}\log|J_2(t)|.$$

Całkujemy od ε do t. Przy $\varepsilon\downarrow 0$ zachodzi $|J_i(\varepsilon)|/\varepsilon\to|D_tJ_i(0)|$, więc iloraz początkowy dąży do 1. Otrzymujemy (14.12.4). Jeżeli J_1 miałoby pierwsze zero przed b, ta nierówność i ciągłość dawałyby tam $0\geq|J_2|>0$, sprzeczność. Dowód obejmuje zatem cały wskazany przedział. □

Wniosek 14.12.3 (Porównanie z modelem)**.** *Jeżeli $K_M\leq\kappa$, to dla normalnego pola Jacobiego $J(0)=0$, $D_tJ(0)=w$ mamy*

$$|J(r)|\geq s_\kappa(r)|w| \tag{14.12.5}$$

do pierwszego zera s_κ (bez ograniczenia czasu, gdy $\kappa\leq 0$). Nie ma więc punktu sprzężonego przed *tym zerem. Jeżeli $K_M\geq\kappa$, nierówność jest odwrotna aż do pierwszego punktu sprzężonego w M i pierwszego zera s_κ.*

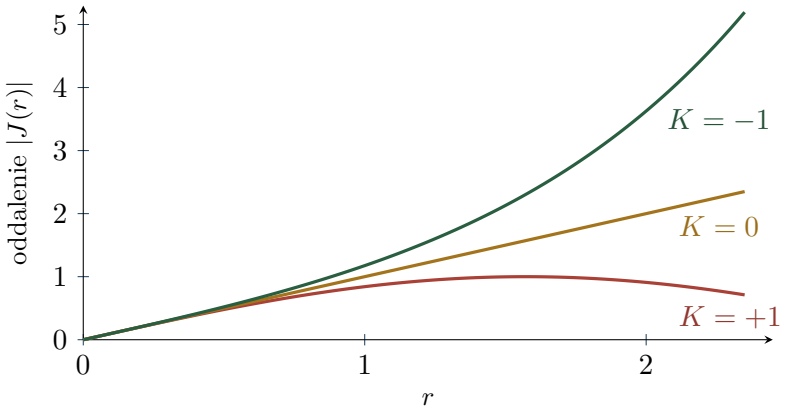
Dowód. Jako drugą przestrzeń w Twierdzeniu 14.12.2 weźmy model o stałej krzywiźnie κ. Jego normalne pole ma długość $s_\kappa(r)|w|$, zgodnie z (14.11.8). Przy odwrotnym ograniczeniu krzywizny zamieniamy role M i modelu; przed pierwszym punktem sprzężonym w M spełniony jest warunek lematu indeksowego. □

Porównanie hesjanu odległości

W tej podsekcji zakładamy, że (M,g) jest spójna i zupełna. Najpierw uzasadnijmy, gdzie odległość $r(x)=d_g(p,x)$ jest gładka.

Lemat 14.12.4 (Czas cięcia i współrzędne biegunowe)**.** *Użyjmy czasu cięcia i zbioru cięcia z Definicji 13.6.1, w skróconej notacji $c(\theta)=c_p(\theta)$ dla $\theta\in S_pM$ oraz $C_p=\mathrm{Cut}(p)$. Odwzorowanie biegunowe $F(t,\theta)=\exp_p(t\theta)$ jest dyfeomorfizmem zbioru $D=\{(t,\theta):0<t<c(\theta)\}$ na $M\setminus(\{p\}\cup C_p)$. Na tym obrazie r jest gładka, a zbiór C_p ma objętość riemannowską zero.*

Dowód. Małe promienie są minimalne, zatem $c(\theta)>0$. Jeśli promień jest minimalny do chwili t, jest też minimalny do każdej wcześniejszej chwili. Ciągłość odległości zapewnia minimalność także przy skończonym $c(\theta)$. Dla każdego $t>0$ zbiór $\{\theta:c(\theta)\geq t\}=\{\theta:d_g(p,F(t,\theta))=t\}$ jest domknięty, więc c jest mierzalna.



Rysunek 14.12: W modelach o krzywiznach $+1, 0, -1$ zerowe początkowe wychylenie i jednostkowa pochodna $D_r J(0)$ dają odpowiednio $|J(r)| = \sin r$, r, $\sinh r$. Wykres pokazuje zakres $0 \le r \le 2{,}35$; pierwsze ponowne zero na sferze występuje później, przy $r = \pi$.

Przed czasem cięcia minimalny promień można przedłużyć minimalnie nieco dalej. Dwie różne minimalne geodezyjne do jego punktu końcowego utworzyłyby, po doklejeniu tego przedłużenia do drugiej drogi, minimalną drogę z narożnikiem. Jest to niemożliwe; gdyby prędkości w miejscu sklejenia były równe, jednoznaczność ODE dawałaby tę samą geodezyjną. Stąd jedyność, a także różnowartościowość F na D. Twierdzenie 14.11.9 wyklucza tam punkty sprzężone, więc $\mathrm{d}\exp_p$ jest odwracalna.

Potrzebujemy jeszcze lokalnej kontroli minimalnych dróg. Jeżeli do $q \neq p$ prowadzi jedyna minimalna geodezyjna z wektorem początkowym v i $\mathrm{d}(\exp_p)_v$ jest odwracalna, to dla $q_j \to q$ wektory minimalnych geodezyjnych v_j mają długości $d_g(p, q_j) \to d_g(p, q)$. Istnieją na mocy Hopfa–Rinowa; zwartość ograniczonych zbiorów w T_pM i ciągłość $\exp_p$ pokazują, że każdy zbieżny podciąg ma granicę v. Zatem wszystkie v_j leżą ostatecznie w dziedzinie tej samej lokalnej odwrotności $\exp_p$. W otoczeniu q każda minimalna droga jest więc wyznaczona przez tę odwrotność, a $r(q') = |\exp_p^{-1}(q')|$ jest gładka. W szczególności ustalmy $t + \eta < c(\theta)$. W punkcie $F(t+\eta, \theta)$ powyższa lokalna odwrotność opisuje wszystkie minimalne drogi do pobliskich punktów. Dla θ' bliskich θ jej wartością na $F(t + \eta, \theta')$ jest $(t + \eta)\theta'$. Zatem $c(\theta') \ge t + \eta > t$; ta sama nierówność zachodzi dla parametrów bliskich t, więc D jest otwarty. Ten sam argument dowodzi, że punkt o jedynej regularnej minimalnej geodezyjnej nie może być końcem cięcia: promień dałoby się przedłużyć minimalnie. Hopf–Rinow zapewnia teraz, że obraz D jest dokładnie podanym dopełnieniem, i lokalne odwrotności sklejają się w globalną odwrotność F.

Pozostaje miara. Wykres skończonych wartości mierzalnej funkcji c, czyli $G = \{(c(\theta), \theta) : c(\theta) < \infty\}$, ma miarę produktową zero: każdy jego przekrój w kierunku t jest jednopunktowy, więc stosujemy twierdzenie Fubiniego. W mapach na sferze oraz na przedziałach $1/k \le t \le k$ odwzorowanie F jest lokalnie Lipschitz. Takie odwzorowania między przestrzeniami tego samego wymiaru przenoszą zbiory miary zero na zbiory miary zero (pokrywamy zbiór małymi sześcianami, których obrazy mają objętości ograniczone stałą razy objętości sześcianów). Przeliczalne pokrycie mapami i porównanie gęstości riemannowskiej z Lebesgue'a dają $\mu_g(F(G)) = 0$, czyli $\mu_g(C_p) = 0$. □

Poza p i zbiorem cięcia lemat Gaussa 13.3.1 daje $\nabla r = T$, gdzie T jest jednostkowym polem radialnych geodezyjnych. *Hesjan* funkcji r jest formą dwuliniową $\operatorname{Hess} r(X, Y) = g(\nabla_X \nabla r, Y)$. Różni się od macierzy zwykłych drugich pochodnych o symbole Christoffela i dlatego jest niezależny od wyboru współrzędnych.

Wniosek 14.12.5 (Porównanie hesjanu)**.** *W punktach, w których r jest gładka, jeżeli $K \le \kappa$,*

to dla $r < \pi/\sqrt{\kappa}$ przy $\kappa > 0$ (i dla każdego $r > 0$ przy $\kappa \le 0$)

$$\operatorname{Hess} r(X, X) \ge c_\kappa(r)\big(|X|^2 - g(X, \nabla r)^2\big). \tag{14.12.6}$$

Jeżeli $K \ge \kappa$, nierówność się odwraca przed zbiorem cięcia i pierwszym zerem s_κ. Na modelu jest równość.

Dowód. Przypadek $X = 0$ jest natychmiastowy. Weźmy najpierw $0 \neq X \perp T$ w końcu radialnej geodezyjnej długości r. Ponieważ $\exp_p$ jest tu lokalnym dyfeomorfizmem, istnieje normalne pole Jacobiego J z $J(0) = 0$ i $J(r) = X$; powstaje ono z wariacji *jednostkowych* prędkości początkowych. Jej krzywe $t \mapsto F(s,t)$ są jednostkowymi geodezyjnymi, więc dla ich pola stycznego $T = \partial_t F$ mamy $D_s T = D_t J$. Różniczkując $\nabla r = T$ w kierunku $X = J(r)$, otrzymujemy

$$\operatorname{Hess} r(X, X) = g(D_t J(r), J(r)) = |X|^2 \,\frac{\mathrm{d}}{\mathrm{d}t} \log |J(t)|\Big|_{t=r}. \tag{14.12.7}$$

Rauch dowodził nawet nierówności między pochodnymi logarytmów. Dla modelu $|J_\kappa(t)| = s_\kappa(t)|w|$, więc jego pochodna to $c_\kappa(t)$. Daje to (14.12.6) dla $X \perp T$ oraz nierówność odwrotną po zamianie ról modeli. Ponieważ $|T| = 1$, $\operatorname{Hess} r(T, \cdot) = 0$; rozkładamy dowolne X na część radialną i prostopadłą i otrzymujemy pełną tezę. □

Na sferze S^n_R prawa strona jest $R^{-1}\cot(r/R)$, w $\mathbb{R}^n$ wynosi $1/r$, a w $\mathbb{H}^n$ jest $\coth r$. Na sferze zmienia znak za równikiem: sfery geodezyjne przestają się rozszerzać i kurczą się przed antypodą. W przestrzeni hiperbolicznej rozszerzają się szybciej niż w płaskiej, zgodnie z Rysunkiem 14.12.

Dodatni Ricci: twierdzenie Bonneta–Myersa

W poprzednich porównaniach ograniczaliśmy krzywiznę *każdej* płaszczyzny zawierającej T. Poniższy wynik wymaga tylko dolnej granicy *sumy* tych krzywizn, czyli $\operatorname{Ric}(T,T)$ z (14.4.3). Już ta suma ogranicza, jak daleko może dojść minimalna geodezyjna.

Twierdzenie 14.12.6 (Bonneta–Myersa)**.** *Niech (M^n, g) będzie spójna i zupełna, $n \ge 2$. Jeśli dla pewnego $\kappa > 0$ i każdego $v \in TM$ zachodzi*

$$\operatorname{Ric}(v, v) \ge (n-1)\kappa |v|^2, \tag{14.12.8}$$

to M jest zwarta i

$$\operatorname{diam}(M, d_g) \le \frac{\pi}{\sqrt{\kappa}}. \tag{14.12.9}$$

Ponadto grupa podstawowa $\pi_1(M)$ jest skończona.

Dowód. Wybierzmy dowolne różne p, q (dla $p = q$ oszacowanie odległości jest oczywiste). Dzięki zupełności Wniosek 13.5.4 daje jednostkową geodezyjną minimalną $\gamma : [0, \ell] \to M$ od p do q. Wybierzmy równoległe pola ortonormalne $E_1, \dots, E_{n-1}$ prostopadłe do T. Dla każdego i weźmy pole wariacyjne $V_i(t) = f(t)E_i(t)$, gdzie $f(t) = \sin(\pi t/\ell)$; obie jego wartości brzegowe są zerowe. Z (14.11.2) otrzymujemy

$$I(V_i, V_i) = \int_0^\ell \Big(f'(t)^2 - f(t)^2 g(R(E_i, T)T, E_i) \Big)\, \mathrm{d}t.$$

Sumujemy po i. Suma wyrazów z krzywizną to $\operatorname{Ric}(T,T)$, a $\operatorname{Ric}(T,T) \ge (n-1)\kappa$, więc

$$\begin{aligned} \sum_{i=1}^{n-1} I(V_i, V_i) &\le (n-1) \int_0^\ell \big(f'(t)^2 - \kappa f(t)^2\big)\mathrm{d}t \\ &= \frac{(n-1)\ell}{2}\left(\frac{\pi^2}{\ell^2} - \kappa\right). \end{aligned}$$

Użyliśmy tutaj $\int_0^\ell \sin^2(\pi t/\ell)\mathrm{d}t = \int_0^\ell \cos^2(\pi t/\ell)\mathrm{d}t = \ell/2$. Gdyby $\ell > \pi/\sqrt{\kappa}$, prawa strona byłaby ujemna. Co najmniej jeden składnik $I(V_i, V_i)$ byłby wtedy ujemny, wbrew Twierdzeniu 14.11.9. Zatem $d_g(p,q) = \ell \le \pi/\sqrt{\kappa}$. Ponieważ p, q były dowolne, mamy (14.12.9). Zbiór M jest domknięty i ograniczony jako przestrzeń metryczna. Wersja Hopfa–Rinowa z 13.5.3 mówi, że na zupełnej rozmaitości riemannowskiej takie zbiory są zwarte; stąd zwartość M.

Na koniec rozważmy uniwersalne nakrycie $\widetilde{M} \to M$ z metryką podniesioną. Jest ono zupełne: każda geodezyjna na nakryciu rzutuje się na geodezyjną w M, którą można przedłużyć na całą prostą, a przedłużenie podnosi się jednoznacznie. Lokalna izometria zachowuje Ricciego, więc ten sam dowód pokazuje, że $\widetilde{M}$ jest zwarta. Włókno nakrycia nad p jest zamkniętym, dyskretnym podzbiorem zwartej $\widetilde{M}$, a zatem jest skończone. Liczba jego punktów równa się liczbie elementów $\pi_1(M)$, co kończy dowód. □

Przykład 14.12.7 (Ostrość oszacowania)**.** Na S^n_R mamy $\mathrm{Ric} = (n-1)R^{-2}g$ i średnicę πR; dla $\kappa = R^{-2}$ zachodzi równość w (14.12.9). Samo $\mathrm{Ric} > 0$ punktowo nie daje jednej liczby κ na rozmaitości niezwartej, jeśli nie ma *jednostajnej* dolnej granicy. Wymiar $n \ge 2$ jest też istotny: dla $n = 1$ warunek $\mathrm{Ric} \ge (n-1)\kappa g$ byłby pusty.

Niedodatnia krzywizna: Cartan–Hadamard

Ujemna krzywizna rozsuwa sąsiednie geodezyjne. Gdy rozmaitość jest ponadto zupełna i nie ma globalnego „zawinięcia" topologicznego, odwzorowanie wykładnicze $\exp_p : T_pM \to M$ okazuje się globalnym dyfeomorfizmem, a jego odwrotność po wyborze bazy w T_pM jest globalną mapą współrzędnych na M.

Twierdzenie 14.12.8 (Cartana–Hadamarda)**.** *Jeżeli (M, g) jest spójna, zupełna i ma $K \le 0$, to dla każdego $p \in M$ odwzorowanie $\exp_p : T_pM \to M$ jest nakryciem. Jeśli ponadto M jest jednospójna, to $\exp_p$ jest globalnym dyfeomorfizmem; w szczególności M jest dyfeomorficzna z $\mathbb{R}^n$ i każde dwa jej punkty łączy jedyna geodezyjna minimalna.*

Dowód. Zupełność i Hopf–Rinow dają $D_p = T_pM$ oraz surjektywność $\exp_p$: każdy q leży na pewnej minimalnej geodezyjnej startującej z p. Z Wniosku 14.12.3 dla $\kappa = 0$ wynika, że niezerowa *normalna* składowa pola Jacobiego z $J(0) = 0$ nie znika ponownie. Składowa styczna ma postać btT, więc całe niezerowe pole również nie może mieć drugiego zera. Stwierdzenie 14.11.6 mówi, że $\mathrm{d}\exp_p$ nie ma jądra, więc $\exp_p$ jest lokalnym dyfeomorfizmem także daleko od 0.

Pokażmy, dlaczego z tego wynika *nakrycie*, a nie tylko lokalna odwracalność. Wyposażmy T_pM w metrykę $g_* := \exp_p^* g$. Jest to metryka riemannowska, a $\exp_p$ staje się lokalną izometrią. Niech $v = r\theta$ i rozłóżmy $w \in T_v(T_pM)$ na część radialną $w_\parallel$ i prostopadłą $w_\perp$. Lemat Gaussa pokazuje ortogonalność obrazów tych części i zachowanie długości radialnej. Dla poprzecznej części $\mathrm{d}(\exp_p)_v(w_\perp)$ jest wartością przy $t = r$ pola Jacobiego o początkowej pochodnej $w_\perp/r$. Rauch z porównaniem do $\mathbb{R}^n$ daje $|\mathrm{d}(\exp_p)_v(w_\perp)| \ge |w_\perp|$. Zatem, także w granicy dla $v = 0$,

$$g_{*,v}(w,w) = |\mathrm{d}(\exp_p)_v(w)|^2_g \ge |w|^2_{g_p}. \tag{14.12.10}$$

Dowolna droga w (T_pM, g_*) ma długość co najmniej równą długości euklidesowej. Jej metryka odległości dominuje więc euklidesową. Ciąg Cauchy'ego dla g_* zbiega euklidesowo do pewnego v; w małym otoczeniu v obie gładkie metryki są porównywalne, więc zbiega też dla g_*. Dziedzina z metryką g_* jest zupełna.

Przypomnijmy używany tutaj fakt o lokalnych izometriach. Surjektywna lokalna izometria $f : N \to M$ z *zupełnego* spójnego N jest nakryciem. Aby zobaczyć mechanizm, weźmy małą normalną kulę $B_\rho(q)$ w M. Dla każdego $x \in f^{-1}(q)$ radialne geodezyjne z q podnoszą się, dzięki zupełności N, do radialnych geodezyjnych startujących w x. Otrzymujemy gładką odwrotną gałąź nad $B_\rho(q)$: odwrotność $(\mathrm{d}f)^{-1}_x$ przenosi początkowy wektor, a wykładnicze odwzorowanie

w N daje jego koniec. Ponieważ złożenie gałęzi z f jest identycznością, jej różniczka jest odwracalna; obraz gałęzi jest więc otwarty, a f jest na nim dyfeomorfizmem na kulę. Dwie takie gałęzie nie mogą się przeciąć: cofnięcie podniesionej geodezyjnej do q wymusiłoby ten sam punkt x. Każdy punkt przeciwobrazu kuli leży na którejś gałęzi, bo można podnieść radialną drogę od niego do q i przedłużyć ją przez cały krótki odcinek. Kula jest więc pokryta rozłącznymi kopiami, co jest definicją nakrycia. Stosujemy ten fakt do $f = \exp_p$.

Jeżeli M jest jednospójna, spójne nakrycie $T_pM \to M$ ma tylko jeden arkusz, zatem jest dyfeomorfizmem. Hopf–Rinow dostarcza geodezyjnej minimalnej między p i każdym q; różnowartościowość $\exp_p$ wymusza jednoznaczność geodezyjnej od p do q. Ponieważ p było dowolne, dotyczy to każdej pary punktów. □

Hiperboloida oraz jej izometryczne modele półprzestrzeni i dysku spełniają założenia twierdzenia: dla nich $K = -1$ i $\exp_p$ jest globalnie odwracalna. Płaski walec z Przykładu 14.11.10 pokazuje rolę jednospójności: jego $K = 0$, lecz $\exp_p$ jest nakryciem o wielu arkuszach, a nie dyfeomorfizmem.

Porównanie objętości Bishopa–Gromowa

Rauch porównuje pojedyncze kierunki, zaś założenie o Riccim kontroluje ich *sumę*. W biegunowych współrzędnych wokół p sumą tę odnajdziemy w pochodnej logarytmu gęstości objętości.

Twierdzenie 14.12.9 (Bishopa–Gromowa)**.** *Niech (M^n, g) będzie spójna i zupełna, $n \geq 2$, oraz* $\mathrm{Ric} \geq (n-1)\kappa g$. *Niech $V_p(r) = \mu_g(B_g(p,r))$ i*

$$V_\kappa(r) = \omega_{n-1} \int_0^r s_\kappa(t)^{n-1}\mathrm{d}t, \qquad \omega_{n-1} = \mathrm{vol}(S^{n-1}). \tag{14.12.11}$$

W przypadku $\kappa > 0$ rozważamy $0 < r < \pi/\sqrt{\kappa}$; w pozostałych przypadkach dowolne $r > 0$. Wówczas

$$r \longmapsto \frac{V_p(r)}{V_\kappa(r)} \quad \textit{jest nierosnąca}, \qquad V_p(r) \leq V_\kappa(r). \tag{14.12.12}$$

Dowód. Krok 1: gęstość wzdłuż jednego promienia. Dla jednostkowego $\theta \in T_pM$ piszemy $\gamma_\theta(t) = \exp_p(t\theta)$. Używamy czasu cięcia $c(\theta)$ z Lematu 14.12.4. Dla $0 < t < c(\theta)$ nie ma punktu sprzężonego na odcinku; macierz Jacobiego $A(t)$ z dowodu Lematu 14.12.1 jest odwracalna. Oznaczmy przez $j(t,\theta) = \det A(t) > 0$ biegunową gęstość objętości. Jest dodatnia, bo $A(t) = t\mathrm{Id} + O(t^3)$, i nie może zmienić znaku bez wyzerowania wyznacznika. Niech $H = A'A^{-1}$ i $m = \operatorname{tr} H$. Wzór na pochodną wyznacznika daje $m = \partial_t \log j$. Biorąc ślad (14.12.3), dostajemy

$$m' = -\operatorname{tr}(H^2) - \mathrm{Ric}(T,T) \leq -\frac{m^2}{n-1} - (n-1)\kappa.$$

Pierwsza nierówność to Cauchy–Schwarz dla wartości własnych symetrycznej macierzy H: $\sum \lambda_i^2 \geq (\sum \lambda_i)^2/(n-1)$. W modelu stałej krzywizny $m_\kappa = (n-1)s_\kappa'/s_\kappa$ spełnia równość w tym równaniu, bo $s_\kappa'' = -\kappa s_\kappa$. Po odjęciu i oznaczeniu $u = m - m_\kappa$ otrzymujemy

$$u' \leq -\frac{m + m_\kappa}{n-1}\, u. \tag{14.12.13}$$

Przy $t \downarrow 0$ rozwinięcie $A = t\mathrm{Id} + O(t^3)$ daje $m = (n-1)/t + O(t)$, a $m_\kappa = (n-1)/t + O(t)$, zatem $u = O(t)$. Niech $b(t) = (m + m_\kappa)/(n-1) = 2/t + O(t)$. Możemy jawnie wybrać czynnik całkujący $\mu(t) = t^2 \exp\bigl(\int_0^t (b(s) - 2/s)\,\mathrm{d}s\bigr)$. Całka jest zbieżna przy zerze, $\mu'/\mu = b$ i $\mu(t)/t^2 \to 1$. Mnożymy nierówność przez ten dodatni czynnik i przechodzimy z dolną granicą całkowania do zera: iloczyn czynnika przez u ma granicę 0. Wynika $u \leq 0$, a więc

$$\partial_t \log \frac{j(t,\theta)}{s_\kappa(t)^{n-1}} = m - m_\kappa \leq 0.$$

Stosunek $h_\theta(t) = j(t,\theta)/s_\kappa(t)^{n-1}$ maleje od wartości 1.

Krok 2: dlaczego wolno całkować tylko do czasu cięcia. Dla $t \geq c(\theta)$ przyjmijmy $h_\theta(t) = 0$. Nadal jest nierosnąca. Na mocy Lematu 14.12.4 odwzorowanie biegunowe jest dyfeomorfizmem przed czasem cięcia, a pominięty zbiór ma miarę zero. Wzór na zmianę zmiennych można więc stosować na tym otwartym zbiorze, a następnie całkować po wszystkich kierunkach dzięki twierdzeniu Tonellego (całkowana funkcja jest nieujemna). Otrzymujemy polarowy wzór

$$V_p(r) = \int_{S_pM} \int_0^r h_\theta(t) s_\kappa(t)^{n-1} \mathrm{d}t \, \mathrm{d}\theta. \tag{14.12.14}$$

Krok 3: iloraz objętości. Prawie wszędzie pochodna $V_p'(r)$ istnieje. Z (14.12.14) wynika, że

$$\frac{V_p'(r)}{V_\kappa'(r)} = \frac{1}{\omega_{n-1}} \int_{S_pM} h_\theta(r) \, \mathrm{d}\theta =: a(r).$$

Każda h_θ jest nierosnąca, więc a także. Ponadto $V_p(r) = \int_0^r a(t) V_\kappa'(t) \mathrm{d}t$; iloraz $V_p(r)/V_\kappa(r)$ jest zatem średnią wartości $a(t)$ z dodatnią wagą $V_\kappa'(t)$. Dla nierosnącej a ta średnia jest co najmniej $a(r)$. Reguła ilorazu daje prawie wszędzie

$$\left(\frac{V_p}{V_\kappa}\right)' = \frac{V_\kappa'}{V_\kappa}\left(a(r) - \frac{V_p}{V_\kappa}\right) \leq 0.$$

Ponieważ $0 \leq a \leq 1$, wzór całkowy pokazuje, że V_p jest lokalnie absolutnie ciągła. Na każdym zwartym przedziale promieni dodatnich V_κ jest gładka i dodatnia, więc iloraz również jest absolutnie ciągły. Całkując jego niedodatnią pochodną, otrzymujemy monotoniczność wszędzie. Sama ciągłość i nierówność dla pochodnej prawie wszędzie nie wystarczyłyby do tego wniosku. Przy $r \downarrow 0$ obie objętości mają asymptotykę $\omega_{n-1} r^n/n$, stąd iloraz dąży do 1 i otrzymujemy drugą część (14.12.12). □

Ten sam rachunek daje *porównanie laplasjanu odległości*. Przy konwencji $\Delta r = \operatorname{div}(\nabla r) = \operatorname{tr}_g \operatorname{Hess} r$, poza p i zbiorem cięcia,

$$\operatorname{Ric} \geq (n-1)\kappa g \quad \Longrightarrow \quad \Delta r = \operatorname{tr}(A' A^{-1}) = m \leq (n-1) c_\kappa(r). \tag{14.12.15}$$

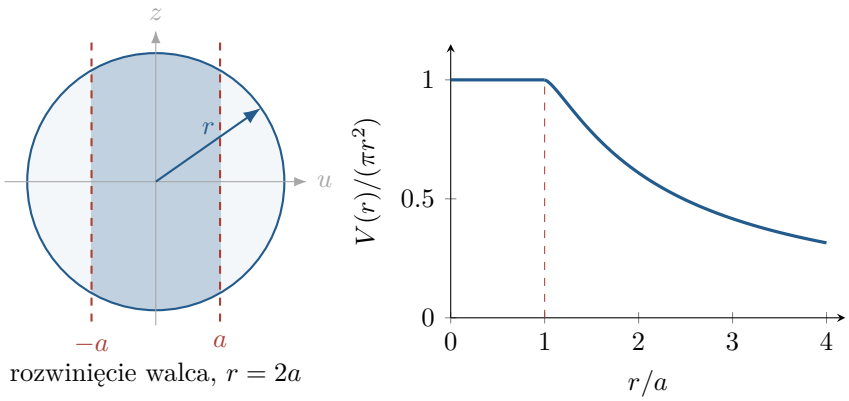
To właśnie nierówność z Kroku 1 dowodu Bishopa–Gromowa. Gdy $K \leq \kappa$, ślad (14.12.6) daje odwrotną nierówność $\Delta r \geq (n-1)c_\kappa(r)$. Obie działają w odpowiednim zakresie $s_\kappa(r) > 0$ przed zbiorem cięcia.

Przykład 14.12.10 (Co widać w modelach)**.** Dla $\mathbb{R}^n$ przy $\kappa = 0$ oraz $\mathbb{H}^n$ przy $\kappa = -1$ iloraz $V_p(r)/V_\kappa(r)$ jest stale równy 1. Na S^n_R zachodzi to samo dla $\kappa = R^{-2}$ i $r < \pi R$. Na płaskim walcu Ricci jest zerowy, ale objętość dużej kuli rośnie tylko liniowo z promieniem, podczas gdy dla $\mathbb{R}^2$ rośnie jak r^2: sam warunek $\operatorname{Ric} \geq 0$ nie wymusza euklidesowego *dolnego* tempa wzrostu objętości.

Policzmy to dla $S^1_R \times \mathbb{R}$, $R > 0$. Po rozwinięciu walca wybieramy reprezentantów $-\pi R \leq u \leq \pi R$, gdzie $u = R\theta$. Odległość od $(0,0)$ to $\sqrt{u^2 + z^2}$: spośród podniesień $(u + 2k\pi R, z)$ właśnie ten reprezentant ma najmniejszą wartość $|u + 2k\pi R|$. Kula jest więc obrazem przecięcia dysku euklidesowego z tym pasem. Utożsamienie jego brzegów nie zmienia pola, bo mają miarę zero. Oznaczając $a = \pi R$, otrzymujemy

$$V(r) = \int_{-\min(r,a)}^{\min(r,a)} 2\sqrt{r^2 - u^2} \, \mathrm{d}u = \begin{cases} \pi r^2, & 0 < r \leq a, \\ 2a\sqrt{r^2 - a^2} + 2r^2 \arcsin(a/r), & r > a. \end{cases}$$

Użyliśmy funkcji pierwotnej $u\sqrt{r^2 - u^2} + r^2 \arcsin(u/r)$. Oba wzory zgadzają się przy $r = a$. Ponieważ $\sqrt{1 - a^2/r^2} \to 1$ i $\arcsin(a/r)/(a/r) \to 1$, mamy $V(r)/(4\pi R r) \to 1$ przy $r \to \infty$. Iloraz $V(r)/(\pi r^2)$ jest równy 1 do promienia injektywności a i następnie maleje do zera.



Rysunek 14.13: Kule na płaskim walcu i porównanie Bishopa–Gromowa. Po lewej zacieniowany obszar ma pole $V(2a)$; przeciwległe brzegi pasa są utożsamione, a $a = \pi R$. Po prawej iloraz pola kuli walca i kuli płaszczyzny: maleje, gdy promień kuli przekracza a, mimo że $K = \mathrm{Ric} = 0$.

Uwaga 14.12.11 (Która krzywizna kontroluje co?). Rauch i porównanie hesjanu korzystają z granic na każdą *krzywiznę sekcyjną*; Bonnet–Myers i Bishop–Gromov tylko z granic na *Ricciego*, czyli sumę takich krzywizn. Cartan–Hadamard dodaje do $K \le 0$ zupełność i jednospójność, by otrzymać globalną informację o topologii i jednoznaczności geodezyjnych. Zamiana górnej granicy na dolną odwraca kierunek porównania.

14.13 Twierdzenie Gaussa–Bonneta

Dotąd krzywizna opisywała geometrię w pobliżu punktu: jak rozchodzą się geodezyjne i jak zmienia się transport równoległy. Teraz zsumujemy krzywiznę *na całej powierzchni*. Wynik zależy od liczby składowych, uchwytów i brzegów powierzchni, czyli od jej topologii. Jest to szczególnie wyraźne po porównaniu sfery z torusem.

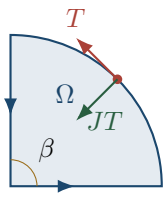
W całej sekcji S jest powierzchnią z *metryką riemannowską*, $K(p) = K_p(T_pS)$ jej krzywizną sekcyjną, a $\mathrm{d}A$ dodatnim elementem pola z Sekcji 11.5. Dla powierzchni zanurzonej w $\mathbb{R}^3$ twierdzenie Gaussa utożsamia tę krzywiznę z iloczynem krzywizn głównych. Całkę $\int_S K\,\mathrm{d}A$ można określić również wtedy, gdy S nie jest orientowalna: $K\,\mathrm{d}A$ jest gęstością, nie wymaga więc wyboru orientacji. W dowodzie najpierw wybierzemy orientację.

Definicja 14.13.1 (Krzywizna geodezyjna i skręt narożnika)**.** Niech S będzie zorientowana, a $J : T_pS \to T_pS$ oznacza dodatni obrót o $90°$: jeżeli (e_1, e_2) jest dodatnią bazą ortonormalną, to $Je_1 = e_2$. Dla łuku brzegu parametryzowanego długością s oznaczmy jednostkowy wektor styczny przez $T = \dot\gamma(s)$. *Krzywizna geodezyjna ze znakiem* tego łuku wynosi

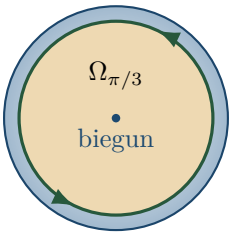
$$k_g = g(\nabla_T T, JT). \tag{14.13.1}$$

W punkcie narożnym niech $\beta \in (0, 2\pi)$ oznacza kąt *wewnątrz* obszaru. Jego *zewnętrzny skręt* to $\varepsilon = \pi - \beta$; dla wklęsłego narożnika jest ujemny. Brzeg obszaru orientujemy tak, aby wnętrze znajdowało się po lewej stronie ruchu. Na łuku gładkim JT wskazuje wtedy lokalnie wnętrze obszaru.

Skąd w definicji znak? Na brzegu euklidesowego dysku promienia r, przebieganym przeciwnie do ruchu wskazówek zegara, $\nabla_T T$ wskazuje środek i ma długość $1/r$. Wektor JT także wskazuje środek, więc $k_g = 1/r$. Na brzegu otworu dodatni kierunek obiegu jest odwrotny: JT wskazuje wówczas na zewnątrz otworu, a k_g okręgu jest ujemne. Równość $k_g = 0$ znaczy, że łuk jest geodezyjną (zob. Sekcję 13.1).



dodatnio zorientowany brzeg



widok od bieguna północnego

Rysunek 14.14: Po lewej ćwierćdysk z dodatnio zorientowanym brzegiem: T jest styczny do okręgu, a JT skierowany do obszaru; zaznaczony kąt wewnętrzny to $\beta = \pi/2$. Po prawej rzut czapki sferycznej o kącie biegunowym $\theta_0 = \pi/3$. Jej brzeg obiegamy przeciwnie do ruchu wskazówek zegara, zgodnie z orientacją od zewnętrznej normalnej sfery.

Twierdzenie 14.13.2 (Gaussa–Bonneta z brzegiem i narożnikami)**.** *Niech Ω będzie zwartą, zorientowaną powierzchnią riemannowską z brzegiem złożonym ze skończonej liczby regularnych łuków klasy C^2. Załóżmy, że w narożnikach istnieją jednostronne styczne i kąty wewnętrzne $\beta_1, \dots, \beta_m \in (0, 2\pi)$. Wówczas*

$$\boxed{\int_\Omega K \,\mathrm{d}A + \int_{\partial\Omega} k_g \,\mathrm{d}s + \sum_{j=1}^{m} (\pi - \beta_j) = 2\pi\chi(\Omega).} \tag{14.13.2}$$

Brzeg całkujemy odcinek po odcinku. Dla brzegu gładkiego suma po narożnikach jest pusta. Charakterystykę Eulera można obliczyć z triangulacji: $\chi(\Omega) = V - E + F$, gdzie V, E, F są liczbami wierzchołków, krawędzi i trójkątów; zgadza się to z opisem homologicznym z Twierdzenia 6.8.7.

Dowód. Krok 1: forma koneksji na małym obszarze. Załóżmy najpierw, że $D \subset \Omega$ jest topologicznym dyskiem, leży w jednej dodatnio zorientowanej mapie i ma brzeg odcinkami gładki. Na otoczeniu D wybierzmy dodatnią ortonormalną ramę (e_1, e_2), $e_2 = Je_1$. Istnieje ona na małym obszarze współrzędnych: wektor pierwszej osi można unormować, a drugi otrzymać przez J. Definiujemy lokalną 1-formę

$$\alpha(X) = g(\nabla_X e_1, e_2).$$

Zgodność koneksji z metryką, czyli $Xg(e_i, e_j) = g(\nabla_X e_i, e_j) + g(e_i, \nabla_X e_j)$, daje dokładnie

$$\nabla_X e_1 = \alpha(X) e_2, \qquad \nabla_X e_2 = -\alpha(X) e_1. \tag{14.13.3}$$

Obliczmy z tego tensor krzywizny przy przyjętym tu znaku (14.1.1). Współczynnik przy e_2 wektora $\nabla_X \nabla_Y e_1$ wynosi $X(\alpha(Y))$; wyrazy przy e_1 z dwóch kolejności odejmują się. Dlatego

$$R(X,Y)e_1 = \big(X\alpha(Y) - Y\alpha(X) - \alpha([X,Y])\big)e_2 = \mathrm{d}\alpha(X,Y)e_2.$$

Dla dodatniej ramy ortonormalnej definicja krzywizny sekcyjnej mówi, że $g(R(e_1,e_2)e_2, e_1) = K$. Ponieważ $R(e_1,e_2)$ jest antysymetryczny względem g, mamy również $g(R(e_1,e_2)e_1, e_2) = -K$. Porównanie z poprzednią równością daje

$$\mathrm{d}\alpha = -K \,\mathrm{d}A. \tag{14.13.4}$$

Minus w tym miejscu jest konsekwencją naszej konwencji dla R; jego zgubienie odwróciłoby znak całki z K.

Krok 2: krzywizna łuku jako obrót stycznej. Na gładkim łuku brzegu dysku można wybrać ciągłą funkcję kąta $\vartheta(s)$ taką, że $T = \cos\vartheta\, e_1 + \sin\vartheta\, e_2$. Różniczkując ten wzór wzdłuż łuku i podstawiając (14.13.3), otrzymujemy

$$\nabla_T T = \big(\vartheta'(s) + \alpha(T)\big)\big(-\sin\vartheta\, e_1 + \cos\vartheta\, e_2\big) = \big(\vartheta'(s) + \alpha(T)\big) JT.$$

Stąd $k_g\,\mathrm{d}s = \mathrm{d}\vartheta + \alpha$ na każdym łuku. Przy przejściu przez narożnik kierunek stycznej obraca się dodatkowo o $\pi - \beta_j$: w wypukłym narożniku w lewo, we wklęsłym w prawo.

Suma zmian kąta ϑ na łukach wraz z obrotami w narożnikach wynosi 2π. Jest to twierdzenie o obrocie stycznej do dodatnio zorientowanej krzywej Jordana na płaszczyźnie. Żeby zobaczyć, skąd bierze się liczba 2π, można łuki przybliżyć łamanymi wraz z ich kierunkami stycznymi. W prostym wielokącie o v wierzchołkach można poprowadzić $v-3$ przekątnych i otrzymać $v-2$ trójkąty. Suma kątów wewnętrznych to $(v-2)\pi$, a suma skrętów zewnętrznych wynosi $v\pi - (v-2)\pi = 2\pi$. Przy zagęszczaniu łamanej skręty wewnątrz łuków dążą do całek z $\vartheta'\mathrm{d}s$; skręty w pierwotnych narożnikach zostają. Wybór dodatniej ramki nad dyskiem nie zmienia wyniku. Przejście od ramki współrzędnych do ramki ortonormalnej jest odwzorowaniem do $\mathrm{GL}^+(2,\mathbb{R})$, a nie samym obrotem. W rozkładzie polarnym tej macierzy dodatnio określony czynnik deformujemy do identyczności przez $(1-s)P + s\mathrm{Id}$; niezerowa styczna pozostaje niezerowa, więc jej liczba obrotów się nie zmienia. Pozostaje odwzorowanie obrotów do $\mathrm{SO}(2)$. Przedłuża się ono na cały dysk, zatem na brzegu ma stopień zero. Liczba obrotów stycznej w naszej ramce nadal wynosi 1.

Sumujemy równość $k_g\mathrm{d}s = \mathrm{d}\vartheta + \alpha$ po łukach, dodajemy obroty narożników i stosujemy Twierdzenie Stokesa 10.7.1 oraz (14.13.4):

$$\int_{\partial D} k_g\,\mathrm{d}s + \sum_j (\pi - \beta_j) = 2\pi + \int_{\partial D}\alpha = 2\pi - \int_D K\,\mathrm{d}A. \tag{14.13.5}$$

Stokesa dla brzegu z narożnikami można tu uzyskać z wersji dla brzegu gładkiego przez zaokrąglenie narożników: długość usuniętych łuków i pole usuniętych małych fragmentów dążą do zera, a α i $\mathrm{d}\alpha$ są ograniczone na zwartym otoczeniu. Zaokrąglamy *tylko* przy zastosowaniu Stokesa; powyższe skręty narożników pozostają w rachunku kątów. Tak otrzymaliśmy wzór dla dysku, ponieważ $\chi(D) = 1$.

Krok 3: sklejenie lokalnych wzorów. Wybierzmy skończoną gładką triangulację Ω na tyle drobną, aby każdy jej trójkąt leżał w jednej mapie; narożniki brzegu włączmy do zbioru wierzchołków. Można to zrobić, korzystając z triangulowalności gładkich powierzchni, z regularnymi krawędziami i niezdegenerowanymi kątami trójkątów przy wierzchołkach. Zastosujmy (14.13.5) do każdego z F trójkątów i zsumujmy. Całki K sumują się do całki po Ω. Na wewnętrznej krawędzi dwie orientacje są przeciwne, a wraz z nimi zmienia się znak k_g, więc jej wkłady znoszą się. Zostaje całka po rzeczywistym brzegu.

Oznaczmy liczbę wierzchołków wewnętrznych przez V_{w}, a brzegowych przez V_{b}. Przy każdym wewnętrznym wierzchołku suma kątów trójkątów wynosi 2π, a przy każdym brzegowym wynosi kąt β_v obszaru (jeśli brzeg jest tam gładki, $\beta_v = \pi$). Suma zewnętrznych skrętów *wszystkich trójkątów* jest więc $3\pi F - 2\pi V_{\mathrm{w}} - \sum_{v\in\partial\Omega}\beta_v$. Po zsumowaniu (14.13.5) dostajemy

$$\int_\Omega K\,\mathrm{d}A + \int_{\partial\Omega} k_g\,\mathrm{d}s = -\pi F + 2\pi V_{\mathrm{w}} + \sum_{v\in\partial\Omega}\beta_v. \tag{14.13.6}$$

Każda krawędź wewnętrzna należy do dwóch trójkątów, a brzegowa do jednego. Każda składowa brzegu jest zamkniętym cyklem z taką samą liczbą krawędzi jak wierzchołków. Zatem $3F = 2E - V_{\mathrm{b}}$ (w przypadku pustego brzegu oba ostatnie zliczenia brzegowe są zerowe). Ponieważ $V = V_{\mathrm{w}} + V_{\mathrm{b}}$,

$$2\pi(V - E + F) - \sum_{v\in\partial\Omega}(\pi - \beta_v) = -\pi F + 2\pi V_{\mathrm{w}} + \sum_{v\in\partial\Omega}\beta_v.$$

Wstawiamy tę tożsamość do (14.13.6). Sztucznie wstawione wierzchołki na gładkich częściach brzegu mają $\beta_v = \pi$ i niczego nie dodają. Otrzymujemy (14.13.2). □

Wniosek 14.13.3 (Gauss–Bonnet dla powierzchni zamkniętej)**.** *Jeżeli S jest zwartą powierzchnią bez brzegu, to*

$$\boxed{\int_S K \,\mathrm{d}A = 2\pi\chi(S).} \tag{14.13.7}$$

W szczególności dla spójnej orientowalnej powierzchni rodzaju g prawa strona wynosi $4\pi(1-g)$.

Dowód. Dla powierzchni orientowalnej stosujemy Twierdzenie 14.13.2 przy $\partial S = \varnothing$. Z klasyfikacji powierzchni zamkniętych $\chi(S) = 2-2g$; równoważnie można tę liczbę policzyć z dowolnej triangulacji standardowego modelu sfery z g uchwytami. Jeśli S nie jest orientowalna, bierzemy jej dwukrotne nakrycie orientacyjne $\widetilde{S} \to S$. Metryka podniesiona ma te same lokalne wartości K, a każdy mały obszar na S występuje dwa razy na $\widetilde{S}$, więc $\int_{\widetilde{S}} K\mathrm{d}A = 2\int_S K\mathrm{d}A$. Podnosząc triangulację, otrzymujemy też $\chi(\widetilde{S}) = 2\chi(S)$. Dzielimy zorientowany wzór przez 2. □

Przykład 14.13.4 (Dysk i czapka sferyczna)**.** Dysk euklidesowy D_r ma $K=0$, $k_g = 1/r$ i brzeg długości $2\pi r$. Stąd $\int_{\partial D_r} k_g \mathrm{d}s = 2\pi = 2\pi\chi(D_r)$. Gdyby pominąć całkę po brzegu, wyszłaby fałszywa równość $0 = 2\pi$. Dla płaskiego pierścienia o promieniach $0<r<R$ zewnętrzny okrąg wnosi 2π, wewnętrzny -2π: suma wynosi 0, zgodnie z $\chi(S^1\times[0,1])=0$.

Na sferze S^2_R opiszmy czapkę od bieguna północnego do kąta biegunowego (kolatytudy) $\theta_0 \in (0,\pi)$:

$$0 \le \theta \le \theta_0, \qquad g = R^2(\mathrm{d}\theta^2 + \sin^2\theta\,\mathrm{d}\varphi^2), \qquad K = R^{-2}.$$

Z elementu pola $R^2\sin\theta\,\mathrm{d}\theta\mathrm{d}\varphi$ dostajemy

$$\int_{\Omega_{\theta_0}} K\mathrm{d}A = \int_0^{2\pi}\int_0^{\theta_0} \sin\theta\,\mathrm{d}\theta\mathrm{d}\varphi = 2\pi(1-\cos\theta_0).$$

Brzeg ma długość $2\pi R\sin\theta_0$. Jego dodatnio skierowany styczny to $T = (R\sin\theta_0)^{-1}\partial_\varphi$, a $JT = -R^{-1}\partial_\theta$. Ponieważ $\Gamma^\theta_{\varphi\varphi} = -\sin\theta\cos\theta$, wzór (14.13.1) daje

$$k_g = \frac{\cos\theta_0}{R\sin\theta_0}, \qquad \int_{\partial\Omega_{\theta_0}} k_g \mathrm{d}s = 2\pi\cos\theta_0.$$

Suma obu całek to 2π, zgodnie z $\chi=1$. Dla półsfery $\theta_0=\pi/2$ równik jest geodezyjną i cały wkład pochodzi z K; dla czapki większej niż półsfera wkład brzegu jest *ujemny*.

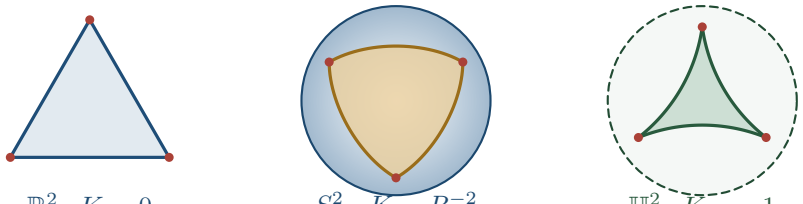
Przykład 14.13.5 (Kąty trójkąta geodezyjnego)**.** Niech trzy łuki geodezyjne tworzą prostą zamkniętą krzywą ograniczającą obszar Δ homeomorficzny z domkniętym dyskiem, o kątach wewnętrznych A, B, C. Wtedy $k_g = 0$ na każdym boku, a $\chi(\Delta)=1$. Z (14.13.2) wynika

$$\int_\Delta K\,\mathrm{d}A = A + B + C - \pi. \tag{14.13.8}$$

W płaszczyźnie daje to $A+B+C=\pi$. Na sferze S^2_R pole trójkąta to $R^2(A+B+C-\pi)$. Trójkąt o wierzchołkach na biegunie północnym i w dwóch punktach równika oddalonych o ćwierć obwodu ma $A=B=C=\pi/2$; jako jedna ósma sfery ma pole $\pi R^2/2$. W płaszczyźnie hiperbolicznej $K=-1$,

$$\mathrm{Area}(\Delta) = \pi - (A+B+C) > 0.$$

To wprost pokazuje, jak dodatnia i ujemna krzywizna zmieniają sumę kątów. Rysunek 14.15 zestawia odpowiednie geodezyjne w trzech modelach.



$\mathbb{R}^2,\ K=0$
$A+B+C=\pi$

$S^2_R,\ K=R^{-2}$
$A=B=C=\pi/2$

$\mathbb{H}^2,\ K=-1$
$A+B+C<\pi$

Rysunek 14.15: Trójkąty geodezyjne w geometrii euklidesowej, na sferze i w modelu dyskowym płaszczyzny hiperbolicznej. Środkowy trójkąt jest oktantem sfery: każdy jego bok stanowi ćwiartkę wielkiego koła, a każdy kąt jest prosty. W dysku boki leżą na okręgach prostopadłych do przerywanego brzegu, który nie należy do $\mathbb{H}^2$. Znaki K odpowiadają sumom kątów ze wzoru (14.13.8).

Przykład 14.13.6 (Sfera i torus: całka nie zależy od metryki)**.** Na sferze S^2_R stała krzywizna R^{-2} i pole $4\pi R^2$ dają całkę 4π; promień się skraca. Na torusie obrotowym niech $a>b>0$, a parametryzacja ma postać

$$X(u,v)=((a+b\cos v)\cos u,(a+b\cos v)\sin u,b\sin v),\qquad (u,v)\in[0,2\pi]^2.$$

Różniczkując X znajdujemy $g=(a+b\cos v)^2\mathrm{d}u^2+b^2\mathrm{d}v^2$ i $\mathrm{d}A=b(a+b\cos v)\mathrm{d}u\mathrm{d}v$. Dla metryki postaci $\mathrm{d}s^2+f(s)^2\mathrm{d}u^2$ rachunek z symboli Christoffela daje $K=-f''(s)/f(s)$: jedyne niezerowe symbole to $\Gamma^s_{uu}=-ff'$ oraz $\Gamma^u_{su}=\Gamma^u_{us}=f'/f$, więc $g(R(\partial_s,\partial_u)\partial_u,\partial_s)=-ff''$, a mianownik we wzorze na K wynosi f^2. Biorąc $s=bv$ i $f(s)=a+b\cos(s/b)$, otrzymujemy

$$K(u,v)=\frac{\cos v}{b(a+b\cos v)},\qquad \int_{T^2}K\,\mathrm{d}A=\int_0^{2\pi}\!\!\int_0^{2\pi}\cos v\,\mathrm{d}u\mathrm{d}v=0.$$

Krzywizna dodatnia po zewnętrznej i ujemna po wewnętrznej stronie torusa znoszą się w całce. Zgadza się to z $\chi(T^2)=0$. Zmiana metryki zmienia lokalne K i $\mathrm{d}A$, ale nie może zmienić ich całki na tej samej zwartej powierzchni.

Uogólnienie I: krzywizna skupiona w punktach

Na gładkiej powierzchni krzywizna $K\,\mathrm{d}A$ jest rozłożona na obszarze. Można jednak skleić płaskie wielokąty w zamkniętą powierzchnię: wnętrze każdej ściany i punkt wewnętrzny każdej sklejonej krawędzi ma płaskie otoczenie. Cała krzywizna jest wtedy skupiona w *wierzchołkach*. Przy wierzchołku v sumujemy kąty przylegających ścian i oznaczamy tę sumę przez θ_v. Brakujący względem pełnego obrotu kąt

$$\delta_v=2\pi-\theta_v \tag{14.13.9}$$

nazywamy *deficytem kąta*. Może być ujemny, jeśli wokół wierzchołka mieści się więcej niż 2π. Lokalnie jest to powierzchnia stożka o kącie całkowitym θ_v; zwykły płaski punkt ma $\theta_v=2\pi$.

Twierdzenie 14.13.7 (Wielościenna postać Gaussa–Bonneta)**.** *Niech P będzie zwartą powierzchnią bez brzegu, powstałą przez sklejenie skończonej liczby trójkątów euklidesowych wzdłuż całych boków. Oznaczmy zbiór jej wierzchołków przez* $\mathrm{Vert}(P)$*. Wówczas*

$$\boxed{\sum_{v\in\mathrm{Vert}(P)}(2\pi-\theta_v)=2\pi\chi(P).} \tag{14.13.10}$$

W sumie można pominąć wierzchołki o $\theta_v=2\pi$.

Dowód. Niech V, E, F oznaczają liczbę wierzchołków, krawędzi i trójkątów. Przy każdym v odejmujemy od 2π wszystkie kąty trójkątów stykających się w v. Każdy kąt pojawia się dokładnie raz, a suma trzech kątów jednego płaskiego trójkąta wynosi π. Dlatego

$$\sum_v (2\pi - \theta_v) = 2\pi V - \pi F.$$

Każdy trójkąt ma trzy boki, a każda krawędź należy do dwóch trójkątów, zatem $3F = 2E$. W konsekwencji $2\pi V - \pi F = 2\pi(V - E + F) = 2\pi\chi(P)$. Ten rachunek wyjaśnia, dlaczego liczymy kąty *wewnątrz* ścian, a nie kąty dwuścienne bryły w $\mathbb{R}^3$. □

Przykład 14.13.8 (Czworościan i sześcian)**.** W każdym wierzchołku foremnego czworościanu spotykają się trzy trójkąty równoboczne. Zatem $\theta_v = \pi$, $\delta_v = \pi$, a cztery wierzchołki dają 4π. W sześcianie spotykają się trzy kąty proste: $\theta_v = 3\pi/2$ i $\delta_v = \pi/2$; osiem wierzchołków znowu daje 4π. Obie powierzchnie są topologicznie sferami, więc $2\pi\chi(S^2) = 4\pi$. Rozkład krzywizny jest inny, lecz suma pozostaje taka sama.

Możemy połączyć krzywiznę gładką z punktowymi deficytami. Załóżmy, że zwarta powierzchnia S bez brzegu ma skończenie wiele punktów p_i o otoczeniach będących płaskimi stożkami o kątach θ_i, a poza nimi jest gładką powierzchnią riemannowską. Wtedy

$$\boxed{\int_{S\setminus\{p_1,\dots,p_N\}} K\,\mathrm{d}A + \sum_{i=1}^{N}(2\pi - \theta_i) = 2\pi\chi(S).} \tag{14.13.11}$$

Istotnie, wytnijmy wnętrza małych dysków stożkowych D_i przy punktach p_i i oznaczmy pozostałą powierzchnię z brzegiem przez $S_0 = S\setminus\bigcup_i \operatorname{int} D_i$. Ma ona charakterystykę Eulera $\chi(S) - N$. Brzeg usuniętego dysku ma długość $\theta_i r$ i krzywiznę geodezyjną $-1/r$: minus bierze się z orientacji brzegu *dziury*. Jego wkład do całki brzegowej to zatem $-\theta_i$. Podstawienie do (14.13.2) daje $\int_{S_0} K\,\mathrm{d}A - \sum_i \theta_i = 2\pi(\chi(S) - N)$, co po przeniesieniu wyrazów jest (14.13.11). Wycięte otoczenia poza wierzchołkami są płaskie, więc całka po S_0 jest równa całce po $S \setminus \{p_1, \dots, p_N\}$. Dla powierzchni nieorientowalnej stosujemy ten rachunek na dwukrotnym nakryciu orientacyjnym i dzielimy przez 2: całka, liczba deficytów i charakterystyka Eulera podwajają się. Gdy część gładka jest płaska, pozostaje dokładnie (14.13.10). W języku miar można myśleć o krzywiźnie jako o $K\,\mathrm{d}A + \sum_i \delta_i \delta_{p_i}$: symbol δ_{p_i} oznacza masę jednostkową w punkcie, a współczynnik δ_i jest deficytem kąta.

Uogólnienie II: parzysty wymiar i twierdzenie Cherna

W wymiarze dwa K jest całą informacją o krzywiźnie riemannowskiej w danym punkcie. W wymiarze cztery lub większym nie wystarczy scałkować samej krzywizny skalarnej: liczy się określona *kombinacja* składowych tensora Riemanna. Oto jej precyzyjny opis w języku form.

Niech (M^{2m}, g), $m \geq 1$, będzie zorientowaną rozmaitością riemannowską, a $(e_1, \dots, e_{2m})$ dodatnio zorientowaną lokalną ramą ortonormalną. Macierz form krzywizny ma wyrazy

$$\Omega_{ij}(X, Y) = g(R(X, Y)e_j, e_i), \qquad \Omega_{ji} = -\Omega_{ij}.$$

Pfaffian takiej macierzy jest formą stopnia $2m$:

$$\operatorname{Pf}(\Omega) = \frac{1}{2^m m!} \sum_{\sigma \in S_{2m}} \operatorname{sgn}(\sigma)\, \Omega_{\sigma(1)\sigma(2)} \wedge \cdots \wedge \Omega_{\sigma(2m-1)\sigma(2m)}. \tag{14.13.12}$$

Zasada konstrukcji: parujemy wszystkie kierunki styczne, bierzemy iloczyny zewnętrzne odpowiadających im krzywizn i dodajemy je ze znakami wyznaczonymi przez permutacje. Dlaczego

otrzymujemy globalną formę? Przy zmianie dodatniej ramki macierzą $Q \in \mathrm{SO}(2m)$ mamy $\widetilde{\Omega} = Q^{\mathsf{T}}\Omega Q$ oraz $\mathrm{Pf}(Q^{\mathsf{T}}\Omega Q) = \det(Q)\,\mathrm{Pf}(\Omega) = \mathrm{Pf}(\Omega)$. Tożsamość wynika z rozpisania wzoru permutacyjnego: po antysymetryzacji iloczyn $2m$ współczynników Q daje jego wyznacznik. Nie ma pochodnych Q, bo Ω pochodzi z tensora krzywizny. Lokalne formy sklejają się więc na przecięciach map. W orientacji przeciwnej znak formy się zmienia razem ze znakiem całkowania. Dla $m = 1$ dostajemy po prostu $\mathrm{Pf}(\Omega) = \Omega_{12} = K\,\mathrm{d}A$; normalizacja z poniższego twierdzenia daje zatem dokładnie (14.13.7).

Twierdzenie 14.13.9 (Cherna–Gaussa–Bonneta)**.** *Jeżeli (M^{2m}, g) jest zwartą, zorientowaną rozmaitością riemannowską* bez brzegu*, to*

$$\boxed{\chi(M) = \frac{1}{(2\pi)^m}\int_M \mathrm{Pf}(\Omega).} \tag{14.13.13}$$

Forma $\mathrm{Pf}(\Omega)/(2\pi)^m$ reprezentuje w kohomologiach de Rhama rzeczywistą klasę Eulera *wiązki stycznej TM. Całka nie zależy więc od wyboru metryki, choć sam Pfaffian zależy od niej punktowo.*

Dowód przez teorię Cherna–Weila przedstawiamy w Rozdziale 17. Warto rozdzielić jego kroki: zamkniętość formy i niezależność jej klasy od koneksji nie wystarczają jeszcze do rozpoznania klasy Eulera. Tę identyfikację daje Stwierdzenie 17.2.2, korzystające z klasy Thoma z Twierdzenia 21.8.1. Lemat 17.2.1 ustala normalizację formy kątowej: jej całka po każdym włóknie sferycznym wynosi 1. Twierdzenie Stokesa wiąże następnie całkę z Pfaffianu z sumą indeksów zer pola stycznego, równą $\chi(M)$. Tu wykonujemy dwa testy wzoru: przypadek $m = 1$ powyżej oraz następujący przykład czterowymiarowy.

W wymiarze cztery

$$\mathrm{Pf}(\Omega) = \Omega_{12}\wedge\Omega_{34} - \Omega_{13}\wedge\Omega_{24} + \Omega_{14}\wedge\Omega_{23}. \tag{14.13.14}$$

Po rozpisaniu w ortonormalnej ramie, przy normach $|\mathrm{Rm}|^2 = \sum_{i,j,k,l} R_{ijkl}^2$ i $|\mathrm{Ric}|^2 = \sum_{i,j}\mathrm{Ric}_{ij}^2$, otrzymujemy równoważną postać. Wskażmy algebraiczny krok prowadzący do współczynników $1, -4, 1$. Niech η^a będzie ramką dualną i $\varepsilon_{1234} = 1$ symbolem całkowicie antysymetrycznym. Ponieważ $\Omega_{ij} = \tfrac{1}{2}\mathcal{R}_{abji}\eta^a\wedge\eta^b$, wzór permutacyjny daje

$$\mathrm{Pf}(\Omega) = \frac{1}{32}\varepsilon_{ijkl}\varepsilon_{abcd}\mathcal{R}_{abji}\mathcal{R}_{cdlk}\,\mathrm{d}\mu_g = \frac{1}{8}\bigl(|\mathrm{Rm}|^2 - 4|\mathrm{Ric}|^2 + \mathrm{Scal}^2\bigr)\,\mathrm{d}\mu_g.$$

W ostatnim przejściu rozwijamy $\varepsilon_{ijkl}\varepsilon_{abcd} = \det(\delta_{uv})_{u\in(i,j,k,l),\,v\in(a,b,c,d)}$. Po zebraniu 24 permutacji, użyciu antysymetrii par, symetrii zamiany par i pierwszej tożsamości Bianchiego kontrakcja wynosi $4|\mathrm{Rm}|^2 - 16|\mathrm{Ric}|^2 + 4\mathrm{Scal}^2$. Iloczyn czynnika $1/8$ z $(2\pi)^{-2}$ daje zatem

$$\chi(M^4) = \frac{1}{32\pi^2}\int_{M^4}\bigl(|\mathrm{Rm}|^2 - 4|\mathrm{Ric}|^2 + \mathrm{Scal}^2\bigr)\,\mathrm{d}\mu_g. \tag{14.13.15}$$

Obecność trzech składników pokazuje, czemu $\int_{M^4}\mathrm{Scal}\,\mathrm{d}\mu_g$ sama nie może być czterowymiarowym odpowiednikiem $\int_S K\,\mathrm{d}A$.

Przykład 14.13.10 (Iloczyn dwóch sfer)**.** Na $M = S^2_a \times S^2_b$ wybierzmy ramę (e_1, e_2) styczną do pierwszej sfery i (e_3, e_4) styczną do drugiej. W metryce iloczynowej jedyne niezerowe formy krzywizny występujące w (14.13.14) to $\Omega_{12} = a^{-2}\mathrm{d}A_a$ i $\Omega_{34} = b^{-2}\mathrm{d}A_b$. Stąd

$$\frac{1}{(2\pi)^2}\int_M \mathrm{Pf}(\Omega) = \frac{1}{4\pi^2}\left(\frac{4\pi a^2}{a^2}\right)\left(\frac{4\pi b^2}{b^2}\right) = 4.$$

Zgadza się to z $\chi(S^2\times S^2) = 4$: komórki iloczynowego rozkładu CW to jedna 0-komórka, dwie 2-komórki i jedna 4-komórka. Promienie ponownie znikają z wyniku. Sprawdźmy też postać (14.13.15). W bazie produktowej $|\mathrm{Rm}|^2 = 4(a^{-4}+b^{-4})$, $|\mathrm{Ric}|^2 = 2(a^{-4}+b^{-4})$ i $\mathrm{Scal} = 2(a^{-2}+b^{-2})$. Zatem $|\mathrm{Rm}|^2 - 4|\mathrm{Ric}|^2 + \mathrm{Scal}^2 = 8a^{-2}b^{-2}$. Iloczyn z objętością $16\pi^2 a^2 b^2$, podzielony przez $32\pi^2$, znowu wynosi 4.

Brzeg, niezwartość i nieparzysty wymiar

Dla zwartej, zorientowanej rozmaitości riemannowskiej parzystego wymiaru o gładkim brzegu twierdzenie Cherna ma wersję z poprawką brzegową. Jej precyzyjną definicję i dowód podajemy w Twierdzeniu 17.3.1; tutaj zapisujemy wzór:

$$\chi(M^{2m}) = \frac{1}{(2\pi)^m} \int_M \operatorname{Pf}(\Omega) + \int_{\partial M} \mathcal{B}_g. \tag{14.13.16}$$

Forma $\mathcal{B}_g$ na gładkim brzegu zawiera jego geometrię wewnętrzną i sposób zanurzenia w M (drugą formę fundamentalną). Nie jest w ogólności samą krzywizną Gaussa brzegu. W wymiarze dwa mamy $\mathcal{B}_g = k_g\,\mathrm{d}s/(2\pi)$; dla brzegu z narożnikami dochodzą jeszcze skręty opisane w (14.13.2). Zasadniczy test: domknięta płaska kula $\overline{B}^{2m} \subset \mathbb{R}^{2m}$ ma zerowy Pfaffian we wnętrzu, lecz $\chi(\overline{B}^{2m}) = 1$, zatem cały wkład w (14.13.16) pochodzi z $\partial\overline{B}^{2m}$.

Bez zwartości całka po wnętrzu również nie musi odtwarzać χ: dla całej płaskiej $\mathbb{R}^2$ mamy $\int_{\mathbb{R}^2} K\,\mathrm{d}A = 0$ i $\chi(\mathbb{R}^2) = 1$. Na wyczerpujących ją dyskach B_R brakujący wkład jest widoczny jako $\int_{\partial B_R} k_g\,\mathrm{d}s = 2\pi$. W twierdzeniach dla przestrzeni niezwartych trzeba kontrolować granicę takiego wyrazu przy $R \to \infty$; nie wolno go po prostu skreślić.

Dla porównania, każda zwarta orientowalna rozmaitość *bez brzegu* nieparzystego wymiaru ma $\chi(M) = 0$. Wynika to z dualności Poincarégo nad $\mathbb{Q}$: $b_i = b_{n-i}$, a gdy n jest nieparzyste, składniki $(-1)^i b_i$ i $(-1)^{n-i} b_{n-i}$ w sumie Eulera znoszą się parami. Nie ma więc w nieparzystym wymiarze analogicznej nietrywialnej całki z Pfaffianu stopnia najwyższego.

Uwaga 14.13.11 (Co mówi, a czego nie mówi całkowita krzywizna?). Dla zamkniętej powierzchni orientowalnej rodzaju $g = 0$ całka K jest dodatnia, dla $g = 1$ zerowa, a dla $g \geq 2$ ujemna. Nie wynika stąd, że K ma ten sam znak w każdym punkcie: wzór określa sumę wkładów. Wzór z samym K jest *dwuwymiarowy*; uogólnienie Cherna dotyczy zwartych rozmaitości riemannowskich parzystego wymiaru. Nie stosujemy żadnego z tych zapisów bezpośrednio do niezwartych czterowymiarowych metryk *lorentzowskich* Schwarzschilda i Kerra: potrzebne są inne założenia, odpowiednia wersja dla sygnatury metryki i analiza brzegu bądź zachowania w nieskończoności.

Dalsza lektura: krzywizna, Schwarzschild i Kerr, rozwiązania typu Kerra w teorii DHOST, Milnor, U. Lang, *Riemannian and Metric Geometry*, §§3.3–3.4, 4.4, 6.1, skalar i małe kule, Gauss–Bonnet, Cherna–Gaussa–Bonneta, uogólnienie z brzegiem.

Cześć II

Grupy Liego i geometria globalna

Rozdział 15

Grupy Liego i ich algebry

W Rozdziale 1 grupa ortogonalna pojawiła się jako rozmaitość, a w Rozdziale 2 poznaliśmy przepływy i nawias pól. Teraz połączymy te konstrukcje. W grupie Liego każdy wektor styczny przy elemencie neutralnym wyznacza pole na całej grupie, a przepływ tego pola daje rodzinę symetrii zależną od jednego parametru. Grupy i homomorfizmy wystąpiły już w Definicji 5.1.1; tutaj wymagamy ponadto gładkości.

15.1 Grupa z gładką strukturą

Definicja 15.1.1 (Grupa Liego)**.** *Grupą Liego* nazywamy skończenie wymiarową gładką rozmaitość bez brzegu G, wyposażoną w strukturę grupy, dla której

$$m : G \times G \longrightarrow G, \quad m(g,h) = gh, \qquad \iota : G \longrightarrow G, \quad \iota(g) = g^{-1}$$

są gładkie. Jej element neutralny oznaczamy e. Intuicyjnie można w niej wykonywać działania grupowe i jednocześnie różniczkować je względem parametrów. Homomorfizm grup Liego nazywamy *gładkim*, gdy jest gładki jako odwzorowanie rozmaitości.

Dla $g \in G$ oznaczamy przez $L_g(h) = gh$ i $R_g(h) = hg$ translacje. Obie są dyfeomorfizmami: są gładkie jako ograniczenia m, a ich odwrotnościami są odpowiednio $L_{g^{-1}}$ i $R_{g^{-1}}$. Pozwalają przenosić rachunek z punktu e do każdego punktu grupy.

Przykład 15.1.2 (Grupy macierzy odwracalnych)**.** Grupa $\mathrm{GL}(n,\mathbb{R})$ z Dodatku C.1 jest otwartym podzbiorem $\mathbb{R}^{n^2}$: jest przeciwobrazem otwartego $\mathbb{R}_*$ przez ciągły wielomian det. Iloczyn macierzy jest wielomianowy w ich współczynnikach, a

$$A^{-1} = \frac{\operatorname{adj} A}{\det A}$$

jest gładki na tym otwartym zbiorze. Stąd $\mathrm{GL}(n,\mathbb{R})$ jest grupą Liego wymiaru n^2. W użytym wzorze $\operatorname{adj} A$ jest transponowaną macierzą dopełnień algebraicznych. Rozwinięcie Laplace'a daje $A \operatorname{adj} A = (\det A)I$: na przekątnej jest to rozwinięcie $\det A$, a poza nią wyznacznik macierzy z dwoma jednakowymi wierszami, równy zeru. Dzielenie przez niezerowy $\det A$ daje zatem odwrotność; jej współczynniki są ilorazami wielomianów. Ten sam argument, po potraktowaniu części rzeczywistych i urojonych współczynników jako współrzędnych, daje $\mathrm{GL}(n,\mathbb{C})$ wymiaru rzeczywistego $2n^2$. W obu przypadkach, dla $\mathbb{K} \in \{\mathbb{R},\mathbb{C}\}$, $T_I\mathrm{GL}(n,\mathbb{K}) = M_n(\mathbb{K})$ jako przestrzeń rzeczywista: otwarty podzbiór przestrzeni macierzy ma tę samą przestrzeń styczną co otoczenie.

Przykład 15.1.3 (Grupy ortogonalne)**.** W przykładzie „Grupa ortogonalna", po Twierdzeniu 1.12.8, wykazaliśmy, że grupa $\mathrm{O}(n)$ z Dodatku C.3 jest gładką rozmaitością i że $T_I\mathrm{O}(n) =$

$\{X : X^T = -X\}$. Mnożenie jest ograniczeniem wielomianowego mnożenia macierzy, a odwrotność ma tutaj prostą postać $A^{-1} = A^T$, więc oba działania są gładkie. Ponieważ $\det A \in \{-1, 1\}$ na $\mathrm{O}(n)$, $\mathrm{SO}(n)$ jest otwartą i domkniętą podrozmaitością $\mathrm{O}(n)$. Istotnie, jest zarówno przeciwobrazem domkniętego $\{1\}$, jak i otwartego $(0, \infty)$ przez ciągły wyznacznik. Jest podgrupą Liego tego samego wymiaru $n(n-1)/2$. Jej przestrzeń styczna przy I również składa się z macierzy skośnie symetrycznych.

Przykład 15.1.4 (Torus jako grupa)**.** Na torusie $T^k = \mathbb{R}^k/\mathbb{Z}^k$ z Przykładu 1.6.10 kładziemy $[x] + [y] = [x + y]$ i $-[x] = [-x]$. Zmiana reprezentantów na $x + m$, $y + n$, gdzie $m, n \in \mathbb{Z}^k$, zmienia sumę o $m + n \in \mathbb{Z}^k$, a przeciwny wektor o $-m$. Działania nie zależą więc od wyboru reprezentantów. W lokalnych mapach utworzonych z rzutowania $\mathbb{R}^k \to T^k$ działania mają postać zwykłego dodawania i zmiany znaku, z ewentualną całkowitą translacją współrzędnych. Są więc gładkie. Równoważny model

$$T^k \longrightarrow (S^1)^k, \qquad [x_1, \ldots, x_k] \longmapsto (e^{2\pi i x_1}, \ldots, e^{2\pi i x_k})$$

przekształca dodawanie w mnożenie zespolone na każdej współrzędnej; odwrotność staje się sprzężeniem zespolonym. Równość $e^{2\pi i x} = e^{2\pi i y}$ zachodzi dokładnie dla $x - y \in \mathbb{Z}$, co daje iniektywność na klasach, a każdy punkt okręgu ma postać $e^{2\pi i x}$, co daje surjektywność. Na krótkim łuku wybieramy gładką gałąź kąta θ; lokalna odwrotność ma współrzędną $\theta/(2\pi)$. Otrzymujemy zatem dyfeomorfizm iloczynów. Dla $k = 2$ wzór $(u, v) \mapsto ((R + r\cos v)\cos u, (R + r\cos v)\sin u, r\sin v)$, gdzie $R > r > 0$, wyznacza dyfeomorfizm $(\mathbb{R}/2\pi\mathbb{Z})^2$ na torus obrotowy z Rozdziału 1. Przenosi on na ten torus strukturę grupy. Jego mnożenie zależy od tej identyfikacji, a nie od dodawania punktów w otaczającej go przestrzeni $\mathbb{R}^3$. Lokalną odwrotność torusa obrotowego także można odczytać: dla punktu (x, y, z) kąt u jest argumentem $x + iy$, a v argumentem $(\sqrt{x^2 + y^2} - R) + iz$. Obie liczby są niezerowe, gdyż ich moduły wynoszą odpowiednio $R + r\cos v \geq R - r > 0$ i $r > 0$. Lokalne gałęzie argumentu są gładkie; globalnie kąty rozumiemy modulo 2π.

Przykład 15.1.5 (Macierze specjalnie unitarne)**.** Niech $\mathrm{SU}(2)$ będzie grupą z Dodatku C.5. Z warunków $U^{-1} = U^*$ i $\det U = 1$ wynika, przez porównanie wzorów na odwrotność, że każdy jej element ma jedyną postać

$$U(a, b) = \begin{pmatrix} a & b \\ -\bar{b} & \bar{a} \end{pmatrix}, \qquad |a|^2 + |b|^2 = 1. \tag{15.1.1}$$

Rozpiszmy porównanie. Dla $U = \left(\begin{smallmatrix} a & b \\ c & d \end{smallmatrix}\right)$ o wyznaczniku 1 wzór na odwrotność daje $U^{-1} = \left(\begin{smallmatrix} d & -b \\ -c & a \end{smallmatrix}\right)$, a sprzężenie hermitowskie $U^* = \left(\begin{smallmatrix} \bar{a} & \bar{c} \\ \bar{b} & \bar{d} \end{smallmatrix}\right)$. Porównanie współczynników daje $d = \bar{a}$, $c = -\bar{b}$. Wyznacznik jest wtedy równy $|a|^2 + |b|^2$, więc warunek $\det U = 1$ jest równaniem sfery. Odwrotnie,

$$\begin{pmatrix} \bar{a} & -b \\ \bar{b} & a \end{pmatrix} \begin{pmatrix} a & b \\ -\bar{b} & \bar{a} \end{pmatrix} = \begin{pmatrix} |a|^2 + |b|^2 & \bar{a}b - b\bar{a} \\ \bar{b}a - a\bar{b} & |a|^2 + |b|^2 \end{pmatrix} = I.$$

Współrzędne $(\operatorname{Re} a, \operatorname{Im} a, \operatorname{Re} b, \operatorname{Im} b)$ identyfikują zatem $\mathrm{SU}(2)$ gładko ze sferą $S^3 \subset \mathbb{R}^4$. Mnożenie macierzy ogranicza się do gładkiego odwzorowania $S^3 \times S^3 \to S^3$, a odwrotność $U^{-1} = U^*$ jest ograniczeniem rzeczywiście liniowego odwzorowania na $M_2(\mathbb{C})$. Jest to więc zwarta, trójwymiarowa grupa Liego. Postać macierzy zgadza się z otrzymaną wcześniej w Przykładzie 4.6.7; tu wykorzystujemy ją jako globalny opis rozmaitości i działań grupowych.

15.2 Od wektora przy jedności do algebry Liego

Definicja 15.2.1 (Pole lewostronnie niezmiennicze i algebra Liego)**.** Pole V na G jest *lewostronnie niezmiennicze*, gdy $(L_g)_* V = V$ dla każdego $g \in G$. Dla $X \in T_e G$ oznaczamy

$$X^L_g := (\mathrm{d}L_g)_e X.$$

Algebrą Liego grupy G nazywamy przestrzeń $\mathfrak{g} = T_eG$ z nawiasem

$$[X, Y]_{\mathfrak{g}} := [X^L, Y^L]_e.$$

Wektor przy jedności opisuje ruch nieskończenie mały; translacje przenoszą ten sam ruch do wszystkich punktów. Przykładami są $\mathfrak{gl}(n, \mathbb{R}) = M_n(\mathbb{R})$ i, jak pokażemy niżej, $\mathfrak{t}^k \cong \mathbb{R}^k$ z zerowym nawiasem.

Twierdzenie 15.2.2 (Niezmienniczość i zamknięcie na nawias)**.** *Odwzorowanie $X \mapsto X^L$ jest izomorfizmem liniowym T_eG na przestrzeń pól lewostronnie niezmienniczych. Nawias dwóch takich pól jest znowu lewostronnie niezmienniczy. W szczególności $\mathfrak{g}$ jest algebrą Liego: jej nawias jest dwuliniowy, antysymetryczny i spełnia tożsamość Jacobiego.*

Dowód. Gładkość X^L wynika z gładkości różniczki mnożenia po ograniczeniu do $G \times \{e\}$. Dla $g, h \in G$ mamy $L_g \circ L_h = L_{gh}$, więc reguła łańcucha daje

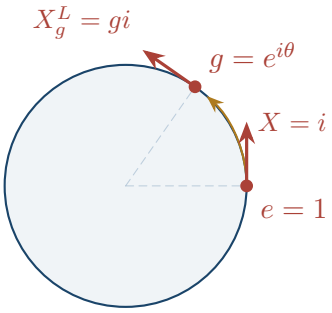
$$(\mathrm{d}L_g)_h X^L_h = ((\mathrm{d}L_g)_h \circ (\mathrm{d}L_h)_e)X = (\mathrm{d}L_{gh})_e X = X^L_{gh}.$$

Jest to niezmienniczość. Jeśli V jest dowolnym polem lewostronnie niezmienniczym, to po podstawieniu $h = e$ otrzymujemy $V_g = (\mathrm{d}L_g)_e V_e$; zatem $V = (V_e)^L$. Wartość przy e jest więc odwrotnością odwzorowania $X \mapsto X^L$, a oba odwzorowania są liniowe.

Dla dyfeomorfizmu F zachodzi $F_*[V, W] = [F_*V, F_*W]$. Można to sprawdzić bezpośrednio na funkcji f: definicja pola przeniesionego daje $(F_*V)(f) = (V(f \circ F)) \circ F^{-1}$, a po dwukrotnym zastosowaniu tego wzoru różnica złożeń staje się $([V, W](f \circ F)) \circ F^{-1}$. Dokładniej, w drugim zastosowaniu skraca się $F^{-1} \circ F$, toteż $(F_*V)((F_*W)f) = (V(W(f \circ F))) \circ F^{-1}$. Po zamianie V, W i odjęciu otrzymujemy wskazany nawias. Stosując tę równość do $F = L_g$ i $V = X^L$, $W = Y^L$, dostajemy

$$(L_g)_*[X^L, Y^L] = [(L_g)_* X^L, (L_g)_* Y^L] = [X^L, Y^L].$$

Własności nawiasu pól zostały dowiedzione w Fakcie 2.2.2. Przez izomorfizm $X \mapsto X^L$ przechodzą na nawias w T_eG. □



L_g obraca okrąg o kąt θ. Jego różniczka obraca również wektor styczny: $(\mathrm{d}L_g)_e(i) = gi$.

Z jednego wektora przy e otrzymujemy całe pole. Wektor gi jest styczny do okręgu w g.

Rysunek 15.1: Pole lewostronnie niezmiennicze na S^1. Niebieski dysk jest tylko tłem rysunku; grupą jest jego brzeg. Pole powstaje przez różniczkowanie translacji, bez wyboru metryki.

Przykład 15.2.3 (Komutator macierzy)**.** Na otwartym $\mathrm{GL}(n, \mathbb{R})$ pole odpowiadające macierzy X ma wartość $X^L_A = AX$. Dla $Y^L_A = AY$ różniczka odwzorowania $A \mapsto AY$ w kierunku H jest równa HY. Wzór współrzędny na nawias z (2.2.3) daje więc

$$[X^L, Y^L]_A = \mathrm{D}(Y^L)_A[AX] - \mathrm{D}(X^L)_A[AY] = AXY - AYX = A(XY - YX).$$

Stąd $[X, Y]_{\mathfrak{gl}} = XY - YX$. To samo obliczenie, po ograniczeniu pól stycznych do podgrupy macierzy, obowiązuje dla $\mathrm{O}(n)$, $\mathrm{SO}(n)$ i $\mathrm{SU}(2)$. W szczególności $\mathfrak{so}(n) = \{X : X^T = -X\}$ jest zamknięta na komutator, bo $(XY - YX)^T = Y^T X^T - X^T Y^T = YX - XY = -(XY - YX)$.

Dla SU(2) różniczkowanie $U^*U = I$ i $\det U = 1$ w punkcie I daje odpowiednio $X^* + X = 0$ i $\operatorname{tr} X = 0$; różniczka wyznacznika w kierunku X wynosi $\operatorname{tr} X$, co widać z rozwinięcia $\det(I+tX) = 1 + t\operatorname{tr} X + t^2 \det X$. Ponieważ obie strony mają wymiar rzeczywisty trzy, otrzymujemy

$$\mathfrak{su}(2) = \left\{ \begin{pmatrix} i\alpha & z \\ -\bar{z} & -i\alpha \end{pmatrix} : \alpha \in \mathbb{R},\ z \in \mathbb{C} \right\}.$$

Przestrzeń po prawej ma trzy rzeczywiste współrzędne: $\alpha, \operatorname{Re} z, \operatorname{Im} z$. Inkluzja wynika z różniczkowania warunków, a równość wymiarów z $\mathrm{SU}(2) \cong S^3$, więc nie zakładamy bez dowodu, że każde rozwiązanie zlinearyzowanych równań jest styczne. Na torusie translacje w mapach ilorazowych mają stałą różniczkę równą identyczności. Odpowiadające im pola mają stałe współczynniki, więc ich nawias znika: $\mathfrak{t}^k \cong (\mathbb{R}^k, 0)$.

Przykład 15.2.4 (Grupa Heisenberga i geometria Nil)**.** Współrzędnym $(x, y, z) \in \mathbb{R}^3$ przypiszmy macierz $H(x,y,z) = \left(\begin{smallmatrix} 1 & x & z \\ 0 & 1 & y \\ 0 & 0 & 1 \end{smallmatrix}\right)$. W iloczynie $H(x,y,z)H(x',y',z')$ współczynnik $(1,3)$ to $1 \cdot z' + x \cdot y' + z \cdot 1$, a współczynniki $(1,2)$ i $(2,3)$ są sumami. Stąd prawo grupowe ma postać

$$(x,y,z)(x',y',z') = (x+x', y+y', z+z'+xy').$$

Element neutralny to $(0,0,0)$, a rozwiązanie równania $(x,y,z)(x',y',z') = (0,0,0)$ daje $(x,y,z)^{-1} = (-x,-y,-z+xy)$. Po podstawieniu w odwrotnej kolejności także dostajemy jedność. Łączność dziedziczymy z macierzy. Oba działania są wielomianowe we współrzędnych, więc jest to grupa Liego na $\mathbb{R}^3$.

Dla ustalonego $g = (x,y,z)$ różniczkujemy $L_g(x',y',z') = (x+x', y+y', z+z'+xy')$ w $(x',y',z') = 0$. Macierz różniczki to $\left(\begin{smallmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & x & 1 \end{smallmatrix}\right)$. Jej kolumny dają pola odpowiadające bazie w jedności: $E_1 = \partial_x$, $E_2 = \partial_y + x\partial_z$, $E_3 = \partial_z$. We wzorze (2.2.3) jedyną niezerową pochodną współczynnika jest $\partial_x(x) = 1$, zatem $[E_1, E_2] = E_3$, $[E_1, E_3] = [E_2, E_3] = 0$.

Równania przepływów możemy rozwiązać od razu: $\Phi_a^{E_1}(x,y,z) = (x+a, y, z)$, $\Phi_b^{E_2}(x,y,z) = (x, y+b, z+xb)$, $\Phi_c^{E_3}(x,y,z) = (x,y,z+c)$. W drugim wzorze x jest stałe w czasie, więc równania $y' = 1$, $z' = x$ dają przyrosty b i xb. Zaczynając w jedności i wykonując kolejno przepływy $E_1, E_2, -E_1, -E_2$ przez czasy a, b, a, b, otrzymujemy

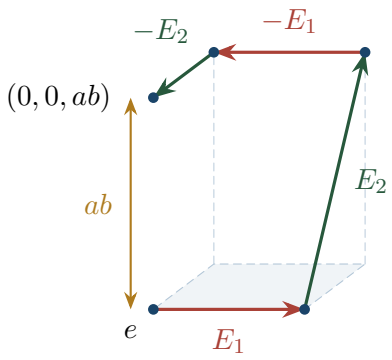
$$(0,0,0) \longmapsto (a,0,0) \longmapsto (a,b,ab) \longmapsto (0,b,ab) \longmapsto (0,0,ab).$$

Rzut na płaszczyznę (x,y) jest zamkniętym prostokątem, ale w grupie pozostaje przyrost ab w kierunku E_3. Tak nawias $[E_1, E_2] = E_3$ mierzy nieprzemienność ruchów.

Formy dualne do tej ramy to $\mathrm{d}x, \mathrm{d}y, \mathrm{d}z - x\mathrm{d}y$. Metryka $g_N = (\mathrm{d}x)^2 + (\mathrm{d}y)^2 + (\mathrm{d}z - x\mathrm{d}y)^2$ z Przykładu 11.2.4 jest lewostronnie niezmiennicza. Aby to sprawdzić, dla $g_0 = (x_0, y_0, z_0)$ oznaczmy współrzędne L_{g_0} przez $(\widetilde{x}, \widetilde{y}, \widetilde{z})$. Mamy $\mathrm{d}\widetilde{x} = \mathrm{d}x$, $\mathrm{d}\widetilde{y} = \mathrm{d}y$ oraz $\mathrm{d}\widetilde{z} = \mathrm{d}z + x_0\mathrm{d}y$, więc $\mathrm{d}\widetilde{z} - \widetilde{x}\mathrm{d}\widetilde{y} = \mathrm{d}z + x_0\mathrm{d}y - (x_0 + x)\mathrm{d}y = \mathrm{d}z - x\mathrm{d}y$. Cofnięcie zachowuje każdy z trzech składników metryki.

15.3 Podgrupy jednoparametrowe i eksponenta

Definicja 15.3.1 (Podgrupa jednoparametrowa)**.** *Podgrupą jednoparametrową* nazywamy gładki homomorfizm $\gamma : (\mathbb{R}, +) \to G$. Warunek homomorfizmu ma postać $\gamma(s+t) = \gamma(s)\gamma(t)$ i $\gamma(0) = e$. Na S^1 przykładem jest $t \mapsto e^{it}$; ruch wraca do jedności po czasie 2π, więc homomorfizm nie musi być różnowartościowy.



Cztery ruchy zamykają prostokąt w rzucie (x,y). Przyrost wysokości pozostaje równy ab.

Odcinki mają czasy a,b,a,b, gdzie $a,b>0$.

Rysunek 15.2: Nieprzemienność w grupie Heisenberga. Rysunek jest rzutem ukośnym współrzędnych (x,y,z). Przerywany prostokąt leży na $z=0$; wzdłuż boku E_2 na poziomie $x=a$ rośnie także współrzędna z.

Twierdzenie 15.3.2 (Wektor styczny wyznacza jedną podgrupę)**.** *Dla każdego $X\in\mathfrak{g}$ istnieje dokładnie jedna podgrupa jednoparametrowa γ_X taka, że $\gamma_X'(0)=X$. Jest ona krzywą całkową pola X^L przez e i zachodzi*

$$\Phi_t^{X^L}(g)=g\gamma_X(t)\qquad (g\in G,\ t\in\mathbb{R}).$$

Dowód. Twierdzenie 2.4.2 daje lokalną krzywą całkową γ pola X^L z $\gamma(0)=e$. Jeżeli $\eta(t)$ jest krzywą całkową przez h, to $(L_{h^{-1}}\circ\eta)(t)$ również jest krzywą całkową X^L: niezmienniczość pola i reguła łańcucha przenoszą równanie $\eta'=X^L_\eta$ na tę krzywą. Dokładniej,

$$(L_{h^{-1}}\circ\eta)'(t)=(\mathrm{d}L_{h^{-1}})_{\eta(t)}X^L_{\eta(t)}=X^L_{h^{-1}\eta(t)}.$$

Jej wartością w zerze jest e. Jednoznaczność rozwiązań z Rozdziału 2 daje zatem, dla małych t, $\Phi_t^{X^L}(h)=h\gamma(t)$.

Wykażmy, że pole jest zupełne. Wybierzmy $\varepsilon>0$, tak aby $\gamma(t)$ istniała dla $|t|<\varepsilon$. Z niezmienniczości X^L krzywa $s\mapsto h\gamma(s)$, $|s|<\varepsilon$, jest rozwiązaniem przez *dowolny* $h\in G$ przez taki sam przedział czasu. Gdyby maksymalna krzywa przez e miała skończony prawy koniec b, wybierając $t_0<b$ z $b-t_0<\varepsilon/2$, przedłużylibyśmy ją wzorem $\gamma(t_0+s)=\gamma(t_0)\gamma(s)$ do $t_0+s>b$, wbrew maksymalności. Na wspólnym przedziale stara i nowa krzywa zgadzają się: po zmianie czasu na $s=0$ rozwiązują to samo równanie z tą samą wartością $\gamma(t_0)$. Jednoznaczność zapewnia więc także gładkie sklejenie. Lewy koniec traktujemy tak samo. Stąd γ istnieje dla wszystkich t.

Dla ustalonego s krzywa $t\mapsto\gamma(s)\gamma(t)$ jest całkowa i w chwili $t=0$ przechodzi przez $\gamma(s)$. Krzywa $t\mapsto\gamma(s+t)$ ma te same własności. Jednoznaczność daje $\gamma(s+t)=\gamma(s)\gamma(t)$, zatem γ jest podgrupą jednoparametrową. Ponownie przez translację jej przepływ przez g ma podaną postać.

Jeśli $\beta:\mathbb{R}\to G$ jest inną gładką podgrupą jednoparametrową z $\beta'(0)=X$, to

$$\beta'(t)=\frac{\mathrm{d}}{\mathrm{d}s}\Big|_{s=0}\beta(t)\beta(s)=(\mathrm{d}L_{\beta(t)})_eX=X^L_{\beta(t)}.$$

Jednoznaczność rozwiązania z warunkiem początkowym w e daje $\beta=\gamma$. □

Lewostronna niezmienniczość pola i prawa translacja w jego przepływie są zgodne. Dla ustalonego g różniczkujemy krzywą $g\gamma_X(t)$ po czasie, a nie po punkcie g. Niezmienniczość przenosi równanie z $\gamma_X(t)$ do $g\gamma_X(t)$ przez L_g. Natomiast dla ustalonego czasu t całe odwzorowanie $g\mapsto g\gamma_X(t)$ jest $R_{\gamma_X(t)}$.

Definicja 15.3.3 (Odwzorowanie wykładnicze)**.** *Odwzorowaniem wykładniczym* grupy Liego nazywamy

$$\exp_G : \mathfrak{g} \longrightarrow G, \qquad \exp_G(X) = \gamma_X(1).$$

Wektor X określa prędkość przy jedności, a $\exp_G(X)$ jest punktem osiągniętym po czasie jeden przy tej stałej, przenoszonej translacjami prędkości. Dla torusa z Przykładu 15.1.4, przy identyfikacji $T_eT^k \cong \mathbb{R}^k$ z mapy ilorazowej, mamy $\exp_{T^k}(v) = [v]$.

Jest to eksponenta *grupowa*. Jej konstrukcja używa mnożenia i pola X^L, bez metryki ani koneksji. Odwzorowanie $\exp_p$ z Definicji 13.2.1 powstawało natomiast z równania geodezyjnych. Nie utożsamiamy tych konstrukcji bez dodatkowego uzasadnienia.

Stwierdzenie 15.3.4 (Własności eksponenty)**.** *Odwzorowanie* $\exp_G$ *jest gładkie,* $(\mathrm{d}\exp_G)_0 = \mathrm{id}_{\mathfrak{g}}$ *oraz*

$$\exp_G((s+t)X) = \exp_G(sX)\exp_G(tX), \qquad \exp_G(-X) = \exp_G(X)^{-1}.$$

W szczególności $\exp_G$ *jest dyfeomorfizmem pewnego otoczenia zera na otoczenie* e*.*

Dowód. Liniowa zależność $X \mapsto X^L$ i gładkość różniczki mnożenia sprawiają, że $(X, g) \mapsto X^L_g$ jest gładkie. Na rozmaitości $\mathfrak{g} \times G$ rozważmy pole $(X, g) \mapsto (0, X^L_g)$. Jego przepływ ma postać $(X, g) \mapsto (X, \Phi^{X^L}_t(g))$ i jest określony dla wszystkich czasów na mocy Twierdzenia 15.3.2. Gładkość przepływu z Twierdzenia 2.4.2 daje więc gładkość $(X, t) \mapsto \gamma_X(t)$, a w szczególności $\exp_G$. Jednoznaczność podgrupy o zadanej pochodnej daje $\gamma_X(t) = \exp_G(tX)$: dla każdej liczby a krzywa $s \mapsto \gamma_X(as)$ ma pochodną aX w zerze, więc $\gamma_{aX}(1) = \gamma_X(a)$. Prawo grupowe z poprzedniego dowodu daje pierwszą równość, a podstawienie $s = -t$ daje drugą.

Dla $X \in \mathfrak{g}$ mamy

$$(\mathrm{d}\exp_G)_0(X) = \left.\frac{\mathrm{d}}{\mathrm{d}t}\right|_{t=0} \exp_G(tX) = \gamma'_X(0) = X.$$

Różniczka jest zatem izomorfizmem. Twierdzenie o funkcji odwrotnej z Rozdziału 1 daje ostatni wniosek. □

Przykład 15.3.5 (Eksponenta macierzowa)**.** Dla $X \in M_n(\mathbb{R})$ lub $M_n(\mathbb{C})$ szereg

$$E_X(t) = \sum_{j=0}^{\infty} \frac{t^j X^j}{j!}$$

jest zbieżny bezwzględnie i jednostajnie z pochodnymi na każdym zwartym przedziale t: wybieramy normę operatorową macierzy. Dla $|t| \le T$ norma składnika nie przekracza $T^j\|X\|^j/j!$, a norma jego m-tej pochodnej dla $j \ge m$ nie przekracza $\|X\|^m(T\|X\|)^{j-m}/(j-m)!$. Szeregi tych oszacowań są zbieżne. Różniczkowanie wyraz po wyrazie i zmiana indeksu $\ell = j - 1$ dają

$$E'_X(t) = \sum_{j=1}^{\infty} \frac{t^{j-1}X^j}{(j-1)!} = \left(\sum_{\ell=0}^{\infty} \frac{t^\ell X^\ell}{\ell!}\right) X = E_X(t)X, \qquad E_X(0) = I.$$

Macierz X komutuje z każdym $E_X(t)$, więc reguła iloczynu i reguła łańcucha dają

$$\frac{\mathrm{d}}{\mathrm{d}t}(E_X(t)E_X(-t)) = E_X(t)XE_X(-t) - E_X(t)E_X(-t)X = 0.$$

Ostatnia równość używa komutowania X z $E_X(-t)$. Wartość iloczynu w zerze to I. Zatem $E_X(t)^{-1} = E_X(-t)$ i cała krzywa leży w $\mathrm{GL}(n, \mathbb{K})$. Spełnia równanie pola $X^L_A = AX$ na $\mathrm{GL}(n, \mathbb{K})$; z jednoznaczności wynika

$$\exp_{\mathrm{GL}(n,\mathbb{K})}(X) = E_X(1) = \sum_{j=0}^{\infty} \frac{X^j}{j!}.$$

Jeżeli $X^T = -X$, to $E_X(t)^T = E_{-X}(t) = E_X(t)^{-1}$; transpozycja przechodzi pod znak szeregu, a $(X^j)^T = (X^T)^j = (-X)^j$. Ciągłość wyznacznika od $t = 0$ pokazuje $E_X(t) \in \mathrm{SO}(n)$. Jeśli $X = \left(\begin{smallmatrix} i\alpha & z \\ -\bar z & -i\alpha \end{smallmatrix}\right) \in \mathfrak{su}(2)$, połóżmy $r = \sqrt{\alpha^2 + |z|^2}$. Mnożenie macierzy daje

$$X^2 = \begin{pmatrix} -\alpha^2 - z\bar z & i\alpha z - i\alpha z \\ -i\alpha\bar z + i\alpha\bar z & -\bar z z - \alpha^2 \end{pmatrix} = -r^2 I.$$

Wobec tego $X^{2j} = (-r^2)^j I$ i $X^{2j+1} = (-r^2)^j X$. Parzyste wyrazy szeregu sumują się do $\cos(rt)I$, a nieparzyste do $\sin(rt)X/r$, czyli $E_X(t) = \cos(rt)I + \sin(rt)X/r$ dla $r > 0$. Przy $r = 0$ mamy $X = 0$, więc $E_X(t) = I$. Jeśli oznaczymy $c = \cos(rt)$, $s = \sin(rt)$, to

$$E_X(t) = \begin{pmatrix} c + i\alpha s/r & zs/r \\ -\bar z s/r & c - i\alpha s/r \end{pmatrix}, \qquad \det E_X(t) = c^2 + \frac{\alpha^2 + |z|^2}{r^2} s^2 = c^2 + s^2.$$

Ponadto $X^* = -X$, zatem $E_X(t)^* E_X(t) = (cI - sX/r)(cI + sX/r) = c^2 I - s^2 X^2/r^2 = (c^2 + s^2)I = I$. Otrzymaliśmy unitarność i wyznacznik 1, czyli $E_X(t) \in \mathrm{SU}(2)$, bez korzystania z ogólnego wzoru na wyznacznik eksponenty.

Dla $J = \left(\begin{smallmatrix} 0 & -1 \\ 1 & 0 \end{smallmatrix}\right)$ zachodzi $J^2 = -I$, więc rozdzielenie parzystych i nieparzystych potęg daje

$$\exp(\theta J) = \begin{pmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{pmatrix}.$$

Torus w modelu $(S^1)^k$ ma z kolei eksponentę $(\theta_1, \dots, \theta_k) \mapsto (e^{i\theta_1}, \dots, e^{i\theta_k})$ i jądro $(2\pi\mathbb{Z})^k$; współrzędne θ są tutaj 2π razy współrzędnymi v z definicji ilorazowej. Lokalna odwracalność eksponenty nie oznacza więc globalnej różnowartościowości. W $\mathrm{GL}(n, \mathbb{R})$ eksponenta nie pokrywa nawet całej grupy: każdy $\exp X$ leży na drodze $t \mapsto \exp(tX)$ od I, więc ma dodatni wyznacznik.

Przeszkoda występuje także pośród macierzy połączonych drogą z I. Dla $A = \mathrm{diag}(-1, -2)$ mamy $\det A = 2 > 0$. Gdyby $A = e^X$ dla rzeczywistej macierzy X, to $XA = AX$, bo X komutuje ze swoim szeregiem wykładniczym. Pisząc $X = \left(\begin{smallmatrix} p & q \\ r & s \end{smallmatrix}\right)$, porównujemy współczynniki $(1,2)$ i $(2,1)$: $-2q = -q$ i $-r = -2r$, czyli $q = r = 0$. Wówczas $e^X = \mathrm{diag}(e^p, e^s)$ ma dodatnie wyrazy diagonalne, sprzeczność. Macierz A należy jednak do składowej jedności: droga $t \mapsto \exp(\pi t J)\,\mathrm{diag}(1, 2^t)$, $0 \le t \le 1$, zaczyna się w I, kończy w A i ma przez cały czas wyznacznik $2^t > 0$.

Dla grupy Heisenberga z Przykładu 15.2.4 wektor (a, b, c) przy jedności reprezentuje macierz $N = \left(\begin{smallmatrix} 0 & a & c \\ 0 & 0 & b \\ 0 & 0 & 0 \end{smallmatrix}\right)$. Jedynym niezerowym współczynnikiem N^2 może być $(N^2)_{13} = ab$, a $N^3 = 0$. Szereg kończy się więc po trzech wyrazach:

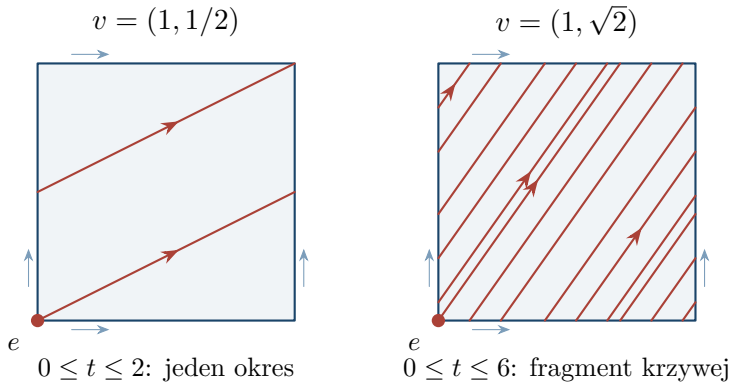
$$\exp(tN) = I + tN + \tfrac{1}{2}t^2 N^2 = H\big(ta, tb, tc + \tfrac{1}{2}t^2 ab\big).$$

W szczególności $\exp(a, b, c) = (a, b, c + ab/2)$ w tych współrzędnych grupowych. Przy $X = (1, 0, 0)$, $Y = (0, 1, 0)$ mamy $\exp(X + Y) = (1, 1, 1/2)$, natomiast prawo mnożenia daje $\exp(X)\exp(Y) = (1, 1, 1)$. Własność z 15.3.4 dotyczy jednej prostej $\mathbb{R}X$; nie uprawnia do takiej równości dla dowolnych X, Y.

Przykład 15.3.6 (Zamknięta i gęsta podgrupa na torusie)**.** Na $T^2 = \mathbb{R}^2/\mathbb{Z}^2$ pole odpowiadające $v \in \mathbb{R}^2$ ma stałe współczynniki, więc jego krzywa przez 0 to $\gamma_v(t) = [tv]$. Powrót do jedności zachodzi dokładnie wtedy, gdy $tv \in \mathbb{Z}^2$. Dla $v = (1, 1/2)$ oznacza to $t \in 2\mathbb{Z}$. Krzywa schodzi więc do injektywnego odwzorowania $\mathbb{R}/2\mathbb{Z} \to T^2$ z niezerową różniczką. Jest zanurzeniem okręgu: ciągła bijekcja na obraz ze zwartej dziedziny do przestrzeni Hausdorffa jest homeomorfizmem, a niezerowa różniczka daje immersję. Jej obraz jest zwarty, zatem domknięty.

Dla $v = (1, \alpha)$, gdzie $\alpha \notin \mathbb{Q}$, warunki $t \in \mathbb{Z}$, $\alpha t \in \mathbb{Z}$ wymuszają $t = 0$. Zatem γ_v jest injektywna i ma wszędzie niezerową różniczkę, ale jej obraz jest gęsty w torusie. Uzasadnijmy gęstość bez dodatkowego twierdzenia. Oznaczmy przez $\{r\} = r - \lfloor r \rfloor$ część ułamkową. Wśród $N+1$ różnych liczb $\{0\alpha\}, \{1\alpha\}, \ldots, \{N\alpha\}$ dwie należą do tego samego z N przedziałów długości $1/N$. Ich dodatnia różnica ma postać $\delta = m\alpha - k$, gdzie $m, k \in \mathbb{Z}$ i $0 < \delta < 1/N$. Dla dowolnego $r \in [0,1)$ liczba $j = \lfloor r/\delta \rfloor$ spełnia $0 \le r - j\delta < \delta$ i $j\delta < 1$. Ponieważ $jm\alpha = jk + j\delta$, klasa $[jm\alpha]$ przybliża $[r]$ z błędem mniejszym niż $1/N$. Klasy $[n\alpha]$, $n \in \mathbb{Z}$, są więc gęste w $\mathbb{R}/\mathbb{Z}$. Dla ustalonego s punkty $\gamma_v(s+n) = ([s], [\alpha s + n\alpha])$ wypełniają gęsto cały okrąg o pierwszej współrzędnej $[s]$. To dowodzi gęstości obrazu w T^2.

Ta injektywna immersja $\mathbb{R} \to T^2$ nie jest zanurzeniem. Powyższa konstrukcja daje $m_N \in \mathbb{Z}$ z $0 < \delta_N = m_N\alpha - k_N < 1/N$. Musi zachodzić $|m_N| \to \infty$: dla ograniczonego zbioru niezerowych m_N odległości $m_N\alpha$ od $\mathbb{Z}$ miałyby dodatnie minimum. Tymczasem $\gamma_v(m_N) = ([0], [\delta_N]) \to ([0], [0])$, a m_N nie dąży do 0. Odwrotność na obrazie nie jest więc ciągła w jedności. Podgrupa jednoparametrowa jest z definicji homomorfizmem; jej obraz nie musi być zanurzoną podrozmaitością.



Rysunek 15.3: Podgrupy jednoparametrowe $t \mapsto [tv]$ w kwadratach fundamentalnych torusa. Przeciwne boki są utożsamione zgodnie z niebieskimi strzałkami. Przy nachyleniu $1/2$ dwa odcinki zamykają krzywą; przy $\sqrt{2}$ kolejne przejścia dają gęstą orbitę, co uzasadniono w Przykładzie 15.3.6.

15.4 Sprzężenie i działanie adjungowane

Definicja 15.4.1 (Działanie adjungowane)**.** Dla $g \in G$ *sprzężenie* przez g to automorfizm $c_g : G \to G$, $c_g(h) = ghg^{-1}$. Jego różniczkę przy e oznaczamy

$$\mathrm{Ad}_g := (\mathrm{d}c_g)_e : \mathfrak{g} \longrightarrow \mathfrak{g}.$$

Ponieważ $c_g \circ c_h = c_{gh}$, otrzymujemy $\mathrm{Ad}_{gh} = \mathrm{Ad}_g \circ \mathrm{Ad}_h$. Jest to liniowy sposób zapisania, jak zmiana punktu odniesienia przez sprzężenie zmienia prędkości przy jedności. W grupie macierzy $\mathrm{Ad}_g X = gXg^{-1}$, co wynika przez zróżniczkowanie $g \exp_G(tX) g^{-1}$ w zerze.

Twierdzenie 15.4.2 (Różniczka działania adjungowanego)**.** *Odwzorowanie $g \mapsto \mathrm{Ad}_g$ jest gładkim homomorfizmem $G \to \mathrm{GL}(\mathfrak{g})$. Dla $X, Y \in \mathfrak{g}$ zachodzi*

$$\left.\frac{\mathrm{d}}{\mathrm{d}t}\right|_{t=0} \mathrm{Ad}_{\exp_G(tX)}\, Y = [X, Y]_{\mathfrak{g}}. \tag{15.4.1}$$

Ponadto $\mathrm{Ad}_g [X, Y]_{\mathfrak{g}} = [\mathrm{Ad}_g X, \mathrm{Ad}_g Y]_{\mathfrak{g}}$.

Dowód. Gładkość sprzężenia jako odwzorowania $(g,h)\mapsto ghg^{-1}$ oraz gładkość jego różniczki dają gładkość $g\mapsto \mathrm{Ad}_g$. Reguła łańcucha i $c_g\circ c_h = c_{gh}$ dają własność homomorfizmu i odwrotność $\mathrm{Ad}_{g^{-1}}$. Ponieważ $c_g\circ L_h = L_{c_g(h)}\circ c_g$, różniczkowanie w e daje

$$\begin{aligned}((c_g)_*Y^L)_{c_g(h)} &= (\mathrm{d}c_g)_h((\mathrm{d}L_h)_eY)\\ &= (\mathrm{d}L_{c_g(h)})_e((\mathrm{d}c_g)_eY) = (\mathrm{Ad}_g Y)^L_{c_g(h)}.\end{aligned}$$

Punkt $c_g(h)$ przebiega całą grupę, toteż otrzymujemy równość pól:

$$(c_g)_*Y^L = (\mathrm{Ad}_g Y)^L. \tag{15.4.2}$$

Ustalmy X i połóżmy $a_t=\exp_G(tX)$. Rodzina c_{a_t} jest przepływem pola $V=X^R-X^L$, gdzie $X^R_h=(\mathrm{d}R_h)_eX$. Istotnie, różniczkowanie a_tha_{-t} przy $t=0$ daje $(\mathrm{d}R_h)_eX-(\mathrm{d}L_h)_eX$. Możemy rozdzielić te dwa wkłady przez odwzorowanie $F(s,t)=a_sha_{-t}$: pochodna $F(t,t)$ w zerze jest sumą $\partial_sF(0,0)+\partial_tF(0,0)$. Pierwsza pochodna pochodzi z krzywej a_sh, druga z ha_{-t} i wnosi minus z reguły łańcucha. Ponadto $c_{a_s}\circ c_{a_t}=c_{a_{s+t}}$. Różniczkując tę tożsamość względem s w zerze, otrzymujemy równanie przepływu V w każdym punkcie krzywej $t\mapsto c_{a_t}(h)$. Przepływem X^R jest $h\mapsto a_th$, a przepływem Y^L jest $h\mapsto h\exp_G(tY)$. Translacje lewe i prawe komutują, bo $a(hb)=(ah)b$, zatem z Stwierdzenia 2.5.6 wynika $[X^R,Y^L]=0$. Korzystając z konwencji pochodnej Liego z Twierdzenia 2.6.2, mamy $(c_{a_t})_*Y^L=(c_{a_{-t}})^*Y^L$. Pochodna cofnięcia przez przepływ o czasie τ to $\mathcal{L}_VY^L=[V,Y^L]$; tutaj $\tau=-t$, więc reguła łańcucha wprowadza znak minus. Dlatego

$$\left.\frac{\mathrm{d}}{\mathrm{d}t}\right|_{t=0}(c_{a_t})_*Y^L = -[X^R-X^L,Y^L]=[X^L,Y^L].$$

Ocena przy e i (15.4.2) dają (15.4.1). Na koniec używamy naturalności nawiasu względem c_g z dowodu Twierdzenia 15.2.2. Ponieważ $c_g(e)=e$, ocena przy jedności daje

$$\begin{aligned}\mathrm{Ad}_g[X,Y]_\mathfrak{g} &= ((c_g)_*[X^L,Y^L])_e\\ &= [(c_g)_*X^L,(c_g)_*Y^L]_e = [\mathrm{Ad}_g X,\mathrm{Ad}_g Y]_\mathfrak{g},\end{aligned}$$

gdzie w ostatnim kroku podstawiliśmy (15.4.2). □

Przykład 15.4.3 (Macierze i torus)**.** Dla grupy macierzy możemy niezależnie sprawdzić znak w (15.4.1):

$$\left.\frac{\mathrm{d}}{\mathrm{d}t}\right|_0 e^{tX}Ye^{-tX} = XY-YX.$$

Pierwszy czynnik ma w zerze pochodną X, ostatni $-X$, a wartości obu wynoszą I. Reguła iloczynu daje więc $XYI+IY(-X)$. Dla konkretnego przykładu weźmy $X=\left(\begin{smallmatrix}1&0\\0&0\end{smallmatrix}\right)$, $Y=\left(\begin{smallmatrix}0&1\\0&0\end{smallmatrix}\right)$. Ponieważ $e^{tX}=\mathrm{diag}(e^t,1)$, bezpośrednio mnożymy

$$\mathrm{Ad}_{e^{tX}}Y = \begin{pmatrix}e^t&0\\0&1\end{pmatrix}\begin{pmatrix}0&1\\0&0\end{pmatrix}\begin{pmatrix}e^{-t}&0\\0&1\end{pmatrix} = e^tY.$$

Pochodna w zerze to Y, zgodnie z $XY=Y$, $YX=0$ i $[X,Y]=Y$. W grupie przemiennej każde sprzężenie jest identycznością. Stąd Ad torusa jest trywialne, a jej różniczka i nawias algebry Liego znikają. W teorii Cherna–Weila z Rozdziału 17 warunek niezmienniczości wielomianu oznacza właśnie niezmienniczość względem takich przekształceń Ad_g.

Stwierdzenie 15.4.4 (Różniczka homomorfizmu i naturalność eksponenty)**.** *Niech $F:G\to H$ będzie gładkim homomorfizmem grup Liego. Wówczas $A=(\mathrm{d}F)_e:\mathfrak{g}\to\mathfrak{h}$ jest homomorfizmem algebr Liego, czyli $A[X,Y]_\mathfrak{g}=[AX,AY]_\mathfrak{h}$. Ponadto $F(\exp_G(tX))=\exp_H(tAX)$ dla każdego $t\in\mathbb{R}$.*

Dowód. Homomorfizm spełnia $F \circ L_g = L_{F(g)} \circ F$. Różniczkując w e, otrzymujemy $(\mathrm{d}F)_g X^L_g = (AX)^L_{F(g)}$. Nie zakładamy, że F jest dyfeomorfizmem: jest to równość wektorów po zastosowaniu różniczki. Dla każdej funkcji gładkiej f na H znaczy ona $X^L(f\circ F) = ((AX)^L f)\circ F$. Stosujemy ją dwukrotnie, najpierw do Y, potem do X, i odejmujemy wzór z zamienionymi X, Y:

$$[X^L, Y^L](f\circ F) = ([(AX)^L, (AY)^L]f)\circ F.$$

Ocena w e i definicja nawiasu algebry Liego dają $A[X,Y] = [AX, AY]$, ponieważ równość zachodzi na każdej f.

Złożenie $F\circ\gamma_X$ jest gładkim homomorfizmem $\mathbb{R}\to H$, a jego pochodna w zerze to AX. Jednoznaczność z Twierdzenia 15.3.2 daje $F\circ\gamma_X = \gamma_{AX}$, czyli drugą tezę. □

Oznaczmy przez ad_X endomorfizm $Y \mapsto [X,Y]$ przestrzeni $\mathfrak{g}$. Wzór (15.4.1) mówi, że $(\mathrm{d}\,\mathrm{Ad})_e(X) = \mathrm{ad}_X$. Stosując Stwierdzenie 15.4.4 do $F = \mathrm{Ad} : G \to \mathrm{GL}(\mathfrak{g})$, otrzymujemy

$$\mathrm{Ad}_{\exp_G(tX)} = \exp_{\mathrm{GL}(\mathfrak{g})}(t\,\mathrm{ad}_X).$$

Po wyborze bazy prawa strona jest szeregiem macierzowym z Przykładu 15.3.5. Na wektorze Y ma wartość $Y + t[X,Y] + \frac{1}{2}t^2[X,[X,Y]] + \cdots$: każda kolejna potęga ad_X dodaje jeden nawias z X.

15.5 Od SU(2) do obrotów przestrzeni

W Przykładzie 4.5.6 grupa Spin(3) została utożsamiona z jednostkowymi kwaternionami. Tutaj połączymy ten opis z macierzami SU(2) i obliczymy samo nakrycie.

Zapiszmy kwaternion jako $q = a + b\mathbf{j}$, gdzie $a, b \in \mathbb{C}$, $\mathbf{j}^2 = -1$ i $\mathbf{j}z = \bar{z}\mathbf{j}$. Iloczyn ma wtedy postać

$$(a+b\mathbf{j})(c+d\mathbf{j}) = (ac - b\bar{d}) + (ad + b\bar{c})\mathbf{j}.$$

Istotnie, po rozdzieleniu nawiasów dostajemy $ac + ad\mathbf{j} + b\mathbf{j}c + b\mathbf{j}d\mathbf{j}$. W trzecim wyrazie używamy $\mathbf{j}c = \bar{c}\mathbf{j}$, a w czwartym $\mathbf{j}d\mathbf{j} = \bar{d}\mathbf{j}^2 = -\bar{d}$. Odwzorowanie $q \mapsto U(a,b)$ z (15.1.1) zachowuje ten iloczyn, co widać po pomnożeniu macierzy: jej pierwszy wiersz ma współczynniki $ac - b\bar{d}$ i $ad + b\bar{c}$. Ponadto $|q|^2 = |a|^2 + |b|^2$. Jest to więc gładki izomorfizm grup jednostkowych kwaternionów z SU(2). Odwrotność odczytuje pierwszy wiersz macierzy, więc także jest gładka. Ten sam wzór $U(a,b)$ zachowuje mnożenie również bez warunku jednostkowej normy.

Twierdzenie 15.5.1 (Jawne dwukrotne nakrycie)**.** *Niech* $\mathrm{Im}\,\mathbb{H}$ *będzie przestrzenią kwaternionów o zerowej części rzeczywistej, utożsamioną z* $\mathbb{R}^3$ *przez bazę* $(\mathbf{i},\mathbf{j},\mathbf{k})$*. Wtedy*

$$\rho : \mathrm{SU}(2) \longrightarrow \mathrm{SO}(3), \qquad \rho(q)(v) = qvq^{-1}, \quad v \in \mathrm{Im}\,\mathbb{H},$$

jest gładkim surjektywnym homomorfizmem o jądrze $\{1,-1\}$*. Każdy punkt* $\mathrm{SO}(3)$ *ma otoczenie równomiernie pokryte przez dwa otwarte zbiory w* $\mathrm{SU}(2)$*; zatem* ρ *jest dwukrotnym nakryciem.*

Dowód. Krok 1: dlaczego sprzężenie jest obrotem? Najpierw uzasadnijmy własności iloczynu. Ze wzoru $\det U(q) = |q|^2$ i mnożenia macierzy wynika $|qr|^2 = \det(U(q)U(r)) = |q|^2|r|^2$, więc $|qr| = |q||r|$. Sprzężenie kwaternionowe ma postać $\overline{a+b\mathbf{j}} = \bar{a} - b\mathbf{j}$. Podstawienie do wzoru na iloczyn daje $q\bar{q} = \bar{q}q = |q|^2$, zatem $q^{-1} = \bar{q}$ dla $|q| = 1$. Jeśli $p = p_0 + \sum_i p_i\mathbf{e}_i$, $r = r_0 + \sum_i r_i\mathbf{e}_i$ w bazie $\mathbf{e}_1 = \mathbf{i}$, $\mathbf{e}_2 = \mathbf{j}$, $\mathbf{e}_3 = \mathbf{k}$, to $\mathrm{Re}(pr) = p_0r_0 - \sum_i p_ir_i = \mathrm{Re}(rp)$: kwadraty generatorów to -1, a mieszane iloczyny są urojone. Stąd $\mathrm{Re}(qvq^{-1}) = \mathrm{Re}(q^{-1}(qv)) = \mathrm{Re}\,v$ oraz $|qvq^{-1}| = |v|$. Odwzorowanie $v \mapsto qvq^{-1}$ jest rzeczywiście liniowe. Zachowuje więc także iloczyn skalarny, otrzymany z normy przez $2\langle v,w\rangle = |v+w|^2 - |v|^2 - |w|^2$. Ogranicza się zatem do izometrii

$\operatorname{Im}\mathbb{H}$. Zależność od q jest gładka, bo $q^{-1} = \bar{q}$ na sferze jednostkowej. Grupa S^3 jest spójna drogowo: każdy jej element można zapisać jako $\cos t + u \sin t$ dla jednostkowego urojonego u (przy $q = \pm 1$ wybór u jest dowolny). Dla $q = a + w$ z $w \neq 0$ wybieramy $t = \arccos a \in (0, \pi)$ i $u = w/|w|$, gdyż $|w| = \sqrt{1 - a^2} = \sin t$. Droga $\tau \mapsto \cos(\tau t) + u \sin(\tau t)$, $0 \leq \tau \leq 1$, łączy 1 z q w sferze jednostkowej. Wyznacznik izometrii $\rho(q)$ jest więc stale równy $+1$, jak dla $q = 1$. Łączność mnożenia daje $\rho(qr) = \rho(q) \circ \rho(r)$: po podstawieniu dowolnego v obie strony dają $q(rvr^{-1})q^{-1}$.

Krok 2: wyprowadzenie kąta obrotu. Dla urojonych kwaternionów u, v mamy $uv = -\langle u, v\rangle + u \times v$. W części rzeczywistej pozostaje $-\sum_i u_i v_i$. Współczynnik przy $\mathbf{i}$ to $u_2 v_3 - u_3 v_2$, bo $\mathbf{jk} = \mathbf{i}$ i $\mathbf{kj} = -\mathbf{i}$; dwie pozostałe współrzędne powstają przez cykliczną zamianę indeksów. To dokładnie współrzędne iloczynu wektorowego. Niech $|u| = 1$ i $q = \cos(\theta/2) + u \sin(\theta/2)$. Ponieważ $uv - vu = 2u \times v$ i $uvu = v - 2\langle u, v\rangle u$, rozwinięcie $(c + su)v(c - su)$ dla $c = \cos(\theta/2)$, $s = \sin(\theta/2)$ daje

$$\begin{aligned}\rho(q)v &= c^2 v + cs(uv - vu) - s^2 uvu \\ &= \cos\theta\, v + \sin\theta\,(u \times v) + (1 - \cos\theta)\langle u, v\rangle u.\end{aligned}$$

Druga użyta tożsamość wynika z $uv + vu = -2\langle u, v\rangle$: mnożymy ją z prawej strony przez u i podstawiamy $u^2 = -1$. Przejście między dwoma wierszami rachunku wykorzystuje $c^2 - s^2 = \cos\theta$, $2cs = \sin\theta$ i $2s^2 = 1 - \cos\theta$. Dla $v = \lambda u + w$, $w \perp u$, wzór upraszcza się do $\rho(q)v = \lambda u + \cos\theta\, w + \sin\theta\,(u \times w)$. Oś u pozostaje nieruchoma. Jeśli w jest jednostkowy, to $(w, u \times w)$ jest dodatnią bazą ortonormalną płaszczyzny $u^\perp$. Podstawienie kolejno w i $u \times w$, z użyciem $u \times (u \times w) = -w$, daje macierz $\left(\begin{smallmatrix}\cos\theta & -\sin\theta \\ \sin\theta & \cos\theta\end{smallmatrix}\right)$ na tej płaszczyźnie. Jest to zatem obrót o kąt θ wokół osi u.

Krok 3: surjektywność. Każda macierz $A \in \mathrm{SO}(3)$ ma oś stałą:

$$\det(I - A) = \det(I - A^T) = \det(A^T)\det(A - I) = \det(A - I) = -\det(I - A),$$

więc $\det(I - A) = 0$. Wybierzmy jednostkowy $u \in \ker(I - A)$. W rachunku użyliśmy $I - A^T = A^T(A - I)$ oraz $\det(A - I) = (-1)^3 \det(I - A)$. Ponieważ $A^T u = u$, dla $w \perp u$ mamy $\langle Aw, u\rangle = \langle w, A^T u\rangle = 0$. Płaszczyzna $u^\perp$ jest więc niezmiennicza. W rozkładzie $\mathbb{R}^3 = \mathbb{R}u \oplus u^\perp$ macierz ma bloki 1 i B, zatem $\det B = \det A = 1$. Na $u^\perp$ macierz A jest izometrią o wyznaczniku $+1$. Orientujemy tę płaszczyznę tak, by $(u, \text{dodatnia baza } u^\perp)$ była dodatnia w $\mathbb{R}^3$; wtedy $A|_{u^\perp}$ jest obrotem pewnego kąta θ. Aby to zobaczyć, zapiszmy pierwszą kolumnę B jako $(a, b)^T$ z $a^2 + b^2 = 1$. Jedyna prostopadła kolumna jednostkowa dająca dodatni wyznacznik to $(-b, a)^T$. Wybór $\cos\theta = a$, $\sin\theta = b$ daje właśnie macierz obrotu. Wzór z Kroku 2 daje kwaternion, który realizuje dokładnie A; ρ jest surjektywna.

Krok 4: jądro i włókna. Jeśli $\rho(q)$ jest identycznością, to q komutuje ze wszystkimi urojonymi v. Po zapisaniu $q = a + u$ z $a \in \mathbb{R}$, $u \in \operatorname{Im}\mathbb{H}$, otrzymujemy $0 = qv - vq = 2u \times v$ dla każdego v. Stąd $u = 0$ i, przez $|q| = 1$, $q = \pm 1$. Rzeczywiście, dla $u \neq 0$ wybór niezerowego $v \perp u$ dałby $|u \times v| = |u||v| > 0$, sprzeczność. Oba kwaterniony ± 1 istotnie działają identycznie. Jeśli $\rho(r) = \rho(q)$, to $\rho(q^{-1}r) = I$, czyli $r = \pm q$. Każde włókno ma zatem dokładnie dwa punkty.

Krok 5: lokalne arkusze nakrycia. Dla $u \in \operatorname{Im}\mathbb{H}$ krzywa $q(t) = \cos(t|u|) + (u/|u|)\sin(t|u|)$ (dla $u = 0$ stała) ma pochodną u w zerze. Różniczkując sprzężenie, dostajemy

$$(\mathrm{d}\rho)_1(u)(v) = \frac{\mathrm{d}}{\mathrm{d}t}\Big|_{t=0} q(t)vq(t)^{-1} = uv - vu = 2u \times v.$$

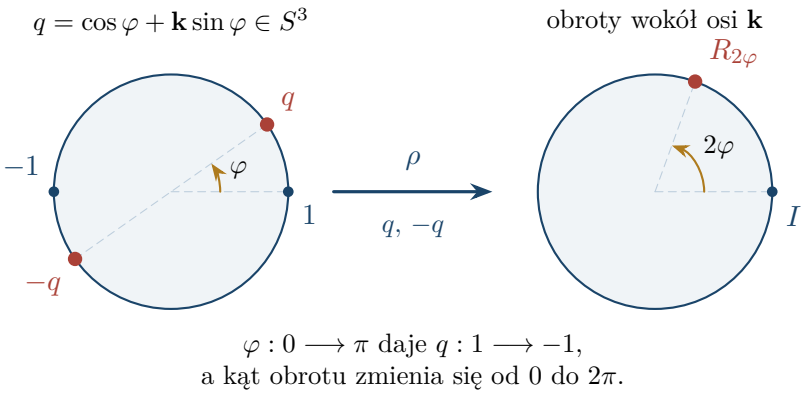
Pochodna $q(t)^{-1}$ w zerze jest równa $-u$: różniczkowanie $q(t)q(t)^{-1} = 1$ daje $u + (q^{-1})'(0) = 0$. W bazie $(\mathbf{i}, \mathbf{j}, \mathbf{k})$, dla $u = (u_1, u_2, u_3)$, otrzymujemy macierz

$$(\mathrm{d}\rho)_1(u) = 2\begin{pmatrix} 0 & -u_3 & u_2 \\ u_3 & 0 & -u_1 \\ -u_2 & u_1 & 0 \end{pmatrix}.$$

Jest to izomorfizm $\operatorname{Im}\mathbb{H} \to \mathfrak{so}(3)$: jest różnowartościowy, bo $u \times v = 0$ dla wszystkich v wymusza $u = 0$, a obie przestrzenie mają wymiar trzy. Ponieważ $\rho \circ L_q = L_{\rho(q)} \circ \rho$, różniczkowanie i odwrócenie różniczki translacji dają

$$(\mathrm{d}\rho)_q = (\mathrm{d}L_{\rho(q)})_I \circ (\mathrm{d}\rho)_1 \circ (\mathrm{d}L_{q^{-1}})_q.$$

Wszystkie trzy czynniki są izomorfizmami. Twierdzenie o funkcji odwrotnej daje więc otoczenie W jedności, na którym ρ jest dyfeomorfizmem. Zmniejszmy W tak, aby $\operatorname{Re} q > 0$ na W; wtedy $W \cap (-W) = \varnothing$. Połóżmy $V = \rho(W)$. Każdy punkt V ma dokładnie dwa przeciwobrazy, zatem $\rho^{-1}(V) = W \sqcup (-W)$ i oba ograniczenia są dyfeomorfizmami na V: na $-W$ odwrotność otrzymujemy z odwrotności na W przez pomnożenie przez -1. Dla dowolnego obrotu $A_0 = \rho(q_0)$ otoczenie A_0V ma arkusze q_0W i $q_0(-W)$. Równość $\rho(q_0 w) = A_0\rho(w)$ przenosi na nie oba lokalne dyfeomorfizmy. To jest definicja dwukrotnego nakrycia z 7.2.1. □



Rysunek 15.4: Podwojenie kąta w nakryciu $\mathrm{SU}(2) \to \mathrm{SO}(3)$. Po lewej pokazano jeden okrąg wielki w S^3, po prawej okrąg podgrupy obrotów wokół ustalonej osi. Punkty antypodalne q i $-q$ dają ten sam obrót: zmiana φ o π zmienia kąt 2φ o 2π.

Przykład 15.5.2 (Obrót o kąt prosty)**.** Weźmy oś $u = \mathbf{k}$ i kąt $\theta = \pi/2$. Połowa kąta to $\pi/4$, zatem wzór z dowodu Twierdzenia 15.5.1 daje $q = (1+\mathbf{k})/\sqrt{2}$. Ponieważ $\mathbf{k} = \mathbf{ij}$, w zapisie $a + b\mathbf{j}$ mamy $a = 1/\sqrt{2}$, $b = i/\sqrt{2}$. Odpowiadająca macierz i obrót to

$$U(q) = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 & i \\ i & 1 \end{pmatrix}, \qquad \rho(q) = \begin{pmatrix} 0 & -1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix}.$$

Drugą macierz otrzymujemy, podstawiając do wzoru obrotu kolejno $\mathbf{i}, \mathbf{j}, \mathbf{k}$: $\mathbf{k} \times \mathbf{i} = \mathbf{j}$, $\mathbf{k} \times \mathbf{j} = -\mathbf{i}$, a oś $\mathbf{k}$ pozostaje nieruchoma. Są to kolejne kolumny macierzy. Kwaternion $-q$ daje te same kolumny, bo w $(-q)v(-q)^{-1}$ oba minusy się znoszą. Natomiast $q^2 = (1 + 2\mathbf{k} + \mathbf{k}^2)/2 = \mathbf{k}$, $q^4 = \mathbf{k}^2 = -1$ i $q^8 = 1$: cztery kolejne obroty o $\pi/2$ wracają do I w $\mathrm{SO}(3)$, a ich podniesienie kończy się w -1. Dopiero osiem takich kroków wraca do 1.

W szczególności $\mathrm{SU}(2) \cong \mathrm{Spin}(3)$ jako grupy Liego, a powyższe ρ jest tym samym nakryciem co w Twierdzeniu 4.5.3. Rzeczywiście w algebrze Clifforda z Przykładu 4.5.6 element $\omega = e_1e_2e_3$ jest centralny, a $\mathcal{J}(v) = -v\omega$ wysyła bazę (e_1, e_2, e_3) na (I, J, K) przestrzeni urojonych kwaternionów. Przesunięcie e_i przez pozostałe dwa generatory wnosi dwa minusy, więc $e_i\omega = \omega e_i$. Na przykład $-e_1\omega = -e_1^2e_2e_3 = e_2e_3 = I$; cykliczna zamiana indeksów daje J, K. Ponieważ ω komutuje z $s \in \mathrm{Spin}(3)$, otrzymujemy $\mathcal{J}(svs^{-1}) = s\mathcal{J}(v)s^{-1}$, czyli obie konstrukcje nakrycia są zgodne pod tym utożsamieniem. Jego różniczka zachowuje nawias na mocy Stwierdzenia 15.4.4 i jest bijekcją, jak obliczyliśmy w Kroku 5. Jest więc izomorfizmem algebr Liego $\mathfrak{su}(2) \cong \mathfrak{so}(3)$,

lecz same grupy Liego nie są izomorficzne. Istotnie, $\mathrm{SU}(2) \cong S^3$ jest jednospójna na mocy Przykładu 7.3.5. Droga $q(t) = \cos(\pi t) + \mathbf{i}\sin(\pi t)$, $0 \le t \le 1$, łączy 1 z -1, a jej obraz przez ρ jest pętlą w $\mathrm{SO}(3)$. Gdyby ta pętla była ściągalna, Twierdzenie 7.2.3 pozwoliłoby podnieść jej homotopię do homotopii dróg o stałych końcach. Początek podniesienia jest stale równy 1. Jego koniec zależy ciągle od parametru homotopii i należy do dyskretnego zbioru $\{1, -1\}$, więc pozostaje równy -1. Tymczasem podniesienie końcowej pętli stałej, zaczynające się w 1, jest stale równe 1. To sprzeczność. Zatem $\pi_1(\mathrm{SO}(3))$ nie jest trywialna. Możemy obliczyć ją dokładnie przez Twierdzenie 7.2.11. Nakrycie ma jednospójną dziedzinę, więc podgrupa H w tym twierdzeniu jest trywialna, a grupa transformacji nakrycia jest izomorficzna z $\pi_1(\mathrm{SO}(3))$. Każda transformacja wysyła q na q albo $-q$. Wybór znaku jest lokalnie stały, zatem stały na spójnej S^3. Obie możliwości są transformacjami, więc otrzymujemy $\pi_1(\mathrm{SO}(3)) \cong \mathbb{Z}/2\mathbb{Z}$.

Dalsza lektura: S. Lie i F. Engel, *Theorie der Transformationsgruppen*, t. I (1888), oryginalne ujęcie grup przekształceń i pól infinitesymalnych; C. Chevalley, *Theory of Lie Groups*, t. I (1946), systematyczne ujęcie grup gładkich i ich algebr. Współczesny wykład z dowodami: E. P. van den Ban, *Lie Groups* (2010), §§2–4 (pola, eksponenta i Ad), §7 (podgrupy) oraz §10 (SU(2) i SO(3)).

Rozdział 16

Geometria Kleina: przestrzeń i jej symetrie

Grupa Liego z Rozdziału 15 może działać na innej rozmaitości. Zamiast pytać tylko o punkty i współrzędne, możemy zapytać, które własności punktów, prostych lub odległości nie zmieniają się pod tym działaniem. Taki był punkt wyjścia programu erlangeńskiego Kleina: geometrię opisuje przestrzeń wraz z wybraną grupą jej przekształceń. Ta sama rozmaitość może więc nieść różne geometrie.

W tym rozdziale zbudujemy język przestrzeni jednorodnych G/H. Przykłady prowadzą od płaszczyzny euklidesowej i afinicznej przez przestrzeń rzutową i sferę do torusa oraz dysku Poincarégo. Metryki hiperboliczne wprowadziliśmy już w Przykładzie 11.2.3; tutaj zbadamy działanie grupy $\mathrm{PSL}(2,\mathbb{R})$ przez izometrie w wymiarze dwa.

16.1 Działanie, orbita i stabilizator

Definicja 16.1.1 (Gładkie działanie grupy Liego)**.** Niech G będzie grupą Liego, a M gładką rozmaitością bez brzegu. *Gładkim działaniem lewym* G na M nazywamy gładkie odwzorowanie

$$a : G \times M \longrightarrow M, \qquad a(g,p) = g \cdot p,$$

dla którego $e \cdot p = p$ oraz $(gh)\cdot p = g\cdot(h\cdot p)$. Każdy g daje dyfeomorfizm $a_g : p \mapsto g\cdot p$, którego odwrotnością jest $a_{g^{-1}}$. Intuicyjnie grupa jest zbiorem dozwolonych ruchów przestrzeni. Na przykład grupa $(\mathbb{R}^n,+)$ działa na $\mathbb{R}^n$ przez translacje $b\cdot x = x+b$.

Definicja 16.1.2 (Orbita, stabilizator i skuteczność)**.** Dla $p \in M$ określamy *orbitę* i *stabilizator*

$$G\cdot p = \{g\cdot p : g \in G\}, \qquad G_p = \{g \in G : g\cdot p = p\}.$$

Działanie jest *przechodnie*, gdy $G\cdot p = M$ dla pewnego, a więc każdego $p\in M$. Jest *skuteczne*, gdy jedynym elementem ustalającym każdy punkt jest e. Orbita mówi, dokąd można przesunąć punkt; stabilizator mówi, które ruchy pozostawiają go na miejscu. Przy translacjach $\mathbb{R}^n$ na $\mathbb{R}^n$ orbita każdego punktu jest całą przestrzenią, a stabilizator jest trywialny.

Stabilizator jest podgrupą: $e\in G_p$, a jeśli $g,h\in G_p$, to $gh^{-1}\cdot p = g\cdot(h^{-1}\cdot p) = p$. Jest też domknięty, gdyż jest przeciwobrazem punktu p przez ciągłe odwzorowanie $g\mapsto g\cdot p$, a rozmaitość M jest Hausdorffa. Nie każda orbita musi być domknięta ani być podrozmaitością z topologią odziedziczoną z M; to rozróżnienie będzie potrzebne w twierdzeniu poniżej.

Lemat 16.1.3 (Stały rząd odwzorowania orbity)**.** *Niech $p\in M$ i $o_p : G\to M$, $o_p(g) = g\cdot p$. Rząd $\mathrm{d}(o_p)_g$ nie zależy od g. Jego jądro w e jest T_eG_p, a G_p jest zanurzoną podrozmaitością G wymiaru $\dim G - \operatorname{rank}\mathrm{d}(o_p)_e$.*

Dowód. Dla $g, h \in G$ zachodzi $o_p \circ L_g = a_g \circ o_p$. Różniczkując tę równość w h i pamiętając, że L_g oraz a_g są dyfeomorfizmami, dostajemy

$$\operatorname{rank} \mathrm{d}(o_p)_{gh} = \operatorname{rank} \mathrm{d}(o_p)_h.$$

Odwzorowanie o_p ma więc stały rząd r. Z Twierdzenia 1.11.11 w mapach wokół $h \in G_p$ i p ma ono postać $(u, v) \mapsto (u, 0)$, gdzie $u \in \mathbb{R}^r$. Jego przeciwobraz punktu p jest lokalnie zadany równaniem $u = 0$. To dowodzi, że $G_p = o_p^{-1}(p)$ jest zanurzoną podrozmaitością o podanym wymiarze i że $T_e G_p = \ker \mathrm{d}(o_p)_e$. Ograniczenia mnożenia i odwrotności w G są gładkie, zatem G_p jest także grupą Liego z otrzymaną strukturą. □

Do opisu G/H dla *dowolnej* domkniętej podgrupy H użyjemy standardowego wyniku o grupach Liego. Jego założenie domkniętości jest istotne: gęsta właściwa podgrupa może dać iloraz, w którym nie da się rozdzielić dwóch klas otwartymi zbiorami.

Twierdzenie 16.1.4 (Iloraz przez domkniętą podgrupę; wynik zewnętrzny)**.** *Niech G będzie skończenie wymiarową grupą Liego, a $H \subseteq G$ domkniętą podgrupą. Wtedy H ma jednoznaczną strukturę zanurzonej podgrupy Liego. Zbiór lewych warstw $G/H = \{gH : g \in G\}$ z topologią ilorazową ma jednoznaczną strukturę gładkiej rozmaitości, dla której rzutowanie $q : G \to G/H$ jest submersją. Zachodzi*

$$\dim(G/H) = \dim G - \dim H, \qquad T_{eH}(G/H) \cong T_e G / T_e H.$$

Działanie G na G/H przez $a \cdot (gH) = (ag)H$ jest gładkie i przechodnie.

Jest to połączenie twierdzenia o domkniętej podgrupie z twierdzeniem o ilorazie przez wolne działanie grupy Liego spełniające warunek właściwości z Definicji 16.3.2; dokładne wersje i dowody podaje J. M. Lee, *Introduction to Smooth Manifolds*, rozdziały 20–21. W drugim twierdzeniu H działa na G z prawej strony przez $(g, h) \mapsto gh$. Działanie jest wolne. Aby sprawdzić jego właściwość, niech $C \subset G \times G$ będzie zwarty i niech K_1, K_2 będą jego rzutami na czynniki. Przeciwobraz C przez $(g, h) \mapsto (g, gh)$ jest domknięty w zwartym zbiorze $K_1 \times (H \cap K_1^{-1} K_2)$: drugi czynnik jest zwarty, bo $K_1^{-1} K_2$ jest zwarty, a H domknięta. Zatem ten przeciwobraz jest zwarty. Wzór na wymiar i przestrzeń styczną wynika już z lokalnej postaci submersji q z Wniosku 1.11.13, ponieważ $q^{-1}(eH) = H$.

Twierdzenie 16.1.5 (Orbita jako przestrzeń jednorodna)**.** *Niech grupa Liego G działa gładko na rozmaitości M bez brzegu i niech $p \in M$, $H = G_p$. Wówczas*

$$F : G/H \longrightarrow M, \qquad F(gH) = g \cdot p,$$

jest dobrze określoną, różnowartościową immersją o obrazie $G \cdot p$. Orbita ma przez F kanoniczną strukturę gładkiej rozmaitości z immersją w M, nawet jeśli jej topologia jako podzbioru M jest inna. Jeśli działanie jest przechodnie, $F : G/H \to M$ jest dyfeomorfizmem. Jeśli dana orbita jest zanurzoną podrozmaitością M, to F jest dyfeomorfizmem również na tę podrozmaitość.

Dowód. Z Lematu 16.1.3 stabilizator jest domkniętą zanurzoną podgrupą, więc G/H istnieje na mocy Twierdzenia 16.1.4. Równość $gH = g'H$ oznacza $g' = gh$ dla pewnego $h \in H$; wtedy $g' \cdot p = g \cdot (h \cdot p) = g \cdot p$. Odwrotnie, jeśli $g' \cdot p = g \cdot p$, to $g^{-1} g' \in H$, zatem $g'H = gH$. To daje poprawność definicji i różnowartościowość F.

Rzutowanie q ma lokalne gładkie przekroje dzięki postaci submersji. Ponieważ $F \circ q = o_p$, złożenie o_p z takim przekrojem daje gładkość F. Różniczkując w e, otrzymujemy

$$\mathrm{d}F_{eH} \circ \mathrm{d}q_e = \mathrm{d}(o_p)_e.$$

Jądra $\mathrm{d}q_e$ i $\mathrm{d}(o_p)_e$ są równe T_eH; stąd $\mathrm{d}F_{eH}$ jest różnowartościowe. Ta sama własność w każdym gH wynika z G-równoważności F i z tego, że działania przez g na obu rozmaitościach są dyfeomorfizmami. Zatem F jest immersją.

Jeśli $G \cdot p = M$ i $\dim M > 0$, stały rząd o_p musi równać się $\dim M$. Gdyby był mniejszy, każdy punkt G byłby krytyczny, a Twierdzenie Sarda 19.1.3 mówiłoby, że obraz $o_p(G) = M$ ma miarę zero w M. To niemożliwe, bo niepusty otwarty zbiór w mapie ma dodatnią miarę. Dla $\dim M = 0$ wniosek o submersji jest natychmiastowy. Zatem $\mathrm{d}(o_p)_e$ jest surjektywne, a powyższa równość różniczek pokazuje, że $\mathrm{d}F_{eH}$, a więc każda $\mathrm{d}F_{gH}$, jest izomorfizmem. Twierdzenie o funkcji odwrotnej czyni F lokalnym dyfeomorfizmem. Jest ono także bijekcją na M, więc jego lokalne odwrotności składają się na gładką odwrotność globalną.

Jeśli zamiast M rozważymy zanurzoną orbitę $N = G \cdot p$, różniczki odwzorowania $F : G/H \to N$ mają ten sam rząd $\dim(G/H)$, zaś argument Sarda zastosowany do przechodniego działania na N daje $\dim N = \dim(G/H)$. Stosujemy więc poprzedni przypadek do N. □

Ostatnie założenie w twierdzeniu ma znaczenie. Działanie $\mathbb{R}$ na T^2 przez $t \cdot [x, y] = [x + t, y + \alpha t]$ dla niewymiernego α ma trywialny stabilizator, lecz orbita $[0, 0]$ jest gęsta i nie jest podrozmaitością z topologią odziedziczoną z torusa. Jest to nawinięcie niewymierne opisane po Przykładzie 1.11.7; odwzorowanie orbity jest różnowartościową immersją, ale nie zanurzeniem w znaczeniu Rozdziału 1.

Definicja 16.1.6 (Geometria Kleina)**.** *Geometrią Kleina* będziemy nazywać parę (G, X), w której X jest spójną gładką rozmaitością, a G grupą Liego działającą na niej gładko i przechodnio. Jej *model skuteczny* ma ponadto skuteczne działanie. Wybór $x_0 \in X$ przedstawia przestrzeń jako $X \cong G/G_{x_0}$; stabilizator zachowuje wybrany punkt. Na przykład $(\mathbb{R}^n, \mathbb{R}^n)$ z translacjami jest geometrią Kleina, w której stabilizator zera jest trywialny.

Niektórzy autorzy wymagają skuteczności już w definicji. Możemy zawsze usunąć nieskuteczność: jądro działania jest

$$K = \{g : g \cdot x = x \text{ dla każdego } x \in X\} = \bigcap_{g \in G} gHg^{-1}, \qquad H = G_{x_0}. \tag{16.1.1}$$

Druga równość wynika z $x = g \cdot x_0$: element a ustala x dokładnie wtedy, gdy $g^{-1}ag \in H$. Jest to domknięta podgrupa normalna. Dlatego G/K jest grupą Liego i działa skutecznie oraz przechodnio na X. W szczególności stabilizator H nie musi być trywialny, aby całe działanie było skuteczne.

16.2 Metryka a wybór grupy

Struktura G/H sama nie wybiera metryki. Można to uściślić, korzystając z działania adjungowanego z Definicji 15.4.1.

Stwierdzenie 16.2.1 (Kiedy istnieje metryka niezmiennicza)**.** *Niech H będzie domkniętą podgrupą G, a $\mathfrak{g} = T_eG$, $\mathfrak{h} = T_eH$. Metryki riemannowskie na G/H niezmiennicze względem działania G odpowiadają dodatnio określonym iloczynom skalarnym na $\mathfrak{g}/\mathfrak{h}$, niezmienniczym względem indukowanego działania* $\mathrm{Ad}(H)$.

Dowód. Każda metryka jest wyznaczona przez swoje wartości w punktach. Jeśli jest G-niezmiennicza, jej wartość w eH musi być niezmiennicza pod stabilizatorem H. Utożsamienie $T_{eH}(G/H) \cong \mathfrak{g}/\mathfrak{h}$ z Twierdzenia 16.1.4 przenosi działanie $h \in H$ na Ad_h modulo $\mathfrak{h}$. Jest ono dobrze określone, bo sprzężenie przez h zachowuje H, więc $\mathrm{Ad}_h \mathfrak{h} = \mathfrak{h}$. Istotnie,

$$h \exp_G(tX) H = h \exp_G(tX) h^{-1} H = \exp_G(t \,\mathrm{Ad}_h X) H.$$

Różniczkowanie w $t=0$ daje tezę o reprezentacji na przestrzeni stycznej.

Odwrotnie, dla takiego iloczynu skalarnego w eH przenosimy go do gH przez dyfeomorfizm działania g. Jeśli $gH = g'H$ z $g' = gh$, dwa sposoby przeniesienia różnią się działaniem h w eH, więc dają ten sam wynik właśnie dzięki niezmienniczości względem H. Lokalne przekroje submersji $G \to G/H$ pokazują, że powstała metryka zależy gładko od punktu. □

16.3 Zwarte stabilizatory, właściwe działania i ilorazy

W przestrzeni jednorodnej $X \cong G/H$ stabilizator H opisuje ruchy pozostawiające wybrany punkt na miejscu. Zwartość H pozwala uśrednić iloczyn skalarny nad tymi ruchami. Na przykład stabilizator zera w grupie ruchów euklidesowych $\mathbb{R}^n \rtimes \mathrm{O}(n)$ jest zwarty: $\mathrm{O}(n)$ jest domkniętym i ograniczonym zbiorem macierzy. Dla pełnej grupy afinicznej stabilizatorem jest niezwarta $\mathrm{GL}(n,\mathbb{R})$, zawierająca wszystkie dylatacje tI, $t>0$. Oba działania obliczymy w Przykładach 16.5.1 i 16.5.2.

Potrzebujemy jednego wyniku zewnętrznego o grupach zwartych: na każdej zwartej grupie Liego H istnieje *znormalizowana miara Haara* μ, czyli miara probabilistyczna niezmiennicza przy mnożeniu z lewej i z prawej strony. Istnienie takiej miary pochodzi z twierdzenia Haara; zob. A. Haar, *Der Massbegriff in der Theorie der kontinuierlichen Gruppen*, Ann. Math. 34 (1933), 147–169. Poniższy argument uśredniania występuje także u P. Scotta, *The Geometries of 3-Manifolds*, § 5.

Stwierdzenie 16.3.1 (Metryka ze zwartego stabilizatora)**.** *Niech grupa Liego G działa gładko i przechodnio na spójnej rozmaitości X bez brzegu. Jeśli stabilizator $H = G_{x_0}$ jest zwarty, to na X istnieje G-niezmiennicza metryka riemannowska.*

Dowód. Oznaczmy przez $\rho(h) = \mathrm{d}(a_h)_{x_0}$ działanie H na $T_{x_0}X$. Wybierzmy dowolny dodatnio określony iloczyn skalarny b na tej przestrzeni i zdefiniujmy

$$b_H(u,v) = \int_H b(\rho(h)u, \rho(h)v)\,\mathrm{d}\mu(h).$$

Całka jest dobrze określona, bo całkujemy ciągłą funkcję po zwartej grupie. Jest symetryczna i dwuliniowa. Jeśli $u \neq 0$, to $\rho(h)u \neq 0$ dla każdego h, więc każdy składnik $b(\rho(h)u,\rho(h)u)$ jest dodatni; stąd $b_H(u,u) > 0$. Niezmienniczość miary przy mnożeniu z prawej daje, dla $k \in H$,

$$b_H\big(\rho(k)u,\rho(k)v\big) = \int_H b(\rho(hk)u,\rho(hk)v)\,\mathrm{d}\mu(h) = b_H(u,v).$$

Zatem b_H spełnia warunek Stwierdzenia 16.2.1: przenosząc ten iloczyn skalarny z x_0 do punktu $a\cdot x_0$ przez różniczkę działania $a \in G$, otrzymujemy metrykę G-niezmienniczą. Wybór a nie ma znaczenia, ponieważ dwa takie elementy różnią się o element H. Gładkość wynika z lokalnych przekrojów submersji $G \to G/H$. □

Zwartość stabilizatora ma też znaczenie topologiczne: zapobiega temu, by elementy grupy uciekające do nieskończoności przenosiły punkty pozostające w ustalonym zwartym obszarze na inne punkty tego samego obszaru.

Definicja 16.3.2 (Działanie właściwe)**.** Niech grupa Liego G działa na rozmaitości X. Działanie jest *właściwe*, gdy odwzorowanie

$$A : G \times X \longrightarrow X \times X, \qquad A(a,x) = (x, a\cdot x),$$

jest właściwe, to znaczy przeciwobraz każdego zbioru zwartego jest zwarty. Jeżeli G jest grupą dyskretną, równoważnie dla każdego zwartego $K \subseteq X$ zbiór

$$\{a \in G : aK \cap K \neq \varnothing\}$$

jest skończony. W tej drugiej postaci warunek mówi, że tylko skończenie wiele ruchów może sprowadzić zwarty obszar z powrotem do siebie.

Istotnie, przy właściwym działaniu wskazany zbiór jest obrazem zwartego $A^{-1}(K \times K)$ przez rzut na dyskretną grupę, a więc jest skończony. Odwrotnie, jeśli jest skończony dla każdego K, przeciwobraz zwartego $C \subset X \times X$ leży w skończonej sumie zbiorów $\{a\} \times K$, gdzie K zawiera oba rzuty C; jest w niej domknięty, zatem zwarty.

Stwierdzenie 16.3.3 (Właściwość działania na G/H)**.** *Niech grupa Liego G działa gładko i przechodnio na spójnej rozmaitości X bez brzegu, a $H = G_{x_0}$. Działanie G na X jest właściwe wtedy i tylko wtedy, gdy H jest zwarty.*

Dowód. Jeśli działanie jest właściwe, to $A^{-1}(\{(x_0, x_0)\}) = H \times \{x_0\}$ jest zwarty, więc H jest zwarty.

Załóżmy odwrotnie, że H jest zwarty. Na mocy Twierdzenia 16.1.5 możemy utożsamić X z G/H. Niech $C \subseteq X \times X$ będzie zwarty, a $K_1, K_2 \subseteq X$ jego rzutami na oba czynniki. Submersja $q : G \to G/H$ ma lokalne gładkie przekroje. Z lokalnej zwartości X możemy wybrać skończenie wiele otwartych zbiorów U_i pokrywających K_1 oraz V_j pokrywających K_2, tak aby ich domknięcia były zwarte i mieściły się w obszarach odpowiednich lokalnych przekrojów s_i oraz t_j odwzorowania q. Jeśli $(a, x) \in A^{-1}(C)$, to dla pewnych i, j mamy $x \in U_i$ i $y = a \cdot x \in V_j$. Ponieważ $s_i(x)H = x$ i $t_j(y)H = y$, zachodzi

$$h := t_j(y)^{-1} a s_i(x) \in H, \qquad a = t_j(y) h s_i(x)^{-1}.$$

Zatem wszystkie możliwe a leżą w skończonej sumie zbiorów zwartych

$$L = \bigcup_{i,j} t_j(\overline{V}_j)\, H\, s_i(\overline{U}_i)^{-1} \subseteq G.$$

Przeciwobraz $A^{-1}(C)$ jest domkniętym podzbiorem zwartego $L \times K_1$, a więc jest zwarty. □

Ważne jest tu założenie przechodniości. Działanie $\mathbb{R}$ na torusie przez nawinięcie niewymierne, opisane przed Definicją 16.1.6, ma trywialne, a więc zwarte stabilizatory, ale nie jest właściwe: jego orbita jest gęsta i nie jest domknięta. Przy właściwym działaniu odwzorowanie orbity $a \mapsto a \cdot x$ jest właściwe (ograniczamy A do $G \times \{x\}$), a więc ma domknięty obraz: jeśli $a_j \cdot x \to y$, właściwość daje podciąg $a_j \to a$ po ograniczeniu do zwartego otoczenia y, skąd $y = a \cdot x$.

Stwierdzenie 16.3.4 (Zupełność metryki jednorodnej)**.** *Jeśli spójna rozmaitość riemannowska (X, g) jest jednorodna, czyli jej grupa izometrii działa przechodnio, to (X, g) jest geodezyjnie i metrycznie zupełna.*

Dowód. Wybierzmy $x_0 \in X$. Lokalna teoria równania geodezyjnej daje $\varepsilon > 0$ takie, że $\exp_{x_0}$ jest określone na $\{v \in T_{x_0}X : |v|_g < \varepsilon\}$. Ustalmy $0 < \delta < \varepsilon$. Dla każdego $x \in X$ istnieje izometria a z $a(x_0) = x$. Izometria przenosi geodezyjne na geodezyjne i zachowuje długość wektorów, więc $\exp_x$ jest określone na kuli $|v|_g < \varepsilon$. Każdą geodezyjną o prędkości 1 można zatem przedłużyć od dowolnego jej punktu co najmniej o czas δ. Gdyby jej maksymalny przedział miał skończony prawy koniec b, wybralibyśmy chwilę $t_0 > b - \delta$; przedłużenie od $\gamma(t_0)$ sięgałoby poza b, co jest sprzecznością. Podobnie postępujemy na lewym końcu. Dla innej niezerowej stałej prędkości przeskalowujemy parametr, a geodezyjne o prędkości zerowej są stałe. Zupełność metryczna wynika z Twierdzenia Hopfa–Rinowa 13.5.3. □

Pozostaje odróżnić sam model X od rozmaitości otrzymanej przez utożsamienie punktów modelu. Wymagamy, by grupa utożsamień była dyskretna w topologii grupy Liego i działała bez punktów stałych.

Definicja 16.3.5 (Podgrupa dyskretna i działanie swobodne)**.** Podgrupa $\Gamma < G$ jest *dyskretna*, jeśli jedność $e \in G$ ma otoczenie V spełniające $V \cap \Gamma = \{e\}$. Działanie Γ na X jest *swobodne*, jeśli $\gamma \cdot x = x$ implikuje $\gamma = e$ dla każdych $x \in X$ i $\gamma \in \Gamma$. Na przykład $\mathbb{Z}^n < \mathbb{R}^n \rtimes \mathrm{O}(n)$ jest dyskretną podgrupą translacji i działa swobodnie na $\mathbb{R}^n$.

Podgrupa dyskretna grupy Liego jest też domknięta. Gdyby różne $\gamma_j \in \Gamma$ zbiegały do punktu grupy G, to $\gamma_j^{-1}\gamma_{j+1} \to e$, mimo że są to niejedynkowe elementy Γ. Przeczyłoby to definicji dyskretności.

Twierdzenie 16.3.6 (Iloraz przez swobodną grupę dyskretną)**.** *Niech G działa gładko i przechodnio na spójnej rozmaitości X bez brzegu, ze zwartym stabilizatorem. Niech g będzie metryką G-niezmienniczą, a $\Gamma < G$ dyskretną podgrupą działającą swobodnie na X. Wtedy $M = \Gamma\backslash X$ jest gładką rozmaitością, rzutowanie $\pi : X \to M$ jest nakryciem i istnieje jednoznaczna metryka g_M, dla której π jest lokalną izometrią. Rozmaitości (X, g) i (M, g_M) są zupełne. Jeśli X jest jednospójna, π jest nakryciem uniwersalnym, a po wyborze punktów bazowych $\pi_1(M) \cong \Gamma$.*

Dowód. Z domkniętości Γ i Stwierdzenia 16.3.3 wynika, że działanie Γ jest właściwe: przeciwobraz zwartego $C \subset X \times X$ przez $\Gamma \times X \to X \times X$ jest domkniętym podzbiorem zwartego przeciwobrazu przez $G \times X \to X \times X$.

Ustalmy $x \in X$. Pokażemy, że istnieje otoczenie U punktu x takie, iż $\gamma U \cap U = \varnothing$ dla każdego $\gamma \neq e$. Gdyby nie istniało, moglibyśmy wybrać malejące do x otoczenia U_j o wspólnym zwartym domknięciu, punkty $u_j, v_j \in U_j$ i $\gamma_j \neq e$ z $\gamma_j u_j = v_j$. Wtedy $u_j, v_j \to x$. Właściwość działania grupy dyskretnej oznacza, że tylko skończenie wiele γ_j może przenieść to zwarte domknięcie na siebie. Na podciągu mamy więc stałe $\gamma_j = \gamma \neq e$, a przejście do granicy daje $\gamma x = x$, wbrew swobodzie działania. Zbiory γU są parami rozłączne i

$$\pi^{-1}(\pi(U)) = \coprod_{\gamma \in \Gamma} \gamma U.$$

Każde ograniczenie $\pi|_{\gamma U}$ jest homeomorfizmem na $\pi(U)$, więc π jest nakryciem.

Iloraz jest Hausdorffa. Jeśli dwie różne orbity Γx, Γy nie miałyby rozłącznych otoczeń w ilorazie, wybralibyśmy malejące otoczenia $U_j \ni x$, $V_j \ni y$ o zwartych domknięciach zawartych w ustalonym zbiorze zwartym oraz $u_j \in U_j$, $v_j \in V_j$ i $\gamma_j \in \Gamma$ z $\gamma_j u_j = v_j$. Właściwość działania znów pozwala wybrać stałe $\gamma_j = \gamma$ na podciągu, skąd $y = \gamma x$, sprzeczność. Rzutowanie π jest otwarte, bo $\pi^{-1}(\pi(U)) = \bigcup_{\gamma \in \Gamma} \gamma U$ jest otwarte dla każdego otwartego $U \subset X$; dlatego obrazy przeliczalnej bazy X tworzą przeliczalną bazę ilorazu. Wybierając U wewnątrz obszaru mapy X, przenosimy tę mapę przez $\pi|_U$ na $\pi(U)$; przejścia między otrzymanymi mapami są lokalnie ograniczeniami działania elementów Γ i są gładkie.

Dla $[x] = \pi(x)$ definiujemy

$$(g_M)_{[x]}(\mathrm{d}\pi_x u, \mathrm{d}\pi_x v) := g_x(u, v).$$

To nie zależy od przedstawiciela x: jeśli $x' = \gamma x$, to $\pi \circ \gamma = \pi$, a γ jest izometrią g. Rzutowanie jest więc lokalną izometrią. Zupełność X daje Stwierdzenie 16.3.4. Każdą geodezyjną w M podnosimy do geodezyjnej w X; przedłużenie podniesionej geodezyjnej rzutuje się na przedłużenie w M. Zatem M jest geodezyjnie zupełna, a z Twierdzenia 13.5.3 również metrycznie zupełna. Jeśli X jest jednospójna, nakrycie π jest uniwersalne. Aby zidentyfikować grupę podstawową, ustalmy $x_0 \in X$. Pętla w M oparta w $[x_0]$ podnosi się od x_0 do drogi kończącej się w dokładnie jednym punkcie γx_0, $\gamma \in \Gamma$. Przypisanie pętli tego elementu γ jest homomorfizmem: podniesienie drugiej pętli od γx_0 jest obrazem jej podniesienia od x_0 przez działanie γ. Każdy γ jest osiągany, bo X jest łukowo spójna i istnieje droga od x_0 do γx_0. Jądro składa się z pętli o zamkniętym podniesieniu, które są zerowe, ponieważ X jest jednospójna i homotopie podnoszą się przez nakrycie. Jest to teoria podnoszenia z Rozdziału 7. □

Przy translacjach $\Gamma = \mathbb{Z}^n$ na $\mathbb{R}^n$ dostajemy płaski torus $T^n = \mathbb{Z}^n\backslash\mathbb{R}^n$. Warunek swobody jest istotny: odbicie $\mathbb{R}^n$ w hiperpłaszczyźnie ma punkty stałe, więc jego iloraz nie jest nakryty przez $\mathbb{R}^n$ w punktach obrazu tej hiperpłaszczyzny. Samo G nie musi natomiast działać na $\Gamma\backslash X$: jego elementy mogą nie zachowywać orbit Γ.

Jeśli stabilizatory nie są trywialne, lokalny iloraz zachowuje informację o symetriach ustalających punkt. Tę informację zapisuje struktura orbifoldu. Jest ona potrzebna w opisie baz rozwłóknień Seiferta w Rozdziale 33.

Definicja 16.3.7 (Orbifold gładki)**.** *Efektywnym orbifoldem gładkim wymiaru n* nazywamy przestrzeń topologiczną $|\mathcal{O}|$, która jest Hausdorffa i ma przeliczalną bazę, wyposażoną w zgodny atlas *map orbifoldowych*. Mapa wokół $y \in |\mathcal{O}|$ składa się z otwartej kuli $B \subset \mathbb{R}^n$ o środku 0, skończonej grupy $H \leq \mathrm{O}(n)$ i homeomorfizmu

$$\varphi : B/H \longrightarrow U \subset |\mathcal{O}|, \qquad \varphi([0]) = y.$$

Symbol $[v]_H$ oznacza orbitę punktu v pod działaniem H; na B/H bierzemy topologię ilorazową. Obrazy takich map są otwarte i pokrywają $|\mathcal{O}|$. Wyjaśnijmy dokładnie, co znaczy *zgodność* map. Niech (C, K, ψ) i (B, H, φ) będą dwiema mapami, o obrazach odpowiednio $V \subset U$. *Zanurzeniem pierwszej mapy w drugiej* jest para złożona z injektywnego homomorfizmu $\iota : K \hookrightarrow H$ i gładkiego zanurzenia $f : C \hookrightarrow B$ spełniająca dla każdego $v \in C$ i $k \in K$ dwa warunki:

$$f(kv) = \iota(k)f(v), \qquad \varphi([f(v)]_H) = \psi([v]_K).$$

Pierwszy warunek mówi, że f zachowuje działanie grup po identyfikacji K z podgrupą H. Drugi mówi, że po przejściu do ilorazów f daje zwykłą inkluzję $V \hookrightarrow U$. Ponieważ obie kule mają wymiar n, zanurzenie f jest dyfeomorfizmem na otwarty obraz.

Atlas jest *zgodny*, gdy dla każdych dwóch jego map o obrazach U_1, U_2 i każdego $y \in U_1 \cap U_2$ istnieje trzecia mapa (C, K, ψ), której obraz V spełnia $y \in V \subset U_1 \cap U_2$ i która zanurza się w obie początkowe mapy. Wybieramy więc mniejszy model całego otoczenia y, a nie tylko odwzorowanie między przestrzeniami podkładowymi. Dwa atlasy określają tę samą strukturę, gdy ich połączenie jest zgodne. Zmiana podniesienia f przez element $h \in H$ zmienia ι przez sprzężenie $\iota(k) \mapsto h\iota(k)h^{-1}$; opisuje tę samą inkluzję na ilorazach.

W mapie wyśrodkowanej w y grupa H jest *grupą lokalną* tego punktu. Jeśli $z \in U$ odpowiada klasie punktu $v \in B$, jego grupą lokalną jest stabilizator H_v; inny wybór punktu w tej samej klasie sprzęga stabilizator w H. Warunek zgodności zapewnia, że grupa lokalna nie zależy, z dokładnością do izomorfizmu, od wybranej mapy. Jej rząd mierzy miejscową symetrię. Sama przestrzeń $|\mathcal{O}|$ to *przestrzeń podkładowa* orbifoldu. Jeśli wszystkie grupy lokalne są trywialne, otrzymujemy zwykły atlas gładkiej rozmaitości.

Jest to wersja efektywna definicji z W. P. Thurstona, *The Geometry and Topology of Three-Manifolds*, rozdział 13, § 13.2.

Przykład 16.3.8 (Rozmaitość i punkty osobliwe orbifoldu)**.** Każda gładka rozmaitość jest orbifoldem z grupami lokalnymi $\{e\}$. Odwrotna implikacja nie zachodzi. Dla $m \geq 2$ niech $D = \{z \in \mathbb{C} : |z| < 1\}$ i niech C_m działa na nim przez obroty $z \mapsto e^{2\pi i/m}z$. Iloraz D/C_m ma w obrazie środka grupę lokalną C_m, a poza nim grupy trywialne. Odwzorowanie $[z] \mapsto z^m$ identyfikuje $|D/C_m|$ topologicznie z dyskiem, ale nie usuwa grupy lokalnej: jako orbifold iloraz nie jest zwykłą rozmaitością. Standardowa metryka ilorazowa ma przy środku kąt stożkowy $2\pi/m$.

Zobaczmy warunek zgodności na tych mapach. Niech $q : D \to D/C_m$ będzie rzutem, a $a \in D \setminus \{0\}$. Wybierzmy $\varepsilon > 0$ tak małe, by dyski $\zeta^k(a + B_\varepsilon(0))$, gdzie $\zeta = e^{2\pi i/m}$ i $0 \leq k < m$, były parami rozłączne. Mapa wokół $q(a)$ ma wtedy postać $(B_\varepsilon(0), \{e\}, \psi)$, gdzie $\psi(v) = q(a + v)$.

Zanurza się ona w mapę $(D, C_m, \mathrm{id}_{D/C_m})$ przez $f(v) = a + v$ i jedyny homomorfizm $\{e\} \hookrightarrow C_m$: równość $q(f(v)) = \psi(v)$ jest dokładnie drugim warunkiem z definicji. Wokół $q(0)$ bierzemy mniejszy dysk o środku 0 z tą samą grupą C_m; tu zanurzenie map jest zwykłą inkluzją dysków i identycznością grup.

Odbicie $z \mapsto \bar{z}$ daje iloraz D z *krawędzią zwierciadlaną*: jej punkty mają stabilizator C_2, a przestrzeń podkładowa jest półdyskiem. W wyższym wymiarze iloraz $\mathbb{R}^3/\{\pm I\}$ ma przy obrazie zera przekrój $\mathbb{RP}^2$. Przebite otoczenie tego punktu ma więc grupę podstawową $\mathbb{Z}/2$, podczas gdy przebita kula w $\mathbb{R}^3$ jest jednospójna. Tutaj nawet przestrzeń podkładowa nie jest rozmaitością w obrazie zera.

Stwierdzenie 16.3.9 (Iloraz z punktami stałymi)**.** *Niech G działa gładko i przechodnio na spójnej rozmaitości X ze zwartym stabilizatorem, a $\Gamma < G$ będzie dyskretna i działa skutecznie na X. Wtedy $\Gamma\backslash X$ ma naturalną strukturę efektywnego orbifoldu. Dla $x \in X$ jego grupa lokalna jest izomorficzna ze stabilizatorem Γ_x.*

Dowód. Z własności działania G na X wynika właściwość działania Γ, jak w dowodzie Twierdzenia 16.3.6. Przeciwobraz punktu (x, x) przez odwzorowanie działania jest zwarty, więc Γ_x jest zwarta; jako podgrupa dyskretna jest skończona. Właściwość działania daje przestrzeń orbit Hausdorffa, a obrazy przeliczalnej bazy X przez otwarty rzut na iloraz tworzą jej przeliczalną bazę, jak w przywołanym dowodzie. Wybierzmy niezmienniczą metrykę ze Stwierdzenia 16.3.1. Właściwość działania daje małe $r > 0$, dla którego $d(x, \gamma x) > 2r$ przy $\gamma \notin \Gamma_x$: w ustalonym zwartym otoczeniu x leży tylko skończenie wiele punktów γx, a pozostałe są oddalone. Zmniejszamy r tak, by odwzorowanie wykładnicze było dyfeomorfizmem na kuli $B_r(0) \subset T_x X$. Wówczas geodezyjna kula $B_r(x)$ jest zachowywana przez Γ_x, a jej obrazy przez elementy spoza Γ_x są z nią rozłączne. Rzut na iloraz identyfikuje zatem otoczenie orbity x z $B_r(x)/\Gamma_x$. Ponieważ dla $h \in \Gamma_x$ zachodzi $h \exp_x(v) = \exp_x(\mathrm{d}h_x v)$, otrzymujemy model $B_r(0)/\Gamma_x$ z ortogonalnym działaniem. To działanie jest skuteczne: izometria o ustalonym punkcie i identycznej różniczce w tym punkcie jest identycznością na spójnej X. Sprawdźmy zgodność tak otrzymanych map. Jeśli ich obrazy przecinają się w orbicie $[z]$, wybieramy przedstawicieli $z_1 \in B_r(x)$ i $z_2 \in B_s(y)$ tej orbity oraz $\gamma \in \Gamma$ takie, że $z_2 = \gamma z_1$. Po przeniesieniu drugiej kuli przez γ^{-1} obie zawierają z_1. Stabilizator Γ_{z_1} jest podgrupą zarówno Γ_x, jak i $\gamma^{-1}\Gamma_y\gamma$: element ustalający z_1 nie może przenieść żadnej z tych kul na rozłączny z nią obraz. Wybieramy małą kulę geodezyjną W wokół z_1, zawartą w przecięciu obu kul i rozłączną ze swoimi obrazami przez elementy spoza Γ_{z_1}. Używając współrzędnych wykładniczych w z_1, otrzymujemy z W/Γ_{z_1} wspólną mapę orbifoldową, która zanurza się w obie wyjściowe mapy przez inkluzję do pierwszej kuli oraz przez γ po inkluzji do drugiej. Towarzyszące homomorfizmy grup to odpowiednio inkluzja $\Gamma_{z_1} \hookrightarrow \Gamma_x$ i odwzorowanie $h \mapsto \gamma h \gamma^{-1}$ z Γ_{z_1} do Γ_y. Ekwiwariantność wynika z podanych homomorfizmów stabilizatorów. Po rzutowaniu do $\Gamma\backslash X$ obydwa zanurzenia przypisują punktowi $w \in W$ tę samą orbitę $[w]$, więc spełniają także drugie równanie z definicji. □

16.4 Struktury lokalnie modelowane na przestrzeni jednorodnej

Geometria Kleina opisuje pojedynczą przestrzeń X z grupą symetrii G. Natomiast rozmaitość może tylko *lokalnie* wyglądać jak X: jej topologia nie musi dopuszczać jednej globalnej mapy do tego modelu. Formalizujemy to analogicznie do atlasu rozmaitości gładkiej, lecz ograniczamy przekształcenia przejścia.

Definicja 16.4.1 (Atlas struktury (G, X))**.** Niech X będzie spójną gładką rozmaitością, na której grupa Liego G działa skutecznie przez dyfeomorfizmy. *Strukturą* (G, X) na rozmaitości M bez brzegu, wymiaru $\dim X$, nazywamy atlas odwzorowań $\varphi_i : U_i \to V_i \subset X$, będących dyfeomorfizmami na otwarte podzbiory modelu, taki że na każdej spójnej składowej przecięcia

$U_i \cap U_j$ odwzorowanie przejścia $\varphi_j \circ \varphi_i^{-1}$ jest ograniczeniem pewnego elementu $g_{ji} \in G$. Zwykle utożsamiamy atlasy zgodne w tym sensie.

Właściwą klasą lokalnych przekształceń jest pseudogrupa utworzona z ograniczeń elementów G i sklejania takich ograniczeń. Zwykły atlas gładki odpowiada znacznie większej pseudogrupie wszystkich lokalnych dyfeomorfizmów; w atlasie geometrycznym przejścia muszą zachowywać wybraną strukturę modelu.

Twierdzenie 16.4.2 (Rozwinięcie i reprezentacja holonomii)**.** *Załóżmy, że X jest spójna i jednospójna, a G działa skutecznie przez izometrie pewnej metryki riemannowskiej na X. Dla spójnej rozmaitości M ze strukturą (G, X) istnieją lokalny dyfeomorfizm* $\mathrm{dev} : \widetilde{M} \to X$ *i homomorfizm $\rho : \pi_1(M) \to G$, spełniające*

$$\mathrm{dev}(\gamma \cdot \widetilde{p}) = \rho(\gamma) \cdot \mathrm{dev}(\widetilde{p}). \tag{16.4.1}$$

Po wyborze punktów bazowych i identyfikacji przekształceń nakrycia para (dev, ρ) *jest wyznaczona z dokładnością do jednoczesnego złożenia* dev *z elementem G i sprzężenia ρ tym elementem.*

Dowód. Wybierzmy punkt bazowy i jedną mapę atlasu w jego otoczeniu. Najpierw zauważmy, że dwie izometrie X zgodne na niepustym zbiorze otwartym są równe. Ich złożenie odwrotne ustala tam punkt i jego całą przestrzeń styczną. Izometria spełnia $F(\exp_p v) = \exp_{F(p)}(\mathrm{d}F_p v)$, więc te same dane ustalają ją w otoczeniu normalnym. Zbiór punktów, w których ustala punkt i różniczkę, jest zatem otwarty; jest też domknięty przez ciągłość. Spójność X daje równość na całym X. W szczególności element grupy odpowiadający przejściu jest jednoznaczny na każdej składowej przecięcia.

Przedłużamy początkową mapę wzdłuż drogi, pokrywając jej zwarty obraz skończenie wieloma dziedzinami map. Jeśli dotychczasowa mapa to $h_i \circ \varphi_i$, a $\varphi_j = g_{ji} \circ \varphi_i$ na otoczeniu przejścia, następną wybieramy jako $(h_i \circ g_{ji}^{-1}) \circ \varphi_j$. Obie zgadzają się na przecięciu. Wstawienie dodatkowej mapy nie zmienia wyniku, ponieważ na wspólnym otoczeniu $g_{ki} = g_{kj} \circ g_{ji}$; równość lokalna jest równością elementów G na mocy poprzedniego akapitu.

Dla homotopii dróg z ustalonymi końcami wybieramy dostatecznie drobną siatkę w kwadracie parametrów, aby obraz każdego prostokąta leżał w jednej dziedzinie mapy. Istnieje taka siatka dzięki lematowi Lebesgue'a. Przesunięcie drogi z dwóch boków małego prostokąta na dwa pozostałe nie zmienia przedłużenia: w jednej mapie oba obliczenia są tym samym odwzorowaniem. Przechodząc przez skończenie wiele prostokątów, otrzymujemy niezależność od homotopii. Model nakrycia uniwersalnego przez klasy dróg daje więc dev; lokalnie jest ono złożeniem mapy atlasu z elementem G, czyli lokalnym dyfeomorfizmem.

Zastosowanie tego przepisu do pętli opartej w punkcie bazowym zmienia początkową mapę o pewien element $\rho(\gamma) \in G$. Składanie pętli odpowiada składaniu tych elementów, co daje homomorfizm; różnica wyników przy zmianie punktu podniesionego to dokładnie równość (16.4.1). Inny wybór początkowej mapy na $a \circ \varphi_0$ daje $\mathrm{dev}' = a \circ \mathrm{dev}$ oraz $\rho'(\gamma) = a \circ \rho(\gamma) \circ a^{-1}$. □

Uwaga 16.4.3 (Dwie różne holonomie). Reprezentacja $\rho : \pi_1(M) \to G$ to *holonomia struktury* (G, X). Nie należy jej utożsamiać z grupą holonomii koneksji Leviego-Civity z Definicji 14.9.1. Na płaskim torusie $T^n = \mathbb{R}^n/\mathbb{Z}^n$ pierwsza holonomia wysyła element $m \in \mathbb{Z}^n$ na przesunięcie $x \mapsto x + m$, więc jest nietrywialna; druga jest trywialna, bo pola współrzędne schodzą do globalnej ramy równoległej.

Stwierdzenie 16.4.4 (Zupełność a globalny iloraz)**.** *Przy założeniach poprzedniego twierdzenia, jeśli X jest zupełna jako rozmaitość riemannowska, a atlas (G, X) na spójnej M wyznacza zupełną metrykę lokalnie izometryczną z X, to* $\mathrm{dev} : \widetilde{M} \to X$ *jest izometrią. Wówczas ρ jest injektywne, jego obraz jest dyskretny i działa swobodnie, a M jest ilorazem $\rho(\pi_1(M))\backslash X$. W szczególności dotyczy to zwartych rozmaitości z taką strukturą.*

Dowód. Metryka z X skleja się na M, ponieważ zmiany współrzędnych są izometriami. Odwzorowanie rozwijające jest lokalną izometrią. Nakrycie uniwersalne z podniesioną metryką jest zupełne: każda jego geodezyjna rzutuje się na geodezyjną w M, którą przedłużamy na całą prostą i podnosimy z powrotem przez nakrycie. Hopf–Rinow daje zupełność metryczną.

Pokażmy, że $F = \mathrm{dev}$ jest nakryciem całej X. Dla $q_0 = F(p_0)$ i dowolnego $q \in X$ wybieramy geodezyjną od q_0 do q. Jej początkową prędkość podnosimy przez $(\mathrm{d}F_{p_0})^{-1}$ i rozwiązujemy równanie geodezyjne w zupełnej $\widetilde{M}$. Lokalna izometryczność i jednoznaczność geodezyjnych dają rzut równy wybranej geodezyjnej w X. Jej koniec jest przeciwobrazem q, więc F jest surjektywne.

Wybierzmy kulę normalną $B(q,r)$ w X. Dla każdego $p \in F^{-1}(q)$ odwzorowanie $v \mapsto \exp_p((\mathrm{d}F_p)^{-1}v)$, gdzie $v \in T_qX$ i $|v| < r$, jest odwrotnością F nad tą kulą po utożsamieniu jej z kulą w T_qX przez $\exp_q$. Obrazy tych odwrotności są rozłączne i wyczerpują $F^{-1}(B(q,r))$: z dowolnego punktu nad kulą podnosimy radialną geodezyjną z powrotem do q. Jej podniesienie ma tylko jeden koniec nad q przez jednoznaczność podnoszenia dla lokalnej izometrii. Są to więc arkusze nakrycia. Nakrycie jednospójnej X jest trywialne, zatem dev jest globalną izometrią. Równość (16.4.1) identyfikuje działanie grupy nakrycia z działaniem $\rho(\pi_1(M))$. Ponieważ dev jest bijekcją, jądro ρ jest trywialne. Swoboda i dyskretność wynikają z odpowiadających im własności grupy przekształceń nakrycia. Jeśli M jest zwarta, jej każda metryka riemannowska jest zupełna dzięki twierdzeniu Hopfa–Rinowa. □

Przykład 16.4.5 (Struktura niezupełna)**.** Na otwartej kuli euklidesowej $B^n \subset \mathbb{R}^n$ wybierzmy atlas otrzymany przez ograniczenie identyczności z modelu $X = \mathbb{R}^n$ i grupy jego izometrii. Nakrycie uniwersalne jest trywialne, $\mathrm{dev} : B^n \hookrightarrow \mathbb{R}^n$ jest inkluzją, a holonomia jest trywialna. Metryka nie jest zupełna: odcinek zbliżający się do brzegu ma skończoną długość. Dlatego nie dostajemy ilorazu całego modelu $\mathbb{R}^n$.

Dalsza lektura: J. S. Purcell, *Hyperbolic Knot Theory*, § 3.1–3.3, rozwinięcie, holonomia i zupełność struktur geometrycznych.

16.5 Przestrzeń euklidesowa i afiniczna

Przykład 16.5.1 (Geometria euklidesowa)**.** Niech $n \geq 1$. Grupa ruchów euklidesowych

$$E(n) = \mathbb{R}^n \rtimes \mathrm{O}(n) = \{(b, A) : b \in \mathbb{R}^n,\ A \in \mathrm{O}(n)\}$$

ma iloczyn $(b,A)(c,B) = (b + Ac, AB)$ i działa na $\mathbb{R}^n$ według $(b,A)\cdot x = b + Ax$. Współrzędne (b,A) oraz gładkość działań w czynnikach czynią z $E(n)$ grupę Liego. Translacje zapewniają przechodniość, a stabilizatorem 0 jest $\{(0,A) : A \in \mathrm{O}(n)\} \cong \mathrm{O}(n)$. Twierdzenie 16.1.5 daje

$$\mathbb{R}^n \cong E(n)/\mathrm{O}(n), \qquad \dim E(n) = n + \frac{n(n-1)}{2}, \qquad \dim \mathrm{O}(n) = \frac{n(n-1)}{2}.$$

Działanie jest skuteczne: ruch ustalający 0 ma $b = 0$, a ustalający następnie każdy wektor bazy ma $A = I$. Macierz ortogonalna zachowuje $|x - y|$, więc zwykła metryka euklidesowa jest $E(n)$-niezmiennicza. Są to wszystkie bijektywne izometrie $\mathbb{R}^n$: po odjęciu obrazu zera izometria f zachowuje iloczyn skalarny z tożsamości polaryzacyjnej, a jej surjektywność daje $\langle f(x+y) - f(x) - f(y), f(z)\rangle = 0$ dla każdego z. Jest więc addytywna, z ciągłości jednorodna, a także ortogonalna. Dopuszczamy odbicia; wybór $\mathbb{R}^n \rtimes \mathrm{SO}(n)$ daje wariant zachowujący orientację.

Przykład 16.5.2 (Grupa afiniczna i przestrzeń afiniczna)**.** Niech

$$\mathrm{Aff}(n,\mathbb{R}) = \mathbb{R}^n \rtimes \mathrm{GL}(n,\mathbb{R}), \qquad (b,A)\cdot x = b + Ax.$$

Wzór na iloczyn jest taki sam jak dla $E(n)$; odwrotność wynosi $(b,A)^{-1} = (-A^{-1}b, A^{-1})$. Ponieważ $\mathrm{GL}(n,\mathbb{R})$ jest otwarta w przestrzeni macierzy, te wzory są gładkie. Stabilizatorem 0 jest $\mathrm{GL}(n,\mathbb{R})$, działanie jest przechodnie dzięki translacjom i skuteczne z tego samego powodu co wyżej. Zatem

$$\mathbb{R}^n \cong \mathrm{Aff}(n,\mathbb{R})/\mathrm{GL}(n,\mathbb{R}), \qquad (n+n^2)-n^2 = n.$$

Jako rozmaitość jest to znowu $\mathbb{R}^n$, lecz większa grupa zachowuje inne własności. Odwzorowanie $x \mapsto Ax+b$ wysyła proste na proste i zachowuje podział odcinka w danym stosunku, gdyż $(1-t)f(x)+tf(y) = f((1-t)x+ty)$. Nie musi zachować długości: $x \mapsto 2x$ należy do grupy afinicznej. Właściwie żadna dodatnio określona metryka riemannowska na $\mathbb{R}^n$ nie jest niezmiennicza względem całej tej grupy. Jej stabilizator zera zawiera $x \mapsto 2x$; niezmienniczość w zerze wymagałaby $g_0(2v,2v) = g_0(v,v)$ dla każdego v, co przeczy dodatniej określoności.

16.6 Przestrzeń rzutowa i sfera

Przestrzeń $\mathbb{RP}^n$ z Przykładu 1.6.5 składa się z jednowymiarowych podprzestrzeni $\mathbb{R}^{n+1}$; punkt zapisujemy $[x_0 : \cdots : x_n]$. W tej geometrii istotne są proste rzutowe i ich wzajemne położenie, a nie odległości.

Przykład 16.6.1 (Projektowa grupa liniowa)**.** Niech $n \geq 1$ i

$$\mathrm{PGL}(n+1,\mathbb{R}) = \mathrm{GL}(n+1,\mathbb{R})/(\mathbb{R}_* I), \qquad \mathbb{R}_* = \mathbb{R}\setminus\{0\}.$$

Podgrupa skalarnych macierzy $\mathbb{R}_* I$ jest domknięta w $\mathrm{GL}(n+1,\mathbb{R})$, więc iloraz jest grupą Liego. Klasa macierzy A działa na $\mathbb{RP}^n$ przez $[A]\cdot[x] = [Ax]$; zmiana A przez niezerowy skalar nie zmienia obrazu. W mapach rzutowych z Przykładu 1.6.5 działanie ma współrzędne będące ilorazami funkcji liniowych o niezerowym mianowniku, więc jest gładkie. Grupa $\mathrm{GL}(n+1,\mathbb{R})$ przenosi dowolną prostą liniową na dowolną inną, zatem działanie jest przechodnie.

Wybierzmy $p = [1:0:\cdots:0]$. Jego stabilizator P składa się z klas blokowych macierzy

$$\begin{pmatrix} \lambda & \beta \\ 0 & B \end{pmatrix}, \qquad \lambda \in \mathbb{R}_*, \quad \beta \in \mathbb{R}^{1\times n}, \quad B \in \mathrm{GL}(n,\mathbb{R}).$$

Warunek zerowego lewego dolnego bloku mówi dokładnie, że pierwsza kolumna jest wielokrotnością e_0. Stąd $\mathbb{RP}^n \cong \mathrm{PGL}(n+1,\mathbb{R})/P$. Kontrola wymiarów daje

$$\dim \mathrm{PGL}(n+1,\mathbb{R}) = (n+1)^2-1, \quad \dim P = n^2+n, \quad \dim \mathbb{RP}^n = n.$$

Wymiar P policzyliśmy jako $1+n+n^2-1$: ostatnie -1 usuwa skalarne macierze.

Działanie PGL jest skuteczne. Jeśli A zachowuje każdą prostą, to $Ae_i = \lambda_i e_i$ dla wektorów bazy. Zachowanie prostej $[e_i+e_j]$ wymusza $\lambda_i = \lambda_j$, a więc A jest skalarna i $[A]$ jest jednością w PGL.

Pełna geometria rzutowa nie ma niezmienniczej metryki riemannowskiej. W mapie $[1 : x_1 : \cdots : x_n]$ element $[\mathrm{diag}(1,2I_n)] \in P$ działa jako $x \mapsto 2x$. Różniczka w p mnoży każdy wektor przez 2, co przeczy niezmienniczości dodatnio określonego iloczynu skalarnego w $T_p\mathbb{RP}^n$. Można *wybrać* na $\mathbb{RP}^n$ metrykę pochodzącą ze sfery, lecz jej grupa symetrii jest mniejsza niż pełne $\mathrm{PGL}(n+1,\mathbb{R})$.

Przykład 16.6.2 (Sfera jako przestrzeń obrotów)**.** Dla $n \geq 1$ grupa $\mathrm{SO}(n+1)$ działa na $S^n \subset \mathbb{R}^{n+1}$ przez obroty. Działanie jest przechodnie: jednostkowe wektory x, y można uzupełnić do dodatnio zorientowanych baz ortonormalnych, a macierz przeprowadzająca jedną bazę w drugą leży w $\mathrm{SO}(n+1)$. Stabilizator e_0 składa się z $\mathrm{diag}(1,B)$, $B \in \mathrm{SO}(n)$. Zatem

$$S^n \cong \mathrm{SO}(n+1)/\mathrm{SO}(n), \qquad \frac{n(n+1)}{2} - \frac{n(n-1)}{2} = n.$$

Dla $n = 1$ konwencja $\mathrm{SO}(1) = \{1\}$ sprawia, że wzór mówi $S^1 \cong \mathrm{SO}(2)$; nie ma tu jednowymiarowego stabilizatora. Działanie jest skuteczne, bo macierz ustalająca wszystkie punkty sfery ustala każdy wektor przestrzeni. Metryka kulista otrzymana przez ograniczenie metryki euklidesowej jest zachowana przez $\mathrm{SO}(n+1)$.

Antypody x i $-x$ na sferze wyznaczają tę samą prostą liniową, stąd $S^n/\{x \sim -x\} \cong \mathbb{RP}^n$. Metryka kulista schodzi na ten iloraz, ponieważ antypodalność jest izometrią. Ta metryka jest dodatkową strukturą: nie jest niezmiennicza względem pełnej grupy rzutowej z poprzedniego przykładu. Grupa $\mathrm{O}(n+1)$ działa na $\mathbb{RP}^n$ przez izometrie tej metryki, z jądrem $\{I, -I\}$; jej skuteczny obraz to $\mathrm{PO}(n+1) = \mathrm{O}(n+1)/\{I, -I\}$.

16.7 Torus: iloraz, grupa i geometria płaska

Przykład 16.7.1 (Dwa działania przechodnie na torusie)**.** Niech $n \geq 1$ i $T^n = \mathbb{R}^n/\mathbb{Z}^n$, jak w Przykładzie 1.6.10. Rozdział 15 wyposażył tę rozmaitość w strukturę grupy Liego: $[x] + [y] = [x+y]$. Dlatego pierwszym, skutecznym modelem jest działanie grupy $G = T^n$ na $X = T^n$ przez translacje. Stabilizator $[0]$ to $H = \{[0]\}$ i

$$T^n \cong T^n/\{[0]\}.$$

Możemy zamiast tego pozostawić grupę $G = (\mathbb{R}^n, +)$ i zdefiniować $a \cdot [x] = [a + x]$. Działanie jest gładkie i przechodnie, a stabilizator $[0]$ jest równy $H = \mathbb{Z}^n$. Otrzymujemy zatem ten sam torus jako

$$T^n \cong \mathbb{R}^n/\mathbb{Z}^n.$$

Tym razem działanie *nie jest skuteczne*: każdy $a \in \mathbb{Z}^n$ działa na każdym $[x]$ jak jedność. Jądro (16.1.1) wynosi właśnie $\mathbb{Z}^n$, a skuteczna grupa ilorazowa to $\mathbb{R}^n/\mathbb{Z}^n = T^n$. Podgrupa $\mathbb{Z}^n$ jest dyskretna, więc wzór na wymiar ma postać $n - 0 = n$.

Zwykła metryka na $\mathbb{R}^n$ jest niezmiennicza względem translacji przez $\mathbb{Z}^n$, toteż przechodzi na płaską metrykę torusa. Metryka zależy od wybranego iloczynu skalarnego na $\mathbb{R}^n$; samo przedstawienie torusa jako grupy Liego nie wyznacza długości. Torus obrotowy zanurzony w $\mathbb{R}^3$ z Przykładu 15.1.4 ma z kolei metrykę indukowaną przez to zanurzenie, na ogół inną od płaskiej. Trzeba więc odróżniać rozmaitość, jej strukturę grupową i wybraną metrykę.

16.8 Dysk Poincarégo jako iloraz grupy Liego

Przykład 16.8.1 (Działanie $\mathrm{PSL}(2,\mathbb{R})$)**.** Zacznijmy od górnej półpłaszczyzny $\mathbb{H}^2 = \{z = x + iy \in \mathbb{C} : y > 0\}$. Niech

$$G = \mathrm{PSL}(2,\mathbb{R}) = \mathrm{SL}(2,\mathbb{R})/\{I, -I\}.$$

Podgrupa $\{I, -I\}$ jest domknięta i normalna, więc G jest grupą Liego. Jej wymiar wynosi trzy: $\mathrm{SL}(2,\mathbb{R}) = \det^{-1}(1)$ jest regularną hiperpowierzchnią w czterowymiarowej przestrzeni macierzy, bo $\mathrm{d}(\det)_A(A) = 2 \det A = 2$; iloraz przez dwuelementową podgrupę nie zmienia wymiaru. Grupa G działa na $\mathbb{H}^2$ przez przekształcenia ułamkowo liniowe

$$\left[\begin{pmatrix} a & b \\ c & d \end{pmatrix}\right] \cdot z = \frac{az+b}{cz+d}, \qquad ad - bc = 1.$$

Znak całej macierzy nie zmienia ułamka. Mianownik nie znika dla $z \in \mathbb{H}^2$, a bezpośrednie obliczenie daje

$$\operatorname{Im} \frac{az+b}{cz+d} = \frac{y}{|cz+d|^2}, \qquad \frac{\mathrm{d}}{\mathrm{d}z} \frac{az+b}{cz+d} = \frac{1}{(cz+d)^2}. \tag{16.8.1}$$

Pierwsza równość pokazuje, że obraz pozostaje w $\mathbb{H}^2$; druga, że działanie jest gładkie.

Działanie jest przechodnie. Dla $z = x + iy$ macierz

$$A_{x,y} = \begin{pmatrix} \sqrt{y} & x/\sqrt{y} \\ 0 & 1/\sqrt{y} \end{pmatrix} \in \mathrm{SL}(2,\mathbb{R})$$

wysyła i w $x + iy$. Stabilizator i obliczamy z $(ai + b)/(ci + d) = i$: po porównaniu części rzeczywistej i urojonej otrzymujemy $b = -c$ oraz $a = d$. Warunek wyznacznika jest wtedy $a^2 + c^2 = 1$. Zatem stabilizator jest *obrazem* $\mathrm{SO}(2)$ w $\mathrm{PSL}(2,\mathbb{R})$, czyli

$$K = \mathrm{SO}(2)/\{I, -I\}, \qquad \mathbb{H}^2 \cong \mathrm{PSL}(2,\mathbb{R})/K, \qquad 3 - 1 = 2.$$

Grupa K jest izomorficzna z kołem obrotów, lecz nie jest dosłownie podgrupą macierzy $\mathrm{SO}(2) \subset \mathrm{SL}(2,\mathbb{R})$: w G utożsamiliśmy macierze I i $-I$. Konkretny izomorfizm na zwykłą grupę obrotów ma postać $[R_\theta] \mapsto R_{2\theta}$.

Metryka hiperboliczna $g_{\mathbb{H}} = ((\mathrm{d}x)^2 + (\mathrm{d}y)^2)/y^2$ z Równania (11.2.3) jest zachowana przez G. Istotnie, przekształcenie holomorficzne w (16.8.1) mnoży euklidesowy element długości przez $|cz + d|^{-2}$, zaś wysokość y przez ten sam czynnik. W ilorazie definiującym $g_{\mathbb{H}}$ czynniki te się skracają. Jeśli element G ustala wszystkie $z \in \mathbb{H}^2$, to wielomian $cz^2 + (d - a)z - b$ znika na zbiorze otwartym, więc $c = b = 0$, $d = a$ i $a = \pm 1$. W G jest to jedność: działanie jest skuteczne.

Przekształcenie Cayleya

$$C : \mathbb{H}^2 \longrightarrow D, \qquad C(z) = \frac{z - i}{z + i}, \qquad D = \{w \in \mathbb{C} : |w| < 1\},$$

jest dyfeomorfizmem na dysk, z odwrotnością $C^{-1}(w) = i(1+w)/(1-w)$ i $C(i) = 0$. Z tożsamości

$$1 - |C(z)|^2 = \frac{4y}{|z + i|^2}, \qquad |C'(z)| = \frac{2}{|z + i|^2}$$

wynika przez podstawienie

$$C^*\left(\frac{4|\mathrm{d}w|^2}{(1 - |w|^2)^2}\right) = \frac{|\mathrm{d}z|^2}{y^2} = g_{\mathbb{H}}.$$

Tak otrzymujemy model dysku Poincarégo z Równania (11.2.4) dla $n = 2$ oraz jego opis $D \cong \mathrm{PSL}(2,\mathbb{R})/K$. Po przeniesieniu działania przez C stabilizator zera działa obrotami dysku: dla macierzy obrotu R_θ bezpośrednie podstawienie daje $C(R_\theta \cdot z) = e^{-2i\theta} C(z)$. Brzeg $|w| = 1$ nie należy do przestrzeni; metryka sprawia, że droga ku niemu ma nieskończoną długość.

16.9 Jak przechodzi się między geometriami

Grupy i ilorazy porządkują opisane przykłady, lecz przejścia między nimi mają różny sens.

Po pierwsze, na *tej samej* przestrzeni $\mathbb{R}^n$ mamy inkluzję grup przekształceń

$$E(n) = \mathbb{R}^n \rtimes \mathrm{O}(n) \;\subset\; \mathrm{Aff}(n,\mathbb{R}) = \mathbb{R}^n \rtimes \mathrm{GL}(n,\mathbb{R}).$$

Większa grupa oznacza mniej własności zachowywanych przez wszystkie ruchy: długość jest euklidesowa, ale nie afiniczna; współliniowość jest afiniczna. Oba modele mają tę samą rozmaitość punktów, choć inne stabilizatory.

Po drugie, odwzorowanie $x \mapsto [1 : x_1 : \cdots : x_n]$ identyfikuje $\mathbb{R}^n$ z otwartym obszarem afinicznym $U_0 = \{[x_0 : \cdots : x_n] : x_0 \neq 0\}$ w $\mathbb{RP}^n$. Homomorfizm

$$(b, A) \longmapsto \left[\begin{pmatrix} 1 & 0 \\ b & A \end{pmatrix}\right] \quad \text{z} \quad \mathrm{Aff}(n,\mathbb{R}) \longrightarrow \mathrm{PGL}(n+1,\mathbb{R})$$

jest różnowartościowy: równość dwóch klas wymagałaby skalarnej proporcjonalności macierzy, a ich lewe górne wyrazy równe 1 wymuszają skalar 1. Realizuje zwykłe działanie $x \mapsto Ax + b$ na U_0. Pełna grupa rzutowa zawiera też przekształcenia, które nie zachowują wybranego obszaru afinicznego: punkt z $\mathbb{R}^n$ może przejść na hiperpłaszczyznę w nieskończoności. Zmienia się więc zarówno grupa, jak i globalna przestrzeń.

Po trzecie, ilorazy zmieniają *topologię* modelu. Torus płaski powstaje z $\mathbb{R}^n$ przez identyfikację $x \sim x + m$, $m \in \mathbb{Z}^n$, a przestrzeń rzutowa ze sfery przez identyfikację punktów antypodalnych. W obu przypadkach należy odróżnić grupę działającą na przestrzeni pokrywającej od skutecznej grupy działającej na ilorazie. Model dysku i półpłaszczyzny jest jeszcze innym przejściem: przekształcenie Cayleya jest izometrią między dwiema postaciami *tej samej* geometrii hiperbolicznej.

Geometrie trójwymiarowe omawiane przy twierdzeniu Thurstona również można zapisywać jako przestrzenie jednorodne grup Liego, lecz sama przechodniość działania nie wystarcza do ich klasyfikacji: w tamtym zagadnieniu ważne są także wybrana metryka i istnienie odpowiednich ilorazów przez dyskretne grupy.

Dalsza lektura: F. Klein, *A Comparative Review of Recent Researches in Geometry* (oryginalny program erlangeński z 1872 roku, przekład); J. M. Lee, *Introduction to Smooth Manifolds*, wyd. 2, rozdziały 20–21 (podgrupy domknięte, działania i ilorazy); B. Solomyak, *The Hyperbolic Plane*, wykład o działaniu $\mathrm{PSL}(2,\mathbb{R})$ i stabilizatorze i.

Rozdział 17

Teoria Cherna–Weila i dowód wzoru Cherna–Gaussa–Bonneta

W Sekcji 14.13 całka z Pfaffianu krzywizny została sformułowana jako wynik zewnętrzny. Pokażemy, dlaczego krzywizna reprezentuje klasę Eulera i skąd bierze się poprawka na brzegu. Ten sam mechanizm określa klasy Pontriagina potrzebne przy sferach Milnora.

17.1 Wielomiany niezmiennicze i transgresja

Niech $E \to M$ będzie zorientowaną wiązką rzeczywistą z metryką i koneksją metryczną ∇. W ramie ortonormalnej macierz koneksji ω jest skośnie symetryczna, a krzywizna ma macierz $\Omega = \mathrm{d}\omega + \omega \wedge \omega$.

Definicja 17.1.1 (Wielomian niezmienniczy)**.** Symetryczne r-liniowe odwzorowanie $P : \mathfrak{so}(q)^r \to \mathbb{R}$ nazywamy *niezmienniczym*, gdy $P(gA_1g^{-1}, \dots, gA_rg^{-1}) = P(A_1, \dots, A_r)$ dla $g \in \mathrm{SO}(q)$. Po podstawieniu macierzy form krzywizny i użyciu iloczynu zewnętrznego otrzymujemy globalną formę $P(\Omega^r)$ stopnia $2r$.

Przykładem jest ślad $P(A, B) = \operatorname{tr}(AB)$. Dla $q = 2m$ polaryzacja Pfaffianu z (14.13.12) jest niezmienniczym wielomianem stopnia m. Sprzężenie krzywizny przy zmianie ramki wyjaśnia, dlaczego te formy sklejają się z lokalnych wzorów.

Twierdzenie 17.1.2 (Cherna–Weila i transgresja)**.** *Forma $P(\Omega^r)$ jest zamknięta, a jej klasa de Rhama nie zależy od koneksji. Dokładniej, dla $\nabla^t = \nabla^0 + tA$, $A = \nabla^1 - \nabla^0$, zachodzi*

$$P(\Omega_1^r) - P(\Omega_0^r) = \mathrm{d}\left(r \int_0^1 P(A, \Omega_t^{r-1})\, \mathrm{d}t \right). \tag{17.1.1}$$

Konstrukcja jest naturalna względem cofnięcia wiązki.

Dowód. Różnica koneksji A jest globalną jednoformą endomorfizmową, więc ścieżka ∇^t ma sens niezależnie od ramki. Jeśli D_t oznacza różniczkę kowariantną form endomorfizmowych, to z rozwinięcia $\Omega_t = \mathrm{d}\omega_t + \omega_t \wedge \omega_t$ wynika $\frac{\mathrm{d}}{\mathrm{d}t}\Omega_t = D_tA$. Tożsamość Bianchiego daje $D_t\Omega_t = 0$. Niezmienniczość P kasuje wyrazy komutatorowe z ω_t, więc

$$\mathrm{d}P(\Omega_t^r) = rP(D_t\Omega_t, \Omega_t^{r-1}) = 0, \qquad \mathrm{d}P(A, \Omega_t^{r-1}) = P(D_tA, \Omega_t^{r-1}).$$

Symetria P daje jednocześnie $\frac{\mathrm{d}}{\mathrm{d}t}P(\Omega_t^r) = rP(D_tA, \Omega_t^{r-1})$. Całkowanie po t kończy dowód. Równość $F^*\Omega_\nabla = \Omega_{F^*\nabla}$ daje naturalność. $\square$

Forma w nawiasie w (17.1.1) to *forma transgresji* Cherna–Simonsa: zapisuje zmianę reprezentanta różniczkowego przy stałej klasie kohomologii.

Przykład 17.1.3 (Euler i pierwsza klasa Pontriagina)**.** Dla orientowanej wiązki rzędu $2m$ określamy $e_\nabla(E) = \mathrm{Pf}(\Omega)/(2\pi)^m$. Zidentyfikujemy ją z topologiczną klasą Eulera poniżej. Dla rzeczywistej wiązki metrycznej normalizacja pierwszej formy Pontriagina jest

$$p_{1,\nabla}(E) = -\frac{1}{8\pi^2}\operatorname{tr}(\Omega\wedge\Omega).$$

Jeśli E rozszczepia się na ortogonalną sumę orientowanych 2-płaszczyzn, a koneksja zachowuje ten rozkład i ma w blokach krzywizny ω_i, blokowy rachunek śladu daje $p_{1,\nabla} = \sum_i(\omega_i/2\pi)^2 = \sum_i e_\nabla(E_i)^2$. Ogólną identyfikację można uzyskać bez założenia takiego rozszczepienia. Z definicji topologicznej w 21.7 klasa $p_1(E)$ jest równa $-c_2(E\otimes_{\mathbb{R}}\mathbb{C})$. Koneksja zespolona ma tę samą macierz krzywizny Ω; ponieważ $\operatorname{tr}\Omega = 0$, składnik stopnia cztery wyrażenia $\det(I + i\Omega/(2\pi))$ wynosi $\operatorname{tr}(\Omega\wedge\Omega)/(8\pi^2)$. Zgodność tak otrzymanej formy Cherna z rzeczywistym obrazem topologicznej klasy c_2 jest tu jawnym wejściem zewnętrznym twierdzenia Cherna–Weila dla wiązek zespolonych. Definicję topologiczną i kontrolny wzór $p_1(E_i) = e(E_i)^2$ podaje A. Hatcher, *Vector Bundles and K-Theory*, §3.1–3.2; zgodność z formą krzywizny oraz obliczenie c_2 opisuje O. Biquarda, *Differential and Riemannian Geometry*, §16.c, wzory (III.39) i (III.41).

17.2 Znormalizowana forma kątowa

Niech teraz E ma rangę $2m$, gdzie $m \geq 1$. Na wiązce sfer jednostkowych $\pi : S(E) \to M$ istnieje tautologiczny przekrój s wiązki π^*E: w punkcie (x,u) jest nim wektor u. Rozszczepmy $\pi^*E = \mathbb{R}s \oplus s^\perp$. Koneksja ∇^s niech czyni s równoległym i na $s^\perp$ niech będzie rzutem $\pi^*\nabla$. Jej forma Eulera jest zerowa, ponieważ krzywizna ma zerowy wiersz i kolumnę w kierunku s.

Lemat 17.2.1 (Forma kątowa)**.** *Niech Ψ_∇ będzie transgresją Pfaffianu od $\pi^*\nabla$ do ∇^s:*

$$\Psi_\nabla = \frac{m}{(2\pi)^m}\int_0^1 P_{\mathrm{Pf}}(A,\Omega_t^{m-1})\,\mathrm{d}t, \qquad A = \nabla^s - \pi^*\nabla.$$

Wtedy $\mathrm{d}\Psi_\nabla = -\pi^*e_\nabla(E)$ oraz $\int_{S(E_x)}\Psi_\nabla = 1$ dla każdego włókna zorientowanego jako brzeg dysku.

Dowód. Pierwsza równość jest (17.1.1), bo forma Eulera ∇^s znika. Obliczmy normalizację na jednym włóknie S^{2m-1}. W ortogonalnej trywializacji $\pi^*\nabla$ ogranicza się do płaskiej koneksji d. Niech u będzie wektorem jednostkowym. Macierz koneksji zachowującej u wynosi $A = u\,\mathrm{d}u^{\mathsf{T}} - \mathrm{d}u\,u^{\mathsf{T}}$: rzeczywiście $Au = -\mathrm{d}u$. W punkcie $u = e_1$ mamy $A_{1a} = \mathrm{d}u^a$, $A_{a1} = -\mathrm{d}u^a$, a $A_{ab} = 0$ dla $a,b > 1$. Krzywizna $\mathrm{d} + tA$ ma wtedy część styczną $(\Omega_t)_{ab} = (2t - t^2)\mathrm{d}u^a\wedge\mathrm{d}u^b$: składnik $\mathrm{d}A$ daje $2t$, a $A\wedge A$ daje $-t^2$. W polaryzacji Pfaffianu jedna para indeksów zawiera 1 i trafia do A, zaś pozostałe parujemy w formach Ω_t. Po uporządkowaniu iloczynów wszystkie wyrazy mają ten sam znak, a ich suma ma współczynnik $(2m-1)!!$. Stąd

$$\Psi_\nabla|_{S^{2m-1}} = \frac{(2m-1)!!}{(2\pi)^m}\left(\int_0^1 (2t-t^2)^{m-1}\mathrm{d}t\right)\mathrm{vol}_{S^{2m-1}}.$$

Podstawienie $v = 1-t$ oraz całkowanie przez części dają $\int_0^1(2t-t^2)^{m-1}\mathrm{d}t = (2m-2)!!/(2m-1)!!$. Z rachunku Gaussa $\mathrm{vol}(S^{2m-1}) = 2\pi^m/(m-1)!$. Ponieważ $(2m-2)!! = 2^{m-1}(m-1)!$, całka z Ψ_∇ jest 1. □

Stwierdzenie 17.2.2 (Identyfikacja klasy Eulera)**.** *Klasa de Rhama $[e_\nabla(E)]$ jest rzeczywistym obrazem topologicznej klasy Eulera $e(E)$.*

Dowód. Wyjaśnijmy użyty model względny. Dla inkluzji $i : S(E) \hookrightarrow D(E)$ jego kochainy stopnia k są parami $(\alpha, \beta) \in \Omega^k(D(E)) \oplus \Omega^{k-1}(S(E))$ z różniczką $\mathrm{d}(\alpha, \beta) = (\mathrm{d}\alpha, i^*\alpha - \mathrm{d}\beta)$. Istotnie, obcięcie form z $D(E)$ na jego brzeg jest surjektywne: formę na $S(E)$ przedłużamy przez kołnierz. Każda zamknięta para jest więc kohomologiczna parze $(\alpha - \mathrm{d}\widetilde{\beta}, 0)$, gdzie $i^*\widetilde{\beta} = \beta$. Jeśli para $(\alpha, 0)$ jest dokładna, to jej prymitywę można tak samo skorygować przedłużeniem formy z brzegu, aby znikała po obcięciu. Kompleks par jest przez to równoważny kompleksowi form na $D(E)$ znikających po obcięciu do $S(E)$. Z twierdzenia de Rhama i ciągów dokładnych par wynika, że jego kohomologia jest $H^*(D(E), S(E); \mathbb{R})$; por. R. Bott i L. Tu, *Differential Forms in Algebraic Topology*, §7.

Para $(\pi^* e_\nabla(E), -\Psi_\nabla)$ jest zamknięta w tym kompleksie, ponieważ $\mathrm{d}e_\nabla(E) = 0$ oraz $\mathrm{d}(-\Psi_\nabla) = \pi^* e_\nabla(E)$ na $S(E)$. Jej ewaluacja na względnym cyklu włókna ma postać $\int_{D(E_x)} \alpha - \int_{S(E_x)} \beta$: znak minus wynika ze Stokesa i powyższej różniczki na parach. Jej całka względna po każdym (D^{2m}, S^{2m-1}) wynosi $0 - \int_{S^{2m-1}}(-\Psi_\nabla) = 1$. Jest więc znormalizowaną klasą Thoma z Twierdzenia 21.8.1. Cofnięcie jej przez zerowy przekrój jest z jednej strony topologiczną klasą Eulera, a z drugiej klasą formy $e_\nabla(E)$. □

17.3 Dowód i poprawka brzegowa

Twierdzenie 17.3.1 (Cherna–Gaussa–Bonneta z gładkim brzegiem)**.** *Niech (M^{2m}, g) będzie zwartą, zorientowaną rozmaitością riemannowską o gładkim brzegu, a ν zewnętrzną jednostkową normalną. Określmy konkretną formę brzegową*

$$\mathcal{B}_g := \nu^* \Psi_{\nabla^{TM}}. \tag{17.3.1}$$

Wtedy

$$\boxed{\chi(M) = \frac{1}{(2\pi)^m} \int_M \mathrm{Pf}(\Omega^{TM}) + \int_{\partial M} \mathcal{B}_g.} \tag{17.3.2}$$

Jeśli brzeg jest pusty, jest to Twierdzenie 14.13.9.

Dowód. Wybierzmy pole wektorowe V równe ν przy brzegu, z niezdegenerowanymi zerami p_i we wnętrzu. Przedłużamy ν przez kołnierz, a potem perturbujemy pole we wnętrzu tak, by było transwersalne do przekroju zerowego. Usuńmy małe rozłączne dyski D_i wokół zer i połóżmy $u = V/|V|$ na pozostałej części M_0. Z Lematu 17.2.1 i twierdzenia Stokesa otrzymujemy

$$\int_{M_0} e_{\nabla^{TM}} = -\int_{\partial M_0} u^*\Psi = -\int_{\partial M} \nu^*\Psi + \sum_i \int_{\partial D_i} u^*\Psi.$$

Na brzegu dziury znak orientacji jest przeciwny do orientacji ∂D_i. Gdy dyski kurczą się do zer, ich całki zbiegają do stopni odwzorowań $u : \partial D_i \to S^{2m-1}$, czyli indeksów V. Aby uzasadnić granicę, ustalmy zorientowane współrzędne wokół p_i oraz gładką zorientowaną ramę ortonormalną TM nad D_i i zapiszmy $x = p_i + \varepsilon y$, $|y| = 1$. Niech L będzie macierzą $\mathrm{D}_{p_i} V$ w tych dwóch bazach. Ponieważ L jest odwracalna, odwzorowania $u_\varepsilon(y)$ i ich pierwsze pochodne są jednostajnie ograniczone i zbiegają do $Ly/|Ly|$. Składowa Ψ zawierająca wyłącznie różniczki zmiennej włóknowej u jest znormalizowaną formą objętości sfery, więc jej całka jest stopniem u_ε. Każdy pozostały składnik zawiera co najmniej jedną różniczkę podstawy $\mathrm{d}x = \varepsilon \mathrm{d}y$; jego całka jest $O(\varepsilon)$. Zatem

$$\int_M e_{\nabla^{TM}} + \int_{\partial M} \nu^*\Psi = \sum_i \mathrm{ind}_{p_i} V.$$

Suma po prawej wynosi $\chi(M)$ dla pola skierowanego na zewnątrz. Wyprowadźmy używaną wersję Poincarégo–Hopfa: wybieramy funkcję Morse'a stałą na brzegu, rosnącą w kierunku

zewnętrznym. Otrzymujemy ją z parametru kołnierza, przedłużonego do wnętrza i perturbowanego z dala od kołnierza. Lokalny argument dołączenia uchwytu z Twierdzenia 22.2.2 stosuje się do kolejnych podpoziomic, bo w kołnierzu nie ma punktów krytycznych. Jej gradient jest zewnętrzny, a zero indeksu Morse'a λ ma indeks pola $(-1)^\lambda$ i wnosi ten sam składnik do sumy naprzemiennej uchwytów. Każde pole zewnętrzne jest homotopijne na brzegu przez pola zewnętrzne, bo ich normalne składowe są dodatnie. Przedłużamy tę homotopię do pól na M i perturbujemy ją we wnętrzu $M \times (0,1)$, zachowując oba pola skrajne i brzeg, do transwersalności względem przekroju zerowego. Zera tworzą wtedy zwartą zorientowaną 1-rozmaitość w $M \times [0,1]$, której końce na poziomie 0 mają znaki przeciwne do indeksów pierwszego pola, a na poziomie 1 zgodne z indeksami drugiego pola. Suma tych znaków na brzegu jest zerem, więc suma indeksów nie zmienia się przy homotopii. To kończy dowód. □

Dla $m = 1$ forma kątowa mierzy obrót jednostkowego wektora. Wzdłuż brzegu obrót ν ma prędkość k_g, więc $\mathcal{B}_g = k_g\,\mathrm{d}s/(2\pi)$, zgodnie z (14.13.2). W ogólnym wymiarze (17.3.1) definiuje formę, która w (14.13.16) była tylko zapowiedziana. Rozwinięcie transgresji zawiera drugą formę fundamentalną brzegu oraz jego krzywiznę.

Przykład 17.3.2 (Płaska kula)**.** Na $D^{2m} \subset \mathbb{R}^{2m}$ krzywizna znika. Normalna zewnętrzna $\nu(u) = u$ na S^{2m-1} jest identycznością włókna, więc Lemat 17.2.1 daje $\int_{\partial D^{2m}} \mathcal{B}_g = 1 = \chi(D^{2m})$. Sprawdza to współczynnik i znak poprawki brzegowej.

Dalsza lektura: S.-S. Chern, *A Simple Intrinsic Proof of the Gauss–Bonnet Formula for Closed Riemannian Manifolds* (1944), §1–2, D. Cibotaru i S. Moroianu, *Odd Pfaffian Forms*, część o transgresji i brzegu.

Rozdział 18

Teoria Hodge'a i metoda Bochnera

Kohomologia de Rhama z Rozdziału 10 rozpoznaje formy zamknięte z dokładnością do form dokładnych. Metryka pozwala wybrać z każdej klasy szczególnego przedstawiciela: formę harmoniczną. Krzywizna narzuca ograniczenia na takie formy, a przez nie na topologię rozmaitości. W tym rozdziale rozpiszemy rachunek geometryczny i dokładnie oddzielimy go od potrzebnego twierdzenia analitycznego o operatorach eliptycznych.

Przez cały rozdział (M^n, g) jest gładką, zwartą, zorientowaną rozmaitością riemannowską *bez brzegu*, a ∇ oznacza koneksję Leviego-Civity. Nie zakładamy spójności, chyba że jest to powiedziane wprost. Forma objętości vol_g jest zgodna z wybraną orientacją. Występowanie brzegu wymagałoby warunków brzegowych i zmieniłoby twierdzenie o rozkładzie.

18.1 Gwiazda Hodge'a i sprzężenie różniczki zewnętrznej

Gwiazda Hodge'a zamienia pomiar w k niezależnych kierunkach na pomiar w kierunkach do nich prostopadłych. Metryka mówi, co znaczy „prostopadły" i jak porównywać wielkości; orientacja wybiera znak. Na przykład w zorientowanej $\mathbb{R}^3$ z metryką euklidesową $*\mathrm{d}x = \mathrm{d}y \wedge \mathrm{d}z$: kierunkowi osi x odpowiada prostopadła, zorientowana płaszczyzna yz. Gwiazda nie różniczkuje formy; wykonuje taką zamianę osobno w każdym punkcie rozmaitości.

Metryka na T_pM indukuje iloczyn skalarny na $\Lambda^k T_p^* M$: kliny rosnących układów elementów ortonormalnej kobazy są ortonormalne. Używamy tu algebry zewnętrznej z Rozdziału 3 i dodatkowego wyboru metryki.

Definicja 18.1.1 (Gwiazda Hodge'a)**.** Dla $\alpha, \beta \in \Omega^k(M)$ forma $*\beta \in \Omega^{n-k}(M)$ jest jednoznacznie określona przez

$$\alpha \wedge *\beta = \langle \alpha, \beta \rangle_g \, \mathrm{vol}_g. \tag{18.1.1}$$

Jeśli $(e^1, \dots, e^n)$ jest dodatnio zorientowaną ortonormalną kobazą i $I = (i_1 < \cdots < i_k)$, to

$$*e^I = \varepsilon(I, I^c) e^{I^c},$$

gdzie $\varepsilon(I, I^c)$ jest znakiem permutacji $(i_1, \dots, i_k, I^c)$.

Istnienie wynika z ostatniego wzoru: po rozłożeniu form w ortonormalnej kobazie współczynnik przy vol_g po lewej stronie (18.1.1) jest właśnie ich iloczynem skalarnym. Wzór nie zależy od wyboru dodatnio zorientowanej kobazy, bo obie strony definicji są niezmiennicze. Gładkość $*$ wynika z gładkości metryki.

Stwierdzenie 18.1.2 (Dwa zastosowania gwiazdy)**.** *Na k-formach zachodzi*

$$** \alpha = (-1)^{k(n-k)} \alpha, \qquad *1 = \mathrm{vol}_g, \quad *\mathrm{vol}_g = 1. \tag{18.1.2}$$

Dowód. W dodatniej ortonormalnej kobazie pierwsze zastosowanie $*$ przenosi e^I na dopełniający klin ze znakiem permutacji. Drugie przestawia blok długości $n-k$ za blok długości k. Wymaga to $k(n-k)$ transpozycji, więc iloczyn obu znaków jest $(-1)^{k(n-k)}$. Dla pustego i pełnego układu indeksów otrzymujemy dwie pozostałe równości. □

Przykład 18.1.3 (Płaszczyzna i torus)**.** W dodatniej ortonormalnej kobazie $(\mathrm{d}x, \mathrm{d}y)$ mamy $*\mathrm{d}x = \mathrm{d}y$, $*\mathrm{d}y = -\mathrm{d}x$, a $*(\mathrm{d}x \wedge \mathrm{d}y) = 1$. Te same formuły obowiązują na płaskim torusie $\mathbb{R}^2/\mathbb{Z}^2$ dla form pochodzących z niezmienniczych względem przesunięć form płaszczyzny. Znak $*\mathrm{d}y$ zapewnia $** = -1$ na 1-formach.

Definiujemy iloczyn L^2 gładkich k-form przez

$$(\alpha, \beta)_{L^2} = \int_M \langle \alpha, \beta \rangle_g \, \mathrm{d}\mu_g = \int_M \alpha \wedge *\beta. \tag{18.1.3}$$

Równość z prawej wynika z (18.1.1) i zgodności $\mathrm{d}\mu_g$ z vol_g opisanej w Stwierdzeniu 11.6.8.

Definicja 18.1.4 (Kodyferencjał i laplasjan Hodge'a)**.** Na k-formach kładziemy

$$\delta = (-1)^{n(k+1)+1} * \mathrm{d} * : \Omega^k(M) \longrightarrow \Omega^{k-1}(M), \qquad \delta|_{\Omega^0} = 0. \tag{18.1.4}$$

Laplasjanem Hodge'a jest

$$\Delta_H = \mathrm{d}\delta + \delta\mathrm{d}. \tag{18.1.5}$$

Forma α jest *harmoniczna*, gdy $\Delta_H \alpha = 0$; przestrzeń harmonicznych k-form oznaczamy przez $\mathcal{H}^k(M, g)$.

Kodyferencjał δ mierzy drugą stronę zmienności formy. Dla 1-formy α odpowiadającej polu $\alpha^\sharp$ jest ujemną dywergencją tego pola: $\delta\alpha = -\operatorname{div}(\alpha^\sharp)$. Różniczka d wykrywa natomiast jego obieg (w wymiarze trzy odpowiada rotacji). Laplasjan Hodge'a łączy oba pomiary: $\Delta_H = \mathrm{d}\delta + \delta\mathrm{d}$. Na funkcjach pozostaje ujemnym laplasjanem znanym z rachunku gradientu. Na zwartej rozmaitości bez brzegu zerowa energia tego operatora oznacza $\mathrm{d}\alpha = \delta\alpha = 0$; dla 1-form jest to jednoczesny brak obiegu i dywergencji. Wykażemy to poniżej.

Symbol δ oznacza tutaj operator na *formach*. W Rozdziale 10 ten sam znak występuje także przy kobrzegu kochain; dziedzina rozstrzyga znaczenie. Na funkcjach $\Delta_H f = \delta\mathrm{d}f = -\operatorname{div}(\nabla_g f)$, czyli znak jest przeciwny do konwencji $\Delta f = \operatorname{div}(\nabla f)$ z Rozdziału 14.

Stwierdzenie 18.1.5 (Sprzężenie i energia)**.** *Dla $1 \le k \le n$, $\eta \in \Omega^{k-1}(M)$ i $\alpha \in \Omega^k(M)$ zachodzi*

$$(\mathrm{d}\eta, \alpha)_{L^2} = (\eta, \delta\alpha)_{L^2}. \tag{18.1.6}$$

Przy umowie $\Omega^{-1}(M) = \Omega^{n+1}(M) = 0$ dla każdej $\alpha \in \Omega^k(M)$, $0 \le k \le n$, mamy

$$(\Delta_H \alpha, \alpha)_{L^2} = \|\mathrm{d}\alpha\|^2_{L^2} + \|\delta\alpha\|^2_{L^2}, \tag{18.1.7}$$

więc α jest harmoniczna wtedy i tylko wtedy, gdy $\mathrm{d}\alpha = 0$ i $\delta\alpha = 0$.

Dowód. Twierdzenie Stokesa na M bez brzegu daje

$$0 = \int_M \mathrm{d}(\eta \wedge *\alpha) = \int_M \mathrm{d}\eta \wedge *\alpha + (-1)^{k-1} \int_M \eta \wedge \mathrm{d} * \alpha.$$

Z (18.1.2) i wykładnika w (18.1.4) wynika $*\delta\alpha = (-1)^k \mathrm{d} * \alpha$. Po podstawieniu druga całka jest $-(\eta, \delta\alpha)_{L^2}$, co dowodzi (18.1.6). Stosujemy tę równość raz do $\mathrm{d}\delta\alpha$, a raz do $\delta\mathrm{d}\alpha$, uzyskując (18.1.7); na krańcach zakresu pomijamy zerowe składniki. Jeżeli jej prawa strona znika, obie nieujemne całki są zerowe. Gładkość form sprawia, że $\mathrm{d}\alpha$ i $\delta\alpha$ znikają w każdym punkcie. Implikacja odwrotna jest bezpośrednia. □

Ponieważ $\mathrm{d}^2 = 0$, a z (18.1.4) także $\delta^2 = 0$, otrzymujemy $\mathrm{d}\Delta_H = \Delta_H \mathrm{d}$ oraz $\delta\Delta_H = \Delta_H \delta$. Równania te pozwalają przenosić rozkład harmoniczny między stopniami.

18.2 Eliptyczność i rozkład Hodge'a

Samo równanie energii nie daje istnienia harmonicznego przedstawiciela klasy: trzeba jeszcze rozwiązać równanie różniczkowe $\Delta_H u = f$. Jego lokalny charakter wyjaśnia symbol główny.

Stwierdzenie 18.2.1 (Symbol laplasjanu)**.** *Jeśli $\xi \in T^*_pM$ jest niezerowy, a w symbolu operatora pochodne zastępujemy przez $i\xi$, to*

$$\sigma_2(\Delta_H)(p,\xi) = |\xi|_g^2 \,\mathrm{id}_{\Lambda^k T^*_pM}. \tag{18.2.1}$$

Zatem Δ_H jest operatorem eliptycznym.

Dowód. W najwyższym rzędzie symbol d jest $i\xi\wedge(\cdot)$, a symbol δ jest $-i\iota_{\xi^\sharp}(\cdot)$; drugi wzór można odczytać z (18.1.4) w ortonormalnej kobazie. Dlatego symbol sumy $\mathrm{d}\delta+\delta\mathrm{d}$ jest

$$\xi\wedge\iota_{\xi^\sharp} + \iota_{\xi^\sharp}(\xi\wedge\cdot).$$

Na dowolnej formie β relacja $\iota_{\xi^\sharp}(\xi\wedge\beta) = |\xi|^2\beta - \xi\wedge\iota_{\xi^\sharp}\beta$ redukuje tę sumę do $|\xi|^2\beta$. Dla $\xi\neq 0$ jest to izomorfizm, zgodnie z definicją eliptyczności. □

Twierdzenie 18.2.2 (Analityczne wejście: alternatywa eliptyczna)**.** *Dla operatora Δ_H na k-formach zwartej rozmaitości bez brzegu przestrzeń $\mathcal{H}^k(M,g)$ jest skończenie wymiarowa i składa się z form gładkich. Jeżeli gładka forma f jest prostopadła do $\mathcal{H}^k(M,g)$ w L^2, to istnieje jednoznaczna gładka forma $u\perp\mathcal{H}^k(M,g)$ taka, że $\Delta_H u = f$.*

Jest to *przyjęte twierdzenie analityczne*, nie wynik dowiedziony w tym skrypcie. Dowód wymaga oszacowań eliptycznych, zwartości zanurzeń Sobolewa i regularności słabych rozwiązań. Rozkład Hodge'a i rolę parametryksu omawiają notatki MIT, wykład 15; klasyczne ujęcie pochodzi z pracy K. Kodairy, *Harmonic Fields in Riemannian Manifolds* (1949). Wszystkie poniższe wnioski z tego wejścia udowodnimy już w ramach rachunku form.

Twierdzenie 18.2.3 (Rozkład Hodge'a)**.** *Każda $\omega\in\Omega^k(M)$ ma jednoznaczny rozkład ortogonalny w L^2*

$$\omega = h + \mathrm{d}\eta + \delta\zeta, \qquad h\in\mathcal{H}^k(M,g),\quad \eta\in\Omega^{k-1}(M),\quad \zeta\in\Omega^{k+1}(M). \tag{18.2.2}$$

Jednoznaczne są trzy składniki *h, $\mathrm{d}\eta$, $\delta\zeta$; same potencjały η,ζ nie muszą być jednoznaczne.*

Dowód. Rzut ortogonalny h na skończenie wymiarową $\mathcal{H}^k$ jest gładki. Z Twierdzenia 18.2.2 istnieje gładkie u z $\Delta_H u = \omega - h$. Stąd $\omega = h + \mathrm{d}(\delta u) + \delta(\mathrm{d}u)$. Harmoniczna forma jest zamknięta i współzamknięta na mocy (18.1.7), więc z (18.1.6) jest prostopadła do form dokładnych i współdokładnych. Te dwie ostatnie przestrzenie też są ortogonalne:

$$(\mathrm{d}\eta, \delta\zeta)_{L^2} = (\mathrm{d}^2\eta,\zeta)_{L^2} = 0.$$

Jeśli dwie trójki składników dawałyby tę samą formę, ich różnica byłaby sumą trzech wzajemnie prostopadłych form o sumie zerowej. Kwadrat normy tej sumy jest sumą kwadratów ich norm; wszystkie muszą zniknąć. □

Wniosek 18.2.4 (Harmoniczny przedstawiciel klasy)**.** *Odwzorowanie*

$$\mathcal{H}^k(M,g) \longrightarrow H^k_{\mathrm{dR}}(M), \qquad h\longmapsto [h]$$

jest izomorfizmem. Każda klasa ma więc dokładnie jeden harmoniczny przedstawiciel, a liczba Bettiego $b_k = \dim H^k_{\mathrm{dR}}(M)$ jest skończona.

Dowód. Jeśli ω jest zamknięta, bierzemy jej rozkład (18.2.2). Po sparowaniu z $\delta\zeta$ dostajemy

$$\|\delta\zeta\|^2_{L^2} = (\omega, \delta\zeta)_{L^2} = (\mathrm{d}\omega, \zeta)_{L^2} = 0,$$

bo pozostałe składniki są do $\delta\zeta$ ortogonalne. Zatem $\omega = h + \mathrm{d}\eta$ i $[\omega] = [h]$. Jeżeli harmoniczna h jest dokładna, powiedzmy $h = \mathrm{d}\eta$, to $\|h\|^2_{L^2} = (\delta h, \eta)_{L^2} = 0$. To daje surjektywność i injektywność. Skończoność wynika z Twierdzenia 18.2.2. □

Wybór metryki zmienia *formę* harmonicznego przedstawiciela, ale nie grupę kohomologii. Geometrycznie h jest przedstawicielem o najmniejszej normie L^2 w swojej klasie. Rzeczywiście każdy inny przedstawiciel ma postać $h + \mathrm{d}\eta$, a z $\delta h = 0$ i (18.1.6) wynika

$$\|h + \mathrm{d}\eta\|^2_{L^2} = \|h\|^2_{L^2} + \|\mathrm{d}\eta\|^2_{L^2}.$$

Na torusie taka forma może być niezerowa: $\mathrm{d}x$ nie ma lokalnego obiegu ani dywergencji, lecz jej całka wzdłuż pętli okrążającej torus jest niezerowa. Gwiazda $*$ jest izometrią punktową i, przez (18.1.4), przenosi formy harmoniczne stopnia k na formy harmoniczne stopnia $n-k$. Otrzymujemy między innymi $b_k = b_{n-k}$.

18.3 Wzór Weitzenböcka dla form stopnia pierwszego

Laplasjan Hodge'a używa różniczki zewnętrznej. Koneksja daje inny operator: laplasjan szorstki $\nabla^*\nabla = -\operatorname{tr}_g \nabla^2$, gdzie $\nabla^2_{X,Y}\alpha = \nabla_X\nabla_Y\alpha - \nabla_{\nabla_X Y}\alpha$. Różnicę między nimi mierzy krzywizna Ricciego z Definicji 14.4.1.

Twierdzenie 18.3.1 (Wzór Weitzenböcka na 1-formach)**.** *Przy konwencji krzywizny* (14.1.1)*, dla każdej $\alpha \in \Omega^1(M)$ mamy*

$$\Delta_H\alpha = \nabla^*\nabla\alpha + \mathrm{Ric}^\sharp(\alpha), \qquad (\mathrm{Ric}^\sharp\alpha)_j = \mathrm{Ric}_j{}^a\alpha_a. \tag{18.3.1}$$

Dowód. W punkcie p wybieramy lokalną ortonormalną ramkę (e_i) z $\nabla e_i(p) = 0$. Jeśli $\alpha_i = \alpha(e_i)$, to w tym punkcie

$$(\mathrm{d}\alpha)_{ij} = \nabla_i\alpha_j - \nabla_j\alpha_i, \qquad \delta\alpha = -\nabla^i\alpha_i, \qquad (\delta\beta)_j = -\nabla^i\beta_{ij}.$$

Ostatni wzór dla 2-formy β wynika z (18.1.4) w tej ramce. Wstawiając go do $\mathrm{d}\delta\alpha + \delta\mathrm{d}\alpha$, dostajemy

$$\begin{aligned}(\Delta_H\alpha)_j &= -\nabla_j\nabla^i\alpha_i - \nabla^i(\nabla_i\alpha_j - \nabla_j\alpha_i)\\ &= -\nabla^i\nabla_i\alpha_j + (\nabla^i\nabla_j - \nabla_j\nabla^i)\alpha_i.\end{aligned}$$

Koneksja na kowektorach ma znak przeciwny do koneksji na wektorach, toteż

$$([\nabla_i, \nabla_j]\alpha)_k = -R^a{}_{kij}\alpha_a.$$

Po zwężeniu pierwszego i trzeciego indeksu używamy antysymetrii tensora krzywizny w dwóch ostatnich argumentach $\mathcal{R}$ oraz (14.4.1):

$$-\sum_i R^a{}_{iij}\alpha_a = \sum_i R^i{}_{aij}\alpha_a = \mathrm{Ric}_j{}^a\alpha_a.$$

Pierwszy składnik wcześniejszego rachunku to w ramce normalnej $(\nabla^*\nabla\alpha)_j$. Ponieważ oba człony są tensorowe, równość zachodzi na całym M. □

Stwierdzenie 18.3.2 (Zintegrowana tożsamość Bochnera)**.** *Dla każdej* 1*-formy* α *zachodzi*

$$\|\mathrm{d}\alpha\|_{L^2}^2 + \|\delta\alpha\|_{L^2}^2 = \|\nabla\alpha\|_{L^2}^2 + \int_M \mathrm{Ric}(\alpha^\sharp, \alpha^\sharp)\,\mathrm{d}\mu_g. \tag{18.3.2}$$

Dowód. Parujemy (18.3.1) z α i całkujemy. Lewa strona jest lewą stroną (18.3.2) dzięki (18.1.7). Dla członu z koneksją stosujemy twierdzenie o dywergencji z Rozdziału 11 do pola określonego przez $g(X,Y) = \langle \nabla_Y \alpha, \alpha\rangle$. W ramce normalnej

$$\operatorname{div} X = \langle \operatorname{tr}_g \nabla^2\alpha, \alpha\rangle + |\nabla\alpha|^2.$$

Całka dywergencji znika, ponieważ M nie ma brzegu. Pozostały składnik to dokładnie $\mathrm{Ric}(\alpha^\sharp, \alpha^\sharp)$. □

Wniosek 18.3.3 (Znikanie Bochnera)**.** *Jeżeli* $\mathrm{Ric} \geq 0$*, każda harmoniczna* 1*-forma jest równoległa. Jeśli ponadto* M *jest spójna i* Ric *jest dodatnio określony choćby w jednym punkcie, to* $H^1_{\mathrm{dR}}(M) = 0$*. W szczególności wynika to z warunku* $\mathrm{Ric} > 0$ *na całym* M*.*

Dowód. Harmoniczność zeruje lewą stronę (18.3.2). Przy $\mathrm{Ric} \geq 0$ obie całki po prawej są nieujemne, zatem $\nabla\alpha = 0$. Długość formy równoległej jest stała na każdej składowej spójnej. Jeśli Ricci jest dodatnio określony w punkcie składowej, równość $\mathrm{Ric}(\alpha^\sharp, \alpha^\sharp) = 0$ tamże wymusza $\alpha = 0$ w tym punkcie, a więc wszędzie na składowej. Na koniec używamy Wniosku 18.2.4. □

Przykład 18.3.4 (Sfera i płaski torus)**.** Na okrągłej S^n_a, $n \geq 2$, Rozdział 14 daje $\mathrm{Ric} = (n-1)a^{-2}g$. Z Wniosku 18.3.3 dostajemy $H^1_{\mathrm{dR}}(S^n_a) = 0$; jest to analityczny dowód topologicznego wyniku obliczonego wcześniej. Na płaskim $T^n = \mathbb{R}^n/\mathbb{Z}^n$ tensor Ricciego jest zerowy. Formy $\mathrm{d}x^1, \ldots, \mathrm{d}x^n$ schodzą na torus i są równoległe, więc harmoniczne. Każda harmoniczna 1-forma jest równoległa, a jej współczynniki w tej globalnej kobazie są stałe. Stąd $\dim H^1_{\mathrm{dR}}(T^n) = n$. W szczególności torus pokazuje, dlaczego sam warunek $\mathrm{Ric} \geq 0$ nie wystarcza do znikania H^1.

18.4 Cztery wymiary: formy samodualne i sygnatura

W wymiarze cztery (18.1.2) daje $*^2 = 1$ na 2-formach. Stąd każda 2-forma rozkłada się punktowo na

$$\alpha^+ = \tfrac{1}{2}(\alpha + *\alpha), \qquad \alpha^- = \tfrac{1}{2}(\alpha - *\alpha), \qquad *\alpha^\pm = \pm\alpha^\pm.$$

Obie podwiązki Λ^2_+ i Λ^2_- mają rangę trzy. Na przykład w dodatniej ortonormalnej kobazie $e^{12} + e^{34}$ jest samodualna, a $e^{12} - e^{34}$ jest antysamodualna. Jest to algebraiczna podstawa późniejszych zagadnień czterowymiarowych. Dla M^4 przez $\mathrm{sign}(M)$ oznaczamy sygnaturę formy przecięcia $Q_M \otimes \mathbb{R}$ z Rozdziału 21: liczbę dodatnich minus liczbę ujemnych kwadratów po jej diagonalizacji nad $\mathbb{R}$.

Stwierdzenie 18.4.1 (Harmoniczny rozkład formy przecięcia)**.** *Jeżeli* M^4 *jest spójna, to* $*$ *zachowuje* $\mathcal{H}^2(M,g)$ *i daje rozkład* $\mathcal{H}^2 = \mathcal{H}^2_+ \oplus \mathcal{H}^2_-$*. Rzeczywiste rozszerzenie formy przecięcia z Rozdziału 21 ma na tych przestrzeniach odpowiednio znak dodatni i ujemny. W konsekwencji*

$$\mathrm{sign}(M) = \dim \mathcal{H}^2_+ - \dim \mathcal{H}^2_-. \tag{18.4.1}$$

Dowód. Na 2-formach w wymiarze cztery $\delta = -*\mathrm{d}*$. Jeżeli α jest harmoniczna, to $\mathrm{d}\alpha = \delta\alpha = 0$, więc $\mathrm{d}*\alpha = 0$ oraz $\delta*\alpha = -*\mathrm{d}\alpha = 0$. Zatem $*$ działa na harmonicznych 2-formach, a ponieważ $*^2 = 1$, dzieli je na dwa podane podprzestrzenie. Twierdzenie de Rhama i dualność Poincarégo utożsamiają rozszerzenie całkowitej formy Q_M do $\mathbb{R}$ z parowaniem $([\alpha],[\beta]) \mapsto \int_M \alpha\wedge\beta$ na $H^2_{\mathrm{dR}}(M)$. Wniosek 18.2.4 pozwala liczyć je na harmonicznych przedstawicielach:

$$(Q_M \otimes \mathbb{R})([\alpha],[\beta]) = \int_M \alpha\wedge\beta = \int_M \langle\alpha, *\beta\rangle\,\mathrm{d}\mu_g.$$

Na $\mathcal{H}^2_+$ jest to iloczyn L^2, na $\mathcal{H}^2_-$ jego przeciwieństwo, a składniki różnych znaków są ortogonalne. Rozszerzenie do $\mathbb{R}$ zachowuje sygnaturę formy całkowitej, co daje (18.4.1). □

Przykład 18.4.2 (Dwie sfery)**.** Na $S^2 \times S^2$ z metryką produktową i orientacją produktową niech ω_1, ω_2 będą cofnięciami form objętości czynników. Wtedy $*\omega_1 = \omega_2$ i $*\omega_2 = \omega_1$. Obie formy są zamknięte, a przez te równości także współzamknięte, zatem harmoniczne. Formy $\omega_1 + \omega_2$ i $\omega_1 - \omega_2$ należą odpowiednio do $\mathcal{H}^2_+$ i $\mathcal{H}^2_-$. Ponieważ $b_2(S^2 \times S^2) = 2$, każda z tych przestrzeni ma wymiar jeden i $\operatorname{sign}(S^2 \times S^2) = 0$, zgodnie z obliczeniem formy przecięcia w Rozdziale 21.

18.5 Trzy wzory indeksowe potrzebne dalej

W dalszych rozdziałach potrzebujemy trzech konkretnych wyników: wzoru na sygnaturę w wymiarach cztery i osiem, całkowitości liczby $\widehat{A}$ dla zamkniętej spinowej 8-rozmaitości oraz indeksu operatora deformacji ASD. Udowodnimy je wspólnym rachunkiem jądra cieplnego. Nie dowodzimy tu twierdzenia indeksowego dla dowolnego symbolu eliptycznego. Jedynym przyjętym wejściem analitycznym jest standardowy rachunek spektralny operatorów eliptycznych i oszacowanie gaussowskie jądra cieplnego, użyte jawnie w poniższym dowodzie.

Indeks i superślad cieplny

Jeśli $D : C^\infty(E^+) \to C^\infty(E^-)$ jest operatorem eliptycznym między wiązkami tej samej rangi nad zamkniętą rozmaitością, jego jądro i kojądro są skończenie wymiarowe. Liczbę

$$\operatorname{ind} D = \dim_{\mathbb{C}} \ker D - \dim_{\mathbb{C}} \ker D^*$$

nazywamy *indeksem*; dla wiązek rzeczywistych liczymy wymiary nad $\mathbb{R}$. Skończoność i dyskretność widma niżej używanych operatorów są częścią przyjętego rachunku eliptycznego. Symbol pierwszego rzędu powstaje przez zastąpienie ∂_j przez $i\xi_j$, tak jak przed Stwierdzeniem 18.2.1. W szczególności symbol operatora Diraca jest $i\,c(\xi)$; relacja $c(\xi)^2 = -|\xi|^2$ daje jego odwracalność dla $\xi \neq 0$.

Lemat 18.5.1 (Tożsamość McKeana–Singera)**.** *Niech $D : E^+ \to E^-$ będzie operatorem eliptycznym pierwszego rzędu na zamkniętej rozmaitości, a $K_t^{\pm}$ jądrami cieplnymi odpowiednio D^*D i DD^*. Wtedy dla każdego $t > 0$*

$$\operatorname{ind} D = \operatorname{Tr} e^{-tD^*D} - \operatorname{Tr} e^{-tDD^*} = \int_M \operatorname{str} K_t(x,x)\, d\mu_g(x). \tag{18.5.1}$$

Dowód. Jeśli $D^*Du = \lambda u$ i $\lambda > 0$, to $Du \neq 0$ oraz $DD^*(Du) = \lambda Du$. Odwrotny izomorfizm na przestrzeniach własnych daje $\lambda^{-1}D^*$. Ich wkłady do różnicy śladów znoszą się. Dla $\lambda = 0$ pozostają $\ker D$ i $\ker D^*$. Drugą równość otrzymujemy, pisząc ślad operatora o gładkim jądrze jako całkę jego śladu na przekątnej. Zwarta rozmaitość zapewnia zbieżność śladów dla $t > 0$. □

Przypomnijmy z Rozdziału 4 spinory chiralne $S = S^+ \oplus S^-$. Na rozmaitości spinowej, dla hermitowskiej wiązki W z koneksją, operator

$$D^+_W = c \circ \nabla^{S^+ \otimes W} : \Gamma(S^+ \otimes W) \longrightarrow \Gamma(S^- \otimes W)$$

jest skręconym operatorem Diraca. Na małej kuli takie spinory i tak istnieją; dlatego ten sam rachunek lokalny ma sens również wtedy, gdy globalny operator pochodzi z modułu Clifforda na rozmaitości niespinowej.

Lemat 18.5.2 (Lokalny rachunek jądra cieplnego)**.** *Niech M^{2m} będzie zamkniętą rozmaitością spinową, a W hermitowską wiązką z koneksją. Dla jądra cieplnego operatora Diraca D_W zachodzi punktowo, w normalizacji Cherna–Weila,*

$$\lim_{t\downarrow 0} \operatorname{str} K_t(x,x)\, d\mu_g = \big[\widehat{A}(TM,\nabla^{TM})\ \operatorname{ch}(W,\nabla^W)\big]_{2m}. \tag{18.5.2}$$

To samo lokalne obliczenie stosuje się do globalnego modułu Clifforda, który na kulach ma postać $S\otimes W$, nawet gdy S i W osobno nie sklejają się globalnie.

Dowód. Opisujemy także krok analityczny odpowiedzialny za przejście od lokalnego modelu do granicy. Ustalmy punkt x, normalne współrzędne y i ramy otrzymane przez transport równoległy po promieniach. Metryka ma postać $g_{ij}(y)=\delta_{ij}+O(|y|^2)$. W ramie radialnej forma koneksji wiązki W spełnia

$$A_i(y) = -\tfrac{1}{2} F^W_{ij}(x) y^j + O(|y|^2).$$

Wynika to z warunku $y^i A_i(y)=0$: pochodna wzdłuż promienia daje krzywiznę, a całkowanie jej wartości liniowej daje czynnik $1/2$. Analogiczne rozwinięcie koneksji spinowej ma w symbolach postać $\nabla^S_i = \partial_i - \tfrac{1}{4}\Omega_{ij}(x)y^j + O(|y|^2)$, gdzie $\Omega_{ij}=\tfrac{1}{2}\sum_{a,b} R_{ijab} e^a\wedge e^b$.

Wzór Weitzenböcka dla skręconego Diraca wyraża D_W^2 jako laplasjan koneksji, składnik scal $/4$ i działanie krzywizny W przez dwa mnożenia Clifforda. Można go sprawdzić w ramie normalnej: w kwadracie $\sum_i c(e_i)\nabla_i$ część symetryczna daje laplasjan, a komutatory $[\nabla_i,\nabla_j]$ dają krzywizny. Utożsammy teraz $\operatorname{End}(S_x)$ z $\Lambda^* T^*_x M\otimes\mathbb{C}$ za pomocą symbolu Clifforda. Iloczyn symboli a i b ma część najwyższego stopnia $a\wedge b$; pozostałe części mają stopień niższy co najmniej o dwa.

Podstawmy $y=\varepsilon z$, $t=\varepsilon^2 s$ i nadajmy formie stopnia r wagę ε^{-r}. Dokładniej, na jednomianie $z^\alpha a_r$ operator $\mathcal{T}_\varepsilon$ mnoży przez $\varepsilon^{|\alpha|-r}$, a $H_\varepsilon=\varepsilon^2\mathcal{T}_\varepsilon D_W^2 \mathcal{T}_\varepsilon^{-1}$. W tym *skalowaniu Getzlera* działanie generatora Clifforda na symbolu a ma postać $c_\varepsilon(v)a = v\wedge a - \varepsilon^2 \iota_v a$. Kontrakcje znikają w granicy, a krzywizny zostają. Przeskalowany kwadrat Diraca zbiega na każdym zbiorze zwartym współczynnik po współczynniku do operatora oscylatora

$$H_0 = -\sum_{i=1}^{2m} \left(\partial_{z_i} - \tfrac{1}{4}\sum_j \Omega_{ij} z^j\right)^2 - F.$$

Tutaj $\Omega=(\Omega_{ij})$ jest macierzą krzywizny stycznej o wartościach w parzystych formach, a F oznacza działanie krzywizny skręcenia po przejściu do symboli; znak przy F odpowiada zapisowi e^{-sH_0}. Wyrazy zawierające pochodne krzywizny lub wyższe potęgi y mają dodatnią potęgę ε i znikają. Jądro K^ε_s jest otrzymane z $K_{\varepsilon^2 s}$ przez tę samą zmianę zmiennych oraz czynnik objętości ε^{2m}. Po wybraniu składowej symbolu stopnia $2m$ oba te czynniki się znoszą.

Wzór Mehlera dla jednowymiarowego oscylatora, zastosowany po formalnym rozszczepieniu antysymetrycznej macierzy Ω na bloki, daje na przekątnej w $z=0$

$$K^0_s(0,0) = (4\pi s)^{-m} \det{}^{1/2}\left(\frac{s\Omega/2}{\sinh(s\Omega/2)}\right) e^{sF}. \tag{18.5.3}$$

Rzeczywiście, dla $-\partial_z^2 + a^2 z^2$ jądro ma postać

$$\left(\frac{a}{2\pi\sinh(2as)}\right)^{1/2} \exp\left[-\frac{a\big((z^2+w^2)\cosh(2as)-2zw\big)}{2\sinh(2as)}\right].$$

Bezpośrednie różniczkowanie sprawdza równanie ciepła, a granica $s\downarrow 0$ jest deltą. Rozłożenie macierzy na bloki oraz formalne podstawienie za a jej wartości własnych daje wyznacznik w (18.5.3). Wszystkie argumenty funkcji hiperbolicznych są tu formalnymi parzystymi formami; szereg urywa się w stopniu $2m$. Każdy blok daje czynnik $(u/2)/\sinh(u/2)$, więc wyznacznik jest formą $\widehat{A}$.

Pozostaje uzasadnić, że model oblicza granicę *rzeczywistego* jądra. Po lokalnym przedłużeniu współczynników poza kulę różnica przeskalowanych operatorów ma współczynniki $O(\varepsilon)$, pomnożone przez ustalone wielomiany w z. Tożsamość Duhamela

$$e^{-sH_\varepsilon} - e^{-sH_0} = -\int_0^s e^{-(s-u)H_\varepsilon}(H_\varepsilon - H_0)e^{-uH_0}\,du$$

i standardowe oszacowania gaussowskie jądra cieplnego oraz jego pochodnych dają dla każdego $\delta > 0$ oszacowanie

$$|K_s^\varepsilon(z,0) - K_s^0(z,0)| \le C_\delta \varepsilon s^{-m+1-\delta} e^{-a|z|^2/s} \quad (0 < s \le 1).$$

W szczególności na przekątnej przy $s = 1$ prawa strona ma normę $O(\varepsilon)$. Właśnie te oszacowania, a nie gotowa formuła indeksowa, są przyjętym wejściem analitycznym. Stosujemy je do jednostajnie eliptycznych operatorów drugiego rzędu na $\mathbb{R}^{2m}$ z jednostajnie ograniczonymi g, g^{-1}, wyrazem pierwszego rzędu ograniczonym przez $C(1+|z|)$ i wyrazem zerowym ograniczonym przez $C(1+|z|)^2$; taką rodzinę dają H_ε po lokalnym wycięciu. Szczegółowy dowód oszacowania dla współczynników rosnących liniowo i kwadratowo podaje Getzler, dodatek A; lokalne wycięcie nie zmienia granicy, bo wkład dróg opuszczających kulę maleje wykładniczo jak $e^{-c/t}$.

Superślad spinorowy usuwa wszystkie symbole oprócz składowej najwyższego stopnia: $\operatorname{str}_S(a) = (2/i)^m \langle [a]_{2m}, \operatorname{vol}_x \rangle$ w dodatniej orientacji. Widać to na bazowych iloczynach generatorów Clifforda: dla mniej niż $2m$ generatorów odpowiedni ślad jest zerowy, a iloczyn wszystkich jest skalarną wielokrotnością chiralii. Po zastosowaniu tej reguły do (18.5.3) czynnik $(4\pi)^{-m}(2/i)^m = (2\pi i)^{-m}$ wprowadza normalizację krzywizn $R/(2\pi i)$ i $F^W/(2\pi i)$. Pozostaje dokładnie składowa najwyższego stopnia formy po prawej stronie (18.5.2). □

Łącząc Lemat 18.5.1 z Lematem 18.5.2 i przechodząc z granicą pod całką na zwartej M, otrzymujemy dla skręconego Diraca

$$\operatorname{ind}_{\mathbb{C}} D_W^+ = \langle \widehat{A}(TM)\operatorname{ch}(W), [M] \rangle. \tag{18.5.4}$$

Dowód tej równości użył lokalnego modelu i rachunku Mehlera; nie odwoływał się do ogólnego twierdzenia o indeksie dowolnego symbolu.

Sygnatura i indeks Diraca w wymiarze osiem

Twierdzenie 18.5.3 (Potrzebne postacie wzoru na sygnaturę)**.** *Dla zamkniętej zorientowanej gładkiej 4-rozmaitości X oraz 8-rozmaitości Y zachodzą odpowiednio*

$$\operatorname{sign}(X) = \frac{1}{3}\langle p_1(TX), [X] \rangle, \qquad \operatorname{sign}(Y) = \frac{1}{45}\langle 7p_2(TY) - p_1(TY)^2, [Y] \rangle. \tag{18.5.5}$$

Dowód. Na zespolonych formach parzystowymiarowej rozmaitości działa $d + \delta$. W wymiarze $4k$ nadajmy im gradację

$$\tau|_{\Omega^p} = i^{\,2k + p(p-1)} * .$$

Z relacji dla gwiazdy wynika $\tau^2 = 1$ i $\tau(d+\delta) = -(d+\delta)\tau$. Indeks części z dodatniej do ujemnej podprzestrzeni τ jest, dzięki Lematowi 18.5.1, śladem τ na harmonicznych formach. Gwiazda paruje stopnie p i $4k - p$, więc ich ślady poza środkiem się znoszą. Na stopniu $2k$ mamy $\tau = *$. Wzór (18.4.1) oraz jego ten sam dowód w wymiarze $4k$ dają indeks równy $\operatorname{sign}(M)$.

Lokalnie $\Lambda^* T^*M \otimes \mathbb{C} \cong S \otimes S^*$; lewy czynnik jest modułem Clifforda, a $d+\delta$ ma symbol Diraca skręconego przez całe S^*. Gradacja τ jest chiralią lewego czynnika. Na rozmaitości niespinowej

oba spinorowe czynniki osobno mogą nie istnieć, lecz ich iloczyn jest globalną wiązką form. Stosujemy więc lokalny rachunek z Lematu 18.5.2.

Niech $x_1, \dots, x_{2k}$ będą formalnymi pierwiastkami Pontriagina, czyli $p(TM) = \prod_j (1+x_j^2)$. Wtedy

$$\widehat{A}(TM) = \prod_j \frac{x_j/2}{\sinh(x_j/2)}, \qquad \mathrm{ch}(S^*) = \prod_j 2\cosh(x_j/2).$$

Ich iloczyn to $2^{2k}\prod_j((x_j/2)/\tanh(x_j/2))$. Składowa stopnia $4k$ jest jednorodna stopnia $2k$ w zmiennych x_j; czynnik 2^{2k} znosi podstawienie $x_j \mapsto x_j/2$. Otrzymujemy

$$\mathrm{sign}(M^{4k}) = \left\langle \left[\prod_j \frac{x_j}{\tanh x_j} \right]_{4k}, [M] \right\rangle.$$

Rozwinięcie $x/\tanh x = 1 + x^2/3 - x^4/45 + \cdots$ daje w stopniu cztery $p_1/3$. W stopniu osiem otrzymujemy

$$\frac{1}{9}\sum_{a<b} x_a^2 x_b^2 - \frac{1}{45}\sum_a x_a^4 = \frac{7p_2 - p_1^2}{45},$$

bo $\sum_a x_a^4 = p_1^2 - 2p_2$. To dowodzi obu wzorów. □

Twierdzenie 18.5.4 (Całkowitość potrzebnej liczby $\widehat{A}$)**.** *Jeśli Y^8 jest zamkniętą spinową rozmaitością, to*

$$\widehat{A}(Y) := \frac{7\langle p_1(TY)^2, [Y]\rangle - 4\langle p_2(TY), [Y]\rangle}{5760} = \mathrm{ind}_{\mathbb{C}}\, D_Y^+ \in \mathbb{Z}. \tag{18.5.6}$$

W konsekwencji

$$\langle p_1(TY)^2, [Y]\rangle - 4\,\mathrm{sign}(Y) = 896\,\widehat{A}(Y). \tag{18.5.7}$$

Dowód. W (18.5.4) bierzemy trywialną linię W. Dla formalnych pierwiastków Pontriagina

$$\frac{x/2}{\sinh(x/2)} = 1 - \frac{x^2}{24} + \frac{7x^4}{5760} + O(x^6).$$

Zatem składowa stopnia osiem iloczynu czterech takich czynników wynosi

$$\frac{7}{5760}\sum_j x_j^4 + \frac{1}{576}\sum_{i<j} x_i^2 x_j^2 = \frac{7p_1^2 - 4p_2}{5760}.$$

Lewa strona (18.5.6) jest indeksem, więc jest całkowita. Eliminując p_2 między (18.5.5) i (18.5.6), dostajemy $896\widehat{A} = p_1^2 - 4\,\mathrm{sign}$. □

Indeks operatora deformacji ASD

Twierdzenie 18.5.5 (Indeks deformacji ASD)**.** *Niech X^4 będzie spójną, zamkniętą, zorientowaną gładką rozmaitością, $P \to X$ wiązką $\mathrm{SU}(2)$, a A połączeniem na P. Dla operatora*

$$D_A = d_A^* \oplus d_A^+ : \Omega^1(X; \mathrm{ad}\, P) \longrightarrow \Omega^0(X; \mathrm{ad}\, P) \oplus \Omega^{2,+}(X; \mathrm{ad}\, P)$$

oraz $k = \langle c_2(P), [X]\rangle$ mamy

$$\mathrm{ind}_{\mathbb{R}}\, D_A = -2\langle p_1(\mathrm{ad}\, P), [X]\rangle - \tfrac{3}{2}(\chi(X) + \mathrm{sign}(X)) = 8k - 3(1 - b_1(X) + b_2^+(X)). \tag{18.5.8}$$

Dowód. Symbol $d_A^* \oplus \sqrt{2}\, d_A^+$ jest izomorfizmem dla $\xi \neq 0$: część równoległą do ξ wykrywa kontrakcja d_A^*, a na części prostopadłej $\sqrt{2}\,\pi_+(\xi \wedge -)$ zachowuje normę. Skalowanie drugiej składowej celu przez $\sqrt{2}$ nie zmienia jądra ani kojądra, a więc indeksu. Ten znormalizowany symbol jest symbolem Diraca.

Na kuli z lokalnym podniesieniem spinowym istnieją identyfikacje

$$(\Lambda^1_{\mathbb{C}},\ \Lambda^0_{\mathbb{C}} \oplus \Lambda^{2,+}_{\mathbb{C}}) \cong (S^- \otimes S^+,\ S^+ \otimes S^+).$$

W drugim czynniku $S^+ \otimes S^+ \cong \Lambda^0_{\mathbb{C}} \oplus \Lambda^{2,+}_{\mathbb{C}}$: część antysymetryczna jest linią skalarną, a symetryczna ma wymiar trzy. Stąd symbol D_A jest symbolem D^- skręconego przez $S^+ \otimes (\operatorname{ad} P)_{\mathbb{C}}$. Składniki niższego rzędu są zwartymi zaburzeniami między przestrzeniami Sobolewa $H^1 \to L^2$ na zwartej rozmaitości, więc nie zmieniają indeksu Fredholma. Kompleksyfikacja zachowuje wymiary jąder i kojąder: $\operatorname{ind}_{\mathbb{R}} D_A = \operatorname{ind}_{\mathbb{C}}(D_A)_{\mathbb{C}}$. Na niespinowym X osobne $S^{\pm}$ nie sklejają się, ale oba iloczyny $S^- \otimes S^+$ i $S^+ \otimes S^+$ są wiązkami stowarzyszonymi z $\mathrm{SO}(4)$. Można więc użyć tej identyfikacji lokalnie w rachunku cieplnym.

W wymiarze cztery piszemy $p_1(TX) = x_1^2 + x_2^2$ i $e(TX) = x_1 x_2$. Wagi S^+ wynoszą $\pm(x_1 + x_2)/2$, stąd

$$\operatorname{ch}(S^+) = 2 + \tfrac{1}{4}(p_1(TX) + 2e(TX)), \qquad \widehat{A}(TX) = 1 - \tfrac{1}{24} p_1(TX)$$

do stopnia cztery. Dla rzeczywistej wiązki rangi trzy $\operatorname{ch}((\operatorname{ad} P)_{\mathbb{C}}) = 3 + p_1(\operatorname{ad} P)$ w tych samych stopniach. Część stopnia cztery ich iloczynu to

$$\Big[\widehat{A}(TX)\operatorname{ch}(S^+)\operatorname{ch}((\operatorname{ad} P)_{\mathbb{C}})\Big]_4 = 2p_1(\operatorname{ad} P) + \tfrac{1}{2}p_1(TX) + \tfrac{3}{2}e(TX).$$

Ponieważ używamy operatora o chiralii ujemnej, indeks jest *przeciwny* do całki tej formy. Twierdzenie 18.5.3 i wzór Cherna–Gaussa–Bonneta z Rozdziału 17 dają $\langle p_1(TX), [X]\rangle = 3\operatorname{sign}(X)$ oraz $\langle e(TX), [X]\rangle = \chi(X)$.

Pozostaje przeliczyć klasę wiązki adjungowanej. Formalne pierwiastki wiązki $E = P \times_{\mathrm{SU}(2)} \mathbb{C}^2$ to $u, -u$, więc $c_2(E) = -u^2$. Kompleksyfikacja $\operatorname{ad} P$ ma wagi $2u, 0, -2u$, skąd

$$p_1(\operatorname{ad} P) = -c_2((\operatorname{ad} P)_{\mathbb{C}}) = 4u^2 = -4c_2(P).$$

Otrzymujemy pierwszy i następnie drugi wzór w (18.5.8), bo z dualności Poincarégo $\chi + \operatorname{sign} = 2(1 - b_1 + b_2^+)$. □

Wzór (18.5.8) liczy *wymiar oczekiwany*. Gładkość przestrzeni moduli wymaga osobnej regularności $H^2_A = 0$, której sam indeks nie zapewnia. Konstrukcję moduli i te wejścia omawia Rozdział 37.

Źródła dowodu indeksowego: E. Getzler, *A Short Proof of the Local Atiyah–Singer Index Theorem* (1986), M. Atiyah, R. Bott i V. K. Patodi, *On the Heat Equation and the Index Theorem* (1973). Identyfikacja symbolu deformacji ma źródło w M. Atiyah, N. Hitchin i I. Singer, *Self-duality in Four-dimensional Riemannian Geometry* (1978); powyżej przeliczono ją w konwencji ASD i $p_1 = -4c_2$ przyjętej w tym skrypcie.

Dalsza lektura: K. Kodaira, *Harmonic Fields in Riemannian Manifolds (Generalized Potential Theory)* (1949), S. Bochner, *Vector Fields and Ricci Curvature* (1946).

Cześć III

Topologia różniczkowa, kobordyzmy i chirurgia

Rozdział 19

Twierdzenie Sarda i transwersalność

W Rozdziale 1 poznaliśmy przeciwobrazy wartości regularnych, a w Rozdziale 13 geodezyjne i ich wariacje. Tutaj odpowiemy na dwa pytania: *czy można znaleźć wartości regularne* i *czy dwa obiekty można ustawić w położeniu ogólnym?* Twierdzenie Sarda odpowiada na pierwsze, a transwersalność precyzuje drugie. Będą one potrzebne do późniejszego badania punktów krytycznych, przecięć rozmaitości stabilnych i niestabilnych, włożeń oraz zabiegów na rozmaitościach. Nazwy z przyszłej teorii Morse'a i Smale'a pojawią się na końcu jako zastosowanie aparatu; ich właściwa teoria będzie osobnym rozdziałem.

O ile nie zaznaczymy inaczej, rozmaitości i podrozmaitości są gładkie i bez brzegu, Hausdorffa i drugoprzeliczalne. Podrozmaitość rozumiemy, zgodnie z Rozdziałem 1, z topologią podprzestrzeni i mapami plasterkowymi (ang. *embedded submanifold*); nie zakładamy jej domkniętości, chyba że jest to wyraźnie powiedziane. Przypadek dziedziny z brzegiem omówimy osobno.

19.1 Wartości krytyczne i twierdzenie Sarda

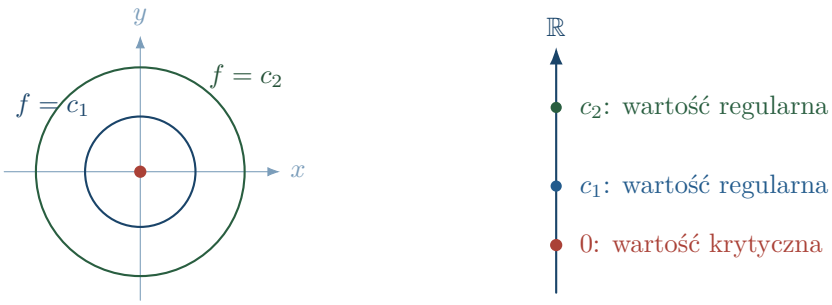
Przypomnijmy Definicję wartości regularnej z Rozdziału 1: $y \in N$ jest regularna dla $f : M \to N$, gdy $\mathrm{d}f_x : T_xM \to T_yN$ jest surjekcją dla *każdego* $x \in f^{-1}(y)$. Jeżeli $f^{-1}(y) = \varnothing$, warunek jest spełniony. Przeciwna sytuacja wymaga rozróżnienia punktu dziedziny od jego obrazu.

Definicja 19.1.1 (Punkt i wartość krytyczna)**.** Niech $f : M^m \to N^n$ będzie gładkie. Punkt $x \in M$ jest *krytyczny*, gdy $\operatorname{rank} \mathrm{d}f_x < n$; jego obraz $f(x)$ nazywamy *wartością krytyczną*. Zbiór punktów krytycznych oznaczamy przez $C(f)$, a zbiór wartości krytycznych przez $f(C(f))$. Jeśli $n = 1$, punkt krytyczny funkcji $f : M \to \mathbb{R}$ spełnia $\mathrm{d}f_x = 0$.

Przykładowo $f(x, y) = x^2 + y^2$ ma jedyny punkt krytyczny $(0, 0)$ i jedyną wartość krytyczną 0. Poziomice $f^{-1}(c)$ dla $c > 0$ są okręgami, poziomica $c = 0$ jest pojedynczym punktem, a dla $c < 0$ przeciwobraz jest pusty. Pusty przeciwobraz też odpowiada wartości regularnej; nie należy utożsamiać „regularna" z „poziomica niepusta".

Definicja 19.1.2 (Zbiór miary zero na rozmaitości)**.** Podzbiór $A \subset \mathbb{R}^n$ ma *miarę zero*, jeśli dla każdego $\varepsilon > 0$ można pokryć go przeliczalnie wieloma kostkami, których suma n-wymiarowych objętości jest mniejsza niż ε. Zbiór $B \subset N^n$ ma miarę zero, jeśli dla każdej mapy (V, ψ) rozmaitości N zbiór $\psi(B \cap V)$ ma miarę zero w $\mathbb{R}^n$.

Ta definicja nie zależy od mapy. Istotnie, przejście między dwiema mapami jest gładkim dyfeomorfizmem. Na każdej zwartej kostce zawartej w dziedzinie przejścia pochodna jest ograniczona, więc twierdzenie o wartości średniej daje tam stałą Lipschitza L. Jeśli mała kostka pokrywająca zbiór zerowy ma bok r, obraz jej przecięcia z ustaloną zwartą kostką mieści się w



Rysunek 19.1: Dla $f(x,y) = x^2+y^2$ punkt krytyczny leży w dziedzinie, a jego wartość krytyczna na osi wyników. Poziomice dodatnie są gładkimi okręgami. Schemat rozróżnia oba pojęcia.

kostce o boku $2L\sqrt{n}\,r$. Suma objętości rośnie zatem najwyżej o stały czynnik. Pokrycia o dowolnie małej sumie objętości pokazują, że obraz zbioru miary zero znów ma miarę zero. Dziedzinę przejścia można pokryć przeliczalnie wieloma zwartymi kostkami. Drugi aksjomat przeliczalności zapewnia także przeliczalne pokrycie rozmaitości mapami. Z tego powodu lokalne dowody o mierze zero można sumować po mapach.

Twierdzenie 19.1.3 (Sarda, wersja gładka)**.** *Niech $f : M^m \to N^n$ będzie gładkim odwzorowaniem rozmaitości bez brzegu, $n \geq 1$. Zbiór jego* wartości krytycznych *$f(C(f))$ ma miarę zero w N. W szczególności wartości regularne są gęste w N.*

Dowód. Wyjaśnimy wszystkie kroki dowodu dla C^∞. Wybieramy mapy dziedziny tak małe, aby ich obrazy przez f mieściły się w mapach przeciwdziedziny. Wystarczy więc rozważyć $f : U \subset \mathbb{R}^m \to \mathbb{R}^n$, z otwartym U. Zbiory $C(f) \cap K$ dla zwartych kostek $K \Subset U$ są zwarte: warunek $\operatorname{rank} \mathrm{d}f < n$ oznacza znikanie wszystkich minorów rzędu n (jeśli $m < n$, zachodzi automatycznie). Ich obrazy są więc zwarte, a $f(C(f))$ jest lokalnie przeliczalną sumą zbiorów zwartych. Wolno zastosować do nich twierdzenie Fubiniego: jeżeli każda sekcja takiego mierzalnego zbioru przez hiperpowierzchnię $\{y_1 = t\}$ ma $(n-1)$-wymiarową miarę zero, to cały zbiór ma n-wymiarową miarę zero.

Krok 1: źródło mniejszego wymiaru. Jeśli $m < n$, na zwartej kostce $Q \Subset U$ odwzorowanie f jest lipschitzowskie. Podzielmy Q na k^m kostek o boku a/k. Obraz każdej mieści się w kostce o boku Ca/k, zatem suma objętości pokrycia $f(Q)$ jest co najwyżej $C'k^m k^{-n} = C'k^{m-n} \to 0$. Stąd cały obraz $f(U)$, a więc tym bardziej zbiór wartości krytycznych, ma miarę zero. To daje również początek indukcji po m; dla $m = 0$ obraz drugoprzeliczalnej rozmaitości zerowymiarowej jest przeliczalny.

Krok 2: punkty krytyczne dodatniego rzędu. Załóżmy twierdzenie dla wszystkich odwzorowań o dziedzinie wymiaru $m-1$ i niech $x \in C(f)$, ale $\operatorname{rank} \mathrm{d}f_x > 0$. Po przestawieniu współrzędnych $\partial f_1/\partial x_1(x) \neq 0$. Twierdzenie o funkcji odwrotnej zastosowane do

$$\Phi(x_1, \ldots, x_m) = (f_1(x), x_2, \ldots, x_m)$$

daje dyfeomorfizm pewnego otwartego otoczenia U_{lok} na jego obraz. W nowych współrzędnych przepis f ma postać $g(t,u) = (t, h(t,u))$, gdzie $u \in \mathbb{R}^{m-1}$. Jeśli $n = 1$, ta postać jest submersją, więc rozważany punkt nie byłby krytyczny. Przy $n \geq 2$ macierz pochodnej ma bloki

$$\mathrm{d}g_{(t,u)} = \begin{pmatrix} 1 & 0 \\ * & \mathrm{d}_u h(t,u) \end{pmatrix}, \qquad \operatorname{rank} \mathrm{d}g = 1 + \operatorname{rank} \mathrm{d}h_t(u), \quad h_t(u) := h(t,u).$$

Zatem w sekcji $\{y_1 = t\}$ obrazy punktów krytycznych g pochodzą z wartości krytycznych $h_t : U_t \to \mathbb{R}^{n-1}$, gdzie $U_t = \{u : (t,u) \in \Phi(U_{\mathrm{lok}})\}$ jest otwartym przekrojem nowej dziedziny. Indukcja mówi, że taka sekcja ma miarę zero. Obraz lokalnego zbioru punktów krytycznych jest

mierzalny (po wyczerpaniu otwartego otoczenia kostkami jest sumą obrazów zwartych zbiorów). Fubini daje miarę zero całego obrazu. Przeliczalne lokalne otoczenia pokrywają wszystkie punkty krytyczne dodatniego rzędu.

Krok 3: punkty o znikających pochodnych. Niech $D_k \subset U$ oznacza zbiór punktów, w których znikają wszystkie pochodne cząstkowe składowych f rzędów $1, \dots, k$. Mamy $D_1 \subset C(f)$ oraz $D_{k+1} \subset D_k$. Jeżeli $x \in D_k \setminus D_{k+1}$, to pewna pochodna rzędu $k+1$ jest niezerowa. Wybierzmy pochodną rzędu k jednej składowej, oznaczoną przez w, której pewna pochodna pierwsza nie znika w x. Ponieważ $w = 0$ na D_k, twierdzenie o funkcji uwikłanej mówi, że $H = \{w = 0\}$ jest w otoczeniu x gładką hiperpowierzchnią zawierającą D_k. Każdy punkt $D_k \cap H$ jest krytyczny dla $f|_H : H^{m-1} \to \mathbb{R}^n$: już $\mathrm{d}f = 0$ na D_k. Na mocy indukcji jego obrazy tworzą zbiór miary zero. Przeliczalne pokrycie punktów $D_k \setminus D_{k+1}$ daje tę samą tezę dla całej tej warstwy.

Krok 4: punkty płaskie do wysokiego rzędu. Wybierzmy $k \geq 1$ tak duże, że $n(k+1) > m$. Na zwartej kostce $Q \Subset U$ pochodne rzędu $k+1$ są ograniczone. Wzór Taylora wokół dowolnego $x \in D_k \cap Q$ ma zerowe składniki rzędów $1, \dots, k$, więc dla y w tej samej małej kostce

$$|f(y) - f(x)| \leq C|y - x|^{k+1}.$$

Podzielmy Q na j^m kostek o boku a/j. W każdej, która przecina D_k, wybierzmy takie x. Obraz jej punktów należących do D_k mieści się w kuli promienia $C' j^{-(k+1)}$. Pokrywając każdą kulę kostką, dostajemy sumę objętości co najwyżej $C'' j^{m-n(k+1)} \to 0$. Zatem $f(D_k \cap Q)$ ma miarę zero; liczymy po kostkach wyczerpujących U.

Na koniec rozkładamy zbiór krytyczny na $C(f) \setminus D_1$, warstwy $D_i \setminus D_{i+1}$ dla $1 \leq i < k$ oraz D_k. Ich obrazy mają miarę zero odpowiednio z Kroków 2, 3 i 4. Przeliczalne pokrycia mapami przenoszą wynik na M i N. Zbiór miary zero nie zawiera niepustego otwartego podzbioru N, więc wartości regularne są gęste. □

Uwaga 19.1.4 (Zakres twierdzenia). Sard mówi o *obrazach* punktów krytycznych, nie o tym, że punktów krytycznych jest mało. Funkcja stała ma wszystkie punkty krytyczne, ale tylko jedną wartość krytyczną. Dla odwzorowań klasy C^r istnieje również wersja przy założeniu całkowitoliczbowym $r > \max\{m - n, 0\}$; powyższy dowód dotyczy wersji gładkiej, z której korzystamy dalej. Jeśli dziedzina ma brzeg, stosujemy wersję bez brzegu oddzielnie do $f|_{\operatorname{int} M}$ i $f|_{\partial M}$. Suma ich zbiorów wartości krytycznych ma miarę zero. Poza nią oba odwzorowania są regularne na odpowiednich przeciwobrazach; na brzegu surjektywność $\mathrm{d}f|_{T\partial M}$ pociąga także surjektywność $\mathrm{d}f$ na całym TM. Późniejsze twierdzenie o brzegu wyjaśni, dlaczego potrzebny jest ten silniejszy warunek.

Wniosek 19.1.5 (Typowa poziomica)**.** *Dla prawie każdego $y \in N^n$ zbiór $f^{-1}(y)$ jest pusty albo gładką podrozmaitością wymiaru $m - n$, a w każdym $x \in f^{-1}(y)$ $T_x f^{-1}(y) = \ker \mathrm{d}f_x$.*

Dowód. Poza zbiorem wartości krytycznych z Twierdzenia 19.1.3 wartość y jest regularna. Stosujemy Twierdzenie 1.12.8; przypadek pustego przeciwobrazu traktujemy osobno. □

19.2 Transwersalność: precyzyjny sens przecięcia

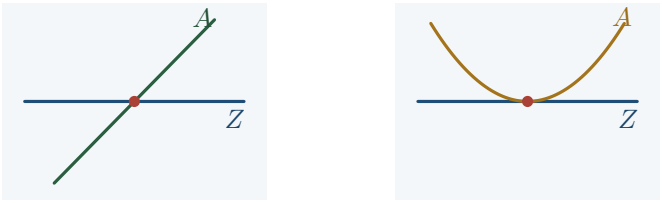
Wartość regularna to szczególny przypadek położenia ogólnego. Zamiast punktu $y \in N$ możemy badać trafienie odwzorowania w całą podrozmaitość $Z \subset N$.

Definicja 19.2.1 (Odwzorowanie transwersalne)**.** Niech $f : M \to N$ będzie gładkie, a $Z \subset N$ podrozmaitością zanurzoną w sensie Rozdziału 1. Piszemy $f \pitchfork Z$, gdy dla każdego $x \in f^{-1}(Z)$ zachodzi

$$\mathrm{d}f_x(T_x M) + T_{f(x)} Z = T_{f(x)} N. \tag{19.2.1}$$

Jeśli $f(M) \cap Z = \varnothing$, warunek jest spełniony w sposób pusty. Dwie podrozmaitości $A, B \subset N$ przecinają się *transwersalnie*, $A \pitchfork B$, jeśli $T_xA + T_xB = T_xN$ przy każdym $x \in A \cap B$.

Suma w (19.2.1) jest sumą *podprzestrzeni*, a nie sumą wektorów o ustalonych długościach. Jeśli $Z = \{y\}$, to $T_yZ = 0$ i otrzymujemy dokładnie warunek, że y jest wartością regularną f. Gdy f jest inkluzją $A \hookrightarrow N$, otrzymujemy definicję transwersalnego przecięcia A z Z.



przecięcie transwersalne styczność: brak transwersalności

Rysunek 19.2: Po lewej dwie proste w płaszczyźnie mają różne kierunki styczne, które razem rozpinają $T_p\mathbb{R}^2$. Po prawej parabola dotyka osi: obie przestrzenie styczne są tą samą prostą.

Twierdzenie 19.2.2 (Przeciwobraz podrozmaitości)**.** *Niech $Z \subset N^n$ będzie podrozmaitością zanurzoną kowymiaru c, a $f : M^m \to N$ niech spełnia $f \pitchfork Z$. Wtedy $f^{-1}(Z)$ jest pusty albo jest podrozmaitością zanurzoną wymiaru $m - c$. W punkcie $x \in f^{-1}(Z)$ zachodzi*

$$T_xf^{-1}(Z) = (\mathrm{d}f_x)^{-1}(T_{f(x)}Z). \tag{19.2.2}$$

Jeśli $m < c$, przeciwobraz jest pusty.

Dowód. Wokół $z = f(x)$ wybierzmy mapę $\psi : V \to \mathbb{R}^{n-c} \times \mathbb{R}^c$, w której $\psi(Z \cap V) = \psi(V) \cap (\mathbb{R}^{n-c} \times \{0\})$. Niech $h = \mathrm{pr}_{\mathbb{R}^c} \circ \psi$. Wtedy lokalnie $Z = h^{-1}(0)$ oraz $\ker \mathrm{d}h_z = T_zZ$. Reguła łańcucha pokazuje, że $\mathrm{d}(h \circ f)_x = \mathrm{d}h_z \circ \mathrm{d}f_x$. Ta różniczka jest surjekcją na $\mathbb{R}^c$ dokładnie wtedy, gdy $\mathrm{d}f_x(T_xM) + \ker \mathrm{d}h_z = T_zN$; jest to (19.2.1). Zatem 0 jest lokalnie wartością regularną $h \circ f$. Twierdzenie 1.12.8 daje podrozmaitość kowymiaru c i

$$\ker \mathrm{d}(h \circ f)_x = \{v : \mathrm{d}f_x v \in \ker \mathrm{d}h_z\},$$

co jest (19.2.2). Jeśli $m < c$, surjekcja $\mathbb{R}^m \to \mathbb{R}^c$ nie istnieje. Nie może więc istnieć punkt przeciwobrazu przy założonej transwersalności. □

Przykład 19.2.3 (Prosta i parabola)**.** W $N = \mathbb{R}^2$ niech $Z = \{(x, 0)\}$. Dla $f(t) = (t, t)$ mamy $f^{-1}(Z) = \{0\}$ oraz $\mathrm{d}f_0(\mathbb{R}) = \mathrm{span}(1, 1)$, który wraz z $T_{(0,0)}Z = \mathrm{span}(1, 0)$ rozpina $\mathbb{R}^2$. Dla $g(t) = (t, t^2)$ przeciwobraz także jest pojedynczym punktem, ale $\mathrm{d}g_0(\mathbb{R}) = T_{(0,0)}Z$: sam fakt, że punktów przecięcia jest skończenie wiele, *nie* oznacza transwersalności. Na Rysunku 19.2 przedstawiono oba przypadki.

Twierdzenie 19.2.4 (Przecięcie i iloczyn włóknisty)**.** *Jeżeli podrozmaitości $A^a, B^b \subset N^n$ spełniają $A \pitchfork B$, to $A \cap B$ jest pusty albo jest podrozmaitością wymiaru $a + b - n$ oraz*

$$T_x(A \cap B) = T_xA \cap T_xB.$$

Ogólniej, dla gładkich $f : M^m \to N^n$ i $g : P^p \to N^n$ załóżmy, że przy każdym $f(x) = g(y) = z$ mamy

$$\mathrm{d}f_x(T_xM) + \mathrm{d}g_y(T_yP) = T_zN. \tag{19.2.3}$$

Wówczas $M \times_N P = \{(x, y) : f(x) = g(y)\}$ jest pusty albo jest podrozmaitością $M \times P$ wymiaru $m + p - n$, a jej przestrzeń styczna składa się z par (u, v) spełniających $\mathrm{d}f_x u = \mathrm{d}g_y v$.

Dowód. Niech $\Delta_N = \{(z,z) : z \in N\}$ będzie diagonalą w $N \times N$. Jej przestrzeń styczna w (z,z) to $\{(w,w) : w \in T_z N\}$. Obliczamy

$$T_{(z,z)}(N \times N)/T_{(z,z)}\Delta_N \cong T_z N, \qquad [(u,v)] \longmapsto u - v.$$

Odwzorowanie $(f,g) : M \times P \to N \times N$ jest transwersalne do diagonali dokładnie wtedy, gdy $(u,v) \mapsto \mathrm{d}f_x u - \mathrm{d}g_y v$ jest surjekcją, czyli gdy zachodzi (19.2.3). Twierdzenie 19.2.2 daje podrozmaitość kowymiaru n. Jej przestrzeń styczna jest jądrem powyższej różnicy, skąd oba wzory. Dla inkluzji $A \hookrightarrow N$ i $B \hookrightarrow N$ iloczyn włóknisty utożsamiamy z $A \cap B$ przez $(z,z) \mapsto z$. Warunek staje się $T_z A + T_z B = T_z N$, a jądro jest przecięciem obu przestrzeni stycznych. □

Uwaga 19.2.5 (Oczekiwany wymiar). Liczba $a+b-n$ to *oczekiwany wymiar* przecięcia. Ujemny wynik wymusza pustkę przy transwersalności. Wynik zero oznacza izolowane punkty przecięcia. Jeśli A jest zwarta, a B domknięta (w szczególności gdy obie są zwarte), przecięcie jest zwarte i dyskretne, więc skończone. Sama dyskretność bez zwartości nie wyklucza nieskończenie wielu punktów. To właśnie przypadek, w którym później można liczyć przecięcia ze znakami, używając orientacji z Sekcji 10.5.

19.3 Brzeg i kontrola miejsca przecięcia

W konstrukcjach topologicznych pojawiają się przestrzenie z brzegiem. Sam warunek $f \pitchfork Z$ we wnętrzu nie gwarantuje poprawnego zachowania przeciwobrazu na brzegu.

Twierdzenie 19.3.1 (Przeciwobraz transwersalny z brzegiem)**.** *Niech M^m będzie rozmaitością z brzegiem, N bez brzegu, $Z \subset N$ podrozmaitością kowymiaru c. Jeżeli zarówno $f : M \to N$, jak i $f|_{\partial M} : \partial M \to N$ są transwersalne do Z, to $W = f^{-1}(Z)$ jest pusty albo jest rozmaitością z brzegiem wymiaru $m - c$ i*

$$\partial W = W \cap \partial M.$$

Dowód. We wnętrzu M stosujemy Twierdzenie 19.2.2. Przy $x \in \partial M \cap W$ wybierzmy współrzędne półprzestrzeni $(r, u_2, \dots, u_m)$, $r \geq 0$, oraz lokalną funkcję definiującą Z, $h : N \to \mathbb{R}^c$ jak w poprzednim dowodzie. Połóżmy $H = h \circ f$. Transwersalność $f|_{\partial M}$ oznacza, że $\mathrm{d}H_x : T_x \partial M \to \mathbb{R}^c$ jest surjekcją. Możemy więc wybrać c kierunków *stycznych do brzegu*, na których współrzędne H tworzą niezależny układ. Po przestawieniu zmiennych u odpowiedni minor $c \times c$ jest odwracalny. Gładkość na półprzestrzeni pozwala przedłużyć H lokalnie przez $r = 0$. Twierdzenie o funkcji odwrotnej dla odwzorowania $(r,u) \mapsto (r, H(r,u), v)$ stosujemy w tym otwartym otoczeniu, a potem ograniczamy do $r \geq 0$. Jego różniczka jest odwracalna właśnie dzięki wybranemu minorowi i zachowaniu pozostałych współrzędnych. Ponieważ r pozostało współrzędną brzegową, zbiór $H = 0$ ma w tych współrzędnych postać $\{(r, 0, v) : r \geq 0\}$. Jego brzeg jest dokładnie $\{r = 0, H = 0\} = W \cap \partial M$. Pozostałe $m - 1 - c$ współrzędne v wraz z r dają wymiar $m - c$. Przy $m < c$ cały przeciwobraz jest pusty; przy $m = c$ nie może spotykać brzegu, ponieważ surjekcja z jego $(m-1)$-wymiarowej przestrzeni stycznej na $\mathbb{R}^c$ nie istnieje. □

Przykład 19.3.2 (Dlaczego warunek na brzegu jest potrzebny)**.** Weźmy górną półpłaszczyznę $M = \{(x,y) \in \mathbb{R}^2 : y \geq 0\}$, $N = \mathbb{R}$ i $Z = \{0\}$. Funkcja $f(x,y) = y$ jest submersją w każdym punkcie M, lecz jej ograniczenie do brzegu jest stale równe zero. Mamy $f^{-1}(0) = \partial M$, czyli prostą *bez* brzegu; równość $\partial f^{-1}(Z) = f^{-1}(Z) \cap \partial M$ byłaby tutaj fałszywa. W praktyce należy sprawdzać oba warunki osobno.

19.4 Transwersalność z parametrem

Nie należy rozumieć „ogólnego położenia” jako założenia o losowości rysunku. Chodzi o precyzyjne twierdzenie: w gładkiej rodzinie dopuszczalnych przesunięć złe parametry tworzą zbiór miary zero.

Twierdzenie 19.4.1 (Transwersalność parametryczna)**.** *Niech M, A, N będą gładkimi rozmaitościami bez brzegu, $Z \subset N$ podrozmaitością zanurzoną, a $F : M \times A \to N$ gładkim odwzorowaniem. Jeżeli $F \pitchfork Z$, to dla prawie każdego $a \in A$ odwzorowanie $F_a(x) = F(x, a)$ spełnia $F_a \pitchfork Z$. W szczególności takie parametry są gęste w A.*

Dowód. Ponieważ $F \pitchfork Z$, $W = F^{-1}(Z)$ jest podrozmaitością $M \times A$ na mocy Twierdzenia 19.2.2. Rozważmy rzutowanie $\pi : W \to A$. W punkcie $(x, a) \in W$, $z = F(x, a)$,

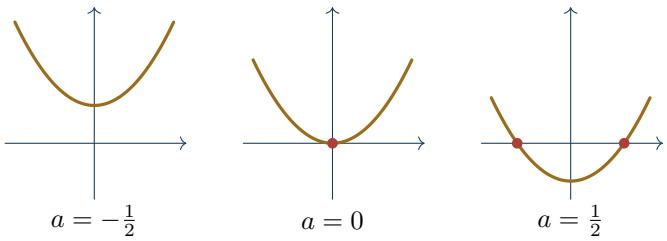
$$T_{(x,a)}W = \{(u, b) : \mathrm{d}_x F_{(x,a)} u + \mathrm{d}_a F_{(x,a)} b \in T_z Z\}.$$

Zatem $\mathrm{d}\pi_{(x,a)}$ jest surjekcją dokładnie wtedy, gdy dla każdego $b \in T_a A$ można dobrać $u \in T_x M$ tak, aby $\mathrm{d}_a F(b) + \mathrm{d}_x F(u) \in T_z Z$. Inaczej mówiąc,

$$\mathrm{d}_a F(T_a A) \subset \mathrm{d}_x F(T_x M) + T_z Z.$$

Łącznie z założeniem $\mathrm{d}_x F(T_x M) + \mathrm{d}_a F(T_a A) + T_z Z = T_z N$ jest to równoważne $\mathrm{d}_x F(T_x M) + T_z Z = T_z N$, czyli transwersalności F_a w punkcie x. Wartość a jest regularna dla π wtedy i tylko wtedy, gdy F_a jest transwersalne do Z we wszystkich punktach przeciwobrazu. Sard zastosowany do $\pi : W \to A$ kończy dowód, jeśli $\dim A \geq 1$. Dla $\dim A = 0$ przestrzeń parametrów jest dyskretna, a $T_a A = 0$. Wtedy $\mathrm{d}F = \mathrm{d}_x F$ na każdej składowej $M \times \{a\}$ i założenie daje tezę dla każdego a, bez odwoływania się do Sarda. □

Przykład 19.4.2 (Rozszczepienie stycznego przecięcia)**.** Niech $M = N = \mathbb{R}$, $Z = \{0\}$ oraz $F(t, a) = t^2 - a$. Pochodna w kierunku parametru wynosi $\partial_a F = -1$, więc cała rodzina $F : \mathbb{R}^2 \to \mathbb{R}$ jest submersją. Dla $a > 0$ odwzorowanie F_a ma dwa regularne zera $t = \pm\sqrt{a}$, bo $F_a'(t) = 2t \neq 0$. Dla $a < 0$ nie ma zer, a $a = 0$ daje styczne, nieregularne zero $t = 0$. Jedyny zły parametr to 0.



Rysunek 19.3: Poziom zero rodziny $F_a(t) = t^2 - a$. Zmiana parametru rozbija styczność w dwa przecięcia transwersalne albo usuwa przecięcie; sam parametr $a = 0$ jest wyjątkowy.

Twierdzenie parametryczne nie mówi jeszcze, że *każde* konkretne odwzorowanie ma dostatecznie bogatą rodzinę perturbacji. Przy zwartej dziedzinie możemy taką rodzinę zbudować bez odwoływania się do twierdzenia Whitneya o zanurzeniach.

Wyjaśnijmy używaną tu topologię przybliżania. Wybierzmy skończenie wiele map x_i w M i y_i w N oraz zwartych zbiorów K_i w dziedzinach x_i tak, by ich wnętrza pokrywały M, a $f(K_i)$ leżały w dziedzinach y_i. Zapewniają to ciągłość f i zwartość M. Dla odwzorowań g bliskich f wymagamy $g(K_i)$ w tych samych mapach i kontrolujemy liczby

$$\max_i \max_{|\alpha| \leq r} \sup_{u \in x_i(K_i)} \left| \partial^\alpha (y_i \circ g \circ x_i^{-1})(u) - \partial^\alpha (y_i \circ f \circ x_i^{-1})(u) \right|.$$

Małość tych liczb określa topologię C^r. Reguła łańcucha i zwartość pokazują, że zmiana skończonego układu map daje tę samą topologię. Topologia C^∞ jest generowana przez te warunki dla wszystkich skończonych r: zbieżność oznacza zbieżność w każdym C^r, a podstawowe otoczenie zadaje tylko skończenie wiele takich ograniczeń. Nie wymagamy jednego oszacowania jednocześnie dla pochodnych wszystkich rzędów.

Twierdzenie 19.4.3 (Przybliżanie odwzorowań transwersalnymi)**.** *Niech M będzie zwartą rozmaitością bez brzegu, N rozmaitością, a $Z \subset N$ podrozmaitością zanurzoną. Każde gładkie $f : M \to N$ można dowolnie blisko przybliżyć w topologii C^∞ gładkim $g : M \to N$ transwersalnym do Z. Można przy tym wybrać gładką homotopię od f do g. Jeśli dodatkowo Z jest domknięta w N, transwersalność jest otwarta w topologii C^1 na gładkich odwzorowaniach z M do N.*

Dowód. Budowa skończonej liczby kierunków perturbacji. Wybierzmy na N dowolną metrykę riemannowską. Przeciągnięta wiązka f^*TN ma nad małymi otoczeniami $U_i \subset M$ gładkie ramy. Ponieważ M jest zwarta, możemy wybrać skończenie wiele mniejszych $V_i \Subset U_i$, które pokrywają M. Dla każdego i wybierzmy funkcję odcinającą ρ_i, równą 1 na V_i i o nośniku w U_i. Pomnóżmy każdy wektor lokalnej ramy $f^*TN|_{U_i}$ przez ρ_i i przedłużmy przez zero. Otrzymujemy skończenie wiele globalnych przekrojów $s_1, \dots, s_k$ wiązki f^*TN takich, że ich wartości rozpinają $T_{f(x)}N$ w każdym x.

Niech $a = (a_1, \dots, a_k)$ przebiega małą kulę w $\mathbb{R}^k$. Definiujemy

$$F(x, a) = \exp^N_{f(x)} \left(\sum_{j=1}^{k} a_j s_j(x) \right).$$

Metryka nie musi być zupełna: wykładnicze odwzorowanie jest określone przy wektorze zero, a zwartość M pozwala wziąć jedną wystarczająco małą kulę parametrów dla wszystkich x. W punkcie $a = 0$ pochodna F względem parametrów przyjmuje na standardowym kierunku j wartość $s_j(x)$, ponieważ $\mathrm{d}(\exp^N_{f(x)})_0 = \mathrm{id}$. Jest więc surjektywna na $T_{f(x)}N$. Surjektywność jest warunkiem otwartym; przez zwartość M pozostaje prawdziwa na $M \times A$ po zmniejszeniu kuli A. Całe odwzorowanie F jest zatem submersją, w szczególności $F \pitchfork Z$. Twierdzenie 19.4.1 dostarcza parametrów a transwersalnych do Z dowolnie blisko zera. Dla $g = F_a$ mamy $F_a \to F_0 = f$ w C^∞: w ustalonych mapach każda pochodna po x zależy ciągle od (x, a), a na skończonym pokryciu zwartych K_i zbieżność przy $a \to 0$ jest jednostajna dla każdego skończonego rzędu. Ścieżka $t \mapsto F_{ta}$ daje gładką homotopię, ponieważ kula A jest wypukła.

Otwartość przy domkniętym Z. Załóżmy, że $f \pitchfork Z$, lecz pewne $f_j \to f$ w C^1 nie są transwersalne. Wybierzmy punkty x_j naruszenia warunku. Po przejściu do podciągu $x_j \to x$ dzięki zwartości M. Ponieważ Z jest domknięta, $f(x) = \lim f_j(x_j)$ należy do Z. W lokalnej mapie spłaszczającej Z transwersalność oznacza, że ustalony minor macierzy pochodnej normalnych współrzędnych jest niezerowy. Dla f jest taki minor w x; ciągłość i zbieżność C^1 dają ten sam niezerowy minor dla f_j w x_j przy dużym j. Otrzymujemy sprzeczność. □

Wniosek 19.4.4 (Perturbacja względna)**.** *Załóżmy dodatkowo w poprzednim twierdzeniu, że Z jest domknięta i $f \pitchfork Z$ na otoczeniu domkniętego $C \subset M$. Wówczas g można wybrać równe f na pewnym otoczeniu C.*

Dowód. Wybierzmy otoczenia $C \subset U_0 \Subset U_1 \Subset U$, gdzie $f \pitchfork Z$ na U. Powtórzmy konstrukcję przekrojów z poprzedniego dowodu tylko nad zwartym zbiorem $M \setminus U_1$, dobierając ich nośniki w $M \setminus \overline{U}_0$. Otrzymana rodzina F_a jest identyczna z f na U_0, a jej pochodna parametryczna rozpina TN na $M \setminus U_1$. Na zwartym $\overline{U}_1 \subset U$ dostatecznie małe perturbacje zachowują transwersalność f. Stosujemy tu dowód otwartości na zwartym podzbiorze, nie twierdzenie o rozmaitości $\overline{U}_1$:

hipotetyczne punkty naruszenia miałyby podciąg z granicą w $\overline{U}_1$, a ten sam argument z niezerowym minorem dawałby sprzeczność. Stąd cała rodzina $F : M \times A \to N$ jest transwersalna do Z. Wybieramy parametr z Twierdzenia 19.4.1 dowolnie blisko zera. Na U_0 wynikowe $g = F_a$ jest dokładnie f. Cała homotopia F_{ta} również pozostaje tam równa f. □

Jeśli M ma brzeg, a rodzina F i jej ograniczenie $F|_{\partial M \times A}$ są transwersalne do Z, można zastosować Sarda do dwóch map bez brzegu: $\pi|_{\operatorname{int} W}$ oraz $\pi|_{\partial W}$, gdzie $W = F^{-1}(Z)$ i $\partial W = W \cap (\partial M \times A)$. Pierwsza kontroluje transwersalność F_a we wnętrzu, druga transwersalność jego ograniczenia do brzegu. Ta ostatnia pociąga też transwersalność F_a na całej przestrzeni stycznej T_xM w punkcie brzegowym. Suma dwóch zbiorów parametrów wyjątkowych nadal ma miarę zero. Dla pozostałych parametrów otrzymujemy oba warunki Twierdzenia 19.3.1.

19.5 Zera przekrojów i punkty krytyczne funkcji

Nie każdy problem ma postać przecięcia dwóch podzbiorów jednej przestrzeni. Często szukamy zer pola wektorowego, 1-formy albo innego przekroju wiązki. Wtedy transwersalność działa względem *przekroju zerowego*.

Twierdzenie 19.5.1 (Regularne zera przekroju)**.** *Niech $E \to M^m$ będzie wiązką wektorową rzędu r, a $s : M \to E$ gładkim przekrojem. W lokalnej trywializacji $s(x) = (x, \sigma(x))$. W punkcie $s(x) = 0$ pochodna $\mathrm{D}_x s := \mathrm{d}\sigma_x : T_xM \to E_x$ nie zależy od wyboru trywializacji po naturalnym utożsamieniu włókien. Jeżeli $\mathrm{D}_x s$ jest surjektywna przy każdym zerze, to zbiór zer $s^{-1}(0_E)$ jest pusty albo jest podrozmaitością kowymiaru r, a $T_x s^{-1}(0_E) = \ker \mathrm{D}_x s$.*

Dowód. W trywializacji przekrój zerowy ma postać $\{(x, 0)\}$, a kierunki normalne do niego odpowiadają współrzędnym włókna. Różniczka $s(x) = (x, \sigma(x))$ ma postać $v \mapsto (v, \mathrm{d}\sigma_x v)$. Warunek $s \pitchfork 0_E$ jest więc dokładnie surjektywnością $\mathrm{d}\sigma_x$. Twierdzenie 19.2.2 daje wymiar i przestrzeń styczną. Przy zmianie trywializacji $\widetilde{\sigma}(y) = A(y)\sigma(y)$, gdzie $A(y)$ jest odwracalną macierzą. W punkcie z $\sigma(x) = 0$ reguła iloczynu daje $\mathrm{d}\widetilde{\sigma}_x = A(x)\mathrm{d}\sigma_x$: wyraz $(\mathrm{d}A_x)\sigma(x)$ znika. Surjektywność i jądro nie zależą więc od trywializacji. W sposób wewnętrzny w zerze $s(x)$ mamy kanoniczny rozkład $T_{0_x}E \cong T_xM \oplus E_x$: pierwsza część jest styczna do przekroju zerowego, a druga jest pionowa. Pionowa składowa $\mathrm{d}s_x$ to właśnie $\mathrm{D}_x s$. Dla $r > m$ surjekcja jest niemożliwa, więc przekrój transwersalny nie ma zer. □

Przykład 19.5.2 (Zera pola na płaszczyźnie)**.** Pole $X(x, y) = x\,\partial_x + y\,\partial_y$ ma jedno zero, a jego pochodna pionowa w zerze jest macierzą jednostkową: zero jest transwersalne. Pole $Y(x, y) = x^2\partial_x + y\,\partial_y$ też ma jedno zero, lecz macierz $\mathrm{D}_0 Y = \operatorname{diag}(0, 1)$ nie jest surjektywna. Sama izolacja zera nie wystarcza do transwersalności.

Dla funkcji $f : M \to \mathbb{R}$ przekrojem, który nas interesuje, jest $df : M \to T^*M$. To pozwala wyjaśnić, skąd w przyszłej teorii Morse'a pojawia się hesjan.

Definicja 19.5.3 (Hesjan i niezdegenerowany punkt krytyczny)**.** Jeśli $\mathrm{d}f_p = 0$, to w dowolnej mapie $(x^1, \dots, x^m)$ wokół p definiujemy

$$\operatorname{Hess}_p f(v, w) = \sum_{i,j} \frac{\partial^2 f}{\partial x^i \partial x^j}(p) v^i w^j.$$

Punkt p nazywamy *niezdegenerowanym*, gdy ta forma dwuliniowa ma nieosobliwą macierz. Funkcja, której wszystkie punkty krytyczne są niezdegenerowane, nazywa się *funkcją Morse'a*.

Hesjan w punkcie krytycznym jest niezależny od mapy. Druga pochodna złożenia $f \circ \varphi^{-1}$ z przejściem współrzędnych ma wyraz z drugą pochodną f przeniesiony przez jakobian oraz wyraz z pierwszą pochodną f pomnożoną przez drugie pochodne przejścia. Ten ostatni wyraz znika właśnie dlatego, że $\mathrm{d}f_p = 0$. Dokładniej, jeśli $x = x(y)$ jest zmianą map, to w punkcie krytycznym

$$\frac{\partial^2 f}{\partial y^a \partial y^b}(p) = \sum_{i,j} \frac{\partial x^i}{\partial y^a}(p) \frac{\partial x^j}{\partial y^b}(p) \frac{\partial^2 f}{\partial x^i \partial x^j}(p).$$

Jest to prawo transformacji formy dwuliniowej, $H_y = J^{\mathsf{T}} H_x J$, więc niezdegenerowanie jest niezależne od mapy. Po wyborze dowolnej koneksji Leviego-Civity wcześniejszy hesjan ma współrzędne $(\nabla df)_{ij} = \partial_i \partial_j f - \Gamma^k_{ij} \partial_k f$; w punkcie krytycznym daje tę samą formę. Nie wymaga ona zatem wyboru metryki w tym punkcie. W mapie wiązki kostycznej przekrój df ma współrzędne $(x, (\partial_1 f, \ldots, \partial_m f))$. Jego pochodna pionowa w punkcie krytycznym jest więc macierzą $(\partial_i \partial_j f)(p)$. Dostajemy równoważność

$$df \pitchfork 0_{T^*M} \quad \Longleftrightarrow \quad \text{każdy punkt krytyczny } f \text{ jest niezdegenerowany.} \tag{19.5.1}$$

Twierdzenie 19.5.4 (Istnienie i typowość funkcji Morse'a)**.** *Na każdej zwartej rozmaitości gładkiej bez brzegu funkcje Morse'a są gęste wśród funkcji gładkich w topologii C^∞ i tworzą zbiór otwarty w topologii C^2. Każda taka funkcja ma skończenie wiele punktów krytycznych. Można dodatkowo osiągnąć, by ich wartości były parami różne.*

Dowód. Gęstość. Weźmy skończone mapy $(U_i, x_i^1, \ldots, x_i^m)$ i funkcje odcinające ρ_i tak, aby mniejsze obszary, na których $\rho_i = 1$, pokrywały M, a $\operatorname{supp} \rho_i \Subset U_i$. Funkcje $\rho_i x_i^j$, przedłużone przez zero poza U_i, są globalnie gładkie. Niech

$$f_a = f + \sum_{i,j} a_{ij} \rho_i x_i^j.$$

W dowolnym x leżącym w mniejszym obszarze mapy i mamy $\mathrm{d}(\rho_i x_i^j)_x = \mathrm{d}x_i^j$. Kowektory te tworzą bazę $T^*_x M$. Zatem parametryczna rodzina przekrojów $(x, a) \mapsto df_a(x)$ ma surjektywną pochodną pionową w kierunkach a: jest transwersalna do przekroju zerowego 0_{T^*M}. Twierdzenie 19.4.1 zastosowane do tej rodziny mówi, że dla prawie każdego małego a przekrój df_a jest transwersalny do zera. Równoważność (19.5.1) czyni f_a funkcją Morse'a. Ponieważ $a \to 0$ można wybrać dowolnie, $f_a \to f$ w C^∞.

Otwartość i skończoność. Jeśli f jest Morse'a, przekrój df jest transwersalny do domkniętego przekroju zerowego. Dowód otwartości z Twierdzenia 19.4.3 stosuje się także do przekrojów; gdy g jest bliskie f w C^2, dg jest bliskie df w C^1. To daje otwartość. Zbiór krytyczny jest zerowymiarową podrozmaitością na mocy Twierdzenia 19.5.1, więc jego punkty są izolowane. Jest także zamknięty w zwartym M; zatem jest skończony.

Różne wartości. Niech krytyczne punkty funkcji Morse'a będą $p_1, \ldots, p_\ell$. Wybierzmy rozłączne małe otoczenia i funkcje odcinające β_i równe 1 w jeszcze mniejszych otoczeniach p_i. Zastąpmy f przez $f + \sum_i c_i \beta_i$. Przy dostatecznie małych c_i w obszarach, gdzie zmieniają się β_i, nie pojawiają się nowe punkty krytyczne: na zwartym zbiorze tych obszarów $|\mathrm{d}f|$ ma dodatnie minimum, a $|\sum_i c_i \mathrm{d}\beta_i|$ może być od niego mniejsze. W pobliżu p_i nowa funkcja różni się od f o stałą c_i, więc zachowuje punkty i hesjany. Nowe wartości to $f(p_i) + c_i$; wybieramy małe c_i poza skończoną sumą hiperpłaszczyzn $f(p_i) + c_i = f(p_j) + c_j$. □

Przykład 19.5.5 (Mała perturbacja funkcji)**.** Na $\mathbb{R}^2$ funkcja $f(x, y) = x^2$ ma całą prostą $x = 0$ punktów krytycznych; hesjan $\operatorname{diag}(2, 0)$ jest osobliwy. Po dodaniu εy^2 (perturbacji małej wraz z pochodnymi na każdym ustalonym zbiorze zwartym) dla $\varepsilon \neq 0$ pozostaje tylko punkt $(0, 0)$, a hesjan $\operatorname{diag}(2, 2\varepsilon)$ jest odwracalny. Gdy $\varepsilon > 0$ otrzymujemy minimum, a gdy $\varepsilon < 0$ punkt siodłowy. To lokalny obraz perturbacji; twierdzenie poprzednie zapewnia analogiczne rozwiązanie globalne na zwartej rozmaitości.

19.6 Dlaczego transwersalność pojawi się u Smale'a?

Niech (M^n, g) będzie rozmaitością riemannowską, a $f : M \to \mathbb{R}$ funkcją Morse'a, a $X = -\nabla_g f$ jej polem spadku. W punkcie krytycznym p *indeks Morse'a* $\lambda(p)$ to liczba ujemnych wartości własnych formy $\mathrm{Hess}_p f$ po podniesieniu jednego indeksu metryką g, liczonych z krotnościami. Prawo bezwładności Sylvestera pokazuje, że ta liczba zależy od formy hesjanu, a nie od pomocniczej metryki użytej do wyznaczenia wartości własnych. W dalszej teorii przepływu gradientowego skonstruujemy rozmaitość niestabilną $W^u(p)$, złożoną z punktów dążących do p przy czasie $t \to -\infty$, oraz stabilną $W^s(q)$, złożoną z punktów dążących do q przy $t \to +\infty$. W tych definicjach wymagamy istnienia trajektorii przez całą odpowiednią półprostą czasu. Na zwartej rozmaitości jest to automatyczne; gdy pole nie jest zupełne, nie wolno tego pomijać. Twierdzenie o rozmaitościach stabilnych daje

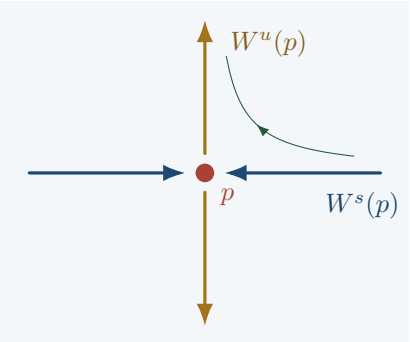
$$\dim W^u(p) = \lambda(p), \qquad \dim W^s(q) = n - \lambda(q).$$

Nie dowodzimy tutaj tego twierdzenia o równaniach różniczkowych; poniżej wyprowadzamy już teraz *konsekwencję transwersalności* tych obiektów. Globalnie traktujemy je jako rozmaitości z immersjami do M; lokalnie każda wybrana gałąź jest podrozmaitością z mapą plasterkową. Wniosek poniżej dotyczy takiego lokalnego przecięcia, co nie wymaga z góry twierdzenia o globalnym zanurzeniu obu zbiorów.

Przykład 19.6.1 (Siodło i dwa kierunki przepływu)**.** W $\mathbb{R}^2$ dla metryki euklidesowej i $f(x, y) = x^2 - y^2$ pole spadku wynosi $X = (-2x, 2y)$. Rozwiązanie startujące z (x_0, y_0) jest jawne:

$$x(t) = x_0 e^{-2t}, \qquad y(t) = y_0 e^{2t}.$$

Do $(0, 0)$ przy $t \to +\infty$ dążą dokładnie punkty z $y_0 = 0$, więc $W^s(0) = \{y = 0\}$. Przy $t \to -\infty$ dążą punkty z $x_0 = 0$, więc $W^u(0) = \{x = 0\}$. Ich styczne w siodle rozpinają $\mathbb{R}^2$, jak przewiduje nieosobliwy hesjan $\mathrm{diag}(2, -2)$.



Rysunek 19.4: Lokalny model siodła $f = x^2 - y^2$. Niebieska oś jest stabilna: przepływ kieruje się ku p. Złota oś jest niestabilna: przepływ oddala się od p. Zielona trajektoria ilustruje ruch poza osiami; osie przecinają się transwersalnie.

Wniosek 19.6.2 (Wymiar przecięcia trajektorii)**.** *Jeżeli $W^u(p)$ i $W^s(q)$ przecinają się transwersalnie, to ich przecięcie jest lokalnie rozmaitością wymiaru $\lambda(p) - \lambda(q)$. Jeśli $p \neq q$, w każdym punkcie należącym do łączącej je trajektorii niezerowe pole X jest styczne do obu rozmaitości. Po lokalnym podzieleniu przez przesunięcie czasu otrzymujemy wymiar $\lambda(p) - \lambda(q) - 1$.*

Dowód. Podstawiamy podane wymiary do Twierdzenia 19.2.4, stosowanego do lokalnych gałęzi (lub do iloczynu włóknistego immersji): $\lambda(p) + (n - \lambda(q)) - n = \lambda(p) - \lambda(q)$. Obie rozmaitości są niezmiennicze pod przepływem X, więc wektor prędkości trajektorii należy do obu przestrzeni

stycznych. Dla połączenia różnych punktów krytycznych nie znika on: gdyby trajektoria dotarła do punktu równowagi w skończonym czasie, jednoznaczność równania przepływu czyniłaby ją stałą. Twierdzenie o prostowaniu pola 2.5.2, zastosowane do ograniczenia X na przecięciu, daje lokalną współrzędną czasu; usunięcie tej jednej współrzędnej zmniejsza wymiar o jeden. □

W szczególności izolowanych trajektorii po lokalnym podzieleniu przez czas oczekujemy przy $\lambda(p) - \lambda(q) = 1$. Gdy różnica indeksów jest niedodatnia, transwersalne połączenie różnych punktów jest niemożliwe. *Warunek Morse'a–Smale'a* żąda właśnie transwersalności wszystkich takich par. Powyższy rachunek wyjaśnia rolę warunku; istnienie odpowiednich perturbacji metryki oraz zwartość odpowiednich uzupełnień przestrzeni trajektorii wymagają osobnych argumentów w późniejszej teorii Morse'a. Sama zerowymiarowość nie dowodzi skończoności liczby trajektorii. Sam lokalny iloraz nie dowodzi też, że globalny iloraz przez czas jest rozmaitością Hausdorffa.

Dalsza lektura: dowód twierdzenia Sarda, wykłady MIT o topologii różniczkowej, przecięcia transwersalne, transwersalność parametryczna i funkcje Morse'a.

Rozdział 20

Zanurzenia i otoczenia podrozmaitości

W Rozdziale 1 poznaliśmy zanurzenia (ang. *embeddings*) i mapy plasterkowe. Teraz pytamy o całe *otoczenie* podrozmaitości: czy można je opisać za pomocą wektorów wychodzących z podrozmaitości? Odpowiedź daje wiązka normalna. Jej lokalny obraz przypomina wąski pas wokół krzywej; globalnie pas może być skręcony, jak wstęga Möbiusa. To rozróżnienie będzie istotne przy dołączaniu uchwytów i operacjach chirurgicznych.

Zależności między wynikami tego rozdziału są następujące. Twierdzenie Whitneya umieszcza abstrakcyjną rozmaitość w przestrzeni euklidesowej. Wiązka normalna opisuje kierunki poprzeczne do tak umieszczonej rozmaitości, a twierdzenie o otoczeniu tubularnym zamienia krótkie wektory normalne w rzeczywiste punkty otoczenia. Kołnierz robi podobną rzecz dla brzegu. Funkcje wyczerpujące pozwalają stosować te konstrukcje także na rozmaitościach niezwartych.

20.1 Zanurzenia właściwe i twierdzenie Whitneya

Przez *zanurzenie*, zdefiniowane już w Rozdziale 1, rozumiemy immersję, która jest homeomorfizmem na obraz. Nie należy go mylić z samą różnowartościową immersją; Przykład 1.11.7 pokazuje różnicę. W tym rozdziale M i N są gładkimi rozmaitościami Hausdorffa z przeliczalną bazą i bez brzegu, chyba że zaznaczymy inaczej (jak w części o kołnierzach).

Definicja 20.1.1 (Odwzorowanie właściwe)**.** Odwzorowanie ciągłe $F : M \to N$ jest *właściwe*, jeżeli przeciwobraz każdego zbioru zwartego w N jest zwarty w M. Zanurzenie właściwe to zanurzenie będące odwzorowaniem właściwym.

Stwierdzenie 20.1.2 (Kiedy immersja jest zanurzeniem)**.** *Różnowartościowa immersja właściwa $F : M \to N$ jest zanurzeniem, a jej obraz jest domknięty w N. Jeśli M jest zwarta, wystarczy, aby immersja była różnowartościowa.*

Dowód. Pokażemy najpierw, że F jest odwzorowaniem domkniętym. Niech $A \subset M$ będzie domknięty i niech $y_j = F(x_j) \in F(A)$ zbiega do $y \in N$. Zbiór $C = \{y\} \cup \{y_j : j \geq 1\}$ jest zwarty (otwarte otoczenie y zawiera prawie wszystkie wyrazy ciągu). Z właściwości $F^{-1}(C)$ jest zwarty. Ciąg x_j ma więc podciąg zbieżny do $x \in F^{-1}(C)$. Ponieważ A jest domknięty, $x \in A$, a ciągłość daje $F(x) = y$. Rozmaitości są metryzowalne, toteż wykazane domknięcie sekwencyjne jest domknięciem topologicznym.

Różnowartościowe odwzorowanie ciągłe i domknięte jest homeomorfizmem na obraz: dla każdego domkniętego $A \subset M$ jego obraz jest domknięty również w $F(M)$, co jest właśnie ciągłością $F^{-1} : F(M) \to M$. W połączeniu z założeniem o immersji daje to zanurzenie. Biorąc $A =$

M, otrzymujemy domknięcie $F(M)$ w N. Gdy M jest zwarta, ciągłe F jest właściwe, bo przeciwobrazy zwartych zbiorów są domkniętymi podzbiorami M. □

Uwaga 20.1.3. Zanurzenie nie musi być właściwe: $(0,1) \hookrightarrow \mathbb{R}$ jest zanurzeniem, ale jego obraz nie jest domknięty. W twierdzeniu tubularnym dla niezwartych podrozmaitości domknięcie obrazu daje wygodną kontrolę globalną.

Twierdzenie 20.1.4 (Whitney: zanurzenie do przestrzeni euklidesowej)**.** *Każda zwarta gładka rozmaitość M^n bez brzegu ma gładkie zanurzenie do $\mathbb{R}^{2n+1}$.*

Dowód. Krok 1: zanurzenie do pewnej $\mathbb{R}^N$. Wybierzmy skończone pokrycie mapami (U_i, φ_i), $i = 1, \ldots, r$, o ograniczonych obrazach. Takie pokrycie otrzymujemy, wybierając przy każdym punkcie mniejszą kulę współrzędnych i korzystając ze zwartości. Niech χ_i będą gładkimi funkcjami podziału jedności, z $\operatorname{supp}\chi_i \subset U_i$. Przez zero poza U_i przedłużamy funkcje $\widetilde{\varphi}_i = \chi_i\varphi_i$. Przedłużenie jest gładkie: przy punkcie poza $\operatorname{supp}\chi_i$ obie funkcje są równe zeru w pewnym otoczeniu. Definiujemy

$$F(x) = \big(\chi_1(x), \widetilde{\varphi}_1(x); \ldots; \chi_r(x), \widetilde{\varphi}_r(x)\big) \in \mathbb{R}^{r(n+1)}.$$

Jeżeli $F(x) = F(y)$, wybierzmy i z $\chi_i(x) > 0$; istnieje taki i, bo $\sum_i \chi_i(x) = 1$. Z pierwszej składowej bloku otrzymujemy $\chi_i(y) = \chi_i(x) > 0$, więc $x, y \in U_i$. Z następnych składowych otrzymujemy $\chi_i(x)\varphi_i(x) = \chi_i(y)\varphi_i(y)$, a zatem $\varphi_i(x) = \varphi_i(y)$ i $x = y$. Jeżeli $\mathrm{d}F_x(v) = 0$, składowa χ_i daje $\mathrm{d}\chi_{ix}(v) = 0$. Różniczkując $\chi_i\varphi_i$, dostajemy

$$0 = \mathrm{d}(\chi_i\varphi_i)_x(v) = \mathrm{d}\chi_{ix}(v)\varphi_i(x) + \chi_i(x)\mathrm{d}\varphi_{ix}(v) = \chi_i(x)\mathrm{d}\varphi_{ix}(v).$$

Ponieważ $\chi_i(x) > 0$ i $\mathrm{d}\varphi_{ix}$ jest izomorfizmem, $v = 0$. Tak więc F jest różnowartościową immersją, a ze zwartości M i Stwierdzenia 20.1.2 wynika, że jest zanurzeniem.

Krok 2: zmniejszanie wymiaru. Możemy dopisać zerowe współrzędne, aby założyć $N > 2n+1$. Dla niezerowego $v \in \mathbb{R}^N$ niech P_v będzie rzutem ortogonalnym na hiperpłaszczyznę $v^\perp \cong \mathbb{R}^{N-1}$. Rzut $P_v \circ F$ przestaje być różnowartościowy dokładnie wtedy, gdy prosta $\mathbb{R}v$ jest kierunkiem siecznej $F(x) - F(y)$ dla pewnych $x \neq y$. Zbiór tych kierunków jest obrazem gładkiego odwzorowania

$$s : (M \times M) \setminus \Delta \longrightarrow \mathbb{R}P^{N-1}, \qquad s(x,y) = [F(x) - F(y)].$$

Dziedzina ma wymiar $2n$, a $\mathbb{R}P^{N-1}$ ma wymiar $N - 1 > 2n$. Żadna różniczka s nie może więc być surjektywna. Z twierdzenia Sarda 19.1.3 obraz s ma miarę zero w mapach przestrzeni projektowej.

Trzeba również zachować immersję. Jej różniczka straciłaby injektywność, gdyby $\mathbb{R}v$ była obrazem pewnego niezerowego wektora stycznego. Takie kierunki są obrazem odwzorowania

$$t : \mathbb{P}(TM) \longrightarrow \mathbb{R}P^{N-1}, \qquad t(x,[w]) = [\mathrm{d}F_x(w)].$$

Przestrzeń prostych stycznych $\mathbb{P}(TM)$ jest lokalnie iloczynem mapy na M z $\mathbb{R}P^{n-1}$, a zatem ma wymiar $n + (n-1) = 2n - 1$. Również obraz t ma miarę zero. Jeżeli $n = 0$, zbiór prostych stycznych jest pusty i ten warunek znika.

Dwa zbiory miary zero nie pokrywają $\mathbb{R}P^{N-1}$. Wybierzmy prostą $[v]$ poza ich sumą. Wtedy $P_v \circ F$ jest różnowartościową immersją, a więc zanurzeniem na mocy zwartości M. Powtarzamy redukcję, dopóki wymiar przestrzeni docelowej nie wyniesie $2n+1$. W każdym kroku przesłanka $N > 2n+1$ jest zachowana do chwili ostatniego rzutowania. □

Twierdzenie 20.1.5 (Mocne twierdzenie Whitneya)**.** *Każda zwarta gładka rozmaitość M^n bez brzegu o $n \geq 1$ ma gładkie zanurzenie w $\mathbb{R}^{2n}$.*

W dowodzie nie można po prostu powtórzyć poprzedniego rzutowania: gdy obraz ma już wymiar $2n+1$, zbiór kierunków siecznych może wypełnić dodatnią część przestrzeni kierunków. Rzut do $\mathbb{R}^{2n}$ będzie jednak zazwyczaj *immersją z izolowanymi punktami podwójnymi*. Trzeba następnie usunąć te punkty. Wyjaśnimy osobno konstrukcję geometryczną, która to umożliwia.

Stwierdzenie 20.1.6 (Dysk Whitneya i usuwanie pary)**.** *Niech $n \geq 3$, niech M będzie zwarta i niech $f : M^n \to \mathbb{R}^{2n}$ będzie immersją z poprzecznymi punktami podwójnymi, bez punktów potrójnych. Przypuśćmy, że dwie takie pary mają preobrazy x_1, y_1 oraz x_2, y_2, a wybór łuków x_1x_2 i y_1y_2 jest* zgodny *w tym sensie: dwa lokalne znaki przecięcia przy końcach są przeciwne po przeniesieniu orientacji wzdłuż łuków. Wtedy istnieje modyfikacja f, wsparta w otoczeniu obu punktów i łączącego je dysku, która usuwa te dwa punkty podwójne i nie tworzy nowych. W przypadku zorientowanego M i parzystego n zgodność oznacza po prostu przeciwne znaki przecięć.*

Dowód. Punkty podwójne mają skończenie wiele preobrazów. Istotnie, transwersalność izoluje pary (x, y) poza przekątną $M \times M$, a lokalna różnowartościowość immersji wyklucza ich gromadzenie się przy przekątnej. Zwartość daje skończoność. Przy $n \geq 3$ możemy wybrać łuki w M, które nie spotykają innych preobrazów punktów podwójnych i są rozłączne: dwie krzywe w n wymiarach po małej perturbacji się mijają, bo $1 + 1 < n$. Niewielka zmiana łuków zapewnia, że ich obrazy przez f także są rozłączne poza obrazami końców. W obrazie tworzą prostą pętlę z dwoma narożami. Ponieważ $\mathbb{R}^{2n}$ jest po prostu spójna, pętla ogranicza odwzorowanie dysku. Najpierw przy jej brzegu ustalamy wąski pas, którego wnętrze omija $f(M)$; przy narożach robimy to w modelu dwóch poprzecznych płaszczyzn. Wypełnienie można wygładzić względnie tego pasa (współrzędne są rzeczywiste, więc wystarczy lokalne wygładzanie i podział jedności). Dysk ma dwa naroża na brzegu; jego powierzchnia nośna jest gładka także przy nich.

Uzasadnijmy dokładniej użyte tu położenie ogólne. W małej mapie wnętrza o współrzędnych (u_1, u_2) dodajemy do wypełnienia perturbacje $\beta(u)(a_0 + a_1u_1 + a_2u_2)$, gdzie $a_i \in \mathbb{R}^{2n}$, a $\beta = 1$ na mniejszej mapie i znika poza większą. Parametry pozwalają niezależnie zmieniać wartość i obie kolumny różniczki. Warstwa macierzy $2n \times 2$ rzędu $r < 2$ ma kowymiar $(2n - r)(2 - r) \geq 2n - 1 > 2$. Wzór na kowymiar wynika z eliminacji blokowej przy odwracalnym minorze rzędu r: pozostały blok jest wyznaczony przez pozostałe trzy bloki. Parametryczna transwersalność do tych warstw zapewnia więc, że mała perturbacja jest immersją. Skończone pokrycie zwartej części dysku poza ustalonym pasem daje skończenie wiele parametrów; przy brzegu immersja jest już ustalona.

Dla otrzymanej immersji pary dostatecznie bliskich punktów nie dają samoprzecięć, także po małej zmianie w C^1. Można to sprawdzić na skończonym pokryciu mapami, w których odpowiedni dwuwymiarowy rzut ma różniczkę bliską ustalonemu izomorfizmowi. Pozostałe możliwe pary leżą w zwartym zbiorze oddalonym od przekątnej. Na rozłącznych mapach dwóch argumentów funkcje odcinające pozwalają zmieniać wartości niezależnie. Transwersalność różnicy wartości do $0 \in \mathbb{R}^{2n}$ usuwa te pary, gdyż $2 + 2 - 2n < 0$. Tak samo dla pary składającej się z punktu wnętrza dysku i punktu M zmieniamy wartość po stronie dysku; wymiar potencjalnego przecięcia to $2 + n - 2n < 0$. W ustalonym pasie nie ma niepożądanych przecięć, a jego węższy podpas możemy pozostawić nietknięty. Zwartość pozwala wybrać skończone rodziny perturbacji na pozostałym obszarze i zachować uzyskaną wcześniej immersję. Otrzymujemy zanurzony dysk D, którego wnętrze nie przecina $f(M)$.

Pozostaje sprawdzić, czy można wykonać ruch jednego płata *przez* ten dysk, nie skręcając go po drodze. Wiązka normalna dysku ma rząd $2n - 2$ i jest trywialna, ponieważ dysk jest ściągalny. Oznaczmy $k = n-1 \geq 2$. Na pierwszym łuku normalne do łuku wewnątrz pierwszego płata dają k-płaszczyznę A w νD, a na drugim analogicznie dostajemy B. Szukamy rozkładu $\nu D = \xi_1 \oplus \xi_2$, w którym $\xi_1 = A$ na pierwszym łuku, zaś $\xi_2 = B$ na drugim. Po wybraniu pomocniczej metryki i standardowego modelu przy narożach odpowiada to pętli L w $\mathrm{Gr}_k(\mathbb{R}^{2k})$: na pierwszym łuku przepisujemy $L = A$, a na drugim $L = B^\perp$. Przy narożach płaszczyzny A i B są dopełniające;

metrykę można tam dobrać tak, by były ortogonalne. Ważne jest użycie dopełnienia na drugim łuku.

Pętla L przedłuża się na dysk dokładnie wtedy, gdy zachowuje orientację swojej k-płaszczyzny. Oto uzasadnienie. Przestrzeń zorientowanych płaszczyzn

$$\mathrm{Gr}_k^+(\mathbb{R}^{2k}) = \mathrm{SO}(2k)/(\mathrm{SO}(k)\times\mathrm{SO}(k))$$

jest po prostu spójna. Wyjaśnijmy używaną własność wiązania: każdą pętlę w ilorazie można podnieść do drogi w grupie, a jej końce połączyć we włóknie, ponieważ $\mathrm{SO}(k)\times\mathrm{SO}(k)$ jest spójna. Dostajemy pętlę w grupie o zadanym rzucie (z dokładnością do dodania stałego odcinka). Jeżeli każdą taką pętlę można zdeformować do pętli w samym włóknie, jej rzut jest ściągalny. Wystarczy zatem sprawdzić surjektywność $\pi_1(\mathrm{SO}(k)\times\mathrm{SO}(k)) \to \pi_1\,\mathrm{SO}(2k)$: obrót o 2π w jednej ustalonej dwupłaszczyźnie pierwszego czynnika daje generator grupy docelowej $\mathbb{Z}/2\mathbb{Z}$. Przypomnijmy uzasadnienie tego ostatniego faktu: $\mathrm{SO}(3)$ ma dwukrotne nakrycie przez jednostkowe kwaterniony S^3, a obrót o 2π podnosi się do drogi od 1 do -1. Wiązanie $\mathrm{SO}(r-1)\to\mathrm{SO}(r)\to S^{r-1}$ wysyła macierz na jej ostatnią kolumnę. Dla $r\ge 4$ sfera ma zerowe π_1 i π_2: przez aproksymację komórkową każde odwzorowanie z okręgu lub dwusfery jest homotopijne z odwzorowaniem stałym. Podnosząc ściągnięcie rzutu pętli, deformujemy ją do włókna. Jeśli pętla we włóknie ogranicza dysk w całej grupie, rzut dysku z zapadniętym brzegiem jest odwzorowaniem $S^2\to S^{r-1}$. Jego ściągnięcie, podniesione względnie brzegu, deformuje dysk do włókna. Inkluzja włókna daje więc izomorfizm grup podstawowych i przenosi wynik z $r=3$ na wszystkie $r\ge 4$. Użyte podnoszenia wynikają z lokalnych trywializacji: dzielimy przedział lub kwadrat parametrów na małe kawałki i w każdym podnosimy przez iloczyn. Trywializacje obu wiązań otrzymujemy, lokalnie uzupełniając ortonormalne bazy metodą Grama–Schmidta. Dla $k=2$ czynnik $\mathrm{SO}(2)$ ma grupę podstawową $\mathbb{Z}$, ale ten sam obrót nadal daje generator obrazu. Dwukrotne nakrycie przez zorientowany grassmannian pokazuje więc, że $\pi_1\,\mathrm{Gr}_k(\mathbb{R}^{2k}) = \mathbb{Z}/2\mathbb{Z}$, a jego jedyną przeszkodą jest odwrócenie orientacji. Reprezentantem klasy niezerowej jest

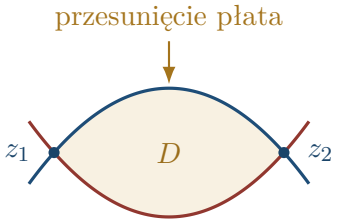
$$L_\theta = \mathrm{span}(\cos\theta\, e_1 + \sin\theta\, e_{k+1}, e_2, \dots, e_k), \qquad 0\le\theta\le\pi.$$

Porównajmy teraz znaki. Orientacje obu płatów przenosimy wzdłuż wybranych łuków. W bazie płata oddzielamy kierunek łuku od pozostałych k kierunków. Przy dwóch końcach para kierunków łuków wyznacza przeciwne orientacje płaszczyzny dysku: łuki ograniczają dwukąt. Aby całe bazy otoczenia miały przeciwne znaki przecięcia, pozostałe kierunki muszą więc skleić się bez odwrócenia orientacji. Jest to właśnie trywialność przeszkody dla L. Zgodność znaków daje zatem przedłużenie L na D, a jego dopełnienie daje ξ_2. Obie wiązki nad dyskiem są trywialne, więc teraz wybieramy ich ramki. Przedłużaliśmy rozkład na podwiązki; nie twierdzimy, że każda z góry zadana pełna ramka na brzegu przedłuża się na dysk.

W tych ramkach otoczenie dysku ma współrzędne $D\times\mathbb{R}^k\times\mathbb{R}^k$ o dostatecznie małym promieniu. Użycie twierdzenia tubularnego jest tu niezależne od twierdzenia Whitneya: jego dowód poniżej korzysta tylko z metryki, funkcji wyczerpującej i twierdzenia odwrotnego. Przy brzegu i narożach dysku najpierw nieco przedłużamy jego powierzchnię nośną, a potem ograniczamy otoczenie do zwartego D. Prostując płaty w wąskich pasach przy łukach, otrzymujemy pierwszy łuk pogrubiony w pierwszym $\mathbb{R}^k$ i drugi w drugim $\mathbb{R}^k$.

Sam ruch w dwuwymiarowym przekroju można opisać jawnie. Po wyborze współrzędnych łuki mają postać $y=x(1-x)$ i $y=-x(1-x)$ dla $0\le x\le 1$, z krótkimi przedłużeniami poza końce. Pierwszy zastępujemy rodziną wykresów $y=x(1-x)-sh(x)$, $0\le s\le 1$, gdzie $h\ge 0$ ma nośnik w przedłużonym przedziale i $h(x)>2x(1-x)$ na $[0,1]$. Na końcu pierwszy wykres leży ściśle poniżej drugiego; poza przedziałem już wcześniej był poniżej. Każdy wykres pozostaje regularny. Pogrubiając go w kierunkach ξ_1, przenosimy ten ruch na płat; kierunki ξ_1 i ξ_2 są dopełniające, więc usunięcie obu przecięć wykresów usuwa też przecięcia płatów. Ruch wygaszamy przy zewnętrznym brzegu pogrubienia. Wnętrze dysku omija $f(M)$, a zwartość

zapewnia, że poza ustalonymi pasami możemy wybrać otoczenie nieprzecinające pozostałej części obrazu. Przy końcach używamy modelu dwóch poprzecznych płaszczyzn. Powstała immersja nie ma nowych punktów podwójnych. □



Rysunek 20.1: Schemat dysku Whitneya D: dwa łuki jego brzegu leżą na różnych płatach immersji i łączą dwa punkty podwójne z_1, z_2. Ruch płata po dysku usuwa oba przecięcia, gdy obramowanie brzegowe da się przedłużyć na D. Rysunek pokazuje tylko dwuwymiarowy przekrój konstrukcji.

Dowód Twierdzenia 20.1.5. Najpierw zakładamy $n \geq 3$ i M spójną. Z Twierdzenia 20.1.4 mamy zanurzenie $F : M \hookrightarrow \mathbb{R}^{2n+1}$. Rzutowanie w kierunku v daje $f = P_v \circ F : M \to \mathbb{R}^{2n}$. Kierunki, dla których f nie jest immersją, tworzą obraz $\mathbb{P}(TM)$ o wymiarze $2n-1$ w przestrzeni kierunków $\mathbb{R}P^{2n}$: podobnie jak w poprzednim dowodzie można więc wybrać v poza tym obrazem.

Rozważmy odwzorowanie kierunków siecznych

$$s : (M \times M) \setminus \Delta_M \longrightarrow \mathbb{R}P^{2n}, \qquad s(x,y) = [F(x) - F(y)].$$

Twierdzenie Sarda daje regularny kierunek $[v]$, który jednocześnie omija kierunki styczne. Wtedy $f(x) = f(y)$, $x \neq y$, oznacza $s(x,y) = [v]$. Regularność s oznacza, że odwzorowanie

$$T_xM \oplus T_yM \longrightarrow \mathbb{R}^{2n}, \qquad (u,w) \longmapsto \mathrm{d}f_x(u) - \mathrm{d}f_y(w)$$

jest surjektywne, czyli obrazy dwóch n-płaszczyzn stycznych są poprzeczne. Rozwiązania są izolowane. Nie mogą gromadzić się przy przekątnej: granice kierunków bardzo krótkich siecznych byłyby kierunkami stycznymi, a wybraliśmy $[v]$ poza nimi. Dokładniej, w jednej mapie dzielimy różnicę $F(x_j) - F(y_j)$ przez odległość współrzędnych argumentów. Po wybraniu podciągu jednostkowych kierunków argumentów wzór całkowy na przyrost daje w granicy $\mathrm{d}F_x(w)$ dla pewnego $|w| = 1$. Immersja zapewnia, że wektor ten jest niezerowy, co daje sprzeczność. Zwartość M daje zatem skończenie wiele punktów podwójnych. Małą perturbacją f usuwamy też ewentualne punkty potrójne. W istocie dla trzech różnych argumentów warunki $f(x) = f(y)$ i $f(x) = f(z)$ mają razem $4n$ równań, podczas gdy (x,y,z) ma wymiar $3n$; perturbacje funkcjami o rozłącznych nośnikach przy x, y, z pozwalają zmieniać obie różnice niezależnie. Transwersalność z parametrem (Twierdzenie 19.4.1) daje więc brak punktów potrójnych. Aby zastosować ją do jednej skończonej rodziny, ustalamy $\delta > 0$ tak małe, że każda dostatecznie bliska w C^1 perturbacja jest różnowartościowa na parach o odległości mniejszej niż δ. Istnienie δ wynika z lokalnych rzutów immersji na współrzędne i skończonego pokrycia zwartej M. Wszystkie możliwe trójki leżą więc w zwartym zbiorze o wzajemnych odległościach argumentów co najmniej δ. Pokrywamy go skończenie wieloma produktami trzech rozłącznych obszarów map. Stałe przesunięcia pomnożone przez funkcje odcinające, równe 1 na mniejszych obszarach, dają rodzinę o surjektywnej pochodnej parametrycznej obu różnic. Transwersalność na otoczeniu tego zwartego zbioru usuwa wszystkie trójki jednocześnie. Dostateczna małość perturbacji zachowuje immersję oraz poprzeczność par: potencjalne pary też leżą w zwartym zbiorze poza przekątną, gdzie stosujemy otwartość transwersalności.

Pokażemy, skąd wziąć partnera dla punktu podwójnego o niezgodnym znaku. Istnieje jawna immersja sfery $S^n = \{(u,x) \in \mathbb{R}\times\mathbb{R}^n : u^2+|x|^2=1\}$ w $\mathbb{R}^{2n}$:

$$W(u,x) = (ux, x).$$

Jedyny jej punkt podwójny to 0, o preobrazach $(1,0)$ i $(-1,0)$. Przy tych punktach styczne obrazy mają postać $\{(h,h)\}$ oraz $\{(-h,h)\}$, więc są poprzeczne. Gdy $x \neq 0$, druga składowa wyznacza x, pierwsza wyznacza u; zerowanie różniczki wymusza najpierw $\delta x = 0$, a następnie $x\delta u = 0$, więc $\delta u = 0$. Przy $x = 0$ warunek styczności do sfery daje $\delta u = 0$, a druga składowa różniczki wykrywa każde $\delta x \neq 0$. Jest to zatem immersja wszędzie. Umieszczamy małą kopię tej immersji w wolnym obszarze i łączymy jej regularny fragment z regularnym fragmentem $f(M)$ wąską rurką. Ponieważ $1+n < 2n$, rdzeń rurki można poprowadzić poza pozostałym obrazem; otrzymujemy immersję $M\#S^n \cong M$ z jednym dodatkowym punktem podwójnym. Używamy standardowego sklejenia brzegów usuniętych dysków: dołączona sfera z usuniętym dyskiem jest zwykłym dyskiem, więc nie zmieniamy gładkiego typu M. Odbicie jednej współrzędnej otoczenia odwraca jego znak w przypadku parzystego n i zorientowanego M. Przy nieparzystym n zamiana ról dwóch lokalnych płatów odwraca znak względny, a gdy M jest niezorientowana, dobór łuku lub jego obieg wokół pętli odwracającej orientację zmienia względne obramowanie. Możemy więc dodać punkt zgodny z danym w sensie Stwierdzenia 20.1.6. Po usunięciu pary liczbę punktów podwójnych zmniejszamy o jeden. Ponieważ początkowo było ich skończenie wiele, powtarzanie daje różnowartościową immersję. Zwartość M czyni ją zanurzeniem.

Dla $n = 1$ każda zwarta spójna rozmaitość jest okręgiem; rozłączne składowe umieszczamy jako rozłączne okręgi w $\mathbb{R}^2$. Dla $n = 2$ poprzedni ruch nie działa: $2+2-4 = 0$, więc dysk Whitneya może przecinać zarówno siebie, jak i powierzchnię. Korzystamy z klasyfikacji zwartych powierzchni: zorientowane powstają jako sumy spójne torusów i sfer, a niezorientowane jako sumy spójne płaszczyzn projektowych. Zorientowane realizujemy w $\mathbb{R}^3$. Dla $\mathbb{R}P^2$ mamy jawne zanurzenie do $\mathbb{R}^4$. Na S^2 położmy $w = x+iy$ i

$$V([x:y:z]) = \big(\mathrm{Re}(w^2), \mathrm{Im}(w^2), \mathrm{Re}(zw), \mathrm{Im}(zw)\big).$$

Wartość nie zmienia się przy $(x,y,z) \mapsto (-x,-y,-z)$, więc wzór schodzi na $\mathbb{R}P^2$. Zapis $[x:y:z]$ oznacza tu wybór reprezentanta jednostkowego; dla dowolnego niezerowego reprezentanta wszystkie cztery składowe należy podzielić przez $x^2+y^2+z^2$. Jeśli $w \neq 0$, równość pierwszych dwóch składowych daje $w' = \pm w$; pozostałe dają $z' = \pm z$ z tym samym znakiem. Jeśli $w = 0$, obie możliwości są biegunami identyfikowanymi w $\mathbb{R}P^2$. Jest więc różnowartościowy. Ponadto zerowanie różniczki pierwszych dwóch składowych przy $w \neq 0$ daje $\delta w = 0$, a ostatnich dwóch $\delta z = 0$. Przy $w = 0$ mamy $z = \pm 1$; zerowanie ostatnich dwóch również daje $\delta w = 0$, a warunek styczności do S^2 daje $\delta z = 0$. Jest immersją, więc ze zwartości jest zanurzeniem. Umieszczając rozłączne powierzchnie w osobnych kulach $\mathbb{R}^4$ i łącząc je cienkimi rurkami wzdłuż rozłącznych łuków w dopełnieniu ($1+2<4$), realizujemy ich sumy spójne. Tak otrzymujemy wszystkie zwarte powierzchnie. Składowych zwartej rozmaitości jest skończenie wiele, ponieważ są otwarte i tworzą pokrycie. Wreszcie składowe rozmaitości M umieszczamy w rozłącznych kulach $\mathbb{R}^{2n}$. □

Uwaga 20.1.7 (Zakres twierdzenia). Pełne mocne twierdzenie Whitneya obejmuje też odpowiednie rozmaitości niezwarte. Powyższy dowód dotyczy zwartych rozmaitości bez brzegu, zgodnie z zakresem wcześniejszego Twierdzenia 20.1.4. W wymiarze dwa użyliśmy klasyfikacji powierzchni; nie podstawiliśmy błędnie argumentu z dyskiem Whitneya w wymiarze cztery. Twierdzenie dotyczy gładkiej struktury, nie zachowania zadanej metryki: zanurzenie $M \to \mathbb{R}^{2n}$ nie musi być izometryczne.

Przykład 20.1.8. Okrąg S^1 jest zanurzony w $\mathbb{R}^2$ przez $\theta \mapsto (\cos\theta, \sin\theta)$ (ściśle: jest to odwzorowanie z $\mathbb{R}/2\pi\mathbb{Z}$). Wersja $2n+1$ gwarantuje jedynie zanurzenie w $\mathbb{R}^3$: jest twierdzeniem uniwersalnym, nie wzorem na najmniejszy wymiar dla konkretnej rozmaitości. Podobnie $S^2 \hookrightarrow \mathbb{R}^3$ ma niższy wymiar niż ogólna gwarancja $\mathbb{R}^5$.

20.2 Wiązka normalna: kierunki poprzeczne

Niech $i : S^k \hookrightarrow M^n$ będzie zanurzeniem. W każdym $x \in S$ różniczka $\mathrm{d}i_x$ identyfikuje T_xS z podprzestrzenią $T_{i(x)}M$. Pisząc $S \subset M$, pomijamy i w zapisie.

Definicja 20.2.1 (Wiązka normalna)**.** *Wiązką normalną* zanurzenia $S \subset M$ nazywamy wiązkę ilorazową

$$\nu(S,M) := TM|_S/TS, \qquad \nu_x(S,M) = T_xM/T_xS.$$

Jej rząd to $n-k$, czyli kowymiar S. Krótki ciąg wiązek

$$0 \longrightarrow TS \xrightarrow{\mathrm{d}i} TM|_S \longrightarrow \nu(S,M) \longrightarrow 0 \tag{20.2.1}$$

jest dokładny we włóknie nad każdym x.

Klasa $[v] \in T_xM/T_xS$ pamięta tę część przemieszczenia, której nie da się osiągnąć ruchem stycznym po S. Wybór metryki riemannowskiej g wskazuje jednego przedstawiciela każdej klasy: wektor prostopadły do T_xS.

Stwierdzenie 20.2.2 (Gładkość i rozszczepienie)**.** *Wiązka $\nu(S,M)$ jest gładką wiązką wektorową rzędu $n-k$. Każda metryka riemannowska g na M daje izomorfizm wiązki $\nu(S,M) \cong (TS)^\perp \subset TM|_S$ oraz rozkład $TM|_S = TS \oplus (TS)^\perp$.*

Dowód. W mapie plasterkowej S jest zbiorem $\{(u,0) : u \in \mathbb{R}^k\}$, a wektor w $T_{(u,0)}M$ ma współrzędne $(a,b) \in \mathbb{R}^k \oplus \mathbb{R}^{n-k}$. Klasy modulo TS są dokładnie parami (u,b). Zmiana mapy daje gładką zmianę baz we włóknach, dlatego lokalne opisy sklejają się w wiązkę gładką.

Niech $P_x^\perp : T_xM \to (T_xS)^\perp$ będzie rzutem ortogonalnym. Jądrem $P_x^\perp$ jest T_xS, więc odwzorowanie $[v] \mapsto P_x^\perp v$ jest dobrze określonym izomorfizmem. W lokalnej ramie TS współczynniki rzutu otrzymuje się przez odwrócenie macierzy Grama $(g(e_a,e_b))_{a,b=1}^k$; macierz ta jest odwracalna i gładko zależy od x. Rzut, a więc również izomorfizm wiązek, jest gładki. □

Przykład 20.2.3 (Dwa przeciwstawne pasy normalne)**.** Dla $S^1 \subset \mathbb{R}^2$ wektor $n(\theta) = (\cos\theta, \sin\theta)$ jest globalnym niezerowym polem normalnym. Wiązka normalna jest iloczynem $S^1 \times \mathbb{R}$. Rozważmy teraz środkowy okrąg wstęgi Möbiusa

$$M_{\mathrm{Mob}} = ([0,2\pi] \times (-1,1))/((0,t) \sim (2\pi,-t)).$$

Wzdłuż środkowego okręgu $t=0$ wektor normalny ∂_t zmienia znak po obejściu okręgu; jego wiązka normalna ma dokładnie takie samo sklejenie $(0,v) \sim (2\pi,-v)$. Nie istnieje globalne niezerowe pole normalne: jego współczynnik $a(\theta)$ musiałby być ciągły, niezerowy i spełniać $a(2\pi) = -a(0)$, co przeczy twierdzeniu o wartości pośredniej.

Przykład 20.2.4 (Przekątna i styczne do M)**.** Dla $\Delta = \{(x,x) : x \in M\} \subset M \times M$ mamy $T_{(x,x)}(M \times M) = T_xM \oplus T_xM$ i $T_{(x,x)}\Delta = \{(u,u) : u \in T_xM\}$. Odwzorowanie

$$[(u,v)] \longmapsto v - u$$

jest izomorfizmem $\nu(\Delta, M \times M) \cong TM$: jest surjektywne, jego jądrem przed przejściem do ilorazu jest właśnie przekątna w $T_xM \oplus T_xM$, a wzór jest gładki w mapach. Wiązka normalna może więc mieć taką samą topologię jak wiązka styczna i wcale nie musi być trywialna.

20.3 Otoczenie tubularne

Zapiszmy $D_\varepsilon\nu = \{(x,v) \in \nu(S,M) : |v|_g < \varepsilon(x)\}$ dla dodatniej funkcji $\varepsilon : S \to (0,\infty)$. Przez Stwierdzenie 20.2.2 traktujemy tu v jako wektor prostopadły w T_xM.

Twierdzenie 20.3.1 (Otoczenie tubularne)**.** *Ustalmy dowolną metrykę riemannowską g na M. Jeśli $S \subset M$ jest domkniętą podrozmaitością zanurzoną bez brzegu, istnieje dodatnia gładka funkcja ε i dyfeomorfizm*

$$E : D_\varepsilon\nu(S,M) \longrightarrow U \subset M, \qquad E(x,v) = \exp_x^M(v),$$

gdzie U jest otwartym otoczeniem S, a $E(x,0) = x$. Jeśli S jest zwarta, można wybrać stałe $\varepsilon > 0$. Każda zanurzona podrozmaitość, także niedomknięta, ma przynajmniej pewne otoczenie dyfeomorficzne z otoczeniem przekroju zerowego swojej wiązki normalnej.

Dowód. Krok lokalny. Przez cały dowód zachowujemy ustaloną metrykę g; nie zakładamy jej zupełności. Odwzorowanie $E(x,v) = \exp_x(v)$ jest określone i gładkie w pewnym otoczeniu przekroju zerowego w $(TS)^\perp$. W punkcie $(x,0)$ przestrzeń styczna wiązki rozkłada się kanonicznie na $T_xS \oplus (T_xS)^\perp$. Jeżeli zmieniamy x w S przy $v = 0$, $E(x,0) = x$, więc różniczka w pierwszym kierunku to u. Jeśli zmieniamy tylko v, własność $\mathrm{d}(\exp_x)_0 = \mathrm{id}_{T_xM}$ daje w. W konsekwencji

$$\mathrm{d}E_{(x,0)}(u,w) = u + w. \tag{20.3.1}$$

Jest to izomorfizm $T_xS \oplus (T_xS)^\perp \to T_xM$. Twierdzenie o odwzorowaniu odwrotnym daje dyfeomorfizm na otoczeniu każdego $(x,0)$.

Jednolita szerokość nad zwartym fragmentem. Niech $A \subset S$ będzie zwarty. Istnieje $\delta_A > 0$ takie, że E jest określone, jest lokalnym dyfeomorfizmem i jest różnowartościowe na wektorach długości mniejszej niż δ_A, których punkty bazowe leżą w A. Istotne jest uzasadnienie różnowartościowości. Gdyby dla dowolnie małych długości zachodziła kolizja $E(x_j,v_j) = E(y_j,w_j)$ z $x_j, y_j \in A$ i $(x_j,v_j) \neq (y_j,w_j)$, to po przejściu do podciągu $x_j \to x$, $y_j \to y$, $v_j, w_j \to 0$. Granica równości daje $x = y$. Obie pary leżałyby wtedy ostatecznie w jednym otoczeniu $(x,0)$, na którym E jest różnowartościowe na mocy twierdzenia odwrotnego: sprzeczność. Gładkość E i zwartość A dają jednocześnie jednolitą dziedzinę określoności i lokalną odwracalność. Gdy S jest zwarta, bierzemy $A = S$.

Niezwarta podrozmaitość domknięta. Wybierzmy gładkie właściwe wyczerpanie $\rho : M \to [0,\infty)$ z Twierdzenia 20.7.2; jego dowód nie korzysta z otoczeń tubularnych. Zbiory $A_j = S \cap \{\rho \le j\}$ są zwarte, gdyż S jest domknięty. Weźmy malejące liczby $\delta_j > 0$ takie, że E jest różnowartościowe i lokalnie odwracalne nad A_j przy $|v| < \delta_j$, a ponadto

$$|\rho(E(x,v)) - \rho(x)| < \tfrac{1}{4} \qquad (x \in A_j,\ |v| < \delta_j).$$

Ostatni warunek wynika z ciągłości $\rho \circ E$ i zwartości A_j: wzdłuż przekroju zerowego różnica jest równa zeru. Możemy zmniejszać kolejne δ_j, zachowując wszystkie te własności. Dobierzmy gładką dodatnią ε tak, aby

$$\varepsilon(x) < \tfrac{1}{4} \quad \text{oraz} \quad \varepsilon(x) < \delta_{j+3} \text{ dla } x \in S,\ j-1 \le \rho(x) \le j.$$

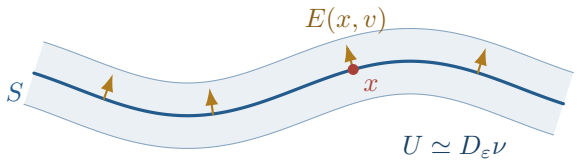
Istnienie takiej funkcji wynika z lokalnie skończonego podziału jedności: na każdym otwartym kawałku nieco szerszym od jednego pierścienia wybieramy dodatnią stałą mniejszą od skończenie wielu sąsiednich δ_j i składamy ją z wagami podziału. Lokalna skończoność gwarantuje gładkość i dodatniość.

Załóżmy $E(x,v) = E(y,w)$ dla par z $D_\varepsilon\nu$ i wybierzmy j z $j-1 \le \rho(x) \le j$. Oznaczmy wspólny obraz przez z. Każdy wektor spełnia ograniczenie nad swoim pierścieniem, zatem

$$|\rho(x) - \rho(y)| \le |\rho(x) - \rho(z)| + |\rho(z) - \rho(y)| < \tfrac{1}{2}.$$

W szczególności $x, y \in A_{j+2}$. Punkt y leży najwyżej w sąsiednim pierścieniu o numerze $j+1$; dolna granica $\rho(y)$ może należeć do pierścienia $j-1$. Z monotoniczności δ_ℓ i podanych ograniczeń dla ε wynika w każdym przypadku $|v|, |w| < \delta_{j+2}$. Jednolita różnowartościowość nad A_{j+2} wymusza $(x, v) = (y, w)$. Tak E jest różnowartościowym lokalnym dyfeomorfizmem, a zatem dyfeomorfizmem na otwarty obraz U. Wykorzystanie ρ działa jednocześnie na wszystkich składowych M.

Jeżeli S nie jest domknięta w M, wybierzmy dla każdego $x \in S$ mapę plasterkową o dziedzinie V_x. Zbiór $S \cap V_x$ jest domknięty w V_x, bo w tej mapie jest przecięciem z domkniętą podprzestrzenią $\mathbb{R}^k \times \{0\}$. Niech $V = \bigcup_{x \in S} V_x$. Domkniętość jest własnością lokalną: dla każdego $y \in V$ wybieramy V_x zawierający y, a w nim $S \cap V_x$ jest domknięty. Stąd S jest domknięta w otwartym otoczeniu $V \subset M$. Stosujemy udowodnioną część twierdzenia do zanurzenia $S \subset V$. Ponieważ $TV|_S = TM|_S$, obie wiązki normalne są tą samą wiązką. Obraz uzyskanego dyfeomorfizmu jest również otwarty w M. Używając metryki $g|_V$, zachowujemy nawet opis przez $\exp^M$: na dostatecznie krótkich geodezyjnych pozostających w V oba odwzorowania wykładnicze są identyczne. □



Rysunek 20.2: Otoczenie tubularne krzywej S (ciemnoniebieska). W metryce euklidesowej złote odcinki są prostopadłe do stycznych krzywej, a $E(x, v) = x + v$ umieszcza ich końce w jasnym pasie U. Brzegi pasa są odsunięte wzdłuż normalnych.

Wniosek 20.3.2 (Cofnięcie otoczenia na podrozmaitość)**.** *W otoczeniu tubularnym istnieje gładkie rzutowanie na podstawę $r = \mathrm{pr}_S \circ E^{-1} : U \to S$. Zanurzenie $S \hookrightarrow U$ jest równoważnością homotopijną. W szczególności $H_*(U; G) \cong H_*(S; G)$ dla dowolnej abelowej grupy współczynników G.*

Dowód. Na dysku wiązki definiujemy $h_t(x, v) = (x, (1-t)v)$, $0 \le t \le 1$. Ponieważ $|(1-t)v| \le |v| < \varepsilon(x)$, jest to dobrze określona homotopia od identyczności do rzutu na przekrój zerowy, stale równa identyczności na tym przekroju. Przeniesienie przez E daje silną retrakcję deformacyjną U na S. Niezmienniczość homotopijna homologii była udowodniona w Rozdziale 8. □

Przykład 20.3.3 (Okrąg i sfera)**.** W $\mathbb{R}^2$ dla okręgu jednostkowego $E(e^{i\theta}, t) = (1+t)e^{i\theta}$ przy $|t| < 1$. Obrazem jest pierścień $0 < |z| < 2$, a $r(z) = z/|z|$. W $\mathbb{R}^3$ analogicznie $E(x, t) = (1+t)x$ dla $x \in S^2$; mały dysk wiązki jest powłoką sferyczną. Na wstędze Möbiusa otoczenie środkowego okręgu jest skręconą wiązką dyskową, nie iloczynem $S^1 \times (-\varepsilon, \varepsilon)$.

20.4 Obramowanie i dane potrzebne do chirurgii

Definicja 20.4.1 (Obramowanie)**.** *Obramowaniem normalnym* (ang. *framing*) zanurzenia $S^k \subset M^n$ nazywamy uporządkowaną bazę gładkich przekrojów $(n_1, \dots, n_{n-k})$ wiązki $\nu(S, M)$ w każdym włóknie; równoważnie, izomorfizm wiązek $\nu(S, M) \cong S \times \mathbb{R}^{n-k}$.

Istnienie obramowania to silniejszy warunek niż orientowalność wiązki: obramowanie daje orientację, lecz orientacja nie zawsze daje globalną bazę. Po wyborze obramowania twierdzenie tu-

bularne przy zwartej S daje zanurzenie

$$S \times D^{n-k}_{\varepsilon} \longrightarrow M, \qquad (x, a_1, \ldots, a_{n-k}) \longmapsto \exp_x \left(\sum_j a_j n_j(x) \right). \tag{20.4.1}$$

Tutaj $D^r_\varepsilon = \{a \in \mathbb{R}^r : |a| \leq \varepsilon\}$ jest *domkniętym* dyskiem, w odróżnieniu od otwartego $D_\varepsilon \nu$ z twierdzenia tubularnego. Istotnie, na zwartej S istnieje $C > 0$ takie, że $|\sum a_j n_j(x)|_g \leq C|a|$. Wybieramy $C\varepsilon$ ściśle mniejsze od jednolitego promienia tubularnego. Wówczas wzór jest zanurzeniem nawet na otoczeniu tego domkniętego dysku. Obramowanie nie musi być ortonormalne. Bez obramowania dziedziną jest dysk *wiązki* normalnej, a nie globalny iloczyn.

Przykład 20.4.2 (Równik w sferze)**.** Włóżmy $S^k \subset S^n \subset \mathbb{R}^{n+1}$ jako punkty $(x, 0)$ w rozkładzie $\mathbb{R}^{n+1} = \mathbb{R}^{k+1} \oplus \mathbb{R}^{n-k}$. Stałe wektory $e_{k+2}, \ldots, e_{n+1}$ są w każdym punkcie $(x, 0)$ styczne do S^n, lecz prostopadłe do $T_x S^k$. Tworzą więc obramowanie normalne. W kontraście środkowy okrąg wstęgi Möbiusa z Przykładu 20.2.3 nie dopuszcza nawet jednego niezerowego normalnego przekroju.

W teorii chirurgii wybiera się często zanurzenie sfery wraz z obramowaniem. Wzór (20.4.1) mówi wtedy dokładnie, *które* otoczenie $S^k \times D^{n-k}$ ma zostać usunięte. Różne obramowania mogą dawać różne sklejenia po usunięciu; samo wskazanie podrozmaitości nie zawiera całej potrzebnej informacji.

20.5 Kołnierz brzegu i podwojenie

Definicja 20.5.1 (Kołnierz)**.** Jeżeli W jest rozmaitością z brzegiem, *kołnierzem brzegu* nazywamy zanurzenie

$$c : \partial W \times [0, 1) \longrightarrow W, \qquad c(p, 0) = p,$$

którego obraz jest otwartym otoczeniem ∂W w W. Parametr t oznacza ruch *do wnętrza*.

Twierdzenie 20.5.2 (Istnienie kołnierza)**.** *Każda gładka rozmaitość z brzegiem ma kołnierz. Jeśli ∂W jest zwarty, kołnierz można przed przeskalowaniem zapisać na $\partial W \times [0, \varepsilon)$ z jedną stałą $\varepsilon > 0$.*

Dowód. W mapie półprzestrzennej $(u^1, \ldots, u^{n-1}, r)$, $r \geq 0$, wektor ∂_r wskazuje do wnętrza w punktach brzegu. Wybierzmy lokalnie skończone pokrycie brzegu takimi mapami i podział jedności na niewielkim otoczeniu brzegu. Ważona suma odpowiednich pól ∂_r jest gładkim polem V, którego składowa skierowana do wnętrza jest dodatnia: każda dodatnia kombinacja wektorów skierowanych do wnętrza nadal jest skierowana do wnętrza.

Lokalny przepływ Φ_t tego pola przy brzegu otrzymujemy, przedłużając jego współczynniki w mapach półprzestrzennych przez $r = 0$ i stosując twierdzenie o równaniach różniczkowych. Jednoznaczność spaja te lokalne rozwiązania, dopóki leżą w W. Dla każdego $p \in \partial W$ istnieje otoczenie B_p w brzegu i czas $\tau_p > 0$, dla których $\Phi_t(q)$ jest określone w dziedzinie V i leży we wnętrzu W dla $q \in B_p$ i $0 < t < \tau_p$. Wynika to z dodatniej składowej pola w kierunku r oraz ciągłej zależności rozwiązania od danych.

Za pomocą lokalnie skończonego podziału jedności na brzegu wybieramy dodatnią gładką funkcję $\varepsilon(p)$ tak małą, by te własności zachodziły dla $0 < t < \varepsilon(p)$. Dokładniej, dla podziału $\{\chi_i\}$ podporządkowanego otoczeniom B_i można wziąć $\varepsilon = \sum_i \chi_i \tau_i / 2$: przy ustalonym p jest to średnia skończenie wielu dopuszczalnych czasów, więc jest mniejsza od największego z nich, także dopuszczalnego przy p.

Odwzorowanie $C(p, t) = \Phi_t(p)$ ma różniczkę

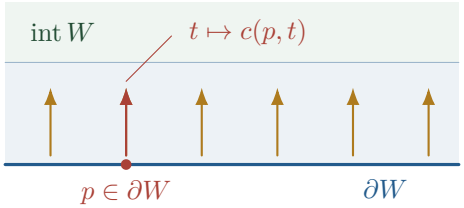
$$\mathrm{d}C_{(p,t)}(u, a) = \mathrm{d}\Phi_{tp}(u + aV_p).$$

Jest ona izomorfizmem: pole V_p jest poprzeczne do $T_p\partial W$, a różniczka lokalnego przepływu jest odwracalna. Przy $t = 0$ stosujemy twierdzenie odwrotne w mapach półprzestrzennych; skierowanie V do wnętrza zapewnia właściwą stronę brzegu. Tak C jest lokalnym dyfeomorfizmem na dziedzinie $\{(p,t) : 0 \le t < \varepsilon(p)\}$.

Globalna różnowartościowość wynika bezpośrednio z jednoznaczności trajektorii. Jeżeli $\Phi_t(p) = \Phi_s(q)$ i $t \ge s$, to cofając obie trajektorie o czas s, dostajemy $\Phi_{t-s}(p) = q$. Dla $t > s$ lewa strona leży we wnętrzu, a q na brzegu, co jest niemożliwe. Zatem $t = s$ i $p = q$. Różnowartościowy lokalny dyfeomorfizm C jest dyfeomorfizmem na otwarte otoczenie brzegu. Wreszcie

$$c(p,s) = C(p, s\varepsilon(p)), \qquad 0 \le s < 1,$$

daje kołnierz z definicji. Przy zwartym brzegu minimum dodatniej funkcji ε jest dodatnie, więc przed przeskalowaniem można użyć stałej szerokości. □



Rysunek 20.3: Kołnierz zamienia całe otoczenie brzegu w produkt $\partial W \times [0,1)$. Współrzędna t rośnie do wnętrza rozmaitości.

Przykład 20.5.3 (Dysk i walec)**.** Dla dysku jednostkowego D^2 kołnierz można zapisać jako $c(p,t) = (1-t)p$ dla $p \in S^1$ i $0 \le t < \varepsilon < 1$. Dla $W = S^1 \times [0,1]$ brzeg ma dwie składowe: przy 0 parametr idzie w górę, a przy 1 w dół. Jest to konkretny powód, dla którego orientacje dwóch składowych brzegu walca są przeciwne.

Wniosek 20.5.4 (Podwojenie rozmaitości)**.** *Dwie kopie W_+ i W_- rozmaitości z brzegiem można skleić wzdłuż identyczności ∂W tak, aby otrzymać gładką rozmaitość bez brzegu $DW = W_+ \cup_{\partial W} W_-$. Jeżeli W jest zwarta, DW też jest zwarta.*

Dowód. Poza brzegiem korzystamy z istniejących map gładkich obu kopii. W pobliżu sklejonego brzegu używamy kołnierzy i współrzędnej $s \in (-1,1)$: dla $s \ge 0$ punkt (p,s) oznacza $c_+(p,s)$, a dla $s \le 0$ oznacza $c_-(p,-s)$. Wspólne przejścia między takimi mapami mają postać $(p,s) \mapsto (\psi \circ \varphi^{-1}(p), s)$, więc są gładkie. Z kolei przejścia do map pochodzących z wnętrza odbywają się dla $s \neq 0$ i także są gładkie. Otrzymujemy atlas bez półprzestrzennych punktów brzegowych. Sprawdźmy też warunki topologiczne. Różne punkty szwu rozdzielamy rozłącznymi otoczeniami w ∂W i ich kołnierzami. Punkt wnętrza można oddzielić od szwu, zmniejszając otoczenie tak, by jego domknięcie nie dochodziło do brzegu; następnie dobieramy odpowiednio małe otoczenie drugiego punktu. Punkty wnętrz rozdziela własność Hausdorffa w kopiach W. Iloraz jest więc Hausdorffa. Przeliczalne atlasy obu wnętrz i brzegu wraz z przedziałami o wymiernych końcach dają przeliczalną bazę ilorazu. Jeśli W jest zwarta, ciągły obraz zwartej sumy rozłącznej $W_+ \sqcup W_-$ jest zwarty. □

20.6 Izotopie i zgodność otoczeń

Izotopia to gładka rodzina zanurzeń $i_t : S \hookrightarrow M$, $0 \le t \le 1$. Rozdział 2 zawiera już dowód twierdzenia o rozszerzeniu izotopii 2.7.5 dla zwartej S bez brzegu: istnieje izotopia otoczenia $h_t : M \to M$ z $h_0 = \mathrm{id}$ i $h_t \circ i_0 = i_t$. Nie powtarzamy tamtego dowodu; wykorzystamy jego wnioski geometryczne.

Wniosek 20.6.1 (Otoczenia i dopełnienia izotopijnych zanurzeń)**.** *Jeśli S jest zwarta bez brzegu, a $i_t : S \hookrightarrow M$ jest gładką izotopią, to*

$$M \setminus i_0(S) \cong M \setminus i_1(S) \quad \text{oraz} \quad \nu(i_0(S), M) \cong \nu(i_1(S), M)$$

jako odpowiednio rozmaitości i wiązki nad S. Można wybrać otoczenia tubularne obu obrazów odpowiadające sobie przez h_1.

Dowód. Twierdzenie 2.7.5 daje dyfeomorfizm h_1 z $h_1(i_0(S)) = i_1(S)$. Jego ograniczenie do dopełnień ma odwrotność h_1^{-1}. Różniczka $\mathrm{d}h_1$ wysyła $T(i_0(S))$ na $T(i_1(S))$, a więc przechodzi do izomorfizmu ilorazów $TM|_{i_0(S)}/T(i_0(S)) \to TM|_{i_1(S)}/T(i_1(S))$. Jeśli $E_0 : D_\varepsilon \nu_0 \to U_0$ jest otoczeniem tubularnym, to złożenie $h_1 \circ E_0$ opisuje otoczenie $h_1(U_0)$ przez tę samą wiązkę; po uzyskanym izomorfizmie $\nu_0 \cong \nu_1$ jest to opis przez ν_1. Precyzyjniej, jeśli A oznacza ten izomorfizm, nowym odwzorowaniem tubularnym jest $E_1 = h_1 \circ E_0 \circ A^{-1}$. Nie musi ono być odwzorowaniem wykładniczym dla początkowej metryki na M. Jest nim dla metryki przeniesionej przez h_1, ponieważ izometria przenosi geodezyjne i normalne. □

Uwaga 20.6.2 (Co właściwie jest zachowane?). Wniosek nie mówi, że dowolne dwa zanurzenia tej samej abstrakcyjnej sfery mają dyfeomorficzne dopełnienia. Wymagana jest *izotopia zanurzeń* w ustalonym M. W szczególności różne węzły w $\mathbb{R}^3$ mogą mieć różne dopełnienia; nie należy utożsamiać deformacji abstrakcyjnego okręgu z izotopią w przestrzeni otaczającej.

Kołnierze tej samej zwartej składowej brzegu można także porównywać: z kołnierza c_j otrzymujemy pole $(c_j)_*(\partial_t)$ w pobliżu brzegu. Oba pola są skierowane do wnętrza. Ich interpolacja $(1-s)V_0 + sV_1$ nadal jest skierowana do wnętrza; jej przepływ daje, po wyborze wspólnego małego czasu na zwartym brzegu, rodzinę kołnierzy łączącą oba opisy. Oznaczmy tę rodzinę przez $C_s(p,t)$. Aby otrzymać dyfeomorfizm, a nie tylko rodzinę opisów, definiujemy w jej obrazie zależne od s pole $Y_s(C_s(p,t)) = \partial_s C_s(p,t)$. Ponieważ $C_s(p,0) = p$, pole to znika na brzegu. Wybieramy gładkie odcięcie równe 1 na mniejszym kołnierzu i równe 0 przed zewnętrznym końcem większego. Zwartość brzegu i przedziału parametrów pozwala dobrać wspólną szerokość i zwarty nośnik dla całej rodziny. Przepływ powstałego pola jest izotopią H_s rozmaitości W, ustaloną na brzegu; jednoznaczność rozwiązań daje $H_s(C_0(p,t)) = C_s(p,t)$ w mniejszym kołnierzu. Stosując H_1 na obu kopiach W, otrzymujemy dyfeomorfizm odpowiednich podwojeń: przy szwie współrzędne $(p, \text{czas ze znakiem})$ są zachowane. Wyjaśnia to niezależność gładkiego podwojenia, z dokładnością do dyfeomorfizmu, od wyboru kołnierza przy zwartym brzegu.

20.7 Funkcje wyczerpujące i regularne poziomice

Definicja 20.7.1 (Funkcja wyczerpująca)**.** Funkcja ciągła $\rho : M \to [0, \infty)$ jest *wyczerpująca*, jeśli jest właściwa, czyli $\rho^{-1}([0,a])$ jest zwarty dla każdego $a \geq 0$. Nie wymaga się, by ρ była funkcją Morse'a.

Twierdzenie 20.7.2 (Istnienie gładkiego wyczerpania)**.** *Każda rozmaitość gładka z przeliczalną bazą, również z brzegiem, ma gładką nieujemną funkcję wyczerpującą. Na rozmaitości bez brzegu istnieje ciąg dowolnie dużych wartości regularnych $a_j \to \infty$; zbiory $\rho^{-1}((-\infty, a_j])$ są wtedy zwartymi rozmaitościami z gładkim brzegiem $\rho^{-1}(a_j)$.*

Dowód. Z lokalnej zwartości i przeliczalnej bazy budujemy zwarte zbiory $K_1 \subset \operatorname{int} K_2 \subset K_2 \subset \operatorname{int} K_3 \subset \cdots$ o sumie równej M. W tym celu wybieramy przeliczalne pokrycie $\{B_j\}$ zbiorami otwartymi o zwartych domknięciach. Mając K_j, pokrywamy zwarty zbiór $K_j \cup \overline{B_{j+1}}$ skończenie wieloma względnie zwartymi otwartymi otoczeniami i za K_{j+1} bierzemy sumę ich domknięć. Zaczynamy od $K_1 \supset \overline{B_1}$; konstrukcja zapewnia zarówno zawieranie we wnętrzach, jak i wyczerpanie M.

Dla każdego j skonstruujmy gładką $\psi_j : M \to [0,1]$ równą 0 w otoczeniu K_j i równą 1 poza $\operatorname{int} K_{j+1}$. Istnienie wynika z gładkiego lematu o funkcji odcinającej: zbiory K_j i $M \setminus \operatorname{int} K_{j+1}$ są rozłączne i domknięte, a lokalnie skończony podział jedności oddziela je gładko. Połóżmy

$$\rho(x) = \sum_{j=1}^{\infty} \psi_j(x).$$

Wybierzmy m tak, by $x \in \operatorname{int} K_m$. Wszystkie ψ_j dla $j \geq m$ są równe zeru na tym samym otoczeniu $\operatorname{int} K_m$; suma jest lokalnie skończona, zatem ρ jest gładka. Jeśli $x \notin K_{N+1}$, to dla $j \leq N$ mamy $x \notin \operatorname{int} K_{j+1}$, więc $\psi_j(x) = 1$ i $\rho(x) \geq N$. Stąd $\{\rho \leq a\}$ zawiera się w K_{N+1} dla $N > a$. Jest domknięty, zatem zwarty; to dowodzi właściwości.

Dla rozmaitości bez brzegu twierdzenie Sarda 19.1.3 daje wartości regularne poza zbiorem miary zero. W każdym przedziale $(j, j+1)$ można wybrać wartość regularną a_j. W pobliżu każdego punktu jej poziomicy twierdzenie o submersji zapisuje ρ jako jedną ze współrzędnych, więc podpoziomica ma lokalny model półprzestrzeni. Jej brzeg jest właśnie $\rho^{-1}(a_j)$. □

Twierdzenie 20.7.3 (Właściwa funkcja Morse'a)**.** *Na każdej gładkiej rozmaitości bez brzegu istnieje nieujemna właściwa funkcja Morse'a $f : M \to \mathbb{R}$. Każda jej podpoziomica $\{f \leq a\}$ jest zwarta. Jej punkty krytyczne mogą być nieskończenie liczne, ale w każdej podpoziomicy jest ich skończenie wiele.*

Dowód. Zaczynamy od gładkiej właściwej funkcji ρ z Twierdzenia 20.7.2. Wybierzmy zwarte $K_1 \subset \operatorname{int} K_2 \subset K_2 \subset \cdots$ o sumie M; dla wygody $K_0 = \varnothing$. Połóżmy $f_0 = \rho$. Skonstruujemy funkcje $f_j = f_{j-1} + h_j$ tak, aby f_j była Morse'a na otoczeniu K_j, a przyszłe poprawki nie niszczyły tej własności.

Pokryjmy K_j skończoną liczbą mniejszych obszarów map. W większych obszarach wybierzmy funkcje odcinające β_i, równe 1 na mniejszych. Funkcje $\beta_i x_i^1, \ldots, \beta_i x_i^n$, przedłużone przez zero, mają różniczki rozpinające T_x^*M dla każdego $x \in K_j$: w jednym z mniejszych obszarów są po prostu współrzędnymi. Zatem dla rodziny

$$f_{j,a} = f_{j-1} + \sum_{i,\ell} a_{i\ell} \beta_i x_i^\ell$$

parametryczna różniczka $(x, a) \mapsto \mathrm{d} f_{j,a}(x)$ jest transwersalna do przekroju zerowego nad otoczeniem K_j. Dowód transwersalności parametrycznej z Twierdzenia 19.4.1 pozwala wybrać *dowolnie małe* parametry a, dla których $f_{j,a}$ jest Morse'a na otoczeniu K_j. Niech h_j będzie otrzymaną poprawką. Jest sumą skończenie wielu funkcji o zwartych nośnikach.

Uściślijmy wybór wielkości poprawek. Ustalmy metrykę riemannowską i jej połączenie ∇ oraz normy

$$\|h\|_{C^r(K)} = \max_{0 \leq \ell \leq r} \sup_{x \in K} |\nabla^\ell h(x)|.$$

Na zbiorach zwartych są one równoważne normom w skończonych układach map; rosną wraz z K i r. Normy na pustym K_0 przyjmujemy równe zeru. Skoro f_i jest Morse'a na otoczeniu zwartego K_i, istnieje $\eta_i > 0$ takie, że perturbacja o normie $C^2(K_i)$ mniejszej od η_i zachowuje niezdegenerowanie wszystkich punktów krytycznych na K_i. Wynika to z otwartości transwersalności $\mathrm{d} f_i$ do przekroju zerowego na zwartym zbiorze. W kroku j wybieramy małe parametry tak, aby dodatkowo

$$\|h_j\|_\infty < 2^{-j}, \qquad \|h_j\|_{C^j(K_{j-1})} < 2^{-j}, \qquad \|h_j\|_{C^2(K_i)} < 2^{-j}\eta_i \quad (i < j).$$

Każdy krok narzuca tylko skończenie wiele warunków otwartych przy $a = 0$, więc można je pogodzić z wyborem dobrego a.

Szereg $f = \rho + \sum_{j\geq 1} h_j$ zbiega gładko na każdym zwartym zbiorze: dla ustalonego K_i i rzędu pochodnej r wszystkie wyrazy o $j > \max(i, r)$ mają normę $C^r(K_i)$ ograniczoną przez 2^{-j}. Ponadto $|f - \rho| \leq \sum_j 2^{-j} = 1$. Zatem przeciwobraz zwartego przedziału $[-A, A]$ przez f leży w zwartej podpoziomicy $\{\rho \leq A + 1\}$ i jest domknięty, czyli zwarty. Funkcja f jest właściwa. Na K_i różnica $f - f_i$ ma normę C^2 mniejszą od $\eta_i \sum_{j>i} 2^{-j} < \eta_i$; funkcja f pozostaje tam Morse'a. Ponieważ K_i wyczerpują M, jest Morse'a wszędzie. Ponieważ $f \geq -1$, zastępujemy ją na końcu przez $f + 1$. Otrzymana funkcja jest nieujemna, nadal właściwa i Morse'a, a jej podpoziomice są przeciwobrazami zwartych przedziałów. Jej punkty krytyczne są izolowane; ich zbiór w zwartej podpoziomicy jest domknięty i dlatego skończony. □

Stwierdzenie 20.7.4 (Metryka zupełna)**.** *Każda rozmaitość gładka bez brzegu ma zupełną metrykę riemannowską. Ten sam wniosek w sensie zupełnej odległości metrycznej zachodzi dla rozmaitości z brzegiem.*

Dowód. Wybierzmy dowolną metrykę g i gładkie właściwe ρ z Twierdzenia 20.7.2. Niech $\lambda = \sqrt{1 + |\nabla_g \rho|_g^2}$ i $g' = \lambda^2 g$. Ponieważ $|\nabla_{g'} \rho|_{g'} = |\nabla_g \rho|_g / \lambda \leq 1$, całkowanie po dowolnej kawałkami gładkiej krzywej γ daje

$$|\rho(\gamma(1)) - \rho(\gamma(0))| \leq L_{g'}(\gamma).$$

Po wzięciu kresu dolnego długości $|\rho(x) - \rho(y)| \leq d_{g'}(x, y)$. Niech (x_j) będzie ciągiem Cauchy'ego w odległości $d_{g'}$. Jego odległości od ustalonego x_1 są ograniczone, więc wartości $\rho(x_j)$ też są ograniczone. Cały ciąg leży w pewnej zwartej podpoziomicy $\{\rho \leq A\}$, zatem ma podciąg zbieżny. Ponieważ (x_j) jest Cauchy'ego i topologia $d_{g'}$ zgadza się z topologią rozmaitości, cały ciąg zbiega. Ten sam argument dla krzywych leżących w rozmaitości z brzegiem daje jej zupełność jako przestrzeni metrycznej. Zgodność topologii przy brzegu wynika z lokalnego porównania metryki z euklidesową w mniejszych wypukłych półkulach map. Przy niespójnym M zupełność riemannowską rozumiemy składowa po składowej, ponieważ między różnymi składowymi nie ma krzywych. Jeśli potrzebna jest jedna skończona odległość na całym M, bierzemy $\min(d_{g'}, 1)$ na każdej składowej i odległość 1 pomiędzy nimi. Jest ona zupełna i wyznacza topologię M. □

Przykład 20.7.5. Na $\mathbb{R}^n$ funkcja $\rho(x) = |x|^2$ jest wyczerpująca, bo $\{\rho \leq a\}$ to domknięta kula promienia $\sqrt{a}$. Na otwartym przedziale $(0, 1)$ działa na przykład $\rho(x) = x^{-2} + (1 - x)^{-2}$: rośnie bez ograniczenia przy obu końcach. Funkcja x^2 na $(0, 1)$ nie jest właściwa: punkty mogą zbliżać się do brzegu 0 przy ograniczonych wartościach x^2.

Twierdzenie 20.7.6 (Pas bez punktów krytycznych jest produktem)**.** *Niech M będzie rozmaitością bez brzegu, $f : M \to \mathbb{R}$ gładką funkcją i właściwą, a $a < b$. Załóżmy, że f nie ma punktów krytycznych w $f^{-1}([a, b])$. Wtedy*

$$f^{-1}([a, b]) \cong f^{-1}(a) \times [a, b], \qquad f \text{ odpowiada rzutowi na } [a, b].$$

Jeżeli poziomica $f^{-1}(a)$ jest pusta, obie strony są puste.

Dowód. Pas $K = f^{-1}([a, b])$ jest zwarty, bo f jest właściwa. Dla $K = \varnothing$ teza jest natychmiastowa. W przeciwnym razie na nim $\nabla f \neq 0$, więc pole

$$X = \frac{\nabla f}{|\nabla f|^2}$$

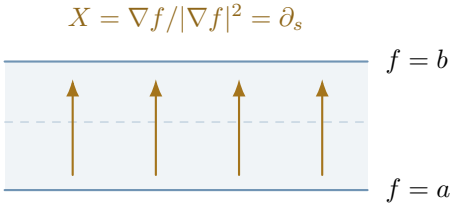
jest określone w otoczeniu K. Wybierzmy gładką funkcję odcinającą χ o zwartym nośniku w tym otoczeniu, równą 1 na K, i zastąpmy X przez globalne, zwartego nośnika pole χX. Jego przepływ Φ_t istnieje dla wszystkich $t \in \mathbb{R}$ dzięki zwartości nośnika. Dopóki trajektoria pozostaje w K, mamy

$$\frac{\mathrm{d}}{\mathrm{d}t} f(\Phi_t(x)) = \mathrm{d}f_{\Phi_t(x)}(X) = g(\nabla f, \nabla f)/|\nabla f|^2 = 1.$$

Startując z $x \in f^{-1}(a)$, trajektoria nie może opuścić K przed czasem $b-a$: wcześniejsze opuszczenie wymagałoby wartości f poza $[a,b]$, podczas gdy na każdym wcześniejszym odcinku $f(\Phi_t(x)) = a + t$. Zatem $\Psi(x,s) = \Phi_{s-a}(x)$ dla $s \in [a,b]$ jest dobrze określona i ma $f(\Psi(x,s)) = s$. Analogicznie trajektoria startująca z $y \in K$ pozostaje w K dla $a - f(y) \le t \le 0$ i spełnia $f(\Phi_t(y)) = f(y) + t$. Dochodzi więc do poziomicy a; jeśli ta jest pusta, nie mogło być żadnego $y \in K$. Własność grupowa przepływu pokazuje, że odwrotnością Ψ jest

$$y \longmapsto \big(\Phi_{a-f(y)}(y),\ f(y)\big).$$

Przepływ i f są gładkie, więc oba odwzorowania są gładkie, także w mapach półprzestrzennych przy a i b. To daje żądaną identyfikację. □



Rysunek 20.4: Przepływ pola X przenosi punkt poziomicy $f = a$ na poziomicę $f = a + t$. Gdy w zwartym pasie nie ma punktów krytycznych, wszystkie poziomice składają się w produkt. Rysunek przedstawia współrzędne produktowe (x, s) wyznaczone przez przepływ; w nich $f = s$.

Uwaga 20.7.7 (Związek z późniejszą teorią Morse'a). Jeśli ρ jest właściwa, zmiany topologii jej podpoziomic mogą zachodzić tylko przy przechodzeniu przez wartości krytyczne: pomiędzy nimi Twierdzenie 20.7.6 identyfikuje pas z produktem. Teoria Morse'a opisze konkretną zmianę przy niezdegenerowanym punkcie krytycznym. Tu potrzebowaliśmy jedynie pojęcia punktu krytycznego z Rozdziału 19.

Dalsza lektura: wykłady MIT o mocnym twierdzeniu Whitneya, omówienie dysku Whitneya w wykładach Benedettiego, wykład MIT o otoczeniach tubularnych.

Rozdział 21

Przecięcia, dualność i klasy charakterystyczne

Otoczenie tubularne z Rozdziału 20 pozwala odróżnić ruch *wzdłuż* podrozmaitości od ruchu *poprzecznego*. Teraz przypiszemy przecięciom liczby, a wiązkom – klasy kohomologii. W ten sposób geometryczne dane zanurzenia stają się niezmiennikami, które można obliczać i porównywać. To przygotowanie do teorii Morse'a, Smale'a i chirurgii; w końcowej sekcji wykonamy też prostą operację wycinania i sklejania rozmaitości.

Przez *zamkniętą rozmaitość* rozumiemy w tym rozdziale rozmaitość zwartą bez brzegu. W dowodzie komórkowym będziemy używać triangulacji gładkiej rozmaitości. Jej istnienie jest osobnym, głębszym twierdzeniem o triangulacji; opisujemy dokładnie argument dualności *po* wybraniu takiej triangulacji. Rozróżnienie tych dwóch kroków zapobiega ukryciu twierdzenia o triangulacji w rysunku.

21.1 Kochainy symplicjalne i iloczyn kubkowy

Kompleksy łańcuchowe i ich duale poznaliśmy w Rozdziałach 6 i 8. Dla skończonej triangulacji K i ciała $\mathbb{F}$ zapisujemy precyzyjnie

$$C^k(K;\mathbb{F}) = \operatorname{Hom}_{\mathbb{F}}(C_k(K;\mathbb{F}),\mathbb{F}), \qquad (\mathrm{d}\varphi)(c) = \varphi(\partial c).$$

Kochain $\varphi \in C^k$ jest więc funkcją liniową *na łańcuchach* stopnia k. Nie jest kolejnym rodzajem sympleksu: przypisuje każdemu łańcuchowi liczbę z $\mathbb{F}$. To polska nazwa angielskiego *cochain*; łańcuch należy do C_k, a kochain do przestrzeni dualnej C^k. Znak ∂ pozostaje zarezerwowany dla łańcuchów, a d dla kochainów. Równość $\mathrm{d}^2 = 0$ wynika od razu z $\partial^2 = 0$. Klasa w H^k to funkcja na cyklach, która nie zmienia się po dodaniu brzegu. Nad ciałem $H^k(K;\mathbb{F}) \cong \operatorname{Hom}_{\mathbb{F}}(H_k(K;\mathbb{F}),\mathbb{F})$: można wybrać uzupełnienia baz jąder i obrazów i zdualizować powstały rozkład. Nad $\mathbb{Z}$ analogiczne zdanie wymaga poprawki Ext, co było omawiane przy zmianie współczynników w Rozdziale 6. Pracę nad ciałem rozpoczniemy tu dlatego, że łatwiej zobaczyć parowanie; dualność Poincarégo ma również wersję całkowitą.

Definicja 21.1.1 (Iloczyn kubkowy)**.** Ustalmy porządek wierzchołków K i przemienny pierścień współczynników R (w szczególności $\mathbb{Z}$ lub ciało). Dla $\alpha \in C^p(K;R)$ i $\beta \in C^q(K;R)$ definiujemy na sympleksach o wierzchołkach zapisanych rosnąco

$$(\alpha \smile \beta)[v_0,\dots,v_{p+q}] = \alpha[v_0,\dots,v_p]\,\beta[v_p,\dots,v_{p+q}].$$

Na przeciwnie zorientowanym sympleksie przedłużamy ten wzór liniowo ze znakiem. Obie ściany dzielą wierzchołek v_p. Po przejściu do kohomologii otrzymamy iloczyn $H^p \times H^q \to H^{p+q}$.

Stwierdzenie 21.1.2 (Reguła Leibniza)**.** *Dla kochainów zachodzi*

$$\mathrm{d}(\alpha \smile \beta) = (\mathrm{d}\alpha) \smile \beta + (-1)^p \alpha \smile (\mathrm{d}\beta).$$

Zatem iloczyn klas kohomologii jest dobrze określony; jest łączny.

Dowód. Obliczamy prawą stronę na $[v_0, \ldots, v_{p+q+1}]$. W $(\mathrm{d}\alpha) \smile \beta$ wyrazy z usunięciem v_i dla $0 \le i \le p$ odpowiadają dokładnie tym samym wyrazom w $\mathrm{d}(\alpha \smile \beta)$. W $(-1)^p \alpha \smile \mathrm{d}\beta$ odpowiadają im pozostałe wyrazy, o indeksach $p+1 \le i \le p+q+1$. Na prawej stronie są ponadto dwa dodatkowe wyrazy:

$$\big((-1)^{p+1} + (-1)^p\big) \alpha[v_0, \ldots, v_p]\, \beta[v_{p+1}, \ldots, v_{p+q+1}] = 0.$$

Pochodzą one odpowiednio z ostatniej ściany $\mathrm{d}\alpha$ i pierwszej ściany $\mathrm{d}\beta$. To one się znoszą; żaden wyraz lewego kobrzegu nie zostaje usunięty. Otrzymujemy regułę Leibniza. Jeśli $\mathrm{d}\alpha = \mathrm{d}\beta = 0$, iloczyn jest kocyklem. Jeśli α zastąpimy przez $\alpha + \mathrm{d}\gamma$, to zmiana iloczynu wynosi $\mathrm{d}(\gamma \smile \beta)$ przy zamkniętej β; przy zmianie β na $\beta + \mathrm{d}\eta$ różnica wynosi $(-1)^p \mathrm{d}(\alpha \smile \eta)$ przy zamkniętej α. Łączność widać bezpośrednio: obie iteracje na sympleksie stopnia $p+q+r$ dają iloczyn wartości na trzech kolejnych ścianach $[v_0, \ldots, v_p]$, $[v_p, \ldots, v_{p+q}]$ i $[v_{p+q}, \ldots, v_{p+q+r}]$. □

Stwierdzenie 21.1.3 (Przemienność z właściwym znakiem)**.** *W kohomologii* $\alpha \smile \beta = (-1)^{pq} \beta \smile \alpha$ *dla* $\alpha \in H^p$, $\beta \in H^q$.

Dowód. Pracujemy najpierw nad $\mathbb{Z}$ i oznaczamy $C = C_*(K; \mathbb{Z})$. Na kompleksie tensorowym przyjmujemy $\partial(a \otimes b) = \partial a \otimes b + (-1)^{|a|} a \otimes \partial b$. Odwzorowanie Alexandera–Whitneya ma postać

$$A[v_0, \ldots, v_m] = \sum_{j=0}^{m} [v_0, \ldots, v_j] \otimes [v_j, \ldots, v_m].$$

Jest odwzorowaniem łańcuchowym: po rozpisaniu brzegów wyrazy wewnętrzne przy miejscu podziału znoszą się tak jak w poprzednim dowodzie. Również $T(a \otimes b) = (-1)^{|a||b|} b \otimes a$ jest odwzorowaniem łańcuchowym.

Skonstruujemy homotopię H między A i TA. Dla wierzchołków oba odwzorowania są równe, więc kładziemy $H = 0$ w stopniu zero. Jeżeli H jest już określone na ścianach sympleksu σ^m, łańcuch

$$z = TA(\sigma) - A(\sigma) - H(\partial\sigma)$$

jest cyklem: stosujemy ∂, korzystamy z łańcuchowości obu odwzorowań i założenia indukcyjnego. Cały z leży w $C_*(\sigma) \otimes C_*(\sigma)$. Ten kompleks ma zerową homologię w dodatnich stopniach: stożkowanie sympleksu do jego wierzchołka jest ściągnięciem łańcuchowym do $\mathbb{Z}$ w stopniu zero, a ze ściągnięć obu czynników konstruujemy ściągnięcie ich iloczynu tensorowego. Możemy więc wybrać $H(\sigma)$ z $\partial H(\sigma) = z$. Indukcja daje $\partial H + H\partial = TA - A$.

Dla kocykli α, β kochain $\alpha \otimes \beta$ znika na brzegach kompleksu tensorowego. Po ewaluacji ostatniej tożsamości otrzymujemy, że $(-1)^{pq}\beta \smile \alpha - \alpha \smile \beta$ jest kobrzegiem kochainu $(\alpha \otimes \beta)H$. Dowód działa po zmianie współczynników na R. Ta sama indukcja w ściągalnych nośnikach pokazuje niezależność od porządku wierzchołków i wyboru przybliżenia przekątnej. W połączeniu z aproksymacją symplicjalną daje naturalność iloczynu w kohomologii. □

W przeciwieństwie do samego wymiaru grup H^k, iloczyn kubkowy pamięta, *jak* różne cykle są względem siebie położone. Ta dodatkowa informacja wyjaśni później liczby przecięcia. Oznaczenie $\smile$ odróżnia iloczyn kochainów od iloczynu zewnętrznego form $\wedge$ z Rozdziału 10.

Definicja 21.1.4 (Iloczyn kapowy i konwencja znaków)**.** Dla m-sympleksu $c = [v_0, \dots, v_m]$ i kochainu α stopnia $k \le m$ kładziemy

$$c \frown \alpha = \alpha[v_0, \dots, v_k]\,[v_k, \dots, v_m].$$

Wzór przedłużamy liniowo. Możemy wziąć całkowity łańcuch i kochain o wartościach w dowolnej grupie abelowej G; wtedy wynik jest łańcuchem z G. Bezpośrednie rozpisanie ścian (z tym samym skróceniem dwóch wyrazów przy podziale) daje

$$\partial(c \frown \alpha) = (-1)^k((\partial c) \frown \alpha - c \frown \mathrm{d}\alpha). \tag{21.1.1}$$

Dlatego cykl i kocykl wyznaczają klasę homologii, niezależną od reprezentantów. Dla współczynników w R mamy ponadto, prosto ze wzorów na ściany,

$$\langle \beta, c \frown \alpha \rangle = \langle \alpha \smile \beta, c \rangle.$$

Ta kolejność czynników będzie obowiązywała w całym rozdziale.

21.2 Orientacja jako klasa homologii

W Stwierdzeniu 8.8.1 ustaliliśmy, że $H_n(M, M \setminus \{x\}; \mathbb{Z}) \cong \mathbb{Z}$. Orientacja oznacza spójny wybór generatorów tych lokalnych grup. Teraz skleimy je w jedną klasę globalną.

Twierdzenie 21.2.1 (Klasa fundamentalna)**.** *Niech M^n będzie spójną, zamkniętą, zorientowaną rozmaitością. Istnieje jedyna klasa $[M] \in H_n(M; \mathbb{Z})$, która w $H_n(M, M \setminus \{x\}; \mathbb{Z})$ przechodzi w wybrany lokalny generator dla każdego x. W szczególności $H_n(M; \mathbb{Z}) \cong \mathbb{Z}$. Dla zwartej zorientowanej rozmaitości z brzegiem otrzymujemy zamiast tego $[M, \partial M] \in H_n(M, \partial M; \mathbb{Z})$. Bez orientacji zawsze istnieje klasa fundamentalna ze współczynnikami $\mathbb{F}_2 = \mathbb{Z}/2$.*

Dowód. Wybierzmy triangulację K zgodną ze strukturą gładką. Orientacja M wyznacza orientację każdego n-sympleksu. Niech $c = \sum_{\sigma^n \in K} \sigma^n$ oznacza sumę tak zorientowanych sympleksów (w zapisie łańcuchowym znaki są już uwzględnione w ich orientacjach). Każda wewnętrzna $(n-1)$-ściana należy dokładnie do dwóch n-sympleksów. Orientacje indukowane na ich wspólnej ścianie są przeciwne, więc odpowiadające współczynniki w ∂c się znoszą. W przypadku $\partial M = \varnothing$ otrzymujemy $\partial c = 0$. W przypadku brzegu pozostają tylko ściany leżące w ∂M, więc $\partial c \in C_{n-1}(\partial M)$: c jest cyklem względnym.

W punkcie x we wnętrzu n-sympleksu obraz c w grupie lokalnej jest generatorem o znaku określonym orientacją. Jeśli x leży na ścianie, mała gwiazda wokół x jest kulą złożoną z przyległych sympleksów; znoszenie się wewnętrznych ścian pokazuje, że ta sama suma daje generator również tam. W przypadku brzegu powyższy warunek lokalnego generatora nakładamy na punkty *wnętrza*. Dla $x \in \partial M$ zwykła grupa $H_n(M, M \setminus \{x\}; \mathbb{Z})$ jest zerowa: półkula i półkula z usuniętym środkiem płaskiej ściany są ściągalne (dla $n \ge 1$). Nie daje więc lokalnej orientacji brzegu. Zamiast tego brzeg klasy względnej spełnia $\partial[M, \partial M] = [\partial M]$ przy orientacji „zewnętrzna normalna najpierw”.

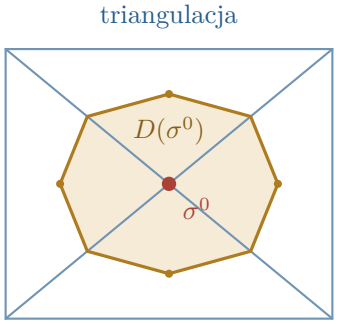
Wyjaśnijmy jedyność w przypadku zamkniętym. W każdym n-cyklu $z = \sum a_\sigma \sigma$ warunek $\partial z = 0$ przy wspólnej $(n-1)$-ścianie mówi, że współczynniki a_σ po obu jej stronach są równe (po uwzględnieniu orientacji). Graf sąsiedztwa najwyższych sympleksów jest spójny, gdy M jest spójna i $n \ge 1$: droga między ich wnętrzami może po małej perturbacji omijać szkielet wymiaru $n-2$ i kolejno przecinać ściany kowymiaru jeden. Wszystkie współczynniki są więc jednakowe. Ponieważ $C_{n+1}(K) = 0$, nie ma nietrywialnych symplicjalnych brzegów w stopniu n. Stąd $H_n(M; \mathbb{Z}) = \mathbb{Z}[c]$. Dla $n = 0$ spójna zamknięta rozmaitość jest punktem i wynik jest bezpośredni. W przypadku względnym to samo porównanie współczynników przez ściany wewnętrzne daje

jedyność klasy względnej. Homologia symplicjalna jest zgodna z singularną na triangulacji, jak pokazano w Rozdziale 8. Jeśli porzucimy znaki i pracujemy nad $\mathbb{F}_2$, dwie ściany sumują się do 0 bez wybierania orientacji. Ten sam argument daje klasę modulo 2. □

Przykład 21.2.2. Na S^2 suma zorientowanych trójkątów daje $[S^2]$. Na torusie analogiczna suma daje $[T^2]$. Dla wstęgi Möbiusa nie istnieje klasa $[M, \partial M]$ nad $\mathbb{Z}$ o lokalnych współczynnikach równych $+1$ w każdym punkcie: po obejściu rdzenia orientacja zmienia znak. Klasa modulo 2 istnieje. Poprawną wersję całkowitą uzyskamy z lokalnymi współczynnikami w Sekcji 21.5.

21.3 Dualność Poincarégo przez komórki dualne

Niech σ będzie k-sympleksem triangulacji K zamkniętej n-rozmaitości. Po podziale barycentrycznym bierzemy wszystkie małe sympleksy odpowiadające łańcuchom ścian $\sigma = \sigma_k \subsetneq \sigma_{k+1} \subsetneq \cdots \subsetneq \sigma_n$. Ich suma, z odpowiednimi ścianami, tworzy $(n-k)$-wymiarową *komórkę dualną* $D(\sigma)$. Komórka $D(\sigma)$ przecina σ w barycentrum i nie przecina wnętrza innych k-sympleksów. W triangulacji zgodnej ze strukturą gładką link σ jest sferą PL (dla najwyższych sympleksów komórki dualne są punktami), więc $D(\sigma)$ jest domkniętym dyskiem, a jego brzeg składa się z komórek dualnych do $(k+1)$-sympleksów zawierających σ.



Rysunek 21.1: Niebieskie trójkąty stanowią fragment triangulacji powierzchni. Złoty dysk jest komórką dualną do środkowego wierzchołka. Analogicznie krawędź ma dualną krawędź przecinającą ją poprzecznie.

Twierdzenie 21.3.1 (Dualność Poincarégo)**.** *Dla zamkniętej zorientowanej rozmaitości M^n i dowolnych abelowych grup współczynników G mnożenie kapowe przez klasę fundamentalną jest izomorfizmem*

$$\mathrm{PD} : H^k(M;G) \xrightarrow{\cong} H_{n-k}(M;G), \qquad \alpha \longmapsto [M] \frown \alpha.$$

Dla zwartej zorientowanej rozmaitości z brzegiem odpowiednie izomorfizmy to

$$H^k(M;G) \cong H_{n-k}(M, \partial M; G), \qquad H^k(M, \partial M; G) \cong H_{n-k}(M;G).$$

Przy $G = \mathbb{F}_2$ orientacja nie jest potrzebna.

Dowód. Najpierw niech $\partial M = \varnothing$. Wybieramy dualny rozkład komórkowy $K^\vee$. Ustalmy orientacje sympleksów. Dla $G = \mathbb{Z}$ niech $\sigma^\#$ będzie kochainem równym 1 na σ i 0 na pozostałych sympleksach tego wymiaru. Orientujemy $D(\sigma)$ tak, aby kolejność $(T\sigma, TD(\sigma))$ dawała orientację M. Dla dowolnej grupy abelowej przenosimy po prostu współczynnik $g \in G$ przy $\sigma^\#$ na tę komórkę. Daje to izomorfizmy grup

$$\mathcal{D}_k : C^k(K;G) \longrightarrow C_{n-k}(K^\vee;G).$$

Rachunek brzegu ma konkretny znak. Jeśli τ^{k+1} zawiera σ^k i u wskazuje od σ do wnętrza τ, to konwencja brzegu daje $\mathrm{or}(\tau) = [\tau : \sigma](-u, \mathrm{or}(\sigma))$. Po przeniesieniu u za k wektorów otrzymujemy $[\tau : \sigma](-1)^{k+1}(\mathrm{or}(\sigma), u)$. W komórce dualnej kierunek u wskazuje na zewnątrz ku ścianie $D(\tau)$. Porównanie orientacji M daje

$$\partial \mathcal{D}_k = (-1)^{k+1} \mathcal{D}_{k+1} \mathrm{d}. \tag{21.3.1}$$

Mimo znaku izomorfizmy $\mathcal{D}_k$ przenoszą kocykle na cykle i kobrzegi na brzegi, zatem dają $H^k(K;G) \cong H_{n-k}(K^\vee;G)$. Jeśli chcemy dosłownego izomorfizmu kompleksów z różniczkami d i ∂, należy użyć $(-1)^{k(k+1)/2}\mathcal{D}_k$. Zachowujemy jednak nieprzeskalowane $\mathcal{D}_k$, zgodne ze znakiem iloczynu kapowego w (21.1.1).

Wyjaśnijmy utożsamienie z $[M] \frown \alpha$. W podziale barycentrycznym obie konstrukcje dla $\sigma^\#$ mają nośnik w zamkniętej gwieździe σ. W stopniu $k = n$ dają punkty z tym samym współczynnikiem orientacji. Różnicę można wypełnić drogą w tej gwieździe. Schodząc kolejno z k do $k-1$, z obu wzorów na brzeg wynika, że różnica po odjęciu już zbudowanej homotopii na kościanach jest cyklem w tej samej gwieździe. Gwiazda jest ściągalna, więc cykl można wypełnić. To indukcja analogiczna do dowodu przemienności iloczynu kubkowego; daje homotopię po sprowadzeniu obu konstrukcji do wspólnego podziału. Wyznaczają więc to samo odwzorowanie na kohomologii, czyli PD. Oba rozkłady komórkowe obliczają homologię M.

Gdy $\partial M \neq \varnothing$, dualna komórka przy brzegu ma dodatkową ścianę *leżącą w brzegu*. Po przejściu do łańcuchów względnych ta ściana znika; daje to pierwszy z podanych izomorfizmów. Z kolei kochainy względne znikają na sympleksach brzegowych, więc ich dualne komórki nie mają obciętej ściany: tworzą podkompleks dualny L z komórek $D(\sigma)$ dla $\sigma \not\subset \partial M$. Ten podkompleks oblicza homologię M. Istotnie, $M \setminus \partial M$ cofa się na L: w każdym barycentrycznym sympleksie zerujemy wagi wierzchołków odpowiadających ścianom brzegowym i normalizujemy pozostałe. Ich suma jest dodatnia poza brzegiem, a homotopia przez liniową zmianę wag jest zgodna na ścianach. Inkluzja wnętrza do M jest równoważnością homotopijną, bo kołnierz pozwala odsunąć brzeg do wnętrza. Stąd drugi izomorfizm z homologii bezwzględnej. W każdym przypadku sprawdzenie (21.3.1) jest tym samym lokalnym rachunkiem incydencji; kołnierz z Twierdzenia 20.5.2 zapewnia standardowy model półprzestrzenny przy brzegu. Nad $\mathbb{F}_2$ wszystkie znaki orientacji znikają. □

Wniosek 21.3.2 (Parowanie i charakterystyka Eulera)**.** *Dla zamkniętej zorientowanej M^n i ciała $\mathbb{F}$ parowanie*

$$H^k(M;\mathbb{F}) \times H^{n-k}(M;\mathbb{F}) \longrightarrow \mathbb{F}, \qquad (\alpha, \beta) \longmapsto \langle \alpha \smile \beta, [M] \rangle$$

jest niezdegenerowane. Zatem $b_k = b_{n-k}$. Jeśli n jest nieparzyste, $\chi(M) = 0$.

Dowód. Dualność identyfikuje H^k z H_{n-k}. Nad ciałem każda niezerowa klasa homologii jest wykrywana przez pewną klasę kohomologii z H^{n-k}, bo dual przestrzeni wektorowej rozdziela punkty. Definicja iloczynu kapowego i kubkowego utożsamia tę ewaluację z podaną liczbą. Stąd parowanie jest niezdegenerowane i w skończonym wymiarze obie strony mają równe wymiary. Jeśli n jest nieparzyste, w sumie $\chi(M) = \sum_k (-1)^k b_k$ wyrazy dla k i $n-k$ mają przeciwne znaki, więc sumują się do zera. □

Przykład 21.3.3 (Torus i iloczyn dwóch sfer)**.** Na T^2 klasy $a, b \in H^1(T^2;\mathbb{Z})$, odpowiadające dwóm kierunkom, spełniają $\langle a \smile b, [T^2] \rangle = 1$ po ustaleniu orientacji. Na $S^2 \times S^2$ dwie klasy $A, B \in H_2(-;\mathbb{Z})$ reprezentowane przez $S^2 \times \{*\}$ i $\{*\} \times S^2$ mają macierz przecięć $\left(\begin{smallmatrix} 0 & 1 \\ 1 & 0 \end{smallmatrix}\right)$. Samych rang $H_2 \cong \mathbb{Z}^2$ nie wystarcza do odtworzenia tej macierzy.

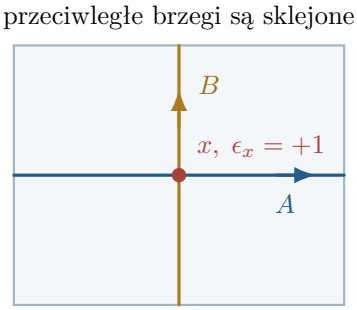
21.4 Liczba przecięcia: znak i niezmienniczość

Niech $A^p, B^{n-p} \subset M^n$ będą zamkniętymi zorientowanymi podrozmaitościami zamkniętej zorientowanej M. Po małej perturbacji, możliwej dzięki Twierdzeniu 19.4.3, możemy założyć $A \pitchfork B$. Przecięcie ma wymiar zero, a ze zwartości jest skończone.

Definicja 21.4.1 (Znak i liczba przecięcia)**.** Dla $x \in A \cap B$ kładziemy $\epsilon_x = +1$, jeżeli uporządkowana baza T_xA *a następnie* T_xB daje orientację T_xM, i $\epsilon_x = -1$ w przeciwnym przypadku. *Liczba przecięcia* to

$$I(A,B) = \sum_{x \in A \cap B} \epsilon_x .$$

Bez orientacji liczymy $\#(A \cap B) \pmod 2$.



Rysunek 21.2: Dwa podstawowe okręgi torusa przedstawionego jako kwadrat z parami sklejonych boków. W punkcie x kierunek poziomy, po nim pionowy, daje dodatnią orientację. Liczba przecięcia wynosi 1.

Twierdzenie 21.4.2 (Przecięcie i iloczyn kubkowy)**.** *Niech* $\alpha_A = \mathrm{PD}^{-1}(i_{A*}[A]) \in H^{n-p}(M;\mathbb{Z})$ *i* $\alpha_B = \mathrm{PD}^{-1}(i_{B*}[B]) \in H^p(M;\mathbb{Z})$. *Przy konwencji orientowania przecięcia z Definicji 21.4.1 zachodzi*

$$I(A,B) = \langle \alpha_A \smile \alpha_B, [M] \rangle . \tag{21.4.1}$$

Liczba zależy więc tylko od klas homologii obu podrozmaitości; jest niezmienna przy izotopii. Jeżeli jest niezerowa, żadna perturbacja w tych klasach nie może rozdzielić A i B.

Dowód. Użyjemy klasy Thoma z Twierdzenia 21.8.1. Jej zamieszczony niżej dowód jest komórkowy i nie korzysta z obecnego twierdzenia ani z klas w_i. Orientujemy normalne warunkiem „normalna, potem styczna”. Wycięcie w otoczeniu tubularnym daje klasy $u_A \in H^{n-p}(M, M \setminus A;\mathbb{Z})$ i $u_B \in H^p(M, M \setminus B;\mathbb{Z})$. Ich obrazy w kohomologii bezwzględnej są α_A, α_B: lokalnie oba opisy przypisują $+1$ dodatnio zorientowanemu normalnemu dyskowi, co jest konstrukcją dualnej klasy. Względny iloczyn ma nośnik na przecięciu, tzn.

$$u_A \smile u_B \in H^n(M, M \setminus (A \cap B);\mathbb{Z}).$$

Wynika to z wersji względnej wzoru kubkowego: po dostatecznym podziale sympleksy poza przecięciem leżą w jednym z dwóch otwartych dopełnień, gdzie odpowiedni czynnik znika. Wycięcie rozkłada ostatnią grupę na sumę grup $H^n(B_x, B_x \setminus \{x\};\mathbb{Z}) \cong \mathbb{Z}$ dla małych rozłącznych kul wokół punktów przecięcia. Ewaluacja na $[M]$ jest sumą tych lokalnych liczb. Jest to argument całkowity, nie tylko rachunek form rzeczywistych, który mógłby zgubić torsję.

Oto kontrola znaku. Niech $q = n - p$, a $(a_1, \dots, a_p)$ i $(b_1, \dots, b_q)$ będą dodatnimi bazami T_xA i T_xB. Załóżmy najpierw, że (a, b) orientuje T_xM dodatnio. Normalną do A orientujemy warunkiem $(\nu_A, a) > 0$, a normalną do B warunkiem $(\nu_B, b) > 0$. Wówczas odpowiadająca

pierwszej normalnej q-forma ω_A ma na bloku b wartość $(-1)^{pq}$, a p-forma ω_B drugiej normalnej ma na bloku a wartość $+1$. We wzorze na $(\omega_A \wedge \omega_B)(a,b)$ przestawienie bloku b przed a daje drugi czynnik $(-1)^{pq}$. Iloczyn dwóch znaków wynosi $+1$. Odwrócenie orientacji jednego z A, B zmienia zarówno ϵ_x, jak i tę wartość na -1. Zatem lokalna ewaluacja iloczynu jest ϵ_x. Po zsumowaniu po rozłącznych małych otoczeniach punktów przecięcia otrzymujemy (21.4.1). W powyższym rachunku formy ω_A, ω_B opisują orientacje liniowych bloków; całkowite generatory są ustalone przez klasy Thoma. Poza tymi kulami nie ma wkładu dzięki względnemu nośnikowi iloczynu. Ten sam dowód modulo 2 działa bez orientacji. Dla transwersalnych przecięć dodatniego wymiaru identyfikuje iloczyn klas Thoma z klasą Thoma sumy normalnych; daje analogiczną interpretację iloczynu jako klasy dualnej do przecięcia.

Prawa strona zależy jedynie od $i_{A*}[A]$ i $i_{B*}[B]$, ponieważ dualność Poincarégo i iloczyn kubkowy są określone na klasach. Izotopijne zanurzenia indukują homotopijne odwzorowania w M, więc dają tę samą klasę homologii. Gdyby obrazy dało się rozłączyć, suma po pustym przecięciu wynosiłaby 0. □

Przykład 21.4.3 (Krzywe na torusie)**.** W standardowej bazie $H_1(T^2;\mathbb{Z}) = \mathbb{Z}a \oplus \mathbb{Z}b$ krzywe o klasach $pa + qb$ i $ra + sb$ mają przecięcie algebraiczne

$$I\big((p,q),(r,s)\big) = \det \begin{pmatrix} p & r \\ q & s \end{pmatrix} = ps - qr.$$

Równość wynika z dwuliniowości iloczynu i z $I(a,b) = 1$, $I(b,a) = -1$, $I(a,a) = I(b,b) = 0$. Na przykład $(1,1)$ i $(1,-1)$ mają liczbę przecięcia -2: co najmniej dwa przecięcia, licząc bez znaków, są nieuniknione w tych klasach. Liczba 0 nie gwarantuje rozłączności konkretnych przedstawicieli: dodatnie i ujemne przecięcia mogą się znosić.

Uwaga 21.4.4 (Samoprzecięcie). Dwie kopie tej samej podrozmaitości nie są transwersalne, gdy się pokrywają. Jedną z nich przesuwamy w małym otoczeniu tubularnym za pomocą przekroju wiązki normalnej. Jeżeli przekrój ma zera, przesunięta kopia przecina pierwotną właśnie w tych zerach. Ta obserwacja prowadzi do klasy Eulera w Sekcji 21.8.

21.5 Lokalne współczynniki i brak orientacji

Zwykła grupa współczynników $\mathbb{Z}$ przyjmuje, że liczba $+1$ oznacza to samo w każdym punkcie. Na rozmaitości nieorientowalnej lokalny generator orientacji wraca po pewnej pętli jako -1. Trzeba więc przenosić współczynniki wraz z drogą.

Definicja 21.5.1 (System lokalny i system orientacji)**.** *System lokalny* grup abelowych $\mathcal{L}$ przypisuje punktowi x grupę $\mathcal{L}_x$, a drodze $\gamma : x \to y$ izomorfizm $T_\gamma : \mathcal{L}_x \to \mathcal{L}_y$, niezmienny przy homotopii drogi z ustalonymi końcami i zgodny ze składaniem dróg. Transport wzdłuż drogi stałej jest identycznością. Dla rozmaitości bez brzegu *system orientacji* $\mathcal{O}_M$ ma włókno

$$(\mathcal{O}_M)_x = H_n(M, M \setminus \{x\}; \mathbb{Z}) \cong \mathbb{Z};$$

transport lokalnej orientacji wzdłuż drogi jest mnożeniem przez $+1$ albo -1. Przy brzegu definiujemy system przez orientacje T_xM, równoważnie przez przedłużenie systemu z wnętrza w kołnierzu. Nie stosujemy tam powyższego wzoru na lokalną homologię.

W łańcuchach z $\mathcal{L}$ sympleks singularny ma współczynnik w grupie nad jego pierwszym wierzchołkiem. Przy operatorze brzegu współczynnik ściany pomijającej pierwszy wierzchołek przenosimy wzdłuż pierwszej krawędzi do nowego wierzchołka; dla pozostałych ścian punkt bazowy się nie zmienia. Znaki przemienne są takie jak w zwykłym operatorze ∂. Dwie drogi transportu przy dwukrotnym usunięciu wierzchołków są homotopijne w obrębie sympleksu, więc odpowiadające wyrazy w ∂^2 znoszą się parami. Tak powstaje $H_*(M;\mathcal{L})$.

Przykład 21.5.2 (Skręcone współczynniki na okręgu)**.** Niech $\mathcal{L}$ nad S^1 ma włókno $\mathbb{Z}$ i transport po pełnym okrążeniu równy -1. W komórkowym modelu okręgu jest jedna 0-komórka i jedna 1-komórka. Przy zwykłych współczynnikach końce krawędzi dają $\partial_1 = 1 - 1 = 0$. Tutaj jeden koniec wraca ze znakiem -1, więc $\partial_1 = (-1) - 1 = -2$. Stąd

$$H_1(S^1;\mathcal{L}) = 0, \qquad H_0(S^1;\mathcal{L}) = \mathbb{Z}/2.$$

Po przejściu do $\mathbb{F}_2$ macierz -2 staje się zerem i dostajemy zwykłe grupy okręgu.

Twierdzenie 21.5.3 (Dualność ze skręconymi współczynnikami)**.** *Dla spójnej zamkniętej n-rozmaitości, także nieorientowalnej, istnieje kanoniczna skręcona klasa fundamentalna $[M]_{\mathcal{O}} \in H_n(M;\mathcal{O}_M)$. Dla stałej abelowej grupy współczynników G otrzymujemy izomorfizm*

$$H^k(M;G) \cong H_{n-k}(M;\mathcal{O}_M \otimes G).$$

Dla zwartej rozmaitości z brzegiem używamy klasy $[M,\partial M]_{\mathcal{O}}$ i otrzymujemy obie wersje względne:

$$H^k(M;G) \cong H_{n-k}(M,\partial M;\mathcal{O}_M \otimes G), \qquad H^k(M,\partial M;G) \cong H_{n-k}(M;\mathcal{O}_M \otimes G).$$

Po zredukowaniu współczynników modulo 2 system orientacji staje się stały.

Dowód. W każdej małej mapie wybieramy generator lokalnej homologii. Gdy przechodzimy do sąsiedniej mapy, ewentualna zmiana orientacji o -1 zmienia jednocześnie współczynnik w $\mathcal{O}_M$ o -1. Iloczyn tych dwóch znaków jest $+1$. Suma wszystkich najwyższych sympleksów z tak dobranymi lokalnymi współczynnikami ma zatem zerowy brzeg na każdej wspólnej ścianie i daje $[M]_{\mathcal{O}}$. W małej kuli jej obraz jest lokalnym generatorem.

W dowodzie Twierdzenia 21.3.1 orientacja M była potrzebna do orientowania komórek $D(\sigma)$. Teraz orientujemy $D(\sigma)$ za pomocą lokalnego generatora $(\mathcal{O}_M)_x$. Przejście do sąsiedniej komórki wnosi dokładnie znak transportu w $\mathcal{O}_M$. Rachunek incydencji (21.3.1) pozostaje więc prawdziwy z tymi współczynnikami. Znowu dostajemy izomorfizmy przenoszące jądra i obrazy (ze znakiem zależnym od stopnia), a więc ich homologie. Na brzegu przechodzimy do łańcuchów względnych tak samo jak w dowodzie wersji zorientowanej. W $\mathbb{F}_2$ mamy $-1 = +1$, więc monodromia znika. □

Przykład 21.5.4 (Wstęga Möbiusa i płaszczyzna rzutowa)**.** Dla wstęgi Möbiusa W nie istnieje zwykła całkowita klasa $[W,\partial W]$ generująca orientację we wszystkich punktach, ale istnieje $[W,\partial W]_{\mathcal{O}} \in H_2(W,\partial W;\mathcal{O}_W) \cong \mathbb{Z}$. Dla $\mathbb{R}P^2$ mamy $H_2(\mathbb{R}P^2;\mathbb{Z}) = 0$, za to $H_2(\mathbb{R}P^2;\mathcal{O}) \cong \mathbb{Z}$ i $H_2(\mathbb{R}P^2;\mathbb{F}_2) \cong \mathbb{F}_2$. Lokalne współczynniki odzyskują orientację bez twierdzenia, że przestrzeń nagle stała się orientowalna.

21.6 Wiązki nad sferami i funkcje sklejające

Sferę S^m rozkładamy na dwa domknięte dyski D^m_+ i D^m_-, sklejone wzdłuż równika S^{m-1}. Wiązka wektorowa nad każdym dyskiem jest trywialna, ponieważ dysk jest ściągalny. Cała informacja o wiązce leży więc w *funkcji sklejającej* na równiku.

Twierdzenie 21.6.1 (Klasyfikacja przez równik)**.** *Dla $m \geq 2$ klasy izomorfizmu zorientowanych rzeczywistych wiązek rzędu $r \geq 1$ nad S^m odpowiadają klasom homotopii*

$$[S^{m-1}, SO(r)] \cong \pi_{m-1}(SO(r)).$$

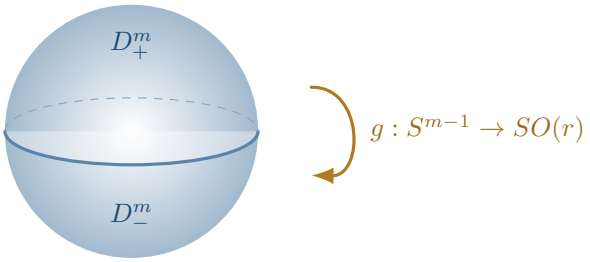
Funkcja $g : S^{m-1} \to SO(r)$ skleja dwie wiązki trywialne przez $(x,v)_+ \sim (x, g(x)v)_-$. Izomorfizmy w tej klasyfikacji zachowują orientację włókien. Dla niezorientowanych wiązek nad S^1 pozostają dwie klasy w każdym dodatnim rzędzie: wiązka trywialna i wiązka z jednym skręceniem typu Möbiusa.

Dowód. Wybierzmy metrykę na włóknach i dodatnio zorientowane ramy nad D^m_+ i D^m_-. Na ich wspólnym równiku ramy różnią się macierzą $g(x) \in SO(r)$. Otrzymujemy opisane sklejenie, więc każda wiązka jest takiej postaci. Wybieramy ramy gładkie, na przykład przez transport wzdłuż promieni dysków. Wtedy g jest gładka; klasy izomorfizmu topologicznego i gładkiego na sferze są tu zgodne przez gładkie przybliżenie.

Zmiana ramy na górnym lub dolnym dysku mnoży g z lewej lub prawej przez ograniczenie $h_\pm : D^m_\pm \to SO(r)$. Każde takie ograniczenie jest homotopijne do stałej: ściągamy dysk do punktu. Ponieważ $SO(r)$ jest spójna dla $r \geq 2$, stałe macierze można dalej połączyć z jednostkową. Zatem izomorfizm wiązek nie zmienia klasy homotopii g. Dla $r = 1$ grupa $SO(1)$ jest trywialna i wniosek również jest prawdziwy.

Odwrotnie, gdy g_t jest homotopią funkcji sklejających, wygładzamy ją względnie końców i sklejamy wiązki trywialne nad $D^m_\pm \times [0,1]$ za pomocą g_t. Powstaje wiązka nad $S^m \times [0,1]$. Wybierzmy na niej metrykę i koneksję (lokalne zwykłe pochodne można skleić podziałem jedności). Transport równoległy w kierunku od $t = 0$ do $t = 1$ zależy gładko od punktu sfery i daje izomorfizm wiązek na obu końcach. To dowodzi, że homotopijne funkcje sklejające dają izomorficzne wiązki. Stałość punktu bazowego nie zmienia klasyfikacji dla spójnej grupy $SO(r)$. Nie tylko odwzorowanie, ale i homotopię g_t można znormalizować: $\widetilde{g}_t(x) = g_t(x_0)^{-1} g_t(x)$ stale przyjmuje wartość I w x_0. To pokazuje injektywność i surjektywność przejścia od swobodnych do opartych klas homotopii.

Nad S^1 równik to dwa punkty S^0. Po zmianie ramy w jednym z dwóch łuków pozostaje tylko informacja, czy transport dookoła okręgu ma wyznacznik $+1$ czy -1. Składowa $GL_r(\mathbb{R})$ o wyznaczniku dodatnim jest spójna, podobnie ujemna; otrzymujemy dokładnie dwie klasy. □



dwie trywializacje spotykają się na równiku

Rysunek 21.3: Sfera jako dwa dyski z równikiem. W każdej połowie wiązka jest iloczynem; macierz $g(x)$ mówi, jak zidentyfikować włókna po obu stronach równika.

Przykład 21.6.2 (Dlaczego TS^2 jest skręcona)**.** Zorientowane wiązki płaszczyznowe nad S^2 opisuje $\pi_1(SO(2)) = \pi_1(S^1) = \mathbb{Z}$. Dla wiązki TS^2 wybierzmy stereograficzne zespolone współrzędne z i w na półkulach z przejściem $w = 1/z$ w pasie równika. Pochodna przejścia $\mathrm{d}w/\mathrm{d}z = -z^{-2}$ obraca ramę styczną dwukrotnie, gdy z okrąża równik raz. Funkcja sklejająca ma więc liczbę nawinięć ± 2 (znak zależy od wyboru orientacji równika). Wiązka TS^2 nie jest trywialna: na sferze nie istnieje globalna rama dwóch niezależnych pól stycznych.

Przykład 21.6.3 (Grupa obrotów w wymiarze trzy)**.** Dla zorientowanych wiązek rzędu 3 nad S^2 otrzymujemy $\pi_1(SO(3)) \cong \mathbb{Z}/2$: są dwie klasy. Opis podwójnego nakrycia $\mathrm{Spin}(3) \to SO(3)$ z Rozdziału 4 pokazuje, skąd bierze się dwójka. Pętla macierzy obrotu reprezentująca klasę niezerową podnosi się do drogi kończącej w drugim punkcie włókna nakrycia. Takiej funkcji sklejającej nie można podnieść do zamkniętej pętli w $\mathrm{Spin}(3)$; wiązka ma niezerowe $w_2 \in H^2(S^2; \mathbb{F}_2)$. Wiązka trywialna ma $w_2 = 0$.

21.7 Klasy charakterystyczne: przeszkody w kohomologii

Definicja 21.7.1 (Idea klasy charakterystycznej)**.** Klasą charakterystyczną wiązki $E \to M$ nazywamy przypisanie $E \mapsto c(E) \in H^k(M; G)$ zgodne z cofnięciem: $c(f^*E) = f^*c(E)$. Jeżeli wiązka jest trywialna, jej klasy dodatniego stopnia są zerowe, bo jest cofnięciem wiązki nad punktem. Odwrotna implikacja nie musi zachodzić: klasy charakterystyczne nie rozróżniają wszystkich wiązek.

Najbardziej elementarna przeszkoda dotyczy orientacji. Nie trzeba jej definiować przez ogólną teorię przestrzeni klasyfikujących.

Stwierdzenie 21.7.2 (Pierwsza klasa Stiefela–Whitneya)**.** *Niech $E \to M$ będzie rzeczywistą wiązką rzędu r. Wybierzmy trywializacje nad dobrym pokryciem $\{U_i\}$ i funkcje przejścia $g_{ij} : U_i \cap U_j \to GL_r(\mathbb{R})$. Znaki $\epsilon_{ij} = \operatorname{sgn}\det g_{ij} \in \{\pm 1\}$ wyznaczają klasę $w_1(E) \in H^1(M; \mathbb{F}_2)$. Mamy $w_1(E) = 0$ wtedy i tylko wtedy, gdy E jest orientowalna. Ponadto $w_1(E \oplus F) = w_1(E) + w_1(F)$.*

Dowód. Na potrójnym przecięciu $g_{ij}g_{jk} = g_{ik}$, a więc $\epsilon_{ij}\epsilon_{jk} = \epsilon_{ik}$. Po utożsamieniu -1 z $1 \in \mathbb{F}_2$ jest to równanie jednokocyklu. Aby utożsamić jego klasę z kohomologią singularną, można obyć się bez dodatkowego formalizmu: mnożymy znaki przejść wzdłuż pętli. Warunek na potrójnych przecięciach zapewnia niezmienniczość przy podziale i homotopii pętli, a więc homomorfizm $\pi_1(M) \to \mathbb{F}_2$. Utożsamienia $H_1(M;\mathbb{Z}) = \pi_1(M)_{\mathrm{ab}}$ i $H^1(M;\mathbb{F}_2) = \operatorname{Hom}(H_1(M;\mathbb{Z}), \mathbb{F}_2)$ dają żądaną klasę na każdej składowej. Gdy homomorfizm znika, transport orientacji z ustalonego punktu nie zależy od drogi i nadaje zgodne orientacje lokalnym ramom. Zmiana ramy na U_i mnoży każdy znak ϵ_{ij} przez znak nowej ramy na U_i i na U_j; odpowiada to dodaniu kobrzegu, więc klasa nie zależy od ram. Jeśli $w_1(E) = 0$, kocykl znaków jest kobrzegiem: zmieniamy orientacje lokalnych ram tak, aby wszystkie macierze przejścia miały dodatni wyznacznik. Ramy nadają wtedy spójną orientację wiązce. Odwrotnie spójna orientacja pozwala od początku wybrać takie ramy i daje kocykel zerowy. Macierz przejścia dla $E \oplus F$ jest blokowa, $\det(g_{ij} \oplus h_{ij}) = \det(g_{ij})\det(h_{ij})$; znaki mnożą się, a w $\mathbb{F}_2$ ich klasy się dodają. □

Przykład 21.7.3. Wiązka Möbiusa nad S^1 ma monodromię -1, więc w_1 jest niezerowym elementem $H^1(S^1;\mathbb{F}_2)$. Trywialna linia ma $w_1 = 0$. Dla rozmaitości $w_1(TM)$ jest dokładnie przeszkodą do jej orientowalności. Jest to również monodromia systemu $\mathcal{O}_M$ z Sekcji 21.5.

Twierdzenie 21.7.4 (Pełna rodzina w_i)**.** *Dla wiązki rzeczywistej E rzędu r istnieją klasy Stiefela–Whitneya*

$$w_i(E) \in H^i(M;\mathbb{F}_2), \quad 0 \le i \le r, \qquad w_0 = 1, \quad w_i = 0 \ (i > r),$$

naturalne przy cofnięciu. Dla sumy wiązek

$$w(E \oplus F) = w(E) \smile w(F), \qquad w(E) = 1 + w_1(E) + \cdots + w_r(E).$$

W szczególności dla zanurzenia $S \subset M$ z Rozdziału 20 zachodzi

$$w(TM|_S) = w(TS) \smile w(\nu(S, M)). \tag{21.7.1}$$

Dowód. Dla $r = 0$ przyjmujemy $w(E) = 1$; dalej $r \ge 1$. Korzystamy z niezależnej konstrukcji klasy Thoma i klasy e_2 poniżej. Dowód tej konstrukcji nie zakłada istnienia w_i; zależności wyjaśnia uwaga po Twierdzeniu 21.8.1.

Uzasadnijmy najpierw potrzebny rachunek we włóknie. Na $\mathbb{R}P^m$ niech $x = w_1(\lambda)$ dla linii tautologicznej. Ograniczenie ustalonego funkcjonału liniowego do λ jest przekrojem λ^*, którego zera tworzą hiperpłaszczyznę $\mathbb{R}P^{m-1}$. Parzystość przecięć pętli z tą hiperpłaszczyzną jest zmianą znaku jej podniesienia do jednostkowych wektorów linii: funkcjonał zmienia znak przy każdym

poprzecznym przejściu przez zero. Jest to dokładnie monodromia w_1, więc hiperpłaszczyzna jest dualna do x. j niezależnych hiperpłaszczyzn przecina się transwersalnie, a w $\mathbb{R}P^j$ ich przecięcie jest jednym punktem. Modułowa wersja rachunku przecięć daje $\langle x^j, [\mathbb{R}P^j]_2\rangle = 1$. Z obliczenia komórkowego grup $\mathbb{R}P^m$ wiemy, że każda grupa $H^j(-;\mathbb{F}_2)$ dla $0 \le j \le m$ jest jednowymiarowa. Zatem $1, x, \dots, x^m$ są bazą, a $x^{m+1} = 0$ z przyczyn wymiarowych.

Podajemy konstrukcję algebraiczną klas ogólnej wiązki. Niech $\pi : P(E) \to M$ będzie wiązką prostych we włóknach E, $\lambda \to P(E)$ wiązką tautologiczną, a $x = w_1(\lambda) \in H^1(P(E);\mathbb{F}_2)$. Włóknem $P(E)$ jest $\mathbb{R}P^{r-1}$; klasy $1, x, \dots, x^{r-1}$ po ograniczeniu do każdego włókna tworzą bazę jego kohomologii. Stąd

$$H^*(P(E);\mathbb{F}_2) = \bigoplus_{j=0}^{r-1} H^*(M;\mathbb{F}_2)\, x^j$$

jako moduł nad $H^*(M)$. Rozpiszmy ten szczególny przypadek twierdzenia Leraya–Hirscha. Wybieramy triangulację M i oznaczamy przez $M^{(d)}$ jej d-szkielet, z $M^{(-1)} = \varnothing$. Dla pary podkompleksów $A \subset B$ i $P_B = \pi^{-1}(B)$, $P_A = \pi^{-1}(A)$ definiujemy łączne odwzorowanie

$$\Phi^q_{B,A} : \bigoplus_{j=0}^{r-1} H^{q-j}(B, A;\mathbb{F}_2) \longrightarrow H^q(P_B, P_A;\mathbb{F}_2), \qquad (a_j)_j \longmapsto \sum_{j=0}^{r-1} \pi^* a_j \smile x^j.$$

Klasy x^j po prawej ograniczamy do P_B; używamy iloczynu klasy względnej z klasą bezwzględną. Grupy w stopniach ujemnych są zerowe. Izomorfizmem ma być cała suma $\Phi^q_{B,A}$, nie każdy jej składnik.

Dla $B = M^{(d)}$ i $A = M^{(d-1)}$ wycinanie rozdziela rachunek względny na dołączane d-komórki. Nad dyskiem charakterystycznym każdej z nich cofnięta wiązka jest trywialna, więc otrzymujemy parę

$$(D^d \times \mathbb{R}P^{r-1},\ \partial D^d \times \mathbb{R}P^{r-1}).$$

Jej kohomologia w stopniu q to $H^{q-d}(\mathbb{R}P^{r-1};\mathbb{F}_2)$: w względnym kompleksie komórkowym jedyna komórka dysku modulo brzeg przesuwa stopnie kompleksu włókna o d. Iloczyn generatora $H^d(D^d, \partial D^d;\mathbb{F}_2)$ z x^j odpowiada elementowi x^j tej grupy w stopniu $q = d + j$. Sprawdzona baza $1, x, \dots, x^{r-1}$ dowodzi zatem, że $\Phi^q_{M^{(d)},M^{(d-1)}}$ jest izomorfizmem. Przy nieskończenie wielu komórkach grupy kochainów są produktami; suma po j ma jednak tylko r składników, więc komutuje z tymi produktami i ten sam wniosek pozostaje prawdziwy.

Dla kolejnych szkieletów i ich przeciwobrazów odwzorowania Φ tworzą przemienny diagram długich ciągów dokładnych par. Zgodność z ograniczeniami wynika z naturalności iloczynu kubkowego, a z homomorfizmami łączącymi — z reguły Leibniza dla zamkniętych reprezentantów x^j. Nad $\mathbb{F}_2$ nie występuje dodatkowy znak. Zaczynając od pustego szkieletu, stosujemy lemat o pięciu odwzorowaniach: izomorfizm na poprzednim szkielecie i izomorfizm względny dają izomorfizm na następnym szkielecie. Triangulacja ma wymiar $\dim M$, więc także dla niezwartych M indukcja kończy się po skończenie wielu stopniach. Dla $A = \varnothing$ otrzymujemy zapowiedziany rozkład modułu. Ogólną wersję tego argumentu podaje Hatcher, *Algebraic Topology*, Twierdzenie 4D.1.

Klasa x^r ma wobec tej bazy jednoznaczny rozkład. Zapisujemy go w postaci

$$x^r + \pi^* w_1(E) x^{r-1} + \cdots + \pi^* w_r(E) = 0.$$

Współczynnik w_i ma stopień i, bo każdy wyraz ma całkowity stopień r. Jednoznaczność rozkładu i zgodność konstrukcji $P(E)$ z cofnięciem dają naturalność. Przy rozszczepieniu $E = L_1 \oplus \cdots \oplus L_r$ relacja włóknowa ma czynniki $\prod_j (x + w_1(L_j))$. Oto bezpośrednie sprawdzenie. Nad $P(E)$ tautologiczna linia λ wchodzi do $\pi^* E$, więc homomorfizm inkluzji jest nigdzie nieznikającym przekrojem wiązki $\mathrm{Hom}(\lambda, \pi^* E) = \bigoplus_j (\lambda^* \otimes \pi^* L_j)$. Jej klasa Eulera modulo 2, oznaczana niezależnie

przez e_2, jest zatem zerowa na mocy Twierdzenia 21.8.1 i uwagi o redukcji modulo 2 w Sekcji 21.8. Klasa Eulera modulo 2 linii jest jej w_1, a $w_1(\lambda^* \otimes L_j) = x + w_1(L_j)$ z rachunku znaków funkcji przejścia. Multiplikatywność klasy Eulera sumy daje właśnie $\prod_j (x + w_1(L_j)) = 0$. Porównanie współczynników daje $w(E) = \prod_j (1 + w_1(L_j))$.

Każdą wiązkę można rozszczepić po cofnięciu do wiązki pełnych flag: po kolei wybieramy prostą w E i w ortogonalnym do niej dopełnieniu. W każdym takim kroku powyższy rozkład modułowy zawiera składnik 1, więc cofnięcie na kohomologiach jest injektywne. Wzór iloczynowy sprawdzony po rozszczepieniu schodzi zatem na M i daje twierdzenie o sumie Whitneya. Dla dwóch wiązek najpierw rozszczepiamy E, potem cofniętą F; oba cofnięcia są injektywne, a obie wiązki rozszczepione. Współczynnik stopnia jeden jest $\sum_j w_1(L_j)$, czyli wcześniej zdefiniowany znak wyznacznika przejść. Nowa definicja w_1 jest więc zgodna z poprzednią. Wreszcie $TM|_S \cong TS \oplus \nu$ z Stwierdzenia 20.2.2; podstawienie do wzoru sumy daje (21.7.1). $\square$

Uwaga 21.7.5 (Gdzie już pojawiło się w_2?). W Rozdziale 4 skonstruowaliśmy $w_2(E)$ dla zorientowanej wiązki jako przeszkodę podniesienia funkcji przejścia z $SO(r)$ do $\mathrm{Spin}(r)$. Wyjaśnijmy zgodność z klasą stopnia dwa z Twierdzenia 21.7.4. Wystarczy ograniczyć się do 2-szkieletu bazy: restrykcja $H^2(M;\mathbb{F}_2)$ do tego szkieletu jest injektywna, ponieważ grupy kochainów i kobrzegi w stopniach $1, 2$ są te same. Na kompleksie wymiaru dwa wiązka rzędu co najmniej trzy ma niezerowy przekrój: wybieramy go na wierzchołkach, przedłużamy po krawędziach przez spójność sfery włókna, a po 2-komórkach przez jej jednospójność. Powtarzając, rozszczepiamy zorientowaną wiązkę na trywialną część i zorientowaną płaszczyznę L. Wzór sumy daje $w_2(E) = w_2(L) = e(L) \bmod 2$. Wybierzmy zorientowaną ramę L na 1-szkielecie; jest to możliwe dzięki spójności $SO(2)$. Na 2-komórce, względem tej ustalonej ramy brzegowej, ostatnia liczba jest parzystością liczby nawinięć funkcji $SO(2)$, bo to stopień przeszkody przedłużenia niezerowego przekroju. Ta sama parzystość jest przeszkodą podniesienia pętli do $\mathrm{Spin}(2) \to SO(2)$, nakrycia $z \mapsto z^2$. Po dodaniu kierunków trywialnych obrót o 2π nadal podnosi się do drogi od 1 do -1 w grupie Spin. Oba kocykle na 2-komórkach są więc równe, co dowodzi zgodności klas. Dla rzędu jeden obie są zerowe. Z warunku (21.7.1) wynika, że jeśli $\nu(S, M)$ ma obramowanie, to $w(\nu) = 1$ i $w(TM)|_S = w(TS)$. To prosty test konieczny dla niektórych zanurzeń obramowanych.

Uwaga 21.7.6 (Klasy zespolone i Pontriagina). Dla zespolonej wiązki rzędu r analogiczna konstrukcja z $\mathbb{C}P^{r-1}$ i klasą pierwszą tautologicznej linii o stopniu 2 daje klasy Cherna $c_i(E) \in H^{2i}(M;\mathbb{Z})$. Dla wiązki rzeczywistej klasy Pontriagina definiuje się przez $p_i(E) = (-1)^i c_{2i}(E \otimes_{\mathbb{R}} \mathbb{C}) \in H^{4i}(M;\mathbb{Z})$. Ich naturalność i zgodność ze stabilnym dołożeniem wiązki trywialnej wynikają z konstrukcji projektowej. W tym rozdziale szczegółowo stosujemy w_1, w_2 i klasę Eulera; pełny rachunek klas c_i, p_i oraz konstrukcja Cherna–Weila wykraczają poza niezbędne przygotowanie do chirurgii.

21.8 Klasa Eulera, zera pól i samoprzecięcie

Twierdzenie 21.8.1 (Klasa Thoma i klasa Eulera)**.** *Niech $E \to M$ będzie zorientowaną rzeczywistą wiązką rzędu r z metryką we włóknach. Dla jej wiązki dysków $D(E)$ i wiązki sfer $S(E)$ istnieje klasa*

$$u_E \in H^r(D(E), S(E); \mathbb{Z}),$$

której ograniczenie do każdego włókna (D^r, S^{r-1}) jest dodatnim generatorem. Iloczyn z u_E daje izomorfizm Thoma

$$H^j(M;\mathbb{Z}) \xrightarrow{\cong} H^{j+r}(D(E), S(E); \mathbb{Z}).$$

Jeśli $s_0 : M \to D(E)$ jest przekrojem zerowym, to klasa Eulera $e(E) = s_0^* u_E \in H^r(M;\mathbb{Z})$ *jest naturalna przy cofnięciu i spełnia $e(E \oplus F) = e(E) \smile e(F)$ dla zorientowanych wiązek. Istnienie nigdzie nieznikającego przekroju pociąga $e(E) = 0$.*

W zapisie $s_0^* u_E$ najpierw zapominamy o względności, przechodząc z $H^r(D(E), S(E))$ do $H^r(D(E))$, a potem cofamy klasę przez s_0. Równoważnym modelem klasy Thoma jest $H^r(E, E \setminus 0)$: wycięcie i radialne cofnięcie włókien utożsamiają go z modelem dyskowym. Ten model pozwala cofać klasę przez przekrój jako klasę pary $(M, M \setminus Z(s))$.

Dowód. Nad komórką bazy wiązka jest trywialna, zatem odpowiednia para w przestrzeni całkowitej jest iloczynem tej komórki z parą (D^r, S^{r-1}). Włóknowa grupa względna w stopniu r jest $\mathbb{Z}$; orientacja określa jej dodatni generator. Na przecięciu sąsiednich trywializacji macierz przejścia ma dodatni wyznacznik, więc przenosi ten generator w niego samego. Sama zgodność lokalnych generatorów nie jest jeszcze dowodem istnienia globalnej klasy. Skonstruujmy ją w kompleksie komórkowym pary $(D(E), S(E))$. Nad każdą d-komórką bazy dołączamy względną komórkę $D^d \times D^r$ wymiaru $d+r$; część $D^d \times S^{r-1}$ leży już w $S(E)$, a $\partial D^d \times D^r$ nad wcześniejszym szkieletem. Orientujemy iloczyn kolejnością „baza, włókno". Liczby incydencji są tymi z bazy pomnożonymi przez stopień transportu orientacji włókna, czyli $+1$. Kompleks względny kochainów jest więc kompleksem bazy przesuniętym o r. Stały kocykl 1 w stopniu zero bazy wyznacza kocykl stopnia r pary, którego klasa to u_E. Jest to jedyna klasa o wymaganych ograniczeniach: pod tym przesunięciem odpowiada funkcji na składowych bazy o wartości 1. Dla niezwartej bazy używamy produktów współczynników po komórkach; indukcja po szkieletach ma skończenie wiele etapów, gdyż rozmaitość ma skończony wymiar.

Teraz sprawdzamy, że mnożenie przez tę już skonstruowaną klasę daje deklarowany izomorfizm: na dołączanej d-komórce relatywne grupy pary wiązki są przesunięciem o r relatywnych grup (D^d, S^{d-1}). Mnożenie przez lokalny generator jest tam izomorfizmem. W długich ciągach dokładnych dla starego szkieletu i nowej komórki wszystkie kwadraty są naturalne; indukcja i lemat o pięciu odwzorowaniach dają izomorfizm w każdym stopniu. Mnożenie ma dokładnie postać $a \mapsto \pi^* a \smile u_E$; na każdej komórce jest opisanym przesunięciem przez włóknowy generator. Dla rzędu zero przyjmujemy $S(E) = \varnothing$ i $u_E = e(E) = 1$.

Cofnięcie wiązki przenosi orientacje i włóknowe generatory, więc przenosi u_E na klasę Thoma cofniętej wiązki. Po ograniczeniu do przekroju zerowego daje to naturalność $e(f^*E) = f^* e(E)$. Dla sumy $E \oplus F$ możemy użyć dysku w normie maksimum, czyli $D(E) \times_M D(F)$. Jego brzeg to $(S(E) \times_M D(F)) \cup (D(E) \times_M S(F))$. Cofamy obie klasy Thoma przez rzuty i bierzemy ich względny iloczyn kubkowy. W każdym włóknie jest on dodatnim generatorem w orientacji „E, potem F", więc z jedyności jest klasą Thoma sumy. Zmiana normy przez radialny homeomorfizm nie zmienia klasy. Cofnięcie do zera daje $e(E \oplus F) = e(E) \smile e(F)$.

Jeśli s nigdzie nie znika, po unormowaniu jest odwzorowaniem $M \to S(E)$. Inkluzja $S(E) \subset D(E)$ powoduje $s^* u_E = 0$, bo względna klasa na $S(E)$ znika. Przekroje s_0 i s są homotopijne jako odwzorowania $M \to D(E)$ przez $t \mapsto ts$. Ich cofnięcia klasy u_E są więc równe; $e(E) = 0$. □

Uwaga 21.8.2 (Wersja modulo 2 i brak błędnego koła). Powyższy dowód nie używa klas Stiefela–Whitneya. Z $\mathbb{F}_2$ działa dla każdej wiązki, ponieważ zmiana orientacji włókna nie zmienia generatora. Oznaczmy otrzymaną klasę Eulera modulo 2 przez $e_2(E)$. Jest naturalna, multiplikatywna i znika przy istnieniu niezerowego przekroju, z dokładnie tych samych dowodów.

Dla linii L mamy $e_2(L) = w_1(L)$. Wybierzmy niezerowe wartości przekroju w wierzchołkach triangulacji i przedłużmy go ogólnie na krawędzie. Parzystość zer na krawędzi wynosi 1 dokładnie wtedy, gdy wartości na końcach mają przeciwne znaki po transporcie w trywializacji tej krawędzi. Jest to kocykl zmiany orientacji, czyli $w_1(L)$; zmiana wartości przy wierzchołku dodaje kobrzeg. Z drugiej strony te same parzystości są lokalnymi stopniami cofnięcia klasy Thoma, więc reprezentują $e_2(L)$.

Te własności e_2 wystarczają do dowodu wzoru w Twierdzeniu 21.7.4; nie zakłada on z góry równości $e_2 = w_r$. Dopiero po rozszczepieniu E na linie otrzymujemy $e_2(E) = \prod_j w_1(L_j) = w_r(E)$. Injektywność cofnięcia do wiązki flag przenosi tę równość na bazę. Dla wiązki zorientowanej re-

dukcja całkowitej klasy Thoma jest klasą Thoma modulo 2, więc również $e(E) \bmod 2 = w_r(E)$.

Twierdzenie 21.8.3 (Zera przekroju reprezentują klasę Eulera)**.** *Niech M^n będzie zamknięta i zorientowana, a $E \to M$ zorientowana rzędu $r \le n$. Dla przekroju s transwersalnego do zera zbiór $Z(s)$ jest zorientowaną $(n-r)$-podrozmaitością i*

$$\mathrm{PD}^{-1}[Z(s)] = e(E).$$

Jeśli $r = n$, zera są skończone i

$$\langle e(E), [M] \rangle = \sum_{x \in Z(s)} \operatorname{sgn} \det(\mathrm{D}_x s). \tag{21.8.1}$$

W bazach zgodnych z orientacją znak nie zależy od wyboru trywializacji.

Dowód. Regularność wynika z Twierdzenia 19.5.1. Pochodna pionowa w zerze daje izomorfizm $\nu(Z(s), M) \cong E|_{Z(s)}$. Nadajemy normalnej orientację przeniesioną z E, a $Z(s)$ orientujemy warunkiem „normalna, potem styczna daje orientację M”.

W modelu $H^r(E, E \setminus 0)$ cofnięcie przez s jest klasą $s^* u_E \in H^r(M, M \setminus Z(s))$. W małej trywializacji ograniczenie s do normalnego dysku ma w zerze odwracalną różniczkę o dodatnim wyznaczniku, więc jego lokalny stopień jest $+1$. Wycięcie i otoczenie tubularne identyfikują $s^* u_E$ z klasą Thoma normalnej do $Z(s)$. Jej obraz w kohomologii bezwzględnej jest klasą dualną do $Z(s)$: na każdej normalnej komórce ocenia $+1$, zgodnie z orientacjami w dowodzie dualności. Liniowa homotopia $s \simeq s_0$ w E pokazuje, że ten sam obraz jest $e(E)$.

Dla $r = n$ każdy punkt zerowy jest zorientowaną 0-komórką o współczynniku $\operatorname{sgn} \det \mathrm{D}_x s$. Zwartość i izolacja zer dają ich skończoność. Ewaluacja na klasie fundamentalnej sumuje te współczynniki, co daje (21.8.1). □

Wniosek 21.8.4 (Samoprzecięcie)**.** *Niech M^{2k} będzie zorientowana, a $S^k \subset M$ zamknięta i zorientowana. W tym wzorze nadajemy wiązce normalnej orientację przez kolejność* styczna do S, potem normalna*, zgodną z orientacją M. Wówczas to liczba przecięcia S z małą przesuniętą kopią wynosi*

$$I(S, S) = \langle e(\nu(S, M)), [S] \rangle.$$

Dowód. W otoczeniu tubularnym zapisujemy S jako przekrój zerowy ν. Wybierzmy mały przekrój s transwersalny do zera i przesuńmy S do jego wykresu. Wykres przecina przekrój zerowy dokładnie dla $s(x) = 0$. W bazach „styczna, normalna” kolumny baz przekroju zerowego i wykresu tworzą macierz $\left(\begin{smallmatrix} I & I \\ 0 & \mathrm{D}_x s \end{smallmatrix}\right)$. Jej wyznacznik to $\det \mathrm{D}_x s$, więc znak przecięcia jest lokalnym stopniem s. Ten rachunek ustala potrzebną orientację normalnej; nie można jej odwrócić dowolnie, zachowując ten sam zapis wzoru. Suma znaków to $\langle e(\nu), [S] \rangle$ z (21.8.1). □

Przykład 21.8.5. Dla $S^2 \times \{p\} \subset S^2 \times S^2$ wiązka normalna jest trywialna: jej włókno to stała przestrzeń $T_p S^2$. Istnieje niezerowy stały przekrój, więc $I(S, S) = 0$. Dwie różne sfery $S^2 \times \{p\}$ i $\{q\} \times S^2$ przecinają się jednak w jednym punkcie z liczbą przecięcia 1.

21.9 Twierdzenie Poincarégo–Hopfa

Definicja 21.9.1 (Indeks zera pola)**.** Jeżeli pole X na n-rozmaitości ma izolowane zero x, wybierzmy małą kulę w mapie wokół x oraz trywializację stycznej przez różniczkę tej mapy. *Indeks* $\operatorname{ind}_x X$ jest stopniem odwzorowania $X/|X| : S^{n-1} \to S^{n-1}$, dla $n \ge 1$. Zmiana mapy zmienia jednocześnie orientację dziedziny i współrzędnych wektora, więc dwa znaki się mnożą do $+1$. Zmienną macierz przejścia na małej kuli można zdeformować do jej wartości w środku, nie

przechodząc przez macierze osobliwe. Indeks nie zależy więc od mapy ani od lokalnej orientacji. Dla $n = 1$ stopień liczymy na $\widetilde{H}_0(S^0)$; dla $n = 0$ umownie każdy punkt zerowy ma indeks 1. Jeśli $\mathrm{D}_x X$ jest odwracalna, $\operatorname{ind}_x X = \operatorname{sgn}\det \mathrm{D}_x X$: na małej sferze $X(y) = \mathrm{D}_x X(y-x) + o(|y-x|)$ jest homotopijne do odwracalnej odwzorowania liniowego.

Twierdzenie 21.9.2 (Poincaré–Hopf)**.** *Jeśli M jest zamkniętą zorientowaną rozmaitością, a pole X ma izolowane zera, to*

$$\sum_{x:X(x)=0} \operatorname{ind}_x X = \langle e(TM), [M]\rangle = \chi(M). \tag{21.9.1}$$

W szczególności $\chi(M) \neq 0$ uniemożliwia istnienie nigdzie nieznikającego pola stycznego.

Dowód. Dla $n = 0$ obie strony liczą punkty M. Dalej przyjmujemy $n \geq 1$. *Od indeksów do klasy Eulera.* Przy zerze nieosobliwym pierwsza równość jest dokładnie Twierdzeniem 21.8.3 dla $E = TM$. Dla zera izolowanego, lecz osobliwego, wybieramy kulę bez zer na brzegu. Mała perturbacja pola wewnątrz kuli, niezmieniająca go przy brzegu, może być transwersalna do przekroju zerowego na mocy Rozdziału 19. Stopień odwzorowania $X/|X|$ na brzegu nie zmienia się w tej homotopii; równa się sumie znaków nowo powstałych zer wewnątrz. Zwartość M pozwala wykonać ten zabieg w skończenie wielu rozłącznych kulach.

Dlaczego suma jest $\chi(M)$? Przypomnijmy i uzasadnijmy potrzebną postać zasady Lefschetza. Dla gładkiego $f : M \to M$ o skończenie wielu nieosobliwych punktach stałych zachodzi

$$\sum_{f(x)=x} \operatorname{sgn}\det(I - \mathrm{D}_x f) = \sum_j (-1)^j \operatorname{tr}(f_* : H_j(M;\mathbb{Q}) \to H_j(M;\mathbb{Q})). \tag{21.9.2}$$

Nadajemy grafowi Γ_f i przekątnej Δ orientacje przeniesione z M, a $M \times M$ orientację produktową. W punkcie stałym, w tej kolejności płatów, macierz baz stycznych wynosi

$$\begin{pmatrix} I & I \\ \mathrm{D}_x f & I \end{pmatrix}, \qquad \det = \det(I - \mathrm{D}_x f).$$

Lewa strona (21.9.2) jest więc $I(\Gamma_f, \Delta)$.

Obliczymy tę liczbę bez pomijania znaku globalnego. Wybierzmy bazę a_{ij} przestrzeni $H^i(M;\mathbb{Q})$ i bazę dualną $b_{ij} \in H^{n-i}(M;\mathbb{Q})$, tzn. $\langle a_{ij} \smile b_{i\ell}, [M]\rangle = \delta_{j\ell}$. Przez $u \times v$ oznaczamy $\mathrm{pr}_1^* u \smile \mathrm{pr}_2^* v$. Te iloczyny tworzą bazę kohomologii produktu nad $\mathbb{Q}$. W tym szczególnym przypadku formułę Künnetha można uzasadnić bez torsji: komórki produktu mają brzeg $\partial(e^p \times e^q) = \partial e^p \times e^q + (-1)^p e^p \times \partial e^q$. Ich kompleks jest tensorem kompleksów czynników. Nad ciałem każdy skończony kompleks rozkłada się na homologię z zerową różniczką i dwuwyrazowe kompleksy izomorfizmów; tensor z każdym z tych ostatnich jest ściągalny. Pozostaje tensor homologii, a po dualizacji podana baza kohomologii.

Klasa dualna przekątnej ma postać

$$\alpha_\Delta = \sum_{i,j} (-1)^{ni}\, b_{ij} \times a_{ij}.$$

Sprawdzamy ją przez ewaluację na bazowych iloczynach: z definicji dualności $\langle \alpha_\Delta \smile (u \times v), [M \times M]\rangle = \langle u \smile v, [M]\rangle$. Dla $|u| = i$, $|v| = n - i$ znak przestawienia czynników w iloczynie $(b_{ij} \times a_{ij}) \smile (u \times v)$ wynosi $(-1)^{i^2}$, a zamiana kolejności b_{ij}, u daje $(-1)^{i(n-i)}$. Razem z $(-1)^{ni}$ jest to $+1$. Dualność baz daje żądaną ewaluację; w innych stopniach wkład jest zerowy. Niezdegenerowanie parowania w produkcie dowodzi wzoru na α_Δ.

Teraz ograniczamy tę klasę do grafu, gdzie pr_1 jest identycznością, a $\mathrm{pr}_2 = f$:

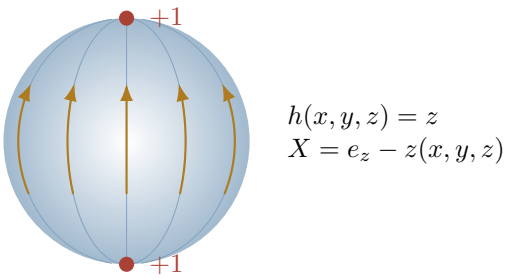
$$\begin{aligned} I(\Gamma_f, \Delta) &= \langle \alpha_\Delta, [\Gamma_f] \rangle \\ &= \sum_{i,j} (-1)^{ni} \langle b_{ij} \smile f^* a_{ij}, [M] \rangle \\ &= \sum_i (-1)^i \operatorname{tr}(f^* : H^i(M;\mathbb{Q}) \to H^i(M;\mathbb{Q})). \end{aligned}$$

Ostatni znak wynika z $ni + i(n-i) \equiv i \pmod 2$. Sumowanie po j wybiera elementy diagonalne macierzy f^*. Ewaluacja identyfikuje f^* z dualnym odwzorowaniem do f_*, więc ich ślady są równe. Otrzymujemy (21.9.2).

Teraz przyjmijmy, że zera X są nieosobliwe, i niech $f = \Phi_{-t}$ będzie przepływem X przez bardzo mały czas $-t < 0$. Punkty zerowe są punktami stałymi. Poza małymi kulami otaczającymi zera norma X ma dodatnie minimum, więc z rozwinięcia $\Phi_{-t}(y) = y - tX(y) + O(t^2)$ jednolitego na tym zbiorze nie ma innych punktów stałych dla małego t. W mapie przy zerze wyrażenie $F(y,t) = (y - \Phi_{-t}(y))/t$ przedłuża się gładko do $t = 0$ przez $F(y,0) = X(y)$; wynika to ze wzoru całkowego na przyrost przepływu. Ponieważ $\mathrm{D}_y F(x,0) = \mathrm{D}_x X$ jest odwracalna, twierdzenie o funkcji uwikłanej z parametrem t daje jedyne rozwiązanie w jednym ustalonym otoczeniu x. Jest nim stale x. Zmniejszamy kule do tych otoczeń, a ich zwarte dopełnienie obejmuje także pozostałe pierścienie wokół zer. Poprzednie jednolite oszacowanie wyklucza tam punkty stałe. W punkcie zerowym

$$I - \mathrm{D}_x \Phi_{-t} = t \mathrm{D}_x X + O(t^2),$$

zatem znak wyznacznika to $\operatorname{ind}_x X$. Przepływ jest homotopijny do identyczności, więc f_* jest identycznością na wszystkich $H_j(M;\mathbb{Q})$. Prawa strona (21.9.2) wynosi $\sum_j (-1)^j b_j = \chi(M)$. Otrzymujemy drugą równość (21.9.1). Perturbacja z początku dowodu rozszerza ją na zera osobliwe. □



Rysunek 21.4: Gradient wysokości na S^2 ma dwa zera: na biegunie dolnym i górnym. Oba mają indeks $+1$, więc suma indeksów i $\chi(S^2)$ są równe 2. Złote łuki pokazują rzuty trajektorii gradientu w metryce standardowej: biegną po południkach od minimum do maksimum. Promień rysunku jest tylko skalą graficzną.

Przykład 21.9.3 (Sfera i torus)**.** Na S^2 gradient funkcji wysokości ma minimum i maksimum. Lokalne macierze pochodnej pola są odpowiednio dodatnio i ujemnie określone w dwóch wymiarach, ale oba wyznaczniki są dodatnie: $1 + 1 = \chi(S^2) = 2$. Na torusie T^2 istnieje nigdzie nieznikające pole styczne wzdłuż jednego czynnika S^1, więc $e(TT^2) = 0$ i $\chi(T^2) = 0$. To dopowiada topologiczną treść wzoru Gaussa–Bonneta z Rozdziału 14.

21.10 Forma przecięcia i przygotowanie do chirurgii

Gdy $n = 2k$, dwie k-podrozmaitości przecinają się w punktach. Ich liczba przecięcia tworzy na środkowej homologii formę dwuliniową. Część torsyjna nie jest wykrywana przez wartości

całkowite tej formy, więc najpierw ją usuwamy.

Twierdzenie 21.10.1 (Forma przecięcia)**.** *Dla zamkniętej zorientowanej M^{2k} parowanie*

$$Q_M : \frac{H_k(M;\mathbb{Z})}{\mathrm{Tor}} \times \frac{H_k(M;\mathbb{Z})}{\mathrm{Tor}} \longrightarrow \mathbb{Z}, \qquad Q_M(a,b) = \langle \mathrm{PD}^{-1}(a) \smile \mathrm{PD}^{-1}(b), [M] \rangle$$

jest unimodularne*, czyli doskonałe nad $\mathbb{Z}$: macierz w dowolnej bazie części wolnej ma wyznacznik ± 1. Ponadto $Q_M(a,b) = (-1)^k Q_M(b,a)$. W wymiarze $4m$ forma jest symetryczna, a w wymiarze $4m+2$ antysymetryczna.*

Dowód. Z dualności Poincarégo otrzymujemy $H_k(M;\mathbb{Z}) \cong H^k(M;\mathbb{Z})$. Twierdzenie o współczynnikach uniwersalnych daje ciąg dokładny

$$0 \longrightarrow \mathrm{Ext}(H_{k-1}(M),\mathbb{Z}) \longrightarrow H^k(M;\mathbb{Z}) \longrightarrow \mathrm{Hom}(H_k(M),\mathbb{Z}) \longrightarrow 0.$$

Grupy homologii zwartej triangulacji są skończenie generowane. Składnik Ext jest więc torsyjny, a grupa Hom jest dualną kratą części wolnej H_k. Po podzieleniu przez torsję otrzymujemy izomorfizm

$$H_k(M)/\mathrm{Tor} \;\cong\; \mathrm{Hom}(H_k(M)/\mathrm{Tor},\mathbb{Z}).$$

Dla wybranej konwencji kapowej ten izomorfizm wysyła a na funkcjonał

$$b \longmapsto \langle \mathrm{PD}^{-1}(a), b\rangle = Q_M(b,a) = (-1)^k Q_M(a,b).$$

Wspólny czynnik $(-1)^k$ nie zmienia odwracalności. Klasy torsyjne nie wpływają na Q_M, ponieważ ich całkowita ewaluacja jest torsyjną liczbą całkowitą, a więc zerem. Definicja na ilorazie jest zatem jednoznaczna. Macierz odwzorowania między wolną grupą abelową a jej dualną jest odwracalna nad $\mathbb{Z}$, stąd jej wyznacznik to ± 1. Dla wszystkich klas, także niereprezentowanych przez zanurzone podrozmaitości, przemienność stopniowana iloczynu kubkowego daje znak $(-1)^{k^2} = (-1)^k$. To dowodzi obu symetrii. Nie zakładamy, że każda całkowita klasa homologii ma reprezentanta będącego podrozmaitością. □

Przykład 21.10.2. Na $S^2 \times S^2$ w bazie $[S^2 \times \{p\}]$, $[\{q\} \times S^2]$ forma ma macierz

$$Q = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, \qquad \det Q = -1.$$

Na torusie $H_1(T^2) = \mathbb{Z}^2$ i w bazie dwóch podstawowych okręgów otrzymujemy $\left(\begin{smallmatrix} 0 & 1 \\ -1 & 0 \end{smallmatrix}\right)$. Druga forma jest antysymetryczna, bo oba cykle mają wymiar nieparzysty.

Definicja 21.10.3 (Elementarna operacja chirurgiczna)**.** Niech $0 \le k \le n-1$ i niech dane będzie *obramowane* zanurzenie $S^k \times D^{n-k} \hookrightarrow M^n$. Elementarna *chirurgia indeksu k* (w przyjętej tutaj konwencji: wymiar operowanej sfery; uchwyt w jej śladzie ma indeks $k+1$) polega na usunięciu wnętrza tego otoczenia i wklejeniu $D^{k+1} \times S^{n-k-1}$ wzdłuż wspólnego brzegu

$$\partial(S^k \times D^{n-k}) = S^k \times S^{n-k-1} = \partial(D^{k+1} \times S^{n-k-1}).$$

Dla ustalonego obramowanego zanurzenia sklejamy punkty o tych samych współrzędnych produktowych na $S^k \times S^{n-k-1}$; jest to określony dyfeomorfizm brzegów. Jego dowolna dodatkowa zmiana jest dodatkową daną i może zmienić wynik. Kołnierze określają gładką strukturę przy szwie. Jeśli chcemy zachować orientację, identyfikacja musi odwracać orientacje indukowane na brzegach obu sklejanych części.

To wyjaśnia rolę wcześniejszych tematów. Twierdzenie o otoczeniu tubularnym zapewnia obszar, który można wyciąć. Obramowanie z Definicji 20.4.1 pozwala zapisać go jako *iloczyn* $S^k \times D^{n-k}$. Klasy charakterystyczne mogą wykazać, że normalna wiązka nie ma takiego obramowania. Forma przecięcia kontroluje, jak cykle środkowego wymiaru są ze sobą powiązane; po operacji trzeba obliczyć ją na nowo. Szczegółowa teoria sklejania, uchwytów i zmian homologii będzie osobnym rozdziałem.

Przykład 21.10.4 (Cięcie sfery w dwóch punktach)**.** Na S^2 wybierzmy dwa rozłączne małe dyski: $S^0 \times D^2$ to właśnie ich suma. Po wycięciu wnętrz pozostaje walec $S^1 \times [0,1]$. W chirurgii $k = 0, n = 2$ dołączamy $D^1 \times S^1$, drugi walec, wzdłuż dwóch brzegowych okręgów. Wybieramy sklejenia zgodne z orientacją powstałej powierzchni, czyli odwracające orientacje jej brzegów. Wtedy dwa walce składają się w zorientowaną zamkniętą powierzchnię rodzaju jeden, czyli torus. Bez tego warunku sklejenie może dać butelkę Kleina: po obejściu podłużnego okręgu kierunek poprzeczny wraca wówczas z przeciwną orientacją. Sama charakterystyka Eulera nie rozróżnia tych wyników. Na poziomie charakterystyki Eulera: ze sfery o $\chi = 2$ usunięcie dwóch dysków odejmuje 2, a dołączenie walca nie zmienia wyniku: $\chi(A \cup B) = \chi(A) + \chi(B) - \chi(A \cap B)$, przy czym zarówno walec, jak i dwa okręgi sklejenia mają charakterystykę 0. Torus ma więc $\chi = 0$, zgodnie z bezpośrednim obliczeniem.

Dalsza lektura: A. Hatcher, *Algebraic Topology*, dualność i iloczyn kubkowy, A. Hatcher, *Vector Bundles and K-Theory*, sklejanie i klasy charakterystyczne, R. Cohen, *Bundles, Manifolds, and Homotopy*, przecięcia i klasa Thoma.

Rozdział 22

Teoria Morse'a: punkty krytyczne, uchwyty i przepływ

Funkcja wysokości pozwala oglądać rozmaitość po jednej poziomicy naraz. Między jej wartościami krytycznymi nic istotnego się nie zmienia: Twierdzenie 20.7.6 identyfikuje taki pas z iloczynem. Wartość krytyczna jest chwilą, w której pojawia się nowa część przestrzeni, otwór albo zamknięcie otworu. Teoria Morse'a zamienia ten obraz w twierdzenia o uchwytach i homologiach. Na końcu poznamy trajektorie gradientowe, które pozwalają obliczać różniczkę kompleksu Morse'a.

W głównej części rozdziału M^n jest gładką rozmaitością *zwartą bez brzegu*, a $f : M \to \mathbb{R}$ funkcją Morse'a. Definicję hesjanu i niezdegenerowania podaliśmy w Definicji 19.5.3; istnienie funkcji Morse'a i możliwość rozdzielenia ich wartości krytycznych dowiedliśmy w Twierdzeniu 19.5.4. Zatem nie będziemy drugi raz udowadniać tych samych faktów. Oznaczamy

$$M^a := f^{-1}((-\infty, a]), \qquad \operatorname{Crit}_k(f) := \{p : \mathrm{d}f_p = 0,\ \lambda(p) = k\}, \qquad c_k := \#\operatorname{Crit}_k(f).$$

Przy wartości regularnej a zbiór M^a jest zwartą rozmaitością z brzegiem $f^{-1}(a)$, o ile nie jest pusty.

22.1 Lemat Morse'a: dokładny opis w pobliżu punktu

Hesjan w punkcie krytycznym mierzy drugorzędową zmianę f. Jego indeks $\lambda(p)$, wprowadzony przy transwersalności w Sekcji 19.6, jest liczbą ujemnych kierunków. Lemat Morse'a mówi znacznie więcej niż wzór Taylora z resztą: po gładkiej zmianie współrzędnych *reszta znika*.

Twierdzenie 22.1.1 (Lemat Morse'a)**.** *Jeśli p jest niezdegenerowanym punktem krytycznym o indeksie λ, istnieje mapa (u, v) wokół p, w której $u \in \mathbb{R}^\lambda$, $v \in \mathbb{R}^{n-\lambda}$, $p = (0, 0)$ i*

$$f(u, v) = f(p) - |u|^2 + |v|^2. \tag{22.1.1}$$

Liczba λ nie zależy od mapy.

Dowód. Wybierzmy dowolne współrzędne x z $x(p) = 0$. Ponieważ $\mathrm{d}f_0 = 0$, liniowa zamiana współrzędnych, twierdzenie Sylvestera i przeskalowanie osi pozwalają założyć

$$\tfrac{1}{2}\operatorname{Hess}_0 f = J := \operatorname{diag}(-I_\lambda, I_{n-\lambda}).$$

Nie wolno jednak na tym poprzestać: forma w punkcie 0 nie opisuje jeszcze całej funkcji w sąsiedztwie. Dwukrotne całkowanie po odcinku $t \mapsto tx$ daje *dokładną* równość

$$f(x) - f(0) = x^{\mathsf{T}} H(x) x, \qquad H(x) = \int_0^1 (1 - t)\, \operatorname{Hess}_{tx} f \, \mathrm{d}t.$$

Macierz $H(x)$ zależy gładko od x, jest symetryczna i $H(0) = J$. Rozbijmy $x = (x_-, x_+)$ i zapiszmy

$$H(x) = \begin{pmatrix} A(x) & B(x) \\ B(x)^{\mathsf{T}} & C(x) \end{pmatrix}.$$

Blisko zera A jest ujemnie określona, a dopełnienie Schura $S = C - B^{\mathsf{T}}A^{-1}B$ dodatnio określone. Istotnie, w zerze mamy $A = -I$, $B = 0$, $S = I$, a określoność jest własnością otwartą. Uzupełniamy kwadrat, nie pomijając zależności macierzy od x:

$$x^{\mathsf{T}}Hx = (x_- + A^{-1}Bx_+)^{\mathsf{T}}A(x_- + A^{-1}Bx_+) + x_+^{\mathsf{T}}Sx_+.$$

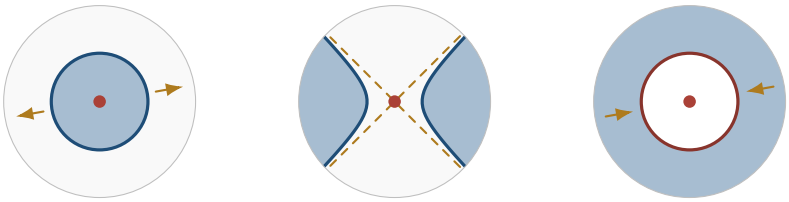
Dodatnio określone macierze $-A$ i S mają gładko zależne od x dodatnie pierwiastki kwadratowe. Blisko I można je zbudować z szeregu potęgowego $\sqrt{I+E} = I + \frac{1}{2}E - \frac{1}{8}E^2 + \cdots$; na mniejszym otoczeniu $\|E\| \le q < 1$. Po dowolnej ustalonej liczbie różniczkowań wyrazy są ograniczone przez wielomian w numerze wyrazu razy potęgę q. Szeregi pochodnych są więc lokalnie jednostajnie zbieżne, co uzasadnia gładkość. Kładziemy

$$u = (-A)^{1/2}(x_- + A^{-1}Bx_+), \qquad v = S^{1/2}x_+.$$

Otrzymujemy (22.1.1). W zerze różniczka zmiany $x \mapsto (u, v)$ jest identycznością, bo $A(0) = -I$, $B(0) = 0$, $S(0) = I$. Twierdzenie o funkcji odwrotnej czyni więc (u, v) współrzędnymi na pewnym otoczeniu p. Przy $\lambda = 0$ pomijamy blok A i bierzemy $v = H(x)^{1/2}x$; przy $\lambda = n$ bierzemy $u = (-H(x))^{1/2}x$. Nie odwracamy w tych przypadkach żadnego nieistniejącego bloku.

Na końcu trzeba sprawdzić jednoznaczność liczby λ: hesjan w tych współrzędnych ma macierz $\operatorname{diag}(-2I_\lambda, 2I_{n-\lambda})$, a prawo bezwładności Sylvestera zachowuje liczbę ujemnych kwadratów przy każdej odwracalnej zmianie bazy. □

Przykład 22.1.2 (Trzy lokalne kształty w wymiarze dwa)**.** Na płaszczyźnie funkcje $x^2 + y^2$, $-x^2 + y^2$ i $-x^2 - y^2$ mają odpowiednio indeksy $0, 1, 2$. Pierwsza tworzy nową składową podpoziomicy. Przy siodle dwie części poziomicy stykają się i zmieniają sposób połączenia. Ostatnia może wypełnić ostatni brzeg powierzchni. Sam rysunek poziomic nie wyznacza jeszcze globalnego wyniku: o sposobie przyklejenia decyduje wcześniejsza część rozmaitości.



minimum $\lambda = 0$ pojawia się dysk — siodło $\lambda = 1$ dwa obszary — maksimum $\lambda = 2$ otwór się zamyka

Rysunek 22.1: Lokalne podpoziomice trzech postaci z lematu Morse'a w wymiarze dwa. Kolor niebieski oznacza $f \le a$: przy minimum pokazujemy $a > f(p)$, a przy siodle i maksimum $a < f(p)$. Złote strzałki wskazują wzrost f: od minimum na zewnątrz, do maksimum ku środkowi. Przerywane proste przy siodle to poziom krytyczny.

22.2 Przekroczenie wartości krytycznej: uchwyt

Przedział bez wartości krytycznych mamy już opisany w Twierdzeniu 20.7.6. Teraz $a < b$ są wartościami regularnymi, a w $f^{-1}([a, b])$ leży dokładnie jeden punkt krytyczny p z $a < f(p) = c < b$ i indeksem λ. Dla przejrzystości piszemy $D^0 = \{\text{punkt}\}$ i $S^{-1} = \varnothing$.

Definicja 22.2.1 (Uchwyt indeksu λ)**.** n-wymiarowy *uchwyt indeksu* λ to $H_\lambda = D^\lambda \times D^{n-\lambda}$. Jego część przyczepiana to $S^{\lambda-1}\times D^{n-\lambda}$. Rdzeń $D^\lambda\times\{0\}$ ma wymiar λ, a dysk $\{0\}\times D^{n-\lambda}$ biegnie w kierunkach poprzecznych. Przyklejamy uchwyt do brzegu dotychczasowej podpoziomicy przez zanurzenie jego części przyczepianej.

Twierdzenie 22.2.2 (Dołączenie uchwytu Morse'a)**.** *W powyższej sytuacji M^b powstaje, z dokładnością do zaokrąglenia naroży i dyfeomorfizmu, z M^a przez dołączenie uchwytu H_λ. W szczególności istnieje odwzorowanie $S^{\lambda-1}\to M^a$ takie, że*

$$M^b \simeq M^a \cup_{S^{\lambda-1}} D^\lambda, \qquad H_j(M^b, M^a;\mathbb{Z}) \cong \begin{cases}\mathbb{Z}, & j=\lambda,\\ 0, & j\neq\lambda.\end{cases} \tag{22.2.1}$$

Przy $\lambda = 0$ pojawia się składowa; przy $\lambda = n$ dołącza się n-wymiarowy dysk wzdłuż całej jego sfery brzegowej.

Dowód. Krok 1: ograniczamy pas. Na częściach $[a, c-\varepsilon]$ i $[c+\varepsilon, b]$ nie ma punktów krytycznych. Przepływ pola $\nabla f/|\nabla f|^2$ z Twierdzenia 20.7.6 identyfikuje te pasy z iloczynami. Wystarczy więc zrozumieć $f^{-1}([c-\varepsilon, c+\varepsilon])$ dla małego $\varepsilon > 0$.

Krok 2: uchwyt z właściwą częścią przyczepianą. W mapie Morse'a mamy $f - c = -|u|^2 + |v|^2$. Wybierzmy $\varepsilon > 0$ i $0 < r^2 < \varepsilon$ tak małe, by poniższy zbiór mieścił się w mapie:

$$H = \{(u,v) : |v| \le r, \quad |u|^2 \le \varepsilon + |v|^2\}.$$

Odwzorowanie

$$(a,b) \longmapsto \left(\sqrt{\varepsilon + r^2|b|^2}\, a, rb\right) \quad (|a|\le 1,\ |b|\le 1)$$

jest dyfeomorfizmem $D^\lambda \times D^{n-\lambda}$ na H. Ponadto $H \subset \operatorname{int} M^{c+\varepsilon}$ oraz

$$H \cap M^{c-\varepsilon} = \{|u|^2 = \varepsilon + |v|^2,\ |v| \le r\}.$$

Jest to dokładnie obraz $S^{\lambda-1}\times D^{n-\lambda}$; przy $\lambda = 0$ przecięcie jest puste. Rdzeń $v = 0$ ma brzeg w poziomicy $c-\varepsilon$. Tak zdefiniowana część przyczepiana już leży na właściwym poziomie; nie trzeba przesuwać jej z płaskiej ściany pudełka.

Krok 3: dopełnienie jest kołnierzem. Wybierzmy metrykę euklidesową na otoczeniu H, przedłużoną podziałem jedności na M. Dla $X = -\nabla f$ mamy tam

$$\dot u = 2u, \quad \dot v = -2v, \qquad (u(t), v(t)) = (e^{2t}u(0), e^{-2t}v(0)).$$

Niech $L = M^{c-\varepsilon} \cup H$. Blisko naroża jego dopełnienie opisują nierówności $F = f - (c-\varepsilon) > 0$ i $G = |v|^2 - r^2 > 0$. Na obu ścianach pole jest skierowane do L, ponieważ

$$XF = -4(|u|^2 + |v|^2) < 0, \qquad XG = -4|v|^2 < 0.$$

Możemy zatem zaokrąglić naroże, zachowując poprzeczność i ten sam kierunek pola: w płaszczyźnie (F, G) zastępujemy narożnik gładkim łukiem o normalnej będącej dodatnią kombinacją normalnych obu ścian. Zaokrąglenie wybieramy na zewnątrz L, małe i wewnątrz $M^{c+\varepsilon}$, tak by zachować $M^{c-\varepsilon} \subset L'$. Otrzymaną rozmaitość oznaczmy przez L'. Punkt p leży w jej wnętrzu.

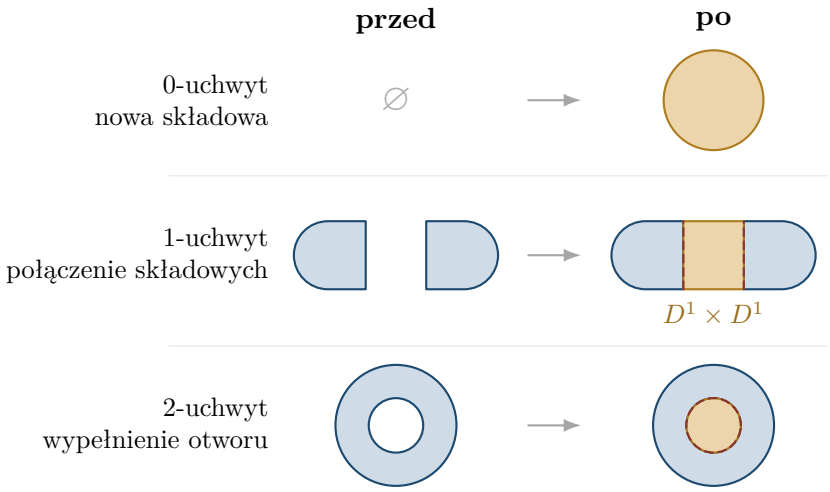
Zbiór $K = M^{c+\varepsilon} \setminus \operatorname{int} L'$ jest zwarty i nie zawiera punktów krytycznych. Stąd $-Xf \ge m > 0$ na K. Każda trajektoria z górnego brzegu dociera do $\partial L'$ w skończonym czasie: inaczej f malałaby co najmniej z prędkością m w zbiorze, na którym jest ograniczona. W odwrotnym czasie każda trajektoria z $\partial L'$ dociera do górnego brzegu. Nie może powtórnie przeciąć $\partial L'$, bo X jest tam ściśle skierowane do środka. Czas trafienia jest gładki na mocy twierdzenia o funkcji uwikłanej i poprzeczności. Przeskalowanie czasu na każdej trajektorii daje $K \cong \partial L' \times [0,1]$. Wchłonięcie

tego kołnierza dowodzi tezy o uchwycie. Przy $\lambda = n$ nie ma ściany $|v| = r$; cały brzeg $H = D^n$ przykleja się do dolnej podpoziomicy. Zamknięte składowe L' nie wymagają żadnego kołnierza.

Krok 4: komórka i homologia względna. Oznaczmy odwzorowanie przyczepienia przez $\alpha(a, b)$. Homotopia $\alpha(a, (1-t)b)$ zastępuje je odwzorowaniem zależnym tylko od $a \in S^{\lambda-1}$. Dołączenia po homotopijnych odwzorowaniach mają ten sam typ homotopijny pary: homotopię realizuje walec na części przyczepianej, który wchłaniamy w jej kołnierz. Po tej zmianie skurczenie czynnika $D^{n-\lambda}$ daje dołączenie samego rdzenia D^λ. Nie jest to skurczenie pierwotnego uchwytu przy jednoczesnym punktowym unieruchomieniu jego całej części przyczepianej. Kołnierze pozwalają zastosować wycięcie (najpierw pogrubiamy część przyczepianą), skąd

$$H_j(M^b, M^a; \mathbb{Z}) \cong H_j(H_\lambda, S^{\lambda-1} \times D^{n-\lambda}; \mathbb{Z}) \cong H_j(D^\lambda, S^{\lambda-1}; \mathbb{Z}).$$

Homologia tej pary jest $\mathbb{Z}$ w stopniu λ i zerem w pozostałych stopniach, także dla $(D^0, S^{-1}) = (\{\text{punkt}\}, \varnothing)$. □



Rysunek 22.2: Trzy niezależne przykłady dla dwuwymiarowej podpoziomicy, pokazane z góry. Niebieski oznacza część istniejącą, złoty nowy uchwyt, a czerwone przerywane odcinki lub okrąg — część przyczepianą. W drugim wierszu prostokąt przykleja się dokładnie do dwóch odcinków brzegu. Inne przyklejenie 1-uchwytu może utworzyć otwór zamiast połączyć składowe.

Przykład 22.2.3 (Wysokość na sferze)**.** Na jednostkowej sferze $S^2 \subset \mathbb{R}^3$ weźmy $f(x, y, z) = z$. Krytyczne są tylko biegun południowy i północny. Przy południowym $z = -\sqrt{1 - x^2 - y^2} = -1 + \frac{1}{2}(x^2 + y^2) + O(|(x, y)|^4)$, więc indeks wynosi 0. Przy północnym znak formy kwadratowej jest przeciwny, więc indeks wynosi 2. Najpierw pojawia się dysk, między biegunami podpoziomice są dyskami, a po przejściu przez biegun północny dołączamy 2-uchwyt. Dostajemy $c_0 = c_2 = 1$, $c_1 = 0$.

Przykład 22.2.4 (Lekko przechylona wysokość torusa)**.** Standardowy torus parametryzujemy przez

$$((R + r\cos\theta)\cos\phi,\ (R + r\cos\theta)\sin\phi,\ r\sin\theta), \qquad R > r > 0.$$

Sama współrzędna $z = r\sin\theta$ ma *okręgi* punktów krytycznych: nie jest funkcją Morse'a. Weźmy zamiast niej

$$f = z + \varepsilon x = r\sin\theta + \varepsilon(R + r\cos\theta)\cos\phi, \qquad 0 < \varepsilon < r/R.$$

Warunek $\partial_\phi f = 0$ daje $\phi = 0$ lub $\phi = \pi$, bo $R + r\cos\theta > 0$. Warunek $\partial_\theta f = 0$ ma dwa rozwiązania przy każdej z tych wartości ϕ, jedno przy górze i jedno przy dole torusa. Można je

zapisać jawnie. Niech $s = \cos\phi \in \{-1, 1\}$, $t = \operatorname{sgn}(\sin\theta) \in \{-1, 1\}$ oraz $L = \sqrt{1+\varepsilon^2}$ i $h = r/L$. Równanie $\cos\theta = \varepsilon s \sin\theta$ daje

$$\sin\theta = \frac{t}{L}, \qquad \cos\theta = \frac{\varepsilon s t}{L}, \qquad (x, y, z) = (sR + t\varepsilon h,\ 0,\ th).$$

Wartość funkcji w tym punkcie wynosi $f = \varepsilon s R + trL$. Te same współrzędne wykorzystano do umieszczenia znaczników na Rysunku 22.3. W tych punktach mieszana pochodna wynosi zero, a na przekątnej hesjanu stoją

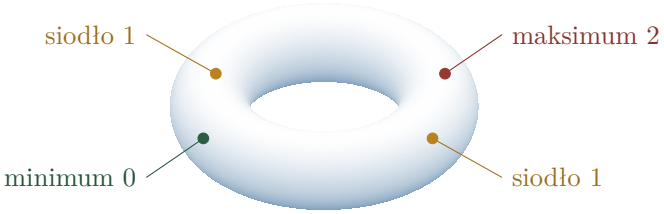
$$f_{\theta\theta} = -r(\sin\theta + \varepsilon\cos\theta\cos\phi), \qquad f_{\phi\phi} = -\varepsilon(R + r\cos\theta)\cos\phi.$$

Pierwsza jest ujemna u góry i dodatnia u dołu; druga jest ujemna dla $\phi = 0$ i dodatnia dla $\phi = \pi$. Zatem indeksy czterech punktów to kolejno $0, 1, 1, 2$. Ich wartości, od najmniejszej do największej, wynoszą

$$-r\sqrt{1+\varepsilon^2} - \varepsilon R, \quad -r\sqrt{1+\varepsilon^2} + \varepsilon R, \quad r\sqrt{1+\varepsilon^2} - \varepsilon R, \quad r\sqrt{1+\varepsilon^2} + \varepsilon R.$$

Nierówność $\varepsilon R < r$ zapewnia tę kolejność. Podpoziomica jest kolejno: dyskiem, pierścieniem, torusem z usuniętym dyskiem i całym torusem. To są dołączenia uchwytów indeksów $0, 1, 1, 2$. Sposób przyklejenia drugiego 1-uchwytu rozstrzyga, że powstaje rodzaj 1.

$$f(x, y, z) = z + \varepsilon x, \qquad \varepsilon > 0$$



Rysunek 22.3: Torus o przekroju kołowym oglądany ukośnie z góry ($R = 2$, $r = 0{,}69$, $\varepsilon = 0{,}16$). Znaczniki pokazują rzuty wszystkich czterech punktów krytycznych, także gdy powierzchnia torusa je przesłania. Punkty te mają indeksy $0, 1, 1, 2$; składnik εx rozdziela ich wartości. Podpoziomice są kolejno dyskiem, pierścieniem, torusem bez dysku i całym torusem.

22.3 Komórki, nierówności Morse'a i twierdzenie Reeba

Przykłady sfery i torusa pokazują, że punkt krytyczny indeksu λ może dodać tylko *jedną* komórkę wymiaru λ. Nie znaczy to, że dodaje niezależną klasę homologii: komórka może zabić wcześniejszy cykl. To właśnie mierzy jej brzeg w kompleksie komórkowym z Rozdziału 8.

Twierdzenie 22.3.1 (Model CW funkcji Morse'a)**.** *Rozmaitość M ma typ homotopijny skończonego kompleksu CW K_f z dokładnie c_k komórkami wymiaru k. W szczególności istnieje kompleks wolnych grup abelowych*

$$0 \longrightarrow C_n \xrightarrow{\partial_n} C_{n-1} \longrightarrow \cdots \xrightarrow{\partial_1} C_0 \longrightarrow 0, \qquad C_k \cong \mathbb{Z}^{c_k},$$

którego homologiami są $H_k(M; \mathbb{Z})$. Generator C_k możemy oznaczyć punktem krytycznym indeksu k.

Dowód. Na zwartej M punktów krytycznych jest skończenie wiele (Twierdzenie 19.5.4). Po małej perturbacji wartości punktów krytycznych są różne; wybieramy perturbację stałą w ich

małych otoczeniach, więc punkty i ich indeksy pozostają te same, a poza otoczeniami różniczka f jest oddzielona od zera. Wybieramy wartości regularne $a_0 < a_1 < \cdots < a_N$ tak, żeby między sąsiednimi znajdował się dokładnie jeden punkt krytyczny, a M^{a_0} było puste i $M^{a_N} = M$. Przy każdym przejściu Twierdzenie 22.2.2 zastępuje parę podpoziomic dołączeniem jednej komórki D^{λ_i}.

Wyjaśnijmy indukcję, ponieważ równoważność homotopijna na jednym etapie nie jest dosłownie równością przestrzeni. Jeśli zbudowany dotąd kompleks K_{i-1} jest homotopijnie równoważny $M^{a_{i-1}}$, przenosimy odwzorowanie $S^{\lambda_i - 1} \to M^{a_{i-1}}$ przez wybraną odwrotność homotopijną do K_{i-1}. Już na tym etapie stosujemy aproksymację komórkową: odwzorowanie ze sfery S^{λ_i-1} zastępujemy homotopijnym odwzorowaniem do $(\lambda_i - 1)$-szkieletu K_{i-1}. Dzięki temu następne dołączenie rzeczywiście daje kompleks CW, nawet jeśli starsze komórki mają większy wymiar. Dla $\lambda_i = 0$ po prostu dodajemy punkt. Dołączenie komórki po odwzorowaniach homotopijnych daje homotopijnie równoważne przestrzenie: homotopię na sferze rozszerza się na dołączony walec $S^{\lambda_i-1} \times [0,1]$, a następnie wchłania ten walec w kołnierz dysku. Tak powstaje K_i z jedną nową komórką. Po ostatnim kroku $K_N \simeq M$. Złożenie komórek daje kompleks łańcuchów CW; ich liczby w każdym stopniu to dokładnie c_k. □

Twierdzenie 22.3.2 (Słabe i mocne nierówności Morse'a)**.** *Niech* $b_k = \dim_{\mathbb{F}} H_k(M;\mathbb{F})$ *dla dowolnego ciała* $\mathbb{F}$*. Wtedy* $c_k \geq b_k$ *oraz dla* $0 \leq q < n$

$$\sum_{k=0}^{q} (-1)^{q-k} c_k \;\geq\; \sum_{k=0}^{q} (-1)^{q-k} b_k. \tag{22.3.1}$$

Na końcu otrzymujemy równość

$$\chi(M) = \sum_{k=0}^{n} (-1)^k c_k. \tag{22.3.2}$$

Dowód. Tensorujemy kompleks z poprzedniego twierdzenia z $\mathbb{F}$. Niech $r_k = \operatorname{rank}_{\mathbb{F}}(\partial_k : C_k \otimes \mathbb{F} \to C_{k-1} \otimes \mathbb{F})$, przy $r_0 = r_{n+1} = 0$. Z twierdzenia o rzędzie i jądrze

$$\dim \ker \partial_k = c_k - r_k.$$

Ponieważ $\partial_k \partial_{k+1} = 0$, obraz ∂_{k+1} jest podprzestrzenią tego jądra i ma wymiar r_{k+1}. Stąd, *bez pominiętego składnika*,

$$b_k = c_k - r_k - r_{k+1}, \qquad c_k = b_k + r_k + r_{k+1}. \tag{22.3.3}$$

Wszystkie rzędy są nieujemne, więc $c_k \geq b_k$. Po przemnożeniu (22.3.3) przez $(-1)^{q-k}$ i zsumowaniu od 0 do q składniki r_k i r_{k+1} skracają się parami. Zostaje dokładnie

$$\sum_{k=0}^{q} (-1)^{q-k} (c_k - b_k) = r_{q+1} \geq 0.$$

To dowodzi (22.3.1). Dla $q = n$ prawa strona wynosi $r_{n+1} = 0$. Pomnożenie przez $(-1)^n$ daje (22.3.2), bo $\chi(M) = \sum (-1)^k b_k$. □

Przykład 22.3.3 (Dolne ograniczenia i torsja)**.** Na S^2 mamy $(b_0, b_1, b_2) = (1, 0, 1)$; wysokość z Przykładu 22.2.3 realizuje dokładnie dwa niezbędne punkty. Dla torusa $(b_0, b_1, b_2) = (1, 2, 1)$, a funkcja z Przykładu 22.2.4 realizuje $(c_0, c_1, c_2) = (1, 2, 1)$. Nierówności możemy stosować nad różnymi ciałami: dla $\mathbb{R}P^2$ współczynniki $\mathbb{F}_2$ dają $(b_0, b_1, b_2) = (1, 1, 1)$, więc każda funkcja Morse'a ma co najmniej trzy punkty krytyczne. Nad $\mathbb{Q}$ środkowa i najwyższa grupa znikają. Różnica pokazuje, dlaczego wybór współczynników może ujawniać torsję, wspomnianą już w Rozdziale 8.

Twierdzenie 22.3.4 (Twierdzenie Reeba o dwóch punktach)**.** *Jeśli spójna zamknięta rozmaitość M^n, $n \geq 1$, ma funkcję Morse'a z dokładnie dwoma punktami krytycznymi, to M jest* homeomorficzna *z S^n.*

Dowód. Minimum i maksimum istnieją, więc są to oba punkty krytyczne; ich indeksy wynoszą 0 i n. Lemat Morse'a daje małą podpoziomicę wokół minimum dyfeomorficzną z D^n oraz małą nadpoziomicę wokół maksimum również dyfeomorficzną z D^n. Pomiędzy nimi nie ma wartości krytycznych, więc Twierdzenie 20.7.6 przedstawia pas jako $S^{n-1}\times[0,1]$. Po wchłonięciu kołnierza otrzymujemy dwie kopie D^n sklejone wzdłuż brzegu pewnym dyfeomorfizmem $h : S^{n-1} \to S^{n-1}$. Jako *homeomorfizm* h przedłuża się radialnie na dysk: $H(ru) = r\,h(u)$ dla $u \in S^{n-1}$, $r \in [0,1]$, oraz $H(0) = 0$. To przedłużenie jest ciągłe również w 0, ma ciągłą odwrotność zbudowaną z h^{-1}. Zmieniając współrzędne na jednym dysku przez H, otrzymujemy standardowe sklejenie dwóch półkul, czyli S^n. □

Uwaga 22.3.5. Ostatni argument jest topologiczny. Radialne przedłużenie h nie musi być gładkie w środku dysku, zatem dowód nie pozwala zastąpić słowa „homeomorficzna" przez „dyfeomorficzna". To rozróżnienie będzie ważne przy egzotycznych strukturach gładkich i chirurgii.

22.4 Gradient i rozmaitości trajektorii

Metryka g przekształca różniczkę $\mathrm{d}f$ w gradient $\nabla_g f$ (Definicja 11.8.1). Nie wybieramy jej po to, by zmieniać punkty krytyczne: te zależą od f. Metryka decyduje natomiast, którędy biegną trajektorie pola $X = -\nabla_g f$. Na zwartej M jego przepływ Φ_t istnieje dla wszystkich $t \in \mathbb{R}$.

Stwierdzenie 22.4.1 (Spadek funkcji i końce trajektorii)**.** *Dla każdej trajektorii $\gamma(t) = \Phi_t(x)$*

$$\frac{\mathrm{d}}{\mathrm{d}t} f(\gamma(t)) = -|\nabla_g f(\gamma(t))|_g^2 \leq 0. \tag{22.4.1}$$

Jeżeli γ nie jest stała, to ma granice przy $t \to -\infty$ i $t \to +\infty$, będące punktami krytycznymi.

Dowód. Pierwsza równość to reguła łańcuchowa i definicja gradientu: $\mathrm{d}f(-\nabla f) = -g(\nabla f, \nabla f)$. Równość zachodzi tylko w punkcie krytycznym; jeśli trajektoria do niego dotrze w skończonym czasie, jednoznaczność równania różniczkowego sprawia, że była stała. Ponieważ $f(M)$ jest ograniczone, funkcja $t \mapsto f(\gamma(t))$ ma granice na obu końcach i

$$\int_0^\infty |\nabla f(\gamma(t))|^2 \,\mathrm{d}t = f(x) - \lim_{t\to\infty} f(\gamma(t)) < \infty.$$

Na zwartej M pole i pochodna funkcji $|\nabla f|^2$ są ograniczone, więc $t \mapsto |\nabla f(\gamma(t))|^2$ jest jednostajnie ciągła. Nieujemna jednostajnie ciągła funkcja o skończonej całce na $[0,\infty)$ dąży do zera: gdyby przy nieskończenie wielu chwilach była większa od $\eta > 0$, jednostajna ciągłość dawałaby rozłączne przedziały stałej dodatniej długości, na których przekracza $\eta/2$, sprzeczne ze skończonością całki. Każdy punkt skupienia $\gamma(t)$ jest zatem krytyczny.

Zbiór graniczny jest przecięciem malejących zwartych, spójnych zbiorów $\overline{\{\gamma(t) : t \geq T\}}$, więc jest spójny i niepusty. Punktów krytycznych funkcji Morse'a na zwartej M jest skończenie wiele; jedyny spójny niepusty podzbiór takiego zbioru to pojedynczy punkt. Cała trajektoria zbiega do niego. Dla $t \to -\infty$ stosujemy ten sam argument do $-X$. □

Definicja 22.4.2 (Rozmaitości stabilna i niestabilna)**.** Dla punktu krytycznego p kładziemy

$$W^s(p) = \{x : \lim_{t\to+\infty} \Phi_t(x) = p\}, \qquad W^u(p) = \{x : \lim_{t\to-\infty} \Phi_t(x) = p\}.$$

Litery s, u pochodzą od angielskich *stable*, *unstable*. W kierunku przyszłości trajektorie na W^s zbiegają do p; trajektorie na W^u wychodzą z p przy biegu czasu do przodu.

Twierdzenie 22.4.3 (Wymiary rozmaitości stabilnych)**.** *Dla dowolnej gładkiej metryki g rozmaitość $W^u(p)$ jest różnowartościowo immersowaną rozmaitością dyfeomorficzną z $\mathbb{R}^{\lambda(p)}$, a $W^s(p)$ z $\mathbb{R}^{n-\lambda(p)}$. Ich przestrzenie styczne w p są odpowiednio dodatnią i ujemną przestrzenią spektralną DX_p. Metrykę można ponadto wybrać euklidesową w małych rozłącznych mapach Morse'a. W tych mapach*

$$W^u_{\mathrm{loc}}(p) = \{v = 0\}, \qquad W^s_{\mathrm{loc}}(p) = \{u = 0\}.$$

Dowód. Ponieważ punktów krytycznych jest skończenie wiele, bierzemy rozłączne mapy z Lematu 22.1.1 i gładkie funkcje odcinające równe 1 blisko ich środków. Wypukłe połączenie metryk euklidesowych w tych mapach z dowolną metryką globalną daje metrykę euklidesową na mniejszych mapach. Tam równania przepływu i ich rozwiązania podaliśmy w dowodzie Twierdzenia 22.2.2. Warunek zbiegania do $(0,0)$ przy $t \to +\infty$ zmusza $u = 0$, bo $u(t) = e^{2t}u(0)$; analogicznie zbieganie przy $t \to -\infty$ zmusza $v = 0$. To dowodzi lokalnego opisu i wymiarów.

Każdy $x \in W^s(p)$ po dostatecznie długim czasie wpada do małego lokalnego dysku $\{u = 0\}$, a $x = \Phi_{-T}(y)$ dla pewnego punktu y tego dysku. Stąd

$$W^s(p) = \bigcup_{T \geq 0} \Phi_{-T}(W^s_{\mathrm{loc}}(p)).$$

Te obrazy są gładkimi kopiami otwartego dysku i są zagnieżdżone, jeśli lokalny dysk wybierzemy niezmienniczy przy przepływie naprzód. Odwzorowania przejścia są ograniczeniami dyfeomorfizmów Φ_t, więc określają gładką strukturę na sumie. Ustalmy w lokalnym dysku kulę promienia δ. Każda trajektoria w $W^s(p) \setminus \{p\}$ przecina jej sferę raz, gdy wbiega do tej kuli: od tej chwili lokalny wzór $v(t) = e^{-2t}v(0)$ ściśle zmniejsza $|v|$. Punkt takiej trajektorii opisują kierunek na $S^{n-\lambda(p)-1}$ i czas od przecięcia. Jawna parametryzacja, dla $v \neq 0$, to

$$v \longmapsto \Phi_{-\frac{1}{2}\log(|v|/\delta)}(0, \delta v/|v|).$$

Blisko zera jest to dokładnie $(0, v)$, więc przedłuża się gładko przez $v = 0$. Jedyność przecięcia sfery i gładkość czasu trafienia dają odwrotność, a więc standardową strukturę $\mathbb{R}^{n-\lambda(p)}$. Inkluzja w M jest różnowartościową immersją. Dla wymiaru zerowego jest to po prostu $\{p\}$. Dla W^u odwracamy czas; wynik ma wymiar $\lambda(p)$. Nie twierdzimy, że globalna immersja jest właściwa.

Uzasadnijmy teraz twierdzenie dla ogólnej metryki. W punkcie krytycznym $A = DX_p = -g_p^{-1}\operatorname{Hess}_p f$ jest samosprzężony względem g_p i nie ma zerowych wartości własnych. Ma $\lambda(p)$ dodatnich i $n - \lambda(p)$ ujemnych wartości własnych. W liniowych współrzędnych spektralnych równanie ma postać $\dot{x} = Ax + R(x)$, gdzie $R(0) = DR(0) = 0$. Oznaczmy części stabilną i niestabilną przez s, u. W odpowiedniej normie, dla pewnego $\alpha > 0$,

$$\|e^{A_s t}\| \leq e^{-\alpha t}, \qquad \|e^{-A_u t}\| \leq e^{-\alpha t} \quad (t \geq 0).$$

Po zmniejszeniu kuli i odcięciu poza nią stała Lipschitza R może być dowolnie mała. Dla zadanego $x_s(0) = a$ rozwiązanie zbiegające do zera musi spełniać

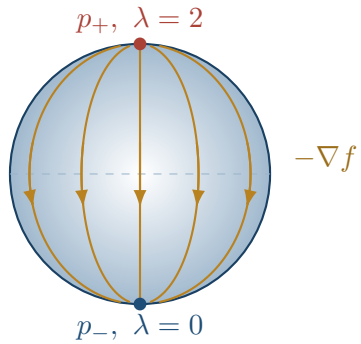
$$x_s(t) = e^{A_s t}a + \int_0^t e^{A_s(t-\tau)}R_s(x(\tau))\,\mathrm{d}\tau,$$
$$x_u(t) = -\int_t^\infty e^{A_u(t-\tau)}R_u(x(\tau))\,\mathrm{d}\tau.$$

Drugi wzór wynika z wariacji stałych i znikania rosnącego rozwiązania jednorodnego w nieskończoności. W przestrzeni funkcji z normą $\|x\|_\beta = \sup_{t\geq 0} e^{\beta t}|x(t)|$, gdzie $0 < \beta < \alpha$, prawa strona jest kontrakcją: jej stała jest nie większa niż

$$\operatorname{Lip}(R)\left((\alpha - \beta)^{-1} + (\alpha + \beta)^{-1}\right) < 1.$$

Twierdzenie o punkcie stałym daje jedyne rozwiązanie. Gładka zależność od a wynika z różniczkowania tego równania: operator $I - D\mathcal{T}$ ma odwrotność $\sum_{j\geq 0}(D\mathcal{T})^j$; argument powtarzamy dla kolejnych pochodnych. Otrzymujemy gładki wykres $x_u(0) = h(a)$, z $h(0) = Dh(0) = 0$. Każda trajektoria pozostająca w małej kuli na przyszłość i zbiegająca do zera leży na tym wykresie: spełnia te same równania całkowe, które są kontrakcją także w normie supremum ($\beta = 0$). Jest to lokalna rozmaitość stabilna. Odwrócenie czasu daje niestabilną.

Na wykresie stabilnym, w parametrze a, mamy $\dot{a} = A_s a + O(|a|^2)$, zatem $\frac{\mathrm{d}}{\mathrm{d}t}|a|^2 < 0$ poza zerem w małej kuli. Przepływ jest poprzeczny do jej sfery brzegowej. Do tej kuli globalna rozmaitość stabilna dokleja więc zewnętrzny nieskończony kołnierz sfery, parametryzowany ujemnym czasem. Kula z takim kołnierzem jest dyfeomorficzna z $\mathbb{R}^{n-\lambda(p)}$: na kołnierzu zamieniamy czas na promień, zgodnie z lokalnym kołnierzem brzegu kuli. Ten sam argument z odwróconym czasem kończy dowód. □



Rysunek 22.4: Spadek funkcji wysokości na sferze. Dla metryki indukowanej trajektorie są południkami i biegną od maksimum do minimum; rysunek pokazuje ich rzuty. Południowy punkt jest stabilny w dwóch wymiarach, a północny niestabilny w dwóch wymiarach; pozostałe zbiory stabilne lub niestabilne tych punktów to same punkty.

22.5 Warunek Morse'a–Smale'a i przestrzenie trajektorii

Dwie rozmaitości $W^u(p)$ i $W^s(q)$ mogą spotkać się stycznie. Wtedy niewielka zmiana metryki zmienia obraz trajektorii w trudny do kontrolowania sposób. Warunek transwersalności usuwa ten problem.

Definicja 22.5.1 (Para Morse'a–Smale'a)**.** Para (f, g) jest *parą Morse'a–Smale'a*, gdy f jest funkcją Morse'a i dla każdych punktów krytycznych p, q rozmaitości $W^u(p)$ i $W^s(q)$ przecinają się transwersalnie. Jeśli $p \neq q$, oznaczamy przez

$$\mathcal{M}(p,q) := (W^u(p) \cap W^s(q))/\mathbb{R}$$

zbiór trajektorii z p do q z zapomnianym początkiem czasu; $\mathbb{R}$ działa przez przesunięcie parametru t.

Stwierdzenie 22.5.2 (Wymiar trajektorii)**.** *Jeśli para jest Morse'a–Smale'a i $\mathcal{M}(p,q)$ jest niepusta, to $\lambda(p) > \lambda(q)$ oraz*

$$\dim \mathcal{M}(p,q) = \lambda(p) - \lambda(q) - 1.$$

Przy różnicy indeksów równej 1 *trajektorie są izolowane.*

Dowód. Transwersalność i Twierdzenie 22.4.3 dają

$$\dim(W^u(p) \cap W^s(q)) = \lambda(p) + (n - \lambda(q)) - n = \lambda(p) - \lambda(q).$$

W punkcie niekrytycznym przecięcia wektor $-\nabla f$ jest niezerowy i styczny do obu rozmaitości, bo obie są niezmiennicze przez przepływ. Dlatego przecięcie ma wymiar co najmniej 1; stąd $\lambda(p) > \lambda(q)$. Koniecznie $f(p) > f(q)$. Wybierzmy regularne s między tymi wartościami i oznaczmy $\Sigma = W^u(p) \cap W^s(q) \cap f^{-1}(s)$. Każda trajektoria przecina Σ dokładnie raz. Czas tego przecięcia jest gładki, ponieważ $Xf \neq 0$ na poziomicy (twierdzenie o funkcji uwikłanej). Przepływ daje zatem globalny dyfeomorfizm

$$\Sigma \times \mathbb{R} \longrightarrow W^u(p) \cap W^s(q), \qquad (z,t) \longmapsto \Phi_t(z).$$

Przecięcia rozumiemy w strukturach rozmaitości immersowanych, czyli jako iloczyny włókniste ich odwzorowań do M. Ich różnowartościowość pozwala utożsamiać punkty z punktami przecięcia w M. W konsekwencji iloraz jest rozmaitością Hausdorffa dyfeomorficzną z Σ, o wymiarze mniejszym o jeden. Samo lokalne odjęcie wymiaru działania nie wystarczałoby do uzasadnienia tych własności ilorazu. □

Twierdzenie 22.5.3 (Istnienie metryk Morse'a–Smale'a)**.** *Dla ustalonej funkcji Morse'a na zwartej M można wybrać metrykę g, euklidesową w małych mapach Morse'a, tak aby (f,g) była parą Morse'a–Smale'a. Takie metryki są gęste wśród metryk z ustalonym zachowaniem blisko punktów krytycznych.*

Dowód. Pokażemy mechanizm transwersalności, a następnie zastosujemy Twierdzenie 19.4.1. Ustalmy różne punkty krytyczne p, q z $f(p) > f(q)$ i regularny poziom $L = f^{-1}(s)$ między nimi. Ślady $W^u(p) \cap L$ i $W^s(q) \cap L$ są gładkimi rozmaitościami immersowanymi w L. Wybieramy s poza ustalonymi małymi otoczeniami punktów krytycznych; poniższe perturbacje nie będą więc zmieniały metryki w tych otoczeniach. Wystarczy uzyskać ich transwersalność na L.

Na obszarze, gdzie $\mathrm{d}f \neq 0$, zmiana metryki może dowolnie zmienić gradient w pierwszym rzędzie w kierunkach poprzecznych do trajektorii. Istotnie, dla $X = -g^{-1}\mathrm{d}f$ i symetrycznej perturbacji h metryki mamy

$$\frac{\mathrm{d}}{\mathrm{d}\varepsilon}(-(g+\varepsilon h)^{-1}\mathrm{d}f)\Big|_{\varepsilon=0} = -g^{-1}hX.$$

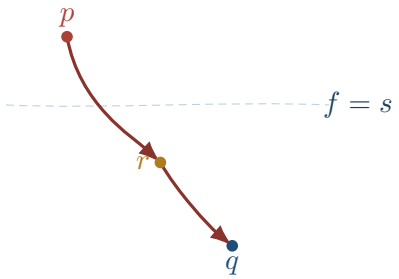
Gdy $X \neq 0$, odwzorowanie $h \mapsto h(X,\cdot)$ z form symetrycznych na kowektory jest surjektywne: w bazie z pierwszym wektorem równoległym do X możemy zadać dowolny pierwszy wiersz i tę samą pierwszą kolumnę macierzy h. Wybieramy kulkę na tej trajektorii *tuż ponad* L i perturbację podpartą tylko w tej kulce. Poniżej L metryka pozostaje taka sama, więc $W^s(q) \cap L$ nie zmienia się. Zmiana wektora prędkości w kierunku stycznym do L zmienia punkt trafienia w L w tym samym kierunku w pierwszym rzędzie: wynika to z całkowego równania dla zlinearyzowanego przepływu; przy zmniejszaniu kulki przeniesienie liniowe na krótkim odcinku zbliża się do identyczności. Wpływ perturbacji na trajektorię zależy gładko od jej skończenie wielu parametrów na mocy gładkiej zależności rozwiązań ODE od parametrów.

Doprecyzujmy argument gęstości, ponieważ same zbiory W^u, W^s zależą od metryki. Ustalmy małą sferę wyjściową $S_p \subset W^u_{\mathrm{loc}}(p)$ i wejściową $S_q \subset W^s_{\mathrm{loc}}(q)$. Są one niezależne od zmienianej metryki. Niech $E_g(x)$ oznacza pierwsze trafienie trajektorii z $x \in S_p$ w L, a $D_g(y)$ pierwsze trafienie trajektorii biegnącej wstecz z $y \in S_q$ w L. Odwzorowania są określone na otwartych zbiorach tych punktów, które osiągają L w skończonym czasie. Zależą gładko od punktu i od skończenie wielu parametrów metryki. Szukany warunek to transwersalność (E_g, D_g) do przekątnej w $L \times L$.

Dla każdego $N \in \mathbb{N}$ żądamy transwersalności we wszystkich przecięciach, których oba czasy trafienia są nie większe niż N. Jest to warunek otwarty: ewentualny ciąg przecięć naruszających go przy $g_j \to g$ ma podciąg zbieżnych punktów na zwartych S_p, S_q i zbieżnych czasów w $[0,N]$; gładka zależność przepływu przeczyłaby transwersalności dla g. Jest też gęsty. Przy ustalonej metryce zbiór takich par startowych jest zwarty, więc wystarcza skończenie wiele małych

obszarów perturbacji opisanych wyżej. Pochodne parametryczne pierwszej ewaluacji rozpinają TL, podczas gdy druga ewaluacja nie zmienia się. Parametryczna transwersalność zastosowana w otoczeniu tego zwartego zbioru daje dowolnie małe perturbacje spełniające warunek. Nowe przecięcia o czasach $\le N$ nie mogą pojawić się poza tym otoczeniem, co wynika z tego samego argumentu zwartości.

Przestrzeń gładkich metryk o ustalonych wartościach w otoczeniach krytycznych jest otwartą częścią zamkniętej afinicznej podprzestrzeni przestrzeni Frécheta gładkich tensorów symetrycznych. Ma własność Baire'a. Przecięcie powyższych otwartych gęstych warunków po wszystkich N jest więc gęste i obejmuje każde przecięcie o skończonych czasach trafienia. Małe perturbacje zachowują dodatnią określoność. Punktów krytycznych jest skończenie wiele, więc przeprowadzamy to dla wszystkich par. Jeśli $f(p) \le f(q)$ i $p \neq q$, trajektoria spadku nie może biec z p do q; przy $p = q$ lokalne osie $\{u = 0\}$ i $\{v = 0\}$ przecinają się transwersalnie w p. $\square$



Rysunek 22.5: Schemat trajektorii łamanej $p \to r \to q$. Pojedyncza trajektoria od p do q może się do niej zbliżać, spędzając coraz więcej czasu blisko r. Taka granica jest punktem brzegowym jednowymiarowej przestrzeni trajektorii, gdy różnica indeksów p, q wynosi 2.

22.6 Kompleks Morse'a: homologia z trajektorii

Teraz ustalmy metrykę Morse'a–Smale'a. Nie mylmy symboli: w *homologii* stosujemy operator brzegu ∂, zaś d pozostaje dla form i operatorów kohomologii z poprzednich rozdziałów.

Lemat 22.6.1 (Zwartość z dopuszczeniem przełamań)**.** *Z każdego ciągu trajektorii od p do q można wybrać podciąg zbiegający do skończonego łańcucha trajektorii $p = r_0 \to r_1 \to \cdots \to r_\ell = q$. Zbieżność oznacza gładką zbieżność na zwartych przedziałach czasu po osobnym przesunięciu czasu dla każdego niestałego odcinka.*

Dowód. Wybierzmy regularne poziomy rozdzielające wszystkie różne wartości krytyczne między $f(q)$ i $f(p)$. Każda trajektoria przecina każdy z tych poziomów raz. Zwartość ich skończonego iloczynu daje podciąg, na którym wszystkie punkty przecięć zbiegają. Przepływ z każdego punktu granicznego wyznacza graniczną trajektorię; gładka zależność od danych początkowych daje wymaganą zbieżność lokalną. Na zwartym paśmie bez zer $|\nabla f| \ge m > 0$, więc czas jego przejścia nie przekracza różnicy poziomów podzielonej przez m^2. Tam odcinki graniczne muszą się łączyć.

Nieograniczone czasy mogą zatem występować tylko w otoczeniach poziomów krytycznych. Końce granicznych odcinków są punktami krytycznymi na mocy Stwierdzenia 22.4.1. Trzeba jeszcze wykluczyć, że odcinek przychodzi do jednego punktu, a następny wychodzi z innego punktu *tej samej* wartości krytycznej. Weźmy rozłączne małe kule wokół tych punktów. Na zwartym obszarze między kulami $|\nabla f| \ge m > 0$, a przejście między różnymi kulami wymaga

długości co najmniej $d > 0$. Spadek funkcji na tym przejściu wynosi

$$\int |\nabla f|^2 \,\mathrm{d}t = \int |\nabla f| \,\mathrm{d}s \geq md,$$

gdzie s jest długością łuku. Nie może on zmieścić się w pasie o szerokości dążącej do zera. Tak więc oba odcinki mają wspólny punkt krytyczny. To samo rozumowanie na małych sferach wyjścia z p i wejścia do q zachowuje końce całego łańcucha. Każdy niestały odcinek ściśle obniża f, a więc łańcuch ma skończoną długość.

Zapis przez przecięcia z wybranymi poziomami wyznacza jednoznacznie trajektorię łamaną. Nadaje zbiorowi takich łańcuchów topologię Hausdorffa pochodzącą z metryki skończonego iloczynu poziomic. Powyższy argument stosuje się też do ciągu łańcuchów: wybieramy podciąg o ustalonej liście punktów krytycznych i stosujemy go do każdego odcinka. Domknięcie przestrzeni trajektorii w tym zbiorze, oznaczane $\overline{\mathcal{M}}(p,q)$, jest zatem zwarte. □

Lemat 22.6.2 (Zwarta przestrzeń trajektorii indeksu jeden)**.** *Jeśli $\lambda(p) - \lambda(q) = 1$, to $\mathcal{M}(p,q)$ jest skończonym zbiorem.*

Dowód. Przestrzeń jest zerowymiarowa przez Stwierdzenie 22.5.2. Każdy odcinek trajektorii łamanej ściśle obniża indeks. Przy różnicy indeksów 1 nie ma miejsca na punkt pośredni. Lemat 22.6.1 daje więc zwartość samej $\mathcal{M}(p,q)$. Zwarta rozmaitość zerowymiarowa jest skończonym zbiorem. □

Wybierzmy orientację każdej rozmaitości $W^u(p)$. Można to zrobić osobno, bo jest dyfeomorficzna z przestrzenią euklidesową; nie wymaga to orientowalności całego M. Dla trajektorii $\gamma : p \to q$ o różnicy indeksów 1 orientacje obu rozmaitości niestabilnych i kierunek przepływu określają znak $\epsilon(\gamma) \in \{\pm 1\}$. Konkretnie w regularnej poziomicy L jest to znak poprzecznego przecięcia $W^u(p) \cap L$ z $W^s(q) \cap L$; normalną orientację drugiego czynnika przenosimy z $T_q W^u(q)$ wzdłuż $W^s(q)$. Jest to jednoznaczne, ponieważ $W^s(q)$ jest ściągalna. Orientację $W^u(p) \cap L$ ustalamy regułą

$$\mathrm{or}(TW^u(p)) = \mathrm{or}(X) \otimes \mathrm{or}(T(W^u(p) \cap L)).$$

Dla różnicy indeksów 1 znak jest zatem znakiem izomorfizmu z przestrzeni stycznej tego śladu do zorientowanej przestrzeni normalnej $W^s(q)$. Przy większej różnicy indeksów orientujemy jądro tego odwzorowania, czyli $T\mathcal{M}(p,q)$, stawiając je przed przestrzenią normalną. Zmiana orientacji jednego $W^u(p)$ zmienia znaki odpowiedniego generatora, lecz nie grupy homologii.

Definicja 22.6.3 (Kompleks trajektorii Morse'a)**.** Grupa $CM_k(f,g;\mathbb{Z})$ jest wolną grupą abelową na punktach $\mathrm{Crit}_k(f)$. Dla generatora p kładziemy

$$\partial_k^{\mathrm{Mor}} p := \sum_{q \in \mathrm{Crit}_{k-1}(f)} \left(\sum_{\gamma \in \mathcal{M}(p,q)} \epsilon(\gamma) \right) q. \tag{22.6.1}$$

Suma jest skończona przez Lemat 22.6.2. Nad $\mathbb{F}_2$ zapominamy znaki: współczynnikiem przy q jest liczba trajektorii modulo 2.

Twierdzenie 22.6.4 (Dlaczego $\partial^2 = 0$)**.** *Operator* (22.6.1) *spełnia $\partial_{k-1}^{\mathrm{Mor}} \partial_k^{\mathrm{Mor}} = 0$.*

Dowód. Ustalmy p o indeksie k i q o indeksie $k-2$. Ze Stwierdzenia 22.5.2 przestrzeń $\mathcal{M}(p,q)$ jest jednowymiarowa. Pokażemy, jakie granice mogą mieć ciągi jej elementów. Argument ze zwartością poziomic z Lematu 22.6.2 daje podciąg zbieżny albo trajektorię $p \to q$, albo trajektorię łamaną. Każde przełamanie zużywa co najmniej jednostkę różnicy indeksów; przy różnicy 2 możliwe jest dokładnie jedno $p \to r \to q$ z $\lambda(r) = k-1$.

Wyjaśnijmy, dlaczego każdy taki łańcuch ma dokładnie jeden kołnierz, a więc jest rzeczywistym końcem. Oznaczmy $l = \lambda(r)$, $b = n - l$. Najpierw załóżmy, że metryka w mapie Morse'a jest euklidesowa. Przekrój wejściowy ma postać $|v| = \delta$, z parametrami (u, θ), gdzie $\theta = v/\delta \in S^{b-1}$. Przekrój wyjściowy $|u| = \delta$ ma parametry (ω, v), gdzie $\omega = u/\delta \in S^{l-1}$. Transwersalność przy ustalonych trajektoriach $p \to r$ i $r \to q$ pozwala zapisać ślady odpowiednich gałęzi jako

$$W^u(p) \cap \Sigma_{\text{in}} : \quad \theta = A(u), \qquad W^s(q) \cap \Sigma_{\text{out}} : \quad \omega = B(v).$$

Istotnie, pierwszy ślad ma wymiar l i jest poprzeczny do $u = 0$, a drugi ma wymiar b i jest poprzeczny do $v = 0$. Przy czasie przejścia T i $\rho = e^{-2T}$ lokalne równania przepływu dają

$$u_{\text{in}} = \delta\rho\omega, \quad v_{\text{in}} = \delta\theta, \quad u_{\text{out}} = \delta\omega, \quad v_{\text{out}} = \delta\rho\theta.$$

Warunek dopasowania to dokładnie

$$\theta = A(\delta\rho\omega), \qquad \omega = B(\delta\rho\theta). \tag{22.6.2}$$

Przy $\rho = 0$ rozwiązaniem jest $(A(0), B(0))$, a różniczka równań względem współrzędnych kątowych (θ, ω) jest identycznością. Twierdzenie o funkcji uwikłanej daje zatem *jedyne* pobliskie rozwiązanie dla każdego małego $\rho \geq 0$. Dla $\rho > 0$ jest to trajektoria niełamana, a $\rho = 0$ oznacza zadany łańcuch. Dla sfer S^0 współrzędne kątowe po prostu nie występują.

Ogólna metryka wymaga dodatkowego argumentu; nie wolno zakładać gładkiej linearyzacji jej gradientu. Wyprostujmy lokalne rozmaitości stabilną i niestabilną z Twierdzenia 22.4.3 do osi $u = 0, v = 0$. Równania mają teraz postać $\dot{u} = A_u u + R_u(u, v)$, $\dot{v} = A_s v + R_s(u, v)$, gdzie $R_u(0, v) = R_s(u, 0) = 0$ i $DR(0) = 0$. W małym pudełku $|u|, |v| \leq \delta$ norma u ściśle rośnie, a norma v ściśle maleje poza odpowiednią osią. Dla warunków mieszanych $v(0) = a$, $u(T) = b_0$ wariacja stałych daje

$$\begin{aligned} u(t) &= e^{A_u(t-T)}b_0 - \int_t^T e^{A_u(t-\tau)}R_u(u(\tau), v(\tau))\,\mathrm{d}\tau, \\ v(t) &= e^{A_s t}a + \int_0^t e^{A_s(t-\tau)}R_s(u(\tau), v(\tau))\,\mathrm{d}\tau. \end{aligned}$$

Tak jak w dowodzie rozmaitości stabilnej, małość DR czyni ten operator kontrakcją, jednostajnie względem T. Stosujemy normę ważoną

$$\sup_{0 \leq t \leq T} \left(e^{\eta(T-t)}|u(t)| + e^{\eta t}|v(t)|\right), \qquad 0 < \eta < \alpha.$$

Znikanie R_u na osi stabilnej i R_s na osi niestabilnej kontroluje wyrazy mieszane: na kuli tej normy pochodne mieszane są ograniczone przez stałą razy $\delta e^{-\eta(T-t)}$ lub $\delta e^{-\eta t}$. Całkowanie jąder wykładniczych daje stałą kontrakcji mniejszą od 1 dla małego δ. Różniczkowanie równania punktu stałego daje te same oszacowania dla pochodnych po a, b_0. W szczególności odwzorowania

$$U_T(a, b_0) = u(0), \qquad V_T(a, b_0) = v(T)$$

dążą do zera w normie C^1 z szybkością $O(e^{-\eta T})$ na małych ustalonych zbiorach parametrów. Zależą gładko od $T < \infty$; można to zobaczyć, przenosząc równania całkowe na ustalony przedział $[0, 1]$.

Równania dopasowania zastępujemy teraz przez

$$\theta = A(U_T(\delta\theta, \delta\omega)), \qquad \omega = B(V_T(\delta\theta, \delta\omega)).$$

Dla dużego T ich prawa strona jest kontrakcją w małym iloczynie map wokół $(A(0), B(0))$. Istnieje więc dokładnie jedno rozwiązanie, gładkie dla skończonego T i zbieżne do rozwiązania

łamanego dla $T \to \infty$. Parametr $1/T \geq 0$ daje topologiczny kołnierz końca, gładki w jego wnętrzu. Możemy go przyjąć za mapę gładkiej struktury rozmaitości z brzegiem. Nie potrzebujemy tu gładkości odwzorowania ewaluacji w zmiennej $1/T$ na samym brzegu. Jedyność rozwiązania i monotoniczność norm zapewniają, że wszystkie dostatecznie bliskie trajektorie są opisane przez ten kołnierz. Wspomniany argument zwartości wyklucza inne końce. Dodając je, otrzymujemy zwartą rozmaitość jednowymiarową z brzegiem

$$\partial\overline{\mathcal{M}}(p,q) = \coprod_{\lambda(r)=k-1} \mathcal{M}(p,r) \times \mathcal{M}(r,q).$$

Orientacje ustalone przed Definicją 22.6.3 orientują wnętrze tej rozmaitości. Porównanie z orientacją końca można przeprowadzić na powyższych równaniach dopasowania. Parametryzacje obu wykresów wnoszą znaki $\epsilon(\gamma_{pr})$ i $\epsilon(\gamma_{rq})$, a macierz dopasowania dąży do identyczności, więc jej wyznacznik jest dodatni. Pozostaje przestawienie bloków: kierunku przepływu, parametru kołnierza i przestrzeni normalnych. Jego znak zależy tylko od wymiarów k, n, nie od trajektorii ani od r (wszystkie te r mają indeks $k-1$). Dlatego znak punktu brzegowego jest

$$\sigma_{k,n}\,\epsilon(\gamma_{pr})\epsilon(\gamma_{rq}), \qquad \sigma_{k,n} \in \{1,-1\},$$

z jednym wspólnym czynnikiem konwencji orientacyjnej. W przypadku ogólnej metryki macierz dopasowania również dąży do identyczności, więc porównanie jest to samo. Każdy zwarty zorientowany odcinek ma dwa końce o przeciwnych znakach, a okrąg nie ma brzegu. Suma znaków brzegu jest zerem; po pomnożeniu przez $\sigma_{k,n}$ dostajemy

$$\sum_{\lambda(r)=k-1} \sum_{\gamma_{pr},\gamma_{rq}} \epsilon(\gamma_{pr})\epsilon(\gamma_{rq}) = 0.$$

Jest to dokładnie współczynnik przy q w $\partial^{\mathrm{Mor}}\partial^{\mathrm{Mor}}p$. Po redukcji modulo 2 to samo rozumowanie mówi, że liczba końców jest parzysta. □

Twierdzenie 22.6.5 (Homologia Morse'a jest homologią M)**.** *Dla zamkniętej rozmaitości i pary Morse'a–Smale'a*

$$H_k(CM_\bullet(f,g;\mathbb{Z}),\partial^{\mathrm{Mor}}) \cong H_k(M;\mathbb{Z}).$$

Wynik nie zależy od wybranego f, metryki ani orientacji generatorów.

Dowód. Krok 1: filtracja według indeksu. Sama zgodność liczby generatorów z liczbą komórek nie porównuje różniczek. Potrzebna jest ponadto filtracja uporządkowana według indeksów. Użyjemy geometrycznego twierdzenia o przestawianiu wartości krytycznych, którego dowód znajduje się w Twierdzeniu 23.5.2. To odwołanie naprzód nie tworzy koła: tamten argument używa przepływu i braku trajektorii między zamienianymi punktami, a nie homologii Morse'a. W konstrukcji zmieniamy funkcję, zachowując pole X: nierówność $X\widetilde{f} < 0$ pozostaje prawdziwa poza punktami krytycznymi, a blisko nich dodajemy do f tylko stałe.

Jeśli dwa sąsiednie punkty w kolejności wartości mają indeksy malejące, od wyższego punktu (o mniejszym indeksie) do niższego nie biegnie trajektoria przez Stwierdzenie 22.5.2. Można więc zamienić ich wartości. Skończenie wiele takich zamian daje funkcję F, której wszystkie punkty indeksu k leżą poniżej wszystkich punktów indeksu $k+1$. Równe wartości można najpierw rozdzielić małymi zmianami stałymi blisko punktów krytycznych. Pole X i jego trajektorie oraz ich znaki pozostają te same. Jeśli chcemy ponownie używać języka gradientu, poza zerami kładziemy

$$\widetilde{g}(X,X) = -\mathrm{d}F(X) > 0, \qquad \widetilde{g}(X,\ker \mathrm{d}F) = 0,$$

a na $\ker \mathrm{d}F$ wybieramy dowolną dodatnią metrykę. Blisko zer pozostawiamy g; sklejenie metryk podziałem jedności zachowuje liniową tożsamość $\widetilde{g}(X,\cdot) = -\mathrm{d}F$. Zatem $X = -\nabla_{\widetilde{g}}F$.

Wybierzmy regularne poziomy a_k po wszystkich punktach indeksu k, a przed punktami wyższych indeksów. Niech $N_k = F^{-1}((-\infty, a_k])$, $N_{-1} = \varnothing$, $N_n = M$. Twierdzenie o uchwycie i wycięcie dają

$$H_j(N_k, N_{k-1}; \mathbb{Z}) = \begin{cases} \mathbb{Z}^{c_k}, & j = k, \\ 0, & j \neq k. \end{cases}$$

Przy pustej grupie indeksów wybieramy po prostu dwa poziomy w tym samym regularnym paśmie. Filtracja jest równoważna filtracji szkieletami modelu CW: na każdym etapie przybywają wyłącznie komórki wymiaru k. Jej kompleks względny ma więc grupy $C_k = H_k(N_k, N_{k-1})$ i brzeg

$$C_k \xrightarrow{\delta} H_{k-1}(N_{k-1}) \longrightarrow H_{k-1}(N_{k-1}, N_{k-2}) = C_{k-1}.$$

Jak w dowodzie twierdzenia o homologii komórkowej, dokładne ciągi par identyfikują jego homologię z $H_*(M)$.

Krok 2: konkretni reprezentanci generatorów. Mały dysk w $W^u(p)$, zorientowany wybraną orientacją, przedłużamy przepływem aż do poziomu a_{k-1}. Każdy punkt jego sfery wyjściowej dociera tam: w przeciwnym razie granicą byłby punkt o indeksie co najmniej k, sprzecznie ze ścisłym spadkiem indeksu. Gładki czas trafienia jest ograniczony na zwartej sferze. Otrzymujemy zanurzony dysk $D_p \subset N_k$ z brzegiem $S_p \subset \partial N_{k-1}$. Reprezentuje generator odpowiadający uchwytowi p: lokalnie jego przestrzeń styczna jest ujemną przestrzenią hesjanu, a więc jego zorientowany dysk jest rdzeniem generatora lokalnej homologii względnej. Przedłużenie przez regularny przepływ dodaje tylko kołnierz.

Dla q indeksu $k-1$ analogicznie przedłużamy mały dysk stabilny wstecz do ∂N_{k-1}. Dostajemy *współrdzeń* E_q uchwytu q i jego brzeg $B_q \subset \partial N_{k-1}$, nazywany sferą pasa. Nie może on zatrzymać się przy innym punkcie indeksu $k-1$, bo nie ma trajektorii między równymi indeksami. Normalną orientację E_q wyznacza $W^u(q)$. W małym modelu uchwytu rdzeń i współrdzeń przecinają się raz, ze znakiem $+1$ przy zgodnych orientacjach. Jest to lokalna dualność, która pozwala odczytać współczynnik generatora w $H_{k-1}(N_{k-1}, N_{k-2})$.

Krok 3: porównanie współczynników. Obraz $[D_p]$ przez δ to $[S_p]$. Jego współczynnik przy q liczymy jako podpisaną liczbę przecięć S_p z B_q w ∂N_{k-1}. Dlaczego ten rachunek daje współczynnik względny? W otoczeniu tubularnym współrdzenia rzut na normalny dysk, po zgnieceniu jego brzegu, mierzy lokalny stopień. Wycięcie redukuje go do pary uchwytu i jego części przyczepianej, gdzie rdzeń daje stopień 1, a pozostałe generatory dają 0. Jest to dokładnie funkcjonał dualny do generatora q. Poprzeczność pozwala obliczać stopień jako sumę lokalnych znaków, również bez orientowania całego M; wystarczają orientacja S_p i koorientacja B_q.

Punkty $S_p \cap B_q$ odpowiadają bijektywnie trajektoriom $p \to q$, gdyż każda przecina ten regularny poziom dokładnie raz. Orientacja brzegu D_p jest określona przez zewnętrzny kierunek X, więc zgadza się z przyjętą orientacją S_p. Koorientacja B_q jest tą samą, której użyliśmy w definicji $\epsilon(\gamma)$. Współczynnik brzegu jest zatem dokładnie sumą w (22.6.1). Kompleks filtracji jest izomorficzny z kompleksem Morse'a przez przypisanie $p \mapsto [D_p]$. Każdy wybór f, g oblicza w ten sposób homologię M, a odwrócenie orientacji $W^u(p)$ zmienia jedynie znak odpowiedniego generatora. □

Przykład 22.6.6 (Kompleks na sferze i torusie)**.** Na S^2 z wysokością z Przykładu 22.2.3 nie ma punktów indeksu 1, więc $CM_2 = \mathbb{Z}$, $CM_1 = 0$, $CM_0 = \mathbb{Z}$, a $\partial = 0$. Homologie to $\mathbb{Z}, 0, \mathbb{Z}$.

Na torusie z Przykładu 22.2.4 mamy $CM_2 = \mathbb{Z}$, $CM_1 = \mathbb{Z}^2$, $CM_0 = \mathbb{Z}$. Znamy $H_0(T^2; \mathbb{Z}) = \mathbb{Z}$, $H_1(T^2; \mathbb{Z}) = \mathbb{Z}^2$, $H_2(T^2; \mathbb{Z}) = \mathbb{Z}$; po przejściu do $\mathbb{Q}$ liczby punktów krytycznych są już równe liczbom Betti'ego. Wzór (22.3.3) zmusza wszystkie r_k do zera. Macierze całkowite o zerowym rzędzie nad $\mathbb{Q}$ są zerowe, więc $\partial = 0$ również nad $\mathbb{Z}$. Geometrycznie podpisane liczby trajektorii między sąsiednimi indeksami znoszą się w sumie.

22.7 Jak to prowadzi do Smale'a i chirurgii?

Funkcja Morse'a opisuje rozmaitość przez uchwyty. Dla kobordyzmu W między M_- i M_+ analogicznie wybiera się funkcję stałą na składowych brzegu; jej punkty krytyczne dają uchwyty dołączane do $M_- \times [0,1]$. Skoro dołączenie uchwytu indeksu λ zmienia topologię określonego obszaru, można pytać, kiedy sąsiednie uchwyty się znoszą, kiedy da się przestawiać ich kolejność i jakie przeszkody pozostają. To są kolejne kroki na drodze do twierdzenia o h-kobordyzmie Smale'a i teorii chirurgii.

Na rozmaitości niezwartej właściwa funkcja Morse'a z Twierdzenia 20.7.3 daje analogiczny opis *po jednym zwartym paśmie naraz*. Dla rozmaitości z brzegiem trzeba kontrolować kierunek gradientu przy brzegu i ewentualne punkty krytyczne funkcji ograniczonej do brzegu. Wyniki tego rozdziału zostały sformułowane dla zamkniętej M właśnie po to, aby takich warunków nie ukrywać.

Dalsza lektura: R. Cohen, *Morse Theory*, lemat Morse'a, uchwyty i nierówności, A. Ritter, *Morse Homology*, trajektorie i ich zliczanie, J. Weber, *The Morse–Witten complex via dynamical systems*, zwartość, sklejanie i orientacje, MIT OCW, wykłady z geometrii rozmaitości.

Indeks

algebra Liego, 113
    definicja, 114

Długość i energia krzywej, 13
druga forma podstawowa, 70
Dualność Poincarégo, 181
dwa ślady krzywizny, 71
Dwa znaczenia zupełności, 55
dysk Poincarégo, 137
Działanie swobodne, 131
Działanie właściwe, 129
działanie adjungowane, 120
działanie grupy Liego, 126
działanie skuteczne, 126

eksponenta macierzowa, 118
Element objętości i miara riemannowska, 16
Elementarna operacja chirurgiczna, 197

Funkcja wyczerpująca, 177

Geodezyjna, 43
geometria Kleina, 126
    definicja, 128
geometria Nil
    metryka, 9
geometria Sol
    metryka, 9
Gradient i dywergencja metryczna, 25
grupa afiniczna, 135
grupa euklidesowa, 135
grupa Heisenberga, 116
grupa Liego, 113
    definicja, 113
grupa ogólna liniowa, 113
grupa ortogonalna, 113
grupa specjalna unitarna, 114
gwiazda Hodge'a, 144

Hesjan i niezdegenerowany punkt krytyczny, 162
holonomia, 86
    ograniczona, 86
    pełna, 86
    struktury geometrycznej, 134

Idea klasy charakterystycznej, 190
Iloczyn kapowy i konwencja znaków, 183
Iloczyn kubkowy, 181
indeks operatora eliptycznego, 149
Indeks zera pola, 194
Izomorfizmy muzyczne, 3

Kodyferencjał, 145
Kołnierz, 175
Kompleks trajektorii Morse'a, 210
komutator macierzy, 115
koneksja, 28
Koneksja afiniczna, 28
konwencja znaku, 66
krzywizna, 66
Krzywizna geodezyjna i skręt narożnika, 104
krzywizna sekcyjna, 69

laplasjan Hodge'a, 145

metoda Bochnera, 144
Metryka indukowana, 17
Metryka lorentzowska, 10
Metryka riemannowska, 3
Miara Hausdorffa, 21
Miejsce cięcia geodezyjnej, 57

nakrycie
    SU(2) nad SO(3), 122

Obramowanie, 174
Odwzorowanie transwersalne, 157
Odwzorowanie właściwe, 166
Odwzorowanie wykładnicze, 45
odwzorowanie wykładnicze
    grupy Liego, 118
operator deformacji ASD, 152
orbifold, 132
    grupa lokalna, 132
    przestrzeń podkładowa, 132
orbita działania, 126

Para Morse'a–Smale'a, 207
Pochodna wzdłuż krzywej, 36
podgrupa dyskretna, 131

podgrupa jednoparametrowa, 116
Pole Jacobiego, 92
pole lewostronnie niezmiennicze, 114
projektowa grupa liniowa, 136
Promień injektywności, 58
przestrzeń afiniczna, 135
przestrzeń jednorodna, 126
Pullback i pushforward metryki, 5
Punkt i wartość krytyczna, 155
Punkty sprzężone, 93

$\widehat{A}$, 151
rozkład de Rhama, 88
Rozmaitości stabilna i niestabilna, 205

sfera
    przestrzeń jednorodna, 136
stabilizator punktu, 126
struktura (G,X), 133
System lokalny i system orientacji, 187

Teoria Cherna–Weila, 140
teoria Hodge'a, 144
teoria Morse'a, 199
Torsja i zgodność z metryką, 29
torus
    geometria Kleina, 137
    jako grupa Liego, 114
Transwersalność, 155
twierdzenie Atiyaha–Singera, 149
twierdzenie Gaussa–Bonneta, 104
twierdzenie o sygnaturze Hirzebrucha, 151

Wiązka normalna, 172
Wielomian niezmienniczy, 140

Zanurzenie, 166
Zbiór cięcia, 57
Zbiór miary zero na rozmaitości, 155
Znak i liczba przecięcia, 186